

Modelos ANOVA y Regresión Lineal

Modelos Matemáticos y Estadísticos Clásicos

Ana María Alvarado Celis

Julio 2026

Introducción a los Modelos Estadísticos

Introducción

Un modelo estadístico es un modelo matemático que permite asignar una estructura definida a datos muestrales mediante una serie de supuestos estadísticos.

Un modelo estadístico representa, de una manera idealizada, el proceso de generación de datos.

Usualmente los modelos estadísticos se usan para generar una estructura, comúnmente en forma de ecuaciones, que permita predecir resultados futuros a través de distintas variables. Algunos de los modelos más utilizados son:

- Análisis de Varianza (ANOVA).
- Regresión Lineal.
- Regresión Logística (Modelos Lineales Generalizados).

Introducción

La Inferencia vista anteriormente, puede ser abordada desde el punto de vista de Modelos Estadísticos.

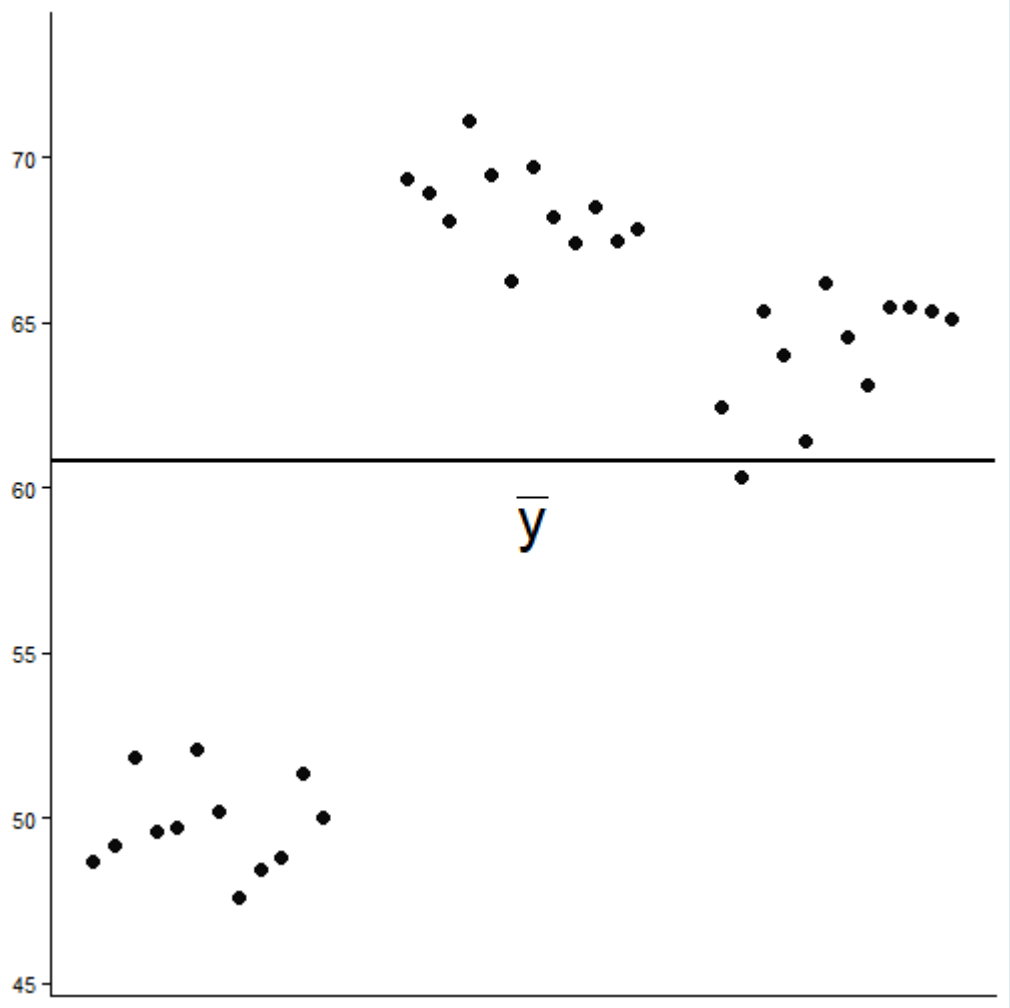
Así por ejemplo, si $Y_1, \ldots, Y_n$ es una muestra aleatoria de una distribución Normal con media μ y varianza σ^2 ambos parámetros desconocidos.

Este experimento se puede escribir en términos del siguiente modelo:

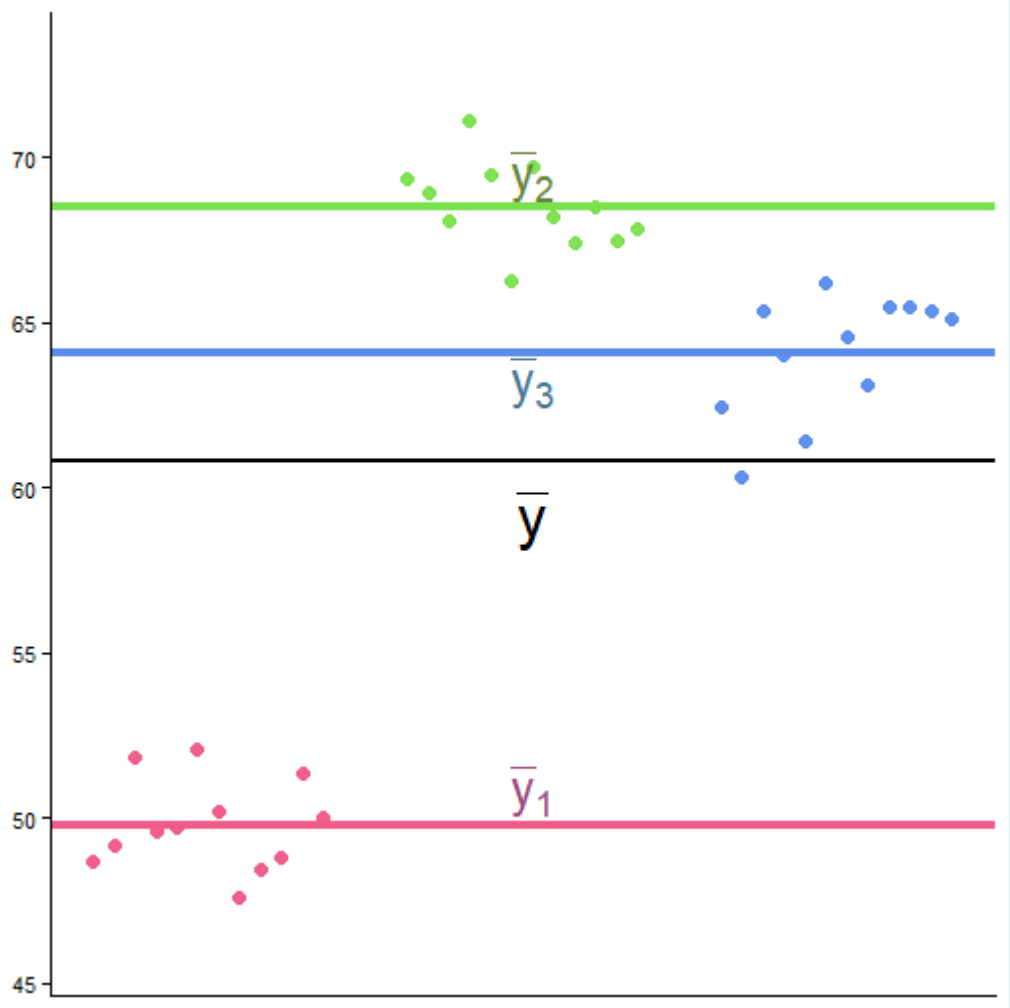
$$Y_i = \mu + \epsilon_i \qquad i = 1, \ldots, n$$

donde ϵ_i tienen distribución normal con media cero y varianza σ_2.

Introducción



Introducción



Test de Hipótesis y Valor-p

Los test de hipótesis son fundamentales en los modelos estadísticos, es por ello que se deben tener claros los conceptos de test de hipótesis y valor-p.

Test de hipótesis

Un **Test de Hipótesis**, se define como el proceso que permite, mediante una muestra, aceptar o rechazar una suposición planteada sobre un parámetro desconocido de la población. En los Test de Hipótesis se definen dos hipótesis complementarias:

- **Hipótesis Nula** (H_0)
- **Hipótesis Alternativa** (H_1)

En los test de hipótesis buscaremos evidencia para rechazar o no la hipótesis nula.

Test de Hipótesis y Valor–p

Valor-p

El valor-p se define como la probabilidad extrema bajo el supuesto de que H_0 es cierto. La interpretación más simple es:

"Valor-p es el error que se comete cuando se rechaza la hipótesis nula, mientras que la significancia será el error máximo que se desea cometer."

Entonces, si tenemos que el **valor-p es menor que nuestro nivel de significancia**, se rechaza la hipótesis nula.

Considere un estadístico observado t desde una distribución desconocida T. Entonces el valor-p es:

- $p = P(T \geq t|H_0)$ para un test de de cola superior.
- $p = P(T \leq t|H_0)$ para un test de de cola inferior.
- $p = 2 \cdot \min\{P(T \geq t|H_0),\ P(T \leq t|H_0)\}$ para un test de dos colas.

Supuestos

Los modelos estadísticos se basan en supuestos estadísticos para su creación, es por esto que debemos probar mediante test de hipótesis si nuestros modelos cumplen estos para justificar que estamos usándolos correctamente. Los supuestos más comunes son:

- **Normalidad**: En general, los modelos estadísticos clásicos tienen componentes de error a los cuales se le asume una distribución Normal en su contrucción. Hay diferentes herramientas visuales y test de hipótesis que permiten probar si un conjunto de datos sigue una distribución Normal.

- **Homocedasticidad**: Un vector de variables aleatorias es homocedástico si la variabilidad es "constante" a lo largo de todos los posibles valores de nuestra variable. La homocedasticidad es un supuesto usual incluido en los errores de los modelos.

Normalidad

Gráficos cuantil-cuantil (Q-Q Plot)

Un gráfico cuantil-cuantil nos permite analizar visualmente si una distribución se parece a otra, mediante la comparación de los cuantiles de esta. En `statsmodels.api` podemos hacer gráfico cuantil-cualtil con la distribución normal:

Desde una base de datos

```
import statsmodels.api

statsmodels.api.qqplot(df['variable'],line='q')
```

Desde un vector

```
statsmodels.api.qqplot(variable, line='q')
```

Normalidad

Test de Shapiro-Wilk

El Test de Shapiro-Wilk nos permite estudiar si un conjunto de datos pequeño (menor a 50 unidades) distribuye de forma normal, este test tiene las siguientes hipótesis.

H_0 : Los datos siguen una distribución Normal.

H_1 : Los datos no siguen una distribución Normal.

En Python: `scipy.stats.shapiro(variable)`

Normalidad

Test de Kolmogorov-Smirnov

El Test de Kolmogorov-Smirnov nos permite comparar si un conjunto de datos proviene de una distribución especificada. En este caso usaremos la distribución Normal.

H_0 : Los datos siguen una distribución Normal.

H_1 : Los datos no siguen una distribución Normal.

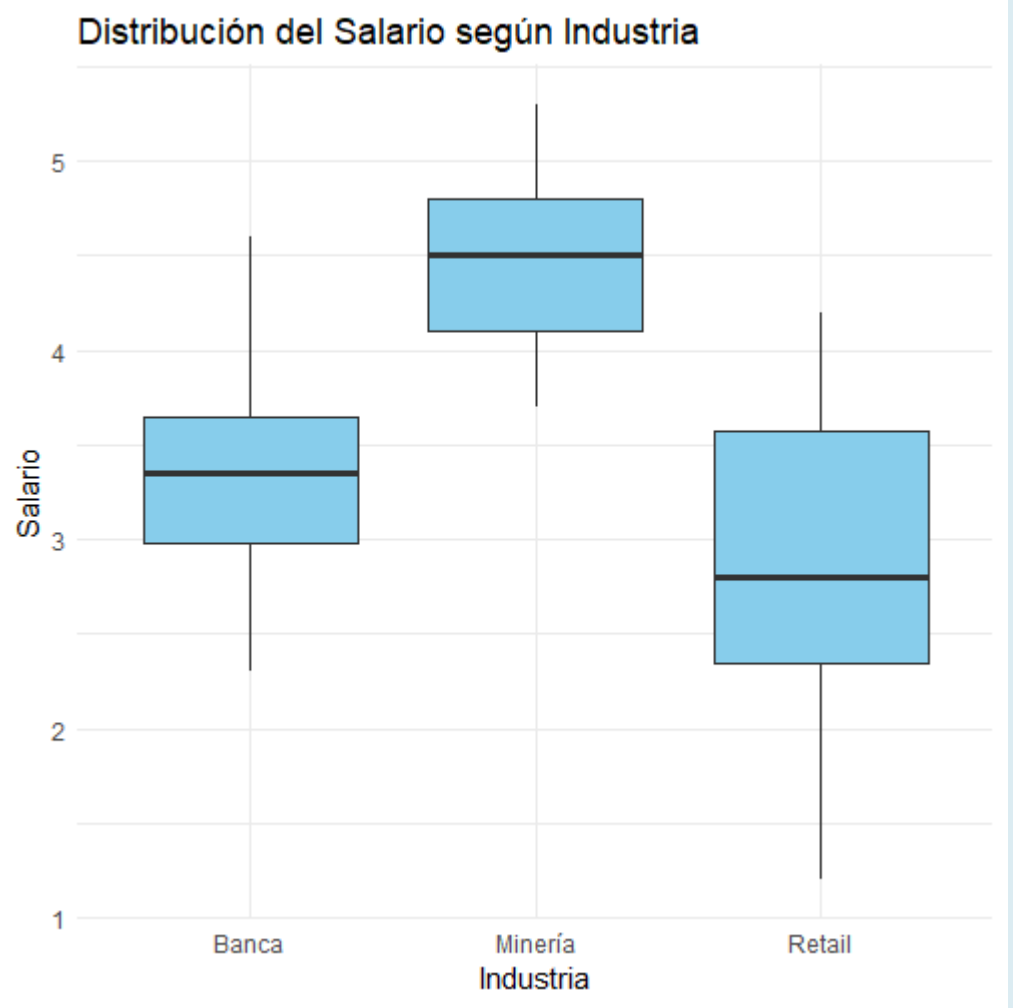
En Python: `scipy.stats.kstest(variable, cdf, alternative)`

En ambos test buscamos valores-p altos, es decir, buscamos no rechazar la hipótesis de normalidad.

Modelos ANOVA

¿Cómo podría saber si el salario promedio es diferente entre personas que trabajan en banca, retail o minería?

Ejemplo


Distribución del Salario según Industria
Salario
5
4
3
2
1
Banca
Minería
Retail
Industria

Modelos ANOVA

ANOVA es una forma de comparar las medias de varios grupos a la vez, usando la variabilidad entre y dentro de los grupos.

De manera formal, el objetivo es comparar la media de k poblaciones (o grupos) independientes entre sí. De cada población se extrae una muestra de tamaño n_j. La estructura de los datos es:

Población			
1	2	...	k
y_{11}	y_{12}	...	y_{1k}
y_{21}	y_{22}	...	y_{2k}
...	...	...	...
$y_{n_1 1}$	$y_{n_2 2}$	...	$y_{n_k k}$

Se tiene que:

- La población está definida por el sub-índice j. Se tiene con $j \in \{1, \ldots, k\}$
- La unidad dentro de cada tratamiento está definida por el sub-índice i. Se tiene $i \in \{1, \ldots, n_j\}$

Con esto, la observación y_{ij} corresponde a la i-ésima observación de la j-ésima población (o grupo).

Modelos ANOVA

- y_{ij} es la característica medida en la i-ésima unidad experimental correspondiente a la j-ésima población.
- $n = \sum_{j=1}^{j} n_j$ es el total de unidades experimentales.
- $\bar{y}_j$ es el estimador de μ_j en la j-ésima población $\bar{y}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} y_{ij}$
- s_j^2 es la estimación de la varianza σ_j^2 de la j-ésima población:

$$s_j^2 = \frac{1}{n_j - 1} \sum_{i=1}^{n_j} (y_{ij} - \bar{y}_j)^2$$

- $\bar{y}$ es la media global, es decir, considerando todas las unidades experimentales:

$$\bar{y} = \frac{1}{n} \sum_{j=1}^{k} \sum_{i=1}^{n_j} y_{ij}$$

Comparación de k tratamientos

Sea μ_j la media del j-ésimo nivel de la población con $j \in \{1, \ldots, k\}$. Con nuestra muestra nos gustaría testear si existe algún grupo dentro de los k que tenga una media estadísticamente diferente de las demás. Es decir, se desea testear:

$$H_0 : \mu_1 = \mu_2 = \ldots = \mu_k \qquad vs \qquad H_1 : \mu_p \neq \mu_q \text{ para algún } (p, q) \text{ con } p \neq q$$

¿Existe algún método que nos permita modelar esto?

Modelo ANOVA de un factor

El modelo ANOVA de un factor describe una técnica para evaluar los efectos de distintos tratamientos sobre una variable respuesta continua, mediante la comparación de medias. Este modelo está definido por:

$$y_{ij} \;=\; \mu + \alpha_j + \varepsilon_{ij}, \quad \text{con } \varepsilon_{ij} \overset{\text{iid}}{\sim} \text{Normal}(0, \sigma^2)$$

donde:

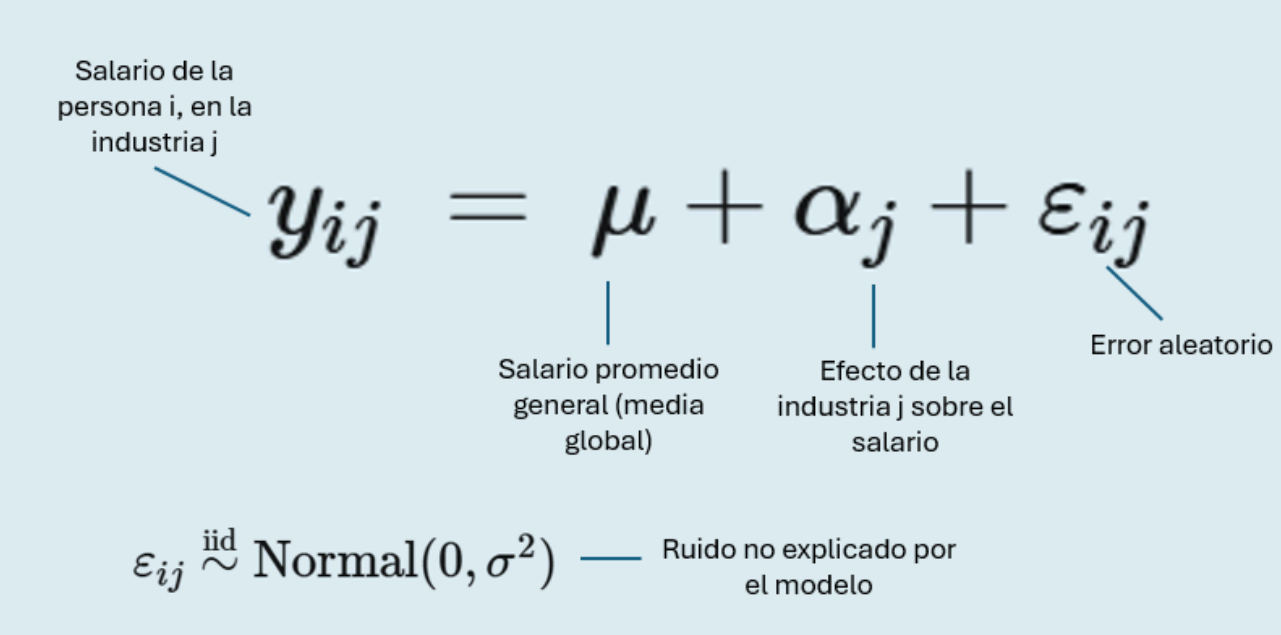
- μ se conoce como la media global.
- α_j se conoce como el efecto i-ésimo tratamiento, con $j \in \{1, \ldots, k\}$.

Con esto definimos $\mu_j = \mu + \alpha_j$ como la media poblacional del j-ésimo tratamiento.

Se tiene que ε_{ij} es el error debido a factores no controlados, al cual se le asume una distribución Normal con varianza constante e igual entre grupos (homocedasticidad). Este supuesto implica que $y_{ij} \overset{\text{iid}}{\sim} Normal(\mu_j, \sigma^2)$

Modelo ANOVA de un factor

En el ejemplo podemos definirlo de la siguiente forma:



El salario de cada persona se explica como el salario promedio global, más un ajuste según la industria en la que trabaja, más un residuo que representa todo lo que no está incluido en el modelo.

Modelo ANOVA de un factor

Para poder estimar los parámetros se impone una restricción sobre los α_j, como por ejemplo $\sum_{j=1}^{k} \alpha_j = 0$ ó $\alpha_j = 0 \,\text{para algún}\, j$. Sin alguna de estas restricciones el modelo no sería identificable y, por consiguiente, sus parámetros no tendrían una interpretación única.

Un modelo ANOVA realiza el análisis a la variabilidad total de los datos, y las compara con la variabilidad de cada grupo, realizando las pruebas necesarias para determinar si el factor tiene algún tipo de efecto. Para construtir el test se utiliza la descomposición de la suma de cuadrados:

$$\underbrace{\sum_{j=1}^{k}\sum_{i=1}^{n_j}(y_{ij}-\bar{y})^2}_{SCTotal} = \underbrace{\sum_{j=1}^{k}\sum_{i=1}^{n_j}(\bar{y}_j-\bar{y})^2}_{SCTrat} + \underbrace{\sum_{j=1}^{k}\sum_{i=1}^{n_j}(y_{ij}-\bar{y}_j)^2}_{SCError}$$

Modelo ANOVA de un factor

Donde:

- $SCTotal$ = Variabilidad total.
- $SCTrat$ = Mide la variación entre las medias de cada tratamiento y la media global.
- $SCError$ = Mide la variabilidad que no captura el modelo ANOVA.

La tabla ANOVA es:

Fuente de variación	g.l.	Sumas de cuadrado	Medias cuadráticas	Estadístico F
Tratamientos	k - 1	SCTrat	$MCTrat = \frac{SCTrat}{k-1}$	$F = \frac{MCTrat}{MCError}$
Error	n - k	SCError	$MCError = \frac{SCError}{n-k}$	~
Total	n - 1	SCTotal	~	~

Modelo ANOVA de un factor

Luego, para testear:

$H_0 : \mu_1 = \mu_2 = \ldots = \mu_k$

$H_1 : \mu_p \neq \mu_q$ para algún (p,q) con p distinto de q.

El estadístico de prueba es:

$$F = \frac{MCTrat}{MCError} \sim F(k-1,\ n-k)$$

Con un nivel α de significancia, se rechaza H_0 en favor de H_1 si $F > F(k-1,\ n-k,\ 1-\alpha)$

Si se rechaza H_0 es necesario saber entre qué pares de poblaciones hay diferencias.

Ejemplo

En esta actividad trabajarán con el archivo *salarios.xlsx*, que contiene información de un conjunto de trabajadores. Para cada persona se dispone de las siguientes variables:

- Salario: ingreso mensual del trabajador (variable numérica).
- Industria: sector económico en el que se desempeña (variable categórica).
- Sexo: sexo del trabajador (variable categórica).
- Años de experiencia: experiencia laboral acumulada (variable numérica).

El objetivo es investigar si existen diferencias en el salario promedio entre distintos grupos y construir un modelo estadístico que permita explicar la variabilidad de los salarios.

Ejemplo

En Python el comando `ols()`, de la biblioteca `statsmodels.formula.api`, toma una fórmula que describe la relación entre las variables en el modelo y los datos que se utilizarán. La función `anova_lm()`, de la biblioteca `statsmodels.api.stats`, nos permite realizar el análisis de varianza y devuelve una tabla de resultados:

```
import statsmodels.formula.api as smf
import statsmodels.api as sa
modelo = smf.ols(formula, data, ...).fit()
anova_resultados = sa.stats.anova_lm(modelo)
```

En donde:

- **`formula`** corresponde a una fórmula del estilo `variable_respuesta ~ variable_predictora`. En el caso de un `ols` la variable respuesta corresponde a una variable numérica continua.
- **data** corresponde a la base de datos que contiene las variables incluidas en `formula` para definir el modelo.

Ejemplo

El comando `ols()` utiliza el primer factor como referencia, esto significa que su efecto está incluido en la media general (Intercept). Esto implica que la interpretación de los parámetros se hacen en relación al tratamiento de referencia.

El objeto generado por `ols()` es una clase, en donde en su interior contiene distintos métodos útiles para el ajuste del modelo.

Con la sentencia `.params` podemos acceder a los coeficientes del modelo, estos son:

```
modelo.params
```

Modelo ANOVA de un factor

Para saber entre qué pares de poblaciones hay diferencias podemos realizar múltiples pruebas T-Student para comparar dos muestras. El problema es que al realizar múltiples comparaciones se aumenta el error tipo I (Rechazar H_0 cuando H_0 es verdadero).

Por ejemplo si tenemos 4 grupos, necesitamos hacer $c = \binom{4}{2} = 6$ comparaciones. Considerando un error tipo I de $\alpha = 0,05$ por comparación, tenemos que el nuevo error tipo I sube a 0.3.

Una solución conservadora es hacer la llamada correción por Bonferroni, la cual consiste en calcular un nuevo valor de α^* con el cual calcular el valor de la tabla T para tomar la decisión acerca de rechazar o no la hipótesis nula. Este nuevo valor se calcula de la siguiente manera:

$$\alpha^* = \frac{\alpha}{c}$$

Modelo ANOVA de un factor

Una segunda alternativa son los test especializados, los cuales corrigen por el número de comparaciones. Entre ellos tenemos:

- Test de Scheffé recomendado cuando hay distinto número de observaciones por tratamientos.
- Test de Tukey recomendado cuando hay el mismo número de observaciones por tratamientos.

Modelo ANOVA de un factor

Test de Scheffé

El test de Scheffé se realiza con el comando `posthoc_scheffe()` de la biblioteca `scikit_posthocs`. Este se usa de la siguiente forma:

```
posthoc_scheffe(Datos, val_col = y, group_col= trt)
```

- y: La variable dependientes (entre comillas).
- trt: La variable tratamiento a probar (entre comillas).
- Datos: DataFrame que posee los datos a utilizar.

Modelo ANOVA de un factor

Test de Tukey

La prueba de Tukey es otro método que tiene como fin comparar las medias individuales provenientes de un análisis de varianza de varias muestras sometidas a tratamientos distintos.

En Python el comando `pairwise_tukeyhsd()`, de la biblioteca `statsmodels.stats.multicomp`, crea una serie de intervalos de confianza de las diferencia de las medias dado una familia de factores. Los intervalos están basados en el estadístico de rango studentizados de Tukey. Este funciona de la siguiente forma:

```
pairwise_tukeyhsd(Datos['Valores'], Datos['Tratamientos'], alpha)
```

Donde:

- **Datos['Valores']**: Columna que contiene las variable dependientes.
- **Datos['Tratamientos']**: Columna que contiene las variables independientes.
- **alpha**: Nivel de significancia.

Modelo ANOVA de un factor

Supuestos del modelo

Los supuestos del modelo se analizan mediante los residuos, que es la diferencia entre los datos reales y el ajuste del modelo. Podemos obtener directamente los residuos con la sentencia `.resid`.

Con los residuos del modelo podemos probar la normalidad.

```
from scipy.stats import shapiro
stat, p_valor = shapiro(modelo.resid)
```

Modelo ANOVA de dos factores

El modelo ANOVA de dos factores aditivo:

$$y_{ijk} \ = \ \mu + \alpha_j + \beta_k + \varepsilon_{ijk}, \quad \text{con } \varepsilon_{ijk} \overset{\text{iid}}{\sim} \text{Normal}(0, \sigma^2)$$

, donde:

- μ se conoce como la media global.
- α_j se conoce como el efecto j-ésimo tratamiento, con $j \in \{1, \ldots, J\}$.
- β_k se conoce como el efecto k-ésimo tratamiento, con $k \in \{1, \ldots, K\}$.

Modelo ANOVA de dos factores en R

Cuando se define un modelo ANOVA con más de un factor, estos ingresan de manera aditiva a el argumento `formula`. El caso de un ANOVA de dos factores se define de la siguiente forma:

```
aov(respuesta ~ factor1 + factor2, datos)
```

Ejemplo

El objeto `ENS.csv` contiene información de una muestra de 350 observaciones proveniente de la la Encuesta Nacional de Salud.

A continuación se presenta una descripción de las variables contenidas en la base de datos:

Variable	Descripción
COLESTEROL	Niveles de Colesterol.
EDAD	Joven: Menor a 30 años, Adulto: Entre 30 y 60 años, Adulto Mayor: Mayor a 60 años.
FUMA	Indica si la persona es fumadora.
DEPORTE	Indica si la persona realiza deporte todas las semanas.

Ejemplo: ANOVA de dos factores en R

Supongamos que se quiere predecir la variable colesterol dado la edad del paciente y si éste realiza deporte semanalmente. Este modelo se ajusta de la siguiente forma:

```
##               Df Sum Sq Mean Sq F value   Pr(>F)
## DEPORTE        1  18789   18789   12.16 0.000553 ***
## EDAD           2  90908   45454   29.41 1.64e-12 ***
## Residuals    342 528613    1546
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## 4 observations deleted due to missingness
```

En este caso ambas variables son significatvas al 0.1% de confianza, por lo que las dejamos con seguridad en el modelo.

Modelo ANOVA con interacciones

El modelo ANOVA de dos factores aditivo con interacción ...

$$y_{ijk} \ = \ \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + \varepsilon_{ijk}, \quad \text{con } \varepsilon_{ijk} \overset{\text{iid}}{\sim} \text{Normal}(0, \sigma^2)$$

, donde:

- μ se conoce como la media global.
- α_j se conoce como el efecto j-ésimo tratamiento, con $j \in \{1, \ldots, J\}$.
- β_k se conoce como el efecto k-ésimo tratamiento, con $k \in \{1, \ldots, K\}$.
- $(\alpha\beta)_{jk}$ se conoce como la interacción j-ésimo tratamiento del efecto 1 con el k-ésimo tratamiento del efecto 2, con $j \in \{1, \ldots, J\}$ y $k \in \{1, \ldots, K\}$.

Ejemplo: Modelo ANOVA de dos factores con interacción en R

Hay distintas formas para definir este modelo en R, estas se ven a continuación:

- Al usar `*` entre dos factores le estamos indicando al R que incluya ambos factores y además la interacción.

```
aov(respuesta ~ factor1*factor2, datos)
```

- Al usar `:` entre dos factores, estaremos considerando la interacción entre las dos variables. Para tener un modelo completo tenemos que ingresar esta interacción como un factor aditivo, de la siguiente forma:

```
aov(respuesta ~ factor1 + factor2 + factor1:factor2, datos)
```

Ejemplo: ANOVA de dos factores con interacción en R

Supongamos que se quere predecir la variable colesterol dado la edad del paciente y si este realiza deporte semanalmente, en este caso, considerando las interacciones entre ambas variables predictoras. Este modelo se define en R de la siguiente forma:

```
##                Df Sum Sq Mean Sq F value   Pr(>F)
## DEPORTE         1  18789   18789  12.207 0.000539 ***
## EDAD            2  90908   45454  29.532 1.49e-12 ***
## DEPORTE:EDAD    2   5308    2654   1.724 0.179847
## Residuals     340 523305    1539
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## 4 observations deleted due to missingness
```

En este caso tenemos que la interacción no es significativa ni a un 10%, en este caso sería recomendable no incorporarlo en el modelo.

Regresión Lineal

¿Podemos predecir el salario de una persona según años de experiencia?

Ejemplo


Relación entre experiencia y sueldo
Sueldo mensual (millones)
Años de experiencia
1
2
3
4
5
5
10
15
20

Modelo de Regresión Lineal

Supongamos que interesa pronosticar el resultado de una variable, Y, basándose en valores de otras variables, $X_1, \ldots, X_n$

Supongamos que tenemos una medición continua.

Interesa pronosticar, mediante una combinación lineal de variables, preferentemente independientes entre ellas, una variable de interés Y.

La recta o plano que forma está combinación lineal representa el valor esperado de Y, condicionado a la información $X_1, \ldots, X_k$.

La estimación de los coeficientes que ponderan cada variable se obtienen mediante mínimos cuadrados.

Modelo de Regresión Lineal

La regresión lineal permite:

- Modelar relaciones entre variables cuantitativas.
- Estimar e interpretar efectos (¿cuánto sube el sueldo por cada año más?).
- Predecir valores futuros.
- Medir ajuste y variabilidad del modelo.

Ejemplos:

- Estimación de variables climatológicas (temperatura, humedad, etc.)
- Consumo de gasolina de un vehículo.
- Accidentes automovilísticos.
- Pronósticos de ventas.
- Y otros diversos modelos matemáticos.

Modelo de Regresión Lineal Simple

El caso más simple es denominado Modelo de Regresión Lineal Simple, que es cuando se utiliza una variable predictora, denominada X, para pronosticar una variable respuesta Y. El modelo está dado por:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \text{con } \varepsilon_i \overset{\text{iid}}{\sim} \text{Normal}(0, \sigma^2)$$

, en donde:

- β_0 es el valor de la variable Y cuando la variable X vale 0.
- β_1 es el cambio en la variable Y cuando la variable X cambia en una unidad.

Con lo anterior se concluye que $y_i|X = x_i \sim Normal(\beta_0 + \beta_1 x_i,\ \sigma^2)$ para todo i.

Regresión lineal vs correlación

Correlación Lineal

Cuantifica como se relacionan dos variables.

El cálculo es independiente del orden o asignación de cada variable a X e Y, mide únicamente la relación entre ambas sin considerar dependencias.

A nivel experimental, se suele emplear cuando ninguna de las variables se ha controlado, simplemente se han medido ambas y se desea saber si están relacionadas.

Los estudios de correlación lineal preceden a la generación de modelos de regresión lineal.

Regresión Lineal Simple

Genera una ecuación (modelo) que, basándose en la relación existente entre ambas variables, permite predecir el valor de una a partir de la otra.

El modelo varía según qué variable se considere dependiente de la otra (lo cual no implica causa-efecto).

Es más común que una de las variables se controle y se mida la otra.

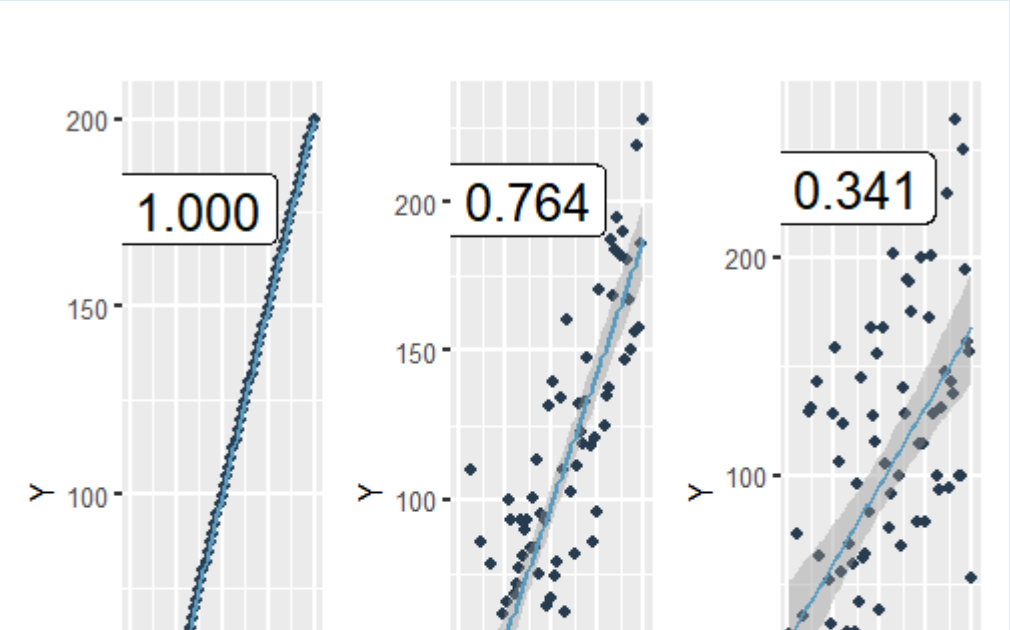
Primero se analiza si ambas variables están correlacionadas y, en caso de estarlo, se procede a generar el modelo de regresión.

Coeficiente de Determinación

El Coeficiente de Determinación R^2 es un índice que indica la calidad del ajuste del modelo de regresión lineal a los datos muestrales. Un ajuste perfecto daría como resultado $R^2 = 1$, y un ajuste muy bueno da como resultado un valor cercano a 1. Un menor ajuste se relaciona con un valor de R^2 cercano a 0.

Este estadístico es una de las principales herramientas usadas para la selección de modelos. Un modelo de regresión lineal es preferible a otro si tiene menos variables y mayor R^2.

```
## Warning: package 'patchwork' was built under R version 4.4.3
```



Prueba de hipótesis

Pruebas de hipótesis para los parámetros

Probar si los parámetros obtenidos son significativos implica comprobar si la variable explica a la respuesta.

$$H_0 : \beta_i = 0 \qquad vs. \qquad H_1 : \beta_i \neq 0$$

Se realizá un test t individual para cada parámetro. Además, se puede obtener los intervalos de confianza de cada uno de ellos.

Pruebas de hipótesis para la significancia del modelo

Probar si al menos uno de los parámetros es significativo.

$$H_0 : \beta_1 = \beta_2 = \ldots \beta_k = 0 \qquad vs. \qquad H_1 : Algún\ \beta_i \neq 0$$

Se realiza un test F a partir de la tabla ANOVA del modelo. En este caso, se reemplaza la idea de Tratamiento por Regresión.

Residuos

Para estimar la ecuación de la recta de regresión utilizamos el método de mínimos cuadrados.

Al ajustar cualquier recta a un conjunto de datos existen pequeñas diferencias entre

- los valores estimados por la recta
- los valores reales observados.

Consideramos los residuos, como la diferencia entre el valor real y el valor predicho. O bien, las distancias verticales entre cada punto y la recta.

$$\epsilon_i = y - \hat{y}_i$$

```
residals()
rstudent()
fitted()
```

¡ Gracias !

Ana María Alvarado

amalvara@uc.cl