

Sesión 18: Regresión Lineal y Correlación

Modelos Matemáticos y Estadísticos Clásicos

Ana María Alvarado Celis

Julio 2026

Repaso

Repaso

¿Existe una brecha salarial real entre diferentes industrias o las diferencias que vemos en los datos son solo casualidad?

ANOVA de un factor

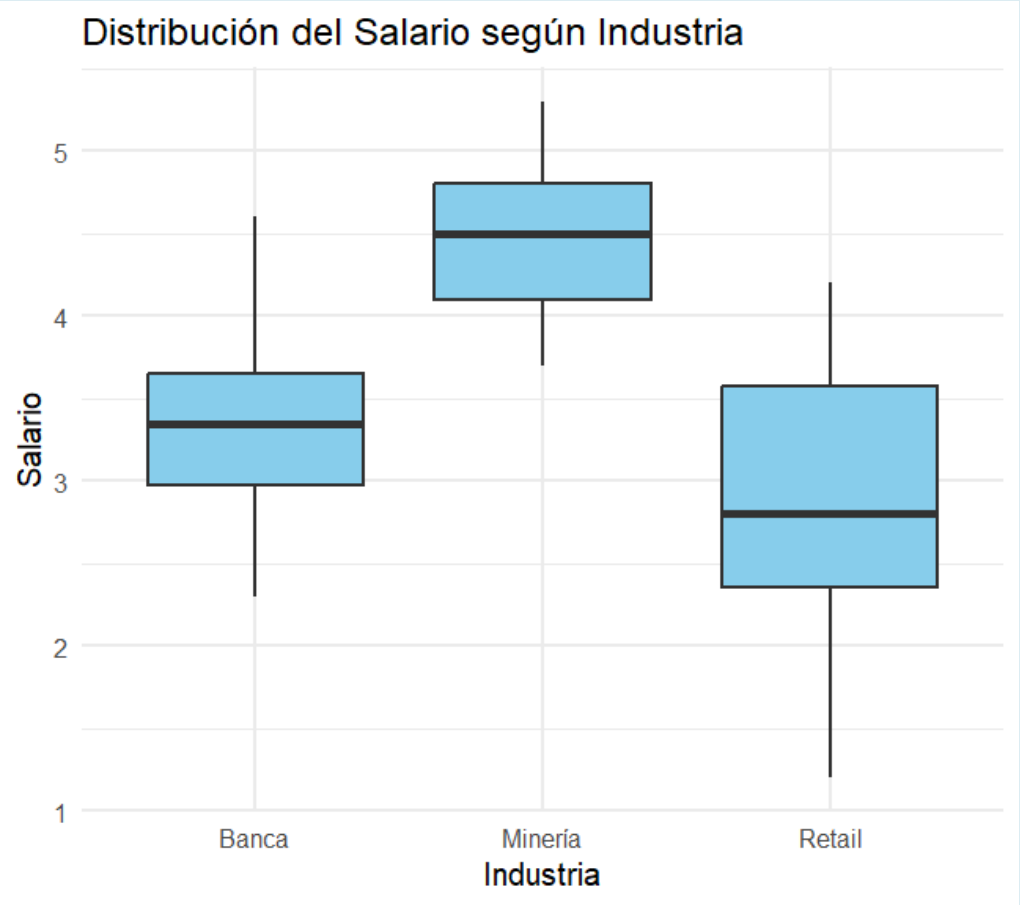
Si controlamos el factor de género, ¿las medias salariales se comportan de manera estadísticamente diferente para cada industria? ¿Cómo cuantificamos ese impacto?"

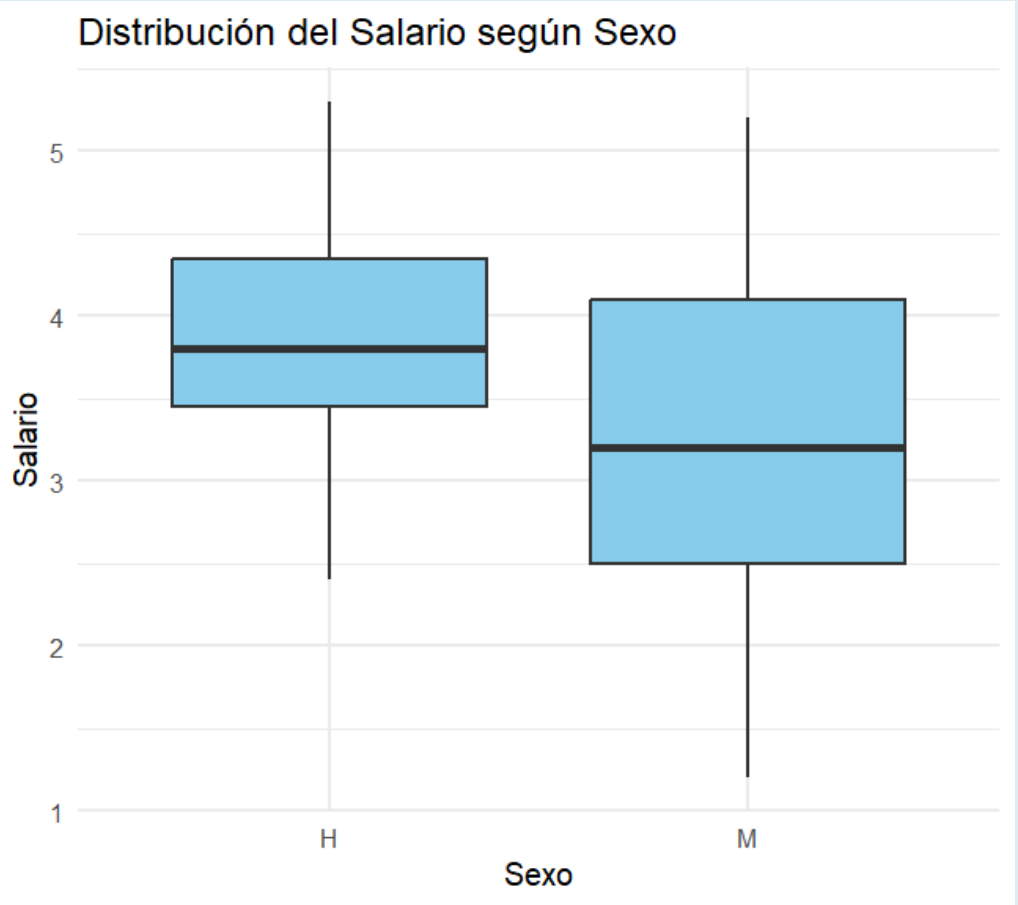
ANOVA de dos factores con efectos aditivos

¿El efecto de la industria sobre el salario es el mismo para todos los géneros, o existe un efecto combinado (interacción) que potencia o disminuye el sueldo?"

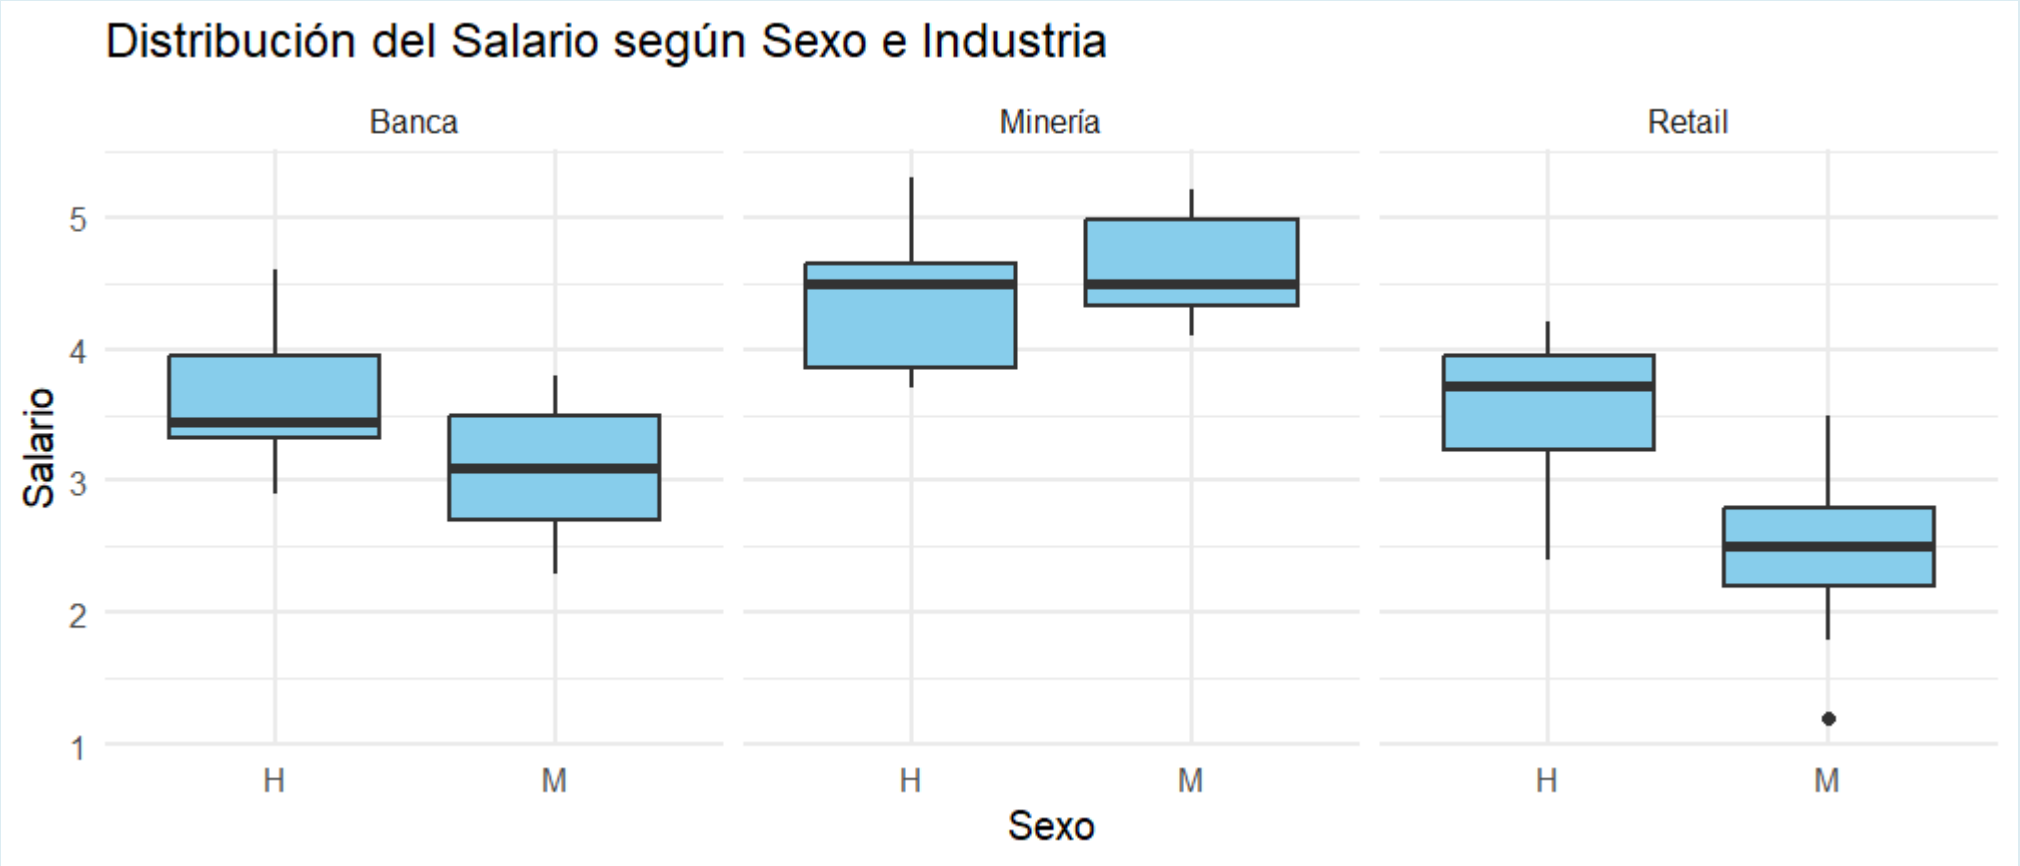
ANOVA de de dos factores con efectos multiplicativos

Ejemplo


Distribución del Salario según Industria
Salario
5
4
3
2
1
Banca
Minería
Retail
Industria

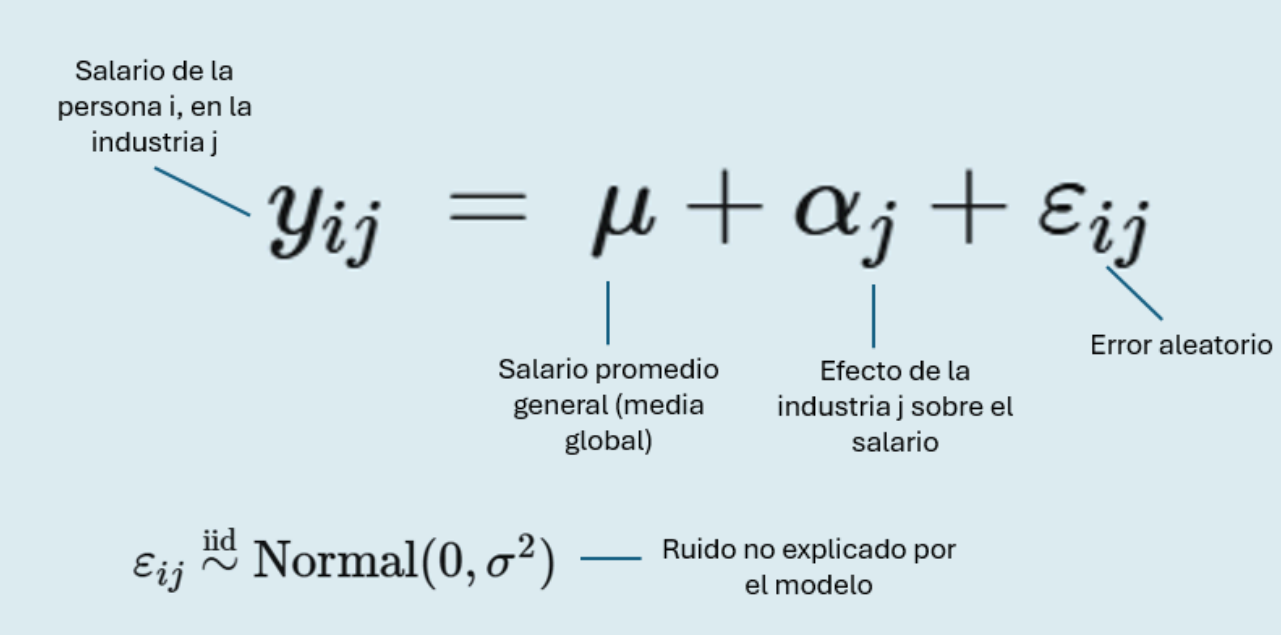

Distribución del Salario según Sexo
Salario
5
4
3
2
1
H
M
Sexo

Ejemplo


Distribución del Salario según Sexo e Industria
Banca
Minería
Retail
Salario
5
4
3
2
1
H
M
H
M
H
M
Sexo

Modelo ANOVA de un factor

En el ejemplo podemos definirlo de la siguiente forma:



El salario de cada persona se explica como el salario promedio global, más un ajuste según la industria en la que trabaja, más un residuo que representa todo lo que no está incluido en el modelo.

Modelo ANOVA de un factor

Donde:

- $SCTotal$ = Variabilidad total.
- $SCTrat$ = Mide la variación entre las medias de cada tratamiento y la media global.
- $SCError$ = Mide la variabilidad que no captura el modelo ANOVA.

La tabla ANOVA es:

Fuente de variación	g.l.	Sumas de cuadrado	Medias cuadráticas	Estadístico F
Tratamientos	k - 1	SCTrat	$MCTrat = \frac{SCTrat}{k-1}$	$F = \frac{MCTrat}{MCError}$
Error	n - k	SCError	$MCError = \frac{SCError}{n-k}$	~
Total	n - 1	SCTotal	~	~

Modelo ANOVA de un factor

Luego, para testear:

$$H_0 : \mu_1 = \mu_2 = \ldots = \mu_k$$

$H_1 : \mu_p \neq \mu_q$ para algún (p,q) con p distinto de q.

El estadístico de prueba es:

$$F = \frac{MCTrat}{MCError} \sim F(k-1,\ n-k)$$

Con un nivel α de significancia, se rechaza H_0 en favor de H_1 si $F > F(k-1,\ n-k,\ 1-\alpha)$

Si se rechaza H_0 es necesario saber entre qué pares de poblaciones hay diferencias.

Modelo ANOVA de un factor

```
summary(aov(Salario~Industria , data= df_salario))
```

```
##              Df Sum Sq Mean Sq F value   Pr(>F)
## Industria     2  17.88   8.941   18.33 2.93e-06 ***
## Residuals    37  18.05   0.488
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El valor-p es menor que 0.05. Por lo tanto, se rechaza H_0 en favor de H_1 , es decir, las diferencias de salario por industria son significativas.

Modelo ANOVA de dos factores

El modelo ANOVA de dos factores aditivo:

$$y_{ijk} = \mu + \alpha_j + \beta_k + \varepsilon_{ijk}, \quad \text{con } \varepsilon_{ijk} \overset{\text{iid}}{\sim} \text{Normal}(0, \sigma^2)$$

, donde:

- μ se conoce como la media global.
- α_j se conoce como el efecto j-ésimo tratamiento, con $j \in \{1, \ldots, J\}$.
- β_k se conoce como el efecto k-ésimo tratamiento, con $k \in \{1, \ldots, K\}$.

Modelo ANOVA de dos factores

```
summary(aov(Salario~Industria+Sexo , data= df_salario))
```

```
##              Df Sum Sq Mean Sq F value   Pr(>F)
## Industria     2 17.883   8.941  20.186 1.32e-06 ***
## Sexo          1  2.098   2.098   4.736   0.0362 *
## Residuals    36 15.947   0.443
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Modelo ANOVA con interacciones

El modelo ANOVA de dos factores aditivo con interacción ...

$$y_{ijk} \;=\; \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + \varepsilon_{ijk}, \quad \text{con } \varepsilon_{ijk} \overset{\text{iid}}{\sim} \text{Normal}(0, \sigma^2)$$

, donde:

- μ se conoce como la media global.
- α_j se conoce como el efecto j-ésimo tratamiento, con $j \in \{1, \ldots, J\}$.
- β_k se conoce como el efecto k-ésimo tratamiento, con $k \in \{1, \ldots, K\}$.
- $(\alpha\beta)_{jk}$ se conoce como la interacción j-ésimo tratamiento del efecto 1 con el k-ésimo tratamiento del efecto 2, con $j \in \{1, \ldots, J\}$ y $k \in \{1, \ldots, K\}$.

Modelo ANOVA con interacciones

```
summary(aov(Salario~Industria*Sexo , data= df_salario))
```

```
##                Df Sum Sq Mean Sq F value   Pr(>F)
## Industria       2 17.883   8.941  23.287 4.26e-07 ***
## Sexo            1  2.098   2.098   5.464   0.0254 *
## Industria:Sexo  2  2.892   1.446   3.766   0.0333 *
## Residuals      34 13.055   0.384
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Supuestos del modelo ANOVA

Los supuestos del modelo se analizan mediante los residuos, que es la diferencia entre los datos reales y el ajuste del modelo.

- Normalidad: Se espera que los errores tengan distribución normal, con media 0 y cierta varianza.
- Independencia: Los errores deben ser independientes entre si.
- Homocedasticidad: Los errores deben tener una dispersión constante en cualquier instante de la variable.

Actividad

El objeto `ENS.csv` contiene información de una muestra de 350 observaciones proveniente de la Encuesta Nacional de Salud.

A continuación se presenta una descripción de las variables contenidas en el conjunto de datos:

Variable	Descripción
COLESTEROL	Niveles de Colesterol.
EDAD	Joven: Menor a 30 años, Adulto: Entre 30 y 60 años, Adulto Mayor: Mayor a 60 años.
FUMA	Indica si la persona es fumadora.
DEPORTE	Indica si la persona realiza deporte todas las semanas.

- Indique si el grupo de edad del paciente afecta a la variable colesterol.
- Indique si el deporte afecta a la variable colesterol del paciente.
- Se puede predecir la variable colesterol dado la edad del paciente y si este realiza deporte semanalmente,
- Analice los supuestos de su modelo seleccionado.

Regresión Lineal

¿Podemos predecir el salario de una persona según años de experiencia?

Ejemplo



¿Parece que hay una relación?

¿Podríamos usar esta relación para predecir cuánto debería ganar alguien con 8 años de experiencia?

Correlación

La correlación es una medida estadística que mide la fuerza y la dirección de una relación **lineal** entre dos variables cuantitativas.

Una correlación positiva significa que cuando una variable aumenta, la otra tiende a aumentar también. Una correlación negativa significa que cuando una variable aumenta, la otra tiende a disminuir.

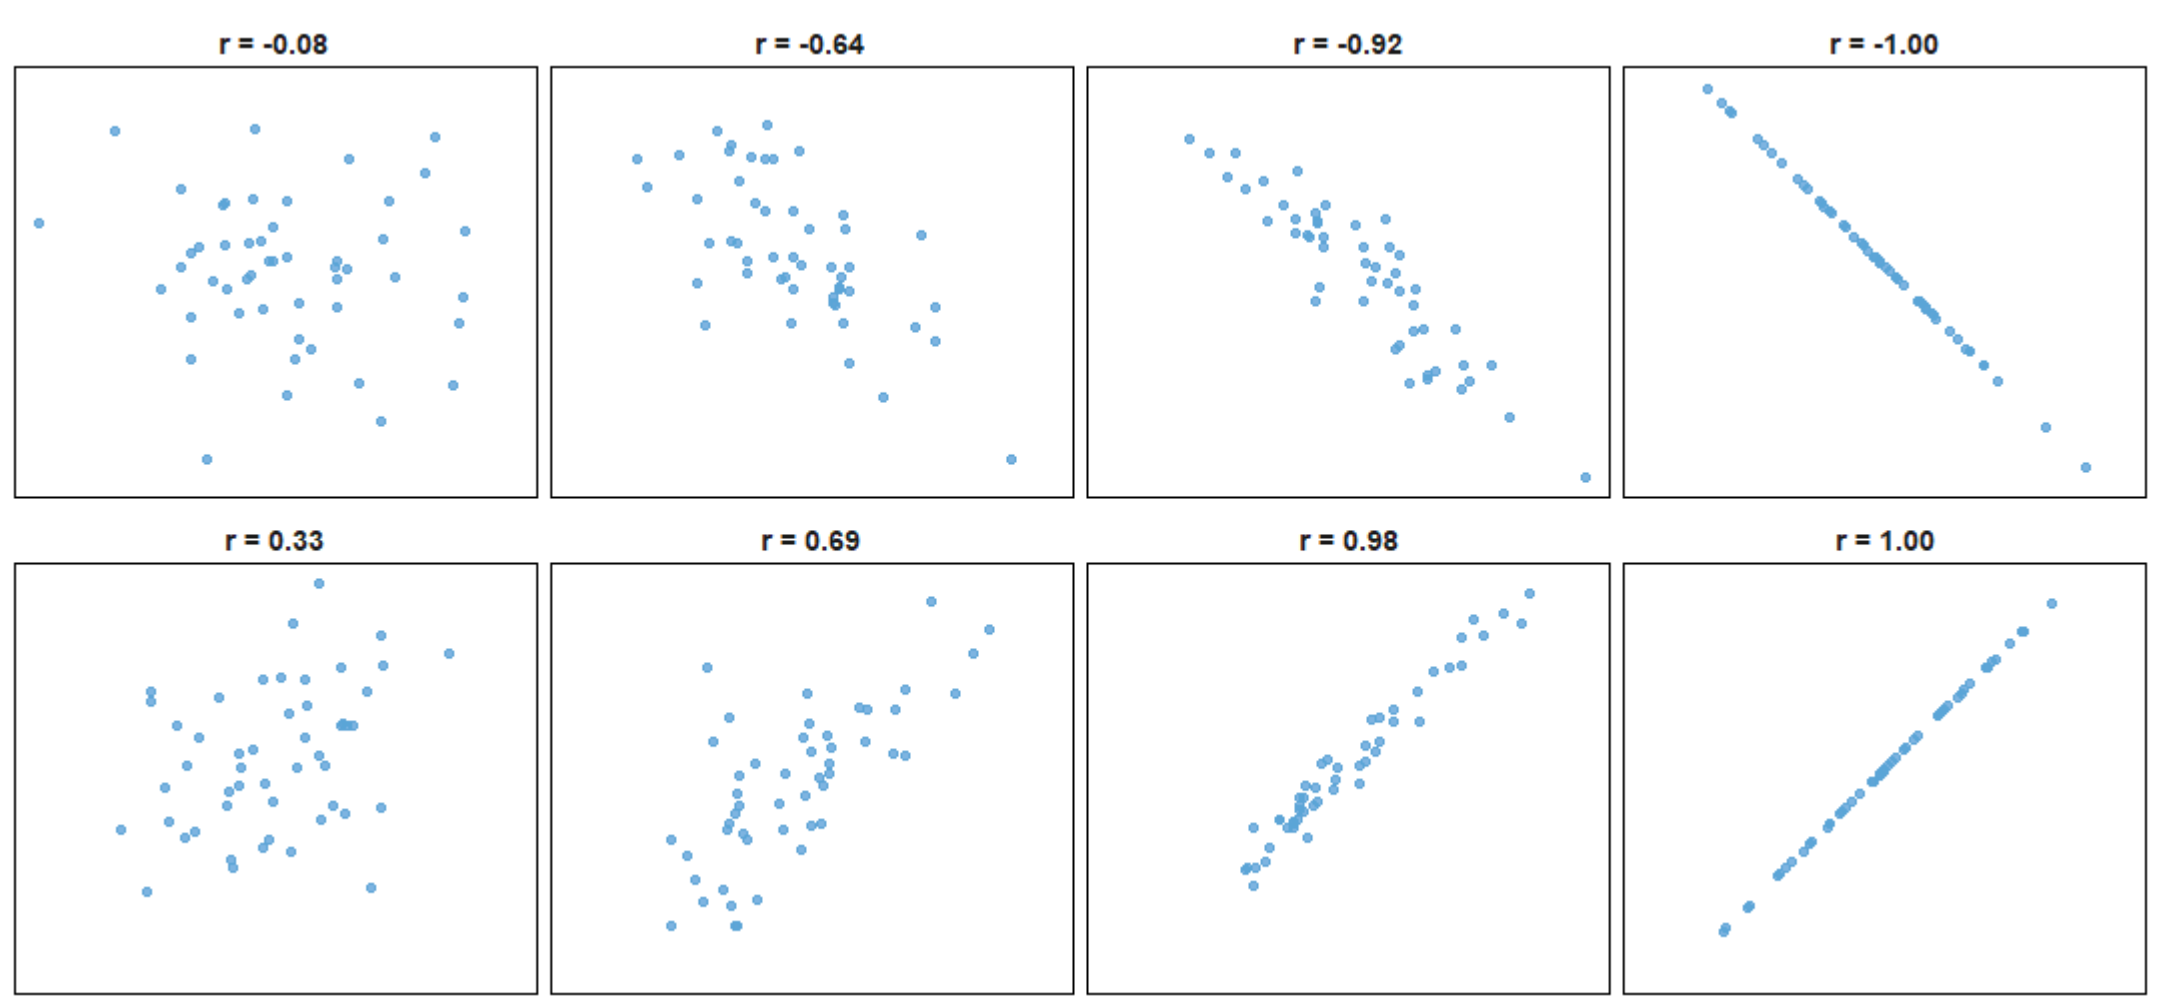
Para calcularla, el método más utilizado es el coeficiente de **correlación de Pearson** (para variables cuantitativas) o el **coeficiente de Spearman** (para variables ordinales o datos no normales).

Correlación de Pearson

El coeficiente de correlación de Pearson (r) mide la fuerza y dirección de la asociación lineal entre dos variables cuantitativas. Toma valores entre -1 y 1:

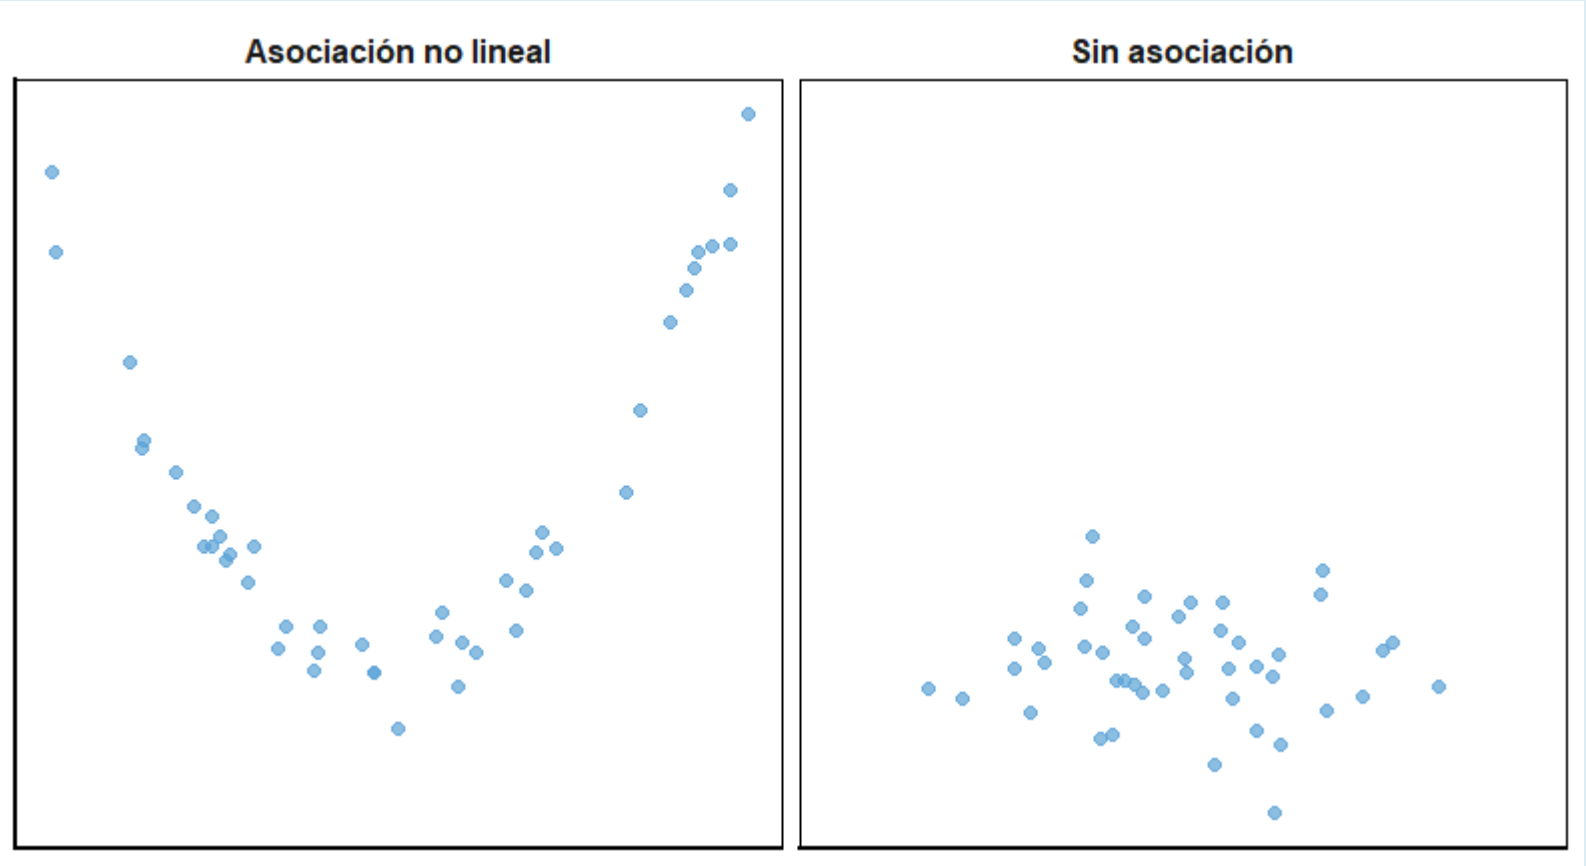
- $r \approx 1$: fuerte asociación lineal positiva.
- $r \approx -1$: fuerte asociación lineal negativa.
- $r \approx 0$: débil o nula asociación lineal.

Coeficiente de Correlación

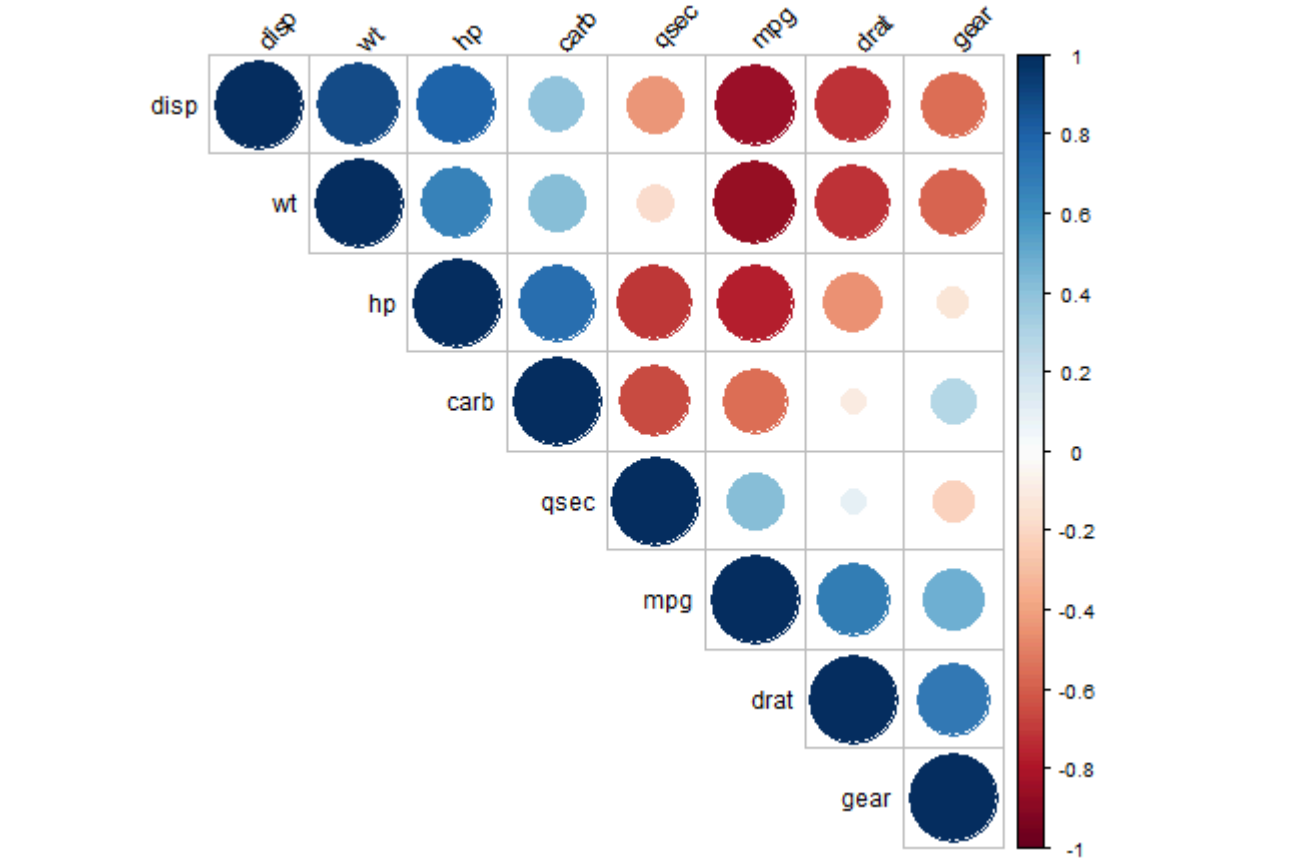


Correlación

Correlación de Pearson igual (o cercana) a 0 no implica ausencia de relación, sino únicamente ausencia de relación lineal.



Matriz de correlación



Modelo de Regresión Lineal

Supongamos que interesa pronosticar el resultado de una variable, Y, basándose en valores de otras variables, $X_1, \ldots, X_n$

Supongamos que tenemos una medición **continua**.

Interesa pronosticar, mediante una combinación lineal de variables, preferentemente independientes entre ellas, una variable de interés Y.

La recta o plano que forma está combinación lineal representa el valor esperado de Y, condicionado a la información $X_1, \ldots, X_k$.

La estimación de los coeficientes que ponderan cada variable se obtienen mediante mínimos cuadrados.

Modelo de Regresión Lineal

La regresión lineal permite:

- Modelar relaciones entre variables cuantitativas.
- Estimar e interpretar efectos (¿cuánto sube el sueldo por cada año más de experiencia?).
- Predecir valores futuros.
- Medir ajuste y variabilidad del modelo.

Ejemplos:

- Estimación de variables climatológicas (temperatura, humedad, etc.)
- Consumo de gasolina de un vehículo.
- Accidentes automovilísticos.
- Pronósticos de ventas.
- Y otros diversos modelos matemáticos.

Modelo de Regresión Lineal Simple

El caso más simple es denominado Modelo de Regresión Lineal Simple, que es cuando se utiliza una variable predictora, denominada X, para pronosticar una variable respuesta Y. El modelo está dado por:

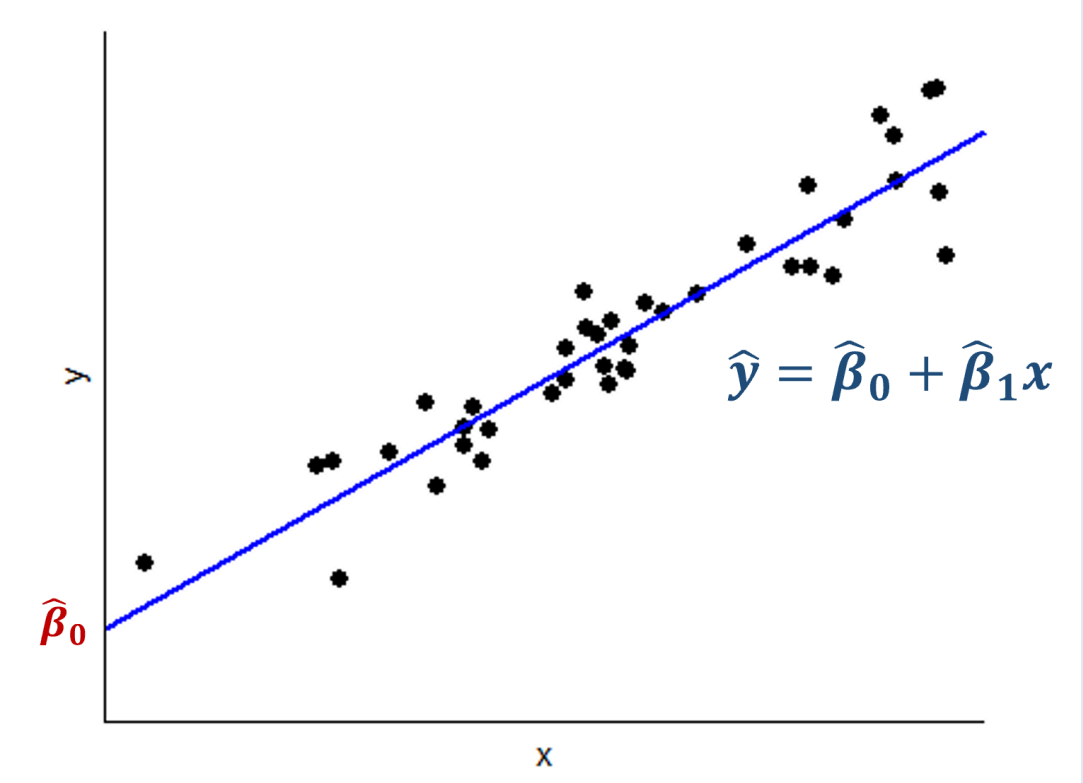
$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \text{con } \varepsilon_i \overset{\text{iid}}{\sim} \text{Normal}(0, \sigma^2)$$

, en donde:

- β_0 es el valor de la variable Y cuando la variable X vale 0.
- β_1 es el cambio en la variable Y cuando la variable X cambia en una unidad.

Con lo anterior se concluye que $y_i | X = x_i \sim Normal(\beta_0 + \beta_1 x_i,\ \sigma^2)$ para todo i.

Regresión lineal simple




```
lm(formula, data, subset, weights, na.action,
   method = "qr", model = TRUE, ...)
```

Regresión lineal vs correlación

Correlación Lineal

Cuantifica como se relacionan dos variables.

El cálculo es independiente del orden de asignación de cada variable a X e Y, mide únicamente la relación entre ambas sin considerar dependencias.

A nivel experimental, se suele emplear cuando ninguna de las variables se ha controlado, simplemente se han medido ambas y se desea saber si están relacionadas.

Los estudios de correlación lineal preceden a la generación de modelos de regresión lineal.

Regresión Lineal Simple

Genera una ecuación (modelo) que, basándose en la relación existente entre ambas variables, permite predecir el valor de una a partir de la otra.

El modelo varía según qué variable se considere dependiente de la otra (lo cual no implica causa-efecto).

Es más común que una de las variables se controle y se mida la otra.

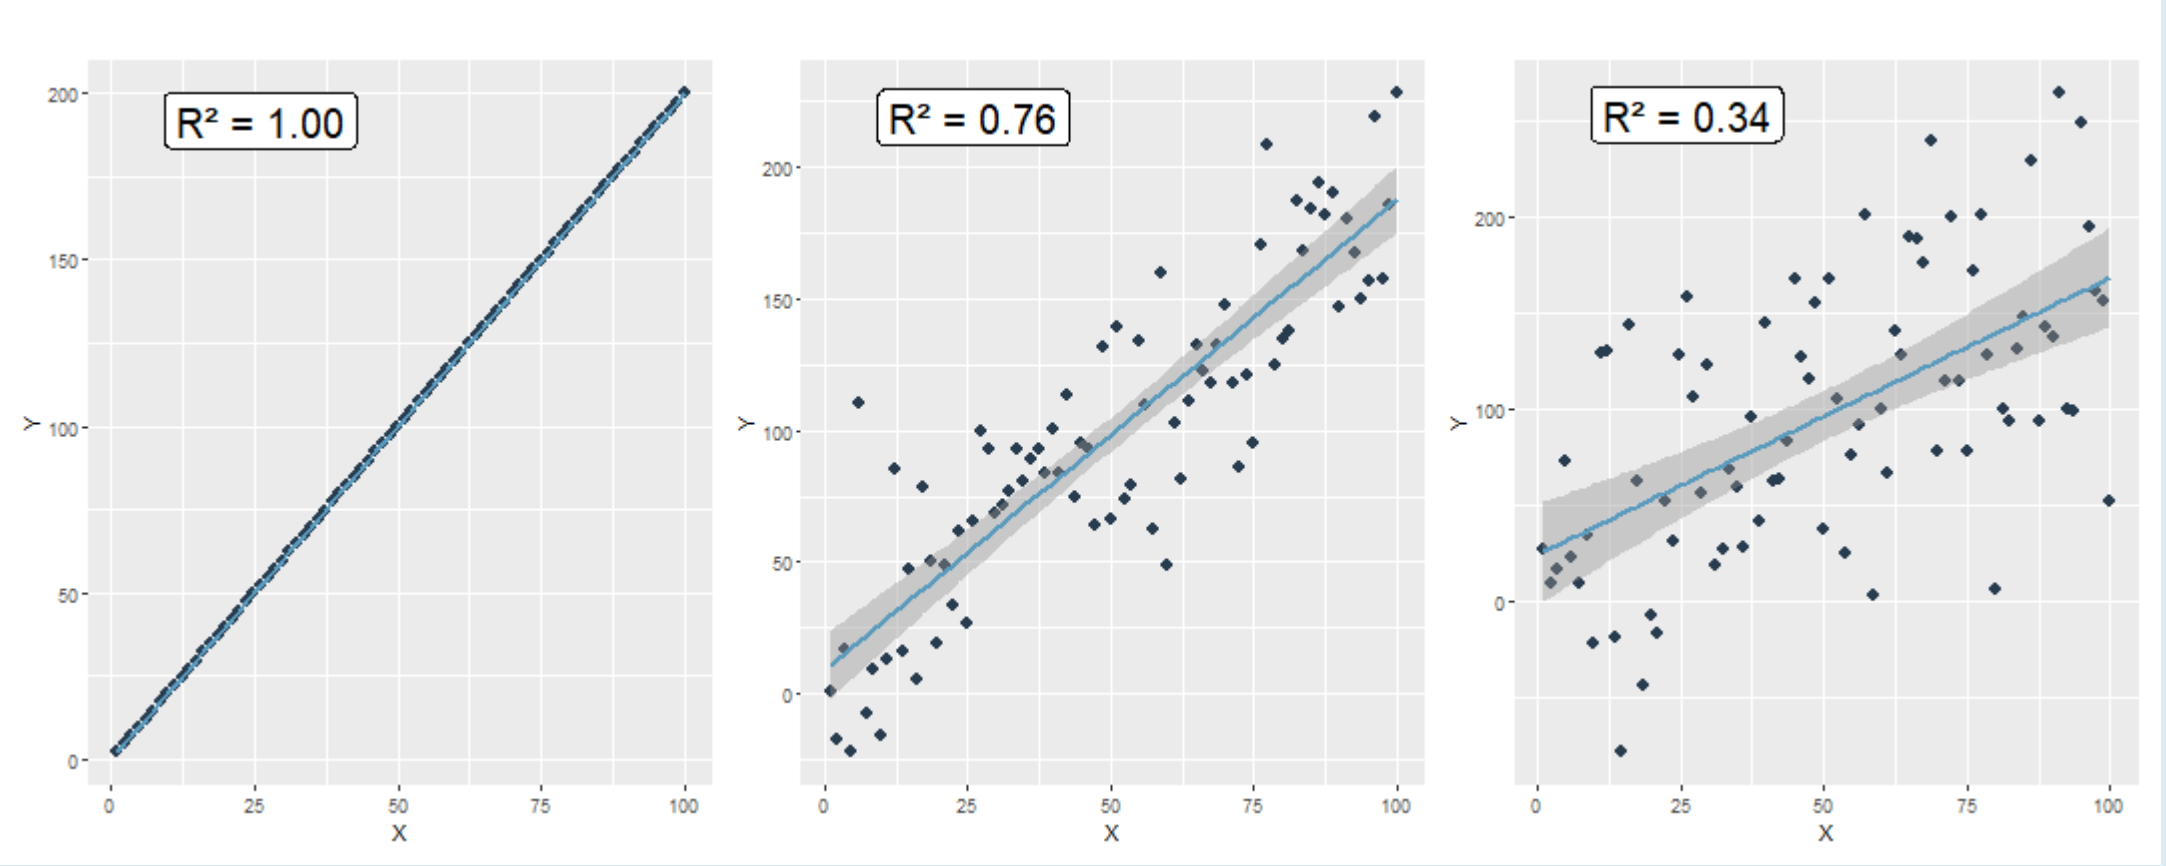
Primero se analiza si ambas variables están correlacionadas y, en caso de estarlo, se procede a generar el modelo de regresión.

Coeficiente de Determinación

El Coeficiente de Determinación R^2 es un índice que indica la calidad del ajuste del modelo de regresión lineal a los datos muestrales. Un ajuste perfecto daría como resultado $R^2 = 1$, y un ajuste muy bueno da como resultado un valor cercano a 1. Un menor ajuste se relaciona con un valor de R^2 cercano a 0.

Este estadístico es una de las principales herramientas usadas para la selección de modelos. Un modelo de regresión lineal es preferible a otro si tiene menos variables y mayor R^2.

Coeficiente de Determinación



> Nota: En regresión lineal simple esl coeficiente de determinación es igual al coeficiente de correlación al cuadrado.

Prueba de hipótesis

Pruebas de hipótesis para los parámetros

Probar si los parámetros obtenidos son significativos implica comprobar si la variable explica a la respuesta.

$$H_0 : \beta_i = 0 \qquad vs. \qquad H_1 : \beta_i \neq 0$$

Se realizá un test t individual para cada parámetro. Además, se puede obtener los intervalos de confianza de cada uno de ellos.

Pruebas de hipótesis para la significancia del modelo

Probar si al menos uno de los parámetros es significativo.

$$H_0 : \beta_1 = \beta_2 = \ldots \beta_k = 0 \qquad vs. \qquad H_1 : Algún\ \beta_i \neq 0$$

Se realiza un test F a partir de la tabla ANOVA del modelo. En este caso, se reemplaza la idea de Tratamiento por Regresión.

Residuos

Para estimar la ecuación de la recta de regresión utilizamos el método de mínimos cuadrados.

Al ajustar cualquier recta a un conjunto de datos existen pequeñas diferencias entre

- los valores estimados por la recta
- los valores reales observados.

Consideramos los residuos, como la diferencia entre el valor real y el valor predicho. O bien, las distancias verticales entre cada punto y la recta.

$$\epsilon_i = y - \hat{y}_i$$

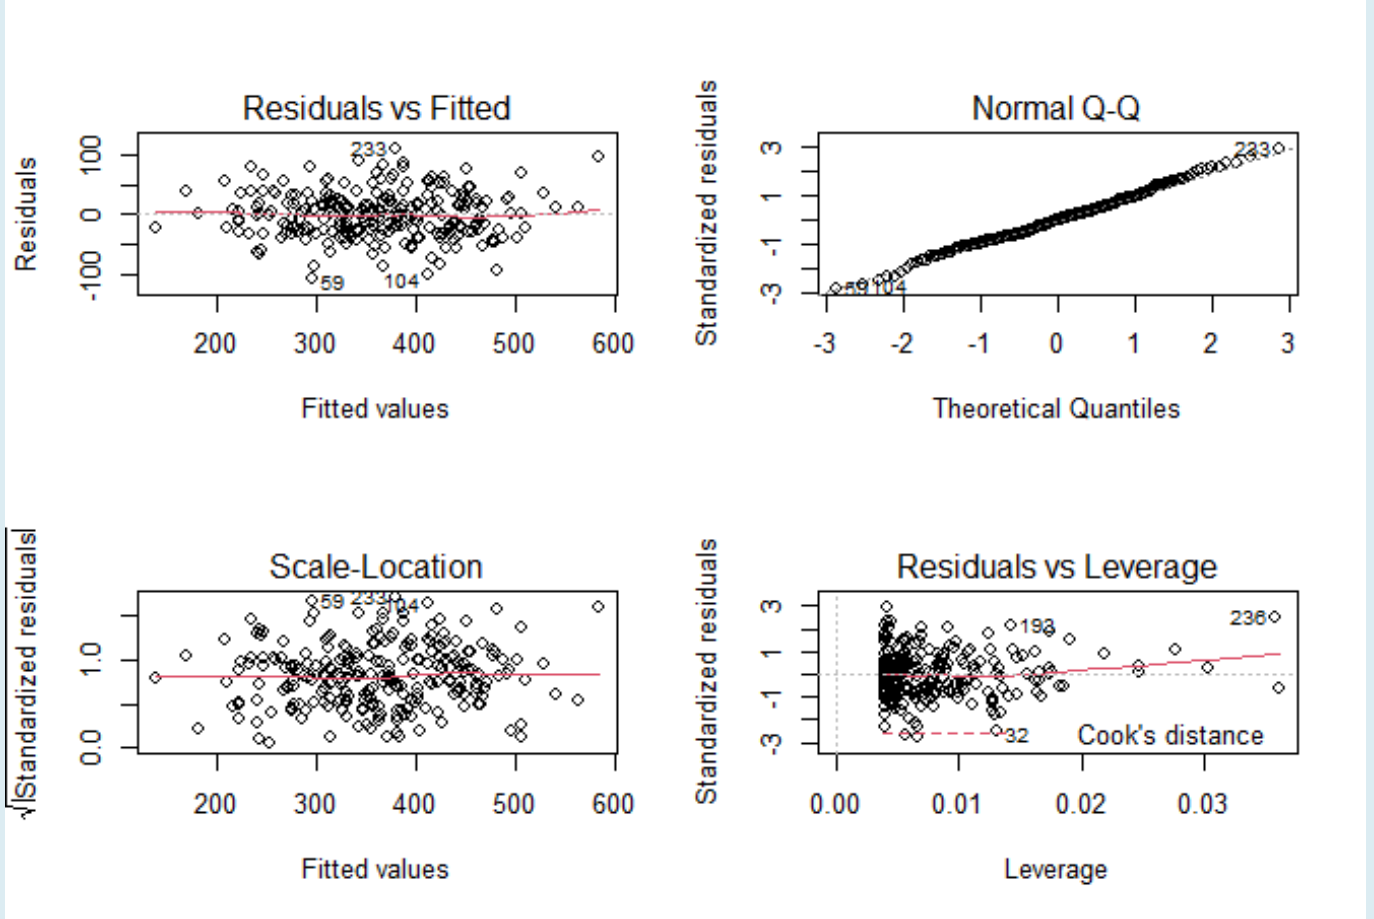
```
residuals()
rstudent()
fitted()
```

Diagnósticos del modelo

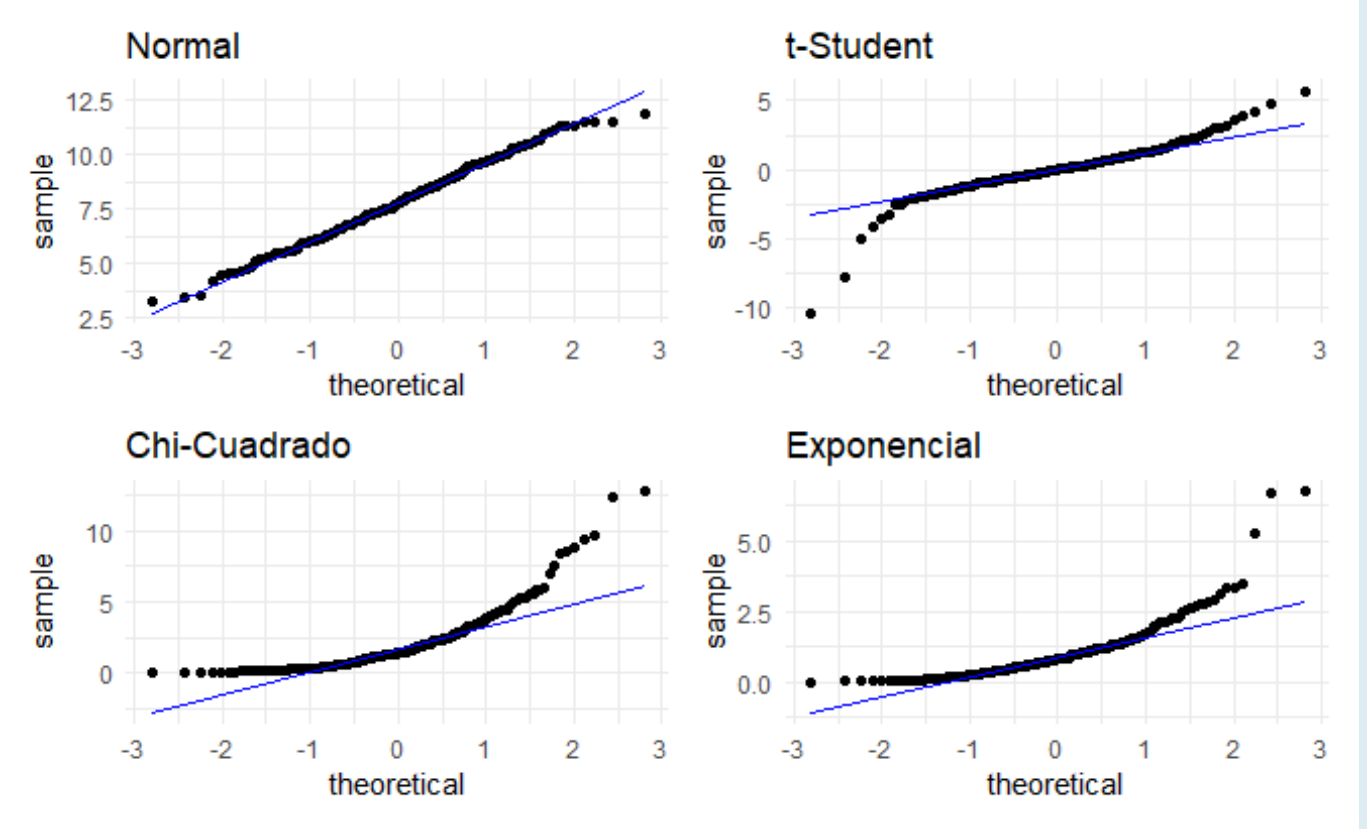
Para que el modelo cumpla las expectativas requeridas, se debe cumplir tres criterios en sus errores:

- **Normalidad**: Se espera que los errores tengan distribución normal, con media 0 y cierta varianza.
- **Independencia**: Los errores deben ser independientes entre si.
- **Homocedasticidad**: Los errores deben tener una dispersión constante en cualquier instante de la variable.

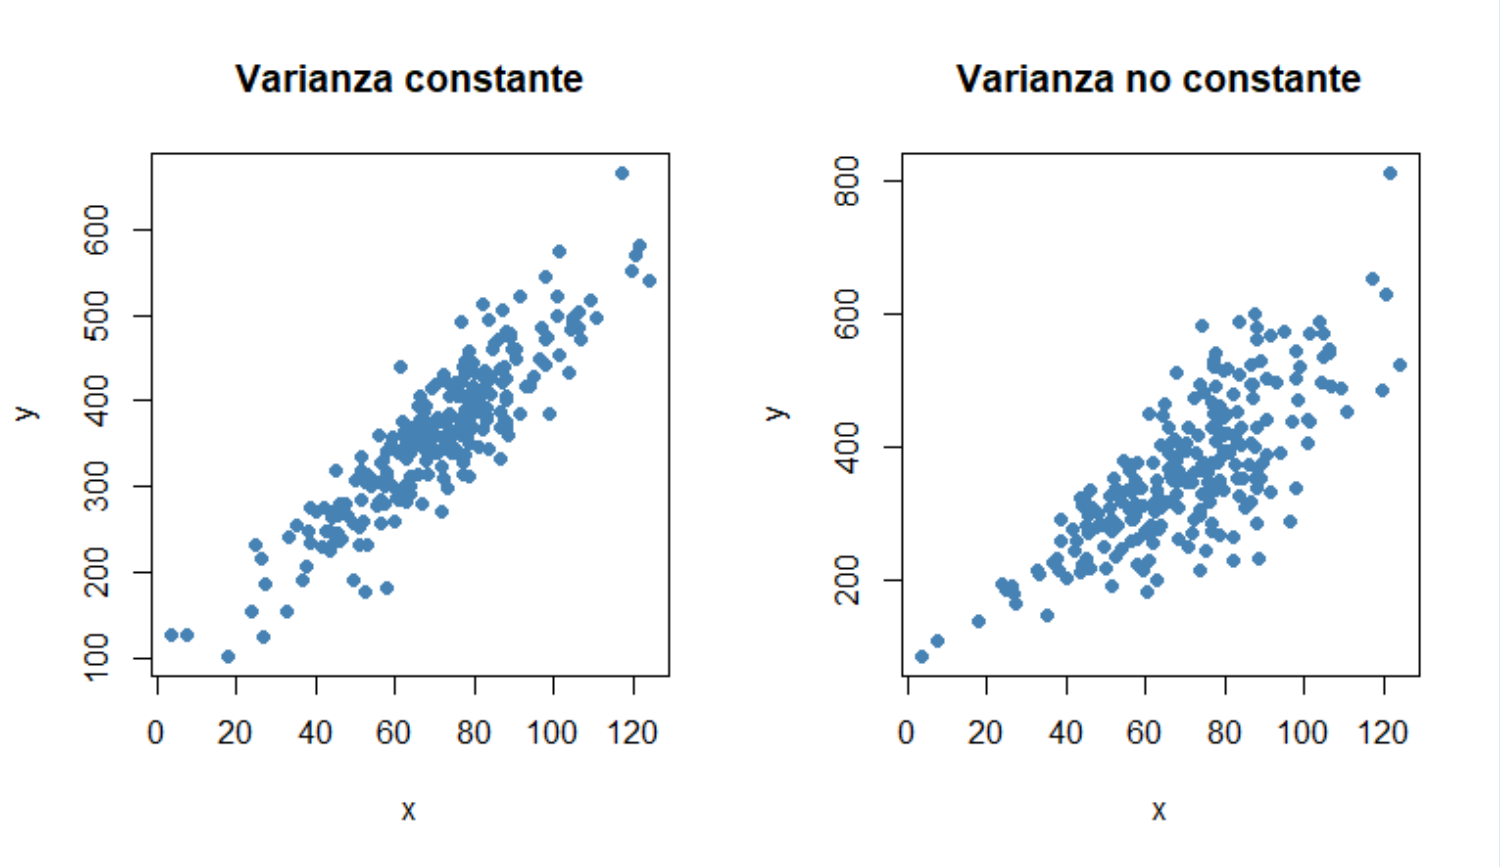
Diagnósticos del modelo



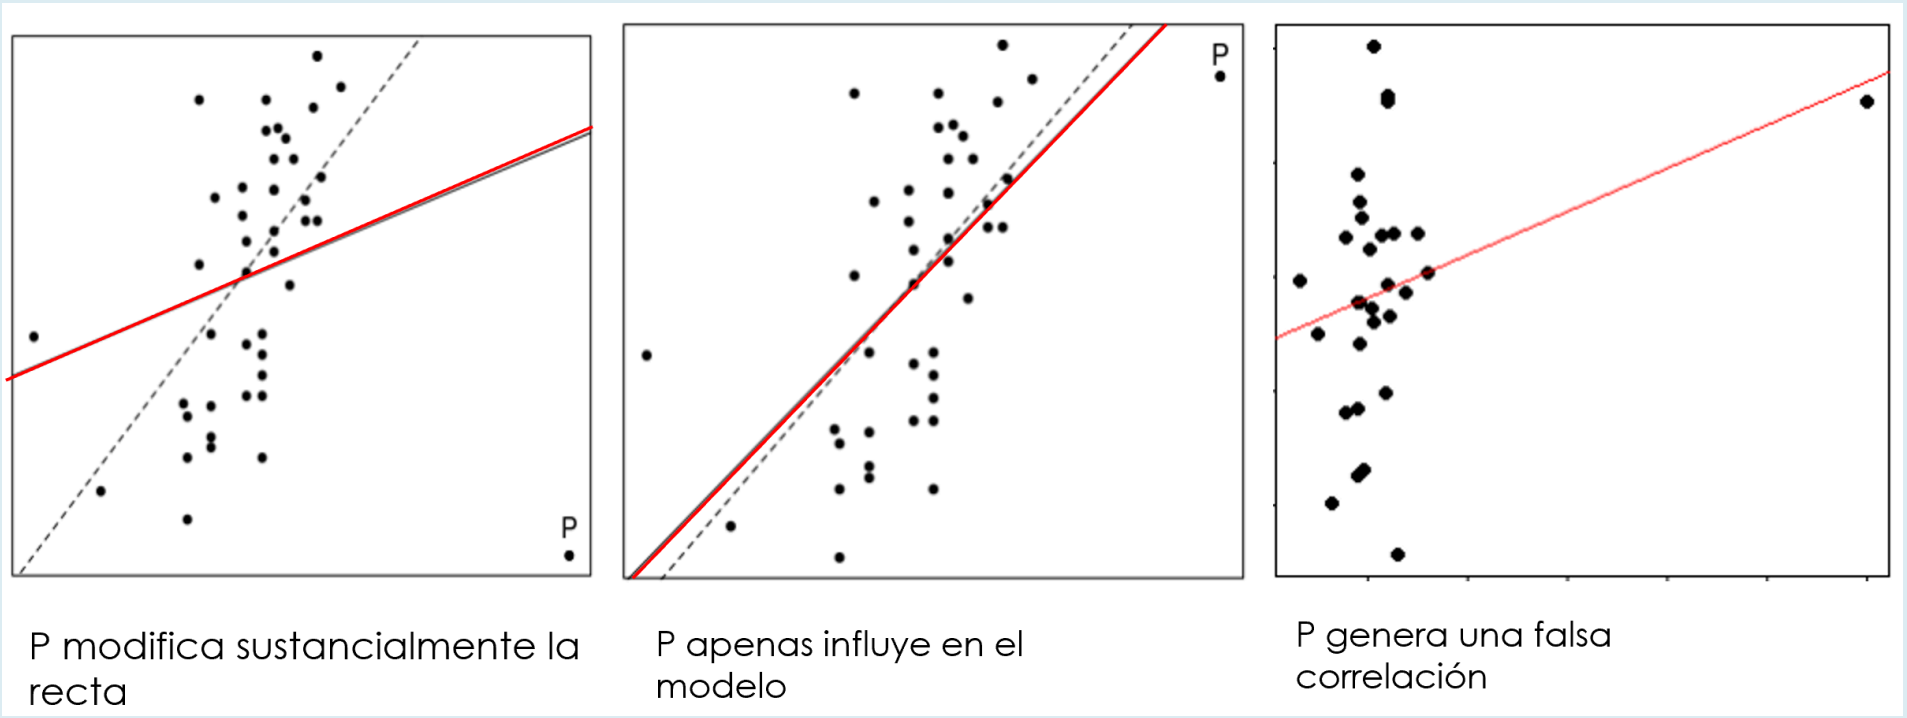
Distribución normal de los residuos



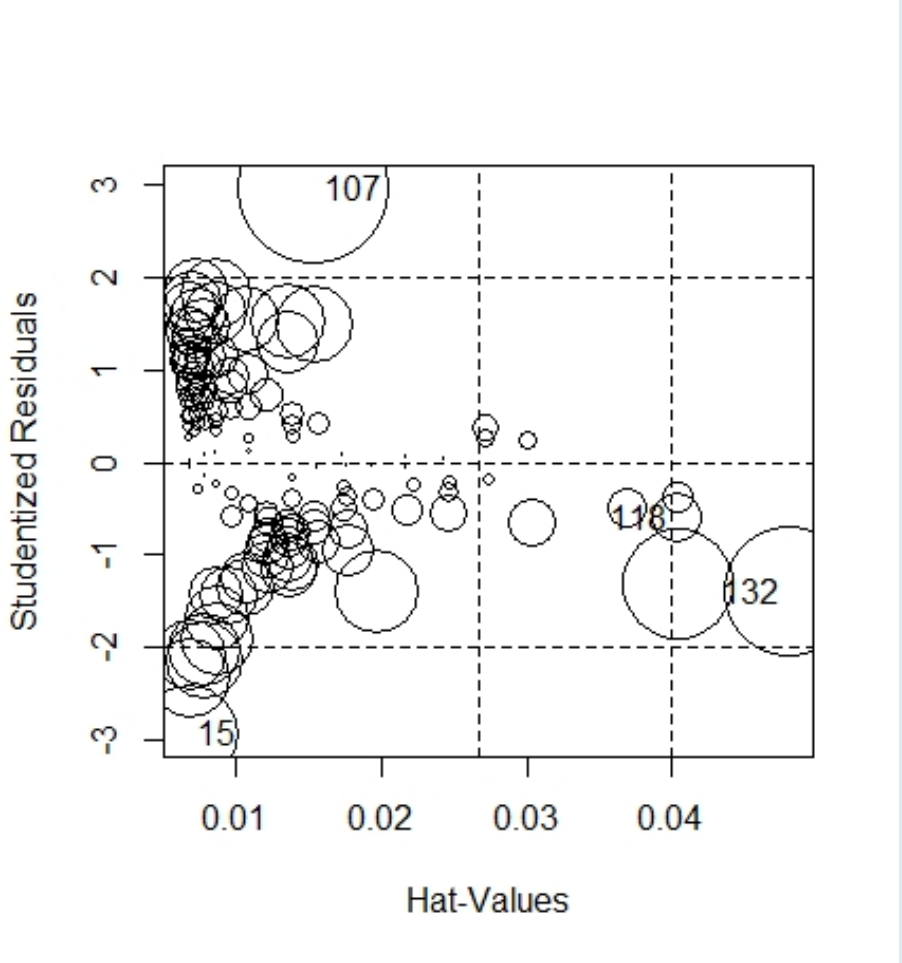
Varianza constante (homocedasticidad)



Valores atípicos y de alta influencia



Valores atípicos y de alta influencia



Modelo de regresión lineal múltiple

Un Modelo de Regresión Lineal Múltiple, corresponde cuando se utilizan varias covariables que intentan explicar una variable a pronosticar.

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \ldots \beta_k X_{ik} + \epsilon_i$$

- β_0: es el valor de Y cuando todos los predictores son cero.
- β_i: es el incremento de la variable Y cuando Xi aumenta en una unidad, manteniéndose constantes el resto de variables.
- ϵ_i: es el error, la diferencia entre el valor observado y el estimado por el modelo.

Modelo de regresión lineal múltiple

Los modelos estadísticos tienen como fin determinar si una o más variables pueden entregar información para explicar una variable respuesta.

Por lo tanto, si se conoce una nueva observación para el conjunto de covariables, se puede realizar un pronóstico de la variable respuesta.

La función `predict()` realiza una estimación puntual, junto con un intervalo de confianza para la nueva observación.

Actividad

Los datos biomass.txt son parte de un estudio realizado por Rick Linthurst, para identificar las características importantes del suelo que influyen en la producción de biomasa aérea de la hierba de marisma Spartina alterniflora.

Se muestreó tres tipos de vegetación Spartina (áreas "muertas" revegetadas, áreas Spartina "cortas" y áreas Spartina "altas") en las ubicaciones (Oak Island, Smith Island y Snows Marsh). Se analizaron 5 muestras del sustrato del suelo dentro de cada ubicación para 14 características fisicoquímicas del suelo y la biomasa (BIO) aérea en cada sitio.

- Sulfuro libre (H2S)
- Salinidad (SAL)
- Potenciales redox a pH 7 (EH7)
- PH del suelo en agua (PH)
- Acidez del tampón a pH 6,6 (BUF)
- Concentración de fósforo (P)
- Concentración de potasio (K)
- Concentración de calcio (CA)
- Concentración de magnesio (MG)
- Concentración de sodio (NA)
- Concentración de manganeso (MN)
- Concentración de zinc (ZN)
- Concentración de cobre (CU)
- Concentración de amonio (NH4)

¡ Gracias !

Ana María Alvarado

amalvara@uc.cl