

Sesión 19: Regresión Lineal Múltiple

Modelos Matemáticos y Estadísticos Clásicos

Ana María Alvarado Celis

Julio 2026

Repaso

Regresión Lineal Simple

El modelo de regresión lineal simple utiliza una variable predictora X, para pronosticar una variable respuesta o de interés Y. El modelo está dado por:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

$$\text{con } \varepsilon_i \overset{\text{iid}}{\sim} \text{Normal}(0, \sigma^2)$$

en donde:

- β_0 es el valor de la variable Y cuando la variable X vale 0.
- β_1 es el cambio en la variable Y cuando la variable X cambia en una unidad.



Regresión Lineal Simple

En Python los modelos de regresión se definen con el comando `ols()`, de la biblioteca `statsmodels.formula.api`:

```
ols(formula, data, ...).fit()
```

donde,

- `formula`: Formula indicando la relación entre la variable explicativa y las variables predictoras. La relación se indica con la virgulilla (~), a continuación se presentan algunos ejemplos:
  - **Un predictor:** `respuesta ~ variable`
  - **Dos o más predictores:** `respuesta ~ predictor1 + predictor2 + ...`
  - **Todas las variables de la base como predictores:** `respuesta ~ .`
- `data`: Nombre de la base de datos que contiene las variables usadas en la definición de la formula.

Supuestos del Modelo

Como se mencionó anteriormente, para que el modelo cumpla las expectativas requeridas, debe cumplir distintos supuestos en sus errores:

- **Normalidad**: Se espera que los errores tengan distribución normal, con media 0 y cierta varianza.
- **Independencia**: Los errores deben ser independientes entre si.
- **Homocedasticidad**: Los errores deben tener una dispersión constante en cualquier instante de la variable.

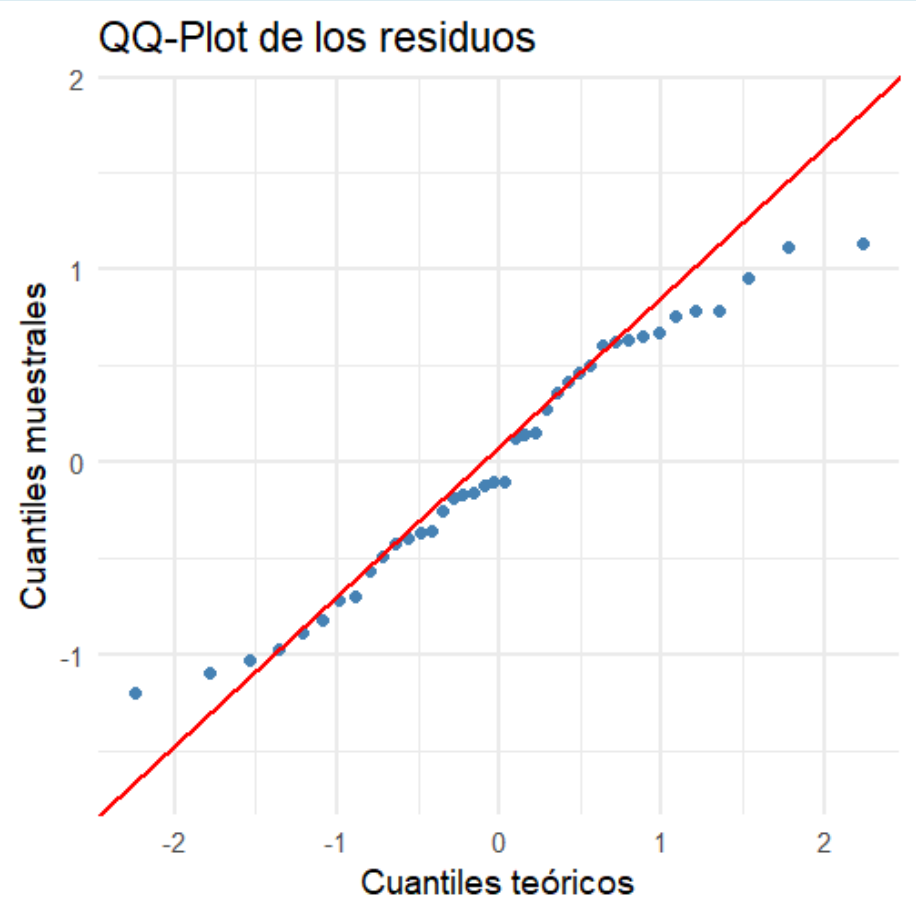
a. Normalidad

Gráficos cuantil-cuantil (Q-Q Plot)

Un gráfico cuantil-cuantil nos permite analizar visualmente si una distribución se parece a otra, mediante la comparación de los cuantiles de esta. En `statsmodels.api` podemos hacer gráfico cuantil-cualtil con la distribución normal:

```
statsmodels.api.qqplot(df['variable'], line='q')
```

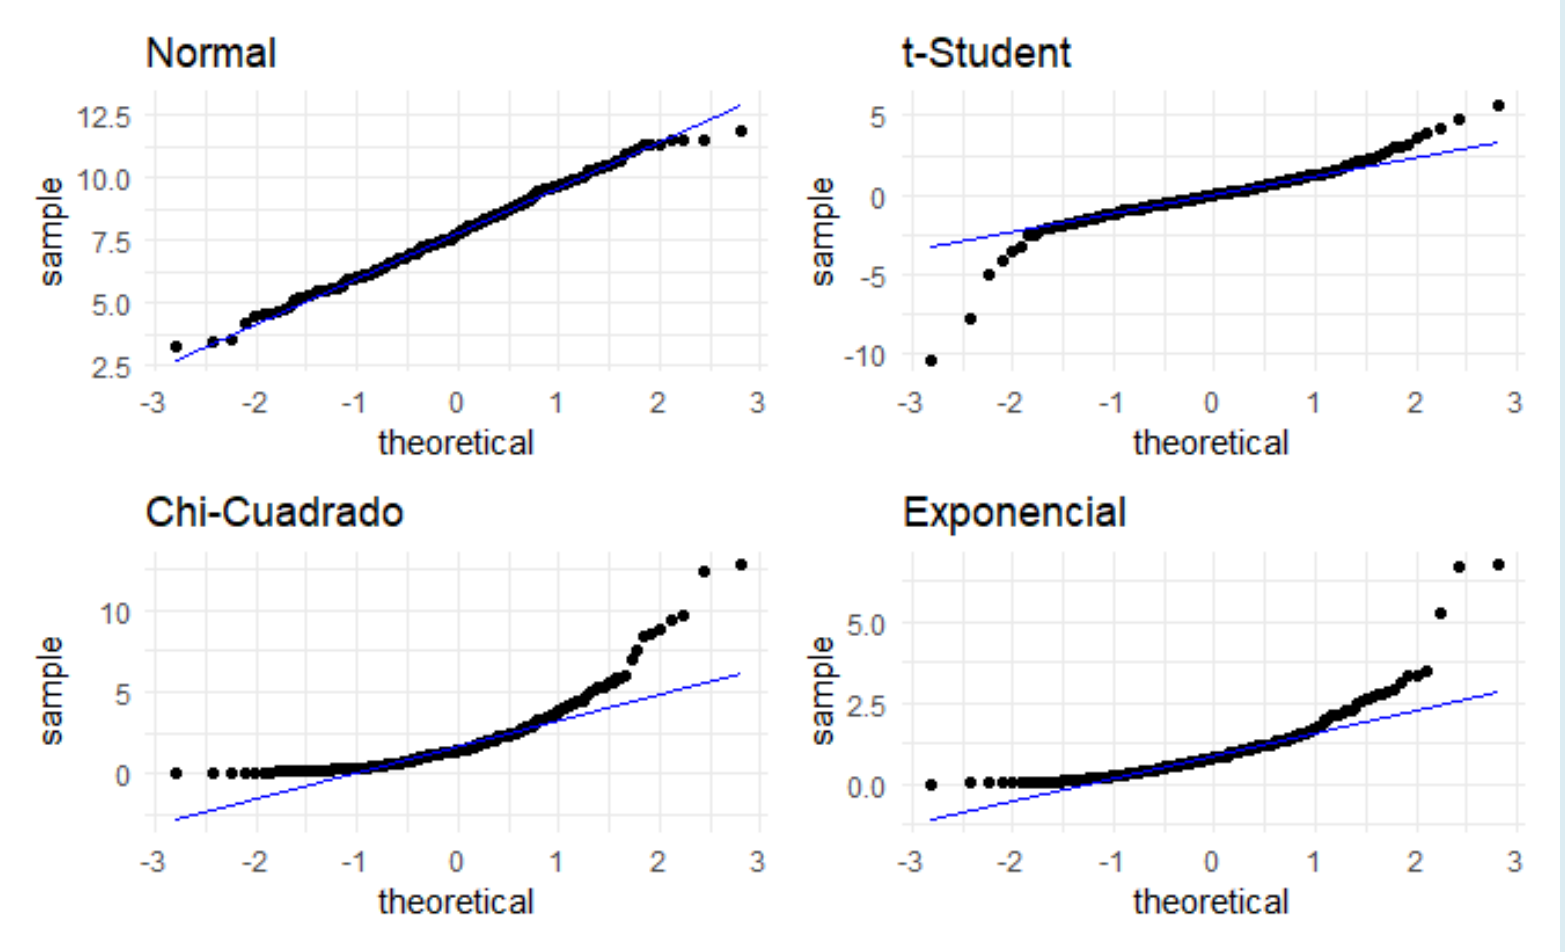
Gráfico Cuantil-Cuantil (QQ-plot)



Notamos que los residuos se alejan de la recta de los cuantiles normales, en especial en las colas de la distribución, entonces con esta evidencia no se estaría cumpliendo el supuesto de normalidad.

El que no se cumpla este supuesto debería parar nuestro análisis y optar por otros modelos u transformaciones de las variables usadas. En este caso, continuaremos el análisis por fines ilustrativos.

Gráfico Cuantil-Cuantil (QQ-plot)



Test de Shapiro-Wilk

El Test de Shapiro-Wilk nos permite estudiar si un conjunto de datos pequeño (menor a 50 unidades) distribuye de forma normal, este test tiene las siguientes hipótesis:

H_0 : Los datos siguen una distribución Normal.

H_1 : Los datos no siguen una distribución Normal.

En Python este test está computado con el comando `shapiro(variable)` de la siguiente forma:

```
from scipy.stats import shapiro
stat, p_valor = shapiro(variable)
```

Para la comprobación de los supuestos se buscan valores-p altos, es decir, buscamos **no** rechazar la hipótesis nula de normalidad.

Test de Kolmogorov-Smirnov

El Test de Kolmogorov-Smirnov nos permite comparar si un conjunto de datos proviene de una distribución especificada. En este caso usaremos la distribución Normal.

H_0 : Los datos siguen una distribución Normal.

H_1 : Los datos no siguen una distribución Normal.

```
scipy.stats.kstest(variable, cdf, alternative)
```

Una alternativa más corta es usar el test de Lilliefors para aplicar Kolmogorov Smirnov directamente en la distribución normal, con el comando `lilliefors` de la biblioteca `statsmodels.stats.diagnostic`:

```
statsmodels.stats.diagnostic.lilliefors(variable, dist='norm',
                                        pvalmethod='table')
```

Para la comprobación de los supuestos se buscan valores-p altos, es decir, buscamos **no** rechazar la hipótesis nula de normalidad.

b. Independencia

La biblioteca `statsmodels.stats.stattools` contiene distintos test para probar supuestos de los modelos de regresión. Para el caso de la independencia de los errores tenemos el test de Durbin-Watson:

Test de Durbin-Watson

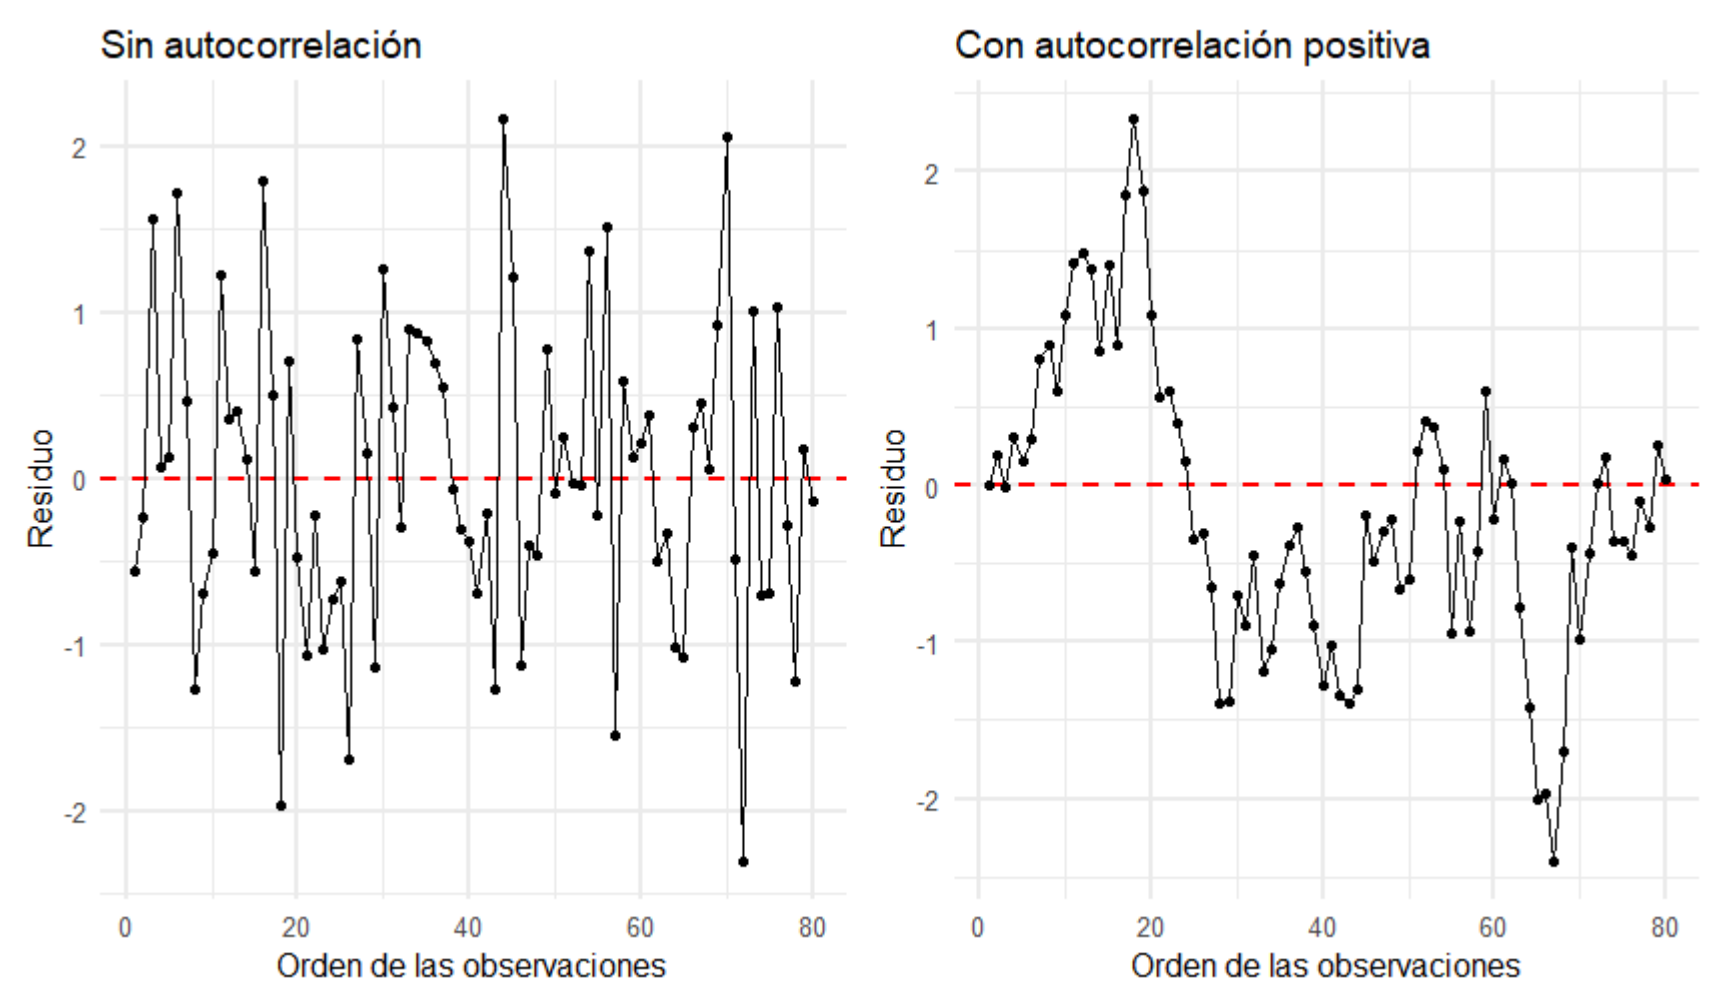
$H_0 : \rho = 0$ Los errores no están auto correlacionados.

$H_1 : \rho \neq 0$ Los errores presentan correlación a un paso.

En Python tenemos el comando `durbin_watson()`. A diferencia de los modelos anteriores el test se aplica directamente al Modelo de Regresión Lineal ajustado.

```
statsmodels.stats.stattools.durbin_watson(residuos)
```

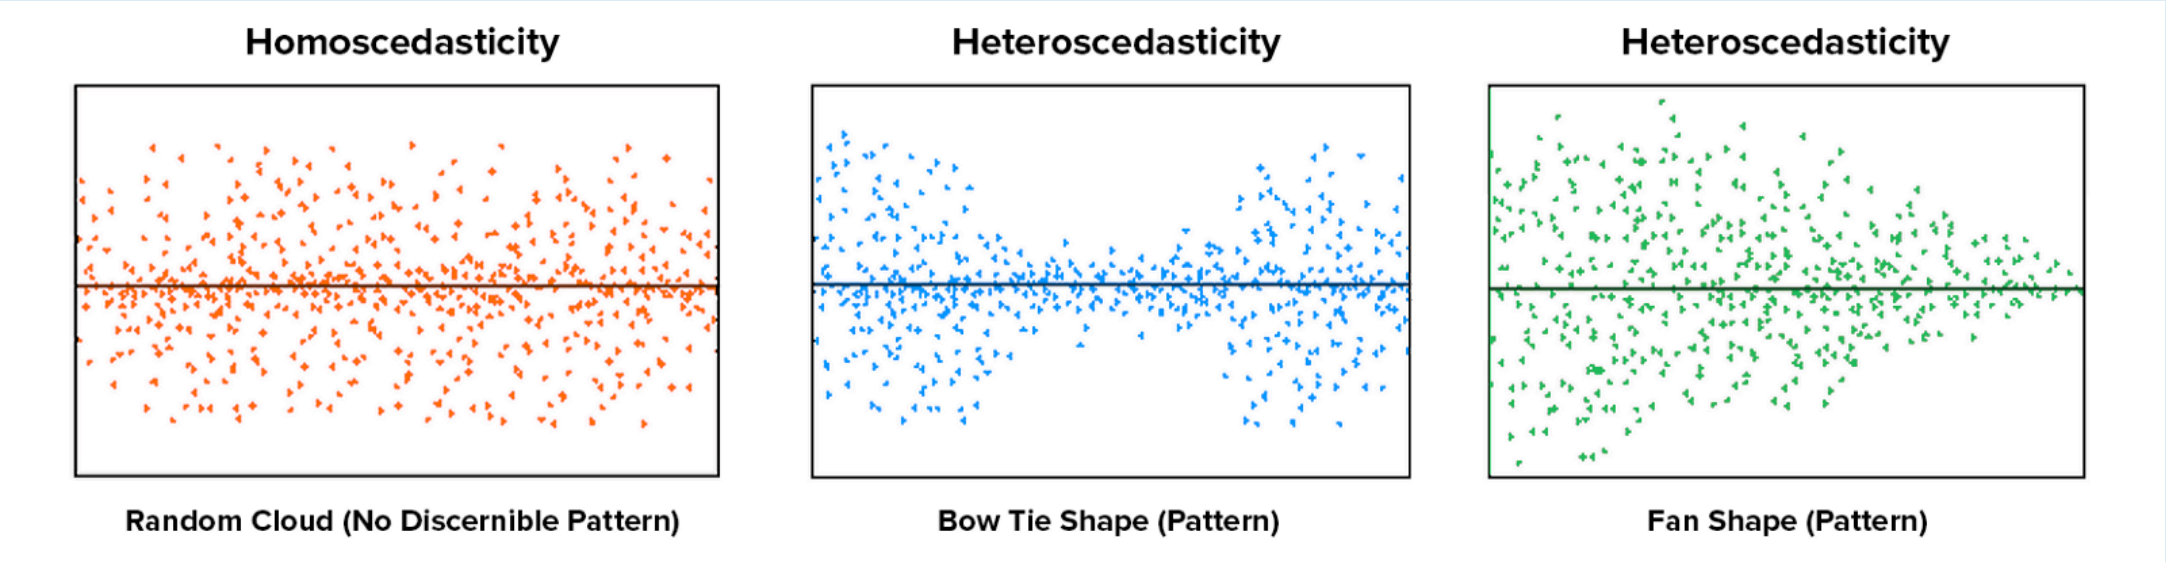
b. Independencia



c. Homocedasticidad

Gráfico de Residuos vs Valores Ajustados

El gráfico de residuos versus valores ajustados nos permite ver la variabilidad de los errores del modelo ajustado, en este gráfico buscamos una nube aleatoria sin ninguna forma definida, además de mostrar un rango constante a lo largo del eje x.



Esto mismo se busca en el gráfico `Scale-Location`, que grafica los valores ajustados junto a los residuos estandarizados.

Test de homocedasticidad

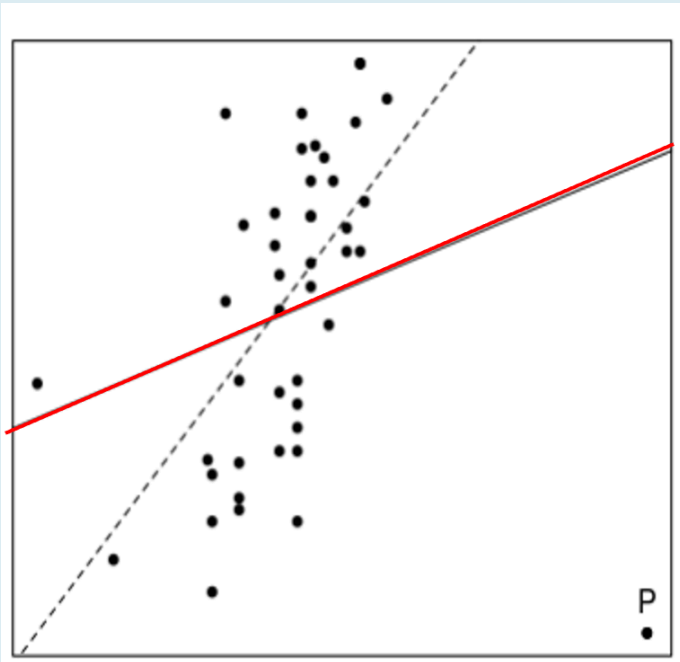
Para probar homocedasticidad usaremos el test de Breusche-Pagan, el cual tiene las siguientes hipótesis:

H_0: Los errores son homocedasticos

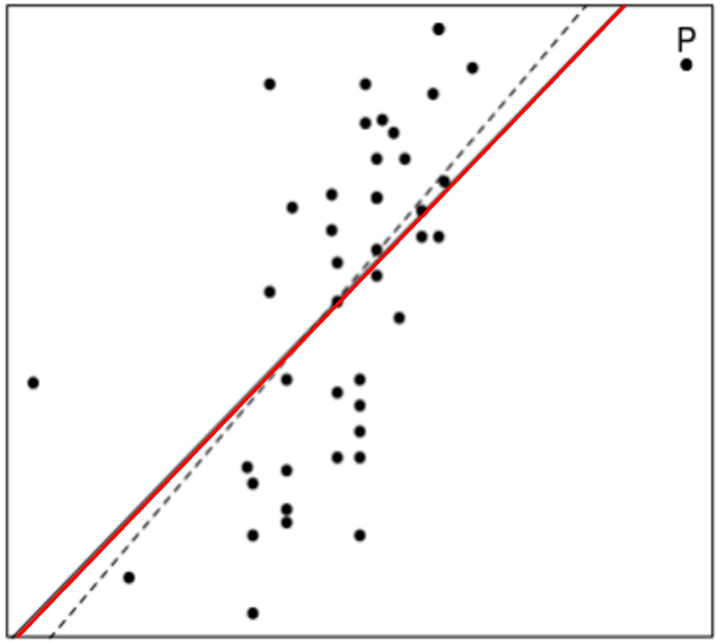
H_1: Los errores son heterocedasticos

En Python tenemos el comando `het_breuschpagan()`, de la librería `statsmodels`.

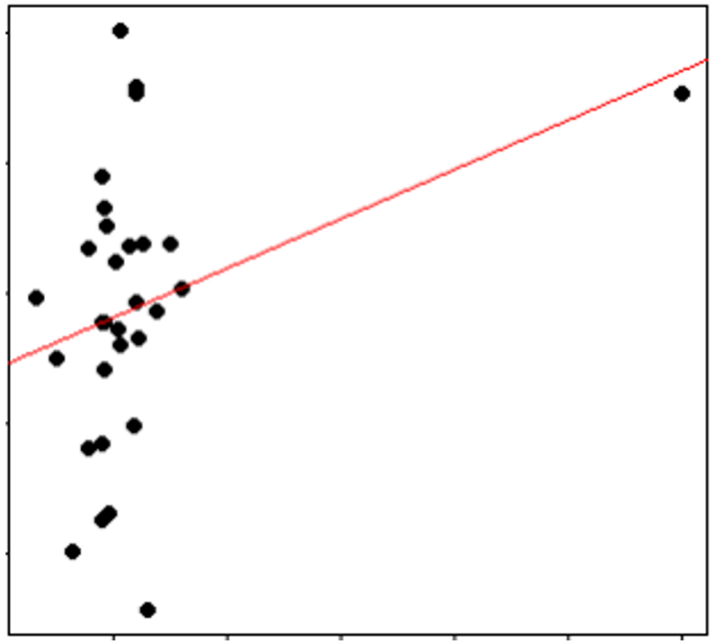
Valores atípicos y de alta influencia



P modifica sustancialmente la recta



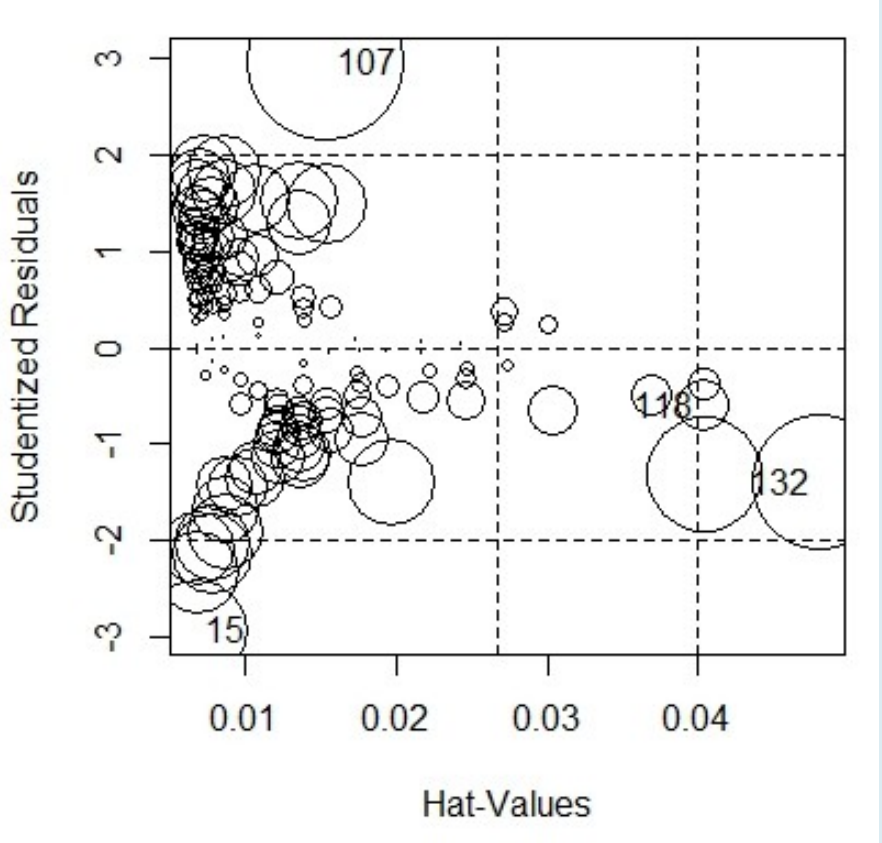
P apenas influye en el modelo



P genera una falsa correlación

Valores atípicos y de alta influencia

Distancia de Cook



Modelo de Regresión Lineal Múltiple

¿Qué ocurre cuando muchas variables afectan simultáneamente a Y?

Si queremos predecir el salario, ¿qué otras variables podrían influir?

- experiencia
- educación
- edad
- género
- ciudad
- tamaño de empresa
- etc.

¿Podemos predecir el salario de una persona en función de todas estas variables?

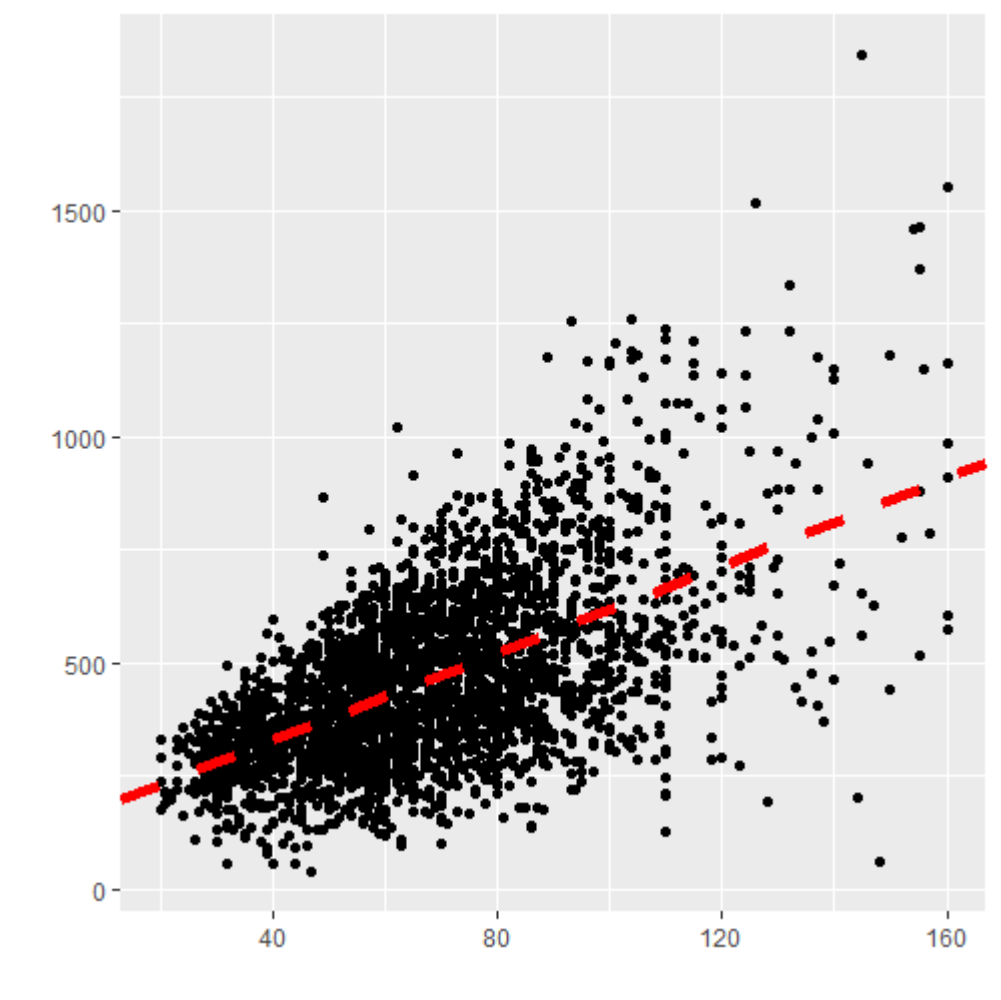
Modelo de regresión lineal múltiple

Un Modelo de Regresión Lineal Múltiple, corresponde cuando se utilizan varias covariables que intentan explicar una variable a pronosticar.

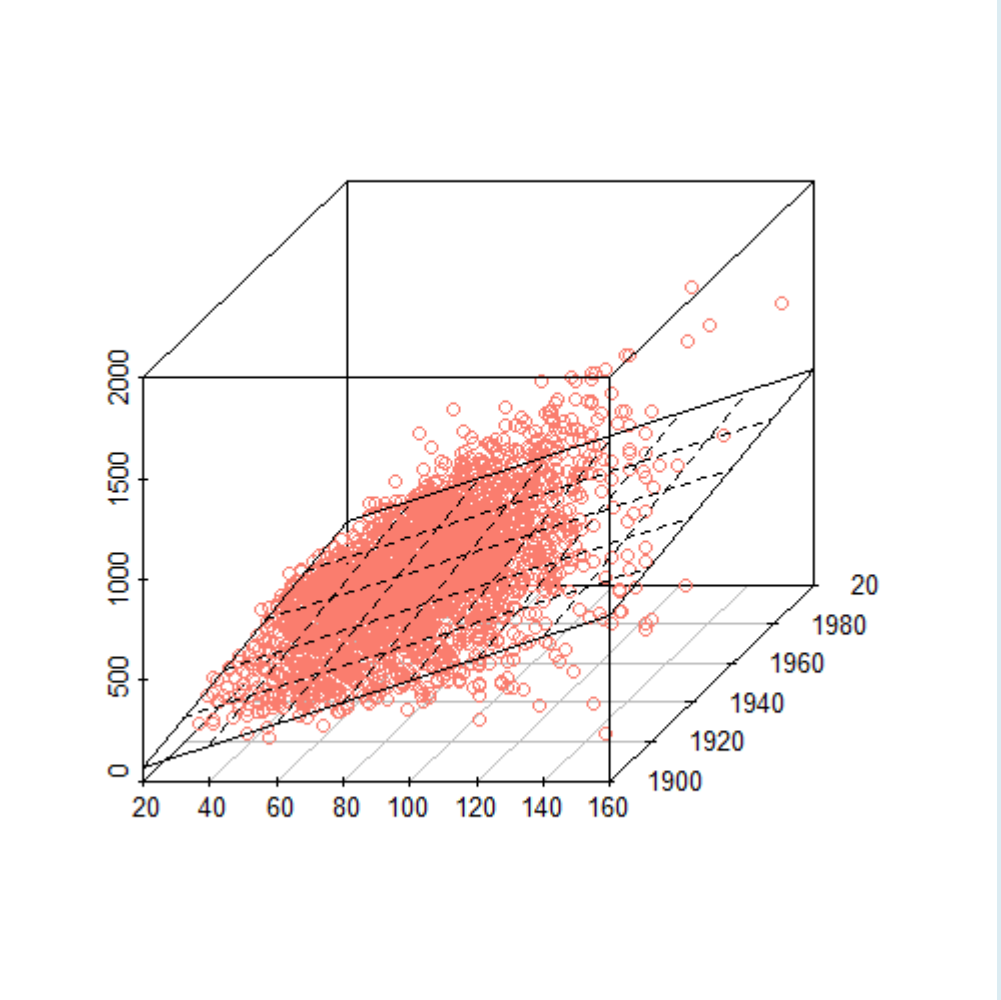
$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \ldots + \beta_k X_{ik} + \epsilon_i$$

- β_0: es el valor de Y cuando todos los predictores son cero.
- β_j: es el incremento de la variable Y cuando X_j aumenta en una unidad, manteniéndose constantes el resto de variables.
- ϵ_i: es el error, la diferencia entre el valor observado y el estimado por el modelo.

Regresión Lineal Simple



Regresión Lineal Múltiple



Modelo de Regresión Lineal

El ajuste de un modelo de regresión busca encontrar estimaciones para $\beta_0, \beta_1, \ldots, \beta_k$ a partir de una base de datos. Estas estimaciones se denotan con el supraindice *gorro* (^), esto es, $\hat{\beta}_0,\ \hat{\beta}_1,\ \ldots,\ \hat{\beta}_k$. Con estos parámetros estimados se obtiene un modelo que nos permite obtener estimaciones para y, las cuales se denotan por $\hat{y}$.

Caso Regresión Lineal Simple

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Caso Regresión Lineal Múltiple

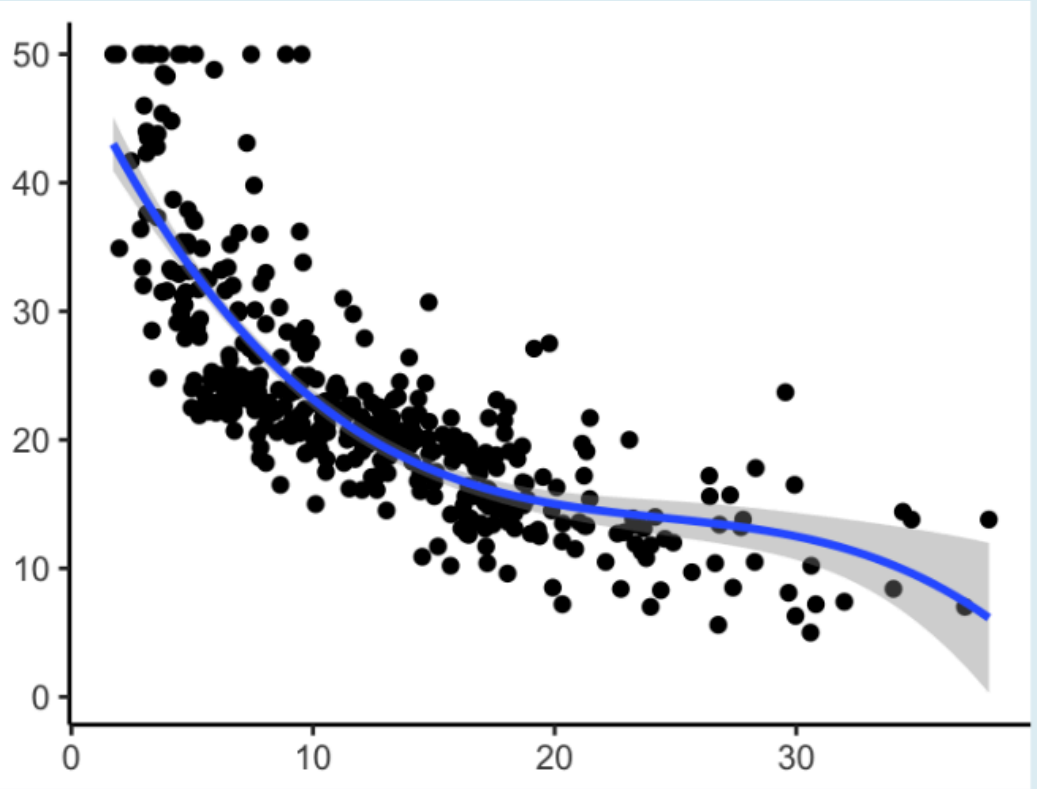
$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \ldots + \hat{\beta}_k x_{ki}$$

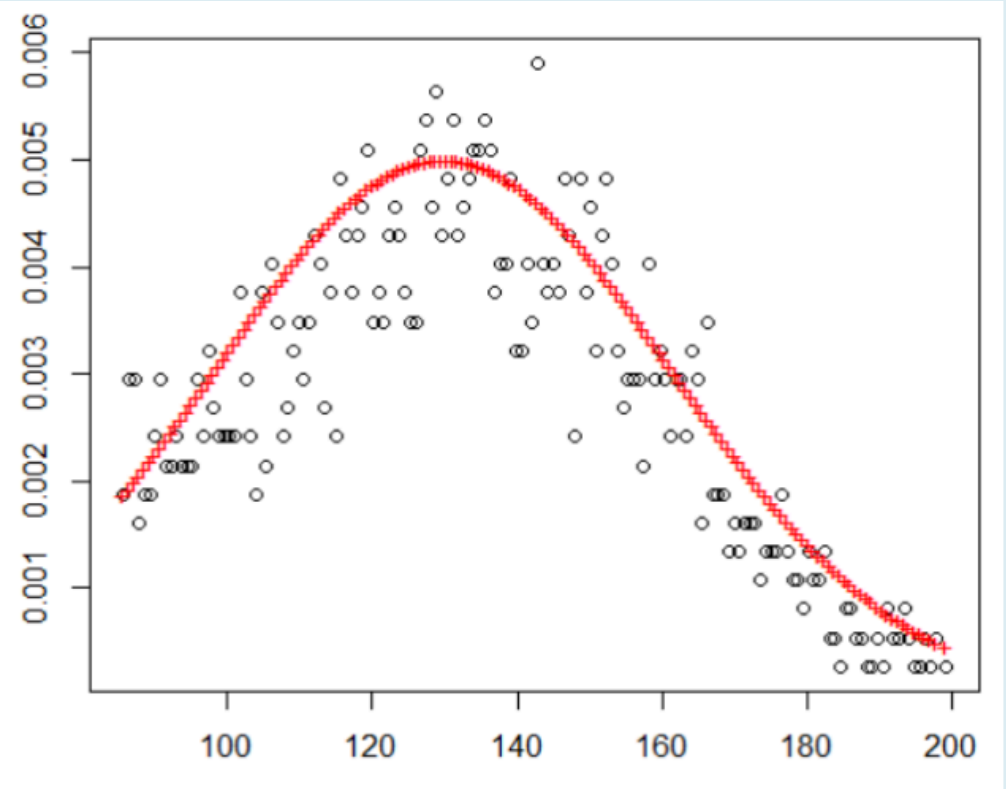
Los residuos del modelo para la i-ésima observación se denotan por e_i, y corresponde a la diferencia entre el valor real y la predicción del modelo:

$$e_i = y_i - \hat{y}_i$$

Modelo de Regresión Lineal

¿Por qué lineal?





Modelo de Regresión Lineal

La linealidad en los parámetros es lo que permite estimar los coeficientes mediante Mínimos Cuadrados Ordinarios (OLS). En notación matricial, el modelo se escribe como

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

donde la matriz $\mathbf{X}$ contiene las variables explicativas y el vector $\boldsymbol{\beta}$ aparece linealmente. Gracias a esta estructura existe una solución analítica para los estimadores:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Modelo de Regresión Lineal

Modelo	¿Es lineal?
$Y = \beta_0 + \beta_1 X$	✅
$Y = \beta_0 + \beta_1 X + \beta_2 X^2$	✅
$Y = \beta_0 + \beta_1 \log(X)$	✅
$Y = \beta_0 + \beta_1 e^X$	✅
$Y = \beta_0 + \beta_1^2 X$	❌
$Y = \beta_0 + e^{\beta_1 X}$	❌
$Y = \beta_0 + \beta_1 \beta_2 X$	❌

Dos preguntas importantes:

I) Probar si los parámetros obtenidos son significativos implica comprobar si la variable explica a la respuesta.

$$H_0 : \beta_i = 0 \ \ vs \ \ H_1 : \beta_i \neq 0$$

Se realizará un **test t** individual para cada parámetro. Además, se puede obtener los intervalos de confianza de cada uno de ellos.

II) Probar si el modelo obtenidos es significativo implica comprobar si el modelo es correcto.

$$H_0 : \beta_1 = \ldots = \beta_k = 0$$

$$H_1 : \text{Al menos un } \beta_j \neq 0 \text{ para } \ j = 1, \ldots, k$$

Se realizará un **test F** a partir de la tabla ANOVA del modelo. En este caso, se reemplaza la idea de Tratamiento por Regresión.

Coeficiente de Determinación

En regresión lineal múltiple el Coeficiente de Determinación R^2 también es un indicador de la calidad del ajuste. Al agregar variables al modelo siempre aumenta el R^2, aunque esos predictores no mejoren significativamente el poder explicativo del modelo.

El R^2 Ajustado también indica la calidad del ajuste del modelo, pero penaliza la inclusión de variables. Para ello, tiene en cuenta tanto el número de predictores como el tamaño de la muestra.

$$R^2_{ajust} = 1 - \left(\frac{(1 - R^2) \cdot (n - 1)}{n - k - 1} \right)$$

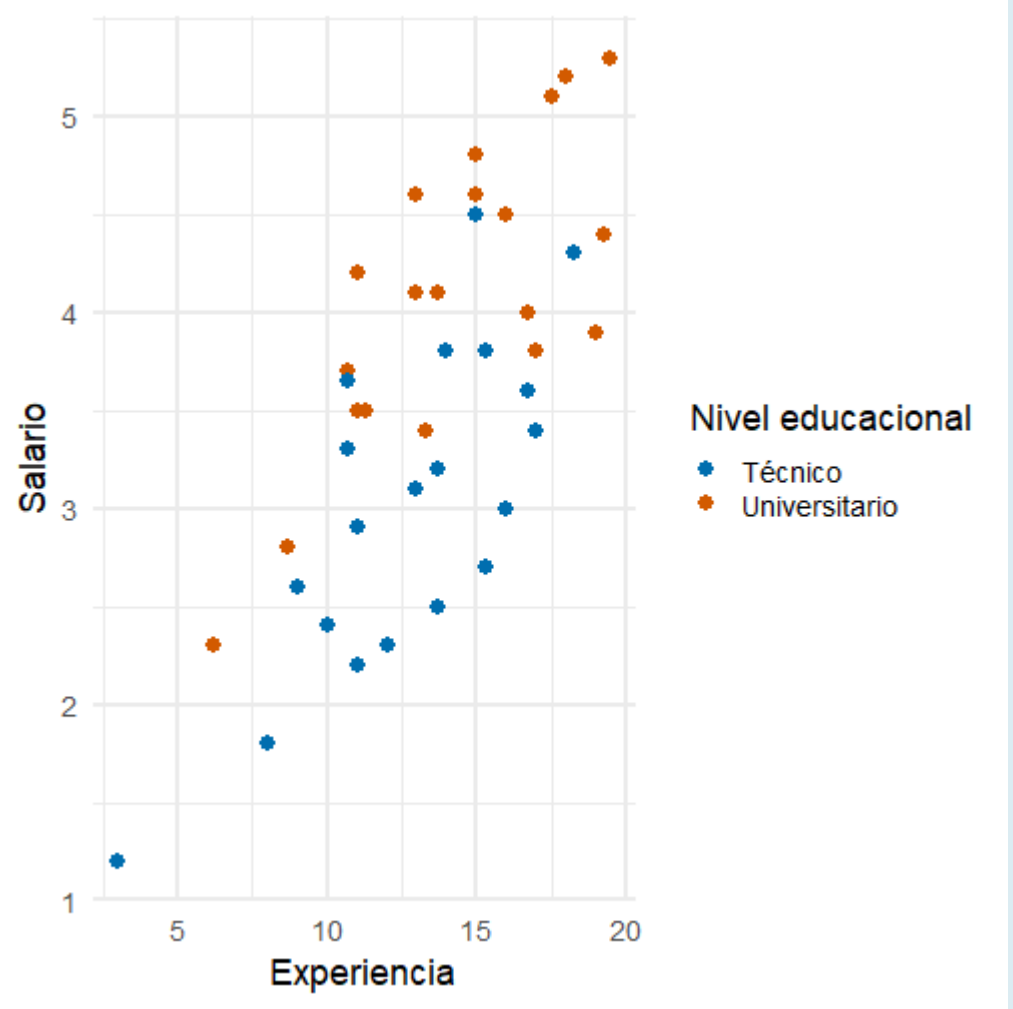
Dónde:

R^2 = Coeficiente de determinación del modelo

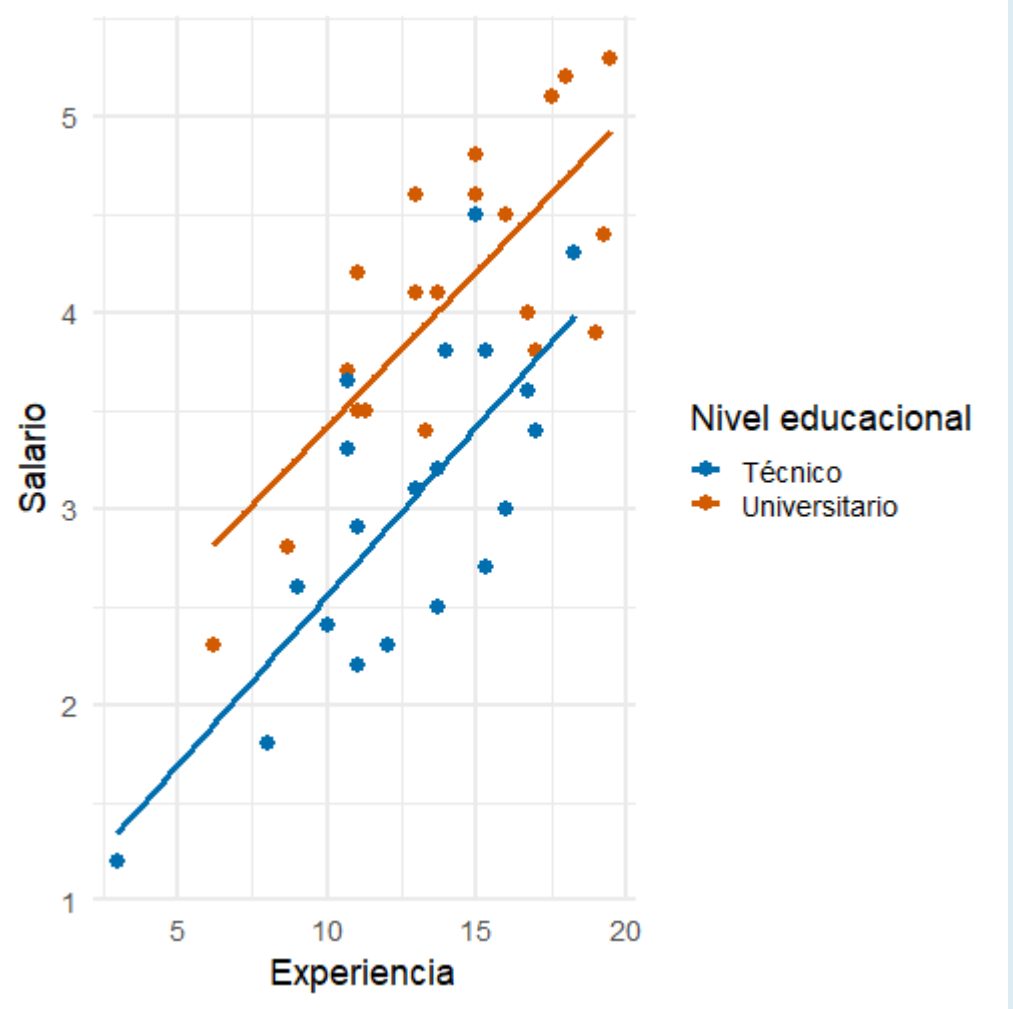
n = número de observaciones

k = número de predictores.

Modelo con Variables Independientes Cualitativas



Modelo con Variables Independientes Cualitativas



Modelo con Variables Independientes Cualitativas

Internamente se construye una variable **Indicadora o dummy** para las categorías, es una variable que indica si la categoría está presente o no.

Sólo existen dos resultados posibles, 1 si corresponde a la categoría, 0 si no corresponde a la categoría.

El modelo ajustado se define como:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot X + \hat{\beta}_2 \cdot Grupo_B$$

$\hat{\beta}_0$: Intercepto del Grupo A.

$\hat{\beta}_1$: Pendiente común para ambos grupos.

$\hat{\beta}_2$: Desplazamiento de la recta del Grupo B respecto al Grupo A.

Diagnóstico del Modelo

En regresión lineal múltiple se deben analizar los mismos supuestos de la regresión simple

- Normalidad
- Independencia
- Homocedasticidad

Multicolinealidad

La multicolinealidad ocurre cuando dos o más variables explicativas de un modelo de regresión están altamente correlacionadas entre sí, de modo que contienen información redundante y resulta difícil separar el efecto individual de cada una sobre la variable respuesta.

Consecuencias principales

- Los coeficientes pueden ser inestables.
- Los errores estándar aumentan.
- Los intervalos de confianza se hacen más amplios.
- Variables realmente importantes pueden aparecer como no significativas.
- La capacidad predictiva del modelo puede seguir siendo buena, aunque la interpretación de los coeficientes sea poco confiable.

Factor de Inflación de la Varianza

El Factor de Inflación de la Varianza (VIF) es la medida más utilizada para evaluar la multicolinealidad.

Para cada variable explicativa, el VIF cuantifica cuánto aumenta la varianza de su coeficiente debido a la correlación con las demás variables del modelo.

VIF	Interpretación
≈ 1	No existe multicolinealidad.
1 – 5	Correlación moderada, generalmente aceptable.
5 – 10	Posible problema; conviene revisar el modelo.
> 10	Evidencia de multicolinealidad severa.

```
statsmodels.stats.outliers_influence.variance_inflation_factor(exog, exog_x)
```

Selección de Modelos

Son técnicas que nos ayudan a elegir qué variables incluir en un modelo de regresión (u otro modelo estadístico), con el fin de mejorar la capacidad predictiva, evitar el sobreajuste y mantener la interpretabilidad.

- **Método jerárquico:** Según criterio del analista, se introducen predictores determinados en un orden determinado.
- **Método de entrada forzada:** Se introducen todos los predictores simultáneamente.
- **Método paso a paso (stepwise):** Emplea criterios matemáticos para decidir qué predictores contribuyen significativamente al modelo y en qué orden se introducen o se eliminan (Forward, Backward y Bidirectional).

Queremos el modelo más simple que describa adecuadamente los datos.

Selección de Modelos

Stepwise necesita un criterio para evaluar si un modelo mejora o empeora al agregar o eliminar una variable.

Los criterios más utilizados son:

- **p-values:** Evalúan la significancia estadística de cada coeficiente.
- **R2-Ajustado:** Mide el porcentaje de variabilidad explicado por el modelo, penalizando la inclusión de variables.
- **AIC (Akaike Information Criterion):** Medida de calidad basada en la bondad de ajuste. Si se poseen varios modelos, se optaría por aquel con valor mínimo de AIC.
- **BIC (Bayesian Information Criterion):** Similar al AIC, pero penaliza más los modelos complejos.

Selección de Modelos

Ventajas

- Muy sencillo de aplicar.
- Reduce rápidamente el número de variables.
- Fácil de interpretar.

Desventajas

- Puede seleccionar modelos diferentes ante pequeños cambios en los datos.
- Ignora el conocimiento del problema.
- Tiende a sobreajustar si hay muchas variables.
- No garantiza encontrar el mejor modelo posible.

Métodos de Regularización

Técnicas de optimización global que introducen una penalización matemática continua sobre la magnitud de los coeficientes β_j.

- LASSO
- Elastic Net
- Ridge

Predicción con Modelos de Regresión Lineal

Los modelos estadísticos tienen como fin determinar si una o más variables pueden entregar información para explicar una variable respuesta.

Por lo tanto, si se conoce una nueva observación para el conjunto de covariables, se puede realizar un pronóstico de la variable respuesta. La función `predict()` realiza una estimación puntual, junto con un intervalo de confianza para la nueva observación.

Modelo de Regresión Lineal

- Un modelo de Regresión Lineal Múltiple explica una variable respuesta Y a partir de varios predictores simultáneamente.
- La estimación de los coeficientes se obtiene por Mínimos Cuadrados Ordinarios, gracias a la linealidad en los parámetros.
- El R^2-ajustado compara modelos con distinto número de predictores, penalizando la complejidad.
- La multicolinealidad (VIF > 10) no afecta la predicción, pero sí la confiabilidad e interpretación de los coeficientes.
- Los métodos de selección de modelos (stepwise, AIC/BIC) y de regularización (Ridge, LASSO, Elastic Net) buscan el modelo más simple que explique bien los datos, evitando el sobreajuste.
- Antes de predecir, hay que verificar que el modelo cumpla los supuestos y que la nueva observación esté dentro del rango de los datos usados para ajustarlo.
- Entre dos modelos con capacidad explicativa similar, se prefiere el más simple, ya que es más interpretable, más estable ante nuevos datos y menos propenso al sobreajuste.

Actividad

Los datos biomass.txt son parte de un estudio realizado por Rick Linthurst, para identificar las características importantes del suelo que influyen en la producción de biomasa aérea de la hierba de marisma Spartina alterniflora.

Se muestreó tres tipos de vegetación Spartina (áreas "muertas" revegetadas, áreas Spartina "cortas" y áreas Spartina "altas") en las ubicaciones (Oak Island, Smith Island y Snows Marsh). Se analizaron 5 muestras del sustrato del suelo dentro de cada ubicación para 14 características fisicoquímicas del suelo y la biomasa (BIO) aérea en cada sitio.

- Sulfuro libre (H2S)
- Salinidad (SAL)
- Potenciales redox a pH 7 (EH7)
- PH del suelo en agua (PH)
- Acidez del tampón a pH 6,6 (BUF)
- Concentración de fósforo (P)
- Concentración de potasio (K)
- Concentración de calcio (CA)
- Concentración de magnesio (MG)
- Concentración de sodio (NA)
- Concentración de manganeso (MN)
- Concentración de zinc (ZN)
- Concentración de cobre (CU)
- Concentración de amonio (NH4)

¡ Gracias !

Ana María Alvarado

amalvara@uc.cl