Clase 20: Modelos Predictivos
Introducción a los Modelos Lineales Generalizados
Modelos Matemáticos y Estadísticos Clásicos

Regresión Logística

Prof. Maritza Márquez
maritza.marquez@uc.cl

Facultad de Matemáticas - Departamento de Estadística
Pontificia Universidad Católica de Chile

Julio 2026



Contenidos

Preliminares

Algunas Distribuciones de Probabilidad Útiles

Modelo Lineal Generalizado

Modelo de Regresión Logística

Métricas de Desempeño para Clasificadores Binarios

Preliminares

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo lineal general

La **inferencia estadística** nos proporciona métodos para utilizar la observaciones $\boldsymbol{y}_i$ para obtener información acerca de la distribución $\boldsymbol{Y}$.

Uno de los pilares fundamentales del análisis estadístico se centra en el **Modelo Lineal General**.

$$\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \qquad \boldsymbol{\varepsilon} \sim \mathcal{N}(\boldsymbol{0}, \sigma^2 \boldsymbol{I}). \tag{1}$$

Donde;

- $\boldsymbol{Y} \in \mathbb{R}^n$, es un vector aleatorio que representa la variable respuesta asociada a n observaciones independientes.
- $\boldsymbol{X} \in \mathbb{R}^{n \times p}$, es la matriz de diseño, cuyas filas contienen los valores observados de p variables explicativas.
- $\boldsymbol{\beta} \in \mathbb{R}^p$. El vector de parámetros desconocidos que cuantifican el efecto de las covariables.
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$. El vector de errores aleatorios.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo lineal general

Si expresamos esta ecuación en términos de vectores y matrices. El modelo queda explicado como:

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} \cdot \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

- La variable respuesta se relaciona con las variables explicativas de forma lineal.
- Los errores del modelo son asumidos independientes e idénticamente distribuidos normales de media cero $\mathbb{E}(\boldsymbol{\varepsilon}) = 0$ y varianza constante, $\mathbb{V}(\boldsymbol{\varepsilon}) = \sigma^2 I_n$.
- Bajo estos supuestos, la esperanza condicional de la variable respuesta está dada por $\mathbb{E}(\boldsymbol{Y} \mid \boldsymbol{X}) = \boldsymbol{X}\boldsymbol{\beta}$. Es decir, la media de la respuesta depende linealmente de los parámetros.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo lineal general

- Existen tres situaciones frecuentes en las que la **variabilidad no es constante**, por lo que el modelo de regresión lineal clásico resulta inadecuado para este tipo de datos.

  1. Cuando la respuesta es una proporción.
  2. Cuando la respuesta es un conteo.
  3. Cuando la respuesta es positiva y continua.

- La regresión lineal tampoco es adecuada cuando la relación entre la variable respuesta y las variables explicativas no puede representarse razonablemente mediante una función lineal.

- Finalmente, la distribución de la variable dependiente podría apartarse de la normalidad.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Tipos de variable respuesta

- **Variable continua:** toma valores dentro de un intervalo determinado (posiblemente ilimitado).
  - Nivel de colesterol (miligramos por decilitro).
  - Tiempo de sobrevida de ratas (semanas).
  - Dinero gastado en cereales (pesos).
- **Variable categórica:** toma valores dentro de un número de categorías o niveles (usualmente finito).
  - Color de ojos (azul, café, verde, otro).
  - Tendencia política (derecha, izquierda, otra).
  - Nivel de colesterol (bajo, normal, alto).

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Variables nominales y variables ordinales

- Las variables **nominales** no tienen un orden natural:
  - Color de ojos (azul, café, otro).
  - Tendencia política (derecha, izquierda, otra).
  - Tipo de música favorito (jazz, rock, rap, otro).
  - Género (hombre, mujer).
- Las variables **ordinales** tienen un orden natural:
  - Estado del cáncer (I, II, III, IV).
  - Calificación (malo, regular, bueno).

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Variable respuesta y predictores

- Las variables de interés se pueden clasificar como: **respuesta o predictoras**.

- **Regresión:** modelar la **respuesta** como una función de las variables explicativas o **predictoras**.

- Si queremos modelar la tendencia política como una función del género y salario:
  - La respuesta sería categórica (derecha, izquierda, otra).
  - Y los predictores serían el salario anual (considerado como continuo) y el género (hombre, mujer).

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS



¿Conoce modelos de regresión para dar cuenta de la pregunta anterior?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Algunas Distribuciones de Probabilidad Útiles

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución Bernoulli

- Una variable es **binaria** si toma dos valores posibles:
  - Hombre/mujer.
  - Infectado/no infectado.

- Y_i sigue una distribución de **Bernoulli** con probabilidad π,

$$Y_i \mid \pi \sim \text{Bernoulli}(\pi),$$

si $P(Y_i = y_i \mid \pi) = \pi^{y_i}(1-\pi)^{1-y_i}, \quad \text{con} \quad y_i \in \{0, 1\}.$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución Binomial

- $Y_i \mid \pi \sim \text{Bernoulli}(\pi)$, $i = 1, \ldots, n$, variables aleatorias independientes e idénticamente distribuidas (iid).

- $Y = \sum_{i=1}^{n} Y_i$ sigue una distribución **Binomial** con parámetros n y π, es decir, $Y \mid n, \pi \sim \text{Bin}(n, \pi)$.

- Y cuenta el número de 1's en la serie $Y_1, \ldots, Y_n$.

- La distribución de probabilidades de $Y \mid n, \pi \sim \text{Bin}(n, \pi)$ es

$$P(Y = y \mid n, \pi) = \binom{n}{y} \pi^y (1 - \pi)^{n-y}, \quad y = 0, 1, \ldots, n.$$

- $E(Y \mid n, \pi) = n\pi$ y $\text{Var}(Y \mid n, \pi) = n\pi(1 - \pi)$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución Multinomial

- La distribución **multinomial** generaliza a la distribución **binomial** a C categorías.
- n ensayos independientes.
- Cada intento resulta en: $Y_{ij} = 1$ si el valor de la j-ésima categoría fue observada, $Y_{ij} = 0$ en otro caso.
- Sea $C = 3$, tal que el resultado de cualquier ensayo toma valores en $\{1, 2, 3\}$.
  - Si el resultado en el ensayo i es 1, entonces $\mathbf{Y}_i = (Y_{i1}, Y_{i2}, Y_{i3}) = (1, 0, 0)$.
  - Si el resultado en el ensayo i es 2, entonces $\mathbf{Y}_i = (Y_{i1}, Y_{i2}, Y_{i3}) = (0, 1, 0)$.
  - Si es 3, entonces $\mathbf{Y}_i = (Y_{i1}, Y_{i2}, Y_{i3}) = (0, 0, 1)$.
- Sea $\mathbf{N} = \sum_{i=1}^{n} \mathbf{Y}_i, \quad \mathbf{N} = (N_1, \ldots, N_C)$, conteo del número de ensayos en la categoría correspondiente.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución multinomial

- Variable de interés a la tendencia política.
- **Derecha** corresponde a 1, **izquierda** corresponde a 2 y **otra** corresponde a 3.
- $n = 6$ personas son muestreadas aleatoriamente.
- Observamos las categorías $1, 1, 3, 2, 1, 2$. Esto corresponde a los vectores:
  - $\mathbf{Y}_1 = (1, 0, 0)$,
  - $\mathbf{Y}_2 = (1, 0, 0)$, $\mathbf{Y}_3 = (0, 0, 1)$, $\mathbf{Y}_4 = (0, 1, 0)$, $\mathbf{Y}_5 = (1, 0, 0)$, y
  - $\mathbf{Y}_6 = (0, 1, 0)$.
- De esta forma, $\mathbf{N} = (3, 2, 1)$, $N_1 = 3$ personas de derecha, $N_2 = 2$ personas de izquierda, y $N_3 = 1$ de otra tendencia, de un total de $n = 6$.
- Note que $N_1 + N_2 + \cdots + N_C = n$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución Multinomial

- Sea $P(Y_{ij} = 1) = \pi_j, \qquad \sum_{j=1}^{C} \pi_j = 1.$

- La distribución de probabilidades está dada por

$$P(N_1 = n_1, \ldots, N_C = n_C \mid n, \boldsymbol{\pi}) = \frac{n!}{n_1! n_2! \cdots n_C!} \pi_1^{n_1} \pi_2^{n_2} \cdots \pi_C^{n_C},$$

  con $\sum_{j=1}^{C} n_j = n \quad$ y $\quad 0 \leq n_j \leq n.$

- Notación: $\mathbf{N} \mid n, \boldsymbol{\pi} \sim \text{Mult}(n, \boldsymbol{\pi})$.

- $E(N_j) = n\pi_j, \quad \text{Var}(N_j) = n\pi_j(1-\pi_j) \quad$ y $\quad \text{Cov}(N_j, N_k) = -n\pi_j\pi_k.$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución Multinomial

Supongamos que, para una persona seleccionada aleatoriamente, las probabilidades de pertenecer a cada tendencia política son:

$$\pi_1 = P(\text{derecha}) = \frac{1}{2}, \quad \pi_2 = P(\text{izquierda}) = \frac{1}{3}, \quad \pi_3 = P(\text{otra}) = \frac{1}{6}.$$

Observe que:

$$\pi_1 + \pi_2 + \pi_3 = \frac{1}{2} + \frac{1}{3} + \frac{1}{6} = 1.$$

Se seleccionan aleatoriamente $n = 6$ personas. ¿Cuál es la probabilidad de observar exactamente 3 personas de derecha, 2 personas de izquierda y 1 personas de otra tendencia?

$$P(N_1 = 3, N_2 = 2, N_3 = 1) = ?$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución Poisson

- Algunos conteos (esencialmente) no tienen una cota superior fija.
- Modela el # de eventos en el tiempo o espacio.
- $Y \mid \lambda \sim \text{Poisson}(\lambda)$.
- Distribución de probabilidades:

$$P(Y = y \mid \lambda) = \frac{\exp\{-\lambda\}}{y!}\lambda^y,$$

con

$$y = 0, 1, 2, \ldots \qquad \text{y} \qquad \lambda > 0.$$

- $E(Y \mid \lambda) = \lambda \qquad \text{y} \qquad \text{Var}(Y \mid \lambda) = \lambda.$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Pregunta



¿Conoce otras distribuciones de probabilidad útiles para modelar datos categóricos o de conteo?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo Lineal Generalizado

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

El modelo lineal generalizado

- **Modelos lineales generalizados (MLG):** Clase que incluye muchos modelos utilizados como casos especiales: regresión lineal, regresión logística (binaria y multinomial) y regresión Poisson, entre otras.

- **MLG:** Consideran muchos componentes que son similares a través de modelos (técnicas para ajustar los modelos, bondad del ajuste, etc).

- **MLG:** especificado por tres componentes:
  1. La distribución de la respuesta Y_i,
  2. el predictor lineal η_i.
  3. la función de enlace $g(\cdot)$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

El Modelo Lineal Generalizado

- El componente **aleatorio** es la respuesta, Y, bajo el supuesto de realizaciones independientes $\mathbf{Y} = (Y_1, \ldots, Y_N)$ desde una distribución de probabilidades perteneciente a la familia exponencial **(de 1 parámetro)**:

$$f(y_i \mid \vartheta_i) = a(\vartheta_i)h(y_i)\exp[y_i Q(\vartheta_i)]\,.$$

- Algunos miembros **(de 1 parámetro)** incluyen: Bernoulli, Binomial, Multinomial, Poisson, Chi-cuadrado, Geométrica, etc.

- ϑ_i es denominado el **parámetro natural**.

- ϑ_i puede depender de variables predictoras $\mathbf{x}_i = (1, x_{i1}, \ldots, x_{i,p-1})$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

El Modelo Lineal Generalizado

Si $Y_i \sim \text{Binomial}(n, \pi)$, su función de probabilidad es

$$f(y_i \mid \pi) = \binom{n}{y_i} \pi^{y_i} (1-\pi)^{n-y_i}.$$

Reordenando:

$$f(y_i \mid \pi) = \binom{n}{y_i} (1-\pi)^n \left(\frac{\pi}{1-\pi}\right)^{y_i} = \binom{n}{y_i} (1-\pi)^n \exp\left\{y_i \log\left(\frac{\pi}{1-\pi}\right)\right\}.$$

Comparando con

$$f(y_i \mid \vartheta_i) = a(\vartheta_i) h(y_i) \exp\left\{y_i Q(\vartheta_i)\right\},$$

se tiene:

$$a(\vartheta_i) = (1-\pi)^n, \qquad h(y_i) = \binom{n}{y_i}, \qquad Q(\vartheta_i) = \log\left(\frac{\pi}{1-\pi}\right).$$

Por lo tanto, la distribución binomial pertenece a la familia exponencial y su parámetro natural es $\vartheta_i = \log\left(\frac{\pi}{1-\pi}\right)$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

El Modelo Lineal Generalizado

- Componentes **sistemáticos:** $\boldsymbol{\eta} = (\eta_1, \ldots, \eta_n)$, donde

$$\eta_i = \beta_0 + \sum_{j=1}^{p-1} x_{ij}\beta_j = \mathbf{x}_i^\top \boldsymbol{\beta}.$$

- η_i es el **predictor lineal**.
- $\mathbf{x}_i = (1, x_{i1}, \ldots, x_{i,p-1})$ conjunto de predictores.
- $\boldsymbol{\beta}$ coeficientes de regresión.
- η_i relaciona $\mathbf{x}_i$ y ϑ_i vía la función de enlace.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

El Modelo Lineal Generalizado

- **Función de enlace** $g(\cdot)$ conecta componentes aleatorios Y_i y sistemáticos η_i.
- Sea $\mu_i = E(Y_i)$.
- Entonces $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta} = g(\mu_i)$.
- $g(\cdot)$ es monótona y suave.
- $g(m) = m$ es el enlace **identidad**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

El Modelo Lineal Generalizado

- El modelo queda definido por

$$E(Y_i) = g^{-1}(\beta_0 + x_{i1}\beta_1 + x_{i2}\beta_2 + \cdots + x_{i,p-1}\beta_{p-1}), \qquad i = 1, \ldots, n,$$

donde Y_i pertenece a la familia exponencial de 1 parámetro.

- $g^{-1}(\cdot)$ es denominada **la función de enlace inversa**.

- Opciones:
  1. $g(x) = x$, así $g^{-1}(x) = x$ **(enlace identidad)**.
  2. $g(x) = \log x$, así $g^{-1}(x) = e^x$ **(enlace log)**.
  3. $g(x) = \log\{x/(1-x)\}$, así $g^{-1}(x) = e^x/(1+e^x)$ **(enlace logit)**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo binario

- $g(\pi) = \log\left(\frac{\pi}{1-\pi}\right)$ es el enlace **logit**.

- $g(\pi)$ es la log-chance de $Y_i = 1$, también llamado el logito de π:

$$\text{logit}(\pi) = \log\left(\frac{\pi}{1-\pi}\right).$$

- Y_i se relaciona con $\mathbf{x}_i = (1, x_{i1}, \ldots, x_{i,p-1})$:

$$Y_i \sim \text{Bern}(\pi_i),$$

$$\log\left(\frac{\pi_i}{1-\pi_i}\right) = \beta_0 + x_{i1}\beta_1 + \cdots + x_{i,p-1}\beta_{p-1} = \mathbf{x}_i^\top \boldsymbol{\beta},$$

llamado modelo de **regresión logística**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo multinomial nominal

- Sea Y **categórica nominal** con J niveles.
- Sea $\pi_j = P(Y = j)$.
- Modelos logísticos **comparan** cada respuesta $Y = j$ con la categoría base, aquí $Y = J$:

$$\log\left(\frac{\pi_j}{\pi_J}\right) = \alpha_j + \mathbf{x}^\top \boldsymbol{\beta}_j, \qquad \text{para } j = 1, \ldots, J-1.$$

- Los parámetros son $\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_{J-1})$ y $(\boldsymbol{\beta}_1, \ldots, \boldsymbol{\beta}_{J-1})$.
- Este modelo es llamado modelo de **regresión logística multinomial**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo multinomial ordinal

- Sea Y **categórica ordinal** con J categorías.
- Una forma de usar el orden a través de logits de probabilidades acumuladas:

$$P(Y \leq j) = \pi_1 + \cdots + \pi_j, \qquad j = 1, \ldots, J.$$

- Logit acumulativos:

$$\begin{aligned} \text{logit}[P(Y \leq j)] &= \log\left(\frac{P(Y \leq j)}{P(Y > j)}\right) \\ &= \log\left(\frac{\pi_1 + \cdots + \pi_j}{\pi_{j+1} + \cdots + \pi_J}\right), \qquad j = 1, \ldots, J-1. \end{aligned} \tag{1}$$

- Este modelo es llamado modelo de **regresión logística ordinal o logit acumulativo**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo Poisson

- $g(\mu) = \log \mu$ es el enlace **log**.

- Y_i se relaciona con $\mathbf{x}_i = (1, x_{i1}, \ldots, x_{i,p-1})$:

$$Y_i \sim \text{Pois}(\mu_i), \qquad \log \mu_i = \beta_0 + x_{i1}\beta_1 + \cdots + x_{i,p-1}\beta_{p-1},$$

llamado modelo de **regresión Poisson**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Pregunta



¿Qué otros modelos lineales generalizados conoce?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo de Regresión Logística

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Problema de Clasificación

- Una persona entra a la emergencia de un hospital con ciertos síntomas y es necesario determinar qué enfermedad tiene.

- Un banco necesita determinar si una operación de la banca en línea es fraudulenta. Se tienen datos sobre la dirección IP, historial de transacciones, etc.

- Usando la secuencia de ADN, un biólogo está interesado en estudiar qué mutaciones de este causan determinado tipo de enfermedad.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Problema de Clasificación

- Una institución financiera está interesada en determinar la condición de sus clientes en términos del pago de su deuda en tarjeta de crédito.

- Se dispone de información sobre el ingreso y estado de cuenta mensual de la tarjeta de crédito de cada cliente.

- La idea es predecir la condición del cliente y tomar ciertas medidas preventivas.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Problema de Clasificación

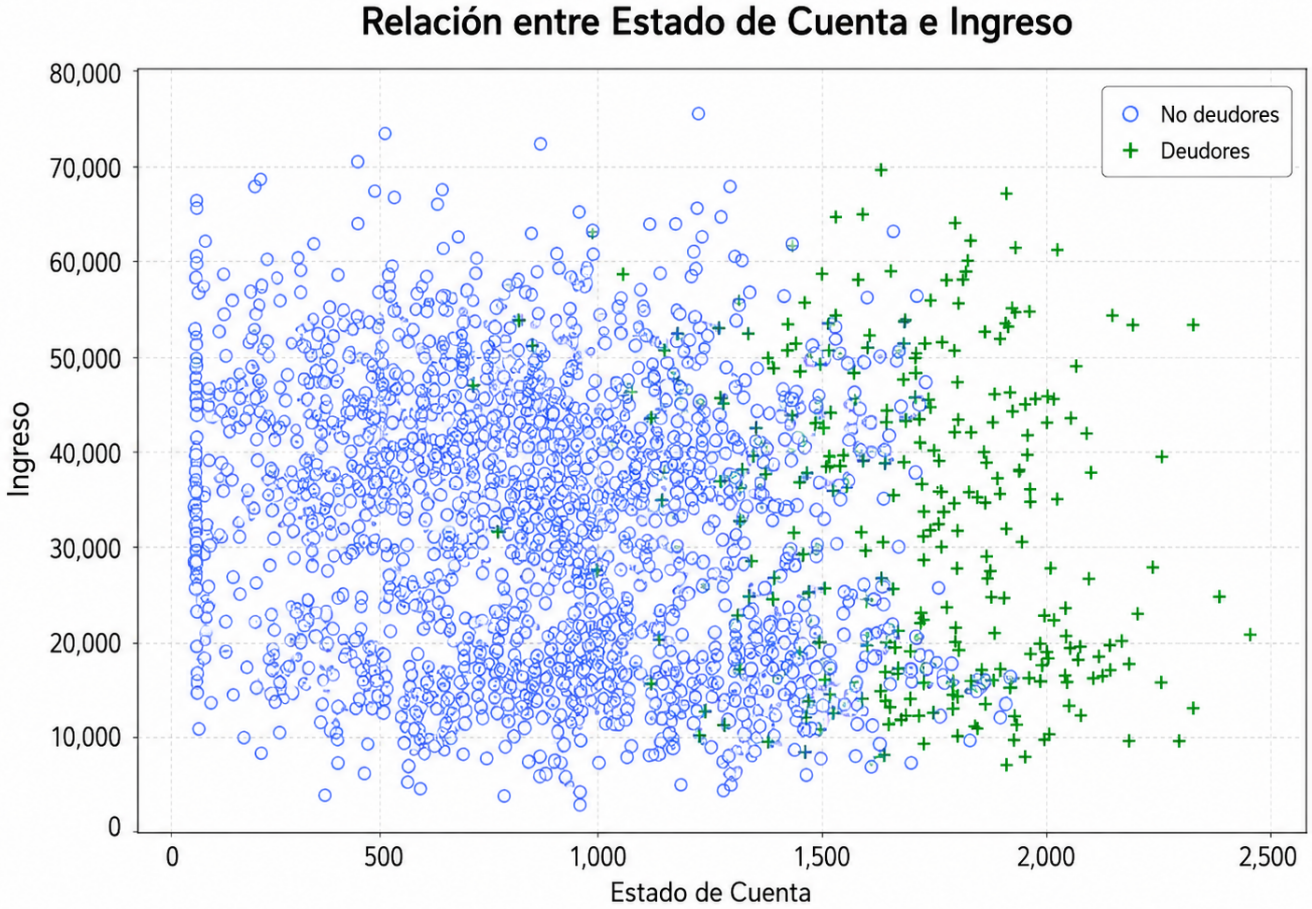


Figura 1. Deudores en verde / No deudores en azul

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Problema de Clasificación

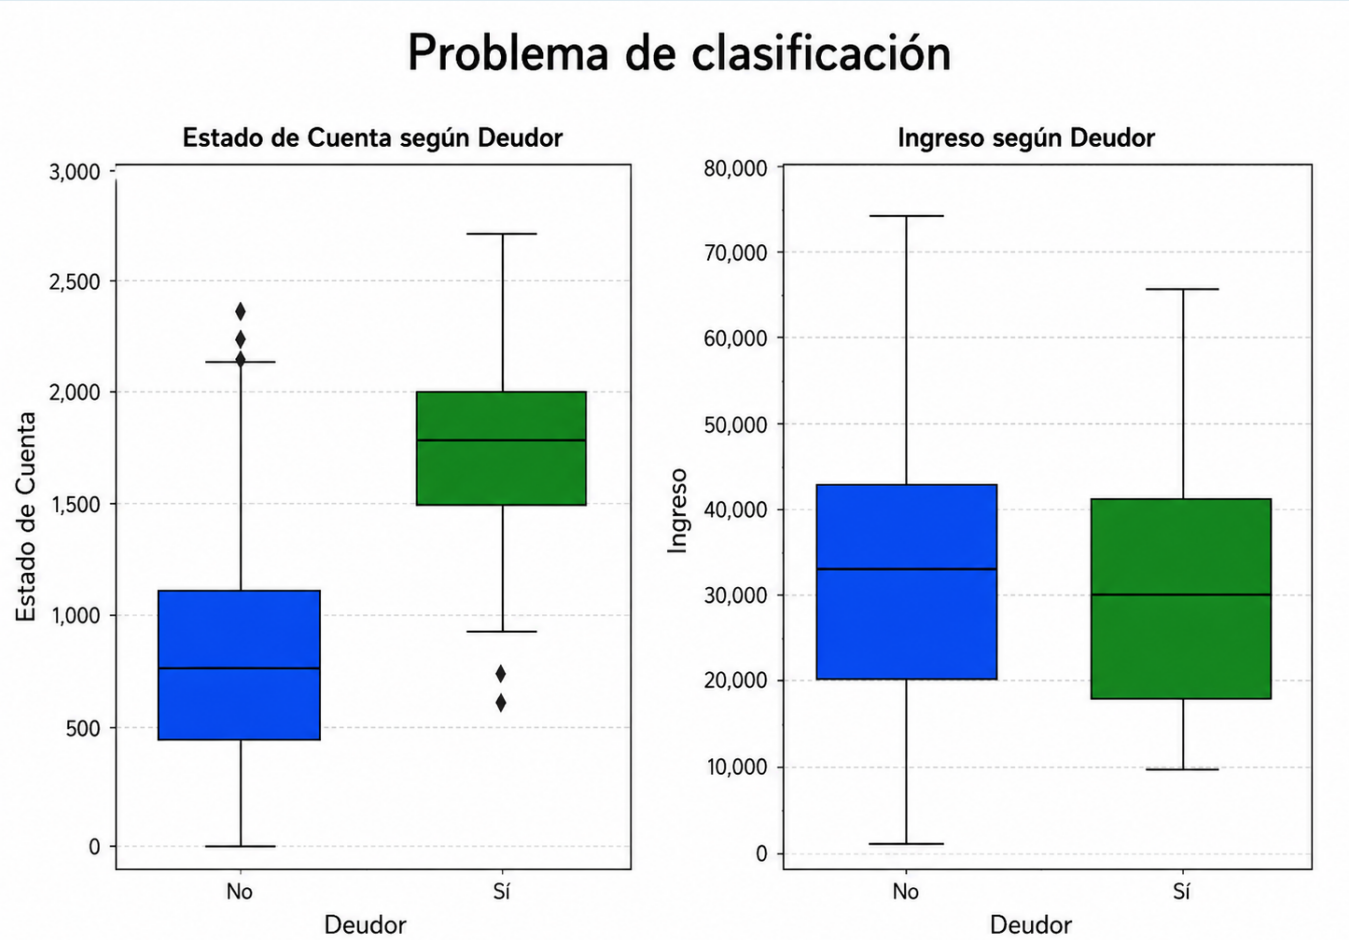


Figura 2. Distribución de Estado de Cuenta e Ingreso según condición de deuda

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión logística

- Un modelo de clasificación basado en lo anterior propone predecir si un sujeto tendrá deuda o no, usando el estado de cuenta mensual.

- Si usamos un modelo de regresión simple, tendremos que $Y = \beta_0 + \beta_1 X$, donde $Y = 0/1$ ($0 =$ no deuda, $1 =$ deuda) y X es el estado de cuenta mensual.

- ¿Qué pasa si estimamos $\widehat{Y}$ usando $\widehat{\beta}_0 + \widehat{\beta}_1 X$ para determinado sujeto?

- ¿Podemos usar lo anterior para estimar

$$P(\text{deuda} \mid \text{estado de cuenta})?$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión Logística

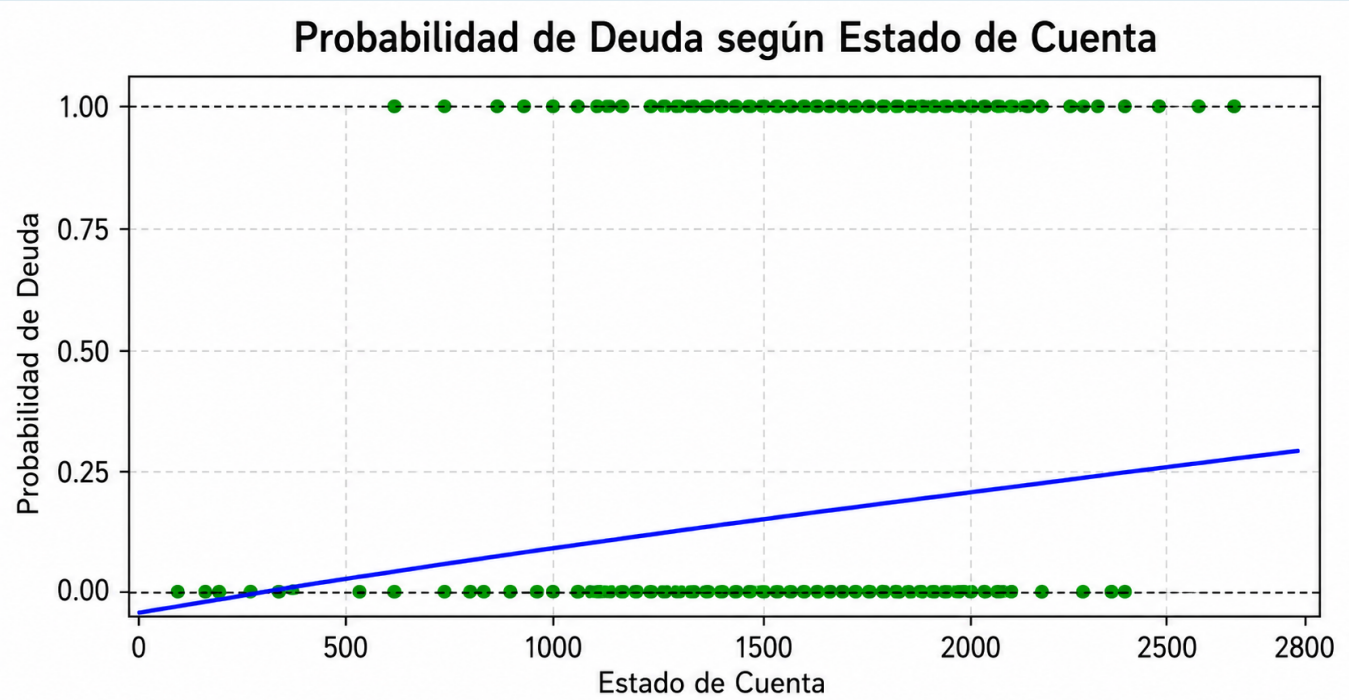


Figura 3. Probabilidad de deuda en función del estado de cuenta

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión logística

- El modelo de regresión logística busca modelar

$$P(\text{deuda} \mid \text{estado de cuenta})$$

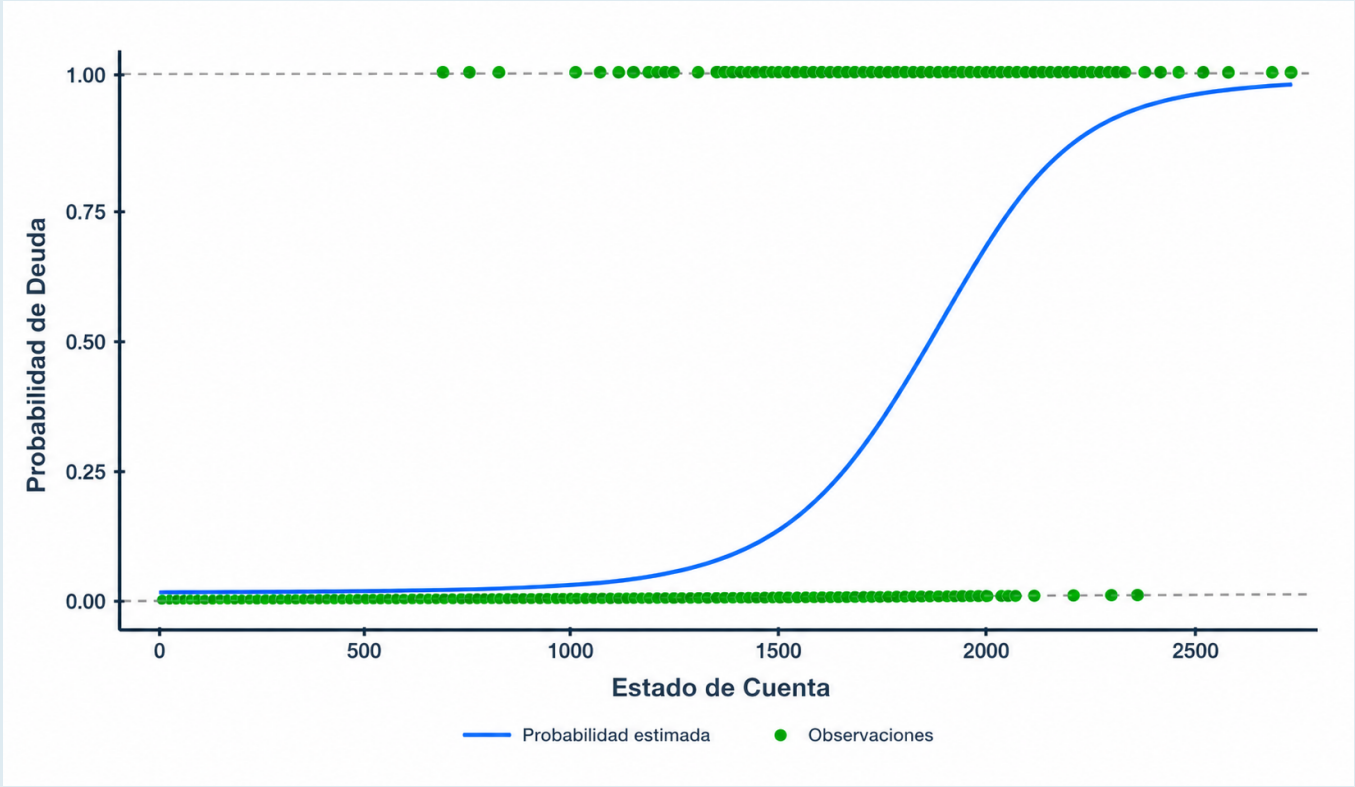
usando la función logística:

$$\pi_i(x_i) = \frac{\exp(\beta_0 + \beta_1 x_i)}{1 + \exp(\beta_0 + \beta_1 x_i)}.$$

- En el caso múltiple, se puede considerar:
  - $\mathbf{x}_i = (1, x_{i1}, \ldots, x_{i,p-1})$, un vector p-dimensional de predictores, incluyendo el valor 1 correspondiente al intercepto.
  - $\boldsymbol{\beta} = (\beta_0, \ldots, \beta_{p-1})$ es un vector p-dimensional de coeficientes de regresión. Estos son parámetros desconocidos.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión Logística



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión logística

- **Chance:**

$$\frac{\pi(x)}{1-\pi(x)} = \exp\{\beta_0 + \beta_1 x\}.$$

- Lo anterior se conoce como la **chance**.

- La **chance** puede tomar valores entre 0 e ∞.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión logística

- **Log chance:**

$$\log\left(\frac{\pi(x)}{1-\pi(x)}\right) = \beta_0 + \beta_1 x.$$

- Lo anterior se conoce como el **logit**.

- El **logit** es lineal en X.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión logística

- **Razón de chances (OR):** cambio en la chance de un evento cuando x cambia en una unidad:

$$\frac{\pi(x+1)/[1-\pi(x+1)]}{\pi(x)/[1-\pi(x)]} = \frac{\left[\dfrac{e^{\beta_0+\beta_1 x+\beta_1}}{1+e^{\beta_0+\beta_1 x+\beta_1}}\right] \Big/ \left[\dfrac{1}{1+e^{\beta_0+\beta_1 x+\beta_1}}\right]}{\left[\dfrac{e^{\beta_0+\beta_1 x}}{1+e^{\beta_0+\beta_1 x}}\right] \Big/ \left[\dfrac{1}{1+e^{\beta_0+\beta_1 x}}\right]}$$

$$= \frac{e^{\beta_0+\beta_1 x+\beta_1}}{e^{\beta_0+\beta_1 x}} = e^{\beta_1}.$$

- Cuando aumentamos x en una unidad, la chance del evento aumenta en el factor e^{β_1}, **independientemente del valor de** x.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión logística

- Los coeficientes se interpretan de la siguiente forma:
  - Si $\beta > 0$, entonces $\mathrm{OR} > 1$ y, por tanto, X es un **factor de riesgo**.
  - Si $\beta = 0$, entonces $\mathrm{OR} = 1$ y, por tanto, no hay efecto del factor X.
  - Si $\beta < 0$, entonces $\mathrm{OR} < 1$ y, por tanto, X es un **factor protector**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Regresión logística

- **Predicción:**

$$\widehat{\pi}_i = \frac{\exp\left(\widehat{\beta}_0 + \widehat{\beta}_1 x_i\right)}{1 + \exp\left(\widehat{\beta}_0 + \widehat{\beta}_1 x_i\right)}.$$

- En el caso múltiple es posible utilizar predictores continuos y categóricos.

- ¿Cómo son los resultados en el caso del problema de clasificación?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Pregunta



¿Considera útil el modelo de regresión logística como clasificador binario?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Métricas de Desempeño para Clasificadores Binarios



Errores de clasificación

- En la práctica, un clasificador binario comete dos tipos de errores.

- Se puede asignar incorrectamente a un individuo como 0 cuando, en realidad, es 1.

- En otras palabras, se puede clasificar a un individuo como **No Default** cuando, en realidad, sí caerá en **Default**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Matriz de confusión

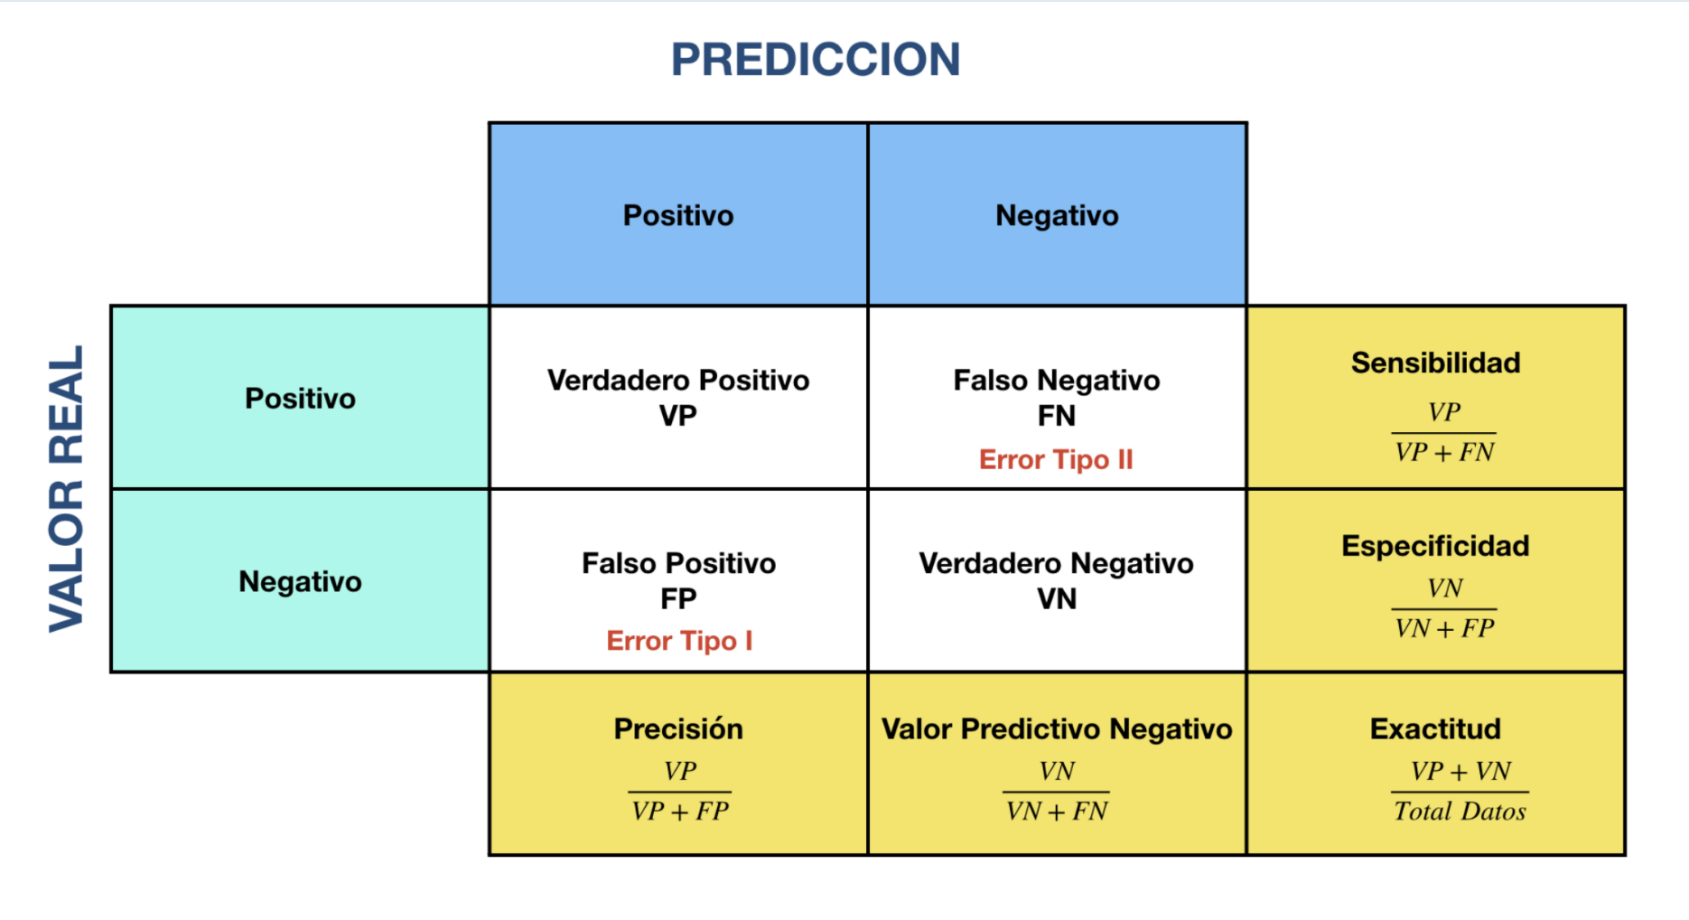
- La matriz de confusión es una matriz de doble entrada que permite ver el grado de buena o mala clasificación determinada por el clasificador.

- En el caso del ejemplo del **Default**, permite visualizar el número de individuos clasificados correcta e incorrectamente a la vez.

- **Sensibilidad y especificidad:** caracterizan el desempeño del clasificador.

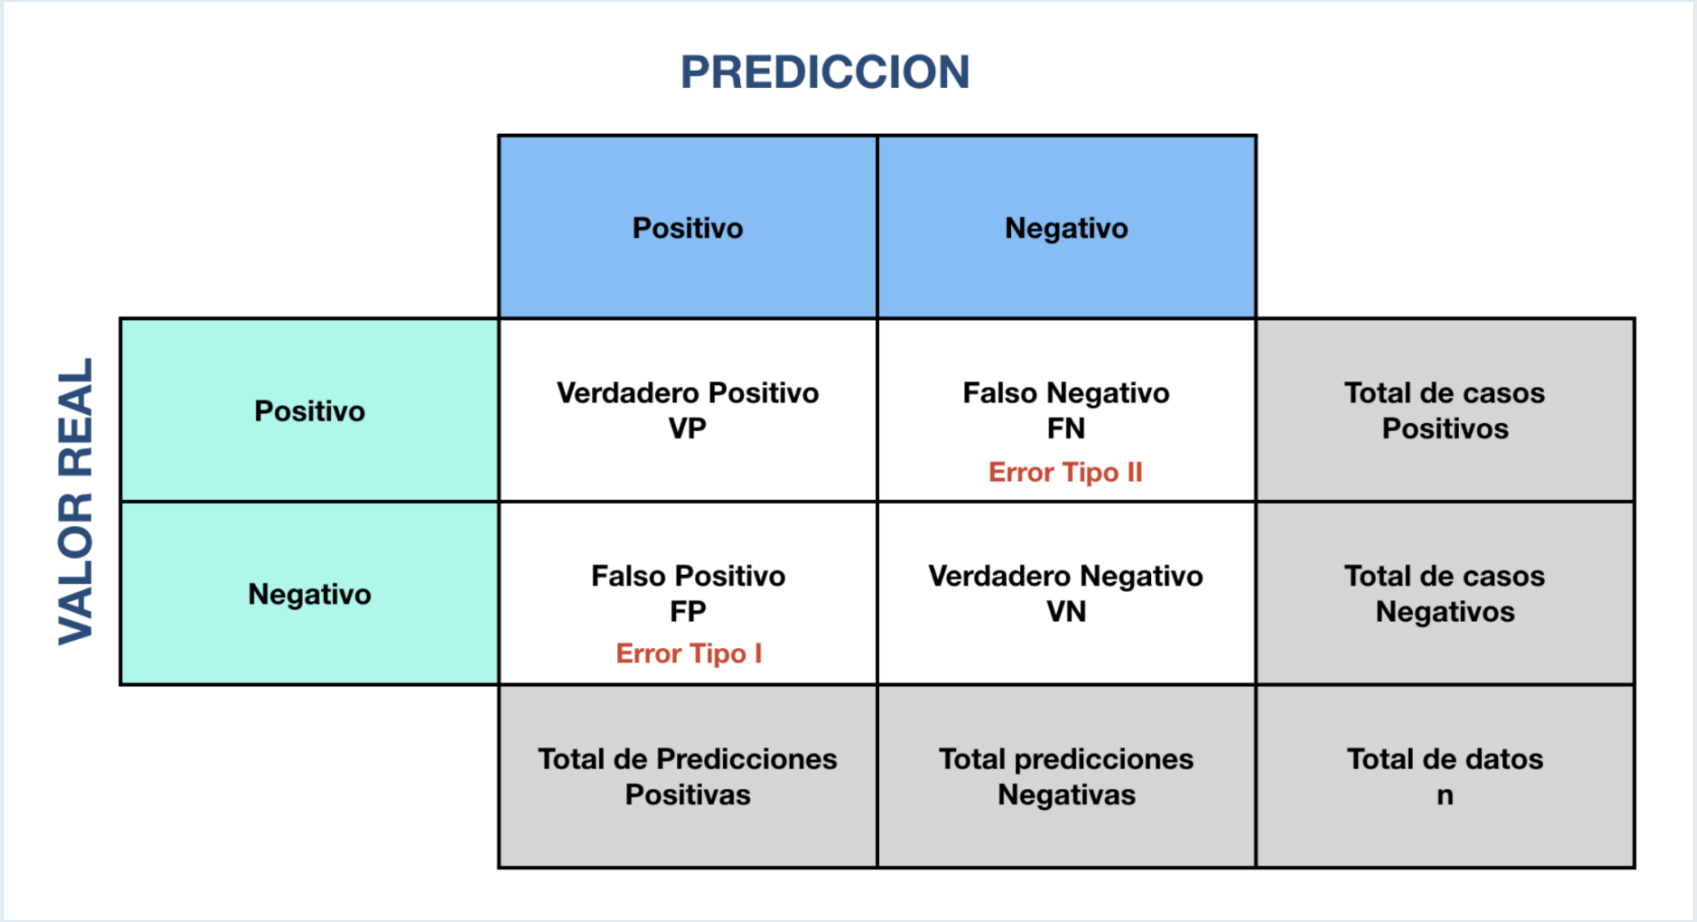
DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Matriz de Confusión



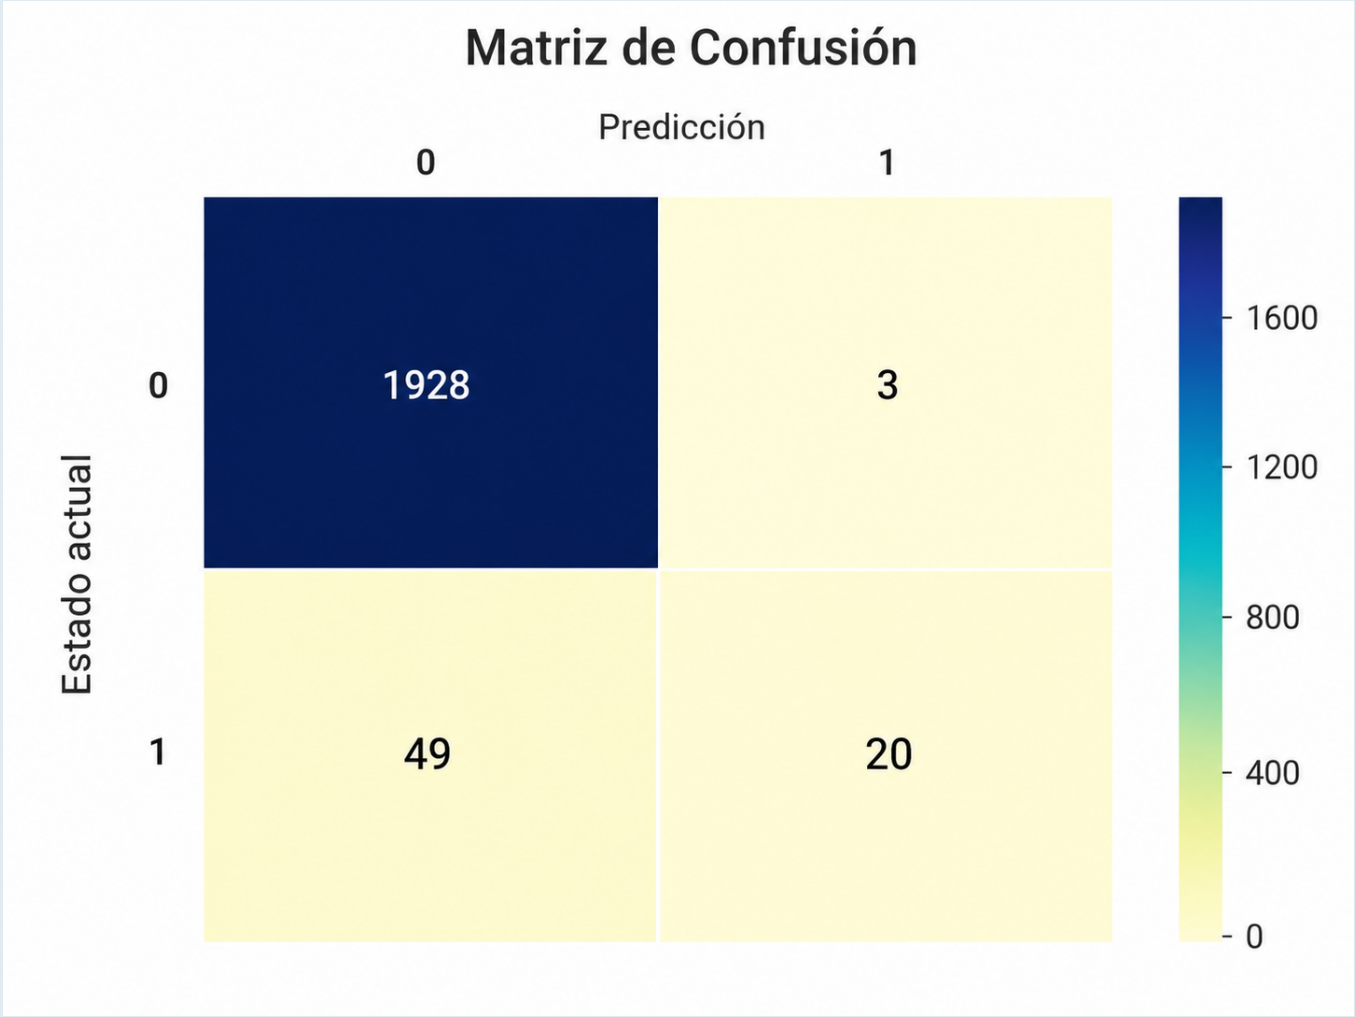
DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Matriz de Confusión



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Matriz de Confusión



Matriz de confusión

- **Precisión:** precisión del modelo al realizar una predicción. Indica qué tan correcto es el modelo al momento de predecir. En el ejemplo, la precisión total es del $97\,\%$.

- Formalmente, la precisión se define como

$$\text{Precision} = \frac{VP}{VP + FP},$$

  donde VP es el número de verdaderos positivos y FP es el número de falsos positivos.

- Intuitivamente, la precisión representa la capacidad del clasificador de no etiquetar como positivo un ejemplo que en realidad es negativo.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Matriz de confusión

- **Recall:** si existen ejemplos positivos en el conjunto de prueba, el modelo puede identificarlos correctamente en un $97\,\%$ de los casos.

- Formalmente, el recall se define como

$$\text{Recall} = \frac{VP}{VP + FN},$$

donde VP es el número de verdaderos positivos y FN es el número de falsos negativos.

- Intuitivamente, el recall representa la capacidad del clasificador para "encontrar" todos los ejemplos positivos presentes en la muestra.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Sensibilidad y especificidad

- **Sensibilidad:** porcentaje de verdaderos positivos identificados; en el ejemplo, corresponde a los verdaderos morosos.

- **Especificidad:** porcentaje de verdaderos negativos identificados; en el ejemplo, corresponde a los verdaderos no morosos.

- Por lo tanto, $1 -$ **Especificidad** corresponde al porcentaje de falsos positivos identificados.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Curva ROC

- **Predicción:** la clasificación se realiza respecto de un valor umbral o condición de corte.

- Esto significa establecer un criterio para asignar

$$\widehat{Y}_i = \begin{cases} 1, & \text{si } \widehat{\pi}_i > \pi_0, \\ 0, & \text{si } \widehat{\pi}_i \leq \pi_0. \end{cases}$$

- El valor que usualmente se considera para el umbral π_0 es $0{,}5$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Curva ROC

- En términos de probabilidades:
  - **Sensibilidad:**

$$P\left(\widehat{Y} = 1 \mid Y = 1\right).$$

  - **Especificidad:**

$$P\left(\widehat{Y} = 0 \mid Y = 0\right).$$

- ¿Cómo cambian la sensibilidad y la especificidad al modificar los valores del umbral π_0?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Curva ROC

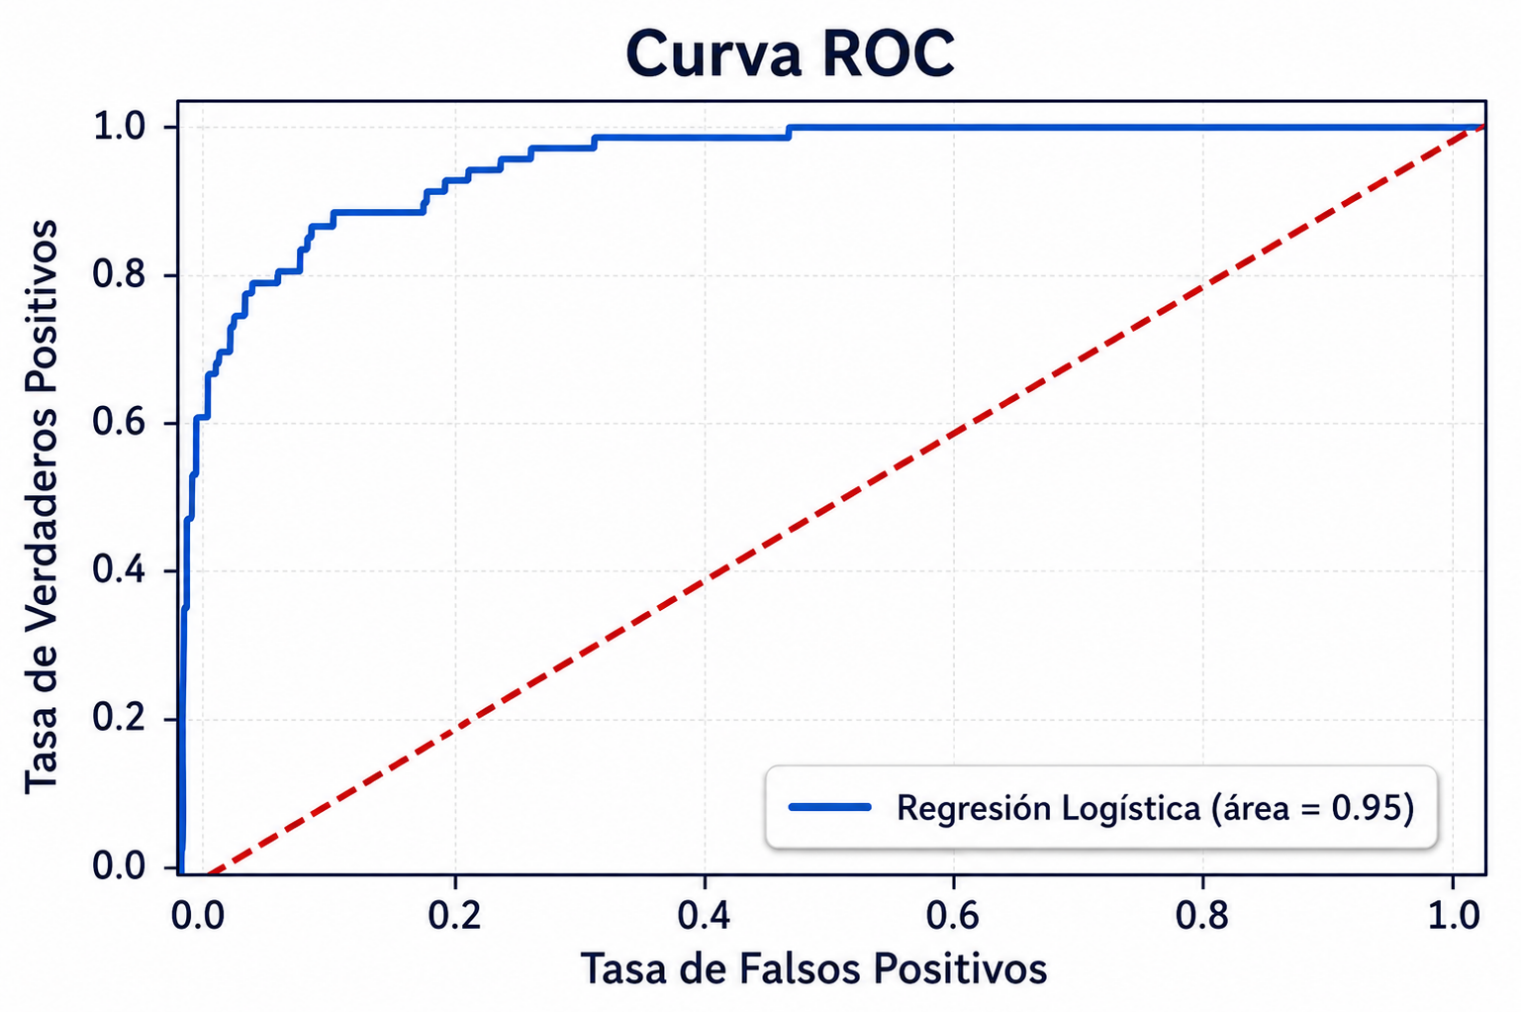
- La curva ROC es un gráfico que permite visualizar simultáneamente los dos tipos de errores cometidos en función de diferentes valores de la **condición de borde (umbral)**.

- Recordar que la condición de borde es el valor considerado para tomar la decisión del clasificador; es decir, clasificar según si la probabilidad estimada es mayor o menor que cierto valor.

- El objetivo de la curva ROC es tener una idea del desempeño del clasificador para varios valores del **umbral**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Curva ROC



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Curva ROC

- Un clasificador que asigna las clases al azar debería presentar un comportamiento similar al de la línea diagonal.

- Un clasificador con buen desempeño tendrá una curva cercana a la esquina superior izquierda.

- Por lo tanto, una forma de comparar el desempeño de dos clasificadores consiste en considerar el **área bajo la curva ROC**, conocida como **AUC**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Pregunta



¿Qué pasa cuando la proporción de 1's o 0's es muy pequeña?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS