Clase 21. Modelo Regresión Logistica Binomial

Maritza Marquez

2026-04-03

Descripción de los datos

El conjunto de datos `wcgs` proviene del paquete `faraway` y corresponde al estudio **Western Collaborative Group Study (WCGS)**, un estudio longitudinal clásico en epidemiología cardiovascular.

El **WCGS** fue un estudio prospectivo diseñado para investigar factores de riesgo asociados a enfermedades cardiovasculares, particularmente la enfermedad coronaria. El dataset está compuesto por 3154 observaciones tal que:

- **Población**: hombres adultos inicialmente sanos.
- **Diseño**: estudio longitudinal (seguimiento en el tiempo).
- **Objetivo**: identificar factores que aumentan el riesgo de desarrollar enfermedad coronaria.

Variables

- chd (Coronary Heart Disease). Es la variable típica para modelar bajo regresión logística, por ejemplo.
  - `0` : no desarrolló enfermedad coronaria.
  - `1` : desarrolló enfermedad coronaria durante el seguimiento.
- cigs (cigarrillos por día). Representa el consumo diario de cigarrillos (variable clave porque el tabaquismo es un factor de riesgo clásico en un análisis como este).
- age: edad.
- chol: colesterol.
- sbp: presión sistólica.
- dbp: presión diastólica.
- bmi: índice de masa corporal.
- typea: comportamiento tipo A.
- height, weight: medidas físicas

El siguiente conjunto de datos conviene trabajarlo mediante una `regresión logística Bernoulli` con función de enlace `logit` , porque el dataset `wcgs` la variable de interés `chd` es binaria (0,1) y `cigs` es una covariable cuantitativa.

1) Cargamos el dataset y exploramos las variables

Primero conviene verificar que las variables estén disponibles, revisar el tipo y hacer una exploración descriptiva mínima para entender el dataset. Aquí el objetivo no es todavía ajustar el modelo, sino dejar claro qué se va a modelar:

- **chd**: variable respuesta binaria de interés.
- **cigs**: número de cigarrillos.
- como el modelo es Bernoulli, cada observación representa un individuo con $Y_i \in \{0, 1\}$.

```
# Parte 1: carga y exploración inicial

# Instalar si hace falta
#if (!require(faraway)) install.packages("faraway")
library(faraway)

# Cargar datos
data(wcgs)

# Revisar estructura
str(wcgs)
```

```
## 'data.frame':    3154 obs. of  13 variables:
##  $ age    : int  49 42 42 41 59 44 44 40 43 42 ...
##  $ height : int  73 70 69 68 70 72 72 71 72 70 ...
##  $ weight : int  150 160 160 152 150 204 164 150 190 175 ...
##  $ sdp    : int  110 154 110 124 144 150 130 138 146 132 ...
##  $ dbp    : int  76 84 78 78 86 90 84 60 76 90 ...
##  $ chol   : int  225 177 181 132 255 182 155 140 149 325 ...
##  $ behave : Factor w/ 4 levels "A1","A2","B3",..: 2 2 3 4 3 4 4 2 3 2 ...
##  $ cigs   : int  25 20 0 20 20 0 0 0 25 0 ...
##  $ dibep  : Factor w/ 2 levels "A","B": 1 1 2 2 2 2 2 1 2 1 ...
##  $ chd    : Factor w/ 2 levels "no","yes": 1 1 1 1 2 1 1 1 1 1 ...
##  $ typechd: Factor w/ 4 levels "angina","infdeath",..: 3 3 3 3 2 3 3 3 3 3 ...
##  $ timechd: int  1664 3071 3071 3064 1885 3102 3074 3071 3064 1032 ...
##  $ arcus  : Factor w/ 2 levels "absent","present": 1 2 1 1 2 1 1 1 1 2 ...
```

```
# Quedarnos solo con las variables de interés
datos <- na.omit(wcgs[, c("chd", "cigs")])

# Resumen descriptivo
summary(datos)
```

```
##   chd           cigs
##  no :2897   Min.   : 0.0
##  yes: 257   1st Qu.: 0.0
##             Median : 0.0
##             Mean   :11.6
##             3rd Qu.:20.0
##             Max.   :99.0
```

```
# Frecuencias de la respuesta
table(datos$chd)
```

```
##
##   no  yes
## 2897  257
```

```
prop.table(table(datos$chd))
```

```
##
##         no        yes
## 0.91851617 0.08148383
```

```
# Resumen de cigs según chd
tapply(datos$cigs, datos$chd, summary)
```

```
## $no
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.00    0.00    0.00   11.15   20.00   99.00
##
## $yes
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##    0.00    0.00   20.00   16.67   30.00   60.00
```

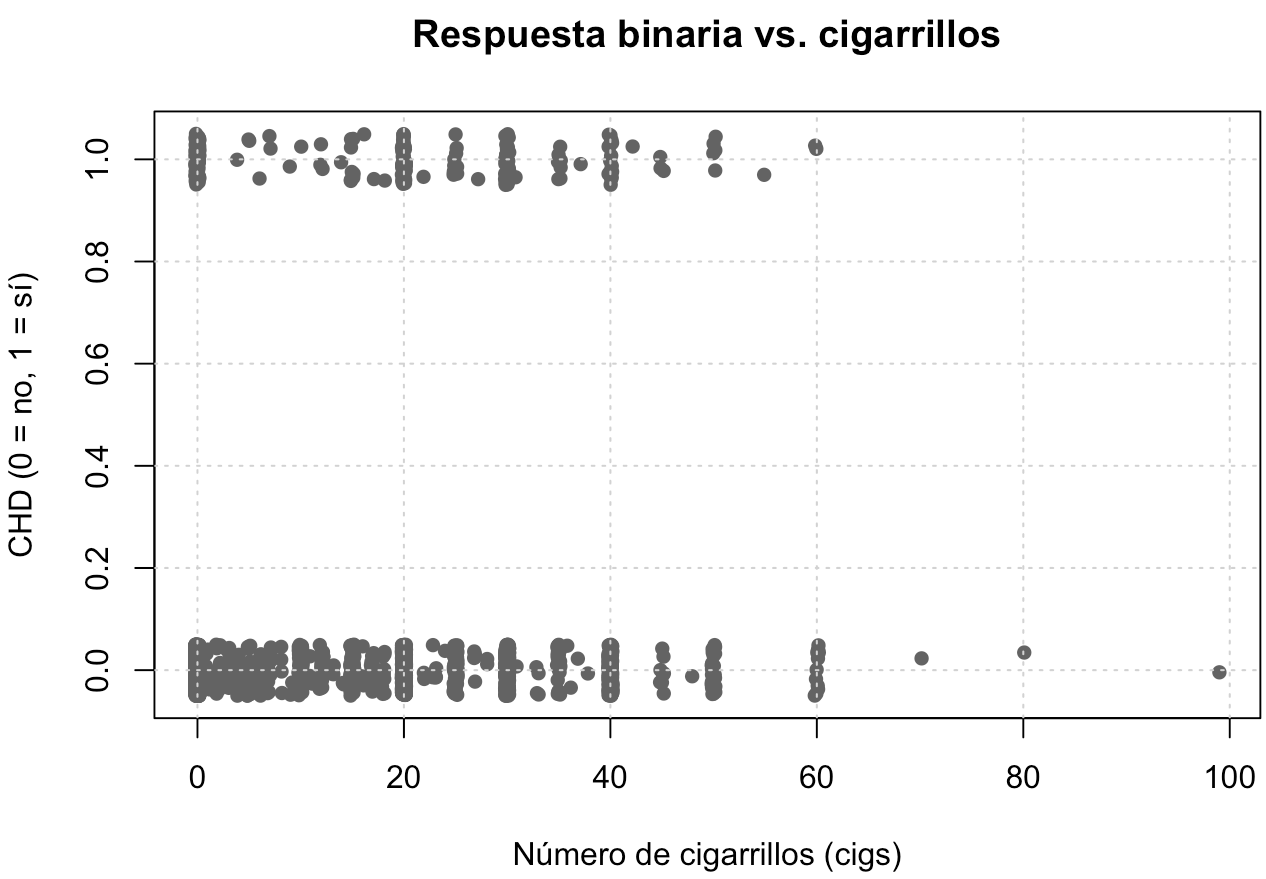
2) Visualización inicial de la relación entre `chd` y `cigs`

Antes de ajustar el modelo, veamos gráficamente la relación entre la respuesta binaria y la covariable cuantitativa de interés. La idea es mostrar que no vamos a ajustar una recta sobre Y, sino una probabilidad de éxito:

$$P(Y = 1|x) = p(x)$$

```
# Parte 2: gráfico exploratorio

chd_num <- as.numeric(datos$chd) - 1
plot(jitter(datos$cigs), jitter(chd_num, amount = 0.05), #Como los datos binarios se mon
tan unos sobre otros, conviene usar jitter
     xlab = "Número de cigarrillos (cigs)",
     ylab = "CHD (0 = no, 1 = sí)",
     main = "Respuesta binaria vs. cigarrillos",
     pch = 16, col = "gray40")
grid()
```



3) Ajustemos un GLM con función de enlace “logit”

$$log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 * cigs_i$$

Modelo propuesto

```
# Parte 3: ajuste del modelo glm con enlace logit

mod_logit <- glm(chd ~ cigs, data = datos, family = binomial(link = "logit"))

summary(mod_logit)
```

```
##
## Call:
## glm(formula = chd ~ cigs, family = binomial(link = "logit"),
##     data = datos)
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept) -2.742160   0.092111 -29.770  < 2e-16 ***
## cigs         0.023220   0.004042   5.744 9.22e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1781.2  on 3153  degrees of freedom
## Residual deviance: 1750.0  on 3152  degrees of freedom
## AIC: 1754
##
## Number of Fisher Scoring iterations: 5
```

Bondad de ajuste del modelo

- La deviance nula corresponde al modelo que contiene únicamente el intercepto: $logit(pi) = \beta_0$. Por lo tanto 1781.2 representa la falta de ajuste del modelo simple.
- La deviance residual corresponde al modelo que incorpora la variable `cigs` : $logit(pi) = \beta_0 + \beta_1 cigs_i$ y representa la falta de ajuste del modelo de interés. En este caso, observamos que disminuye de 1781.2 a 1750.0, incluir el número de cigarrillos mejorando el ajuste del modelo.
- En un modelo binomial, la varianza viene determinada por la media: $Var(Y_i) = p_i(1 - p_i)$ para una respuesta Bernoulli, o bien $Var(Y_i) = n_i\, p_i(1 - p_i)$ para una respuesta binomial agrupada. El párametro de dispersión no se estima libremente, sino que se fija en $\phi = 1$.
- El criterio de información de Akaike (AIC) combina dos elementos: $AIC = -2logL + 2k$, donde L es la verosimilitud del modelo y k es el número de parámetros estimados.

```
# Ajustamos otros modelos

mod_logit <- glm(
  chd ~ cigs,
  data = datos,
  family = binomial(link = "logit")
)

mod_probit <- glm(
  chd ~ cigs,
  data = datos,
  family = binomial(link = "probit")
)

mod_cloglog <- glm(
  chd ~ cigs,
  data = datos,
  family = binomial(link = "cloglog")
)
```

Y comparamos sus AIC

```
AIC(mod_logit, mod_probit, mod_cloglog)
```

```
##             df      AIC
## mod_logit    2 1753.969
## mod_probit   2 1753.495
## mod_cloglog  2 1754.246
```

Modelos Anidados

Dos modelos son anidados cuando uno se obtiene eliminando variables del otro. Veamos el ejemplo a continuación:

```
# Ajustamos otros modelos

mod_1 <- glm(
  chd ~ cigs,
  data = wcgs,
  family = binomial(link = "logit")
)

mod_2 <- glm(
  chd ~ cigs + age,
  data = wcgs,
  family = binomial(link = "logit")
)

mod_3 <- glm(
  chd ~ cigs + age + chol,
  data = wcgs,
  family = binomial(link = "logit")
)
```

En ese caso, además del AIC, se puede utilizar una prueba de razón de verosimilitudes:

```
anova(mod_1, mod_2, test = "Chisq")
```

```
## Analysis of Deviance Table
##
## Model 1: chd ~ cigs
## Model 2: chd ~ cigs + age
##   Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
## 1      3152     1750.0
## 2      3151     1705.9  1   44.109 3.105e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Esta prueba evalúa: $H_0 : \beta_{age} = 0$ vs $H_1 : \beta_{age} \neq 0$

Si el p-valor es pequeño, la variable o el grupo de variables incorporado mejora significativamente el ajuste.

Diferencia entre ambos criterios

- El AIC responde:
    - ¿Cuál de los modelos presenta un mejor equilibrio entre ajuste y complejidad?
- La prueba de razón de verosimilitudes responde:
    - ¿La incorporación de las nuevas variables mejora significativamente el ajuste?

4) Interpretación de los coeficientes

Después del ajuste, conviene observar que pasa con:

- $\widehat{\beta}_0$: log-odds cuando $cigs = 0$.
- $\widehat{\beta}_1$: cambio en el log-odds por cada cigarrillo adicional.
- $e^{\widehat{\beta}_1}$: odds ratio por cada unidad de cigs.

```
# Parte 4: interpretación de los coeficientes

# Coeficientes estimados en escala logit
coeficientes <- coef(mod_logit)
coeficientes
```

```
## (Intercept)        cigs
## -2.74215950  0.02321981
```

```
beta0 <- coeficientes["(Intercept)"]
beta1 <- coeficientes["cigs"]

# Exponencial de los coeficientes
odds0 <- exp(beta0)
OR_1  <- exp(beta1)

# Probabilidad estimada cuando cigs = 0
prob0 <- plogis(beta0)

# Cambio porcentual en los odds por cada cigarrillo adicional
cambio_porcentual <- 100 * (OR_1 - 1)

# Odds ratios para aumentos de 5, 10 y 20 cigarrillos diarios
OR_5  <- exp(5 * beta1)
OR_10 <- exp(10 * beta1)
OR_20 <- exp(20 * beta1)

# Mostrar resultados
cat("Intercepto estimado:", round(beta0, 4), "\n")
```

```
## Intercepto estimado: -2.7422
```

```
cat("Pendiente estimada para cigs:", round(beta1, 4), "\n\n")
```

```
## Pendiente estimada para cigs: 0.0232
```

```
cat("Odds para una persona que fuma 0 cigarrillos:",
    round(odds0, 4), "\n")
```

```
## Odds para una persona que fuma 0 cigarrillos: 0.0644
```

```
cat("Probabilidad estimada de CHD para una persona que fuma 0 cigarrillos:",
    round(prob0, 4), "\n\n")
```

```
## Probabilidad estimada de CHD para una persona que fuma 0 cigarrillos: 0.0605
```

```
cat("Odds ratio por cada cigarrillo adicional:",
    round(OR_1, 4), "\n")
```

```
## Odds ratio por cada cigarrillo adicional: 1.0235
```

```
cat("Cambio porcentual en los odds por cada cigarrillo adicional:",
    round(cambio_porcentual, 2), "%\n\n")
```

```
## Cambio porcentual en los odds por cada cigarrillo adicional: 2.35 %
```

```
cat("Odds ratio por 5 cigarrillos adicionales:",
    round(OR_5, 4), "\n")
```

```
## Odds ratio por 5 cigarrillos adicionales: 1.1231
```

```
cat("Odds ratio por 10 cigarrillos adicionales:",
    round(OR_10, 4), "\n")
```

```
## Odds ratio por 10 cigarrillos adicionales: 1.2614
```

```
cat("Odds ratio por 20 cigarrillos adicionales:",
    round(OR_20, 4), "\n")
```

```
## Odds ratio por 20 cigarrillos adicionales: 1.5911
```

En general para un aumento de k cigarrillos, el odds ratio es: $OR(k) = exp(k\hat{\beta}_1))$.

Si este valor es por ejemplo 1.2614, se interpretaría así: Una persona que fuma 10 cigarrillos diarios más que otra presenta unos odds estimados de desarrollar enfermedad coronaria 1.35 veces más que la otra persona; es decir, aproximadamente un 35% mayores.

```
#Parte 5. Intervalos de Confianza para los odds ratios

# Intervalos de confianza de los coeficientes
IC_beta <- confint(mod_logit)
```

```
## Waiting for profiling to be done...
```

```
# Intervalos de confianza en escala de odds ratios
IC_OR <- exp(IC_beta)

IC_OR
```

```
##                 2.5 %     97.5 %
## (Intercept) 0.05356251 0.07687144
## cigs        1.01535443 1.03159008
```

```
cat(
  "Por cada cigarrillo adicional consumido diariamente,",
  "los odds de desarrollar enfermedad coronaria se multiplican por",
  round(exp(beta1), 3),
  ". El intervalo de confianza del 95% para este odds ratio es",
  paste0(
    "(",
    round(exp(IC_beta["cigs", 1]), 3),
    ", ",
    round(exp(IC_beta["cigs", 2]), 3),
    ")."
  )
)
```

```
## Por cada cigarrillo adicional consumido diariamente, los odds de desarrollar enfermed
ad coronaria se multiplican por 1.023 . El intervalo de confianza del 95% para este odds
ratio es (1.015, 1.032).
```

La regla de interpretación es:

- Si el intervalo contiene al valor 1, no existe evidencia estadísticamente significativa de una asociación entre el consumo de cigarrillos y la enfermedad coronaria al nivel del 5%.
- Si todo el intervalo está por encima de 1, un mayor consumo se asocia con mayores odds de enfermedad coronaria.
- Si todo el intervalo está por debajo de 1, un mayor consumo se asocia con menores odds.

```
# Parte 6. Resumen de los Odds

tabla_interpretacion <- data.frame(
  Cantidad = c(
    "Intercepto",
    "Efecto de 1 cigarrillo",
    "Efecto de 5 cigarrillos",
    "Efecto de 10 cigarrillos",
    "Efecto de 20 cigarrillos"
  ),
  Valor = c(
    exp(beta0),
    exp(beta1),
    exp(5 * beta1),
    exp(10 * beta1),
    exp(20 * beta1)
  ),
  Interpretacion = c(
    "Odds estimados de CHD cuando cigs = 0",
    "Factor multiplicativo de los odds por 1 cigarrillo adicional",
    "Factor multiplicativo de los odds por 5 cigarrillos adicionales",
    "Factor multiplicativo de los odds por 10 cigarrillos adicionales",
    "Factor multiplicativo de los odds por 20 cigarrillos adicionales"
  )
)

tabla_interpretacion$Valor <- round(tabla_interpretacion$Valor, 4)

knitr::kable(
  tabla_interpretacion,
  caption = "Interpretación contextual de los coeficientes del modelo logístico"
)
```

Interpretación contextual de los coeficientes del modelo logístico

Cantidad	Valor	Interpretacion
Intercepto	0.0644	Odds estimados de CHD cuando cigs = 0
Efecto de 1 cigarrillo	1.0235	Factor multiplicativo de los odds por 1 cigarrillo adicional
Efecto de 5 cigarrillos	1.1231	Factor multiplicativo de los odds por 5 cigarrillos adicionales
Efecto de 10 cigarrillos	1.2614	Factor multiplicativo de los odds por 10 cigarrillos adicionales
Efecto de 20 cigarrillos	1.5911	Factor multiplicativo de los odds por 20 cigarrillos adicionales

```
#Parte 7. Probabilidades estimadas
consumo <- data.frame(
  cigs = c(0, 5, 10, 20, 30, 40)
)

consumo$probabilidad_CHD <- predict(
  mod_logit,
  newdata = consumo,
  type = "response"
)

consumo$probabilidad_CHD <- round(
  consumo$probabilidad_CHD,
  4
)

knitr::kable(
  consumo,
  col.names = c(
    "Cigarrillos diarios",
    "Probabilidad estimada de CHD"
  ),
  caption = "Probabilidad estimada de enfermedad coronaria según consumo diario"
)
```

Probabilidad estimada de enfermedad coronaria según consumo diario

Cigarrillos diarios	Probabilidad estimada de CHD
0	0.0605
5	0.0675
10	0.0752
20	0.0930
30	0.1145
40	0.1402

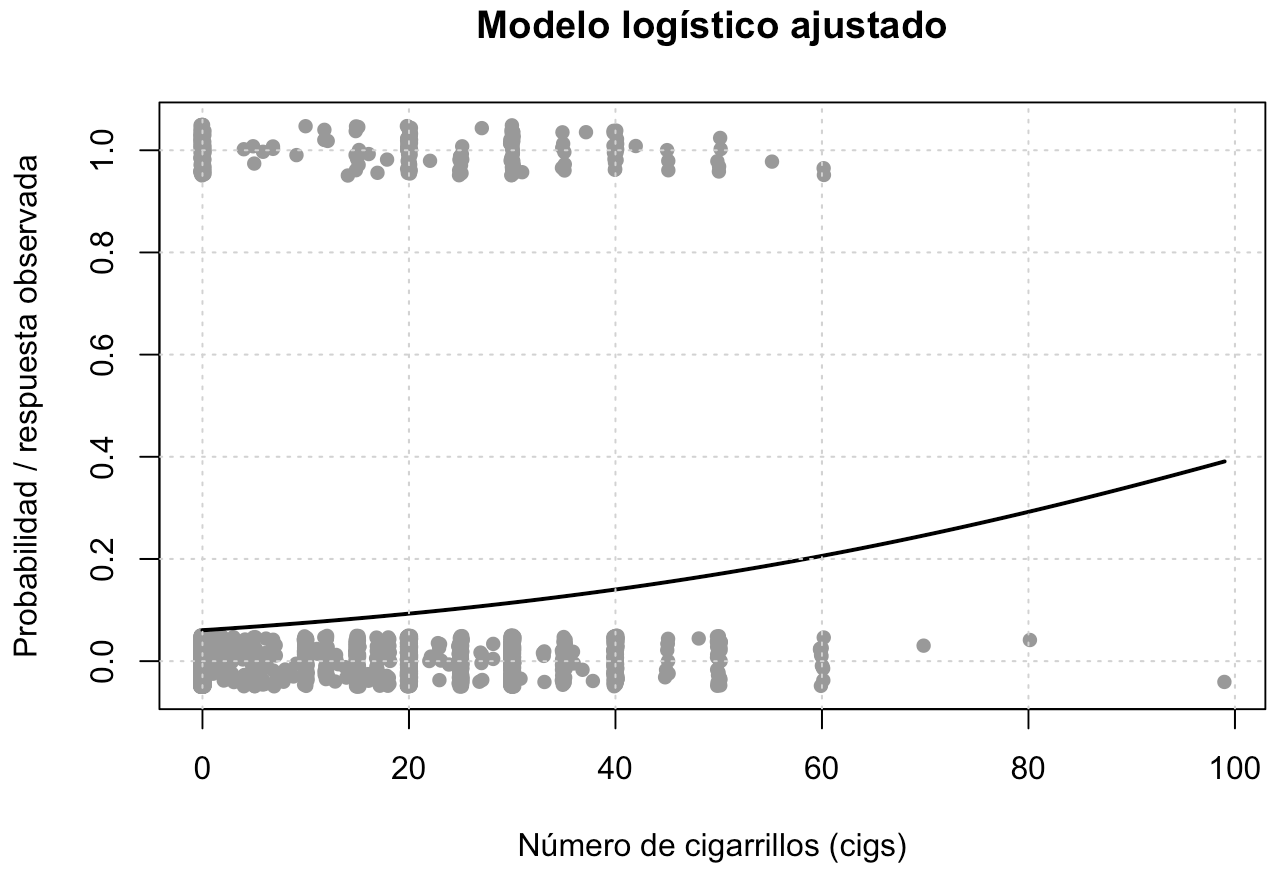
5) Curva ajustada sobre los datos

```
# Parte 8: curva logística ajustada

xg <- seq(min(datos$cigs), max(datos$cigs), length.out = 200)
pg <- predict(mod_logit,
              newdata = data.frame(cigs = xg),
              type = "response")

plot(jitter(datos$cigs), jitter(chd_num, amount = 0.05),
     xlab = "Número de cigarrillos (cigs)",
     ylab = "Probabilidad / respuesta observada",
     main = "Modelo logístico ajustado",
     pch = 16, col = "gray60")

lines(xg, pg, lwd = 2)
grid()
```



6) Clasificación

La regresión logística ya estima la probabilidad de pertenecer a la clase 1. Para convertirla en un método de clasificación se define un punto de corte:

$$Y_i = \begin{cases} 1, & \text{si } p_i \geq c, \\ 0, & \text{si } p_i < c. \end{cases}$$

donde habitualmente se comienza con $c = 0.5$.

Para evaluar la clasificación correctamente, conviene separar los datos en una muestra de entrenamiento y otra de prueba.

```
# Parte 9: Clasificación mediante regresión logística

set.seed(123)

# División de los datos: 70% entrenamiento y 30% prueba
indice_train <- sample(
  seq_len(nrow(datos)),
  size = floor(0.70 * nrow(datos))
)

datos_train <- datos[indice_train, ]
datos_test  <- datos[-indice_train, ]
```

```
# Ajuste del modelo con los datos de entrenamiento
mod_logit_clas <- glm(
  chd ~ cigs,
  data = datos_train,
  family = binomial(link = "logit")
)
```

```
# Probabilidades estimadas para los datos de prueba
prob_test <- predict(
  mod_logit_clas,
  newdata = datos_test,
  type = "response"
)
```

```
# Clasificación utilizando un punto de corte de 0.5
umbral <- 0.5
clase_predicha <- ifelse(prob_test >= umbral, 1, 0)

# Clases reales
clase_real <- if (is.factor(datos_test$chd)) {
  as.numeric(datos_test$chd) - 1
} else {
  datos_test$chd
}

# Matriz de confusión
matriz_confusion <- table(
  Real = factor(clase_real, levels = c(0, 1)),
  Predicha = factor(clase_predicha, levels = c(0, 1))
)

matriz_confusion
```

```
##     Predicha
## Real   0   1
##    0 881   0
##    1  66   0
```

```
# Medidas de clasificación
VN <- matriz_confusion["0", "0"]
FP <- matriz_confusion["0", "1"]
FN <- matriz_confusion["1", "0"]
VP <- matriz_confusion["1", "1"]

metricas <- c(
  Exactitud = (VP + VN) / sum(matriz_confusion),
  Sensibilidad = VP / (VP + FN),
  Especificidad = VN / (VN + FP)
)

round(metricas, 3)
```

```
##     Exactitud  Sensibilidad Especificidad
##          0.93          0.00          1.00
```

Esto significa:

- **881 verdaderos negativos**: eran `chd = 0` y el modelo predijo 0.
- **0 falsos positivos**: ninguna persona sana fue clasificada como enferma.
- **66 falsos negativos**: eran `chd = 1` , pero el modelo las clasificó como 0.
- **0 verdaderos positivos**: el modelo no identificó ningún caso de enfermedad.

Interpretación de las métricas

$$Exactitud = \frac{881 + 0}{881 + 0} \approx 0.93$$

La exactitud es alta, aproximadamente 93%, pero resulta engañosa. Como la mayoría de las personas pertenece a la clase 0, el modelo obtiene una alta exactitud simplemente prediciendo siempre 0.

La sensibilidad es:

$$Sensibilidad = \frac{VP}{VP + FN} = \frac{0}{0 + 66} \approx 0$$

Esto indica que el modelo identifica correctamente al 0% de las personas con enfermedad coronaria. Desde el punto de vista clínico, el clasificador es inútil para detectar casos positivos.

La especificidad es:

$$Especificidad = \frac{VN}{VN + FP} = \frac{881}{881 + 0} \approx 1$$

El modelo identifica correctamente al 100% de las personas sin enfermedad, pero lo consigue porque clasifica absolutamente a todos como sanos.

¿Por qué ocurre?

La clase positiva es poco frecuente:

$$\frac{66}{881 + 66} \approx 0.07$$

Apenas cerca del 7% de los individuos del conjunto de prueba tiene `chd = 1`. Además, al utilizar un umbral de 0.5, probablemente ninguna probabilidad estimada supera ese valor:

```
summary(prob_test)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.06334 0.06334 0.06334 0.08728 0.09945 0.27349
```

```
max(prob_test)
```

```
## [1] 0.2734932
```

Se puede verificar cuántas predicciones superan distintos umbrales:

```
sum(prob_test >= 0.50)
```

```
## [1] 0
```

```
sum(prob_test >= 0.20)
```

```
## [1] 6
```

```
sum(prob_test >= 0.10)
```

```
## [1] 220
```

```
sum(prob_test >= 0.05)
```

```
## [1] 947
```

Conclusión para los estudiantes

Aunque el modelo presenta una exactitud del 93%, no logra identificar ningún individuo con enfermedad coronaria. La alta exactitud se debe al desbalance entre las clases y no a una buena capacidad de clasificación. Por ello, en respuestas binarias desbalanceadas no debe evaluarse el modelo solamente mediante la exactitud; es necesario considerar especialmente la sensibilidad, la especificidad y el área bajo la curva ROC.

En este problema conviene evaluar la curva ROC y seleccionar un punto de corte menor que 0.5. El umbral de 0.5 es una costumbre, pero no una ley.

7) Curva ROC

```
library(pROC)
```

```
## Type 'citation("pROC")' for a citation.
```

```
##
## Attaching package: 'pROC'
```

```
## The following objects are masked from 'package:stats':
##
##     cov, smooth, var
```

```
# Construcción de la curva ROC
curva_roc <- roc(
  response = clase_real,
  predictor = prob_test,
  levels = c(0, 1),
  direction = "<"
)

# Coordenadas de la curva
falsos_positivos <- 1 - curva_roc$specificities
verdaderos_positivos <- curva_roc$sensitivities

# Ordenar las coordenadas
orden <- order(
  falsos_positivos,
  verdaderos_positivos
)

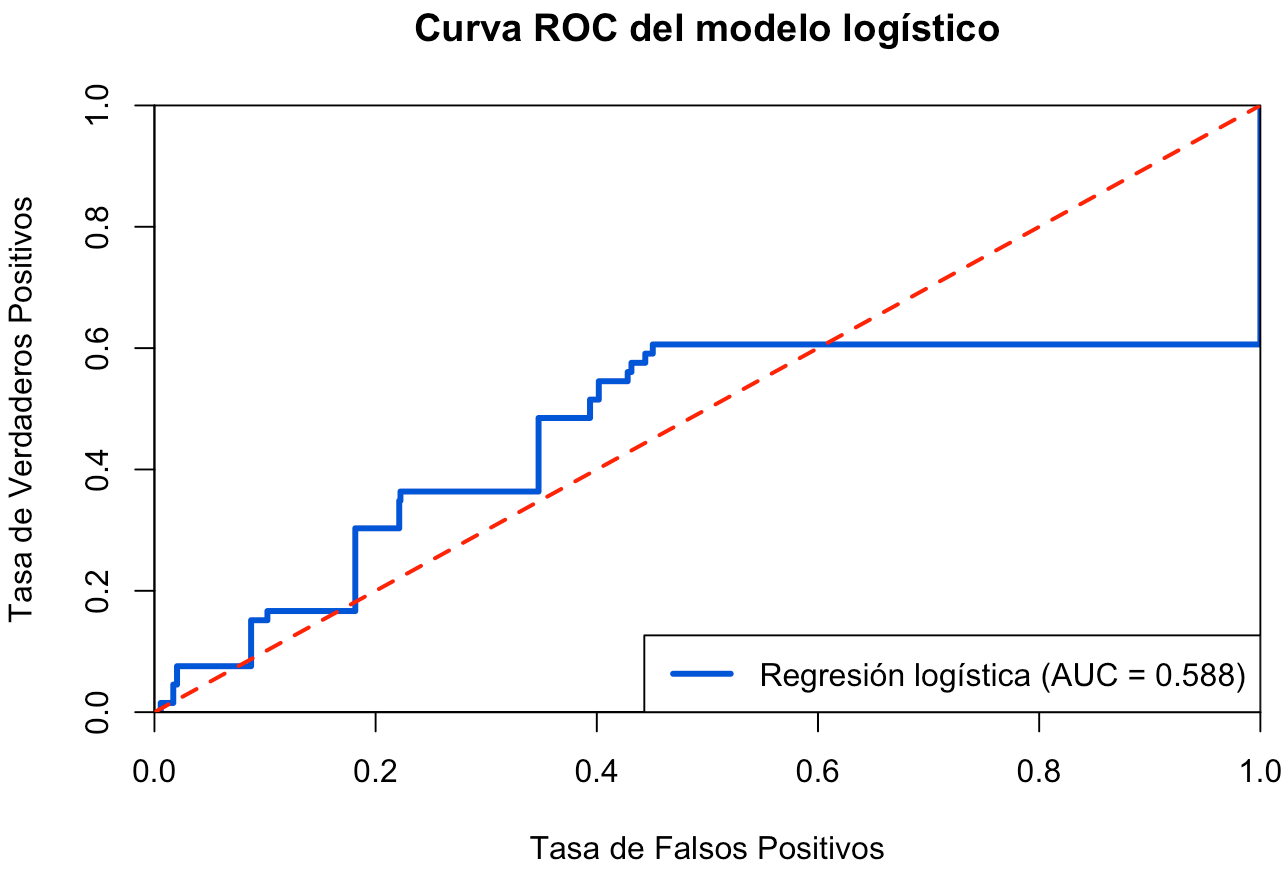
# Área bajo la curva
valor_auc <- as.numeric(auc(curva_roc))

# Gráfico
plot(
  falsos_positivos[orden],
  verdaderos_positivos[orden],
  type = "s",
  xlim = c(0, 1),
  ylim = c(0, 1),
  xaxs = "i",
  yaxs = "i",
  col = "#0057D9",
  lwd = 3,
  main = "Curva ROC del modelo logístico",
  xlab = "Tasa de Falsos Positivos",
  ylab = "Tasa de Verdaderos Positivos"
)

# Línea correspondiente a un clasificador al azar
abline(
  a = 0,
  b = 1,
  col = "red",
  lty = 2,
  lwd = 2
)

# Leyenda con el AUC
legend(
  "bottomright",
  legend = sprintf(
    "Regresión logística (AUC = %.3f)",
    valor_auc
```

```
  ),
  col = "#0057D9",
  lwd = 3,
  bg = "white"
)
```




```
# Punto de corte óptimo según el índice de Youden

punto_optimo <- coords(
  curva_roc,
  x = "best",
  best.method = "youden",
  ret = c("threshold", "sensitivity", "specificity"),
  transpose = FALSE
)

punto_optimo
```

```
##    threshold sensitivity specificity
## 1 0.06863037   0.6060606   0.5493757
```

```
# Clasificación con el punto de corte óptimo

umbral_optimo <- as.numeric(punto_optimo["threshold"])

clase_predicha_optima <- ifelse(
  prob_test >= umbral_optimo,
  1,
  0
)

table(
  Real = factor(clase_real, levels = c(0, 1)),
  Predicha = factor(clase_predicha_optima, levels = c(0, 1))
)
```

```
##     Predicha
## Real   0   1
##    0 484 397
##    1  26  40
```