Clase 21. Poisson para modelar tasas: cáncer de pulmón

Prof. Maritza Márquez

Mayo 2026

Ajustamos un **Modelo Lineal Generalizado Poisson** para datos de conteo, considerando un ejemplo sobre el número de casos de cáncer de pulmón observados en distintas ciudades y grupos de edad.

El punto central no es solo modelar el número de casos, sino modelar una **tasa de ocurrencia**, porque las poblaciones expuestas no son iguales entre ciudades ni entre grupos etarios.

En este contexto:

- Y_i representa el número de casos observados.
- m_i representa la población expuesta.
- $\mu_i = E(Y_i)$ representa el número esperado de casos.
- θ_i representa la tasa de ocurrencia por persona expuesta.

El modelo teórico es:

$$Y_i \sim \text{Poisson}(\mu_i), \qquad \mu_i = m_i \theta_i .$$

Si se modela la tasa mediante

$$\theta_i = \exp(x_i^\top \beta),$$

entonces se obtiene

$$\mu_i = m_i \exp(x_i^\top \beta).$$

Aplicando logaritmo:

$$\log(\mu_i) = \log(m_i) + x_i^\top \beta.$$

El término $\log(m_i)$ es un **offset**: entra al predictor lineal con coeficiente fijo igual a 1. Se ajusta por el tamaño de la población sin estimar un coeficiente para ella.

Datos

Los datos corresponden al número de casos de cáncer de pulmón observados en cuatro ciudades: Fredericia, Horsens, Kolding y Vejle. Para cada ciudad se tiene el número de casos y la población expuesta en distintos grupos de edad.

```
library(dplyr)
library(tidyr)
library(ggplot2)
library(knitr)
library(broom)

cancer <- tibble::tribble(
  ~edad,      ~ciudad,      ~casos, ~poblacion,
  "40–54",   "Fredericia", 11,     3059,
  "55–59",   "Fredericia", 11,      800,
  "60–64",   "Fredericia", 11,      710,
  "65–69",   "Fredericia", 10,      581,
  "70–74",   "Fredericia", 11,      509,
  "Over 74", "Fredericia", 10,      605,

  "40–54",   "Horsens",    13,     2879,
  "55–59",   "Horsens",     6,     1083,
  "60–64",   "Horsens",    15,      923,
  "65–69",   "Horsens",    10,      834,
  "70–74",   "Horsens",    12,      634,
  "Over 74", "Horsens",     2,      782,

  "40–54",   "Kolding",     4,     3142,
  "55–59",   "Kolding",     8,     1050,
  "60–64",   "Kolding",     7,      895,
  "65–69",   "Kolding",    11,      702,
  "70–74",   "Kolding",     9,      535,
  "Over 74", "Kolding",    12,      659,

  "40–54",   "Vejle",       5,     2520,
  "55–59",   "Vejle",       7,      878,
  "60–64",   "Vejle",      10,      839,
  "65–69",   "Vejle",      14,      631,
  "70–74",   "Vejle",       8,      539,
  "Over 74", "Vejle",       7,      619
)

cancer <- cancer %>%
  mutate(
    edad = factor(edad, levels = c("40–54", "55–59", "60–64", "65–69", "70–74", "Over 7
4")),
    ciudad = factor(ciudad),
    tasa_1000 = 1000 * casos / poblacion
  )

kable(cancer, digits = 3, caption = "Datos de cáncer de pulmón: casos, población expuest
a y tasa por 1000 habitantes.")
```

Datos de cáncer de pulmón: casos, población expuesta y tasa por 1000 habitantes.

edad	ciudad	casos	poblacion	tasa_1000

edad	ciudad	casos	poblacion	tasa_1000
40-54	Fredericia	11	3059	3.596
55-59	Fredericia	11	800	13.750
60-64	Fredericia	11	710	15.493
65-69	Fredericia	10	581	17.212
70-74	Fredericia	11	509	21.611
Over 74	Fredericia	10	605	16.529
40-54	Horsens	13	2879	4.515
55-59	Horsens	6	1083	5.540
60-64	Horsens	15	923	16.251
65-69	Horsens	10	834	11.990
70-74	Horsens	12	634	18.927
Over 74	Horsens	2	782	2.558
40-54	Kolding	4	3142	1.273
55-59	Kolding	8	1050	7.619
60-64	Kolding	7	895	7.821
65-69	Kolding	11	702	15.670
70-74	Kolding	9	535	16.822
Over 74	Kolding	12	659	18.209
40-54	Vejle	5	2520	1.984
55-59	Vejle	7	878	7.973
60-64	Vejle	10	839	11.919
65-69	Vejle	14	631	22.187
70-74	Vejle	8	539	14.842
Over 74	Vejle	7	619	11.309

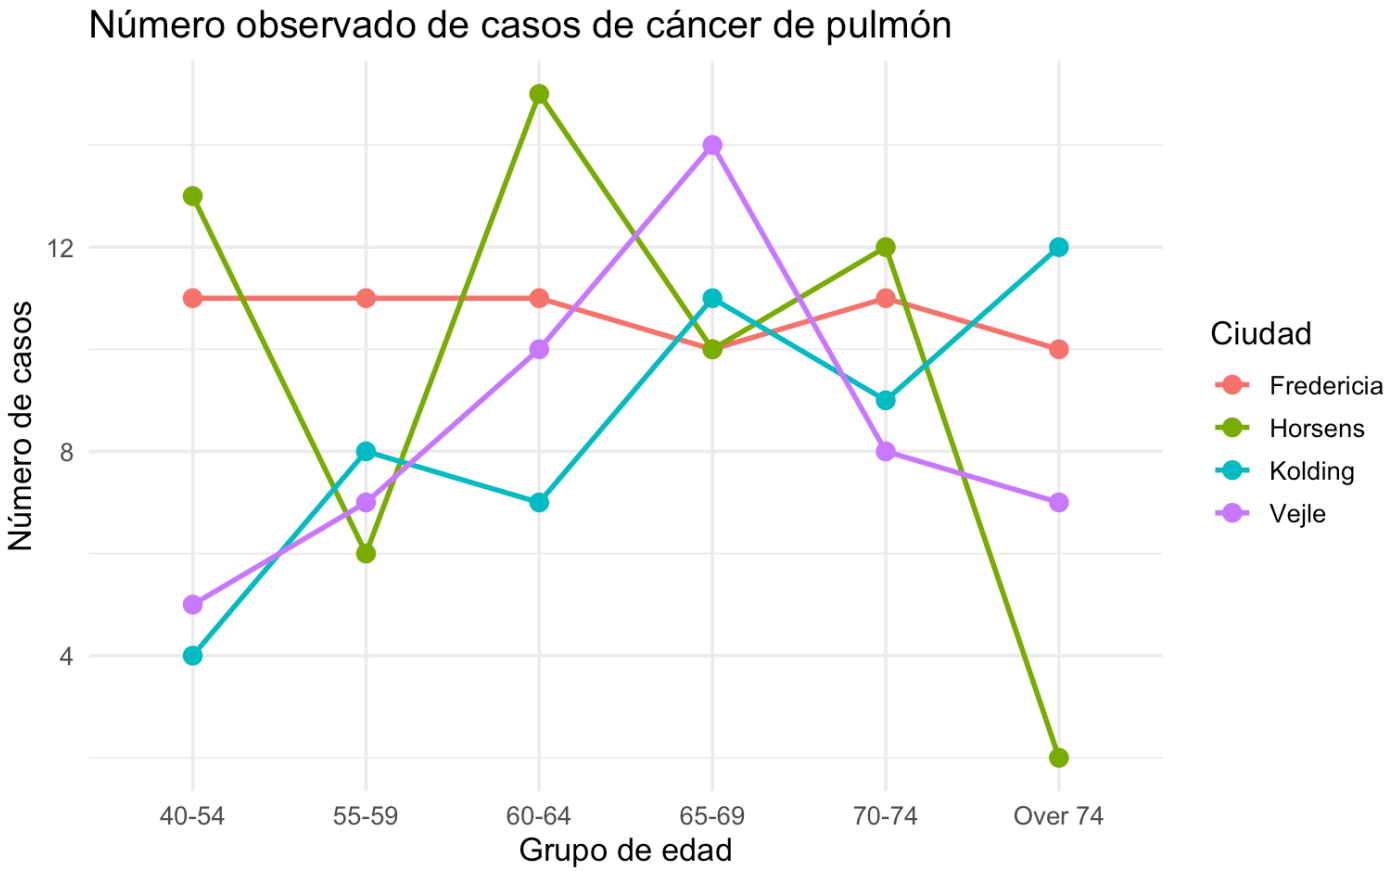
La variable respuesta `número` de casos es un conteo. Sin embargo, comparar directamente los conteos puede ser engañoso, porque una ciudad con más población expuesta puede tener más casos simplemente por tener más personas observadas.

Por eso se trabaja con un modelo Poisson con offset, donde la población expuesta se incorpora mediante log(población).

EDA

Casos observados por ciudad y edad

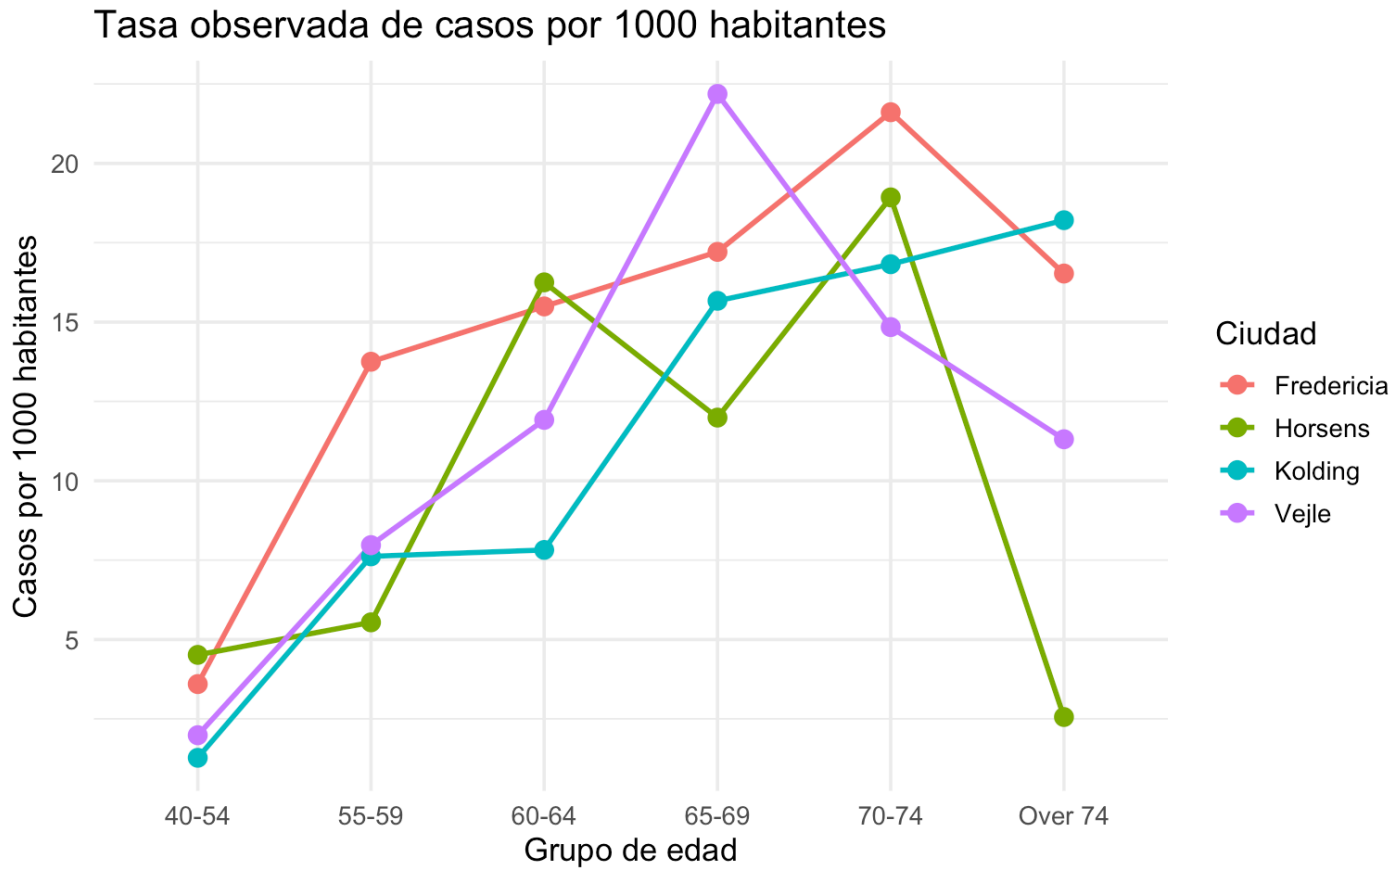
```
ggplot(cancer, aes(x = edad, y = casos, group = ciudad, color = ciudad)) +
  geom_line(linewidth = 1) +
  geom_point(size = 3) +
  labs(
    title = "Número observado de casos de cáncer de pulmón",
    x = "Grupo de edad",
    y = "Número de casos",
    color = "Ciudad"
  ) +
  theme_minimal(base_size = 13)
```



Este gráfico muestra los conteos observados. Sirve como una primera aproximación, pero no corrige por el tamaño de la población expuesta. Por lo tanto, no permite concluir directamente qué ciudad tiene mayor riesgo o mayor tasa.

Tasas observadas por 1000 habitantes

```
ggplot(cancer, aes(x = edad, y = tasa_1000, group = ciudad, color = ciudad)) +
  geom_line(linewidth = 1) +
  geom_point(size = 3) +
  labs(
    title = "Tasa observada de casos por 1000 habitantes",
    x = "Grupo de edad",
    y = "Casos por 1000 habitantes",
    color = "Ciudad"
  ) +
  theme_minimal(base_size = 13)
```



Este gráfico es más informativo que el gráfico de conteos, porque incorpora la población expuesta. Aquí ya no se comparan cantidades brutas, sino tasas observadas.

La edad parece tener un efecto importante sobre la tasa. Esto es esperable en datos epidemiológicos: el riesgo suele cambiar con la edad.

Modelo Poisson con offset

Se ajusta el siguiente modelo:

$$Y_i \sim \text{Poisson}(\mu_i),$$

con

$$\log(\mu_i) = \log(m_i) + \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi}.$$

En R, esto se implementa usando:

$$\text{offset}(\log(\text{población})).$$

El modelo ajustado considera como covariables la ciudad y el grupo de edad.

```
mod_pois <- glm(
  casos ~ ciudad + edad + offset(log(poblacion)),
  family = poisson(link = "log"),
  data = cancer
)

summary_mod <- summary(mod_pois)
summary_mod
```

```
##
## Call:
## glm(formula = casos ~ ciudad + edad + offset(log(poblacion)),
##     family = poisson(link = "log"), data = cancer)
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -5.6321     0.2003 -28.125  < 2e-16 ***
## ciudadHorsens  -0.3301     0.1815  -1.818   0.0690 .
## ciudadKolding  -0.3715     0.1878  -1.978   0.0479 *
## ciudadVejle    -0.2723     0.1879  -1.450   0.1472
## edad55-59       1.1010     0.2483   4.434 9.23e-06 ***
## edad60-64       1.5186     0.2316   6.556 5.53e-11 ***
## edad65-69       1.7677     0.2294   7.704 1.31e-14 ***
## edad70-74       1.8569     0.2353   7.891 3.00e-15 ***
## edadOver 74     1.4197     0.2503   5.672 1.41e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##     Null deviance: 129.908  on 23  degrees of freedom
## Residual deviance:  23.447  on 15  degrees of freedom
## AIC: 137.84
##
## Number of Fisher Scoring iterations: 5
```

El modelo estima efectos sobre el logaritmo de la tasa. Por lo tanto, los coeficientes no se interpretan directamente como cambios aditivos en el número de casos, sino como cambios multiplicativos en la tasa esperada.

Coeficientes e interpretación mediante Rate Ratios

Si β_j es un coeficiente del modelo, entonces

$$RR_j = e^{\beta_j}.$$

Este valor se interpreta como una **razón de tasas**. Si $RR_j > 1$, la tasa aumenta respecto a la categoría de referencia. Si $RR_j < 1$, la tasa disminuye respecto a la categoría de referencia.

```
rr_tabla <- broom::tidy(mod_pois, conf.int = TRUE, exponentiate = TRUE) %>%
  mutate(
    interpretacion = case_when(
      estimate > 1 ~ "Mayor tasa que la referencia",
      estimate < 1 ~ "Menor tasa que la referencia",
      TRUE ~ "Sin cambio relativo"
    )
  ) %>%
  rename(
    termino = term,
    RR = estimate,
    IC_inf = conf.low,
    IC_sup = conf.high,
    valor_p = p.value
  )

kable(rr_tabla, digits = 3, caption = "Rate Ratios estimados para el modelo Poisson.")
```

Rate Ratios estimados para el modelo Poisson.

termino	RR	std.error	statistic	valor_p	IC_inf	IC_sup	interpretacion
(Intercept)	0.004	0.200	-28.125	0.000	0.002	0.005	Menor tasa que la referencia
ciudadHorsens	0.719	0.182	-1.818	0.069	0.503	1.026	Menor tasa que la referencia
ciudadKolding	0.690	0.188	-1.978	0.048	0.476	0.995	Menor tasa que la referencia
ciudadVejle	0.762	0.188	-1.450	0.147	0.525	1.099	Menor tasa que la referencia
edad55-59	3.007	0.248	4.434	0.000	1.843	4.901	Mayor tasa que la referencia
edad60-64	4.566	0.232	6.556	0.000	2.907	7.236	Mayor tasa que la referencia
edad65-69	5.857	0.229	7.704	0.000	3.748	9.249	Mayor tasa que la referencia
edad70-74	6.404	0.235	7.891	0.000	4.043	10.212	Mayor tasa que la referencia
edadOver 74	4.136	0.250	5.672	0.000	2.523	6.762	Mayor tasa que la referencia

La categoría de referencia para ciudad y edad corresponde a la primera categoría de cada factor en R. En este caso, para edad la referencia es `40−54`. Para ciudad, R usa como referencia la primera categoría alfabética, salvo que se modifique explícitamente.

Los Rate Ratios asociados a los grupos de edad comparan la tasa esperada de cada grupo etario con la tasa esperada del grupo `40−54`, manteniendo constante la ciudad.

Valores ajustados

Los valores ajustados corresponden a:

$$\widehat{\mu}_i = m_i \exp(x_i^\top \widehat{\beta}).$$

En términos prácticos, representan el número esperado de casos para cada combinación de ciudad y grupo de edad, considerando su población expuesta.

```
cancer_aug <- cancer %>%
  mutate(
    mu_hat = fitted(mod_pois),
    tasa_hat_1000 = 1000 * mu_hat / poblacion,
    resid_pearson = residuals(mod_pois, type = "pearson"),
    resid_deviance = residuals(mod_pois, type = "deviance")
  )

kable(
  cancer_aug %>% select(edad, ciudad, casos, poblacion, tasa_1000, mu_hat, tasa_hat_100
0),
  digits = 3,
  caption = "Casos observados, casos ajustados y tasas ajustadas por 1000 habitantes."
)
```

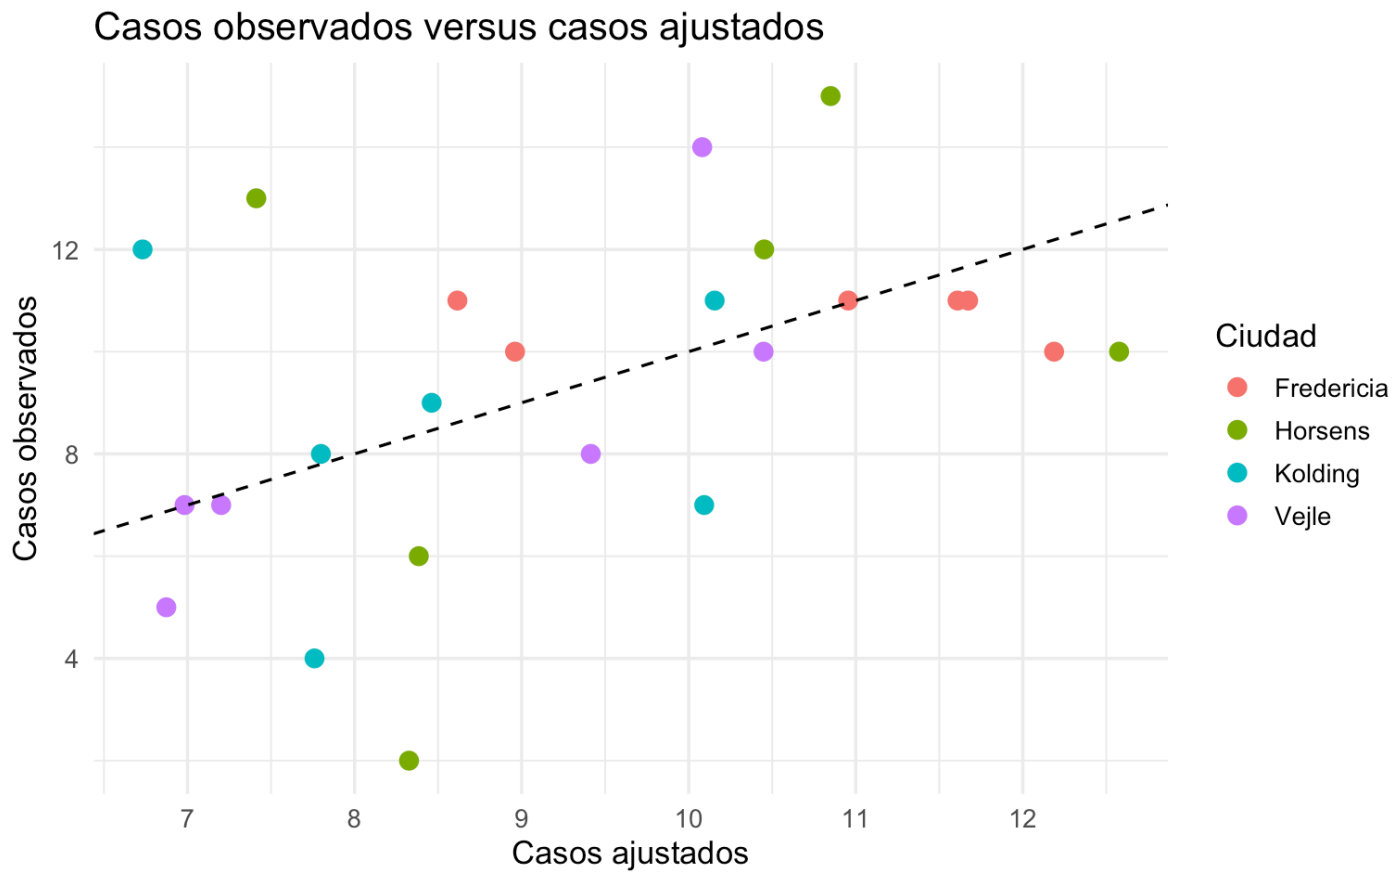
Casos observados, casos ajustados y tasas ajustadas por 1000 habitantes.

edad	ciudad	casos	poblacion	tasa_1000	mu_hat	tasa_hat_1000
40-54	Fredericia	11	3059	3.596	10.955	3.581
55-59	Fredericia	11	800	13.750	8.615	10.769
60-64	Fredericia	11	710	15.493	11.609	16.351
65-69	Fredericia	10	581	17.212	12.187	20.976
70-74	Fredericia	11	509	21.611	11.673	22.932
Over 74	Fredericia	10	605	16.529	8.960	14.811
40-54	Horsens	13	2879	4.515	7.412	2.574
55-59	Horsens	6	1083	5.540	8.384	7.742
60-64	Horsens	15	923	16.251	10.849	11.755
65-69	Horsens	10	834	11.990	12.576	15.080
70-74	Horsens	12	634	18.927	10.452	16.486
Over 74	Horsens	2	782	2.558	8.326	10.647
40-54	Kolding	4	3142	1.273	7.760	2.470
55-59	Kolding	8	1050	7.619	7.799	7.427

edad	ciudad	casos	poblacion	tasa_1000	mu_hat	tasa_hat_1000
60-64	Kolding	7	895	7.821	10.093	11.277
65-69	Kolding	11	702	15.670	10.156	14.467
70-74	Kolding	9	535	16.822	8.461	15.816
Over 74	Kolding	12	659	18.209	6.731	10.214
40-54	Vejle	5	2520	1.984	6.873	2.727
55-59	Vejle	7	878	7.973	7.201	8.202
60-64	Vejle	10	839	11.919	10.448	12.453
65-69	Vejle	14	631	22.187	10.081	15.976
70-74	Vejle	8	539	14.842	9.414	17.466
Over 74	Vejle	7	619	11.309	6.982	11.280

Casos observados versus casos ajustados

```
ggplot(cancer_aug, aes(x = mu_hat, y = casos, color = ciudad)) +
  geom_point(size = 3) +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed") +
  labs(
    title = "Casos observados versus casos ajustados",
    x = "Casos ajustados",
    y = "Casos observados",
    color = "Ciudad"
  ) +
  theme_minimal(base_size = 13)
```

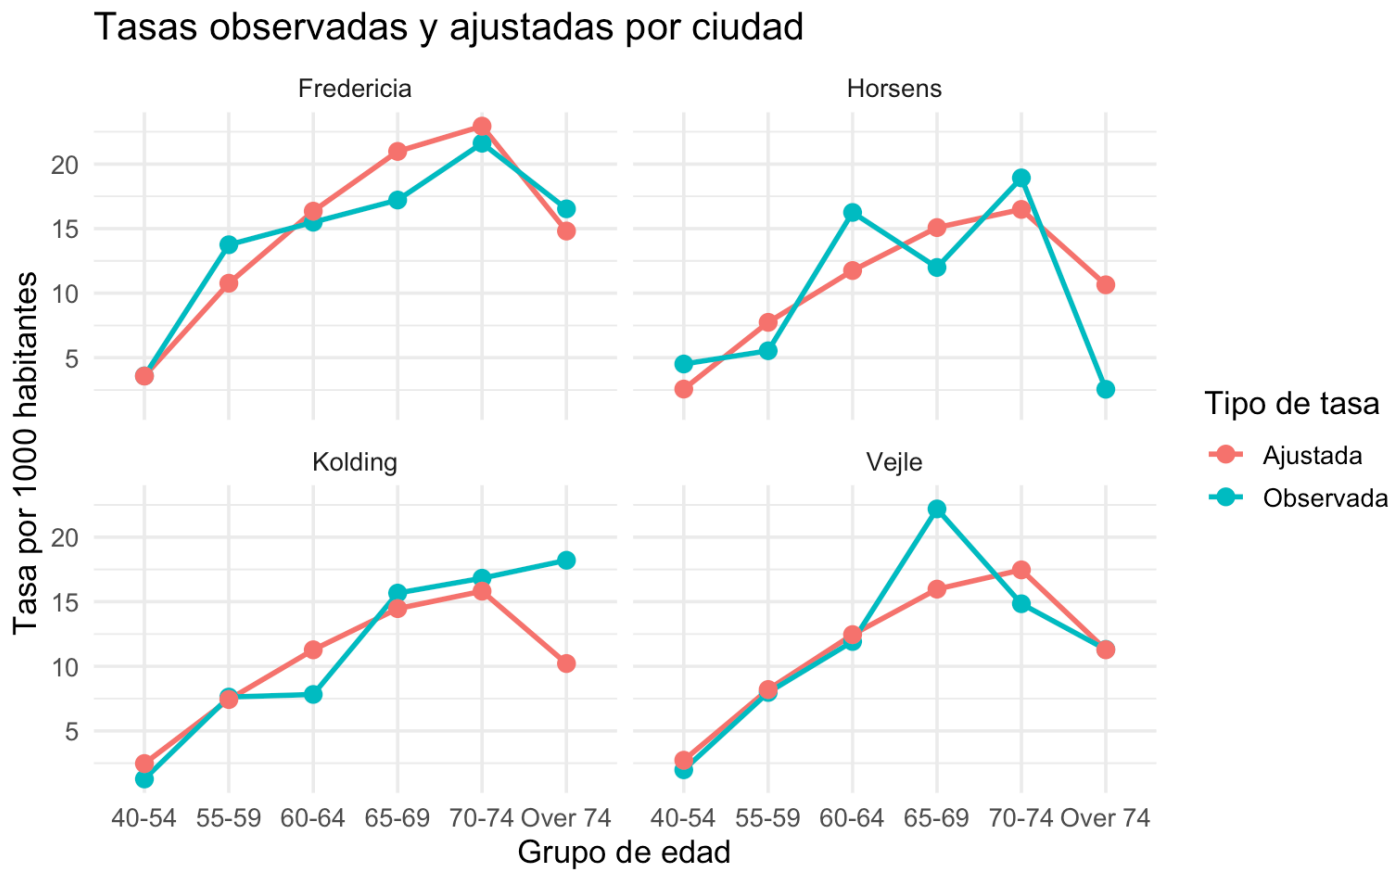


Si el modelo ajusta razonablemente bien, los puntos deberían ubicarse cerca de la línea diagonal. Desviaciones importantes pueden indicar falta de ajuste, observaciones influyentes o sobredispersión.

Tasas observadas y tasas ajustadas

```
cancer_long <- cancer_aug %>%
  select(edad, ciudad, tasa_1000, tasa_hat_1000) %>%
  pivot_longer(
    cols = c(tasa_1000, tasa_hat_1000),
    names_to = "tipo",
    values_to = "tasa"
  ) %>%
  mutate(
    tipo = recode(tipo,
                  tasa_1000 = "Observada",
                  tasa_hat_1000 = "Ajustada")
  )

ggplot(cancer_long, aes(x = edad, y = tasa, group = tipo, color = tipo)) +
  geom_line(linewidth = 1) +
  geom_point(size = 2.8) +
  facet_wrap(~ ciudad) +
  labs(
    title = "Tasas observadas y ajustadas por ciudad",
    x = "Grupo de edad",
    y = "Tasa por 1000 habitantes",
    color = "Tipo de tasa"
  ) +
  theme_minimal(base_size = 13)
```



Este gráfico permite observar si el modelo captura adecuadamente el patrón de tasas por edad y ciudad.

Bondad de ajuste

Para el modelo Poisson se utilizan dos medidas clásicas de bondad de ajuste: la deviance y el estadístico de Pearson.

```
dev <- deviance(mod_pois)
df_res <- df.residual(mod_pois)
p_dev <- pchisq(dev, df = df_res, lower.tail = FALSE)

pearson_x2 <- sum(residuals(mod_pois, type = "pearson")^2)
p_pearson <- pchisq(pearson_x2, df = df_res, lower.tail = FALSE)
phi_hat <- pearson_x2 / df_res

bondad <- tibble::tibble(
  medida = c("Deviance", "Pearson X2", "Dispersión estimada phi = X2/(n-p)"),
  valor = c(dev, pearson_x2, phi_hat),
  grados_libertad = c(df_res, df_res, NA),
  valor_p = c(p_dev, p_pearson, NA)
)

kable(bondad, digits = 4, caption = "Medidas de bondad de ajuste del modelo Poisson.")
```

Medidas de bondad de ajuste del modelo Poisson.

medida	valor	grados_libertad	valor_p
Deviance	23.4475	15	0.0751
Pearson X2	22.5616	15	0.0939
Dispersión estimada phi = X2/(n-p)	1.5041	NA	NA

Una regla práctica es observar el valor de $\widehat{\phi} = X^2/(n-p)$.

- Si $\widehat{\phi} \approx 1$, la dispersión es compatible con Poisson.
- Si $\widehat{\phi} > 1$, puede haber sobredispersión.
- Si $\widehat{\phi} < 1$, puede haber baja dispersión.

La distribución Poisson impone que:

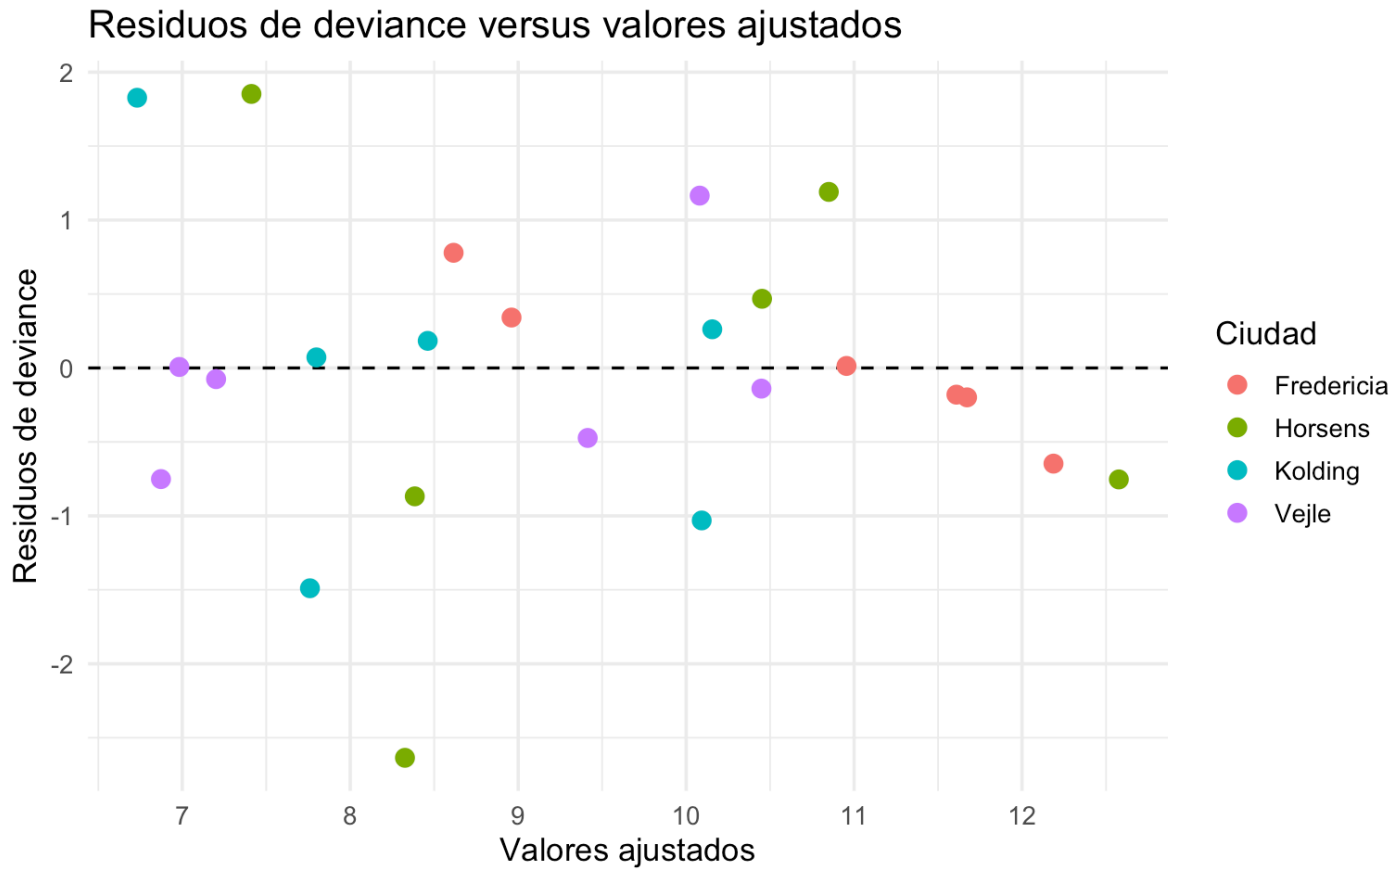
$$E(Y_i) = Var(Y_i) = \mu_i.$$

Este supuesto es fuerte. Cuando falla, el modelo puede subestimar o sobreestimar los errores estándar.

Diagnóstico gráfico

Residuos de deviance versus valores ajustados

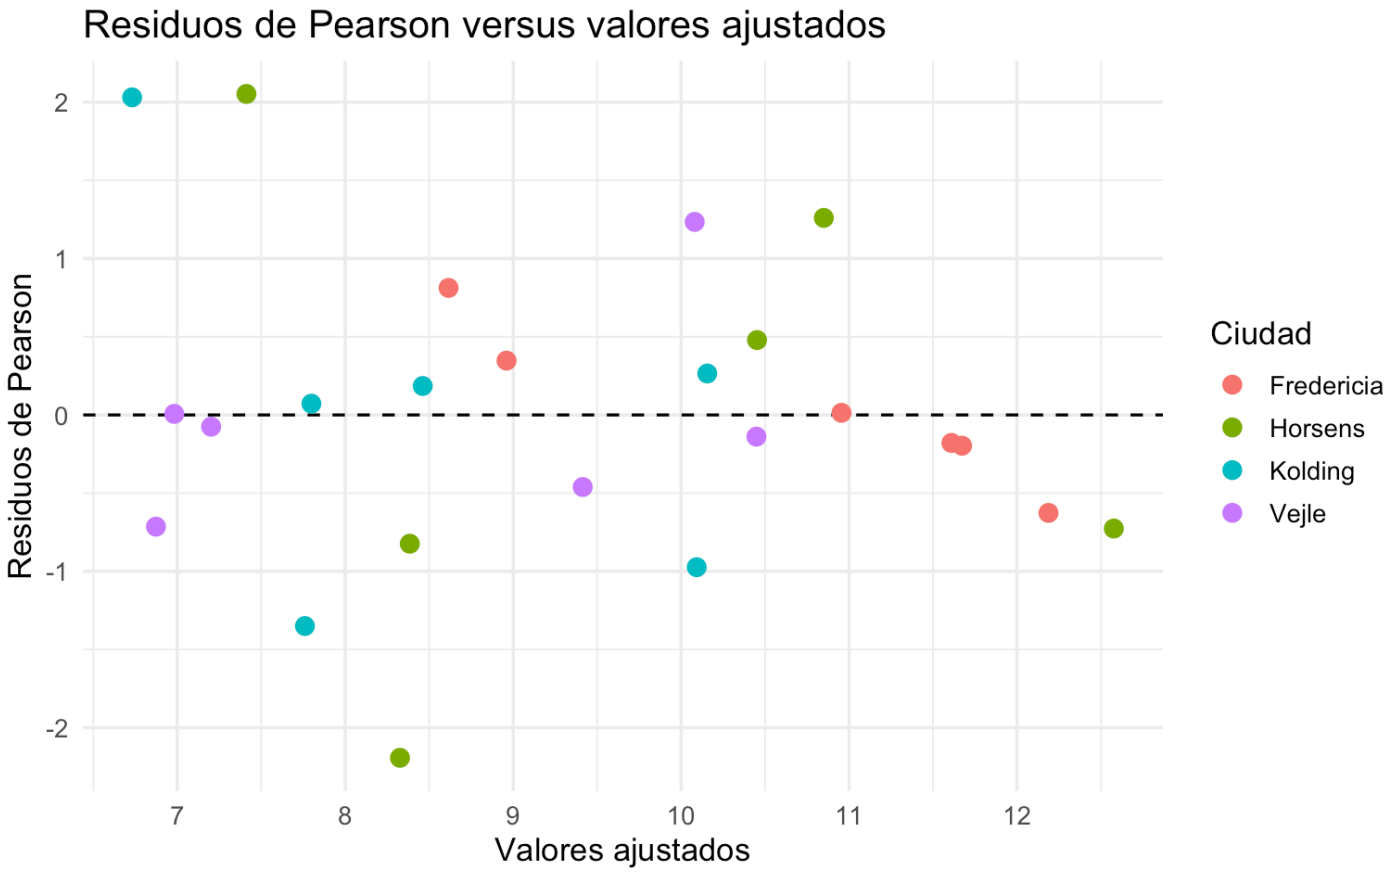
```
ggplot(cancer_aug, aes(x = mu_hat, y = resid_deviance, color = ciudad)) +
  geom_hline(yintercept = 0, linetype = "dashed") +
  geom_point(size = 3) +
  labs(
    title = "Residuos de deviance versus valores ajustados",
    x = "Valores ajustados",
    y = "Residuos de deviance",
    color = "Ciudad"
  ) +
  theme_minimal(base_size = 13)
```



El gráfico permite revisar si los residuos se distribuyen alrededor de cero sin patrones sistemáticos. Un patrón claro puede sugerir que falta alguna covariable, interacción o estructura adicional.

Residuos de Pearson versus valores ajustados

```
ggplot(cancer_aug, aes(x = mu_hat, y = resid_pearson, color = ciudad)) +
  geom_hline(yintercept = 0, linetype = "dashed") +
  geom_point(size = 3) +
  labs(
    title = "Residuos de Pearson versus valores ajustados",
    x = "Valores ajustados",
    y = "Residuos de Pearson",
    color = "Ciudad"
  ) +
  theme_minimal(base_size = 13)
```



Los residuos de Pearson son útiles para detectar observaciones que se alejan más de lo esperado bajo el supuesto Poisson.

Comparación de modelos

Se comparan tres modelos anidados:

1. Modelo nulo: solo intercepto y offset.
2. Modelo con edad.
3. Modelo con edad y ciudad.

```
mod_null <- glm(
  casos ~ 1 + offset(log(poblacion)),
  family = poisson(link = "log"),
  data = cancer
)

mod_edad <- glm(
  casos ~ edad + offset(log(poblacion)),
  family = poisson(link = "log"),
  data = cancer
)

mod_edad_ciudad <- glm(
  casos ~ edad + ciudad + offset(log(poblacion)),
  family = poisson(link = "log"),
  data = cancer
)

anova_tab <- anova(mod_null, mod_edad, mod_edad_ciudad, test = "Chisq")

kable(anova_tab, digits = 4, caption = "Comparación de modelos Poisson mediante diferenc
ias de deviance.")
```

Comparación de modelos Poisson mediante diferencias de deviance.

Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
23	129.9079	NA	NA	NA
18	28.3065	5	101.6014	0.0000
15	23.4475	3	4.8590	0.1824

La comparación se basa en diferencias de deviance. Si al agregar una covariable la deviance disminuye significativamente, esa covariable mejora el ajuste del modelo.

En particular, este análisis permite evaluar si el grupo de edad y la ciudad aportan información relevante para explicar la tasa de casos.

Modelo Quasi-Poisson como revisión de sobredispersión

Si se detecta sobredispersión, una alternativa sencilla es ajustar un modelo Quasi-Poisson. Este mantiene la misma media, pero permite:

$$Var(Y_i) = \phi \mu_i .$$

```
mod_quasi <- glm(
  casos ~ ciudad + edad + offset(log(poblacion)),
  family = quasipoisson(link = "log"),
  data = cancer
)

kable(
  broom::tidy(mod_quasi, conf.int = TRUE, exponentiate = TRUE) %>%
    rename(
      termino = term,
      RR = estimate,
      IC_inf = conf.low,
      IC_sup = conf.high,
      valor_p = p.value
    ),
  digits = 3,
  caption = "Rate Ratios estimados usando modelo Quasi-Poisson."
)
```

Rate Ratios estimados usando modelo Quasi-Poisson.

termino	RR	std.error	statistic	valor_p	IC_inf	IC_sup
(Intercept)	0.004	0.246	-22.932	0.000	0.002	0.006
ciudadHorsens	0.719	0.223	-1.483	0.159	0.463	1.112
ciudadKolding	0.690	0.230	-1.613	0.128	0.437	1.081
ciudadVejle	0.762	0.230	-1.182	0.256	0.482	1.194
edad55-59	3.007	0.305	3.616	0.003	1.647	5.481
edad60-64	4.566	0.284	5.346	0.000	2.625	8.051
edad65-69	5.857	0.281	6.282	0.000	3.389	10.284
edad70-74	6.404	0.289	6.434	0.000	3.642	11.375
edadOver 74	4.136	0.307	4.625	0.000	2.252	7.568

El modelo Quasi-Poisson no cambia los valores ajustados respecto al modelo Poisson con la misma estructura media. Lo que cambia principalmente son los errores estándar, intervalos de confianza y pruebas de hipótesis.

En síntesis, el modelo Poisson con offset permite responder una pregunta estadísticamente más fina: no solo cuántos casos hay, sino cuántos casos se esperan **por unidad de exposición**. Ahí está la diferencia entre contar y modelar.