Clase 22: Experimentación, A/B Testing y Causalidad Aplicada

Modelos Matemáticos y Estadísticos Clásicos

De la predicción a la decisión: medir efectos, no solo correlaciones

Prof. Maritza Márquez
maritza.marquez@uc.cl

Facultad de Matemáticas - Departamento de Estadística
Pontificia Universidad Católica de Chile

Julio 2026

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Resultados de aprendizaje

Al finalizar la clase, el estudiante debería poder:

- Distinguir una pregunta predictiva de una pregunta causal.
- Formular un experimento A/B con hipótesis, unidad de asignación, métrica primaria y guardrails.
- Calcular e interpretar diferencia de tasas, intervalo de confianza, p-valor y potencia.
- Detectar problemas de instrumentación: SRM, peeking y comparaciones múltiples.
- Usar regresión, covariables, CUPED y DiD como herramientas de análisis causal aplicado.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Contenidos

Motivación

Historia breve del A/B testing

Causalidad

Anatomía de un experimento A/B

Motivación

Hasta ahora hemos trabajado con modelos predictivos. Utilizamos características del usuario para anticipar quién comprará, quién abandonará una aplicación o quién responderá a una campaña.
Pero cuando una empresa debe tomar una decisión, la pregunta cambia. Ya no basta con saber quién comprará. Queremos saber qué ocurrirá si cambiamos algo: el checkout, el precio, el algoritmo o el mensaje.
La causalidad requiere estimar qué habría ocurrido con los usuarios tratados si no hubieran recibido el tratamiento.

¿El cambio causó una mejora o solo apareció junto con ella?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Motivación

Machine Learning

- Predice Y usando X.
- Optimiza el error de predicción.
- Predice resultados, respondiendo ¿Quién ...?

Inferencia Causal

- Estima el efecto de cambiar T.
- Evalúa consecuencias de decisiones.
- Estima lo ocurrido si ¿cambiamos ...?

Correlación pregunta qué variables se mueven juntas; causalidad pregunta qué cambiaría en el resultado si interviniéramos sobre una de ellas.

El A/B testing resuelve este problema mediante la aleatorización.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Historia breve del A/B testing

1747 · James Lind. A bordo del HMS Salisbury, comparó seis tratamientos en 12 marineros con escorbuto. La pareja que recibió naranjas y limón mostró la recuperación más rápida: un antecedente temprano de los ensayos controlados.

↓

1920s · Ronald Fisher. Transformó los ensayos agrícolas mediante aleatorización, replicación y bloqueo. El ANOVA permitió separar el efecto de los tratamientos de la variabilidad natural del terreno, sentando las bases del diseño experimental moderno.

↓

1948 · Estreptomicina. El Medical Research Council asignó aleatoriamente a 107 pacientes con tuberculosis a estreptomicina más reposo o solo reposo. La mortalidad a seis meses fue 7 % frente a 27 %:, sentando las bases del ensayo clínico moderno.

↓

2000s – hoy · Web y plataformas. Google, Amazon, E-commerce, apps y modelos de ML llevan la experimentación a escala industrial.

Historia breve del A/B testing: Casos populares

- **Google y los tonos de azul**: Probó distintas tonalidades de los enlaces publicitarios. Una diferencia mínima en clics, multiplicada por millones de usuarios, se tradujo en una mejora económica considerable.
- **Obama 2008**: Evaluó 24 combinaciones de imágenes y botones. La versión ganadora aumentó los registros cerca de un 40 % y fortaleció posteriormente la captación de donaciones.
- **Bing**: Un pequeño cambio en la presentación de los anuncios, inicialmente postergado, aumentó los ingresos alrededor de un 12 % sin deteriorar la experiencia de usuario.

Moraleja

La magnitud visual de un cambio no determina la magnitud de su efecto; por eso las ideas se experimentan antes de implementarse.

SCIENCE UC
FACULTAD DE MATEMÁTICAS

Historia breve del A/B testing: ¿Dónde se usa hoy?

- E-commerce: checkout, precios, promociones.
- Banca y fintech: onboarding, campañas, ofertas.
- Apps y SaaS: registro, paywalls, notificaciones.
- Medios y streaming: titulares, miniaturas, orden del feed.
- Videojuegos: tutoriales, dificultad, monetización.
- Educación: mensajes, recordatorios, rutas de aprendizaje.
- Modelos de ML: ranking actual vs. ranking nuevo.
- Operaciones: scripts, formularios, tiempos de contacto.

Requisito mínimo: métrica medible, unidades asignables y tráfico suficiente.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Causalidad

Sea $T_i \in \{0, 1\}$ el tratamiento y Y_i la respuesta. Tal que:

$$Y_i(1) : \text{resultado si recibe tratamiento,}$$

$$Y_i(0) : \text{resultado si queda en control.}$$

El efecto individual sería:

$$\tau_i = Y_i(1) - Y_i(0).$$

Problema fundamental

Para una misma unidad nunca observamos simultáneamente $Y_i(1)$ y $Y_i(0)$. Observamos uno; el otro es el **contrafactual**.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Efecto promedio del tratamiento

El objetivo usual del A/B testing es estimar:

$$ATE = \mathrm{E}\{Y(1) - Y(0)\}.$$

Estimador bajo aleatorización

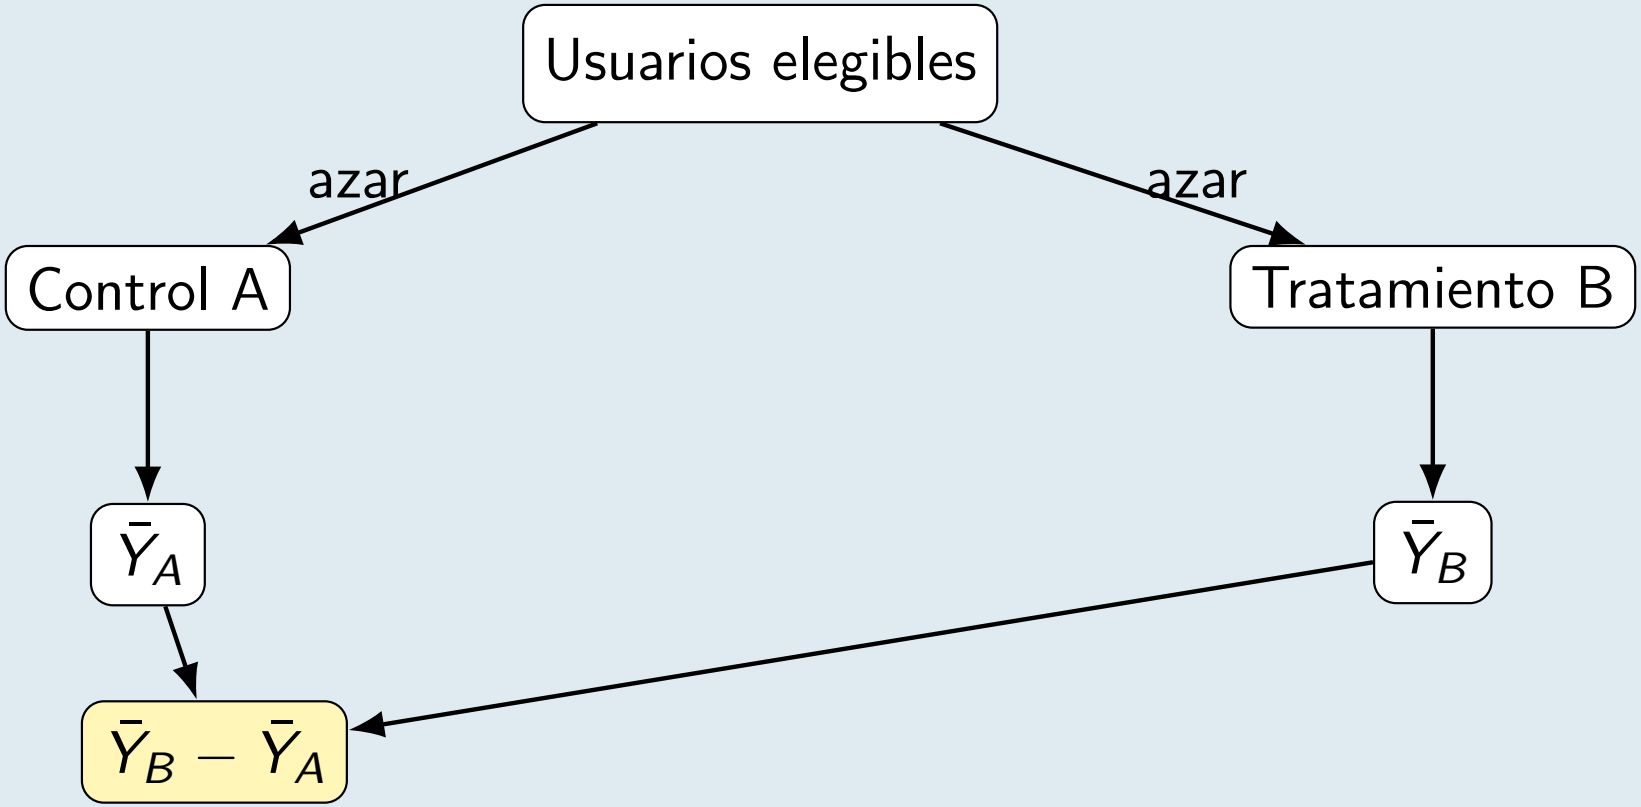
Si la asignación al tratamiento es aleatoria, entonces:

$$\widehat{ATE} = \bar{Y}_{T=1} - \bar{Y}_{T=0}.$$

La clave no es que los grupos sean idénticos persona por persona, sino que sean comparables **en promedio**. Esa es la gracia de aleatorizar.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

¿Por qué la aleatorización permite hablar de causalidad?



Identificación

La asignación por azar rompe la asociación sistemática entre tratamiento y características observadas/no observadas antes del experimento.

Anatomía de un experimento A/B

Elemento	Decisión práctica
Hipótesis	Qué cambio se espera y sobre qué métrica.
Unidad Aleatorización	Usuario, cuenta, comuna, tienda; cliente; llamada; producto; etc.
Tratamiento	Variante B: checkout nuevo, recomendador nuevo, mensaje nuevo.
Control	Estado actual: variante A.
OEC	Overall Evaluation Criterion: métrica primaria que decide.
Guardrails	Métricas que pueden vetar: latencia, reclamos, churn, errores.
Duración	Fijada antes de mirar resultados.
Plan de análisis	Test, covariables, segmentos y criterio de decisión.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Métrica primaria y Guardrails

Métrica primaria

Es la que responde la pregunta central.

- compras,
- ingreso por usuario,
- retención,
- tiempo hasta completar flujo.

Guardrails

No deciden por sí solos, pero pueden frenar el lanzamiento.

- tasa de error,
- latencia,
- reclamos,
- abandono posterior,
- métricas de equidad.

La métrica primaria funciona como el acelerador nos indica si avanzamos. Las guardrails funcionan como los frenos y las señales del tablero de un auto: evitan que avancemos dañando el sistema.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Hipótesis y estimador en conversión

Si $Y_i = 1$ indica conversión, entonces:

$$\hat{p}_B - \hat{p}_A = \frac{x_B}{n_B} - \frac{x_A}{n_A}.$$

Contraste típico bilateral

$$H_0 : p_B - p_A = 0, \qquad H_1 : p_B - p_A \neq 0.$$

Intervalo aproximado

$$(\hat{p}_B - \hat{p}_A) \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}_B(1-\hat{p}_B)}{n_B} + \frac{\hat{p}_A(1-\hat{p}_A)}{n_A}}.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

El test de proporciones y la regresión dicen lo mismo

Para una respuesta binaria, el modelo lineal de probabilidad es:

$$Y_i = \beta_0 + \beta_1 T_i + \varepsilon_i.$$

- $\hat{\beta}_0 = \bar{Y}_A$: tasa de conversión del control.
- $\hat{\beta}_1 = \bar{Y}_B - \bar{Y}_A$: diferencia de tasas.

También se puede usar regresión logística:

$$\log\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \beta_1 T_i,$$

que conecta naturalmente con modelos lineales generalizados.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Ejemplo de la práctica: nuevo checkout

Grupo	Usuarios	Conversiones	Tasa
Control	10.965	974	8,88 %
Tratamiento	11.035	1.194	10,82 %

Resultado

$$\hat{p}_B - \hat{p}_A = 0,0194 = 1,94 \text{ pp.}$$

Intervalo aproximado: $[1,15; 2,72]$ pp. p-valor $\approx 1,43 \times 10^{-6}$.

El efecto parece real y relevante. Ahora falta preguntarse: ¿la aleatorización, la medición, la exposición y la ejecución del experimento fueron correctas?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Potencia, MDE y Tamaño Muestral

Antes de iniciar el experimento, se define el **MDE**: el mínimo efecto detectable que el estudio debe ser capaz de detectar.

- α: probabilidad tolerada de falso positivo.
- Potencia $1 - \beta$: probabilidad de detectar un efecto real del tamaño MDE.
- Si el MDE baja, el tamaño muestral sube fuerte. La estadística no hace milagros; apenas cobra por ellos.

Ejemplo

Conversión histórica 9 %; se quiere detectar 10,5 % con potencia 80 % y $\alpha = 0,05$:

$$n \approx 6{,}131 \text{ usuarios por grupo.}$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Diseño en R

```
# Conversion historica 9%; detectar +1.5 pp
power.prop.test(p1 = 0.09, p2 = 0.105,
                sig.level = 0.05,
                power = 0.80)
```

Lectura

El resultado entrega el número de usuarios por grupo. Se requieren aproximadamente 6.131 usuarios en cada grupo, es decir, 12.262 usuarios en total, para detectar un aumento de 9 % a 10,5 % con una potencia del 80 %.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Error frecuente 1: Sample Ratio Mismatch

El **SRM** ocurre cuando la proporción observada de usuarios por grupo no coincide con la proporción esperada de asignación.

Chequeo

$$H_0 : (n_A, n_B) \sim \text{asignación esperada, por ejemplo } 50/50.$$

Se usa un test chi-cuadrado sobre los conteos de grupo.

Regla práctica

Si $p < 0,001$, no se reporta el efecto: se audita la instrumentación.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

SRM en R

```
ab <- read.csv("ab_checkout.csv")
table(ab$grupo)
chisq.test(table(ab$grupo), p = c(0.5, 0.5))

srm <- read.csv("ab_srm.csv")
table(srm$grupo)
chisq.test(table(srm$grupo), p = c(0.5, 0.5))
prop.table(table(srm$grupo, srm$dispositivo), margin = 1)
```

Interpretación: Si la asignación se rompió, el dashboard se apaga y entra la auditoría. Primero, se verifica que la infraestructura, la asignación y el registro de datos funcionaron correctamente. Después, p-valores.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Error frecuente 2: mirar antes de tiempo

El **peeking** es mirar el p-valor repetidamente y detener el experimento cuando finalmente da significativo.



Con 10 miradas independientes al 5 %, el falso positivo puede acercarse a 40 %.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Error frecuente 3: muchos cortes, una sola estrella

- Probar 20 métricas y reportar solo la significativa infla falsos positivos.
- Mirar segmentos no preespecificados también cuenta: edad, región, dispositivo, canal, nuevos vs. antiguos.
- Los análisis exploratorios son válidos, pero deben etiquetarse como exploratorios.

Disciplina mínima

Métrica primaria, segmentos principales y guardrails se escriben antes de lanzar.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Covariables: no arreglan un mal experimento

En un experimento bien aleatorizado, ajustar por covariables pre-tratamiento no es para corregir sesgo; es para mejorar precisión.

$$Y_i = \beta_0 + \beta_1 T_i + \gamma X_i + \varepsilon_i.$$

- X_i debe estar medido antes del tratamiento.
- Nunca se ajusta por variables afectadas por el tratamiento.
- El coeficiente β_1 sigue siendo el efecto promedio ajustado.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

CUPED: reducir varianza con historia previa

CUPED usa una covariable pre-experimento X correlacionada con la respuesta Y.

$$Y_i^{cuped} = Y_i - \theta(X_i - \bar{X}), \qquad \theta = \frac{\mathrm{Cov}(Y, X)}{\mathrm{Var}(X)}.$$

Intuición

Si el gasto previo explica parte de la variabilidad de conversión, se resta esa parte y queda una respuesta más limpia para comparar grupos.

Advertencia

CUPED no salva un SRM ni una mala aleatorización. Reduce ruido; no lava pecados de diseño.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

CUPED en R

```
theta <- cov(ab$convierte, ab$gasto_pre) / var(ab$gasto_pre)
ab$y_cuped <- ab$convierte - theta *
  (ab$gasto_pre - mean(ab$gasto_pre))

mpl      <- lm(convierte ~ trat, data = ab)
mpl_cuped <- lm(y_cuped ~ trat, data = ab)

se_sin <- summary(mpl)$coefficients["trat", 2]
se_cuped <- summary(mpl_cuped)$coefficients["trat", 2]
1 - (se_cuped / se_sin)^2
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Heterogeneidad: útil, pero peligrosa

No todo efecto promedio cuenta la historia completa. Puede interesar saber si el tratamiento funciona distinto por dispositivo, región o tipo de usuario.

$$Y_i = \beta_0 + \beta_1 T_i + \beta_2 D_i + \beta_3 (T_i D_i) + \varepsilon_i.$$

- β_3 mide diferencia de efecto entre segmentos.
- Debe estar preespecificado si se usará para decisión.
- En producción, heterogeneidad real puede guiar personalización.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Cuando no se puede aleatorizar

No todo problema permite A/B testing:

- cambios regulatorios,
- políticas públicas,
- campañas regionales,
- lanzamientos obligatorios,
- restricciones éticas u operacionales.

En esos casos entran diseños cuasi-experimentales: matching, regresión discontinua, variables instrumentales, datos de panel y diferencia-en-diferencias.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Diferencia-en-diferencias

Si tenemos grupo tratado y grupo de control observados antes y después:

$$DiD = (\bar{Y}_{T,post} - \bar{Y}_{T,pre}) - (\bar{Y}_{C,post} - \bar{Y}_{C,pre}).$$

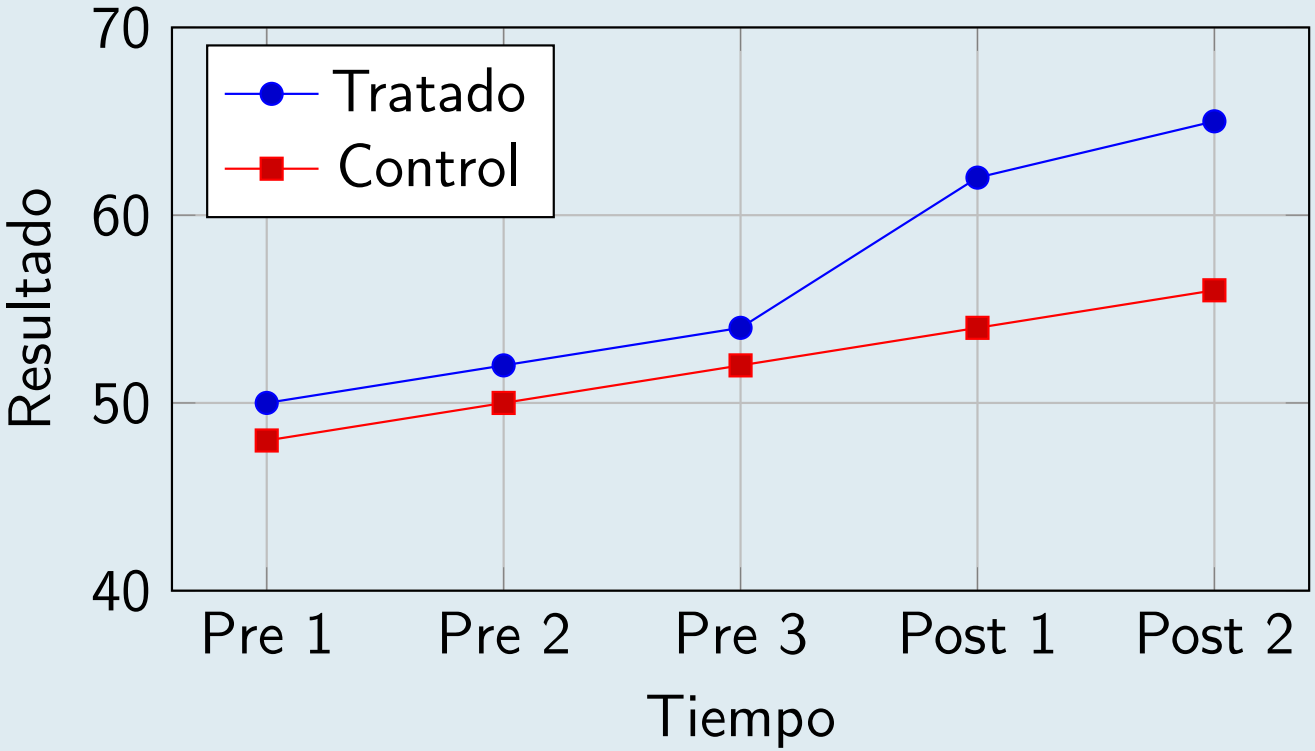
Modelo de regresión

$$Y_{it} = \beta_0 + \beta_1 Trat_i + \beta_2 Post_t + \beta_3 (Trat_i \times Post_t) + u_{it}.$$

El parámetro causal de interés es β_3.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Supuesto clave: tendencias paralelas



Lectura

Antes del tratamiento, ambos grupos deberían moverse de forma parecida. Si antes ya corrían en direcciones distintas, el DiD queda a medio camino.

Ejemplo de la práctica: lanzamiento regional de app

Estimación DiD	Efecto	IC 95 %	p-valor
Tratado × *Post*	5,76 puntos	[4,58; 6,94]	$< 0,001$

Interpretación

Tras el lanzamiento en RM, el uso promedio de la app aumenta aproximadamente 5,76 puntos más que en otras regiones, bajo el supuesto de tendencias paralelas.

Lo que se debe defender

No basta con correr la regresión: hay que mostrar evidencia pre-tratamiento y explicar por qué el grupo control es creíble.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Checklist antes de lanzar un experimento

- Hipótesis falsable y una sola métrica primaria.
- MDE acordado con negocio; tamaño muestral y duración calculados.
- Unidad de aleatorización definida y estable.
- Guardrails y chequeo de SRM programados desde el momento 1.
- Fecha de término fijada; no se mira el p-valor antes.
- Plan de análisis escrito: test, covariables, segmentos preespecificados.
- Criterio de decisión: lanzar, no lanzar, iterar o repetir.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Práctica guiada

Archivo	Uso en clase
`ab_checkout.csv`	Experimento limpio: diseño, SRM, diferencia de tasas, regresión, logit, covariables y CUPED.
`ab_srm.csv`	Experimento roto: diagnóstico de Sample Ratio Mismatch y cruce por dispositivo.
`did_app_regiones.csv`	Panel regional: tendencias paralelas y estimación DiD.
`Clase22_ABtesting.R`	Script completo en R con funciones auxiliares y preguntas.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Mini-guía para la práctica

1. Calcular tamaño muestral requerido.
2. Cargar `ab_checkout.csv` y chequear SRM.
3. Estimar efecto por diferencia de tasas, regresión lineal y logística.
4. Ajustar por `gasto_pre` y aplicar CUPED.
5. Diagnosticar `ab_srm.csv`; decidir si se reporta o no.
6. Estimar DiD con `did_app_regiones.csv`.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Cierre: de la correlación a la decisión

- La causalidad no sale del algoritmo; sale del diseño.
- A/B testing es el estándar cuando se puede aleatorizar.
- La regresión ayuda a estimar y ganar precisión, pero no reemplaza la identificación.
- SRM, peeking y múltiples comparaciones pueden destruir un experimento bonito.
- Si no se puede experimentar, DiD y otros diseños exigen supuestos claros y defendibles.

Buen experimento primero; modelo elegante después.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Referencias breves

- Cunningham, S. (2021). *Causal Inference: The Mixtape*. Yale University Press.
- Kohavi, R., Tang, D. y Xu, Y. (2020). *Trustworthy Online Controlled Experiments*. Cambridge University Press.
- Deng, A., Xu, Y., Kohavi, R. y Walker, T. (2013). Improving the sensitivity of online controlled experiments by utilizing pre-experiment data. *WSDM*.
- Bishop, C. M. y Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer. Útil para conectar modelos predictivos y aprendizaje supervisado.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS