Clase 23: Modelos Predictivos
Introducción a la Estadística Bayesiana
Modelos Matemáticos y Estadísticos Clásicos

Fundamentos de la Estadística Bayesiana

Prof. Maritza Márquez
maritza.marquez@uc.cl

Facultad de Matemáticas - Departamento de Estadística
Pontificia Universidad Católica de Chile

Julio 2026

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Contenidos

Motivación y ruta de aprendizaje

Teorema de Bayes

Modelo bayesiano básico

Práctica computacional y cierre

Motivación y ruta de aprendizaje

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Objetivos de la clase

- Comprender la diferencia conceptual entre inferencia **Frecuentista** e inferencia **Bayesiana**.
- Interpretar la probabilidad como una medida de **incertidumbre** sobre eventos, parámetros y predicciones.
- Usar el **Teorema de Bayes** para actualizar conocimiento con datos observados.
- Construir un modelo bayesiano sencillo identificando:

$$\text{Priori} \quad + \quad \text{Verosimilitud} \quad \longrightarrow \quad \text{Posteriori}.$$

- Aplicar el modelo Beta–Binomial en problemas de proporciones.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

¿Por qué estudiar Estadística Bayesiana?

- En Data Science no solo queremos estimar un número; queremos cuantificar **qué tan seguros estamos** de ese número.

- El enfoque bayesiano permite incorporar información a priori (previa): experiencia clínica, resultados históricos, conocimiento experto o estudios anteriores.

- Es especialmente útil cuando los datos son escasos, costosos, desbalanceados o llegan de forma secuencial.

- La idea central es simple:

$$\text{Creencia Inicial} + \text{Evidencia Nueva} = \text{Creencia Actualizada}.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Ejemplos donde aparece naturalmente

- **Salud:** Estimar la probabilidad real de enfermedad después de un test positivo.
- **Educación:** Estimar la tasa de aprobación de un curso considerando cohortes anteriores.
- **Ingeniería:** Actualizar la probabilidad de falla de un componente luego de observar nuevas pruebas.
- **Data Science:** Comparar dos versiones de una página web mediante experimentos A/B.
- **Enfermería y Epidemiología:** Estimar proporciones de adherencia, prevalencia o respuesta a un tratamiento.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Inferencia Frecuentista vs. Inferencia Bayesiana

Frecuentista	**Bayesiana**
El parámetro es fijo, pero desconocido.	El parámetro desconocido se describe mediante una distribución de probabilidad.
La probabilidad se asocia a repetición de experimentos.	La probabilidad cuantifica incertidumbre.
La inferencia se basa en estimadores, errores estándar, valores-p e intervalos de confianza.	La inferencia se basa en la distribución posteriori.
Los datos son aleatorios.	Los datos observados son fijos; la incertidumbre está en los parámetros.

Ambos enfoques son útiles.

Probabilidad como incertidumbre

- En el enfoque bayesiano podemos escribir expresiones como:

$$P(\theta > 0{,}6 \mid \text{datos}) = 0{,}82.$$

- Esto se interpreta directamente como:

  dado lo observado, hay 82 % de probabilidad de que el parámetro sea mayor que 0.6.

- Esta interpretación suele ser más natural para profesionales no estadísticos.

- La clave es recordar que θ representa una cantidad desconocida: una proporción, una media, una tasa o un efecto.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS



Si una prueba médica resulta positiva, ¿la probabilidad de enfermedad debe ser igual a la sensibilidad de la prueba?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Teorema de Bayes

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Probabilidad condicional

- La probabilidad condicional de A dado B se define como:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \qquad P(B) > 0.$$

- Se lee como: probabilidad de que ocurra A, sabiendo que B ya ocurrió.

- En problemas reales:
  - A: la persona tiene una enfermedad.
  - B: el test salió positivo.

- Lo que interesa usualmente es $P(A \mid B)$, no $P(B \mid A)$.

Teorema de Bayes

A partir de la definición de probabilidad condicional:

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}.$$

- $P(A)$: probabilidad a **priori** de A.
- $P(B \mid A)$: probabilidad de observar B si A fuera verdadero.
- $P(B)$: probabilidad total de observar la evidencia.
- $P(A \mid B)$: probabilidad a **posteriori**; lo que creemos después de observar B.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Bayes en palabras

Versión conceptual

$$\text{posteriori} = \frac{\text{verosimilitud} \times \text{priori}}{\text{evidencia}}.$$

- La **priori** resume lo que sabíamos antes de observar los datos.
- La **verosimilitud** mide qué tan compatibles son los datos con distintos valores del parámetro.
- La **posteriori** resume lo que sabemos después de observar los datos.
- La evidencia normaliza para que la posteriori sea una distribución de probabilidad válida.

Ejemplo: prueba diagnóstica

Supongamos una enfermedad con:

- Prevalencia: $P(E) = 0{,}01$.
- Sensibilidad: $P(+ \mid E) = 0{,}95$.
- Especificidad: $P(- \mid E^c) = 0{,}90$.

Queremos calcular:

$$P(E \mid +).$$

Aplicando Bayes:

$$P(E \mid +) = \frac{P(+ \mid E)P(E)}{P(+ \mid E)P(E) + P(+ \mid E^c)P(E^c)}.$$

Como $P(+ \mid E^c) = 1 - 0{,}90 = 0{,}10$:

$$P(E \mid +) = \frac{0{,}95(0{,}01)}{0{,}95(0{,}01) + 0{,}10(0{,}99)} \approx 0{,}088.$$

Interpretación del ejemplo diagnóstico

- Aunque la prueba tenga alta sensibilidad, la probabilidad posteriori de enfermedad es aproximadamente $8{,}8\,\%$.
- Esto ocurre porque la enfermedad es poco prevalente.
- La prevalencia funciona como información previa.
- El test positivo actualiza la probabilidad, pero no borra el contexto inicial.
- Conclusión práctica: nunca se interpreta un test sin considerar la prevalencia.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Ejercicio breve

Una plataforma educativa tiene una tasa histórica de finalización de cursos de $40\,\%$. En una nueva cohorte de 20 estudiantes, 12 finalizan el curso.

1. ¿Cuál sería una interpretación frecuentista directa de la proporción observada?

2. ¿Qué información previa razonable podríamos incorporar?

3. ¿La evidencia de esta nueva cohorte parece mejorar la tasa histórica?

4. ¿Qué incertidumbre queda después de observar los datos?



¿La información a priori es siempre subjetiva o puede provenir de datos históricos bien documentados?

Modelo bayesiano básico

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Parámetros como cantidades inciertas

- Sea θ una cantidad desconocida: una proporción, una media, una tasa o un efecto.

- En inferencia bayesiana asignamos a θ una distribución a priori:

$$\theta \sim p(\theta).$$

- Después observamos los datos y con un modelo probabilístico:

$$y \mid \theta \sim p(y \mid \theta).$$

- La inferencia se realiza mediante:

$$p(\theta \mid y) = \frac{p(y \mid \theta)p(\theta)}{p(y)}.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Tres piezas del modelo

- **Distribución a priori:**

$$p(\theta).$$

Resume la información disponible antes de observar los datos actuales.

- **Verosimilitud:**

$$L(\theta; y) = p(y \mid \theta).$$

No es una distribución de probabilidad en θ; mide compatibilidad entre datos y valores de θ.

- **Distribución posteriori:**

$$p(\theta \mid y) \propto p(y \mid \theta)p(\theta).$$

Resume la incertidumbre actualizada sobre θ.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

El símbolo proporcional

- Muchas veces escribimos:

$$p(\theta \mid y) \propto p(y \mid \theta)p(\theta).$$

- El símbolo $\propto$ significa "proporcional a".

- Estamos ignorando temporalmente la constante de normalización:

$$p(y) = \int p(y \mid \theta)p(\theta)d\theta.$$

- Esta constante no depende de θ; solo sirve para que la posterior integre 1.

- En la práctica computacional, muchas técnicas bayesianas trabajan con la posteriori no normalizada.

Ejemplo: Proporción de Aprobación

- Queremos estimar la proporción θ de estudiantes que aprueban un módulo del diplomado.

- Observamos $Y = y$ aprobados entre n estudiantes:

$$Y \mid \theta \sim \text{Binomial}(n, \theta).$$

- La verosimilitud es:

$$p(y \mid \theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y}.$$

- Como θ es una proporción, debe cumplir:

$$0 < \theta < 1.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución Beta como priori

- Una distribución natural para una proporción es la distribución Beta:

$$\theta \sim \text{Beta}(\alpha, \beta).$$

- Su densidad es:

$$p(\theta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\theta^{\alpha-1}(1-\theta)^{\beta-1}, \qquad 0 < \theta < 1.$$

- Intuitivamente, α y β pueden verse como información a priori equivalente a éxitos y fracasos previos.

- Si $\alpha = \beta = 1$, la priori es uniforme: todos los valores entre 0 y 1 son igualmente plausibles.

Modelo conjugado Beta–Binomial

Si

$$Y \mid \theta \sim \text{Binomial}(n, \theta) \quad \text{y} \quad \theta \sim \text{Beta}(\alpha, \beta),$$

entonces:

$$\theta \mid y \sim \text{Beta}(\alpha + y,\ \beta + n - y).$$

- La priori y la posteriori pertenecen a la misma familia.
- A esto se le llama **conjugación**.
- La actualización es muy intuitiva:

$$\text{éxitos previos} + \text{éxitos observados},$$

$$\text{fracasos previos} + \text{fracasos observados}.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Ejemplo numérico: Aprobación

Supongamos que:

- Priori: $\theta \sim \text{Beta}(2, 2)$.
- Datos: $y = 14$ aprobados de $n = 20$ estudiantes.

Entonces:

$$\theta \mid y \sim \text{Beta}(2 + 14,\ 2 + 20 - 14) = \text{Beta}(16, 8).$$

- Media posteriori:

$$E(\theta \mid y) = \frac{16}{16 + 8} = 0{,}667.$$

- La estimación se acerca a $14/20 = 0{,}70$, pero queda suavizada por la priori.

Estimación puntual bayesiana

- La posteriori completa es el resultado principal.
- Sin embargo, a veces necesitamos resumirla con un número:
  - media posteriori: $E(\theta \mid y)$,
  - mediana posteriori,
  - moda posteriori.
- Para $\theta \mid y \sim \text{Beta}(a, b)$:

$$E(\theta \mid y) = \frac{a}{a+b}.$$

- La estimación puntual es útil, pero no debe ocultar la incertidumbre.

Intervalo creíble

- Un intervalo creíble bayesiano al $95\,\%$ es un intervalo $[a, b]$ tal que:

$$P(a < \theta < b \mid y) = 0{,}95.$$

- Su interpretación es directa:

  dado el modelo, la priori y los datos, hay 95 % de probabilidad a posteriori de que θ esté en ese intervalo.

- Esta interpretación no es la misma que la de un intervalo de confianza frecuentista.

Intervalo creíble vs. intervalo de confianza

Intervalo de confianza	**Intervalo creíble**
Procedimiento de largo plazo: si repitiéramos el muestreo muchas veces, cierta proporción de intervalos contendría el parámetro.	Probabilidad posteriori directa sobre el parámetro dado lo observado.
El parámetro se considera fijo.	El parámetro se trata como incierto.
No se interpreta como $P(\theta \in I \mid y) = 0{,}95$.	Sí se interpreta como $P(\theta \in I \mid y) = 0{,}95$.

La frase correcta depende del marco inferencial. La gramática estadística también existe.

Algunas conjugaciones típicas en inferencia bayesiana

Una distribución previa es conjugada cuando la distribución posterior pertenece a la misma familia que la previa.

Modelo de los datos	**Distribución priori**	**Distribución posteriori**
$Y \mid \theta \sim \text{Binomial}(n, \theta)$	$\theta \sim \text{Beta}(\alpha, \beta)$	$\theta \mid y \sim \text{Beta}(\alpha + y, \beta + n - y)$
$Y_i \mid \theta \sim \text{Bernoulli}(\theta)$	$\theta \sim \text{Beta}(\alpha, \beta)$	$\theta \mid \mathbf{y} \sim \text{Beta}(\alpha + S, \beta + m - S)$
$Y_i \mid \lambda \sim \text{Poisson}(\lambda)$	$\lambda \sim \text{Gamma}(a, b)$	$\lambda \mid \mathbf{y} \sim \text{Gamma}(a + S, b + m)$
$Y_i \mid \lambda \sim \text{Exponencial}(\lambda)$	$\lambda \sim \text{Gamma}(a, b)$	$\lambda \mid \mathbf{y} \sim \text{Gamma}(a + m, b + S)$

Aquí $S = \sum_{i=1}^{m} y_i$. En la distribución Gamma se utiliza la parametrización forma–tasa.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS



Si la posteriori completa está disponible, ¿por qué no reportar solo la media posteriori?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Práctica computacional y cierre

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Actividad práctica: R y Python

- La práctica de esta clase se desarrolla en archivos separados:
  - `Clase23_Bayes_R.Rmd`

- Problemas incluidos:
  1. Actualización de una prueba diagnóstica,
  2. Modelo Beta–Binomial para proporciones,
  3. Comparación de prioris,
  4. Estimación puntual e intervalos creíbles por simulación.

- La idea no es memorizar código: es mirar cómo cambia la incertidumbre cuando entran datos nuevos.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Cierre de la Clase 23

- La inferencia bayesiana actualiza incertidumbre usando el teorema de Bayes.
- La posteriori combina priori y verosimilitud.
- En proporciones, el modelo Beta–Binomial permite actualización cerrada y es muy interpretable.
- Los intervalos creíbles tienen interpretación probabilística directa.
- En la próxima clase estudiaremos predicción, simulación de Monte Carlo e introducción a MCMC.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS