Clase 24: Modelos Predictivos
Introducción a la Estadística Bayesiana
Modelos Matemáticos y Estadísticos Clásicos

Inferencia y Aplicaciones

Prof. Maritza Márquez
maritza.marquez@uc.cl

Facultad de Matemáticas - Departamento de Estadística
Pontificia Universidad Católica de Chile

Julio 2026

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Contenidos

Repaso

Inferencia posterior

Distribución predictiva posterior

Simulación Monte Carlo

Introducción intuitiva a MCMC

Práctica computacional y cierre

Repaso

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Repaso Clase 23

- La inferencia bayesiana usa:

$$p(\theta \mid y) \propto p(y \mid \theta) p(\theta).$$

- La **priori** representa conocimiento inicial sobre θ.
- La **verosimilitud** conecta el parámetro con los datos observados.
- La **posteriori** resume la incertidumbre actualizada.
- En el modelo Beta–Binomial, la actualización se obtiene de forma cerrada.

Objetivos de la clase

- Interpretar estimaciones puntuales e intervalos creíbles desde la posteriori.
- Comprender la distribución predictiva a posteriori.
- Usar simulación de Monte Carlo para aproximar cantidades de interés.
- Introducir de manera intuitiva la lógica de los métodos MCMC.
- Aplicar inferencia bayesiana en proporciones, medias, salud, educación y experimentos A/B.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS



¿Qué es más informativo: una estimación puntual o una distribución posterior completa?

Inferencia posterior

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

La posterior como objeto central

- En Bayes, el resultado principal no es solo un estimador ni mirar un valor-p.

- El resultado principal es:

$$p(\theta \mid y).$$

- A partir de la posterior podemos calcular:
  - estimaciones puntuales,
  - intervalos creíbles,
  - probabilidades posteriores,
  - predicciones,
  - comparación entre modelos o decisiones.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Probabilidades posteriores útiles

- En lugar de preguntar solo si un efecto es distinto de cero, podemos preguntar:

$$P(\theta > 0 \mid y), \qquad P(\theta > 0{,}2 \mid y), \qquad P(a < \theta < b \mid y).$$

- Ejemplos:
  - Probabilidad de que la tasa de aprobación supere el $70\,\%$.
  - Probabilidad de que un tratamiento reduzca el riesgo en al menos $5\,\%$.

- Estas preguntas son cercanas al lenguaje de toma de decisiones.

Modelo Normal con varianza conocida

Sea:

$$Y_i \mid \mu \sim \mathcal{N}(\mu, \sigma^2), \qquad i = 1, \ldots, n,$$

con σ^2 conocida. Para la media usamos:

$$\mu \sim \mathcal{N}(m_0, s_0^2).$$

Entonces la posterior también es normal:

$$\mu \mid y \sim \mathcal{N}(m_n, s_n^2),$$

donde

$$s_n^2 = \left(\frac{1}{s_0^2} + \frac{n}{\sigma^2} \right)^{-1},$$

$$m_n = s_n^2 \left(\frac{m_0}{s_0^2} + \frac{n\bar{y}}{\sigma^2} \right).$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Interpretación del modelo Normal

- m_0 es la media priori: lo que esperábamos antes de observar los datos.
- s_0^2 mide cuánta incertidumbre tenemos previamente sobre μ.
- $\bar{y}$ es la información entregada por los datos.
- La media posteriori m_n combina m_0 y $\bar{y}$ ponderando por sus precisiones.
- Más datos implican más peso para la evidencia observada.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Ejemplo: Puntaje Promedio en Educación

- Queremos estimar el puntaje promedio μ en una prueba de diagnóstico inicial.

- Estudios anteriores sugieren $\mu \approx 60$, pero con alta incertidumbre:
$$\mu \sim \mathcal{N}(60, 15^2).$$

- En una nueva cohorte, $n = 25$ estudiantes tienen promedio observado $\bar{y} = 66$.

- Si suponemos $\sigma = 10$, la posteriori combina la evidencia histórica con la muestra actual.

- La pregunta práctica no es solo "¿cuál es el promedio?", sino también:
$$P(\mu > 65 \mid y).$$



Si aumenta el tamaño muestral, ¿la priori desaparece o simplemente pierde peso relativo?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Distribución predictiva posterior

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Predicción bayesiana

- La inferencia bayesiana permite predecir una nueva observación $\widetilde{Y}$.

- La distribución predictiva posterior es:

$$p(\widetilde{y} \mid y) = \int p(\widetilde{y} \mid \theta) p(\theta \mid y) d\theta.$$

- Esta expresión promedia todas las predicciones posibles considerando la incertidumbre sobre θ.

- En vez de predecir como si θ fuera conocido, propagamos la incertidumbre.

Ejemplo predictivo: Próxima Cohorte

Supongamos que:

$$\theta \mid y \sim \text{Beta}(16, 8).$$

- Queremos predecir cuántos estudiantes aprobarán en una próxima cohorte de $m = 10$ estudiantes.
- La predicción no usa solo $\widehat{\theta} = 0{,}667$.
- Primero se simula:

$$\theta^{(s)} \sim p(\theta \mid y),$$

- Luego:

$$\widetilde{Y}^{(s)} \mid \theta^{(s)} \sim \text{Binomial}(10, \theta^{(s)}).$$

- Así se obtiene la incertidumbre predictiva completa.

¿Por qué importa la predicción?

- En Data Science muchas decisiones son predictivas: demanda, riesgo, abandono, conversión, falla, respuesta.
- La distribución predictiva entrega no solo un valor esperado, sino un rango plausible de resultados futuros.
- Esto permite comunicar riesgo operativo.
- Ejemplo: no basta decir "aprobarán 7 estudiantes"; conviene decir qué tan probable es que aprueben menos de 5.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Simulación Monte Carlo

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Idea de Monte Carlo

- Muchas cantidades posteriores son integrales difíciles:

$$I = \int g(\theta) p(\theta \mid y) d\theta = E[g(\theta) \mid y].$$

- Generamos muestras independientes directamente desde la posteriori:

$$\theta^{(1)}, \ldots, \theta^{(M)} \overset{iid}{\sim} p(\theta \mid y),$$

  y aproximamos:

$$I \approx \frac{1}{M} \sum_{m=1}^{M} g(\theta^{(m)}).$$

- La integral se reemplaza por un promedio.

Probabilidades posteriores por simulación

Si queremos calcular:

$$P(\theta > 0{,}6 \mid y),$$

simulamos M valores de la posteriori y usamos:

$$P(\theta > 0{,}6 \mid y) \approx \frac{1}{M} \sum_{m=1}^{M} \mathbb{1}\{\theta^{(m)} > 0{,}6\}.$$

- Es una proporción de simulaciones que cumplen la condición.
- Mientras mayor sea M, menor será el error de simulación.
- Esta idea se usa constantemente en análisis bayesiano aplicado.

Introducción intuitiva a MCMC

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Cuando la posterior no tiene forma cerrada

- En modelos simples, como Beta–Binomial o Normal–Normal, podemos obtener la posteriori de forma analítica.

- En modelos más realistas, la posteriori suele ser compleja.

- Ejemplos:
  - regresión logística bayesiana,
  - modelos jerárquicos,
  - modelos con datos faltantes,
  - modelos longitudinales,
  - modelos con muchas fuentes de incertidumbre.

- Allí usamos métodos computacionales como MCMC.

¿Qué significa MCMC?

- MCMC significa **Markov Chain Monte Carlo**.

- La idea es construir una cadena de valores:

$$\theta^{(1)} \to \theta^{(2)} \to \ldots \to \theta^{(M)},$$

  cuya distribución de equilibrio sea la posteriori $p(\theta \mid y)$.

- Después de una etapa inicial, los valores de la cadena se usan como simulaciones aproximadas de la posteriori.

$$I \approx \frac{1}{M} \sum_{m=1}^{M} h\left(\theta^{(m)}\right).$$

- No necesitamos conocer la constante de normalización de la posteriori.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Metropolis–Hastings: (idea básica)

En cada iteración:

1. Partimos del valor actual $\theta^{(m)}$.
2. Proponemos un nuevo valor $\theta^{\star}$ cercano.
3. Comparamos qué tan plausible es $\theta^{\star}$ frente a $\theta^{(m)}$ según la posteriori.
4. Aceptamos o rechazamos la propuesta con cierta probabilidad.
5. Si se acepta, la cadena se mueve; si se rechaza, se queda donde estaba.

MCMC es el enfoque general y Metropolis–Hastings es uno de los algoritmos utilizados para generar la cadena.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Diagnóstico visual básico

- **Traza:** gráfico de los valores simulados contra la iteración.
- **Histograma o densidad:** aproximación de la distribución posterior.
- **Burn-in:** iteraciones iniciales que se descartan.
- **Mezcla:** capacidad de la cadena para explorar bien la posterior.
- Si la cadena se queda pegada, el algoritmo puede ser que no esté explorando bien.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

MCMC

- Requiere revisar convergencia y sensibilidad a elecciones computacionales.
- Una muestra MCMC grande no arregla un modelo mal especificado.
- Las prioris deben ser razonables y reportadas.
- Los resultados deben comunicarse en términos de incertidumbre y decisiones.
- En cursos avanzados se estudian algoritmos como Gibbs, Metropolis–Hastings, Hamiltonian Monte Carlo y NUTS.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Práctica computacional y cierre

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Actividad práctica: R y Python

- La práctica de esta clase se desarrolla en archivos separados:
  - `Clase24_Bayes_R.Rmd`

- Actividades incluidas:
  1. Modelo Normal–Normal para una media,
  2. Distribución predictiva posterior,
  3. Comparación A/B mediante simulación Monte Carlo,
  4. Introducción a Metropolis–Hastings.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS