# Clase 25: Modelos de Series de Tiempo
# Modelos Matemáticos y Estadísticos Clásicos

## Time Series Analysis - Wilfredo Palma
## Introducción

Wiley Series in Probability and Statistics 2016

Prof. Cristian Vásquez

Facultad de Matemáticas - Departamento de Estadística
Pontificia Universidad Católica de Chile

2026



# Análisis de Series de Tiempo

## Contenidos

Agenda:

- Introducción.
- Modelos para Series de Tiempo Estacionarias.
- Modelos para Series de Tiempo no Estacionarias

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

En esta sección se presenta la familia de modelos ARMA (autoregressive moving average) ampliamente desarrollados en a literatura para modelar fenómenos estacionarios.

La experiencia ha demostrado que la mayoría de los fenómenos reales de carácter económico, financiero, ecológico o de otra índole pueden ser aproximados por esta familia de modelos.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Estos modelos fueron desarrollados por Box y Jenkins en la década de los 70'. Esta familia de modelos se clasifican de la siguiente manera:

- AR($p$): Modelos autorregresivos de orden $p$.
- MA($q$): Modelos de medias móviles de orden $q$.
- ARMA($p, q$): Modelos autorregresivos de medias móviles de orden $(p, q)$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

## Modelos Autorregresivos

Se dice que una serie de tiempo $\{Y_t\}$ es un modelo autorregresivo si es estacionario y para todo instante del tiempo $t$ puede ser representado:

$$Y_t = \mu + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t,$$

donde el componente $\{\varepsilon_t\}$ es una secuencia de ruido blanco $(0, \sigma^2)$. Estos modelos se denominan "autorregresivos" porque pueden expresarse como una ecuación de regresión lineal, donde los posibles valores que toma la variable $Y$ en el tiempo $t$ depende de sus mismos valores observados en períodos anteriores, ponderados por los coeficientes $\phi_1, \ldots, \phi_p$

Entonces, el orden del modelo indica cuantos rezagos se hacen sobre $Y$. Por ejemplo:

- AR(1): Modelo autorregresivo de orden 1:

$$Y_t = \mu + \phi Y_{t-1} + \varepsilon_t,$$

- AR(2): Modelo autorregresivo de orden 2:

$$Y_t = \mu + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t,$$

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Existen ciertas restricciones sobre los parámetros $\phi$ para que estos modelos sean estacionarios, por ejemplo:

- AR(1): Modelo autorregresivo de orden 1, debe cumplir $|\phi| < 1$.
- AR(2): Modelo autorregresivo de orden 2, debe cumplir

$$\begin{aligned} \phi_2 + \phi_1 &< 1, \\ \phi_2 - \phi_1 &< 1, \\ |\phi_2| &< 1. \end{aligned}$$

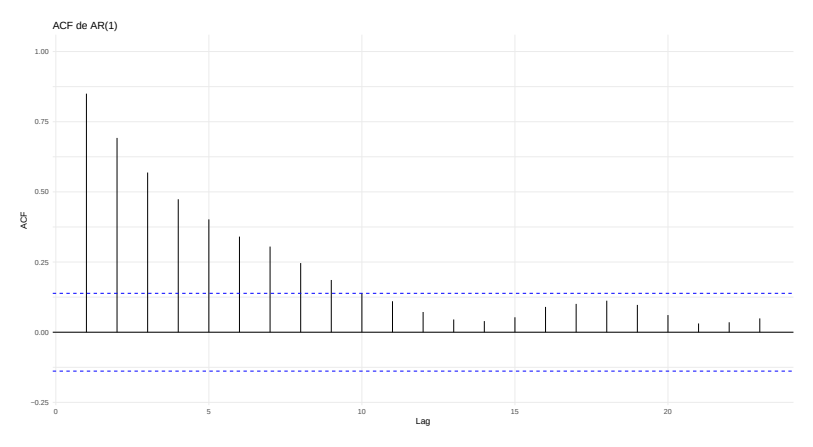
DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## ¿Cómo identificar cuando un modelo es autorregresivo?

Estos modelos se pueden identificar utilizando la función de autocorrelación. Todos lo modelos autorregresivos tienen un decaimiento exponencial en la función de autocorrelación:




Autocorrelación AR(1)

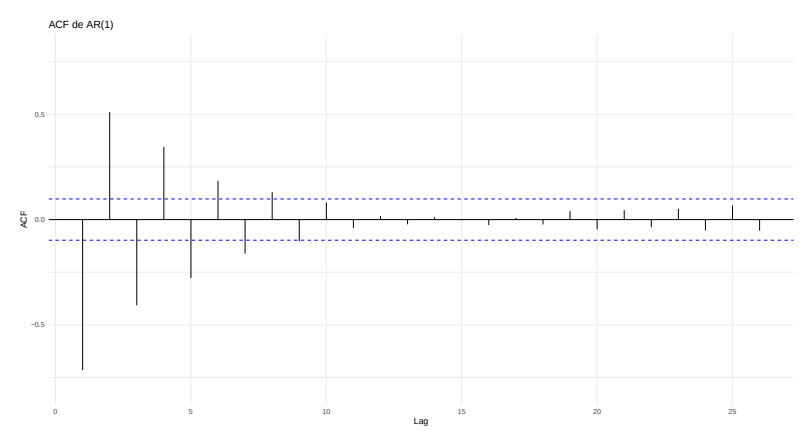
$$\rho(k) = \phi^k,$$

donde $\phi = 0.8$

# Análisis de Series de Tiempo

## Contenidos: Series de Tiempo Estacionarias

Si el parámetro es negativo, es decir, $-1 < \phi < 0$




Autocorrelación AR(1)

$$\rho(k) = \phi^k,$$

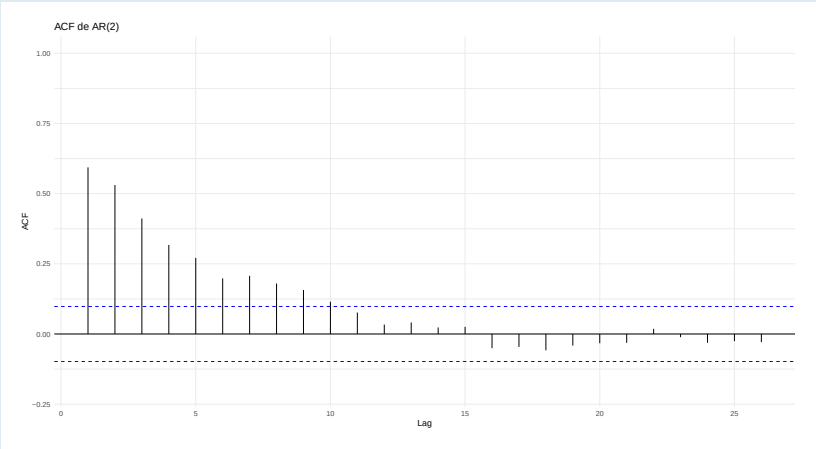
donde $\phi = -0.75$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

## Contenidos: Series de Tiempo Estacionarias

Ahora un ejemplo de AR(2):




Autocorrelación AR(2)

$$\rho(k) = \phi_1 \rho(k-1) + \phi_2 \rho(k-2),$$

para $k \geq 3$, donde

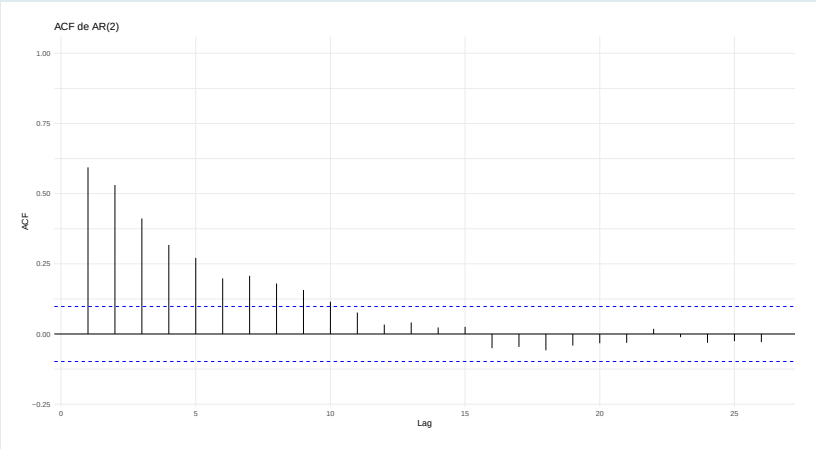
$$\begin{aligned} \rho(1) &= \phi_1/(1-\phi_2), \\ \rho(2) &= \phi_2 + \phi_1^2/(1-\phi_2) \end{aligned}$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Ahora un ejemplo de AR(2):




Autocorrelación AR(2)

$$\rho(k) = \phi_1 \rho(k-1) + \phi_2 \rho(k-2),$$

para $k \geq 3$, donde

$$\begin{aligned} \rho(1) &= \phi_1/(1-\phi_2), \\ \rho(2) &= \phi_2 + \phi_1^2/(1-\phi_2) \end{aligned}$$

En la práctica ¿Cómo identifico el valor de $p$?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

## Función de Autocorrelación Parcial (PACF)

Esta función contiene información relevante sobre la estructura de dependencia de las serie de tiempo estacionarias.

PACF en $k$ calcula la correlación entre $Y_1$ y $Y_{k+1}$ ajustado por la intervención de $Y_2, \ldots, Y_k$.

$$\begin{aligned} \alpha(1) &= \rho(1), \\ \alpha(k) &= \text{Corr}(Y_{k+1} - \widehat{Y}_{k+1}, Y_1 - \widehat{Y}_1),\ k \geq 2 \end{aligned}$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Para identificar un modelo ARMA se utiliza una análisis gráfico de la serie, acompañado de la ACF y PACF.

- El gráfico de la serie nos muestra si al serie de tiempo se varía entorno a una constante.
- La función ACF nos indica el tipo de decaimiento.
- La función PACF nos indica el orden (en los modelos AR).

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

La librería base `stat` de R dispone de las funciones `acf()` y `pacf()` para calcular las funciones de autocorrelación y autocorrelación parcial respectivamente. Sin embargo, para tener una mejor visualización es recomendable utilizar las funciones `ggAcf()` y `ggPacf()` de la librería `forecast`.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

La forma general de ambas fuciones

```
ggAcf(serie, type = c("correlation","covariance"), lag.max)
```

donde

- `serie`: Corresponde a la serie de tiempo.
- `type`: Se indica si es correlación o covarianza.
- `lag.max`: El máximo de rezagos que se desea visualizar en el gráfico

Ambas funciones son compatibles con la gramática de `ggplot2`.

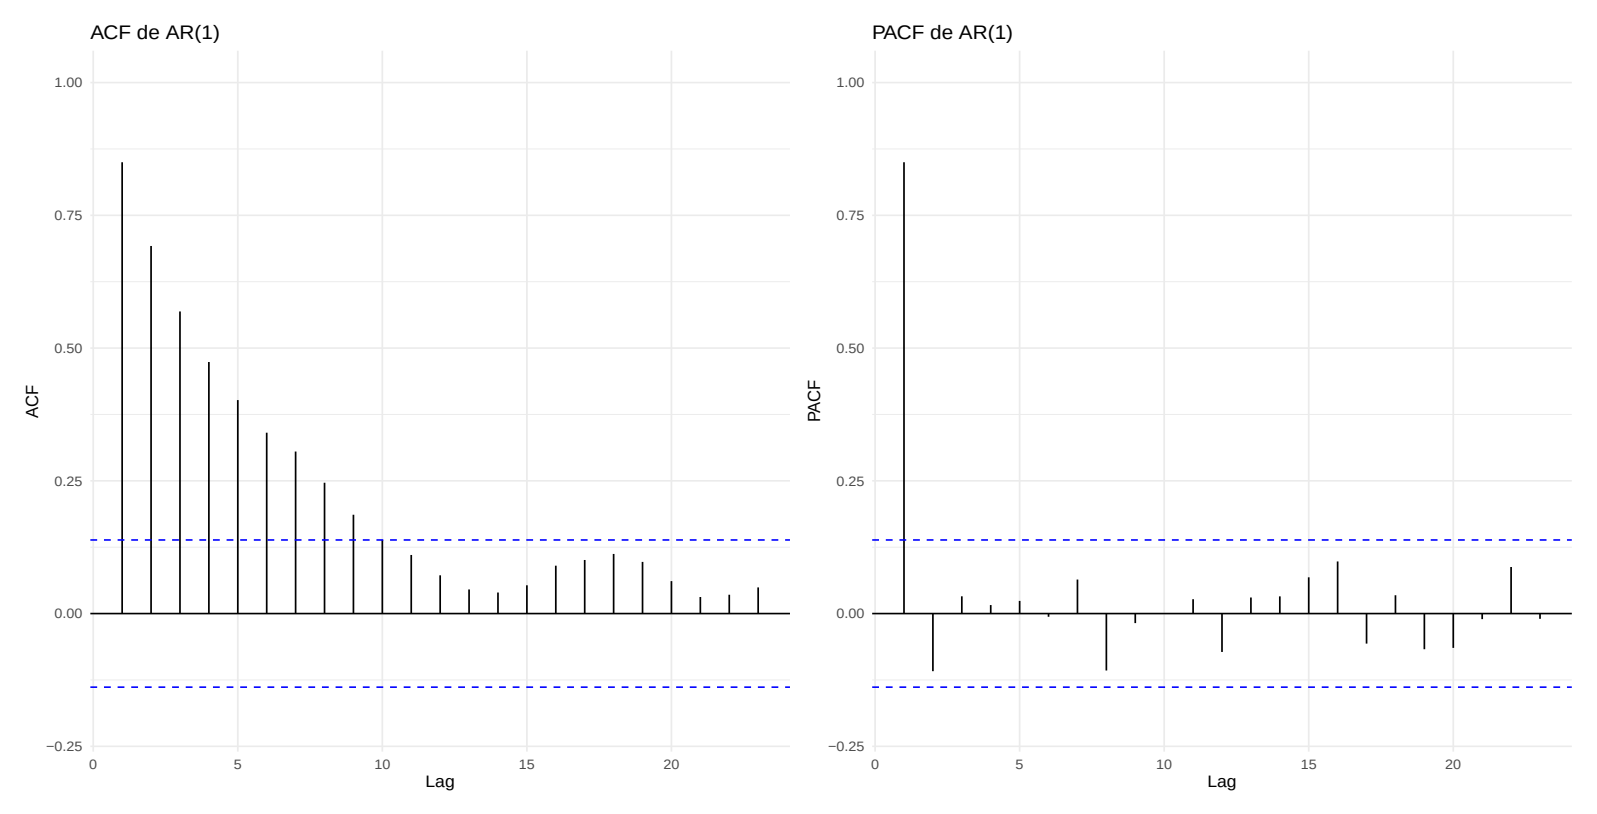


DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

## Contenidos: Series de Tiempo Estacionarias

Ejemplo $Y_t = \phi Y_{t-1} + \varepsilon_t$, donde $\phi = 0.8$

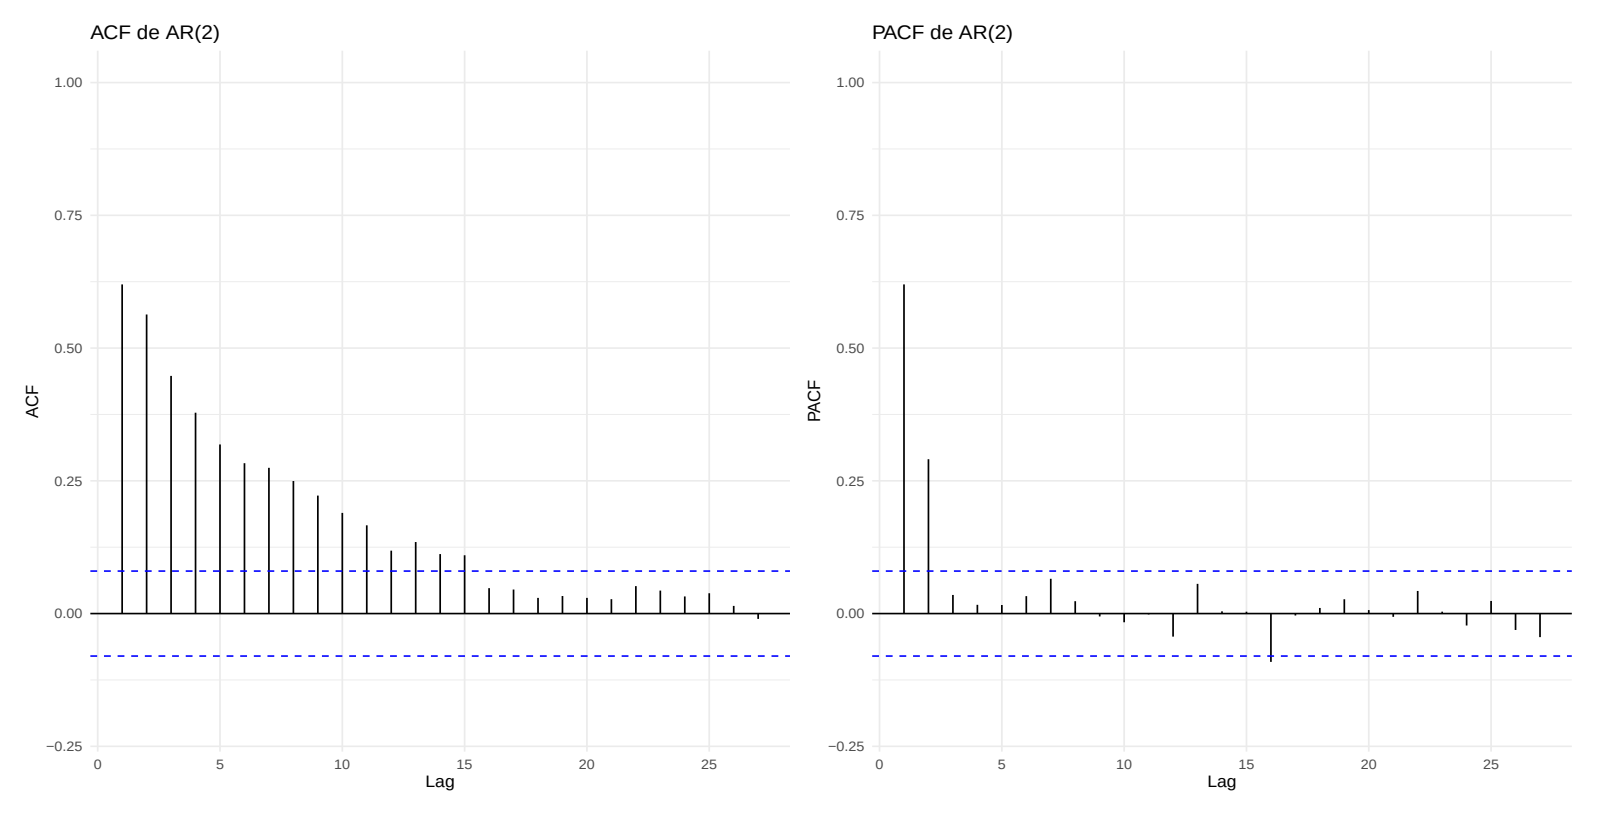



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

## Contenidos: Series de Tiempo Estacionarias

Ejemplo $Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$, donde $\phi_1 = 0.5$ y $\phi_2 = 0.3$




DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

## Modelos de Medias Móviles

Una serie de tiempo $\{Y_t\}$ es un proceso de medias móviles sí para todo instante del tiempo $t$ puede ser representado:

$$Y_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q},$$

donde $\{\varepsilon_t\}$ es una secuencia de ruido blanco $(0, \sigma^2)$. La idea básica es que la serie $\{Y_t\}$ puede ser representado como una suma ponderada de ruidos $\{\varepsilon_t\}$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Aquí $q$ corresponde al número de choques aleatorios:

- MA(1): Modelo de medias móviles de orden 1:

$$Y_t = \mu + \varepsilon_t - \theta\varepsilon_{t-1},$$

- MA(2): Modelo de medias móviles de orden 2:

$$Y_t = \mu + \varepsilon_t - \theta_1\varepsilon_{t-1} - \theta_2\varepsilon_{t-2},$$

Estos modelos son siempre estacionarios, se pide que los valores de los parámetros $\theta$ cumplan con algunas condiciones para poder transformar el proceso a un AR.

- MA(1): Modelo de medias móviles de orden 1, debe cumplir $|\theta| < 1$.
- MA(2): Modelo de medias móviles de orden 2, debe cumplir

$$\begin{aligned} \theta_2 + \theta_1 &< 1, \\ \theta_2 - \theta_1 &< 1, \\ |\theta_2| &< 1. \end{aligned}$$

La ACF y PACF para los modelos de medias móviles se comporta de manera invertida que en un modelo autorregresivo:

- $q$ indica en la ACF cuantas correlaciones son significativas o distintas de cero.
- Independiente de $q$ siempre tiene un decaimiento exponencial la PACF

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Ejemplo $Y_t = \varepsilon_t - \theta\varepsilon_{t-1}$ entonces

$$\rho(k) = \begin{cases} -\dfrac{\theta}{(1+\theta^2)}, & \text{si } k = 1, \\ 0, & \text{si } k \geq 2. \end{cases}$$

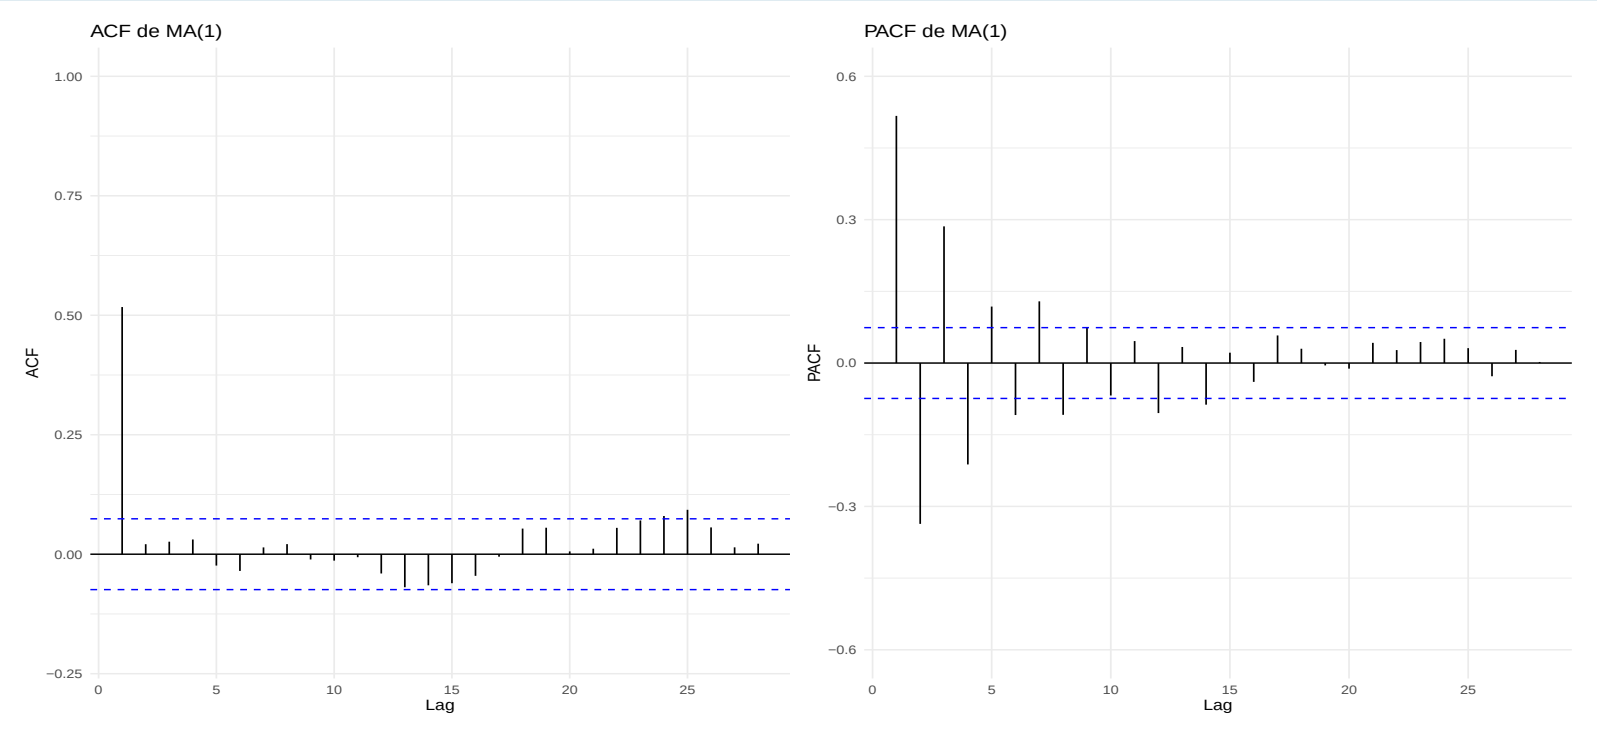
$$\alpha(k) = \begin{cases} -\dfrac{\theta}{(1+\theta^2)}, & \text{si } k = 1, \\ \dfrac{-\theta^k(1-\theta^2)}{1-\theta^{2(k+1)}}, & \text{si } k \geq 2. \end{cases}$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

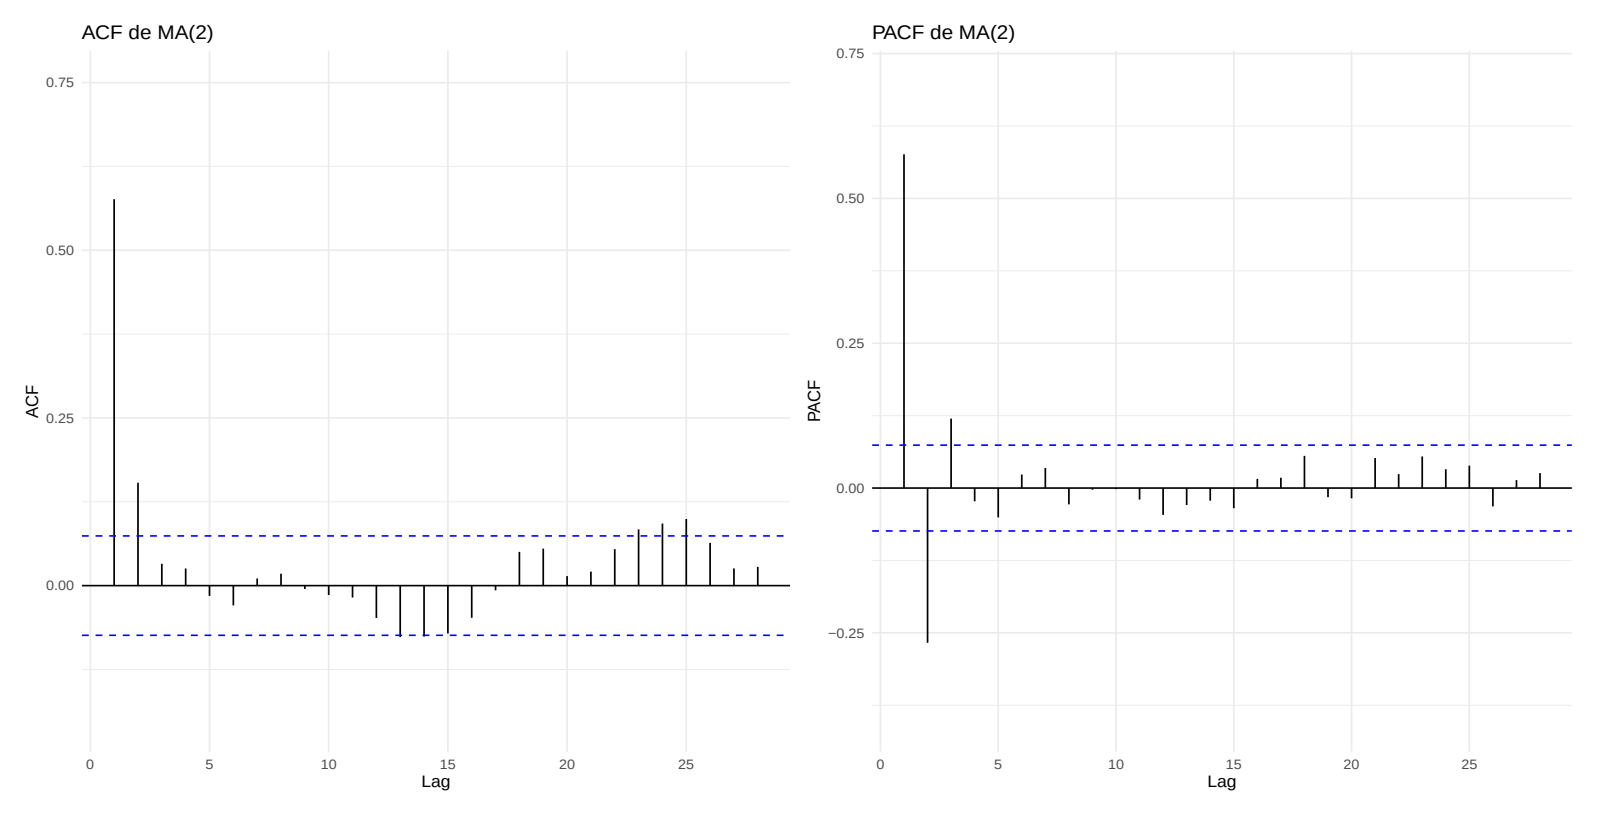
Los modelos de medias móviles en la práctica se puede identificar mediante la ACF y PACF. Ejemplo un MA(1) donde $\theta = -0.9$



# Análisis de Series de Tiempo

## Contenidos: Series de Tiempo Estacionarias

Ejemplo $Y_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2}$, donde $\theta_1 = -0.7$ y $\theta_2 = -0.2$



## Modelos Autorregresivos de Medias Móviles

Estos modelos son una generalización de los modelos AR y MA, ya que combina ambas clases de modelos. Estos modelos conocidos en la literatura como ARMA$(p, q)$ y se representan mediante

$$Y_t = \mu + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q},$$

donde $\{\varepsilon_t\}$ es ruido blanco $(0, \sigma^2)$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

- Estos modelos surgen del hecho que muchas series de tiempo que se observan en la práctica presentan características AR y MA.

- Los modelos ARMA son más parsimoniosos para construir modelos, necesitan menos parámetros que los anteriores.

- Por consideraciones técnicas, son viables cuando hay agregación de información, es decir,

$$Y_t = W_{1t} + W_{2t},$$

donde $\{W_{1t}\}$ y $\{W_{2t}\}$ son procesos estacionarios independientes.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Los modelos ARMA

- Siempre presentan decaimiento exponencial en la ACF.
- Siempre presentan decaimiento exponencial en la PACF.
- También hay condiciones sobre $\phi$ y $\theta$ para que el proceso sea estacionario

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Los modelos ARMA

- Siempre presentan decaimiento exponencial en la ACF.
- Siempre presentan decaimiento exponencial en la PACF.
- También hay condiciones sobre $\phi$ y $\theta$ para que el proceso sea estacionario

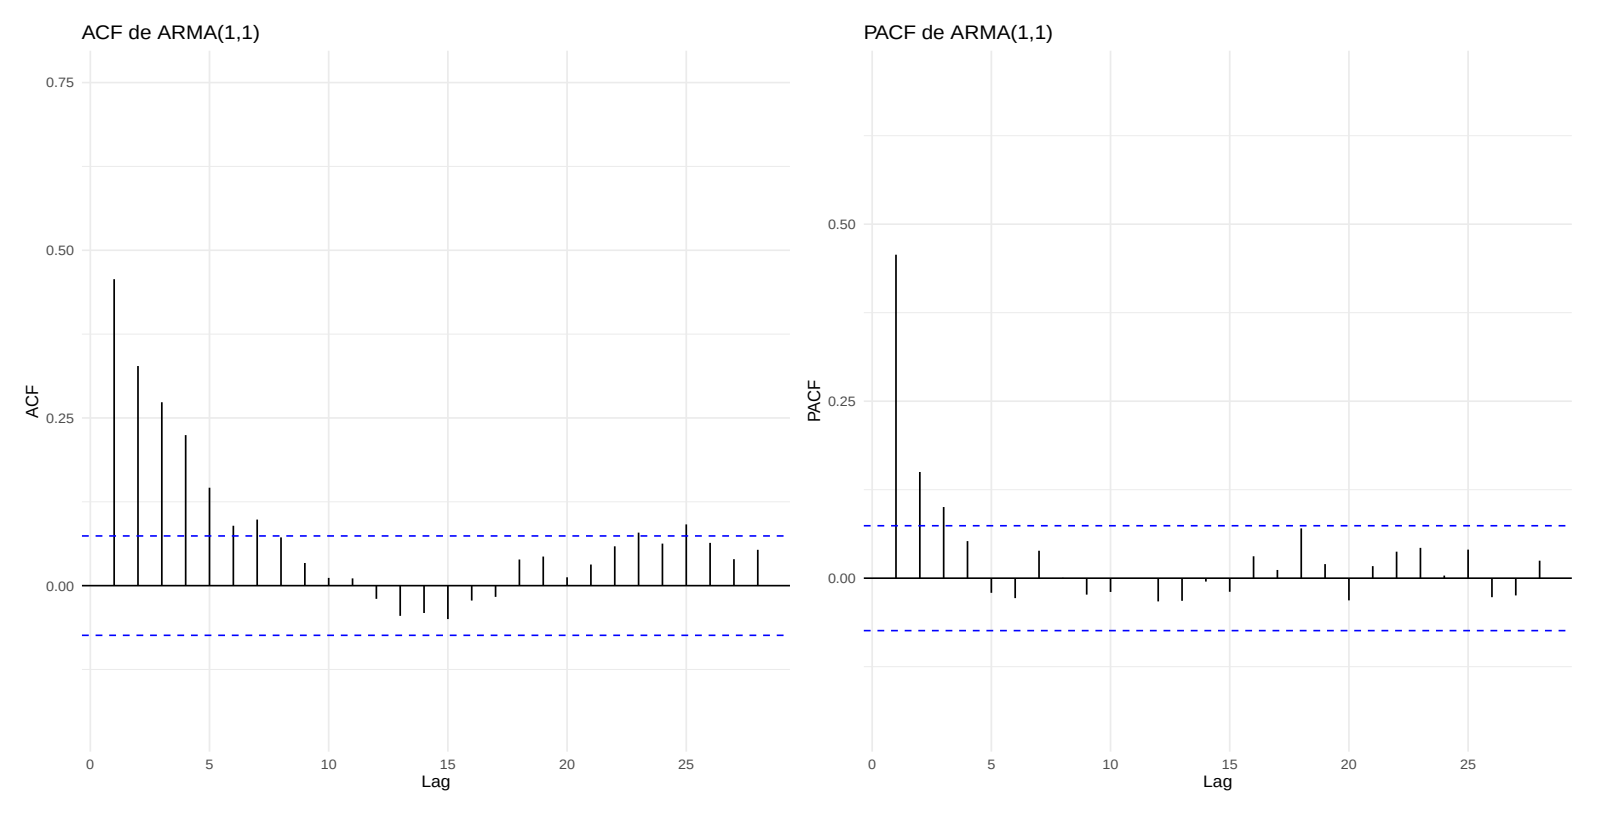
En la práctica ¿Cómo se determina el valor de $p$ y $q$?

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

## Contenidos: Series de Tiempo Estacionarias

Ejemplo ARMA(1, 1) donde $Y_t = \phi Y_{t-1} + \varepsilon_t - \theta \varepsilon_{t-1}$, con $\phi = 0.8$ y $\theta = 0.5$



## Estimación de los parámetros

Una vez identificados $p$ y $q$ existen varios métodos para estimar los parámetros del modelo.

- Método de Yule-Walker para series autorregresivas.
- Máxima verosimilitud.
- Estimador de Whittle.
- Espacio Estado.

`R` por medio de sus librerías dispone de todos los estimadores mencionados

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Una distribución importante en el análisis de series temporales es la *distribución normal multivariada*.

Dada la serie $\{y_1, y_2, \ldots, y_n\}$, podemos escribir el vector aleatorio $X = (y_1, y_2, \ldots, y_n)$. Se dice que $X$ es una variable aleatoria gaussiana multivariada, con la media $\mu$ y la matriz de varianza-covarianza $\Sigma$, denotada como $N(\mu, \Sigma)$, si la función de densidad es

$$f(X) = (2\pi)^{-n/2}|\Sigma|^{-n/2}e^{-\frac{1}{2}(X-\mu)'\Sigma^{-1}(X-\mu)}.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Observe que los elementos de $\Sigma$ corresponden a las covarianzas entre los componentes del vector aleatorio $X$, es decir, $\Sigma_{t,s} = \text{Cov}(y_t, y_s)$. Si la serie temporal es estacionaria, existe una función $\gamma(\cdot)$ tal que $\gamma(|t-s|) = \text{Cov}(y_t, y_s)$.

En este caso, la matriz de varianza-covarianza se puede escribir como

$$\Sigma = \begin{bmatrix} \gamma(0) & \gamma(1) & \gamma(2) & \cdots & \gamma(n-1) \\ \gamma(1) & \gamma(0) & \gamma(1) & \cdots & \gamma(n-2) \\ \vdots & \vdots & \vdots & & \vdots \\ \gamma(n-1) & \gamma(n-2) & \gamma(n-3) & \cdots & \gamma(0) \end{bmatrix}.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Utilizando el principio estadístico de máxima verosimilitud se pueden estimar los parámetros desconocidos $\vartheta$ del modelo, buscando los argumentos que maximizan la función de log-verosimilitud:

$$\ell(\vartheta) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log|\Sigma| - \frac{1}{2}(X-\mu)'\Sigma^{-1}(X-\mu),$$

donde $\vartheta = (\boldsymbol{\mu}, \boldsymbol{\theta}, \boldsymbol{\phi}, \sigma^2)'$ son los parámetros desconocidos y el estimador

$$\widehat{\vartheta} = \arg_{\vartheta} \max \ell(\vartheta)$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Las librerías más populares para ajustar modelos ARMA son:

- `stat`: función `arima()`.
- `forecast`: función `Arima()` similar a `arima()`.
- `tseries`: función `arma()`.
- `fArma`: Librería desarrollada por `Rmetrics` cuenta con la función `armaFit()`.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Las librerías mencionadas anteriormente utilizan los estimadores de mínimos cuadrados o máxima verosimilitud y Yule-Walker. La librería `afmtools` tiene la función `arfima.whittle()` para estimar los parámetros con el estimador de Whittle.

Todas las librerías reportan valores de estimación similares, la diferencia se encuentra en las salidas.

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Las librerías básica `'stat'` de `R` tiene la función `arima()` que permite ajustar modelos arma utilizando el clásico método de máxima verosimilitud. La librería `forecast` tiene la función `Arima()` similar a la anterior pero reporta más estadísticas.

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

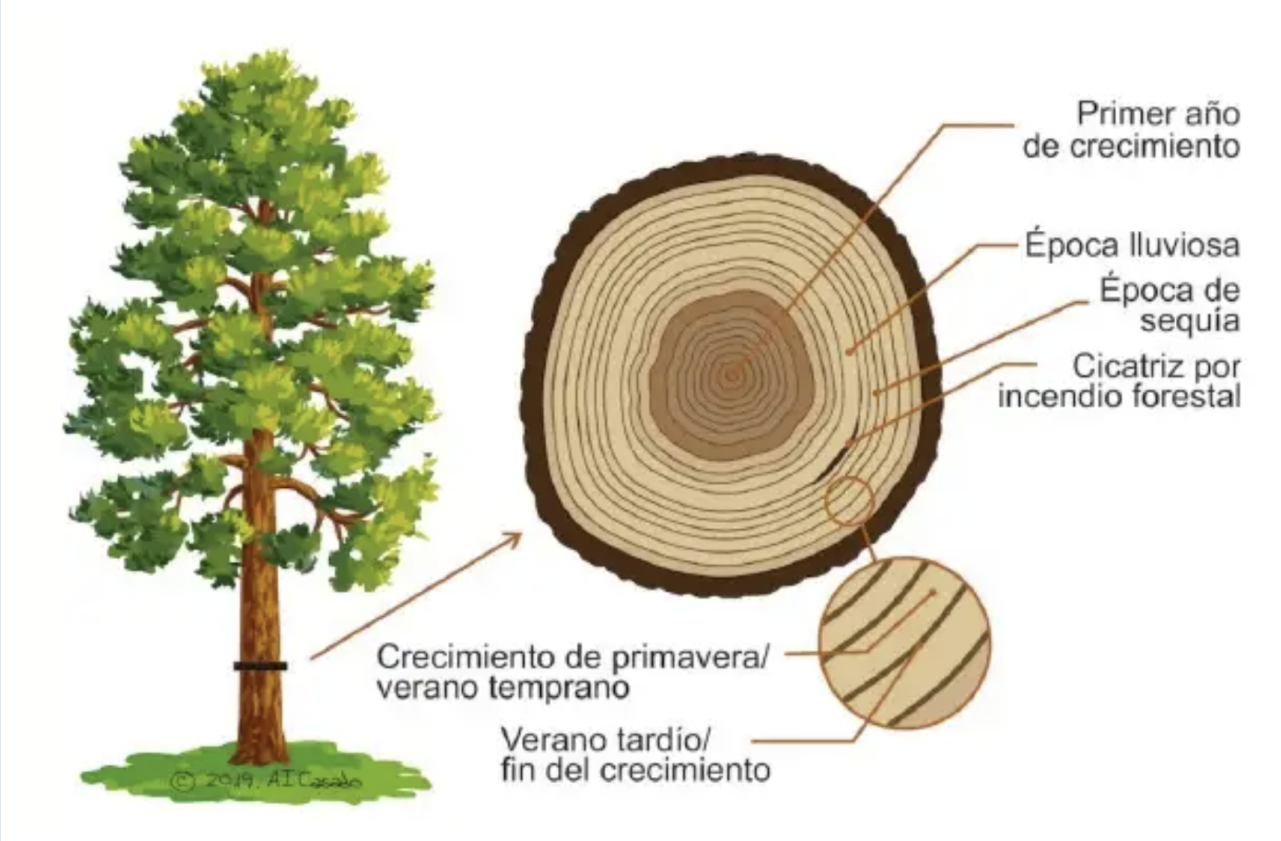
Ejemplo: En el archivo `'tree.xlsx'` se encuentra la medición del crecimiento anual de los anillos de un árbol en Idaho, USA. Estas series son de mucha utilidad en el área de la climatología ya que se puede reconstruir el clima, precipitación, temperatura del pasado en períodos de los que no se tiene constancia meteorológica de ningún tipo.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

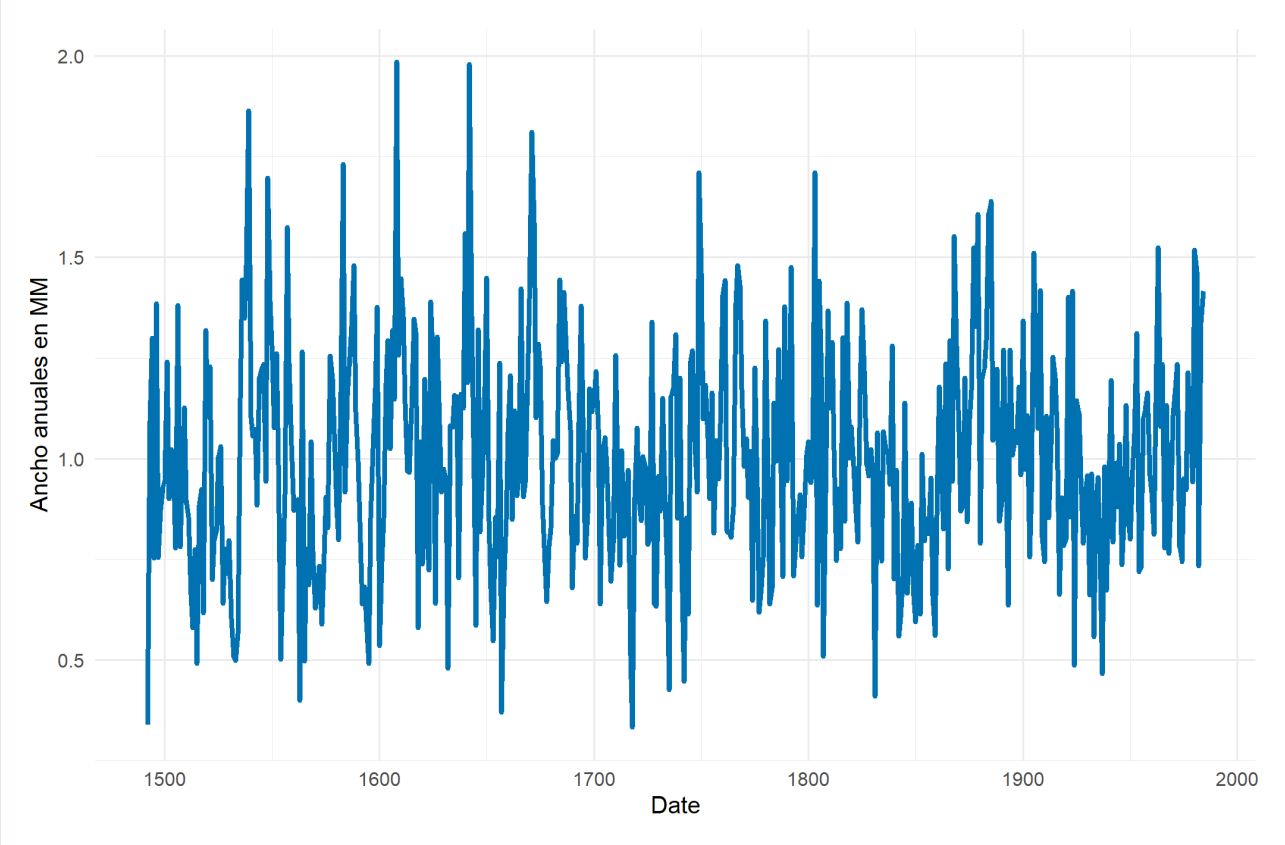
Contenidos: Series de Tiempo Estacionarias

## Dendrocronología:



# Análisis de Series de Tiempo

## Contenidos: Series de Tiempo Estacionarias




DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Algunas estadísticas descriptivas:

```
> mean(tree$Idaho)
[1] 1.000024
> median(tree$Idaho)
[1] 0.973
> sd(tree$Idaho)
[1] 0.2784397
> var(tree$Idaho)
[1] 0.07752866
> IQR(tree$Idaho)
[1] 0.386
> summary(tree$Idaho)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  0.332   0.797   0.973   1.000   1.183   1.985
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Algunas estadísticas descriptivas:

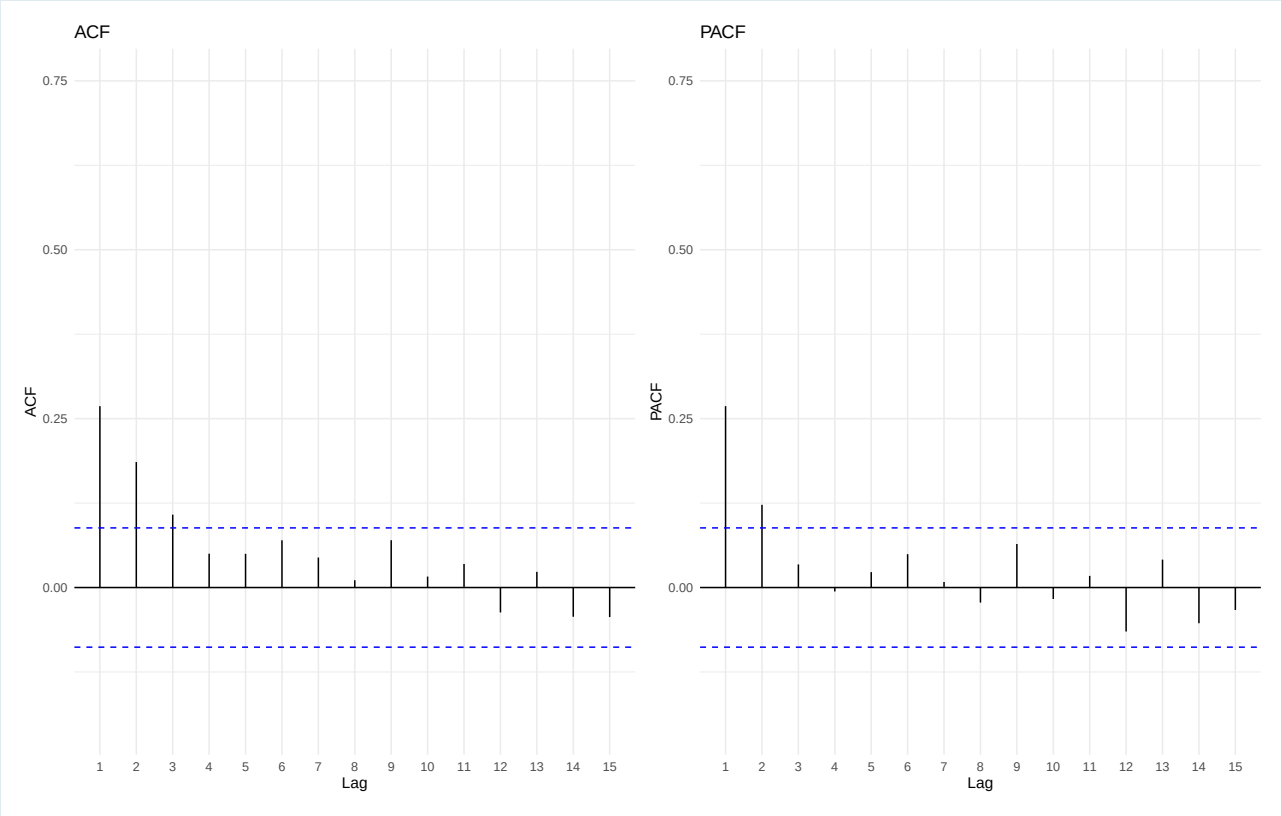
```
> mean(tree$Idaho)
[1] 1.000024
> median(tree$Idaho)
[1] 0.973
> sd(tree$Idaho)
[1] 0.2784397
> var(tree$Idaho)
[1] 0.07752866
> IQR(tree$Idaho)
[1] 0.386
> summary(tree$Idaho)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  0.332   0.797   0.973   1.000   1.183   1.985
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Gráficos de ACF y PACF




DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

En el código de ajustan los siguientes modelos:

| Indicador | Modelo |
|---|---|
| 1 | `arma(0,3)` |
| 2 | `arma(0,2)` |
| 3 | `arma(1,0)` |
| 4 | `arma(2,0)` |
| 5 | `arma(1,1)` |

Las funciones `arima()`, `Arima()` y `armaFit()` reportan los mismos resultados

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Modelo 1:

```
> summary(modelo1)
Call:
arma(x = tree$Idaho, order = c(0, 3))

Model:
ARMA(0,3)

Coefficient(s):
           Estimate  Std. Error  t value Pr(>|t|)
ma1         0.23819     0.04492    5.302 1.14e-07 ***
ma2         0.17289     0.04493    3.848 0.000119 ***
ma3         0.08113     0.04286    1.893 0.058349 .
intercept   1.00090     0.01774   56.408  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Fit:
sigma^2 estimated as 0.07004,
Conditional Sum-of-Squares = 34.25,
AIC = 96.37
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Modelo 2:

```
> summary(modelo2)
Call:
arma(x = tree$Idaho, order = c(0, 2))

Model:
ARMA(0,2)

Coefficient(s):
           Estimate  Std. Error  t value Pr(>|t|)
ma1         0.22602     0.04465    5.062 4.15e-07 ***
ma2         0.15891     0.04352    3.651 0.000261 ***
intercept   1.00176     0.01654   60.567  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Fit:
sigma^2 estimated as 0.07059,
Conditional Sum-of-Squares = 34.59,
AIC = 98.21
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Modelo 3:

```
> summary(modelo3)
Call:
arma(x = tree$Idaho, order = c(1, 0))

Model:
ARMA(1,0)

Coefficient(s):
           Estimate  Std. Error  t value Pr(>|t|)
ar1         0.26975     0.04321    6.243 4.28e-10 ***
intercept   0.73181     0.04481   16.332  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Fit:
sigma^2 estimated as 0.07117,
Conditional Sum-of-Squares = 34.94,
AIC = 100.22
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Modelo 4:

```
> summary(modelo4)
Call:
arma(x = tree$Idaho, order = c(2, 0))

Model:
ARMA(2,0)

Coefficient(s):
           Estimate  Std. Error  t value Pr(>|t|)
ar1         0.24147     0.04472    5.400 6.66e-08 ***
ar2         0.12272     0.04453    2.756  0.00585 **
intercept   0.63704     0.05526   11.528  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Fit:
sigma^2 estimated as 0.07008,
Conditional Sum-of-Squares = 34.34,
AIC = 94.64
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Modelo 5:

```
> summary(modelo5)
Call:
arma(x = tree$Idaho, order = c(1, 1))

Model:
ARMA(1,1)

Coefficient(s):
           Estimate  Std. Error  t value Pr(>|t|)
ar1          0.5602      0.1148    4.880 1.06e-06 ***
ma1         -0.3083      0.1275   -2.417 0.015633 *
intercept    0.4412      0.1152    3.830 0.000128 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Fit:
sigma^2 estimated as 0.07048,
Conditional Sum-of-Squares = 34.6,
AIC = 97.41
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Para seleccionar modelos se puede utilizar el criterio del menor AIC:

| Modelo | *AIC* |
|---|---|
| 1 | 102.77 |
| 2 | 104.77 |
| 3 | 105.98 |
| 4 | 100.48 |
| 5 | 100.11 |

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelo Ajustado:

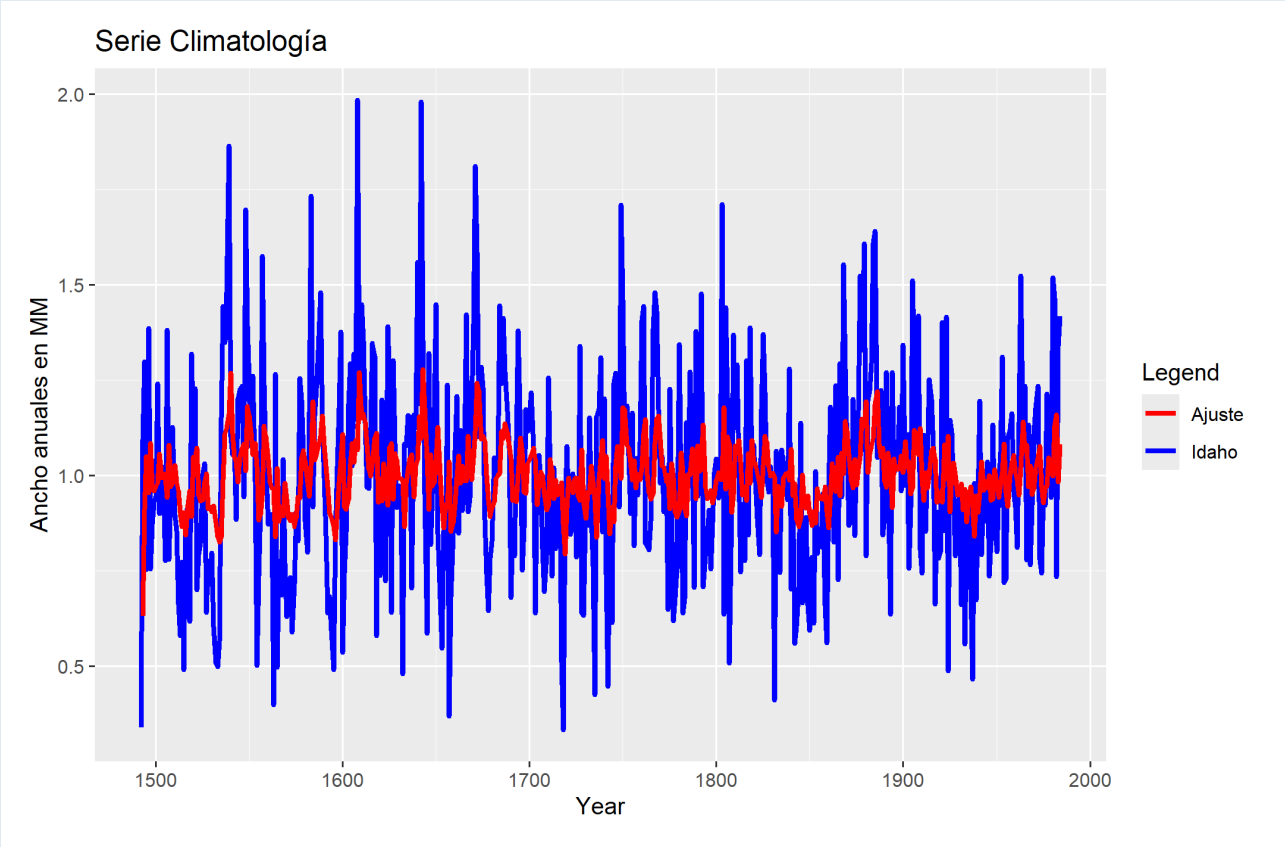
$$Y_t = 1.0 - 0.652 Y_{t-1} + \varepsilon_t + 0.415 \varepsilon_{t-1}$$

donde $\widehat{\sigma}^2 = .0706$. Si se quiere ver el ajuste del modelo para compara con los valores reales, se puede utilizar la función `fitted()`.

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Valores de la serie real vs valores ajustados:



# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Falta el diagnostico de los residuos. Para ajustar modelos ARMA se está suponiendo que los residuos son ruido blanco.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

## Test de Ljung & Box

Este test permite verificar si los residuos son no correlacionados. La hipótesis nula del test $H_0 : \rho_1 = \rho_2 = \cdots = \rho_m = 0$ vs $H_1 : \rho_i \neq 0$ para algún $i \in \{1, \ldots, m\}$. El estadístico asociado al test bajo $H_0$

$$Q(m) = n(n+2) \sum_{r=1}^{m} \frac{\widehat{\rho}_r^{\,2}}{n-r}.$$

La regla de decisión es rechazar $H_0$ sí $Q(m) > \chi^2_{1-\alpha}$ donde $\chi^2_{1-\alpha}$ corresponde al percentil de la distribución chi cuadrado que acumula $100(1-\alpha)\,\%$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

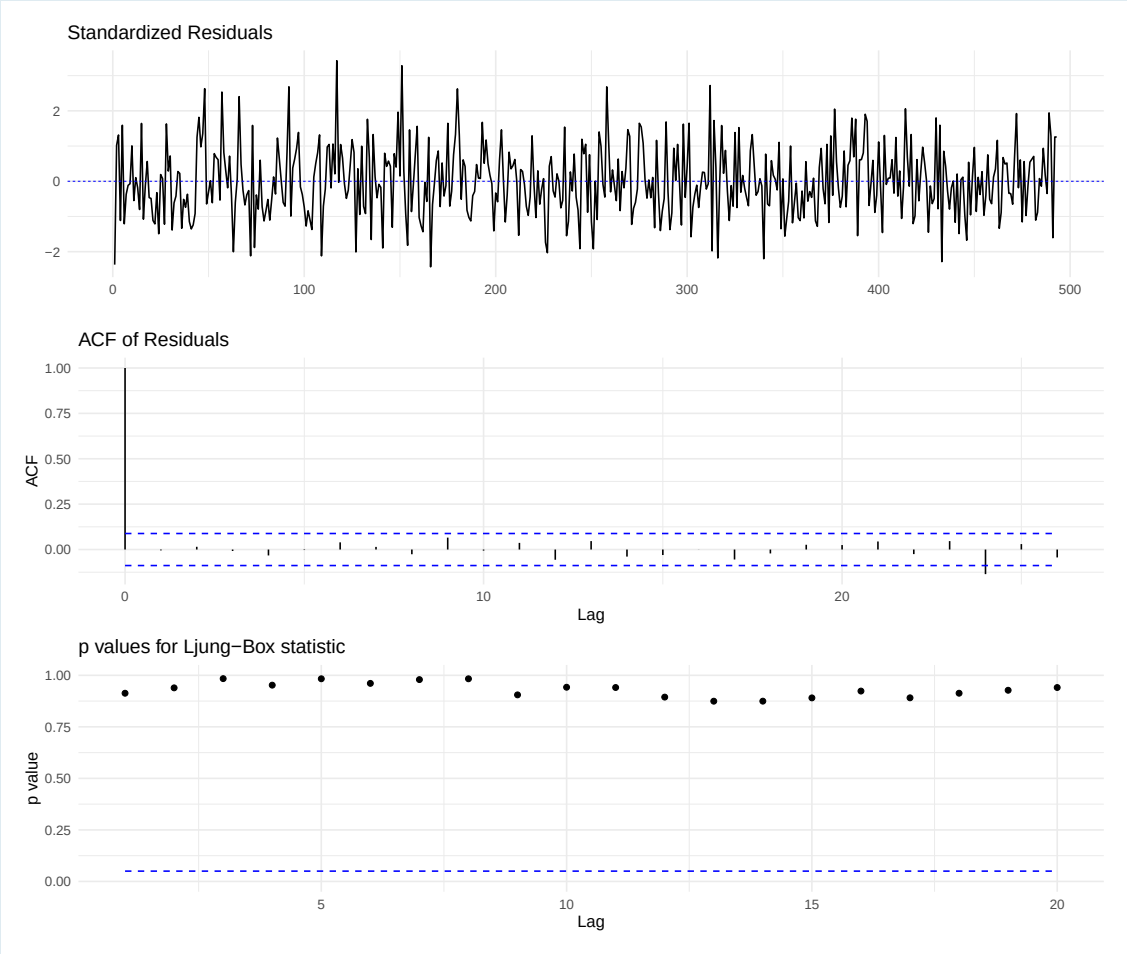
Contenidos: Series de Tiempo Estacionarias

En `R` la librería base `stat` tiene la función `tsdiag()` que realiza el test de Ljung & Box para los residuos de un modelo ajustado. La librería `ggfortify` permite hacer el mismo test y graficar con `ggplot2` sobre objetos creados con la librería `forecast` utilizando la función `ggtsdiag()`.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

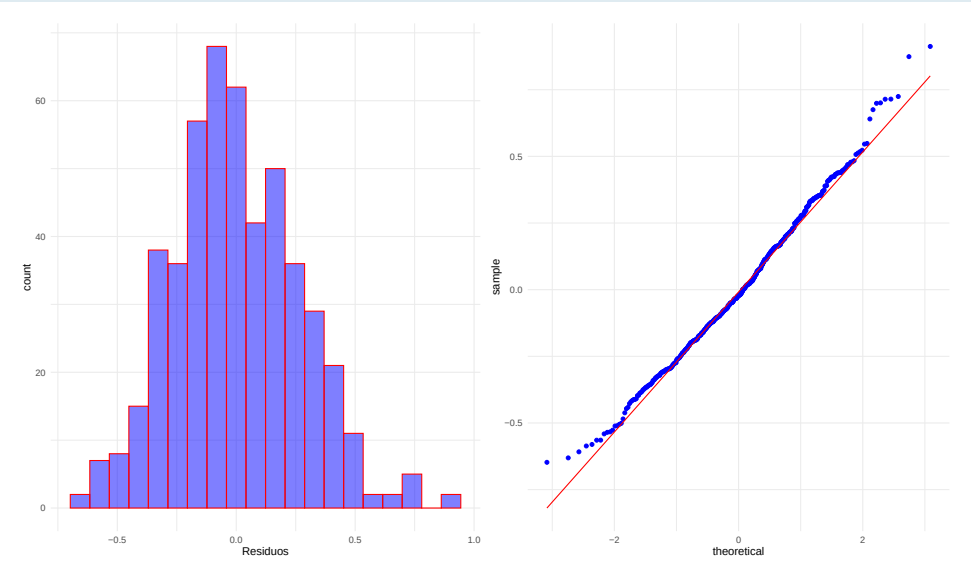
## Contenidos: Series de Tiempo Estacionarias




DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

## Contenidos: Series de Tiempo Estacionarias




```
> media = mean(tree$Residuos)
> desv  = sd(tree$Residuos)
> ks.test(tree$Residuos,
              "pnorm",
               media,
               desv)

        One-sample Kolmogorov
                   Smirnov test

data:  tree$Residuos
D = 0.04101, p-value = 0.3783
alternative hypothesis: two-sided
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Un punto relevante es obtener las predicciones de la serie de tiempo que se está analizando.

Dadas las observaciones hasta el tiempo $t$, uno puede querer pronosticar $h$-pasos por delante,*horizonte de predicción*, $\widehat{y}_{t+h}$, siendo la esperanza condicional el mejor predictor.

$$\widehat{y}_{t+h} = \mathrm{E}[y_{t+h}|y_t, y_{t-1}, y_{t-2}, \dots].$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Para un proceso gaussiano, el *mejor predictor* es precisamente el *mejor predictor lineal*, independientemente del modelo que vincula $y_{t+h}$ con $y_t, y_{t-1}, y_{t-2}, \ldots$.

Además, tenga en cuenta que en la práctica solo hay disponible un tramo finito de datos, $\{y_1, y_2, \ldots, y_n\}$, por ejemplo.

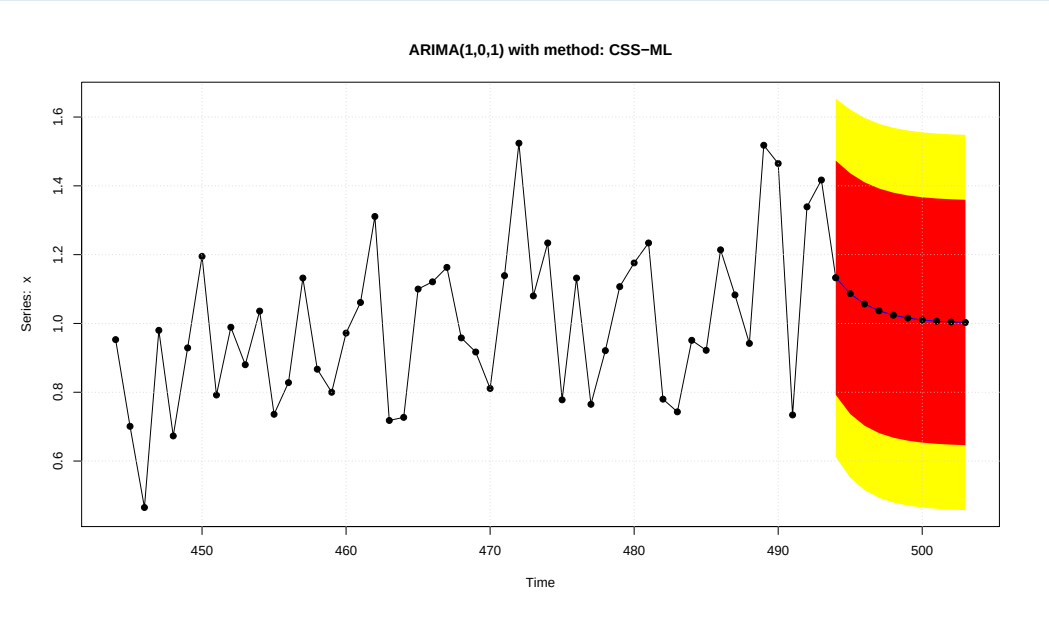
En este caso, el predictor *pasado finito* está dado por,

$$\widehat{y}_{n+h} = \mathrm{E}[y_{n+h}|y_n, y_{n-1}, y_{n-2}, \ldots, y_1].$$

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

Para obtener las predicciones se puede utilizar la función `predict()` o `forecast()` de la librería `forecast`




DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

Contenidos: Series de Tiempo Estacionarias

## Resultados

```
> predict(modelo5, h = 10)

Time Series:
Start = 494
End = 503
Frequency = 1
    Low 95 Low 80 Forecast High 80 High 95
494 0.6122 0.7924   1.1328  1.4732  1.6534
495 0.5515 0.7367   1.0866  1.4364  1.6216
496 0.5154 0.7027   1.0564  1.4102  1.5975
497 0.4932 0.6814   1.0368  1.3922  1.5804
498 0.4793 0.6678   1.0240  1.3801  1.5687
499 0.4705 0.6592   1.0156  1.3721  1.5608
500 0.4649 0.6536   1.0102  1.3668  1.5555
501 0.4612 0.6500   1.0066  1.3633  1.5520
502 0.4589 0.6477   1.0043  1.3610  1.5498
503 0.4574 0.6462   1.0028  1.3595  1.5483
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

# Análisis de Series de Tiempo

## Contenidos

Espacio para consultas o dudas sobre extensiones



Gracias por su atención

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

## Bibliografía

Profundizar contenidos


- *Econometría*. Damodar N. Gujarati, Dawn C. Porter. S.A. Quinta edición, McGraw-Hill(2010).
- *Introduction to Time Series and Forecasting*. Peter J. Brockwell, Richard A. Davis. 3rd edition Springer (2016).


DATA
SCIENCE UC
FACULTAD DE MATEMÁTICAS