Clase 27: Modelos de Series de Tiempo
Modelos Matemáticos y Estadísticos Clásicos

Time Series Analysis - Wilfredo Palma
Introducción

Wiley Series in Probability and Statistics 2016

Prof. Cristian Vásquez

Facultad de Matemáticas - Departamento de Estadística
Pontificia Universidad Católica de Chile

2026



Análisis de Series de Tiempo

Contenidos

Agenda:

- Introducción.
- Modelos para Series de Tiempo Estacionarias.
- Modelos para Series de Tiempo Estacional y para Series No Estacionarias

Agenda de la Presentación

Agenda

Modelos ARMA Estacional



Modelos Estacionarios

Modelo ARMA Estacional

Cuando se trabaja con series de tiempo, es común utilizar operador el back- ward shift.

$$\nabla Y_t = Y_t - Y_{t-1} = (1 - B)Y_t, \qquad BY_t = Y_{t-1}.$$

Utilizando este operador, los procesos pueden ser expresados en función de este operador

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

Note lo siguiente:

$$\begin{aligned} B^j Y_t &= Y_{t-j}, \\ \nabla^2 Y_t &= \nabla(\nabla Y_t) = (1-B)(1-B)Y_t = Y_t - 2Y_{t-1} + Y_{t-2} \end{aligned}$$

Los polinomios en el operador B se pueden trabajar de la misma forma que funciones de polinomios de variables reales.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

A partir de esta notación, los modelos ARMA en general se pueden expresar en función de polinomios en la parte autoregresiva y de medias móviles:

$$\phi(B)(Y_t - \mu) = \theta(B)\varepsilon_t,$$

donde

- $\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p$ es un polinomio autorregresivo en el operador backshift B.
- $\theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q$ es un polinomio de media móvil.
- Los polinomios tienen diferentes raíces

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

En la práctica existe una familia de modelos, que son una extensión de los modelos ARMA, dado que además consideran un patrón de dependencia estacional. Por ejemplo, suponga que se está analizando una serie mensual, entonces uno debería evaluar un componente estacional para esa serie cada 12 períodos en lugar de considerar solamente $Y_{t-1}, Y_{t-2}, \ldots$. Estos modelos incorporan explícitamente:

$$Y_{t-12}, Y_{t-24}, Y_{t-36}, \ldots$$

Es decir, comparamos una observación con observaciones correspondientes a años anteriores. Por ejemplo: $Y_{\text{enero 2026}}$ puede depender de $Y_{\text{enero 2025}}$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

Ejemplo: Considere un proceso ARMA$(1,0)$ con estacionalidad $s = 12$, o equivalentemente el proceso AR$(1)_{12}$ descrito por

$$Y_t = \Phi Y_{t-12} + \varepsilon_t$$

donde $|\Phi| < 1$ y $\varepsilon_t \sim \text{RB}(0, \sigma^2)$. Para este proceso la función de autocorrelación está dada por

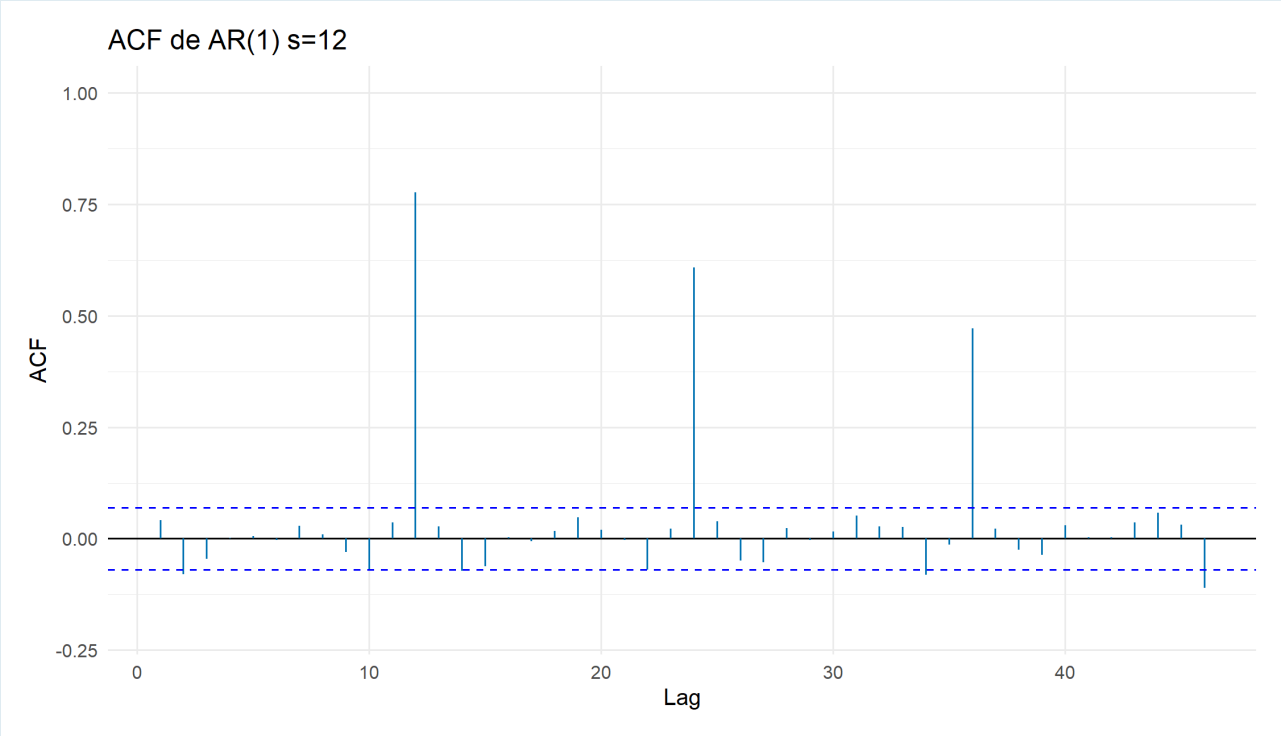
$$\rho(k) = \begin{cases} \Phi^{k/12}, & \text{para } k = 12, 24, 36, \ldots \\ 0, & \text{en otro caso.} \end{cases}$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

Ilustración de la ACF del proceso $Y_t = 0.8 Y_{t-12} + \varepsilon_t$



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

De manera general, un proceso SARMA$(p, q)(P, Q)_S$ se puede representar como

$$\phi(B)\,\Phi(B^s)(Y_t - \mu) = \theta(B)\,\Theta(B^s)\,\varepsilon_t,$$

donde ε_t es una secuencia de ruido blanco con media cero y varianza σ^2, μ el valor esperado del proceso.

El aporte estacional del proceso es generado por los polinomios $\Phi(B^2)$ y $\Theta(B^s)$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

Los respectivos polinomios están dados por:

$$
\begin{aligned}
\phi(B) &= 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p, \\
\Phi(B^s) &= 1 - \Phi_1 B^s - \Phi_2 B^{2s} - \cdots - \Phi_P B^{Ps}, \\
\theta(B) &= 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q, \\
\Theta(B^s) &= 1 - \Theta_1 B^s - \Theta_2 B^{2s} - \cdots - \Theta_Q B^{Qs}.
\end{aligned}
$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Agenda de la Presentación

Agenda

Modelos SARMA: Aplicación



Modelos Estacionarios

Modelo ARMA Estacional - Aplicación

Muertes accidentales en los EE. UU. 1973-1978.

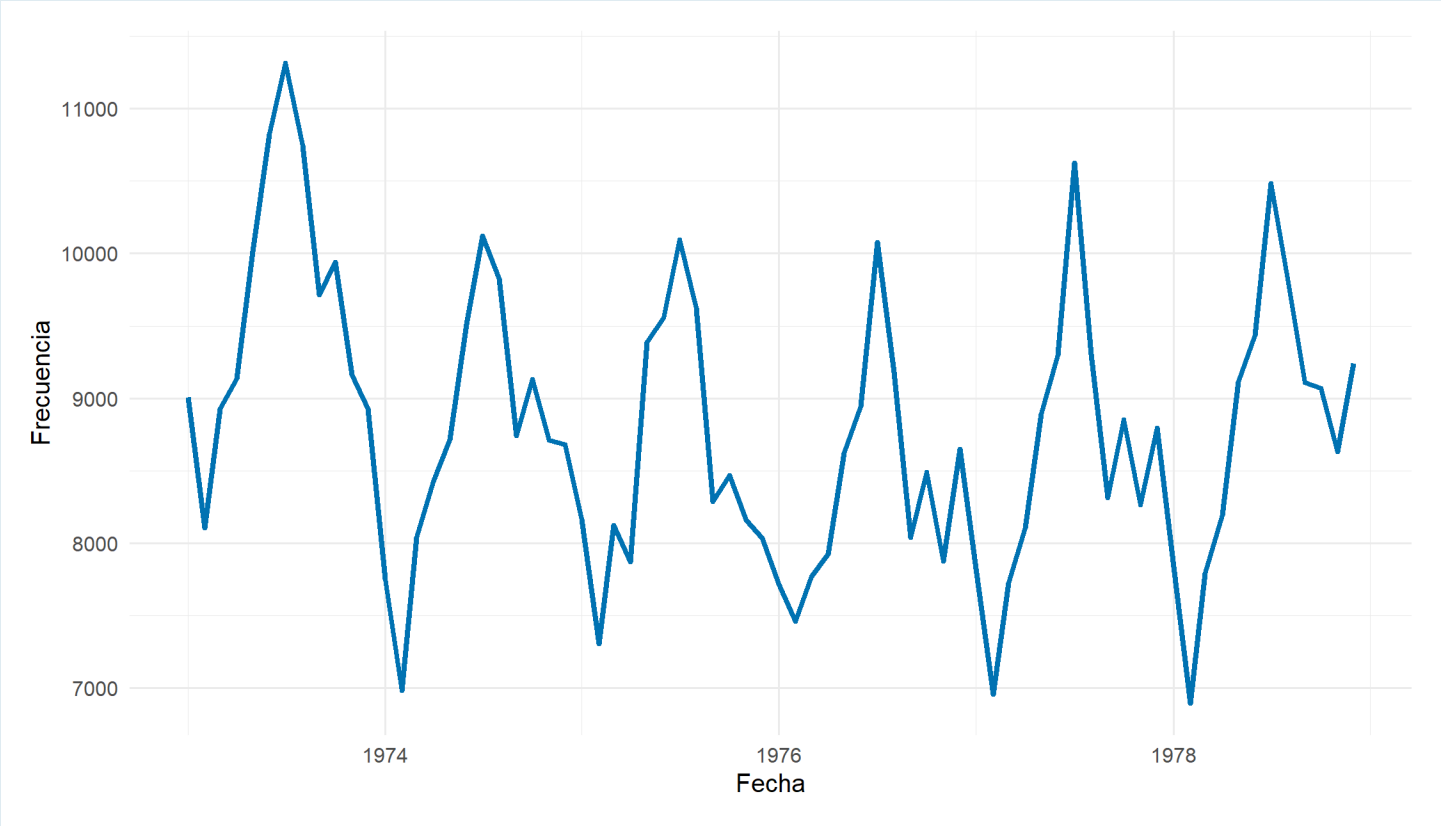


Figura: Fallecimientos mensuales por accidentes en EE.UU.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

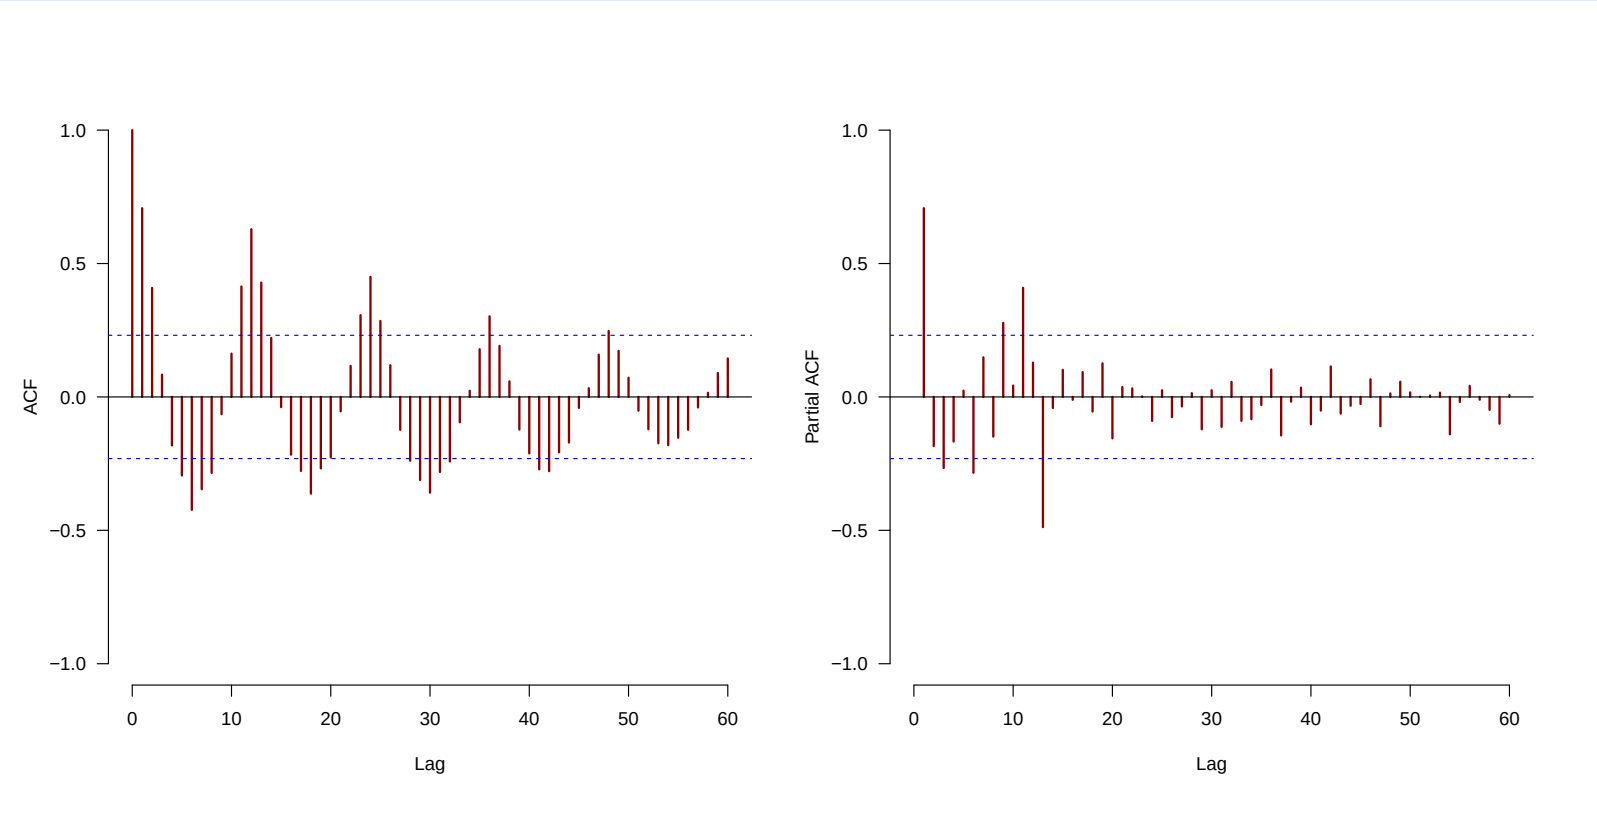


Figura: ACF y PACF

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

```
model <- forecast::auto.arima(Y, max.p = 11, max.q = 11, max.P = 1, max.Q = 4, d = 0, D = 0)

salida.arima(Y, fit = model)
Series: Y
ARIMA(1,0,0)(1,0,0)[12] with non-zero mean

Coefficients:
         ar1    sar1       mean
      0.7579  0.8501  9214.7102
s.e.  0.0768  0.0498   676.1701

sigma^2 = 132733:  log likelihood = -533.45
AIC=1074.89   AICc=1075.49   BIC=1084

Training set error measures:
                    ME     RMSE      MAE        MPE     MAPE     MASE        ACF1
Training set -27.44004 356.6552 274.1326 -0.4874762 3.172515 0.626947 -0.1256753


  Adjusted R-squared
         0.8602067

            Estimate Std. Error z value Pr(>|z|)
ar1           0.7579     0.0768  9.8645        0
sar1          0.8501     0.0498 17.0816        0
intercept 9214.7102   676.1701 13.6278        0

 Residuals:
         Kolmogorov-Smirnov test Breusch-Pagan test
p-value                0.957828          0.2892881
```



Modelos Estacionarios

Modelo ARMA Estacional

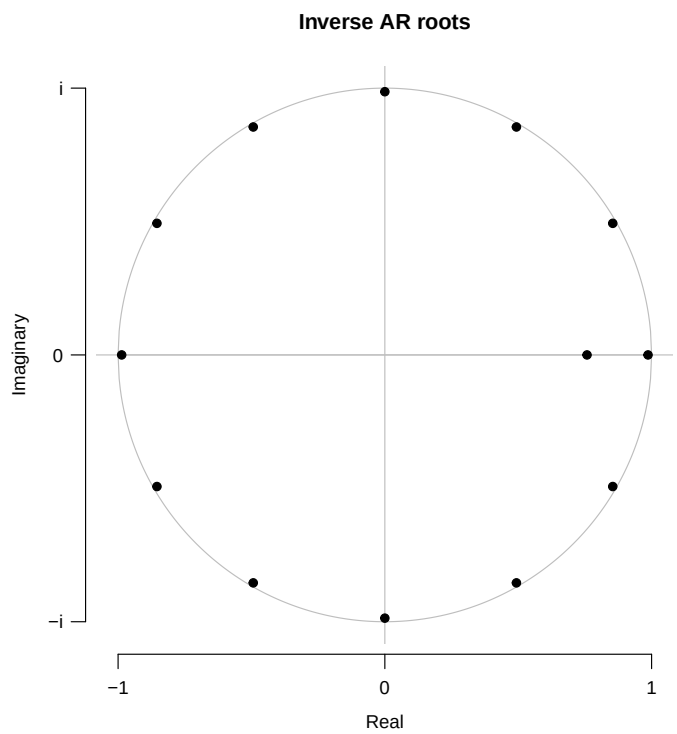


Figura: Raíces Inversas

Modelos Estacionarios

Modelo ARMA Estacional

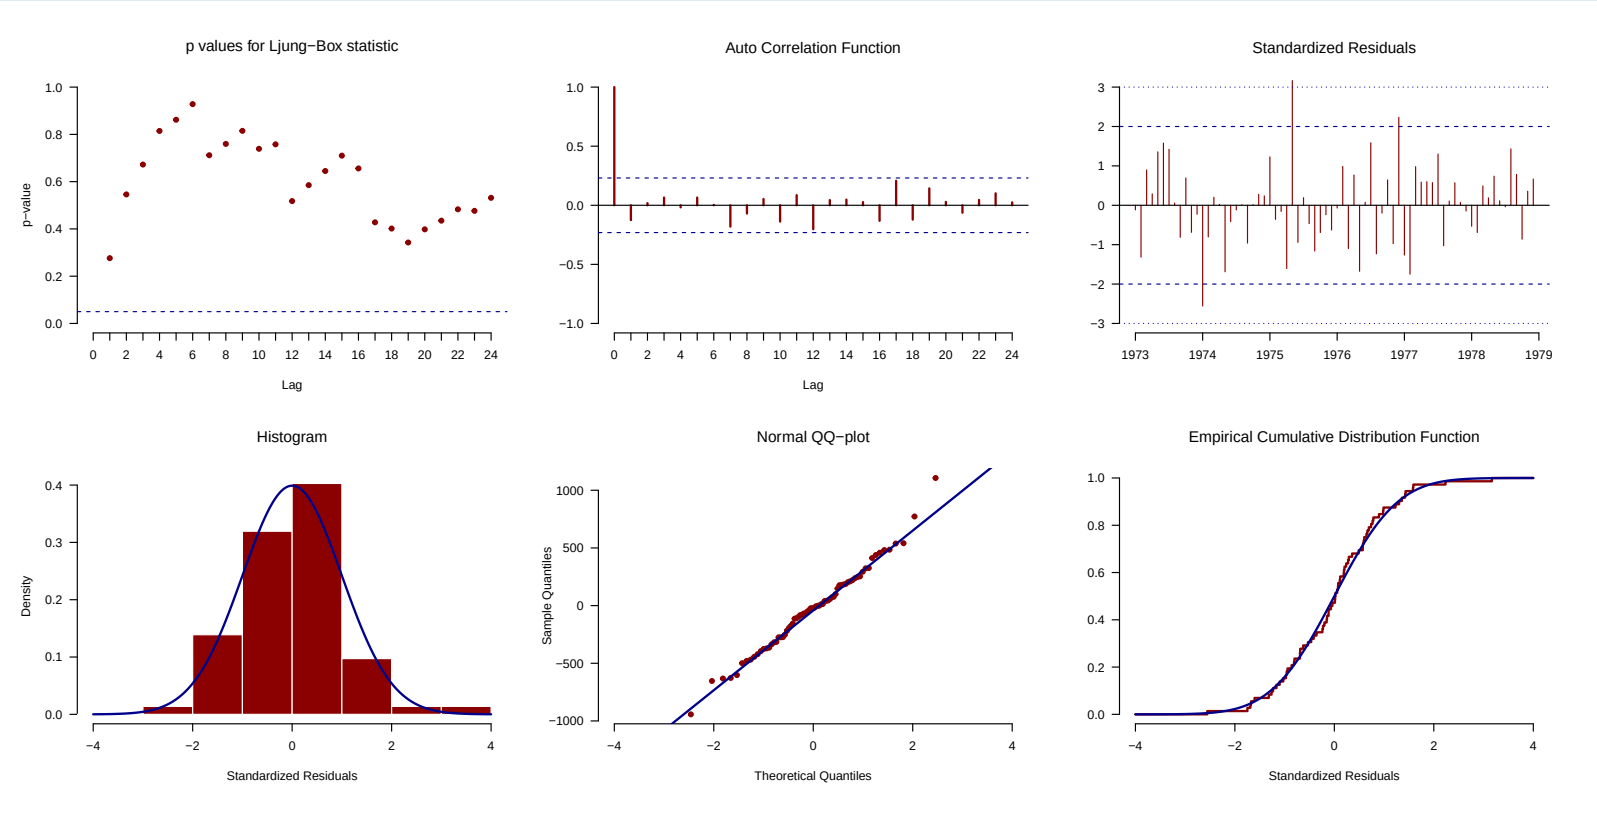


Figura: Diagnóstico de Residuos

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Modelos Estacionarios

Modelo ARMA Estacional

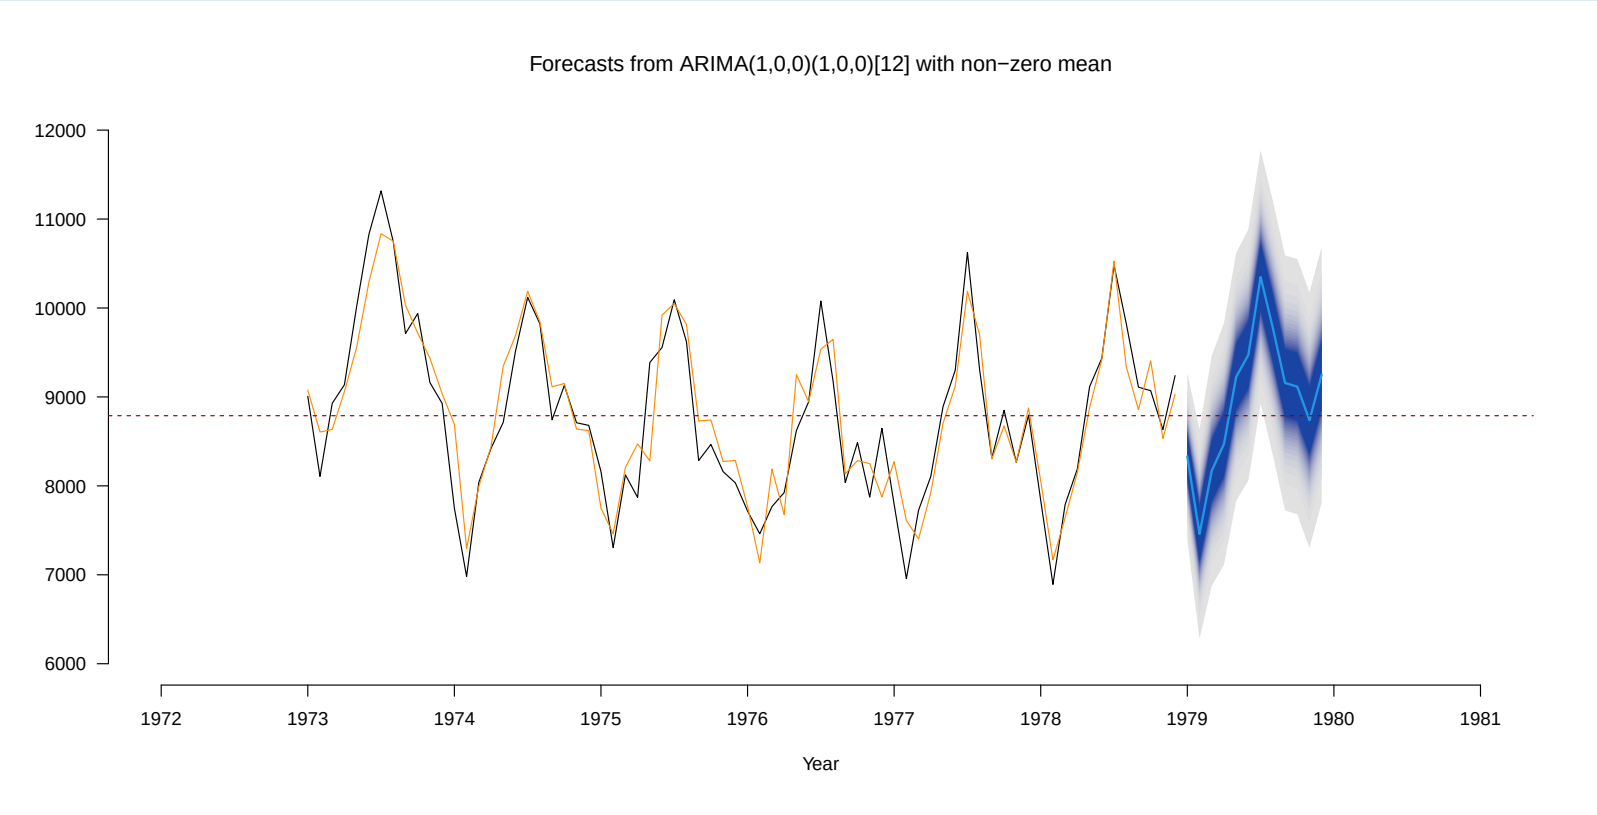


Figura: Ajuste y Predicción

Agenda de la Presentación

Agenda

Modelos ARIMA y SARIMA



Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

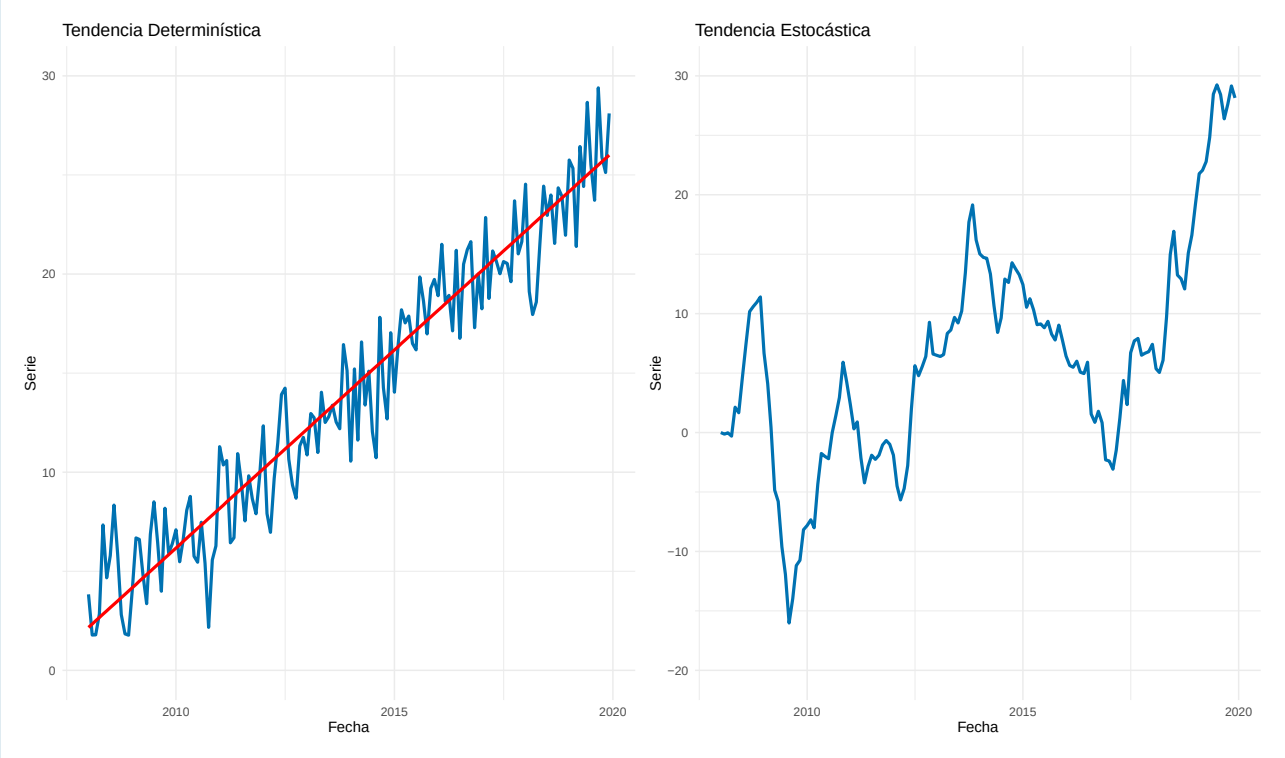
En la práctica la mayoría de las series de tiempo que se analizan no son estacionarias, entonces los modelos ARIMA (autoregressive integrated moving average) son una herramienta importante para modelar fenómenos que no son estacionarios.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

Distinguir entre tendencia determinística y tendencia estocástica:



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

- Tendencia determinística es cuando se está seguro la tendencia no puede variar. Aquí es mejor ajustar un polinomio a la tendencia y proponer un modelo ARMA para los errores.

- Tendencia estocástica se refiere a que la tendencia del proceso puede ir cambiando a través del tiempo.

Para trabajar con estos fenómenos es conveniente utilizar el backward shift para diferenciar la serie de tiempo:

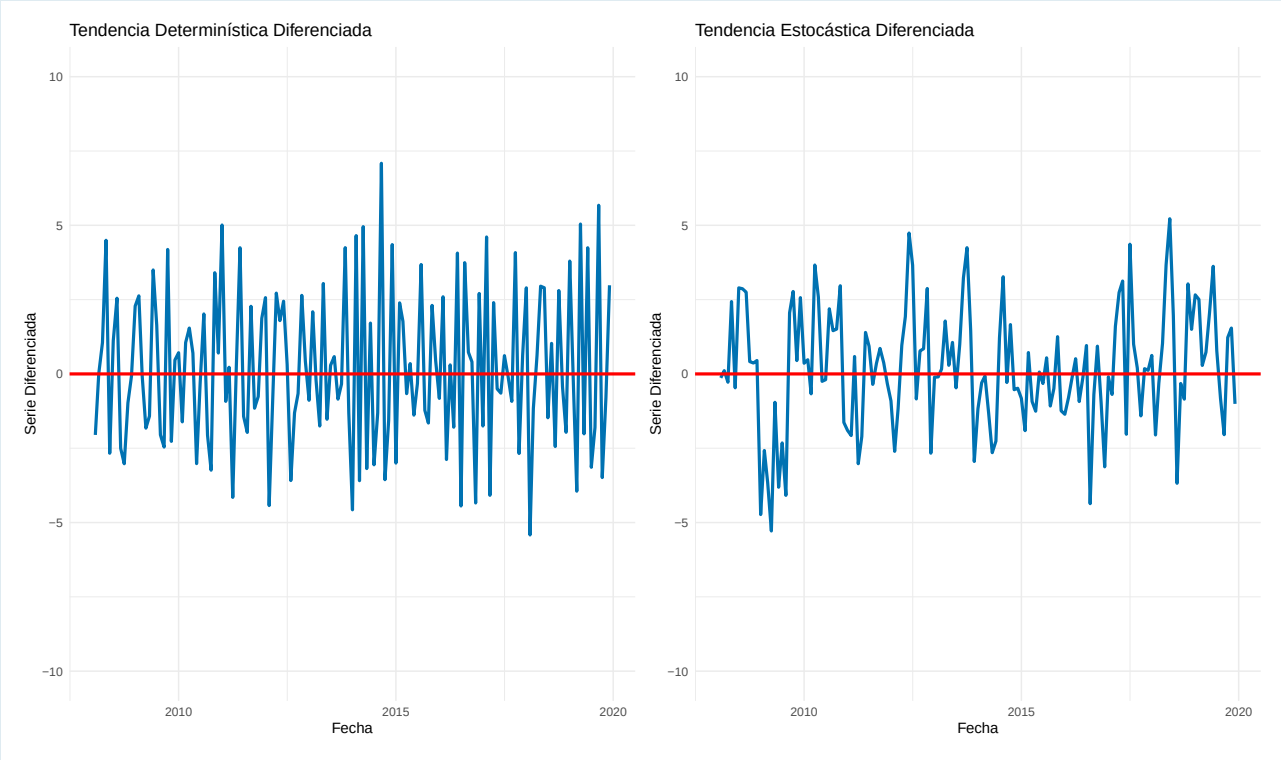
$$\nabla Y_t = Y_t - Y_{t-1} = (1 - B)Y_t, \qquad BY_t = Y_{t-1}.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

Las series diferenciadas pueden ser trabajadas por los modelos AR-MA:



Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

Los modelos ARIMA son aquellos que al diferenciar se transforman en modelos ARMA, útiles cuando el fenómeno presenta tendencia. La notación general ARIMA(p, d, q) donde:

$$(1 - \phi_1 B - \cdots - \phi_p B^p)(1 - B)^d (Y_t - \mu) = (1 - \theta_1 B - \cdots \theta_q B^q)\varepsilon_t$$

donde p es el orden de la parte autorregresiva, q es el orden de la parte de medias móviles y d es la cantidad de veces que debe ser diferenciado el proceso para ser estacionario.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

- $Y_t \sim$ ARIMA$(0,1,0)$: Caminata Aleatoria

$$Y_t = Y_{t-1} + \varepsilon_t$$

- $Y_t \sim$ ARIMA(1,1,0):

$$(1 - \phi B)(1 - B)Y_t = \varepsilon_t$$

- $Y_t \sim$ ARIMA(0,1,1):

$$Y_t = Y_{t-1} + \varepsilon_t - \theta\varepsilon_{t-1}$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

- En la práctica no se debería diferencia más de una vez la serie de tiempo, en algunos casos extremos 2 veces.
- Diferenciar una tendencia determinística puede aumentar su varianza, igual es preferible ajustar la media por un polinomio a través del tiempo.
- En muchas ocasiones no es fácil distinguir la presencia de tendencia estocástica

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Test de Raíces Unitarias

Estos test estadísticos son una herramienta para determinar si el proceso presenta tendencia. Existen 2 versiones muy utilizadas en la literatura para evaluar la presencia de tendencia, estos son:

- Test Dickey-Fuller Clásico.
- Test Dickey-Fuller Aumentado.

Ambos test se pueden realizar utilizando la función `adf.test()` de la librería `tseries`.

El test en un principio se deduce de pensar que el proceso Y_t es o no una caminata aleatoria

$$Y_t = \phi Y_{t-1} + \varepsilon_t,$$

donde ε_t es ruido blanco $(0, \sigma^2)$, el test evalúa las hipótesis $H_0 : \phi = 1$ vs $H_1 : \phi < 1$ utilizando el estimador de ϕ y la desviación del estimador.

La versión aumentada y general del test utiliza el modelo

$$Y_t = T_t + \phi Y_{t-1} + \phi_1 \nabla Y_{t-1} + \cdots + \phi_p \nabla Y_{t-p} + \varepsilon_t,$$

donde

- $T_t = \beta_0 + \beta_1 t$ es una tendencia determinística.
- $\nabla Y_{t-k} = Y_{t-k} - Y_{t-k-1}$

Las hipótesis que se evalúan son $H_0 : \phi = 1$ vs $H_1 : \phi \neq 1$.

La versión puede ser modificada y trabajar con las diferencias:

$$\nabla Y_t = T_t + \gamma Y_{t-1} + \phi_1 \nabla Y_{t-1} + \cdots + \phi_p \nabla Y_{t-p} + \varepsilon_t,$$

Con esa modificación se evalúa las siguientes hipótesis $H_0 : \gamma = 0$ vs $H_1 : \gamma \neq 0$.

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

- La función `adf.test()` de la librería `tseries` no considera como opción modificar la tendencia T_t.

- Hay dos versión más flexibles: La librería `urca`, la función `ur.df()` permite realizar el test DF aumentado (sólo intercepto o tendencia). La librería `fUnitRoots` dispone de la función `adfTest()`.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

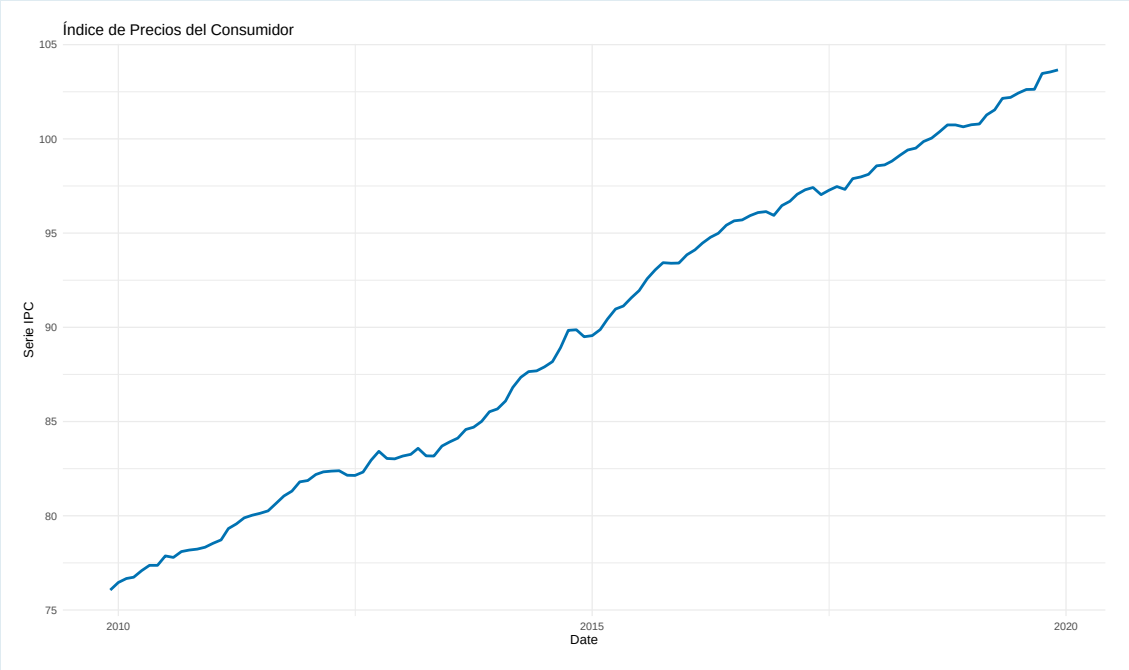
Contenidos: Series de Tiempo no Estacionarias

Ejemplo: En el archivo `'serie-histórica-empalmada-ipc.xlsx'` se encuentra la serie histórica del IPC desde diciembre del año 2009 hasta la fecha.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

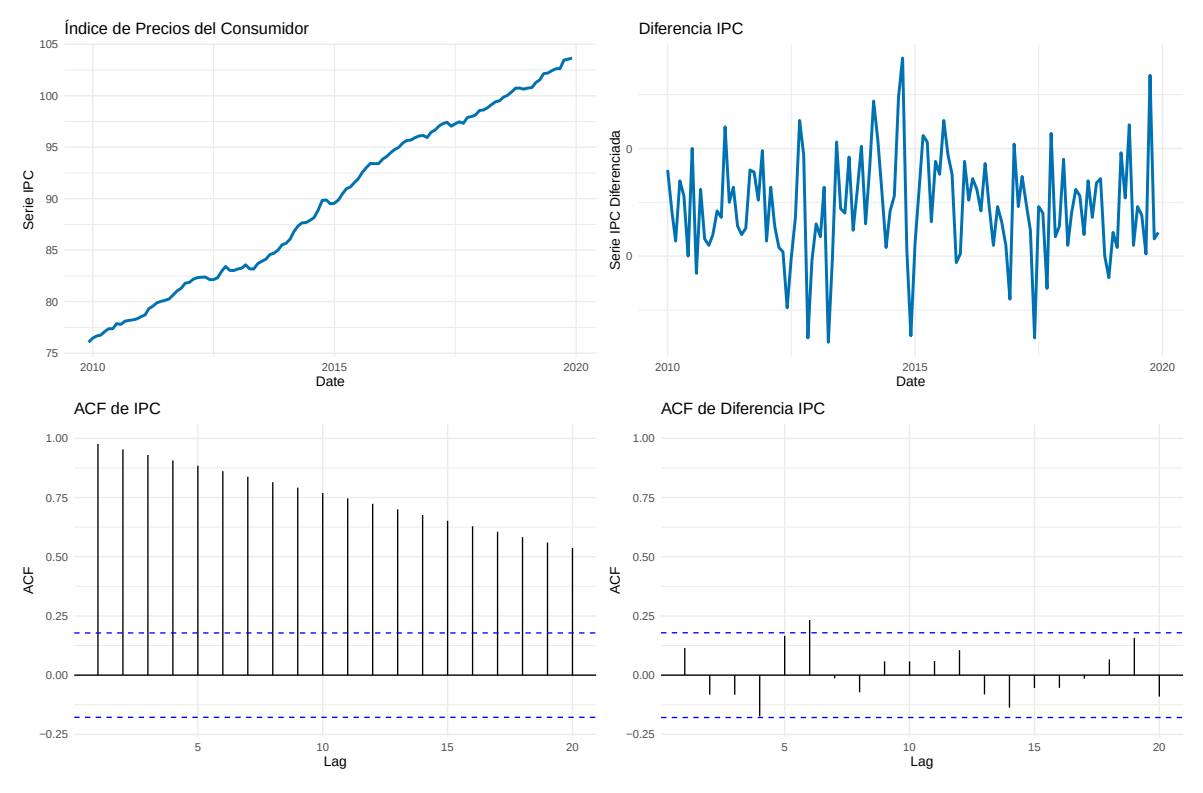
Contenidos: Series de Tiempo no Estacionarias



Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

Comparación de IPC_t vs $\nabla\text{IPC}_t = \text{IPC}_t - \text{IPC}_{t-1}$:



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

```
> ### librería fUnitRoots
>
> adfTest(baseipc$Indice, type ="c")

Title:
 Augmented Dickey-Fuller Test

Test Results:
  PARAMETER:
    Lag Order: 1
  STATISTIC:
    Dickey-Fuller: 0.0711
  P VALUE:
    0.9599
```

```
> m1 = ar(baseipc$DiffIpc[-1],method = "mle")
> m1$order
[1] 6
> adfTest(baseipc$Indice, type ="c", lags=6)

Title:
 Augmented Dickey-Fuller Test

Test Results:
  PARAMETER:
    Lag Order: 6
  STATISTIC:
    Dickey-Fuller: -0.0972
  P VALUE:
    0.9438
```

Existe evidencia empírica que indica presencia de tendencia.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

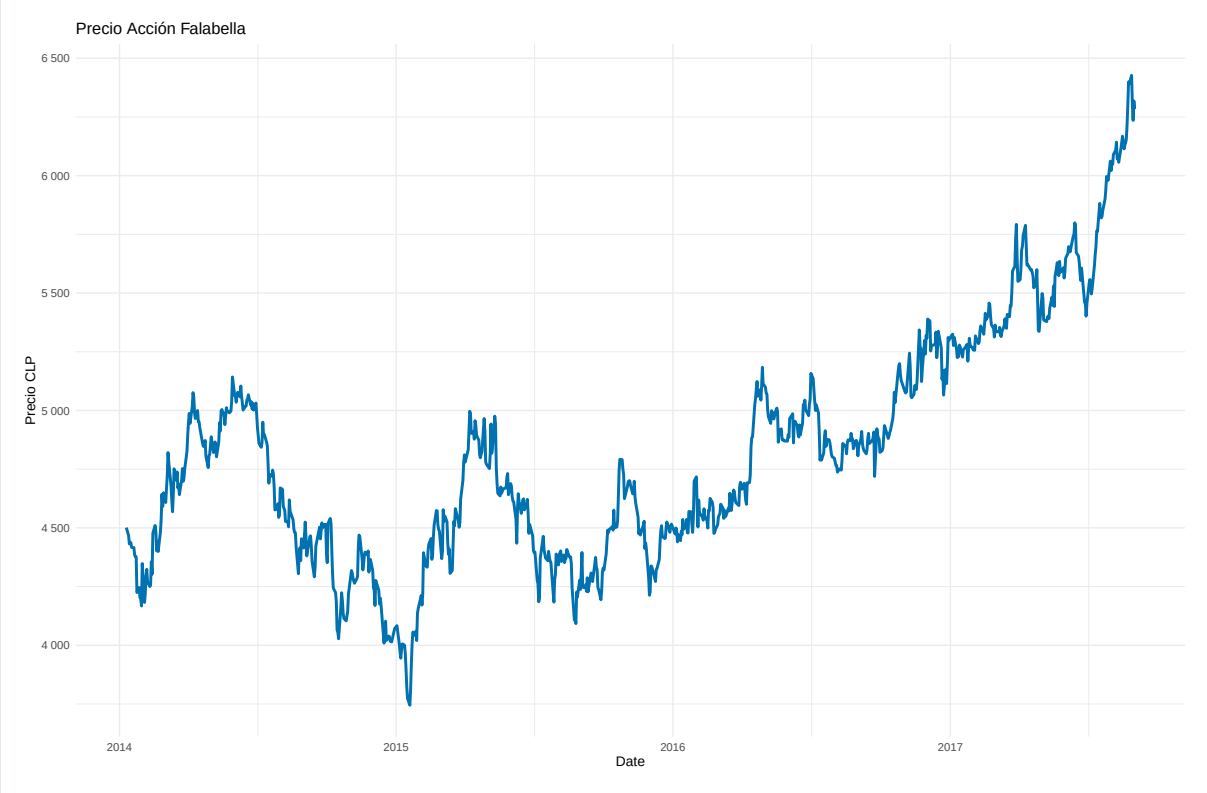
Contenidos: Series de Tiempo no Estacionarias

Ejemplo: En el archivo `'Historico_Falabella.csv'` se encuentra la serie histórica del precio de cierre de las acciones de Falabella desde Enero del 2014 hasta Enero del 2020. Para esta ilustración se utilizarán los datos informados hasta Septiembre 2017.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias



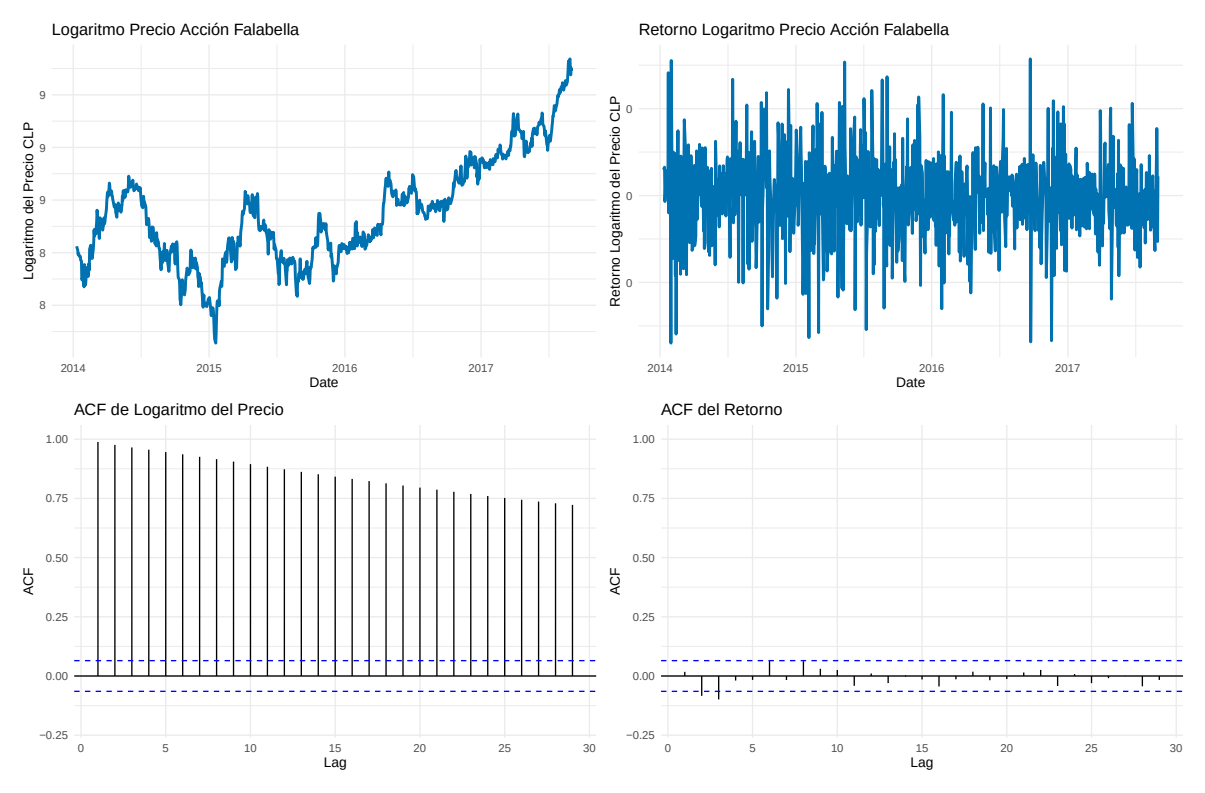
Los precios serán trabajados en escala logaritmo natural.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

Aquí las series $\log(P_t)$ vs $\log(P_t) - \log(P_{t-1})$



Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

- Parece que al diferencia la serie se quita la tendencia y se obtiene un ruido blanco.
- En Econometría financiera es normal trabajar con $\log(P_t) - \log(P_{t-1})$, ya que es muy difícil modelar las series de precios originales.
- La serie $\log(P_t) - \log(P_{t-1}) \approx \frac{P_t - P_{t-1}}{P_t}$.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

```
> adfTest(SerieLog, type ="c", lags = 3)

Title:
 Augmented Dickey-Fuller Test

Test Results:
  PARAMETER:
    Lag Order: 3
  STATISTIC:
    Dickey-Fuller: -0.4659
  P VALUE:
    0.8866
```

```
> m1 = ar(SerieRet,method = "mle")
> m1$order
[1] 3
> adfTest(SerieLog, type ="nc", lags=3)

Title:
 Augmented Dickey-Fuller Test

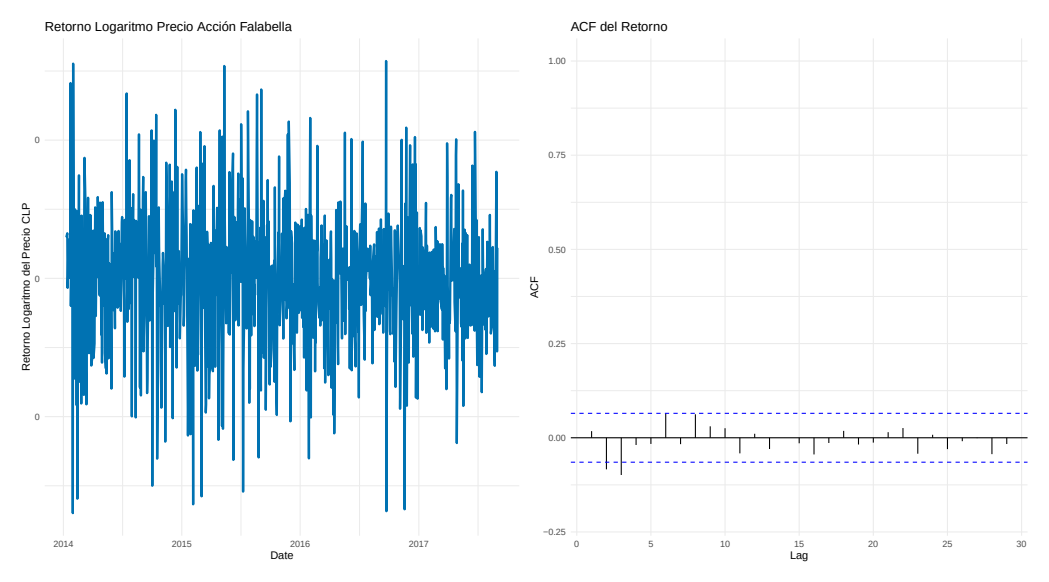
Test Results:
  PARAMETER:
    Lag Order: 3
  STATISTIC:
    Dickey-Fuller: 1.1053
  P VALUE:
    0.9276
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

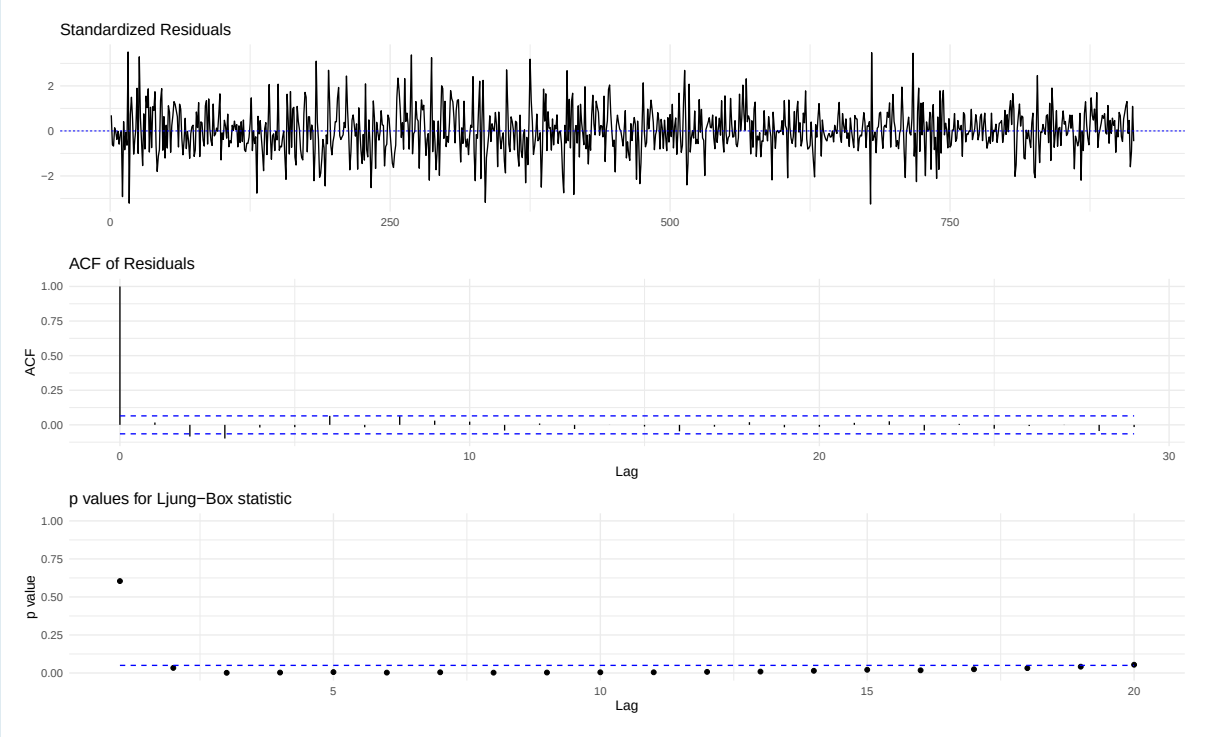
Hay presencia de tendencia, pero al diferenciar la serie parece ser ruido blanco. Sin embargo, se puede realizar un test de Ruido Blanco y verificar si esto es verdad



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

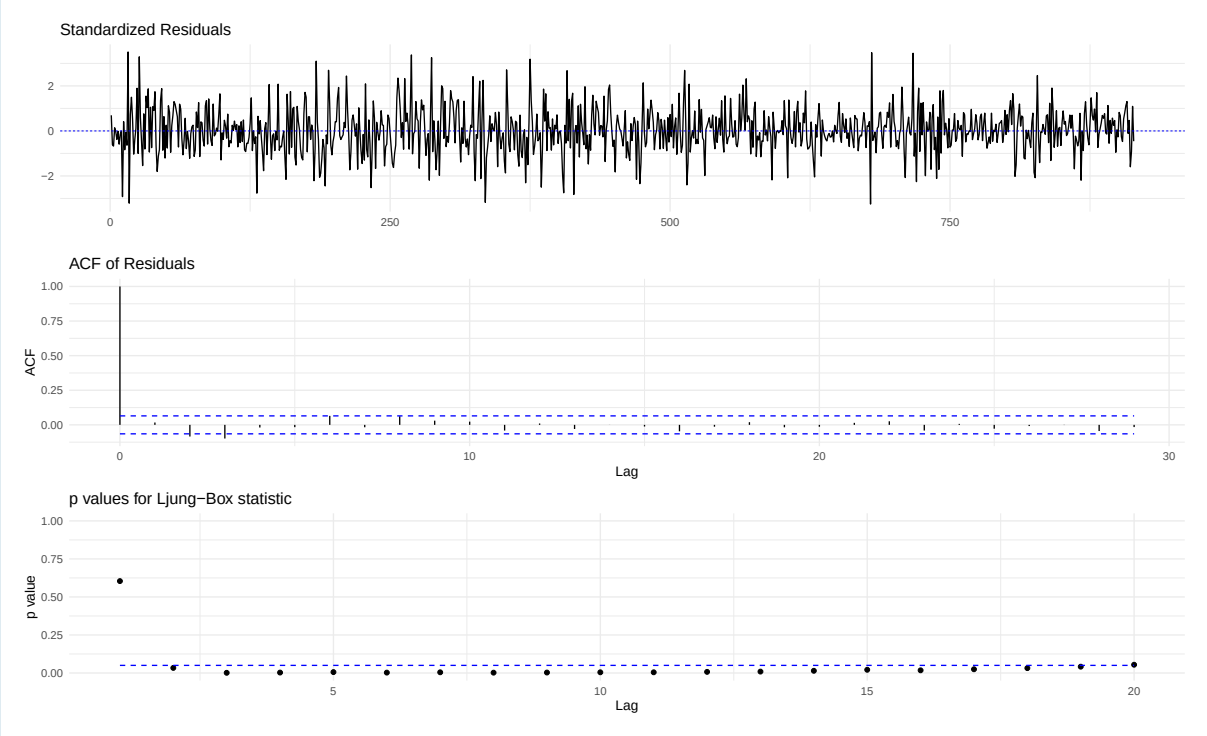
Contenidos: Series de Tiempo no Estacionarias



DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias



No es Ruido Blanco

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

Se podría ajustar un modelo MA(3) para remover la correlación:

```
> modelo0 = arma(SerieRet, order = c(0,3))
> summary(modelo0)

arma(x = SerieRet, order = c(0, 3))

ARMA(0,3)

Coefficient(s):
            Estimate  Std. Error  t value Pr(>|t|)
ma1        0.0079168   0.0329796    0.240  0.81029
ma2       -0.0885166   0.0329010   -2.690  0.00714 **
ma3       -0.0893046   0.0304729   -2.931  0.00338 **
intercept -0.0003832   0.0003300   -1.161  0.24548
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Fit:
sigma^2 estimated as 0.0001443
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

Utilizando la opción `fixed` se puede forzar los valores de los parámetros:

```
> modelo1 = Arima(SerieRet, order = c(0,0,3),
+                   include.mean = FALSE,
+                   fixed   = c(0,NA,NA))
> modelo1
Series: SerieRet
ARIMA(0,0,3) with zero mean

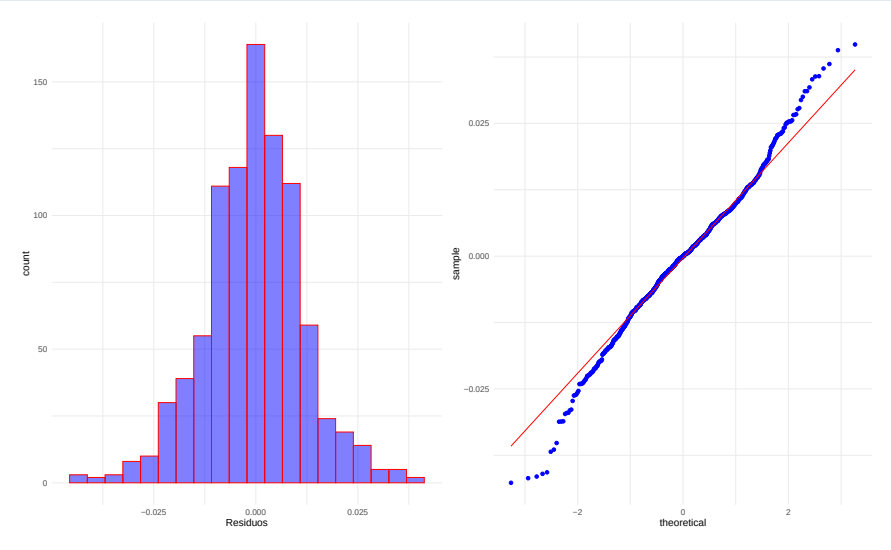
Coefficients:
      ma1      ma2      ma3
        0  -0.0863  -0.0863
s.e.    0   0.0328   0.0303

sigma^2 = 0.0001443:  log likelihood = 2742.55
AIC=-5479.11   AICc=-5479.08   BIC=-5464.66
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias




```
> media = mean(Residuos)
> desv  = sd(Residuos)
> ks.test(Residuos, "pnorm",media,desv)

        One-sample Kolmogorov-Smirnov t

data:  Residuos
D = 0.041757, p-value = 0.08284
alternative hypothesis: two-sided
```

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos: Series de Tiempo no Estacionarias

El modelo ajustado es de la forma:

$$\log\left(\frac{P_t}{P_{t-1}}\right) = \varepsilon_t + 0.086\varepsilon_{t-2} + 0.086\varepsilon_{t-3}.$$

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Análisis de Series de Tiempo

Contenidos

Espacio para consultas o dudas sobre extensiones



Gracias por su atención

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Bibliografía

Profundizar contenidos

- *Econometría*. Damodar N. Gujarati, Dawn C. Porter. S.A. Quinta edición, McGraw-Hill(2010).
- *Introduction to Time Series and Forecasting*. Peter J. Brockwell, Richard A. Davis. 3rd edition Springer (2016).


DATA
SCIENCE UC
FACULTAD DE MATEMÁTICAS