Preparación para Machine Learning: variables, datos y validación

Sesión 30 — Apunte de estudio

Esta sesión cierra el bloque de fundamentos estadísticos del Diplomado y prepara el terreno para Machine Learning. Todo lo que han trabajado hasta ahora —metodología, código, estadística descriptiva, regresión e inferencia— converge en una pregunta práctica: **¿cómo preparamos los datos para que un modelo pueda aprender de ellos de forma confiable?**

Este apunte desarrolla los conceptos que revisamos en clase y recupera las actividades para que se puedan repasar después de la sesión con más calma.

1. El ciclo de análisis exploratorio de datos (EDA)

El análisis exploratorio de datos no es un paso que hacemos una sola vez y dejamos atrás: es un ciclo. Lo repetimos tantas veces como sea necesario hasta entender suficientemente bien los datos antes de modelar.

- **Genera preguntas.** Antes de tocar una sola celda del dataset, nos preguntamos qué esperamos encontrar: ¿cuántas categorías debería tener esta variable?, ¿en qué rango deberían estar los valores?, ¿qué relación esperamos entre dos columnas? Estas preguntas orientan la exploración y evitan revisar datos sin un propósito claro.
- **Busca respuestas.** Usamos estadísticos descriptivos, gráficos de distribución, tablas de frecuencia y cruces simples para responder esas preguntas. En esta etapa aparecen datos faltantes, valores atípicos e inconsistencias entre variables.
- **Refina y repite.** Cada respuesta puede abrir una pregunta nueva. Si encontramos un valor atípico, por ejemplo, debemos preguntarnos si es un error de registro o un caso real y poco frecuente. El ciclo continúa hasta que contamos con suficiente evidencia para decidir cómo tratar los datos.

Qué hacer cuando falta un dato

La decisión de cómo ***imputar (completar)*** un dato faltante depende del tipo de variable, su distribución y de la información disponible en otras variables. La siguiente tabla resume las estrategias simples que usamos en clase.

Situación	Estrategia	Por qué
Variable numérica con distribución aproximadamente normal, sin atípicos	Imputar con la media	La media representa bien el centro cuando la distribución es simétrica y no existen valores extremos que la distorsionen.
Variable numérica con valores atípicos	Imputar con la mediana	La mediana es más robusta frente a valores extremos que podrían arrastrar la media hacia arriba o hacia abajo.
Variable categórica	Imputar con la moda	La media y la mediana no tienen sentido para categorías. La moda es una estrategia simple y habitual cuando necesitamos completar con la categoría más frecuente.

Situación	Estrategia	Por qué
Variable relacionada con otras columnas del dataset	Imputar con un modelo de regresión	Si el valor faltante puede predecirse razonablemente bien a partir de otras variables, podemos aprovechar esa relación en lugar de usar un único estadístico fijo.

Actividad de clase — Bloque A

Piensen qué estrategia de imputación usarían en cada caso: media, mediana, moda o regresión.

1. Tienen una columna con la edad de los clientes. Su distribución es aproximadamente normal y no hay valores atípicos. ¿Qué usarían para completar los datos faltantes?

2. Tienen una columna con el ingreso del hogar. Hay personas con ingresos muy por encima del resto. ¿Qué usarían?

3. Tienen una columna categórica con el país de origen del cliente. ¿Qué usarían?

4. Tienen una columna con el gasto mensual, que está fuertemente relacionado con el número de compras del cliente. ¿Qué usarían?

> **Respuesta**
>
> **1. Media.** La edad tiene una distribución aproximadamente normal y no presenta valores atípicos.
>
> **2. Mediana.** Los ingresos presentan valores extremos y la mediana es menos sensible a ellos.
>
> **3. Moda.** Es una variable categórica, por lo que usamos la categoría más frecuente como estrategia simple de imputación.
>
> **4. Regresión.** Podemos usar el número de compras como predictor si existe una relación suficientemente fuerte con el gasto mensual.

2. Las cuatro dimensiones de calidad de datos

Un dataset puede estar completo y aun así contener información poco confiable. Del mismo modo, puede tener algunos datos faltantes y ser útil en el resto de sus registros. Por eso conviene mirar la calidad desde distintas dimensiones, no como una sola propiedad.

Dimensión	Pregunta que responde	Ejemplo de falla
Exactitud	¿El dato refleja la realidad?	Un sensor mal calibrado registra 45 °C cuando la temperatura real es 22 °C.
Completitud	¿Falta información?	Un 20% de los productos de un catálogo no tiene categoría asignada.
Coherencia	¿Las distintas fuentes concuerdan entre sí?	El sistema de RR.HH. y el sistema de nómina muestran sueldos distintos para el mismo empleado.
Frescura	¿El dato sigue vigente?	La ficha clínica de un paciente no se actualiza hace ocho meses, aunque su tratamiento cambió en ese periodo.

Estas dimensiones no son mutuamente excluyentes: un mismo conjunto de datos puede presentar problemas en más de una dimensión. El objetivo es diagnosticar qué está fallando antes de decidir cómo intervenir los datos.

Actividad de clase — Bloque B

Identifiquen qué dimensión —exactitud, completitud, coherencia o frescura— está fallando en cada caso.

1. RR.HH.: el sistema de recursos humanos y el sistema de nómina muestran un sueldo distinto para el mismo empleado.
2. Retail: a un 20% de los productos del catálogo le falta la categoría asignada.
3. Mantenimiento: los sensores de una planta reportan temperaturas fuera de todo rango físicamente posible.
4. Salud: la ficha de un paciente no se ha actualizado en los últimos ocho meses, aunque su tratamiento cambió en ese tiempo.

> **Respuesta**
>
> 1. **Coherencia.** Las dos fuentes no concuerdan entre sí.
> 2. **Completitud.** Falta información en una parte del catálogo.
> 3. **Exactitud.** El dato no representa una realidad físicamente posible.
> 4. **Frescura.** La información ya no refleja el estado actual del paciente.

3. División de datos: por qué el conjunto de prueba debe mantenerse separado

Un modelo aprende a partir de datos históricos, pero después debe enfrentarse a datos que no vio durante su desarrollo. Si evaluamos el modelo con los mismos datos con los que aprendió, podemos obtener una impresión demasiado optimista de su desempeño: el modelo puede haber memorizado particularidades del entrenamiento en lugar de aprender un patrón que generalice.

El ejemplo del COVID que usamos en clase ayuda a entender esta idea: un modelo entrenado con datos de 2019 podía funcionar bien mientras el contexto se parecía a 2019. Cuando la pandemia cambió de forma abrupta patrones de consumo, empleo y movilidad, muchas relaciones históricas dejaron de representar bien la realidad. El punto no es que el conjunto de prueba “prediga el futuro”, sino que nos permite evaluar el modelo con datos que quedaron fuera de su aprendizaje.

Una forma habitual de organizar los datos es dividirlos en entrenamiento, validación y prueba. Las proporciones dependen del tamaño y la naturaleza del problema; 70% - 15% - 15% es solo una referencia frecuente, no una regla universal.

Conjunto	Proporción de referencia	Para qué se usa
Entrenamiento	70%	El modelo aprende sus parámetros a partir de estos datos.
Validación	15%	Se usa durante el desarrollo para comparar configuraciones, ajustar hiperparámetros y elegir alternativas sin tocar el conjunto de prueba.
Prueba (test)	15%	Se reserva para una evaluación final e independiente con datos que no se utilizaron para entrenar ni ajustar el modelo.

Decimos que el conjunto de prueba es "sagrado" porque debe mantenerse fuera de las decisiones de desarrollo. Si lo consultamos repetidamente para ajustar hiperparámetros, probar variantes o decidir entre modelos, deja de ser una medición independiente. El resultado puede parecer mejor de lo que realmente será con datos nuevos. A esta ***filtración de información*** hacia el proceso de desarrollo la llamamos ***Data Leakage.***

4. Estrategias de muestreo

Cómo dividimos el dataset tampoco es un detalle menor. La estrategia de muestreo debe responder a la estructura de los datos y al problema que queremos resolver.

- **Muestreo aleatorio simple.** Cada observación tiene la misma probabilidad de quedar en entrenamiento, validación o prueba. Es una opción razonable cuando no existe una estructura temporal importante ni clases muy desbalanceadas que debamos preservar.
- **Muestreo estratificado.** Cuando las clases están desbalanceadas —por ejemplo, 95% de casos normales y 5% de fraude— preservamos aproximadamente esa proporción en cada conjunto. Así evitamos que la clase minoritaria quede subrepresentada, especialmente en validación o prueba.
- **Muestreo consciente del tiempo.** Cuando existe una componente temporal, dividir al azar puede introducir información del futuro en el entrenamiento. En esos casos, respetamos el orden cronológico: entrenamos con periodos anteriores y validamos o probamos con periodos posteriores.

5. Repaso: regularización y métricas de desempeño

Regularización — Lasso vs. Ridge

Regularizar significa agregar una penalización que limita la complejidad del modelo. La idea es evitar que el modelo dé demasiado peso a particularidades del conjunto de entrenamiento y favorecer soluciones que generalicen mejor.

- **Lasso (L1).** Puede llevar algunos coeficientes exactamente a cero. En la práctica, esto hace que ciertas variables dejen de participar en el modelo, por lo que resulta útil cuando sospechamos que varias variables aportan poco o agregan ruido.

- **Ridge (L2).** Reduce la magnitud de los coeficientes, pero normalmente no los lleva a cero. Ayuda a estabilizar el modelo cuando muchas variables aportan información y queremos evitar pesos excesivos.

Por qué Accuracy, por sí solo, puede engañar

Accuracy mide la proporción total de predicciones correctas. El problema aparece cuando las clases están muy desbalanceadas. Si el 95% de los casos corresponde a "no fraude", un modelo que siempre predice "no fraude" obtiene 95% de Accuracy sin detectar ningún fraude real. Por eso necesitamos mirar métricas que nos cuenten qué está pasando con la clase que realmente nos interesa.

Métrica	Qué nos ayuda a responder
Precision	De todo lo que el modelo marcó como positivo, ¿qué proporción realmente era positiva?
Recall	De todos los casos positivos reales, ¿qué proporción logró detectar el modelo?
F1-Score	¿Cómo equilibramos Precision y Recall cuando ambas importan y no queremos mejorar una a costa de deteriorar demasiado la otra?

6. La demo de código: qué mostró la caída de desempeño

La demostración en vivo comparó el desempeño del mismo modelo en dos conjuntos: obtuvo 98% de acierto sobre los datos de entrenamiento y 61% sobre datos nuevos que no había visto. Esa brecha de 37 puntos porcentuales es una señal clara de ***sobreajuste (overfitting).***

El modelo rindió muy bien sobre los datos que conocía, pero parte de lo que aprendió correspondía a particularidades —incluido ruido— que no se repitieron en datos nuevos. Justamente por eso necesitamos un conjunto de prueba separado, estrategias de regularización y métricas que vayan más allá del Accuracy: nos ayudan a detectar estos problemas antes de llevar un modelo a producción.

7. Cierre: de reglas fijas a aprendizaje

A lo largo del diplomado hemos trabajado decisiones que el analista define explícitamente: cómo limpiar un dato, qué criterio usar para imputar, cómo dividir una muestra o qué métrica mirar. En los modelos de machine learning, una parte importante de las reglas de decisión deja de ser escrita de forma explícita por el analista y pasa a aprenderse a partir de los datos.

Eso no hace menos importante todo lo anterior. Al contrario: para aprender patrones útiles, un modelo necesita datos suficientemente limpios, confiables y bien organizados, además de una forma honesta de evaluar su desempeño. Esta sesión funciona como puente entre la preparación de los datos y los modelos que comenzaremos a trabajar a continuación.

Para pensar después de la clase

- ¿Qué variable de su trabajo es más difícil de medir bien?
- ¿Dónde confían más en los datos hoy que hace un año, y por qué?
- ¿Qué decisión se toma hoy en su trabajo con reglas fijas o con un modelo simple?

Pregunta puente hacia la Sesión 31: ¿Qué problema de su trabajo resuelven hoy con reglas fijas? En la próxima sesión lo volveremos a mirar desde la lógica del aprendizaje a partir de datos.