Caso de Estudio: Scoring de Crédito de Consumo

Preparación, Validación y Evaluación para Modelos Predictivos

Contexto Estratégico y de Negocio

Cuando desarrollamos una solución de Inteligencia Artificial para apoyar decisiones de negocio, la **preparación de los datos** es una de las etapas más importantes. Un buen modelo no depende solo del algoritmo que utilicemos: también depende, y mucho, de la calidad de los datos con los que aprende.

Esta idea está en el centro del enfoque **Data-Centric AI**, que pone el foco en revisar, limpiar y mejorar los datos antes de intentar aumentar la complejidad del modelo.

Si los datos tienen errores, valores faltantes, inconsistencias o sesgos, el modelo puede aprender patrones equivocados y entregar resultados poco confiables. En un contexto de negocio, esto puede traducirse en malas decisiones y costos para la organización.

Contexto del problema: Un banco chileno quiere desarrollar un modelo para estimar la probabilidad de que un cliente no pague un crédito de consumo (**default**).

Para ello cuenta con información histórica de **100.000 clientes** y **120 variables**, entre ellas datos demográficos, transacciones y comportamiento crediticio.

Sin embargo, antes de entrenar el modelo, el equipo debe resolver varios problemas en los datos: existen valores faltantes, diferencias entre la información registrada en canales físicos y digitales, un número muy alto de variables y un fuerte desbalance entre las clases, ya que solo el **2% de los clientes** presenta históricamente una situación de impago.

El desafío, entonces, consiste en asegurarse primero de que los datos sean adecuados para que el modelo pueda aprender de manera confiable.

Desafío 1: Calidad e Imputación de Datos Faltantes

Antes de entrenar el modelo, el equipo de Data Science debe revisar algunos problemas de calidad presentes en cuatro variables relevantes de la base de datos:

Variable	Tipo de Dato	Estado de la Variable en la Base de Datos
Ingreso Mensual	Numérico	Presenta un 8% de valores nulos. La distribución de los datos muestra un fuerte sesgo a la derecha debido a la presencia de un grupo pequeño de clientes de ingresos extremadamente altos (outliers).
Edad del Solicitante	Numérico	Presenta un 2% de valores faltantes. Su distribución es simétrica, asemejándose a una curva normal, y está libre de valores atípicos.
Comuna de Residencia	Categórico	Presenta un 5% de registros vacíos (valores nulos).
Monto Solicitado	Numérico	En el 12% de los registros, el valor registrado mediante la plataforma web no coincide con el del contrato de crédito físico firmado por el cliente ante notario.

Aplica lo aprendido con las siguientes preguntas.

Pregunta 1.1: Según los métodos de ***imputación de datos faltantes***, ¿qué técnica estadística —media, mediana o moda— debería utilizarse para completar los valores nulos de: a) Ingreso Mensual, b) Edad del Solicitante y c) Comuna de Residencia? Justifique su elección considerando el tipo de dato y la presencia de valores atípicos.

Respuesta
a) Ingreso Mensual: Mediana. La distribución está sesgada a la derecha y existen valores extremos, por lo que la media podría quedar arrastrada por los ingresos muy altos. La mediana es más robusta frente a estos casos.

b) Edad del Solicitante: Media. La variable presenta una distribución aproximadamente simétrica y sin valores atípicos, por lo que la media representa adecuadamente su centro.

c) Comuna de Residencia: Moda. Al tratarse de una variable categórica, corresponde utilizar la categoría que aparece con mayor frecuencia.

Pregunta 1.2: La variable *Monto Solicitado* presenta valores distintos según la fuente de información. ¿Qué dimensión de calidad de datos está fallando: **Exactitud, Completitud, Coherencia o Frescura**?

Explica cuál debería considerarse como ***Ground-truth (fuente de referencia)*** y qué podría ocurrir si esta diferencia no se corrige antes de entrenar el modelo.

Respuesta
La dimensión que está fallando es la ***Exactitud***, porque existen dos valores distintos para un mismo monto solicitado y uno de ellos no representa correctamente la transacción real.

En este caso, **el contrato físico firmado** debería considerarse como ***Ground-truth o fuente de referencia***, ya que corresponde al monto formalmente acordado. Si esta diferencia no se corrige antes de entrenar el modelo, este podría aprender a partir de información incorrecta y generar estimaciones de riesgo poco confiables.

Desafío 2: División de los Datos y Prevención de Data Leakage

El equipo de TI del banco propone una división simple de los datos: utilizar el **90% para entrenar el modelo** y dejar el **10% restante para evaluarlo**.

Sin embargo, el equipo de Riesgo plantea que no basta con separar los datos en dos grupos. Para desarrollar y evaluar un modelo de manera adecuada, es necesario trabajar con **tres conjuntos distintos: entrenamiento, validación y prueba**, donde cada uno cumple un propósito específico.

Aplica lo aprendido con las siguientes preguntas.

Pregunta 2.1: ¿Por qué es importante dividir los datos en **entrenamiento, validación y prueba**, en lugar de utilizar solo un conjunto para entrenar y otro para evaluar?

Explica qué función cumple cada uno de estos conjuntos durante el desarrollo del modelo.

Respuesta
Los tres conjuntos cumplen funciones diferentes y permiten separar el aprendizaje del modelo de su evaluación.

- **Entrenamiento:** se utiliza para que el modelo aprenda sus parámetros a partir de los datos.
- **Validación:** se utiliza durante el desarrollo para comparar alternativas, ajustar hiperparámetros y tomar decisiones sobre la configuración del modelo.
- **Prueba (test):** se reserva para la evaluación final con datos que el modelo no ha utilizado durante el entrenamiento ni el ajuste.

La proporción exacta puede variar según el problema y el volumen de datos. Lo importante es mantener estos roles separados para obtener una evaluación más confiable de la capacidad de generalización del modelo.

Pregunta 2.2: ¿Por qué el conjunto de **prueba (test)** debe mantenerse separado durante todo el proceso de entrenamiento y ajuste del modelo?

Explica qué entendemos por **Data Leakage** y qué podría ocurrir si utilizamos, directa o indirectamente, información del conjunto de prueba antes de la evaluación final.

Respuesta
El conjunto de prueba debe mantenerse separado porque su objetivo es simular una evaluación con datos realmente no vistos. Si utilizamos información del test para entrenar, seleccionar variables, ajustar hiperparámetros o tomar decisiones sobre el modelo, se produce **Data Leakage** o lo que es igual **Fuga de Datos**

Esto **puede hacer que el desempeño medido parezca mejor de lo que realmente será en producción**, porque el modelo o el proceso de desarrollo ya tuvo acceso, directa o indirectamente, a información que debía permanecer desconocida.

Desafío 3: Regularización y Métricas en Clases Desbalanceadas

El banco enfrenta ahora dos desafíos adicionales. Por una parte, el modelo trabaja con **120 variables**, y no todas aportan información útil: algunas pueden ser redundantes o agregar ruido. Por otra, existe un fuerte **desbalance entre las clases**, ya que solo el **2% de los clientes cae en impago**, mientras que el **98% restante no lo hace**.

Esto obliga al equipo a tomar decisiones no solo sobre cómo simplificar el modelo, sino también sobre **qué métricas utilizar para evaluar si realmente está cumpliendo el objetivo del negocio**.

Aplica lo aprendido con las siguientes preguntas.

Pregunta 3.1:

Si queremos simplificar el modelo y reducir el efecto de variables poco relevantes, ¿qué técnica sería más conveniente: **Lasso (L1)** o **Ridge (L2)**?

Explica qué ocurre con los coeficientes en cada caso y por qué una de estas alternativas puede ayudar a reducir el número de variables que finalmente utiliza el modelo.

Respuesta

La alternativa más conveniente es ***Lasso (L1).*** Esta regularización agrega una penalización basada en el valor absoluto de los coeficientes y puede llevar algunos de ellos exactamente a cero. En la práctica, esto permite que ciertas variables dejen de participar en el modelo y funciona como una forma de selección de variables.

Ridge (L2), en cambio, penaliza el cuadrado de los coeficientes y tiende a reducir su magnitud, pero normalmente no los lleva exactamente a cero. Por eso puede controlar la complejidad, pero no elimina variables de la misma manera que Lasso.

Pregunta 3.2:

Un analista presenta un modelo que predice que **ningún cliente caerá en default** y obtiene un **Accuracy del 98%**.

A primera vista, el resultado parece muy bueno. Sin embargo, ¿por qué esta métrica puede ser engañosa en un problema donde solo el 2% de los clientes cae en impago?

Explica qué información importante sobre el desempeño del modelo estamos perdiendo si miramos solamente el Accuracy.

Respuesta

El Accuracy del 98% es engañoso porque refleja principalmente la clase mayoritaria. Como el 98% de los clientes no cae en impago, un modelo que siempre prediga "no default" acertaría en el 98% de los casos sin detectar a ningún cliente riesgoso.

Por eso, mirar ***solo Accuracy oculta el desempeño sobre la clase que más interesa al negocio***: los clientes que efectivamente caerán en impago. En este tipo de problemas es necesario complementar el análisis con métricas que consideren específicamente la detección de la clase positiva, como Precision, Recall y, según el objetivo, F1-Score.

Pregunta 3.3:

Para el banco, un **Falso Negativo** ocurre cuando el modelo clasifica a un cliente como buen pagador, pero finalmente ese cliente cae en impago.

Si este tipo de error tiene un costo financiero importante, ¿qué métrica debería tener mayor relevancia: **Precision** o **Recall**?

Fundamenta tu respuesta considerando qué tipo de clientes le interesa detectar al banco y qué costo tiene no identificarlos a tiempo.

Respuesta

En este escenario debería darse mayor relevancia al ***Recall***. Esta métrica responde a la pregunta: de todos los clientes que realmente caerán en impago, ¿cuántos logró detectar el modelo?

Si el costo de un Falso Negativo es alto, interesa reducir los casos en que un cliente riesgoso es clasificado como buen pagador. Maximizar Recall ayuda a capturar una mayor proporción de estos clientes. Sin embargo, en una decisión real de negocio también debe observarse Precision, porque aumentar demasiado el Recall puede generar más Falsos Positivos y llevar a rechazar clientes que sí podrían pagar.