

Sesión 30: Preparación para Machine Learning: variables, datos y validación

Laura Sánchez Fernández

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

EL CAMINO DE LOS DATOS

Los modelos de IA son un reflejo de la calidad de sus datos.

1. Diagnóstico

- Calidad de Datos
- Imputación

2. Arquitectura

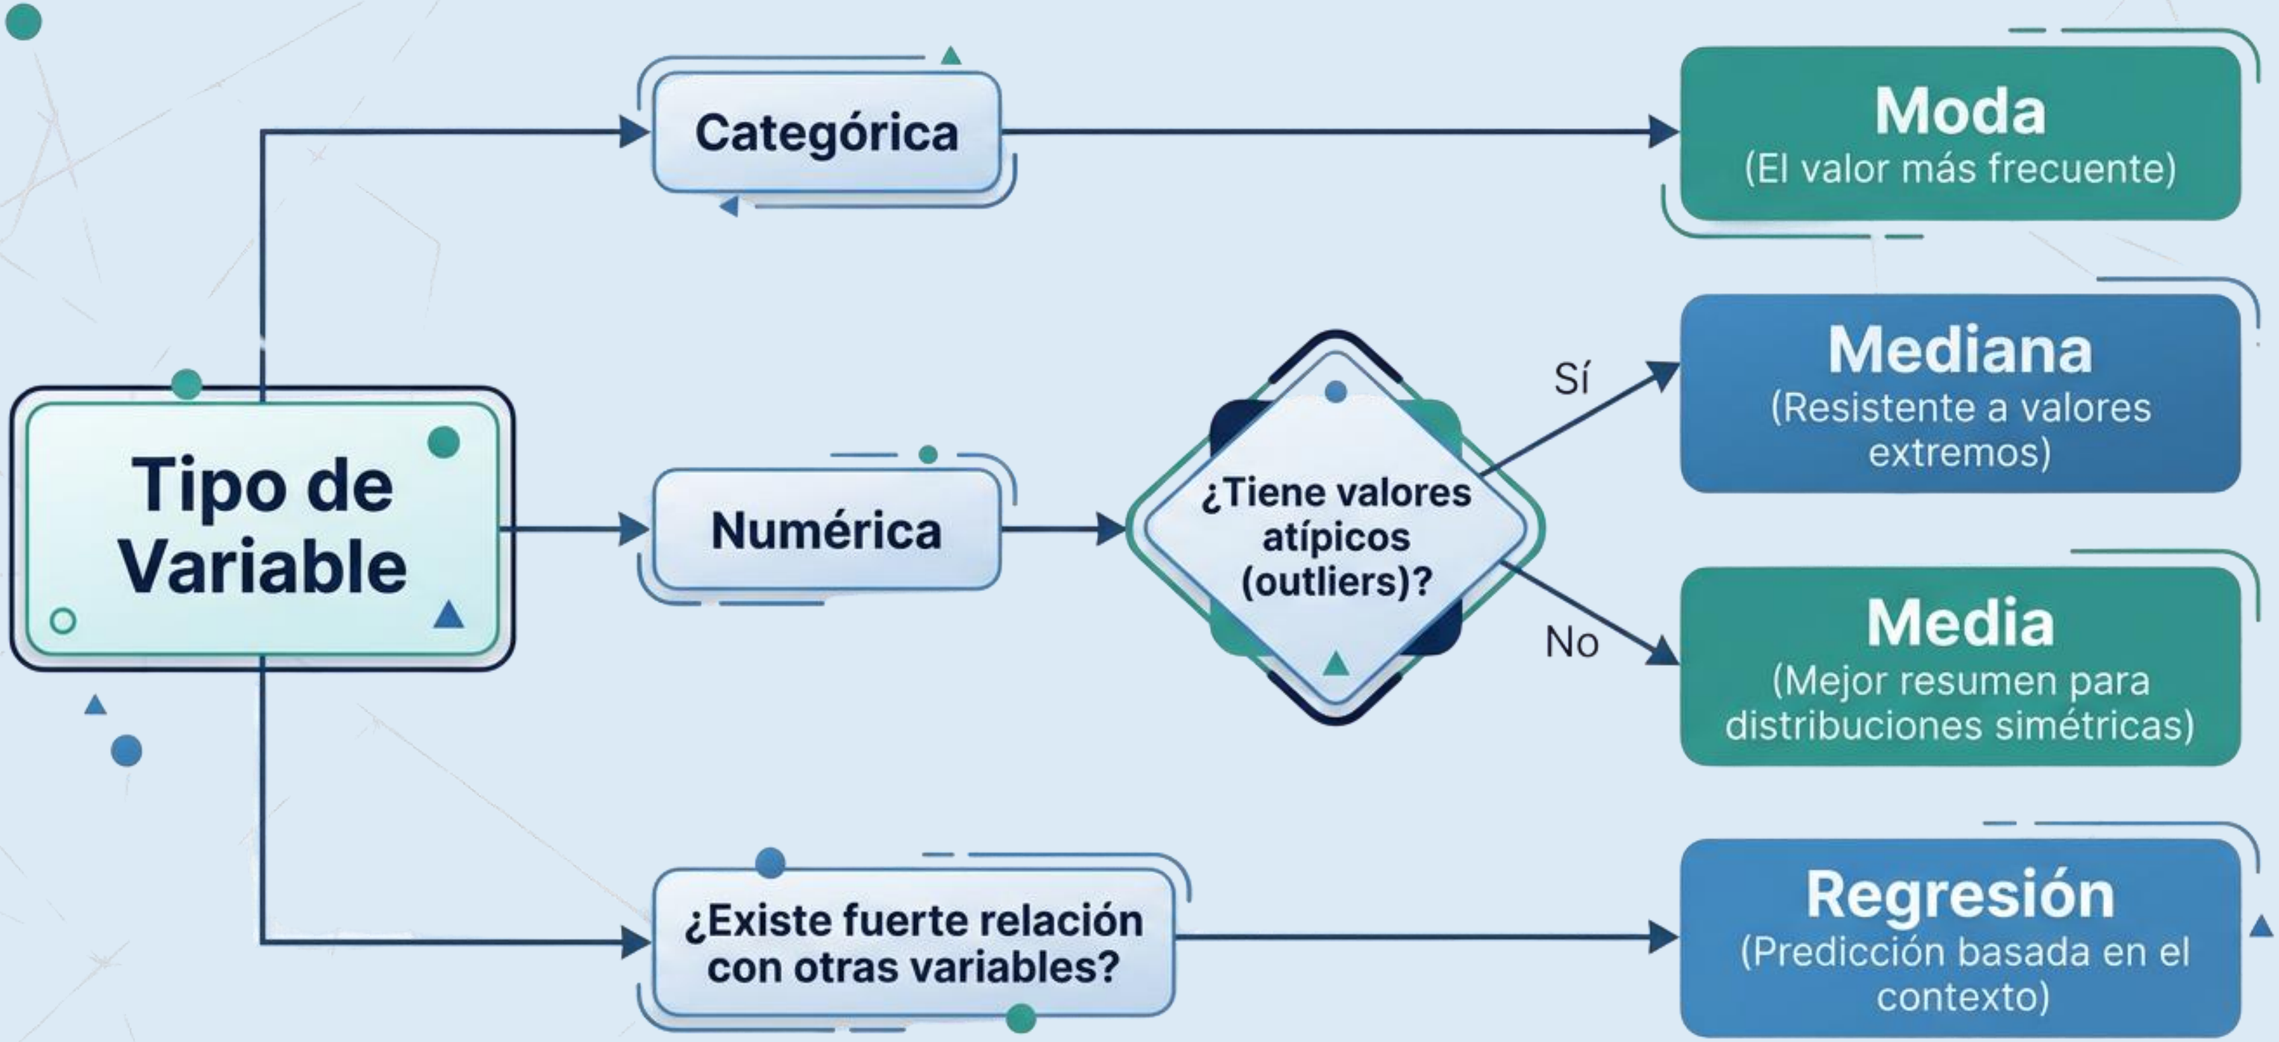
- División (Split)
- Muestreo

3. Defensa

- Métricas Avanzadas
- Regularización

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Imputación: Qué Hacer Cuando Falta un Dato



Diagnóstico Rápido: Estrategias de Imputación

Ejercicio práctico A: Aplicar la regla de decisión.

Edad de clientes, distribución normal, sin atípicos.	**Respuesta:** Media
Ingresos del hogar, con personas ganando muy por encima del resto.	**Respuesta:** Mediana
País de origen del cliente (categórica).	**Respuesta:** Moda
Gasto mensual, altamente correlacionado con el número de compras.	**Respuesta:** Regresión

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Las Cuatro Dimensiones de la Calidad



Exactitud (Accuracy)

¿El dato refleja la realidad?

Ejemplo: Un sensor reporta 45°C cuando la temperatura real es 22°C.



Completitud (Completeness)

¿Falta información vital?

Ejemplo: Al 20% de los productos del catálogo le falta su categoría.



Coherencia (Consistency)

¿Las fuentes concuerdan?

Ejemplo: Sistemas de RR.HH. y Nómina muestran sueldos distintos para la misma persona.



Frescura (Timeliness)

¿El dato sigue vigente?

Ejemplo: Ficha médica sin actualizar en 8 meses, mientras el tratamiento cambió.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Diagnóstico Rápido: Identificando Fallas

Ejercicio práctico B : Escriban en el chat el número del caso y la dimensión que falla.

Caso 1 (RR.HH.):

Sistemas muestran distinto sueldo para el mismo empleado.

Respuesta: Coherencia

Caso 2 (Retail):

Faltan categorías en el 20% del catálogo.

Respuesta: Completitud

Caso 3 (Mantenimiento):

Sensores reportan temperaturas físicamente imposibles.

Respuesta: Exactitud

Caso 4 (Salud):

Ficha no actualizada hace 8 meses tras cambio de tratamiento.

Respuesta: Frescura

La Arquitectura de la Confianza: División de Datos

Donde el modelo aprende sus parámetros.



El veredicto. Se usa una sola vez al final.

Donde ajustamos hiperparámetros y comparamos alternativas

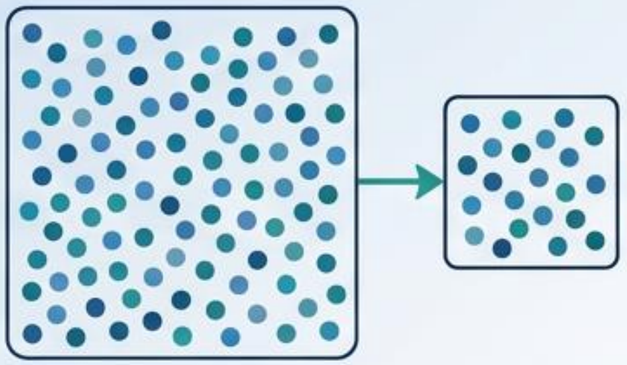
La Lección del COVID

Entrenar un modelo con datos de 2019 y evaluarlo con los mismos datos es engañoso.
Cuando el COVID alteró el consumo en 2020, los modelos colapsaron.
El conjunto de prueba simula ese futuro desconocido para evitar sorpresas.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Estrategias de Muestreo: Diseñando el Experimento

Aleatorio Simple



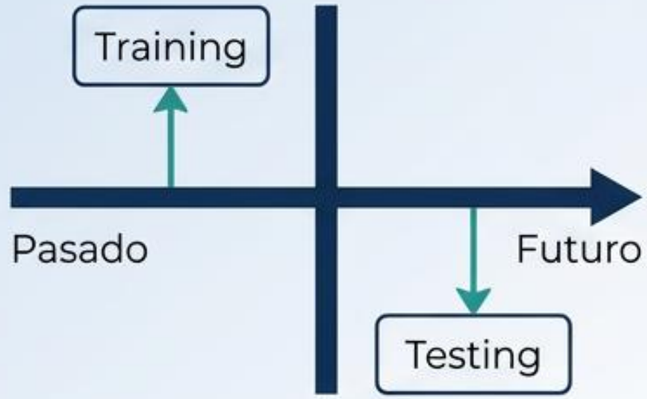
Para datasets grandes y homogéneos.

Estratificado



Protege las proporciones originales. Vital para clases desbalanceadas (ej. Fraude).

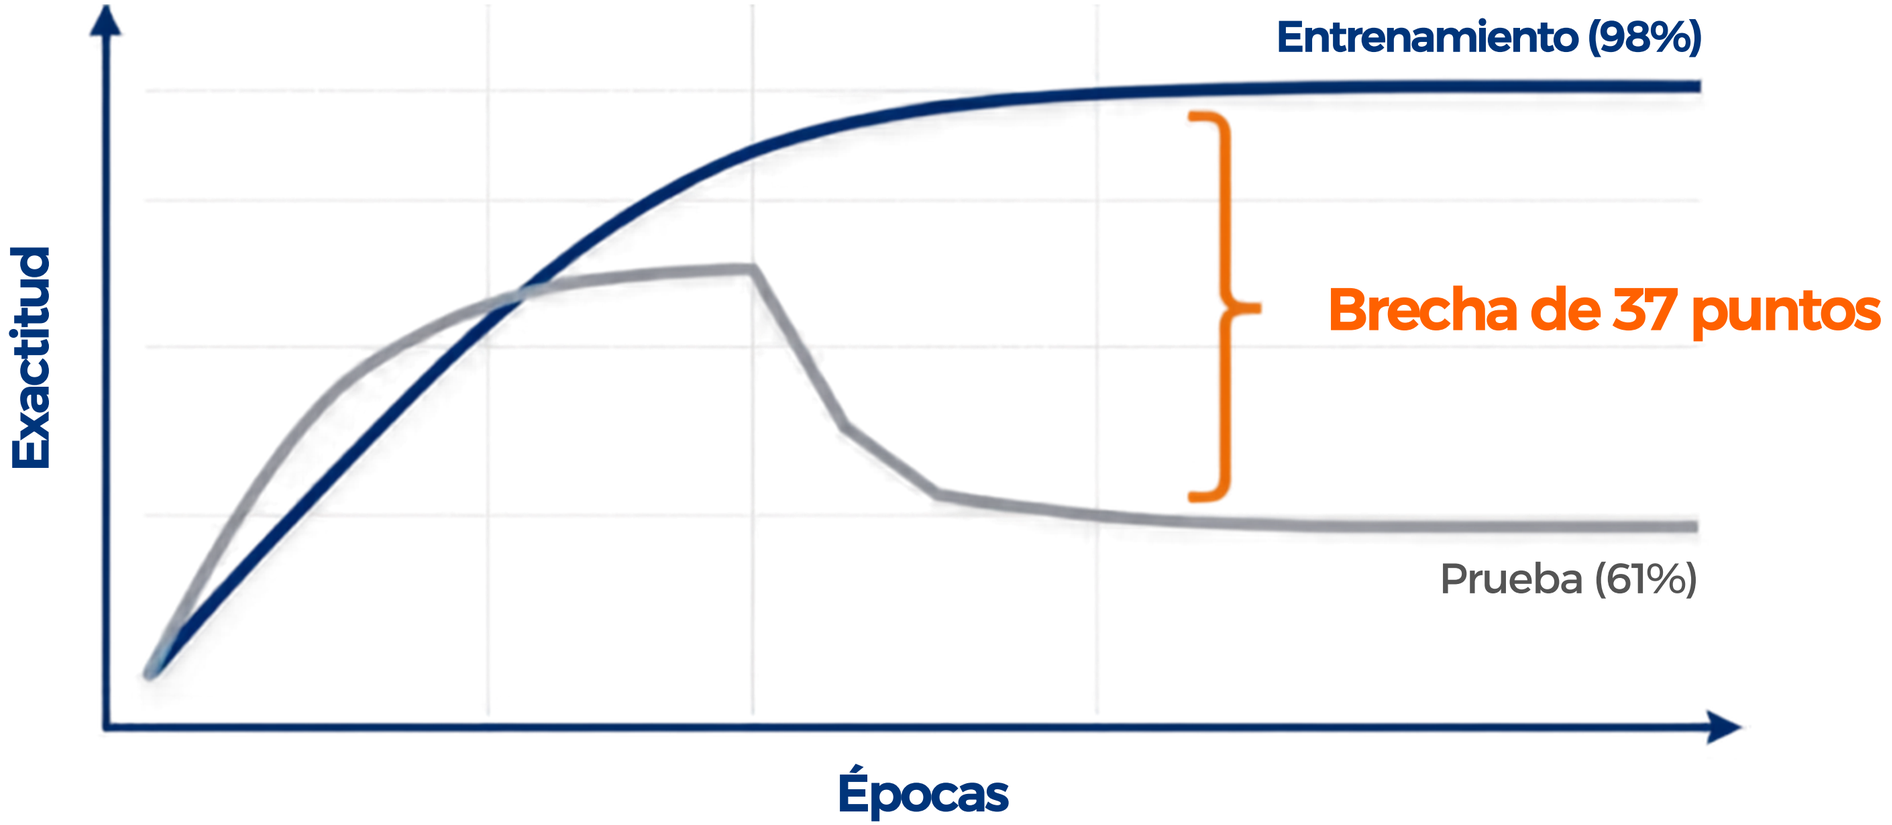
Consciente del Tiempo



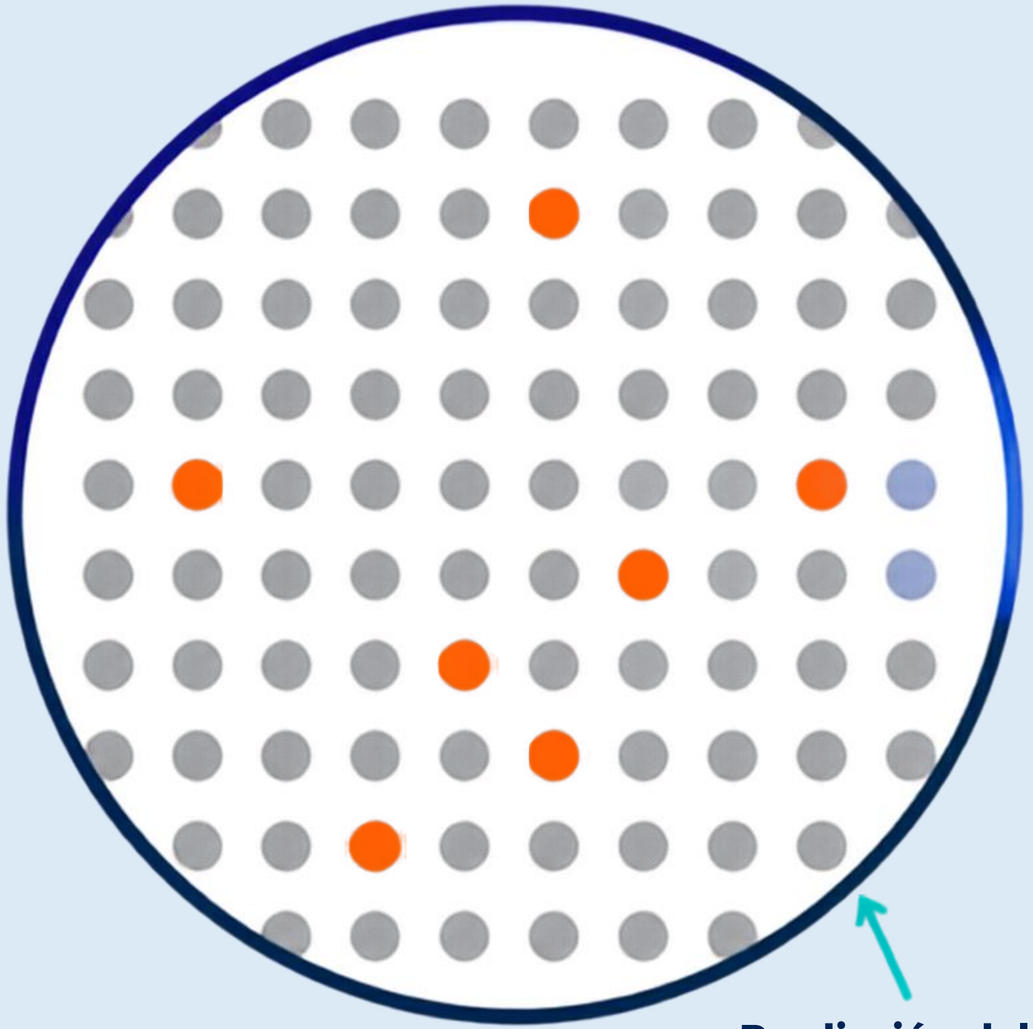
Para series temporales. Jamás entrenar con información del futuro para predecir el pasado.

El Enemigo Principal: El Sobreajuste (Overfitting)

La demostración en código lo confirmó: El modelo no aprendió el patrón general del problema. Memorizó el ruido de los datos de entrenamiento.



La Trampa del ‘Accuracy’ (Exactitud)



Predicción del Modelo: Todo es gris

Score del Modelo

95% Accuracy

(Exactitud matemática aparente)

Realidad del Negocio

0% detectado

(No se detectó ningún fraude real)

El accuracy esconde fallas sistemáticas cuando los datos están desbalanceados. Un modelo “tonto” que siempre predice negativo parece perfecto, pero fracasa en su único trabajo.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Más Allá de la Exactitud: El Radar de Evaluación



Precision (Precisión)

Pregunta del Negocio:

¿De todo lo que el modelo marcó como positivo, cuántos realmente lo eran?

Foco Estratégico:

Minimizar falsas alarmas.



Recall (Exhaustividad)

Pregunta del Negocio:

¿De todos los positivos reales en el mundo, cuántos logró detectar el modelo?

Foco Estratégico:

No dejar escapar ningún caso crítico.



F1-Score

Pregunta del Negocio:

¿Cómo equilibramos ambas?

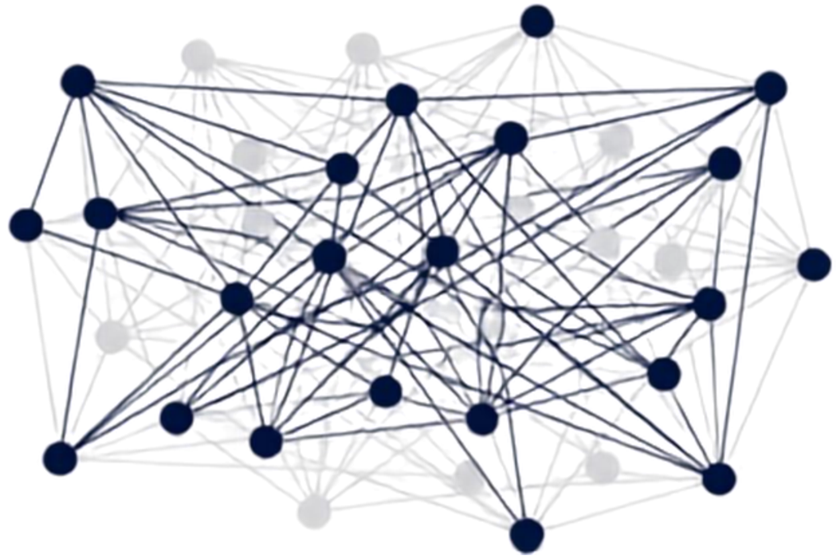
Foco Estratégico:

Métrica combinada usada cuando ambas fallas (falsos positivos y falsos negativos) son costosas.

Regularización: Poniendo Límites a la Complejidad

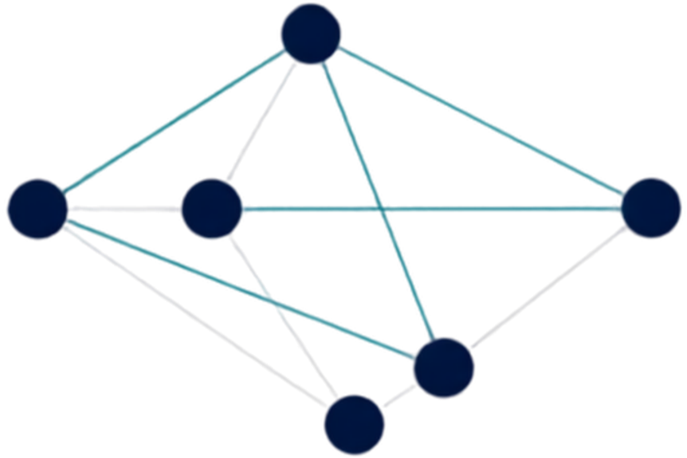
Regularizar es aplicar un “castigo” matemático a modelos demasiado complejos. Obliga a la IA a buscar la regla general, no la excepción.

Sin



El modelo intenta memorizar cada detalle, cargando peso innecesario.

Con



El modelo se ve obligado a quedarse con lo esencial. Menos peso, más eficiencia.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Herramientas de Restricción: Lasso vs. Ridge

Lasso (L1)



Mecanismo

Fuerza los coeficientes irrelevantes **exactamente a cero**.

Efecto

Elimina variables. Genera un modelo "liviano". Ideal cuando sospechamos que muchas variables son ruido.

Ridge (L2)



Mecanismo

Reduce el tamaño de todos los coeficientes, pero **rara vez a cero**.

Efecto

Estabiliza. Genera un modelo **"cargado" pero ordenado**. Ideal cuando todas las variables aportan algo de valor.

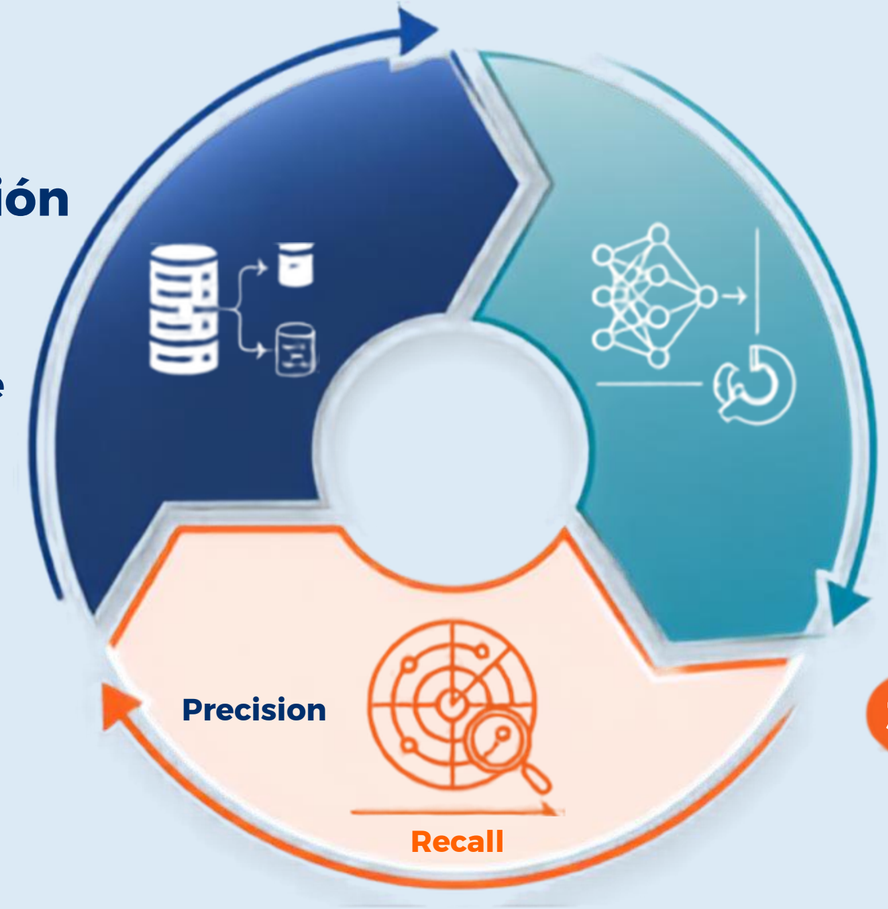
Nota: 'Elastic Net' combina ambas estrategias.

El Sistema de Defensa Unificado

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

1. El Cimiento (División y Muestreo)

Garantiza un entorno de prueba honesto.



2. Los Frenos (Regularización)

Evita que el algoritmo memorice el ruido.

3. El Radar (Precision/Recall)

Detecta trampas que el ‘Accuracy’ esconde.

Individualmente, son herramientas estadísticas. Juntas, forman una defensa sólida contra el sobreajuste, cerrando la brecha del 98% -> 61% y asegurando un modelo listo para producción.

DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

De Reglas Fijas a Aprendizaje Inferido

1. **¿Qué variable de su negocio** actual es **más difícil** de medir con exactitud?
2. **¿Dónde confía** más en los datos hoy en comparación a hace un año?
3. **¿Qué decisión toma** su empresa hoy basándose en reglas fijas?



Pregunta para pensar estos días: ¿Qué problema complejo resuelven hoy con reglas estáticas?
En la Sesión 31, volveremos a mirar ese problema con otros ojos.