Introducción a Machine Learning: cómo aprenden los modelos y cómo elegir el enfoque correcto

Sesión 31 — Apunte de estudio

La Sesión 30 terminó con una pregunta puente: ¿qué problema de su trabajo resuelven hoy con reglas fijas? En esta sesión retomamos esa pregunta y damos el siguiente paso: en lugar de programar todas las reglas de decisión, usamos datos para que un modelo encuentre patrones, produzca predicciones y mejore a partir de la evaluación.

Este apunte resume los conceptos trabajados en clase y las demostraciones del notebook práctico para poder repasarlos después con más calma. El hilo conductor es siempre el mismo: entender **qué queremos aprender, qué datos tenemos, cómo aprende el modelo y cómo sabremos si su resultado es útil.**

1. De reglas fijas a aprendizaje inferido

Las tres preguntas del cierre anterior tenían un propósito: convertir una situación de negocio en un problema que pueda abordarse con Machine Learning.

Pregunta	Qué nos ayuda a definir
¿Qué variable o resultado quiero conocer?	El objetivo, patrón o resultado de interés.
¿En qué datos confío?	La evidencia disponible y, cuando existen, las etiquetas históricas.
¿Qué decisión tomo hoy con reglas fijas?	La regla actual o baseline contra el que compararemos el modelo.

El cambio conceptual es importante: **una regla fija dice explícitamente qué hacer** ante determinadas condiciones. **Un modelo de Machine Learning**, en cambio, **ajusta sus parámetros a partir de ejemplos** para capturar una relación que no necesitamos escribir completa de antemano.

El ciclo de trabajo

- **Datos**: Aportan los ejemplos y la información histórica.
- **Modelo**: Se entrena para encontrar patrones en esos datos.
- **Evaluación**: Comparamos sus predicciones con la realidad mediante métricas apropiadas.
- **Mejora**: Ajustamos datos, variables, modelo o configuración y repetimos el ciclo.

2. El mapa general: IA, Machine Learning y Deep Learning

Machine Learning (ML) es un subconjunto de la Inteligencia Artificial (IA): reúne algoritmos capaces de mejorar su desempeño a partir de datos o experiencia. Deep Learning (DL) es, a su vez, una familia dentro de ML basada en redes neuronales con múltiples capas de procesamiento.

DIFERENCIAS ENTRE CONCEPTOS DE IA

Concepto	Qué describe	Ejemplo
Machine Learning	Aprendizaje a partir de datos.	Clasificación, regresión, clustering, refuerzo.
Deep Learning	Arquitecturas de redes neuronales profundas.	Visión artificial, audio, PLN complejo.
Aprendizaje por Refuerzo	Un paradigma de ML basado en acciones y recompensas.	Agentes que aprenden por ensayo y error.

Importante: **Aprendizaje por Refuerzo pertenece a Machine Learning;** no es sinónimo de Deep Learning. Ambos pueden combinarse cuando un agente de refuerzo utiliza redes neuronales profundas.

3. La gran taxonomía del aprendizaje

Paradigma	Datos / señal	Objetivo
Supervisado	Ejemplos etiquetados: conocemos la respuesta correcta.	Predecir una categoría o un valor.
No supervisado	Datos sin una respuesta objetivo predefinida.	Descubrir estructura o simplificar.
Por refuerzo	Interacción con un entorno y una señal de recompensa.	Aprender acciones que maximicen la recompensa.
Híbrido o mixto	Combina señales o técnicas.	Aprovechar mejor escenarios con etiquetas escasas.

Actividad de repaso — Taxonomía

Clasificar cada caso como supervisado, no supervisado o por refuerzo:

1. Predecir si un cliente cancelará usando casos históricos donde sabemos quién canceló.
2. Encontrar segmentos de clientes sin definir de antemano qué tipos existen.
3. Un agente decide qué acción tomar, observa el resultado y recibe una recompensa.
4. Predecir el gasto mensual de un cliente como un valor numérico.

Respuesta

1. Supervisado — clasificación.
2. No supervisado — clustering.
3. Aprendizaje por refuerzo.
4. Supervisado — regresión.

4. Aprendizaje supervisado: entrenamiento, inferencia, clasificación y regresión

En aprendizaje supervisado disponemos de ejemplos donde conocemos la respuesta correcta.

Durante el entrenamiento, el modelo observa esos ejemplos y ajusta sus parámetros.

Durante la inferencia, recibe un caso nuevo y utiliza los patrones aprendidos para producir una predicción.

Problema	Qué predice	Ejemplo de clase	Métrica / evaluación
Clasificación	Una categoría discreta.	¿Este cliente cancelará?	Accuracy, Precision, Recall, F1; matriz de confusión.
Regresión	Un valor numérico continuo.	¿Cuál será el gasto mensual?	MSE, RMSE, R^2.

Demo práctica — Clasificación

En el notebook se entrenó un modelo de clasificación para estimar la cancelación de clientes a partir de variables como antigüedad, uso, edad, quejas y gasto. La idea central no era memorizar una fórmula, sino observar el flujo completo: separar variables predictoras y objetivo, dividir los datos, entrenar y luego predecir un cliente nuevo.

Demo práctica — Regresión

También se trabajó un problema de regresión para predecir un resultado numérico. Aquí la salida ya no es una clase, sino un valor continuo; por eso cambian tanto la interpretación como las métricas de evaluación.

5. Aprendizaje no supervisado: descubrir estructura sin etiquetas

En aprendizaje no supervisado no entregamos al algoritmo una columna con la respuesta correcta. **El objetivo es encontrar estructura útil en las variables observadas.**

Clustering con K-Means

K-Means agrupa observaciones parecidas alrededor de centros o centroides. El algoritmo crea los grupos **a partir de las distancias** entre los datos; después corresponde al analista interpretar qué significa cada segmento para el negocio.

En la práctica se segmentaron clientes usando antigüedad, uso mensual y gasto. Un detalle importante del notebook es que la variable de cancelación no se utilizó para formar los clusters. Después se revisó esa variable para interpretar si alguno de los segmentos concentraba mayor riesgo.

Reducción de dimensionalidad con PCA

PCA transforma varias variables correlacionadas en componentes que resumen la mayor parte de su variación. Es útil cuando queremos simplificar o visualizar información de muchas dimensiones. En el notebook, los mismos clientes se proyectaron en dos componentes y se reportó el porcentaje de variación explicado.

Actividad de clase — De una variable difícil a un patrón latente

Pensemos en una variable difícil de medir directamente —por ejemplo, lealtad, perfil de cliente o intensidad de uso—. ¿Podría representarse mediante segmentos o mediante una combinación de variables observables? ¿Qué columnas usaríamos?

Respuesta

No existe una única respuesta. La clave es distinguir entre una etiqueta que ya conocemos y un concepto que queremos descubrir.

Si no tenemos una etiqueta confiable pero sí varias conductas observables, clustering o PCA pueden ayudar a explorar estructura.

6. Aprendizaje por Refuerzo.

En Aprendizaje por Refuerzo un agente interactúa con un entorno. Observa un estado, elige una acción, recibe una recompensa y utiliza esa experiencia para mejorar sus decisiones futuras.

El objetivo es aprender una estrategia que acumule la mayor recompensa posible a lo largo del tiempo.

Elemento	Pregunta
Agente	¿Quién toma la decisión?
Estado	¿Qué información describe la situación actual?
Acción	¿Qué puede hacer el agente?
Recompensa	¿Cómo medimos si la acción fue buena o mala?
Política	¿Qué estrategia aprende para decidir qué acción tomar?

Ejemplos trabajables incluyen decisiones secuenciales, optimización dinámica y situaciones donde el resultado de una acción afecta lo que ocurrirá después.

7. El salto a Deep Learning

Deep Learning utiliza redes neuronales con múltiples capas ocultas. Frente al ML clásico, donde el diseño de variables suele depender más del trabajo humano, las redes profundas pueden aprender representaciones cada vez más abstractas directamente desde datos complejos.

Anatomía básica de una neurona

- **Entradas (x)**: Los datos que llegan a la neurona.
- **Pesos (w)**: Indican la importancia relativa de cada conexión.
- **Suma ponderada**: Combina las señales de entrada.
- **Función de activación**: Decide qué señal se propaga hacia la salida.

Cómo aprende una red neuronal

Paso	Qué ocurre
Forward propagation	Los datos avanzan por la red y generan una predicción.
Función de pérdida	Mide la diferencia entre la predicción y la realidad.
Backpropagation	El error se propaga hacia atrás y se ajustan los pesos para reducirlo.

ML clásico vs. Deep Learning

Criterio	ML clásico	Deep Learning
Volumen de datos	Puede funcionar con miles de registros.	Suele beneficiarse de volúmenes mucho mayores.
Hardware	Puede ejecutarse en CPU estándar.	Frecuentemente requiere GPU.
Extracción de atributos	Más manual y dependiente del experto.	Más automática mediante capas ocultas.
Interpretabilidad	Suele ser mayor.	Suele ser menor.
Casos de uso	Datos tabulares, scoring.	Imágenes, audio, PLN complejo, IA generativa.

8. El dilema del ajuste: aprender el patrón sin memorizar el ruido

El notebook retomó la idea central de la Sesión 30 mediante tres modelos sobre el mismo problema: uno demasiado simple (subajuste), uno con complejidad adecuada y otro excesivamente complejo (sobreajuste).

Situación	Qué ocurre	Señal típica
Subajuste	El modelo no captura suficientemente el patrón.	Rendimiento bajo incluso en entrenamiento.
Ajuste adecuado	Captura el patrón y generaliza razonablemente.	Buen rendimiento en datos nuevos.
Sobreajuste	Memoriza particularidades y ruido.	Train muy alto, test claramente peor.

La comparación entre entrenamiento y test sigue siendo esencial: un desempeño excelente sobre datos conocidos no basta si el modelo pierde capacidad al enfrentarse a casos nuevos.

Regularización — Ridge y Lasso

La práctica añadió variables de ruido para observar el efecto de la regularización. **Lasso (L1)** puede llevar coeficientes a cero y, en la práctica, apagar variables poco útiles. **Ridge (L2)** reduce la magnitud de los coeficientes, pero normalmente los conserva. Ambas técnicas buscan controlar la complejidad y favorecer la generalización.

9. Evaluación del modelo más allá de la exactitud o accuracy.

La clase volvió al ejemplo de datos desbalanceados. Si solo 5% de los casos son positivos, un modelo que siempre predice la clase mayoritaria obtiene 95% de Accuracy y sin embargo, puede tener 0% de Recall para la clase que realmente importa.

Métrica	Pregunta que responde	Cuándo importa especialmente
Precision	De lo marcado como positivo, ¿cuánto era realmente positivo?	Cuando las falsas alarmas son costosas.
Recall	De los positivos reales, ¿cuántos detectó?	Cuando dejar escapar un positivo es costoso.
F1-Score	¿Cómo equilibramos Precision y Recall?	Cuando ambas clases de error importan.
Accuracy	¿Qué proporción total fue correcta?	Útil, pero insuficiente por sí sola con fuerte desbalance.

Actividad de repaso — La trampa del 95%

En 1.000 casos hay 50 casos reales de riesgo. Un modelo predice siempre «sin riesgo». ¿Qué conclusión sacaríamos si solo viéramos el Accuracy?

Respuesta

El Accuracy sería 95%, pero esa cifra es engañosa para el objetivo de detectar riesgo.

El Recall de la clase positiva sería 0%: el modelo no detecta ninguno de los 50 casos reales.

La métrica correcta depende del costo de cada tipo de error, no de cuál número se vea más alto.

10. Cómo elegir el algoritmo adecuado a mi problema.

Antes de elegir un algoritmo, conviene diagnosticar la naturaleza del problema. El notebook cerró con un árbol de decisión simplificado que resume el criterio trabajado durante la sesión.

Si el problema es...	Enfoque a considerar
Predecir una categoría con ejemplos etiquetados	Clasificación — aprendizaje supervisado.
Predecir un número con ejemplos etiquetados	Regresión — aprendizaje supervisado.
Descubrir grupos sin etiquetas	Clustering — aprendizaje no supervisado.
Simplificar muchas variables	PCA — aprendizaje no supervisado.
Tomar decisiones secuenciales por ensayo y error	Aprendizaje por Refuerzo.
Trabajar con imágenes, audio, texto complejo o gran escala	Deep Learning / redes neuronales.

NOTA: No existe una solución universal. Elegir bien significa alinear la naturaleza del problema, los datos disponibles, la arquitectura del modelo y la forma de evaluación.

11. Reto final: llevar una regla fija al lenguaje de Machine Learning

Vuelvan a la regla fija que identificaron al inicio de la clase y respondan:

1. ¿Qué decisión o resultado quiero mejorar?
2. ¿Tengo ejemplos históricos con una respuesta correcta o etiqueta?
3. Si es supervisado, ¿quiero predecir una categoría o un número?
4. Si no tengo etiquetas, ¿quiero descubrir grupos o simplificar variables?
5. ¿Es una secuencia de decisiones donde las acciones cambian el entorno?
6. ¿El problema requiere datos complejos como imágenes, audio o lenguaje natural?
7. ¿Con qué métrica demostraría que el modelo supera a la regla actual?

Para pensar después de la clase

- ¿Qué regla de su trabajo podría reemplazarse o complementarse con un modelo aprendido a partir de datos?
- ¿Qué etiqueta necesitarían registrar hoy para poder entrenar un modelo supervisado mañana?
- ¿Qué variable aparentemente «difícil de medir» podría ser en realidad un patrón latente que se descubre con varias variables?
- ¿Qué error sería más costoso en su caso: una falsa alarma o dejar escapar un caso importante?