Reducción de dimensionalidad y representación de variables

Sesión 32 — Apunte de estudio

Esta sesión continua el recorrido de las dos clases anteriores. En la Sesión 30 trabajamos la calidad y la división de los datos; en la Sesión 31 vimos cómo un modelo aprende y distinguimos aprendizaje supervisado, no supervisado y por refuerzo.

Ahora damos un paso previo al modelado que suele decidir gran parte del resultado: **cómo representar las variables y cómo resumirlas cuando tenemos demasiadas.**

El caso práctico vuelve al problema de churn: predecir si un cliente de una telco cancelará su suscripción. La práctica utiliza por defecto un dataset sintético reproducible de 1.500 clientes y desarrolla cuatro bloques: **alta dimensionalidad, representación de variables, PCA y t-SNE.**

1. El problema de la dimensionalidad

Tener más columnas no significa automáticamente tener más información útil. A medida que crece el número de variables pueden aparecer costos e inestabilidades que dificultan tanto el aprendizaje como la puesta en producción.

Problema	Qué ocurre
Costo computacional	Más columnas implican más tiempo de procesamiento y entrenamiento.
Multicolinealidad	Variables muy correlacionadas contienen información redundante y pueden generar inestabilidad.
Variables ruido	Algunas columnas no aportan señal real y pueden distraer al modelo.
Sesgo vs. varianza	Con pocas observaciones, agregar variables puede aumentar la varianza de las predicciones y favorecer el sobreajuste.

Reducir dimensiones puede hacer el entrenamiento más eficiente, facilitar la depuración y comprensión, eliminar redundancia y producir soluciones más simples de mantener. Pero reducir no es gratis: debemos decidir qué información conservar y cuánto desempeño estamos dispuestos a ceder.

Definición de manifold y por qué es útil.

Usemos la analogía de un globo terráqueo: una superficie 3D puede representarse en un mapa 2D conservando relaciones esenciales. Un **manifold** es esa estructura de menor dimensión que está “doblada” dentro de un espacio de más dimensiones. Reducir dimensionalidad busca encontrar una representación más pequeña que preserve la estructura relevante.

Dos caminos para reducir

Camino	Qué hacemos	Ventaja principal
Selección de variables	Eliminamos columnas redundantes o poco informativas y conservamos variables originales.	Mayor interpretabilidad.
Extracción / creación	Combinamos variables en nuevas representaciones que resumen la información original.	Mayor compresión; PCA es el ejemplo central de la sesión.

2. Diferencias entre calidad de datos y representación.

En la Sesión 30 la pregunta era **"¿son datos confiables?"**. En esta sesión la pregunta cambia a **"¿en qué forma se los entrego al modelo?".** Un dato puede ser correcto y completo, pero estar representado de una manera que distorsione distancias, varianzas o relaciones.

Situación	Problema para el modelo	Respuesta
Escalas distintas	Una variable que llega a miles puede dominar a otra que vale 0/1.	Escalar o estandarizar.
Texto o categorías	El algoritmo necesita una representación numérica.	Codificar categorías.
Información implícita	La señal útil puede estar en una combinación de columnas.	Feature engineering.

Idea clave: PCA y t-SNE trabajan con distancias y/o varianzas. Si las variables están mal representadas, el algoritmo puede resumir una distorsión en lugar de información útil.

3. Escalamiento y estandarización

Antes de aplicar PCA, t-SNE o métodos basados en distancias, las variables numéricas deben quedar en escalas comparables.

Técnica	Qué hace	Uso destacado en clase
Estandarización (z-score)	Centra las variables en 0 y expresa los valores en desviaciones típicas respecto de la media.	Es el estándar utilizado para PCA y t-SNE.
Normalización (min-max)	Lleva los valores a un rango entre 0 y 1 conservando el orden.	Útil cuando se requieren límites fijos, por ejemplo, en algunas redes neuronales.

En Python se trabajó con StandardScaler y se reforzó una regla de la Sesión 30: el escalador se ajusta (fit) únicamente con entrenamiento y luego se aplica (transform) a test. Ajustarlo con todos los datos produciría Data Leakage.

Actividad de repaso — ¿Por qué importa la escala?

Supongan que una variable mide segundos de llamada y toma valores de miles, mientras reclamos vale 0 o 1. ¿Qué puede ocurrir si aplicamos PCA directamente sin escalar?

Respuesta

La variable de mayor magnitud puede dominar la varianza y, por tanto, los componentes.

No significa necesariamente que "segundos" sea más importante: parte del efecto proviene de la unidad de medida. Por eso estandarizamos antes de PCA.

4. Codificación de variables categóricas

Asignar números a categorías no siempre convierte una variable en una magnitud válida**. La codificación debe respetar el significado de la variable.**

Técnica	Cuándo usarla	Ejemplo
Ordinal encoding	Existe un orden real entre categorías.	Nivel bajo → alto.
One-hot encoding	Las categorías no tienen un orden cuantitativo.	tipo_plan → columnas binarias.
Target / frequency encoding	Hay muchas categorías y se necesita una representación compacta.	comuna → frecuencia o tasa histórica.

En el caso churn, tipo_plan y estado venían como enteros 1-2. Eso puede funcionar directamente en modelos de árbol, pero para PCA/t-SNE se transformaron a one-hot porque estos métodos interpretan diferencias numéricas como distancias.

5. Feature engineering: construir la variable que falta

A veces la variable más informativa no existe como columna cruda. Feature engineering consiste en construir variables que expresen mejor un comportamiento o concepto a partir de datos ya disponibles. En la práctica se crearon tres ejemplos antes de escalar y reducir:

Variable creada	Construcción	Lectura
duracion_prom_llamada	**segundos ÷ frec_llamadas**	Distingue muchas llamadas cortas de pocas llamadas largas.
sms_por_antiguedad	**frec_sms ÷ antiguedad**	Normaliza el uso de SMS por el tiempo que el cliente lleva en la compañía.
intensidad_contacto	**n_contactos ÷ frec_llamadas**	Aproxima cuán concentrada está la actividad en pocos contactos.

Estas variables se agregan antes del escalamiento y de la reducción dimensional. Representar mejor los datos es un paso previo; PCA y t-SNE no sustituyen el feature engineering.

6. PCA: resumir muchas variables en componentes

Análisis de Componentes Principales (PCA) toma varias variables y las resume en nuevas variables llamadas componentes principales, tratando de perder la menor cantidad posible de información. **Es una técnica no supervisada: la variable objetivo no se utiliza para construir los componentes.**

La intuición detrás de PCA

1. Busca la dirección en la que los datos varían más: allí encuentra el primer patrón principal.

2. Esa dirección se convierte en PC1. PC2 busca la siguiente dirección más informativa sin repetir lo ya explicado por PC1.

3. El proceso continúa: cada componente captura el patrón más fuerte que todavía no había sido explicado.

Cada componente es una "receta": una combinación de las variables originales. Por eso PCA reduce el número de columnas, pero sacrifica parte de la interpretabilidad directa de cada variable original.

7. PCA aplicado al caso de churn

La práctica trabaja con 1.500 clientes. La variable objetivo es fuga (1 = abandonó, 0 = activo), pero se deja fuera del PCA y se utiliza solo después para colorear o evaluar resultados. Antes del análisis se mantienen las reglas de calidad de la Sesión 30 y se revisan correlaciones.

La matriz de correlación mostró una señal clara de redundancia: segundos, frecuencia de llamadas, contactos, SMS, monto y CLV están fuertemente relacionados. PCA puede condensar buena parte de esa información común en menos componentes.

¿Cuántas componentes elegimos?

El scree plot muestra la varianza explicada por cada componente y su acumulado. En el notebook, 8 componentes alcanzan al menos el 80% de la varianza total. La lógica no es buscar un número mágico, sino detectar el punto donde agregar otra componente aporta cada vez menos información nueva.

¿Qué significan PC1 y PC2?

Componente	Lectura del caso
PC1	**Agrupa principalmente el uso general del servicio**: segundos, llamadas, contactos, SMS, monto y CLV. Un PC1 mayor se asocia a mayor uso.
PC2	**Mezcla señales como fallas técnicas y reclamos**; un valor alto se interpreta como mayor fricción o insatisfacción con el servicio.

El círculo de correlaciones ayuda a interpretar estas recetas: las flechas muestran cuánto pesa y en qué dirección se relaciona cada variable con las primeras componentes.

8. El trade-off real: simplificar vs. conservar desempeño

La clase compara una regresión logística con las variables representadas originales frente al mismo modelo usando PCA. El objetivo es medir qué se pierde al simplificar aplicando PCA.

Modelo	N.º variables/componentes	F1-score	MCC
Variables originales	15	0.270	0.265
PCA	8	0.267	0.252

Lectura: con 8 componentes en lugar de 15 columnas, el desempeño baja solo un poco. Ese es el trade-off: ceder algo de capacidad predictiva a cambio de un modelo más compacto, liviano y fácil de mantener. La decisión depende del problema; PCA no es automáticamente mejor ni "gratis".

9. t-SNE: un mapa no lineal para explorar estructura

t-Distributed Stochastic Neighbor Embedding (t-SNE) busca una representación en 2D o 3D que **mantenga cerca, a los puntos que eran vecinos en el espacio original.** A diferencia de PCA, no busca conservar la varianza global, sino las relaciones de vecindad local.

Cómo funciona, sin fórmulas

1. Mide quién se parece a quién en el espacio original de muchas variables.
2. Dibuja los puntos en 2D y los va moviendo hasta que las vecindades del mapa se parezcan a las originales.
3. El proceso es iterativo; por eso puede tardar y el resultado puede cambiar ligeramente entre corridas.

Perplexity, el hiperparámetro clave en t-SNE.

En lenguaje coloquial, **perplexity indica aproximadamente a cuántos vecinos presta atención el algoritmo**. Valores bajos enfatizan grupos pequeños y locales; valores altos entregan una visión más panorámica. La presentación recomienda probar habitualmente entre 5 y 50 y recuerda que debe ser menor que el número de observaciones.

Consideraciones prácticas

Aspecto	Qué recordar
No determinístico	Distintas corridas pueden variar; random_state ayuda a reproducir resultados.
No es clustering	Los grupos visuales no deben interpretarse automáticamente como clusters ni sus distancias como distancias reales.
Costo alto	El costo computacional crece rápido con el número de observaciones.
Uso	Está pensado principalmente para explorar y visualizar, no como transformación estándar de producción.

10. PCA vs. t-SNE

Criterio	PCA	t-SNE
Naturaleza	Lineal	No lineal
Qué conserva	Varianza global	Vecindades locales
Resultado	Determinístico	Puede variar entre corridas
Costo	Bajo / rápido	Más alto
Nuevos datos	Permite transformarlos	No está pensado para transformarlos directamente
Uso típico	Reducir antes de modelar / producción	Explorar y visualizar estructura

En la presentación mencionamos además otras alternativas de reducción a modo de tener un listado de técnicas disponibles que no veremos en estas sesiones: Análisis Factorial, Análisis Discriminante y SVD entre las lineales; Autoencoders, IsoMap, Local Linear Embedding y UMAP entre las no lineales.

11. El hilo de las sesiones 30 → 31 → 32

Sesión	Condición que resolvimos
30 · Calidad de datos	Diagnosticamos, imputamos y dividimos honestamente el dataset.
31 · Aprendizaje	Entendimos el ciclo de ML y las familias supervisado / no supervisado.
32 · Representación y reducción	Escalamos, codificamos, construimos y resumimos variables con PCA / t-SNE.

RESUMIENDO: primero necesitamos datos confiables; después entendemos cómo aprende un modelo; finalmente decidimos en qué forma entregarle la información y cuánto podemos resumir sin perder lo que importa.

12. Actividad de repaso-¿seleccionar, construir o extraer?

Para cada situación, elige la acción principal: selección de variables, feature engineering, PCA o t-SNE.

1. Tienen seis variables de uso muy correlacionadas y quieren un modelo más liviano para producción.
2. Tienen segundos totales y número de llamadas, pero quieren distinguir llamadas largas de cortas.
3. Quieren explorar visualmente si existen estructuras locales no lineales entre clientes.
4. Una columna no aporta información y además complica la explicación del modelo.

Respuesta

1. PCA: puede resumir la redundancia en menos componentes.

2. Feature engineering: construir duración promedio de llamada.

3. t-SNE: está diseñado para visualizar vecindades y estructura no lineal.

4. Selección: eliminar una variable poco informativa conserva interpretabilidad.

Para pensar después de la clase

- ¿Cuáles de las variables de su proyecto cree que están altamente correlacionadas entre sí?
- ¿Qué variable nueva podría construir combinando dos columnas que ya tiene?
- Si tuviera que quedarse con la mitad de sus variables, ¿las eliminaría o las resumiría con PCA?
- ¿Cuándo preferiría un mapa t-SNE para explorar sus datos y cuándo un PCA para reducir antes de modelar?