DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Herramientas Computacionales para Data Science

Evaluación de modelos supervisados y selección de modelos

Sesión 38 · 24 de septiembre de 2026

Eloy Alvarado Narváez

Tenemos predicciones. ¿Cuál conviene usar?

Estimar una cantidad
Dos modelos predicen la resistencia de una mezcla de hormigón.

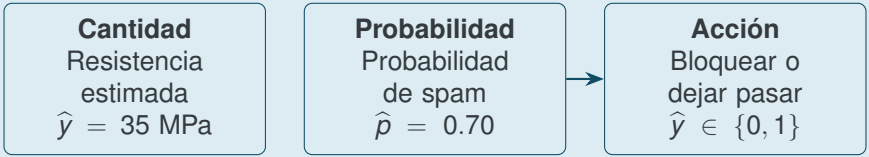
Uno comete errores pequeños casi siempre; otro evita errores muy grandes.

Tomar una decisión
Dos filtros identifican spam con el mismo porcentaje de aciertos.

Uno bloquea más correos legítimos; otro deja pasar más spam.

“Mejor modelo” necesita una definición: qué error importa, para qué uso y en qué datos nuevos.

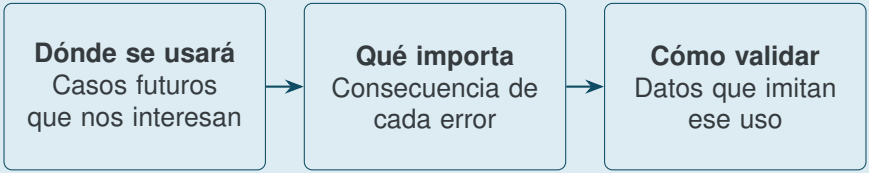
La salida del modelo y su uso son cosas distintas



La cantidad se compara con un valor real. Una probabilidad expresa incertidumbre; una acción añade una regla de decisión.

Evaluar bien exige evaluar la salida que se va a utilizar. Una sola cifra no responde todas las preguntas.

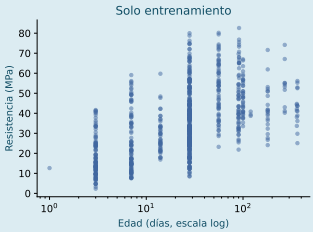
Antes de elegir: ¿mejor para qué y para quién?

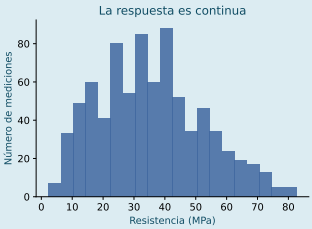


La métrica representa qué errores importan; la partición representa los casos nuevos que queremos predecir.

Con ese problema definido, comparamos en validación y evaluamos la elección final en prueba reservada.

Una predicción útil necesita una evaluación útil





Queremos predecir la **resistencia del hormigón** usando su composición y edad.

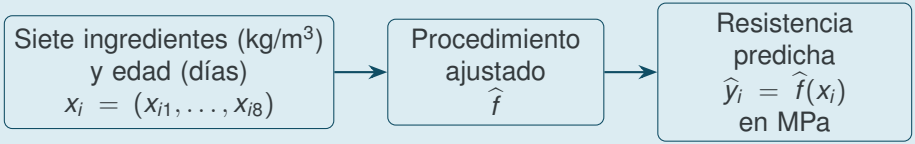
Se mide en **megapascales (MPa)**, una unidad de presión.

¿Cuánto nos equivocaremos en una composición que quedó fuera del ajuste?

La pregunta no termina al obtener una predicción: hay que elegir cómo compararla y dónde evaluarla.

Yeh (1998), Concrete Compressive Strength, UCI. Gráficos: solo entrenamiento.

De los datos a la tarea supervisada



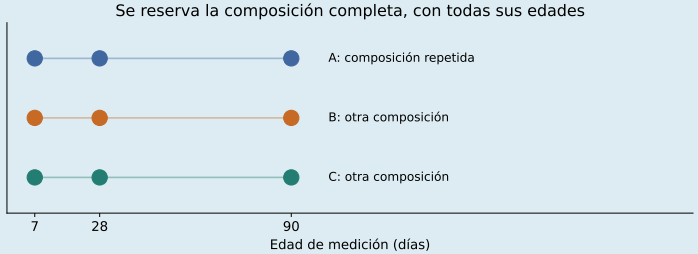
1030 mediciones; ocho predictores numéricos; respuesta continua y_i.

Los ingredientes son cemento, escoria, ceniza, agua, superplastificante y agregados grueso y fino.

y_i es el valor observado; $\widehat{y}_i$ es la predicción. Un identificador no es un predictor.

Datos UCI, DOI 10.24432/C5PK67; licencia CC BY 4.0.

¿Una fila nueva representa una composición nueva?



Hay mediciones con los mismos siete ingredientes y distintas edades. Separar sus filas puede dejar la misma composición en ajuste y validación.

Agrupamos por igualdad exacta de ingredientes y reservamos grupos completos. Edad y respuesta no definen el grupo.

La pérdida define qué significa equivocarse

Con entrenamiento $\mathcal{T}$, ajustamos $\widehat{f}_{\mathcal{T}}$ y consideramos un caso nuevo (X, Y):

$$R(\widehat{f}_{\mathcal{T}}) = \mathbb{E}\Big[L\Big(Y, \widehat{f}_{\mathcal{T}}(X)\Big) \mid \mathcal{T}\Big].$$

Pérdida
Penaliza el error de un caso.

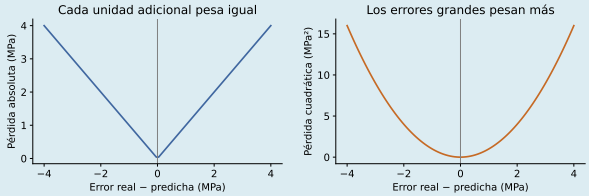
$$L(y, \widehat{y}) = (y - \widehat{y})^2.$$

Riesgo
Promedia la pérdida en la población de interés. Esa población debe concordar con la forma de validar.

La métrica resume errores en una muestra; el riesgo describe lo que esperamos en casos nuevos.

Aquí aproximamos el desempeño en composiciones excluidas de la misma base histórica.

Dos formas de resumir el error: MAE y RMSE



MAE: error absoluto medio

Mean Absolute Error

$$\mathrm{MAE} = \frac{1}{n}\sum_i |y_i - \widehat{y}_i|.$$

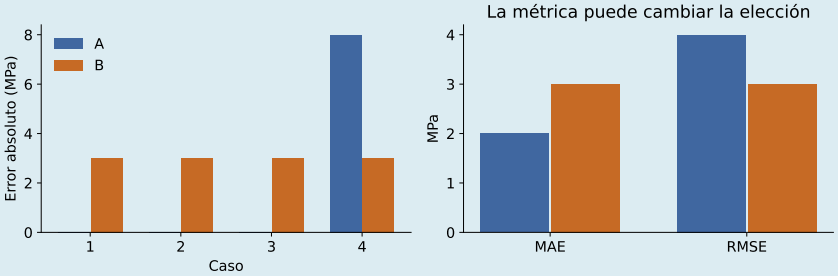
RMSE: raíz del error cuadrático medio

Root Mean Squared Error

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_i (y_i - \widehat{y}_i)^2}.$$

Ambos se expresan en MPa. RMSE da mayor peso a los errores grandes.

Cambiar la métrica puede cambiar el ganador



A tiene MAE $= 2$ y RMSE $= 4$; B tiene MAE $= 3$ y RMSE $= 3$.

Con MAE elegimos A; con RMSE elegimos B. El criterio se define antes de consultar los resultados.

Cuatro errores construidos para ilustrar la decisión; no son resultados de hormigón.

R^2 necesita una referencia clara

$$R^2_{\text{eval}} = 1 - \frac{\sum_i (y_i - \widehat{y}_i)^2}{\sum_i (y_i - \overline{y}_{\text{eval}})^2}.$$

- Compara contra la media del conjunto evaluado; puede ser negativo.
- No tiene unidades y no expresa el tamaño del error en MPa.
- Una referencia ejecutable predice la **media de entrenamiento**, calculada sin las respuestas de prueba.

Un $R^2 < 0$ indica más error cuadrático que usar la media del conjunto evaluado.

Usaremos RMSE para seleccionar; MAE y R^2 para describir. La referencia se fija antes de evaluar.

Una correlación alta puede ocultar errores grandes

Si $y = (1, 2, 3)$ y $\widehat{y} = (11, 12, 13)$:

$$\text{cor}(y, \widehat{y})^2 = 1, \qquad \text{RMSE} = 10, \qquad R^2 = 1 - \frac{300}{2} = -149.$$

La predicción conserva el orden, pero tiene un desplazamiento de 10 unidades.

Evaluar el error de predicción directamente. Si la respuesta es constante, la fórmula usual de R^2 no se define.

La unidad de separación determina el alcance

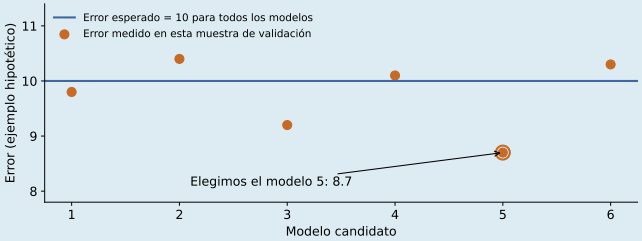
806 mediciones /
342 composiciones
Ajustar y seleccionar
Validación cruzada
(CV) en cinco pliegues

224 mediciones /
86 composiciones
Prueba reservada
Evaluar la elección final

428 composiciones en total. Se reservó 20 % de los grupos; eso no exige 20 % exacto de las filas.

Ninguna composición aparece a ambos lados de una partición. Esto no acredita generalización a otra planta o laboratorio.

El menor error de validación puede ser optimista



Los seis modelos tienen error esperado **10**. Elegimos el modelo 5 porque su error de validación fue **8.7**: esa muestra lo favoreció.

Para estimar cómo rendirá el modelo elegido, lo evaluamos en datos de prueba que no participaron en la elección.

Ejemplo hipotético. El 8.7 usado para elegir subestima aquí el error esperado de 10.

Qué se ajusta y qué se selecciona

Ajuste dentro de un candidato

Estimar coeficientes, medias y escalas usando las filas autorizadas.

$$\widehat{\beta}_{\mathcal{T}}.$$

Selección entre candidatos

Elegir variables, transformaciones o penalización usando el error de validación.

$$\widehat{m} = \arg\min_{m \in \mathcal{M}} \widehat{R}_{\mathrm{CV}}(m).$$

Validar un candidato exige ajustarlo de nuevo en cada pliegue; seleccionar compara los errores de esos ajustes.

Cada candidato es una receta completa. La prueba se reserva para evaluar la receta seleccionada y reajustada.

Qué modelos vamos a comparar

1. Modelo constante

$$\widehat{y} = \overline{y}_{\mathcal{T}}.$$

2. Regresión lineal múltiple

$$\widehat{y} = \widehat{\beta}_0 + \sum_{j=1}^{8} \widehat{\beta}_j x_j.$$

3. Regresión cuadrática con penalización ridge

$$\widehat{y} = \widehat{\beta}_0 + \underbrace{\sum_{j=1}^{8} \widehat{\beta}_j x_j}_{\text{8 lineales}} + \underbrace{\sum_{j=1}^{8} \widehat{\gamma}_j x_j^2}_{\text{8 cuadrados}} + \underbrace{\sum_{j<k} \widehat{\delta}_{jk} x_j x_k}_{\text{28 interacciones}} .$$

Ejemplos: cemento^2 y cemento $\times$ agua. Ridge controla el tamaño de los coeficientes.

7 candidatos: 1 constante, 1 lineal y 5 ridge ($\alpha = 0.1, 1, 10, 100, 1000$).

Cómo ajustamos el modelo cuadrático: ridge

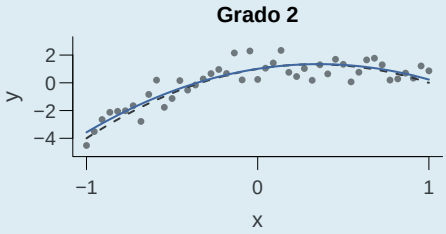
En z_i reunimos los 44 términos del modelo anterior, estandarizados. Ridge ajusta:

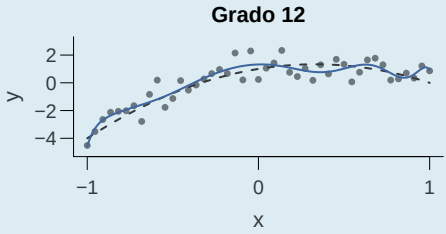
$$\min_{\beta_0,\beta} \left\{ \sum_{i \in \mathcal{T}} (y_i - \beta_0 - z_i^\top \beta)^2 + \alpha \sum_{j=1}^{44} \beta_j^2 \right\}.$$

- α pequeño permite coeficientes de mayor magnitud.
- α grande restringe el ajuste con más fuerza.
- El intercepto no se penaliza. La escala de los términos importa.

Los coeficientes se estiman al ajustar; α se elige al comparar errores de validación.

Sobreajuste: comparar ajuste y datos nuevos





RMSE de ajuste: **0.67**
RMSE en datos nuevos: **0.64**

RMSE de ajuste: **0.58**
RMSE en datos nuevos: **0.73**

Azul: ajuste; discontinua: señal del ejemplo simulado.

El grado 12 ajusta mejor los datos conocidos, pero predice peor los nuevos. El grado 2 generaliza mejor en este ejemplo.

Sesgo, varianza y ruido: tres fuentes de error

Para una nueva respuesta en x, el error cuadrático esperado se descompone en:

$$\text{Error cuadrático esperado} = \text{Sesgo}^2 + \text{Varianza} + \text{Ruido}.$$

Sesgo
Distancia entre la señal y el ajuste promedio

Varianza
Cuánto cambia el ajuste al cambiar la muestra

Ruido
Variación de Y incluso al fijar $X = x$

Para x fijo, bajo $Y = f(x) + \varepsilon$, con ruido de media cero, varianza σ^2 e independiente del ajuste.

Aumentar la flexibilidad puede reducir el sesgo y aumentar la varianza. La validación permite comparar el efecto conjunto.

Predicciones fuera de pliegue: OOF

OOF significa *out-of-fold*: cada predicción se obtiene con un modelo ajustado **sin el pliegue de esa observación**.

Aquí el pliegue $k(i)$ deja fuera también todo el grupo de i:

$$\widehat{y}_i^{\mathrm{OOF}} = \widehat{f}^{(-k(i))}(x_i), \qquad \mathrm{RMSE}_{\mathrm{OOF}} = \sqrt{\frac{1}{806}\sum_{i=1}^{806}(y_i - \widehat{y}_i^{\mathrm{OOF}})^2}.$$

- Cada candidato produce 806 predicciones mediante cinco ajustes distintos.
- Sumamos errores cuadrados, dividimos por 806 y extraemos la raíz.
- Cada **medición** pesa igual; los grupos controlan la separación.

Separar por grupos no implica dar el mismo peso a cada grupo. Son dos decisiones distintas.

Promedio de RMSE y RMSE OOF: qué resumen

Dos pliegues de igual tamaño: $\mathrm{MSE}_1 = 1$ y $\mathrm{MSE}_2 = 9$.

MSE: error cuadrático medio (*Mean Squared Error*).

Promedio de RMSE

$$\frac{\sqrt{1} + \sqrt{9}}{2} = \frac{1+3}{2} = 2.$$

Calcula la raíz en cada pliegue y luego promedia. Cada **pliegue** pesa igual.

RMSE OOF

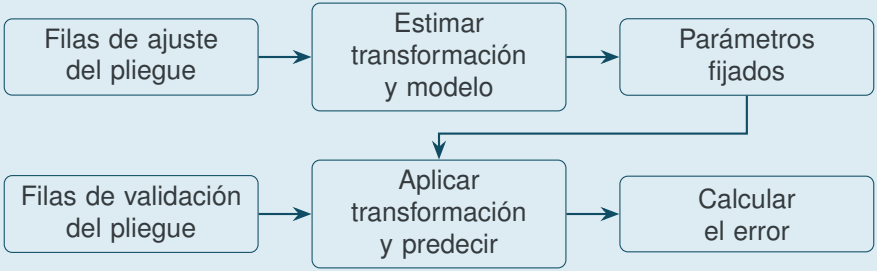
$$\sqrt{\frac{1+9}{2}} = \sqrt{5} \approx 2.236.$$

Reúne los errores cuadrados y luego toma una raíz. Cada **observación** pesa igual.

La raíz es no lineal: el orden de las operaciones puede cambiar el resultado.

Ambos son válidos, pero no intercambiables. Aquí seleccionamos con RMSE OOF: 2.236 **en este ejemplo.**

La receta completa se reaprende en cada ajuste

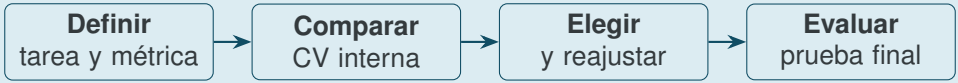


En el candidato cuadrático: estandarizar entradas, expandir términos, estandarizar términos y ajustar ridge.

La validación recibe las escalas ya estimadas; no vuelve a calcularlas con sus propias filas.

Así evitamos fuga de datos (*data leakage*): las escalas se aprenden sin usar el pliegue reservado para validar.

Un protocolo fijado antes de comparar



- Siete candidatos; cinco pliegues por composición; 35 ajustes de CV.
- Menor RMSE OOF; empate numérico exacto según orden declarado.
- MAE y R^2 describen; no reemplazan el criterio a posteriori.
- Prueba reservada y referencia de la media definida desde el inicio.

Material para seguir los ejemplos

Guardar los dos scripts y los dos CSV en **una misma carpeta**.

Utilizar el **editor o entorno de su preferencia**. Ambos códigos desarrollan el mismo recorrido.

Python	**R**
`38_evaluacion_seleccion.py`	`38_evaluacion_seleccion.R`

Datos comunes: `hormigon_s38.csv` y `spam_s38.csv`.

Seguir los tramos numerados en orden, comenzando por 00, para interpretar cada resultado antes de continuar.

Seguir una predicción hasta su origen

Python · sección 03

```python
for k in range(1, 6):
    valida = folds == k
    ajuste = clone(modelo).fit(
        x.loc[~valida], y[~valida])
    oof[valida] = ajuste.predict(
        x.loc[valida])
rmse = np.sqrt(np.mean((y-oof)**2))
```

R · sección 03

```r
for (k in 1:5) {
  valida <- entrenamiento$fold == k
  ajuste <- ajustar_regresion(nombre,
    x[!valida, ], y[!valida])
  oof[valida] <- predecir_regresion(
    ajuste, x[valida, ])
}
rmse <- sqrt(mean((y-oof)^2))
```

Las transformaciones se aprenden dentro del ajuste. Los pliegues conservan composiciones completas.

Misma operación en ambos lenguajes: predecir sin usar el pliegue de la observación para ajustar.

Leer el ranking sin perder las unidades

Candidato	RMSE OOF (MPa)	MAE OOF (MPa)
Cuadrática, $\alpha = 0.1$	**8.229**	**6.234**
Cuadrática, $\alpha = 1$	8.308	6.260
Cuadrática, $\alpha = 10$	8.489	6.390
Cuadrática, $\alpha = 100$	9.640	7.638
Regresión lineal	10.560	8.426
Cuadrática, $\alpha = 1000$	13.051	10.595
Media de entrenamiento	16.746	13.631

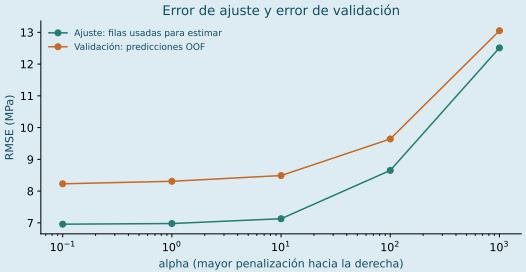
Cómo leerla

Menor RMSE OOF elige el candidato. MAE describe otra dimensión del error.

La media muestra cuánto aporta usar los predictores.

Gana $\alpha = 0.1$, pero la ventaja sobre $\alpha = 1$ es solo 0.079 MPa. Elegir no prueba superioridad estable.

Curva de validación: leer ambos errores



Tres valores de la cuadrícula
RMSE en MPa; R y Python.

α	Ajuste	OOF
0.1	6.958	8.229
10	7.130	8.489
1000	12.511	13.051

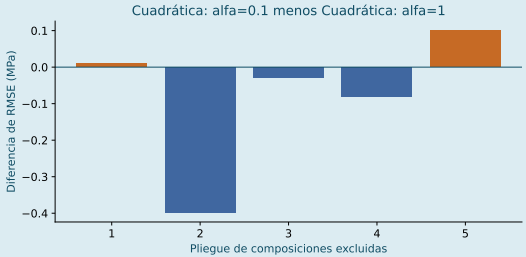
Con $\alpha = 1000$ aumentan ambos errores: la penalización restringe demasiado el ajuste en esta comparación.

Elegimos con OOF. La brecha con ajuste describe optimismo dentro de muestra; una curva en U no está garantizada.

La diferencia no es idéntica en cada pliegue

RMSE por pliegue (MPa)

Pliegue	$\alpha = 0.1$	$\alpha = 1$
1	7.110	7.099
2	7.670	8.069
3	8.806	8.836
4	9.320	9.401
5	8.058	7.957



$\alpha = 0.1$ mejora en tres pliegues, pero empeora en dos. Bajo cero favorece 0.1; sobre cero, 1.

Los ajustes comparten datos. Cinco diferencias de pliegues no son cinco réplicas independientes ni un intervalo de confianza.

Una regla de elección no prueba superioridad

Lo que decide la regla

$\alpha = 0.1$: 8.229 MPa.
$\alpha = 1$: 8.308 MPa.

La menor cifra elige el primer candidato.

Lo que no establece

Una diferencia de unos 0.079 MPa no acredita una ventaja estable en otros datos.

El ganador está en el borde de la cuadrícula; no prueba un óptimo global.

Si queremos preferir simplicidad dentro de una tolerancia, esa regla también debe fijarse antes de comparar.

Reajustar significa volver a estimar

Python · sección 05

```python
ganador = ranking.modelo.iloc[0]
modelo_final = clone(modelos[ganador])
modelo_final.fit(
    entrenamiento[variables],
    entrenamiento.resistencia)
pred_prueba = modelo_final.predict(
    prueba[variables])
```

R · sección 05

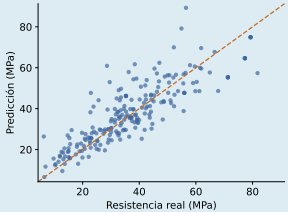
```r
ganador <- ranking$modelo[1]
modelo_final <- ajustar_regresion(
  ganador, entrenamiento[variables],
  entrenamiento$resistencia)
pred_prueba <- predecir_regresion(
  modelo_final, prueba[variables])
```

Reaprender escalas y coeficientes con las 806 filas; predecir las 224 reservadas con ese único ajuste.

No promediamos los cinco modelos de CV: ese sería otro procedimiento.

La evaluación final se expresa en MPa

Procedimiento	RMSE	MAE	R^2
Cuadrática, $\alpha = 0.1$	**8.823**	**6.494**	**0.716**
Media de entrenamiento	16.605	12.826	-0.007

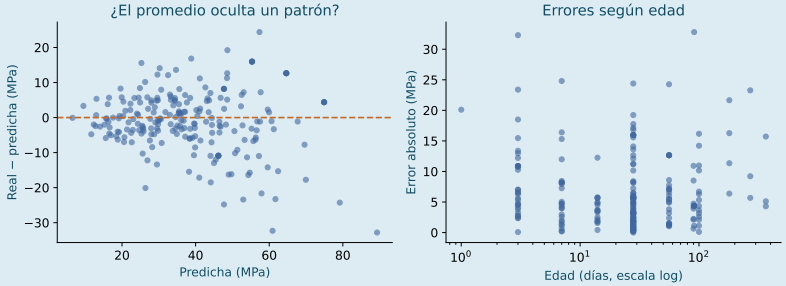


224 observaciones de prueba. R y Python coinciden en las cifras mostradas; RMSE y MAE están en MPa.

El RMSE baja 46.9 % frente a la media de entrenamiento. La diagonal representa predicción perfecta.

RMSE resume el error; no es una cota para cada caso. Esta mejora corresponde a la prueba por composición.

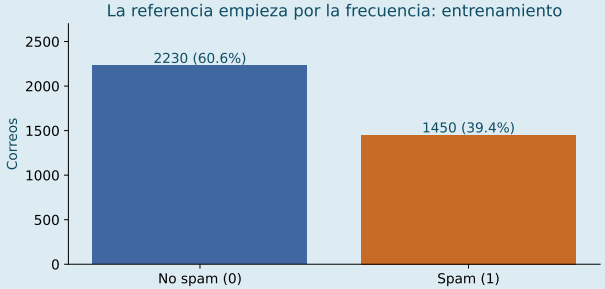
Una cifra promedio no reemplaza el diagnóstico



Residuos positivos indican subestimación. Los gráficos permiten localizar errores grandes y patrones que un promedio oculta.

Elegimos con validación y evaluamos en prueba. Los residuos muestran límites que el RMSE global puede ocultar.

Clasificación: misma lógica, otras preguntas



Caso: detectar spam

$y = 1$: spam.

$y = 0$: correo legítimo.

4601 correos; 57 entradas numéricas: frecuencias de palabras, caracteres y medidas de mayúsculas.

Conservamos la separación entre seleccionar y evaluar. Ahora distinguimos calidad de las probabilidades y costo de decidir.

Spambase, UCI, Hopkins et al. (1999), DOI 10.24432/C53G6X. Corpus histórico; no es una prueba de un filtro actual.

Dos errores con consecuencias diferentes

Falso positivo: FP

El correo es legítimo y lo marcamos como spam.

Consecuencia: ocultar un mensaje que el usuario necesitaba recibir.

Falso negativo: FN

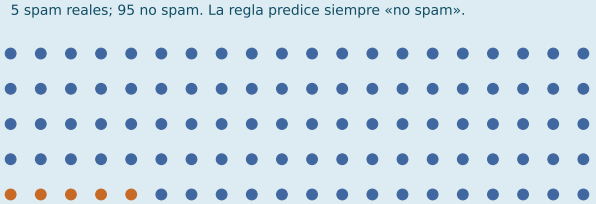
El correo es spam y lo dejamos pasar.

Consecuencia: ruido y trabajo adicional en la bandeja de entrada.

La matriz de confusión conserva estos conteos; la métrica decide cuánto pesa cada uno.

Contar errores sin distinguir su tipo supone que equivocarse cuesta lo mismo en ambos sentidos.

Un porcentaje alto de aciertos puede ser insuficiente



La regla “siempre no spam” acierta 95 de 100 correos, pero detecta **0 de los 5 spam**.

Accuracy = 95 % describe los aciertos. No demuestra que resolvamos la tarea de detectar spam.

Ejemplo hipotético con 5 % de spam; no es la proporción de Spambase.

La métrica puede expresar el costo del error

Supongamos un costo de **5 unidades por FP** y **1 por FN**. Los aciertos tienen costo cero.

$$\widehat{C} = \frac{5\,\mathrm{FP} + \mathrm{FN}}{n}.$$

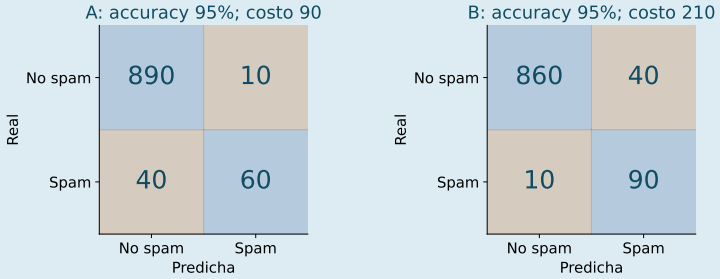
Bloquear correo legítimo	Dejar pasar spam
5 unidades por caso	1 unidad por caso

Multiplicaremos $\widehat{C}$ por 1000 para comparar costos en una escala común, aunque cambie el tamaño del conjunto.

La razón 5:1 representa una prioridad elegida antes de comparar. Si cambia esa prioridad, puede cambiar la regla preferida.

Costos hipotéticos para el ejemplo; no son costos medidos en UCI.

Mismos aciertos, decisiones de distinto valor



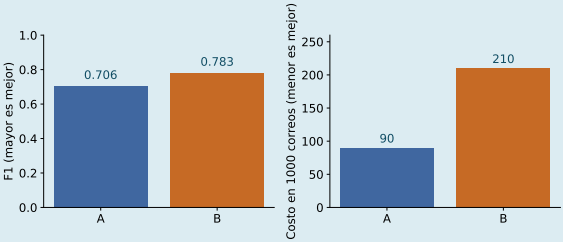
A: $5(10) + 40 = 90$.

B: $5(40) + 10 = 210$.

Ambos aciertan 95 %. Con los costos fijados, preferimos A porque bloquea menos correos legítimos.

Ejemplo hipotético: 1000 correos, 100 spam. Filas reales, columnas predichas; orden 0,1.

F1 y costo pueden preferir modelos distintos



$$\text{Precision} = \text{VP}/(\text{VP} + \text{FP}); \quad \text{Recall} = \text{VP}/(\text{VP} + \text{FN}).$$

$$F_1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}}.$$

F1 favorece B en este ejemplo. No incorpora la razón de costos 5:1; no sustituye nuestra función de costo.

Tres preguntas para las mismas probabilidades

Ejemplo: un filtro asigna probabilidad de spam a tres correos.

Correo A: 0.90	Correo B: 0.60	Correo C: 0.20

¿Qué revisar primero?
A, luego B, luego C.

Evaluamos si los spam reales suelen quedar antes que los legítimos.

¿Es fiable el 0.90?
Entre muchos correos con esa probabilidad, esperamos cerca de 90 % de spam.

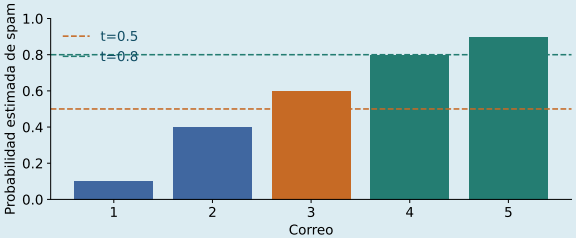
Contrastamos probabilidades con lo observado.

¿Cuáles bloquear?
Con $t = 0.80$: solo A.
Con $t = 0.50$: A y B.

Evaluamos los FP, los FN y el costo de esa decisión.

Ordenar bien, estimar bien una probabilidad y decidir bien son objetivos distintos. Una sola métrica no responde las tres preguntas.

El umbral convierte una probabilidad en una acción



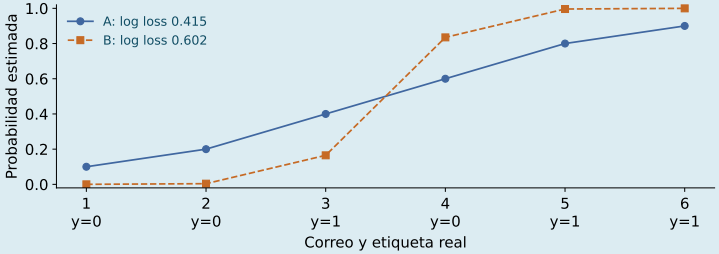
$$\widehat{y}_i(t) = 1 \text{ si } \widehat{p}_i \geq t, \qquad 0 \text{ en otro caso.}$$

Subir el umbral exige más evidencia para bloquear: pueden disminuir FP y aumentar FN.

Cambiar t cambia las decisiones, aunque el modelo y sus probabilidades permanezcan iguales. El umbral también se selecciona.

Probabilidades hipotéticas. Con $t = 0.5$ se marcan 3 correos; con $t = 0.8$, se marcan 2.

Ordenar igual no significa estimar igual

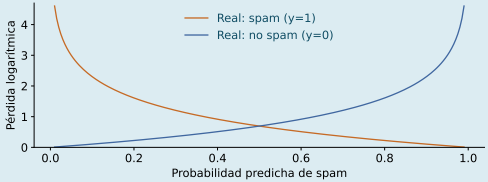


Ambas series ordenan los correos igual, pero asignan probabilidades distintas. El orden no cambia al aumentar la certeza.

B expresa más certeza, incluso cuando se equivoca. La calidad de esa certeza requiere otra evaluación.

Ejemplo hipotético. Log loss: A = 0.415; B = 0.602. Se define a continuación.

Log loss: penalizar probabilidades equivocadas



$$\text{LogLoss} = -\frac{1}{n}\sum_{i}\left[y_i \log \widehat{p}_i + (1 - y_i)\log(1 - \widehat{p}_i)\right].$$

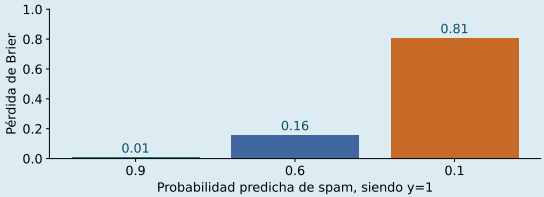
Pérdida logarítmica, o entropía cruzada binaria; usamos logaritmo natural. Menor es mejor.

Para un spam real ($y = 1$), predecir 0.9 aporta 0.105; predecir 0.1 aporta 2.303.

Asignar probabilidad casi cero a lo que ocurrió recibe una penalización grande. Importa la probabilidad completa, no solo la clase.

Brier: error cuadrático de una probabilidad

$$\text{Brier} = \frac{1}{n}\sum_i (y_i - \hat{p}_i)^2.$$



Con $y_i \in \{0, 1\}$, el score binario está entre 0 y 1. Menor es mejor.

Para $y = 1$, predecir 0.9 aporta 0.01; predecir 0.1 aporta 0.81.

Log loss y Brier valoran probabilidades. Sus penalizaciones son distintas y ninguno mide solo calibración.

Qué debería significar una probabilidad de 0.8

Correos con probabilidades cercanas a 0.8



Esperamos cerca de 80 % de spam
si las probabilidades están bien calibradas

La calibración compara probabilidades predichas con frecuencias observadas en conjuntos de casos similares.

No significa que cada grupo de diez tenga exactamente ocho spam. La muestra introduce variación.

Esquema ilustrativo de calibración; no son diez observaciones del corpus.

ROC y precision–recall miran aspectos diferentes

ROC: *Receiver Operating Characteristic*, curva característica operativa del receptor.

Curva ROC
Eje vertical: recall o sensibilidad, $\mathrm{VP}/(\mathrm{VP}+\mathrm{FN})$.

Eje horizontal: tasa de falsos positivos, $\mathrm{FP}/(\mathrm{FP}+\mathrm{VN})$.

Curva precision–recall (PR)
Eje vertical: precision, $\mathrm{VP}/(\mathrm{VP}+\mathrm{FP})$.

Eje horizontal: recall. En ambas curvas, cada punto corresponde a un umbral.

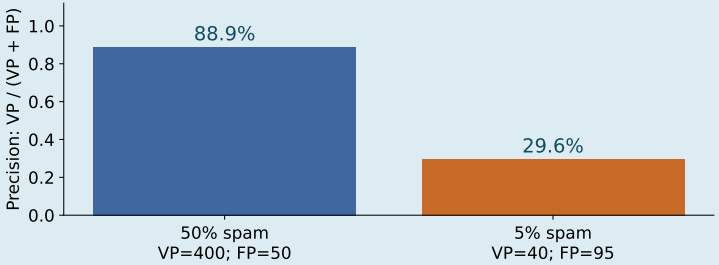
AUC (*Area Under the Curve*) significa área bajo la curva. **ROC AUC** resume el área bajo ROC.

AP (*average precision*) resume PR ponderando precision por los incrementos de recall.

ROC AUC y AP describen el ranking; no fijan un umbral ni certifican calibración. AP depende de la proporción de positivos.

La frecuencia de spam cambia la precision

Misma sensibilidad = 80 % y misma tasa de FP = 10 %, en 1000 correos:



Si hay pocos spam, los negativos son muchos: incluso una tasa de FP pequeña puede producir numerosos falsos avisos.

El desempeño útil depende también de la población. Una precision medida en un corpus no se traslada automáticamente a otro.

Un protocolo para probabilidades y decisiones

1. Reservar **921 correos** para prueba; usar 3680 para ajuste y selección.
2. Comparar tres candidatos por **log loss OOF**, con cinco pliegues.
3. En el ganador, elegir $t \in \{0.05, 0.10, \ldots, 0.95\}$ por menor costo OOF.
4. Reajustar y evaluar una vez el modelo y umbral elegidos.

Primero calidad probabilística, después decisión. Este protocolo no busca conjuntamente el menor costo entre todos los modelos y umbrales.

Entradas idénticas se conservan en el mismo grupo y partición. Empates: orden declarado de modelos; mayor umbral.

Los candidatos son instrumentos de comparación

Frecuencia
Probabilidad constante: proporción de spam en las filas de ajuste.

Referencia sin usar los predictores.

Regresión logística
Escala aprendida dentro del ajuste y penalización fija, $C = 1$.

C regula la penalización: menor C, mayor penalización.

Bosque aleatorio
Promedio de 150 árboles; profundidad máxima 8; mínimo 5 casos por hoja.

R usa ranger y Python scikit-learn para el bosque. Mismo protocolo; las implementaciones pueden producir probabilidades distintas.

En código: una probabilidad OOF por correo

Python · sección 08

```python
for k in range(1, 6):
    valida = tr.fold.to_numpy() == k
    ajuste = clone(recipe).fit(
        x.loc[~valida], y[~valida])
    p[valida] = ajuste.predict_proba(
        x.loc[valida])[:, 1]
error = log_loss(y, p)
```

R · sección 08

```r
for (k in 1:5) {
  valida <- tr$fold == k
  ajuste <- ajustar_clasificador(nombre,
    x[!valida, ], y[!valida])
  p[valida] <- predecir_probabilidad(
    ajuste, x[valida, ])
}
error <- probabilisticas(y, p)$log_loss
```

En ambos casos obtenemos la probabilidad de spam ($y = 1$).

La selección utiliza probabilidades fuera de ajuste; las etiquetas de prueba permanecen reservadas.

La regla fijada elige por calidad probabilística

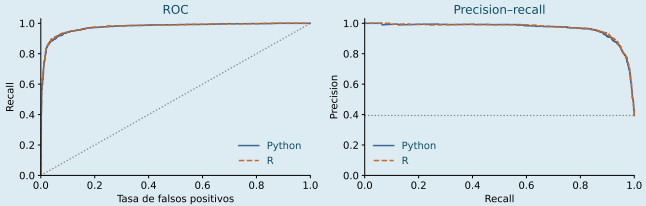
Validación OOF: 3680 correos. En ambas métricas, menor es mejor.

Candidato	Log loss Python	Log loss R	Brier Python	Brier R
Frecuencia	0.671	0.671	0.239	0.239
Logística ($C = 1$)	0.275	0.275	0.075	0.075
Bosque (prof. 8)	**0.228**	**0.223**	**0.061**	**0.060**

El bosque obtiene el menor log loss en ambas versiones. La frecuencia es la referencia para valorar el aporte de los predictores.

Log loss selecciona; Brier describe. Elegimos el bosque, pero aún falta revisar calibración y decidir el umbral.

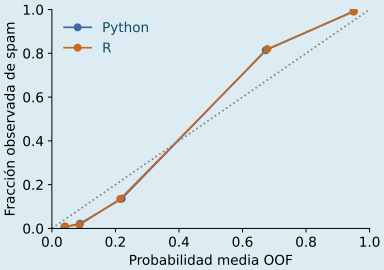
Cómo ordena el ganador los correos



Versión	ROC AUC	AP
Python	0.975	0.966
R	0.976	0.967

AUC de 0.975 no significa 97.5 % de aciertos: resume ordenamiento sobre múltiples umbrales.

Una AUC alta no garantiza calibración



Cuarto quintil

736 correos por versión.

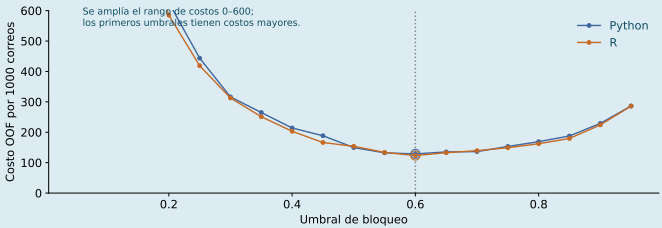
Versión	Prob. media	Fracción spam
Python	0.673	0.814
R	0.678	0.819

Predice 67–68 %; observamos 81–82 % de spam. Subestima en este rango.

Bajo la diagonal sobreestima; sobre ella subestima. Cada curva resume cinco grupos de probabilidades OOF.

Un buen ranking no garantiza probabilidades calibradas. Recalibrar cambia la receta y exige validación.

Elegimos el umbral usando el costo en validación



Cerca del mínimo
Costo OOF por 1000 correos.

Umbral	Python	R
0.55	132.3	133.7
0.60	**128.8**	**123.4**
0.65	135.3	132.9

Entre los 19 umbrales ensayados, ambos eligen $t = 0.60$. La tabla muestra el mínimo y sus vecinos.

Las probabilidades son las mismas al variar el umbral. Cambian las decisiones; el mínimo usado para elegir aún necesita prueba.

El mismo modelo, otra combinación de errores

Versión	Umbral	FP	FN	Aciertos (%)	Costo por 1000
Python	0.50	74	181	93.1	149.7
Python	**0.60**	**44**	**254**	**91.9**	**128.8**
R	0.50	78	176	93.1	153.8
R	**0.60**	**41**	**249**	**92.1**	**123.4**

Python: 30 FP menos y 73 FN más. Ahorro: $5 \times 30 - 73 = 77$ unidades.

R: 37 FP menos y 73 FN más. Ahorro: $5 \times 37 - 73 = 112$ unidades.

Baja el porcentaje de aciertos, pero también baja el costo: evitamos errores que pesan más, según la razón 5:1.

Los costos también sugieren un umbral teórico

Si $p = P(Y = 1 \mid x)$ es la probabilidad correcta:

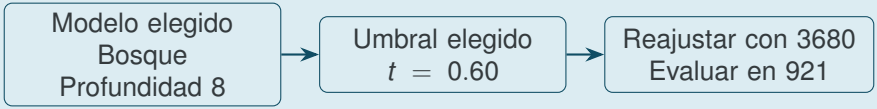
Bloquear	**Dejar pasar**
Costo esperado $= 5(1 - p)$.	Costo esperado $= p$.

$$5(1 - p) < p \quad \Longleftrightarrow \quad p > \frac{5}{6} \approx 0.833.$$

El umbral empírico puede diferir: probabilidades imperfectas, muestra finita y una cuadrícula de búsqueda finita.

La fórmula supone probabilidades correctas, costos conocidos y aciertos sin costo. No reemplazamos el umbral elegido después de mirar prueba.

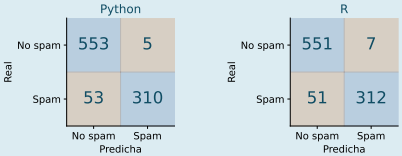
La regla completa queda cerrada antes de prueba



La referencia de decisión deja pasar todos los correos. No comete FP, pero no detecta ningún spam.

Prueba evalúa el procedimiento completo: preprocesamiento, modelo, umbral y costos declarados.

Qué obtiene la regla en datos reservados

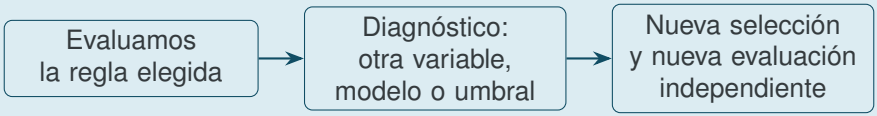


Versión	Log loss	Brier	Aciertos (%)	Precision (%)	Recall (%)	Costo por 1000
Python	0.194	0.0502	93.7	98.4	85.4	84.7
R	0.192	0.0497	93.7	97.8	86.0	93.4

Iguales aciertos; distinto costo por la combinación de FP y FN.

La referencia “siempre no spam” cuesta 394.1 por 1000. La mejora evalúa la regla cerrada en este corpus.

Cambiar la receta después de prueba cambia la evidencia



La prueba anterior ayuda a formular una hipótesis, pero ya no queda intacta para confirmar el rediseño.

La regla es la misma para resistencia y spam: el desempeño usado para elegir no reemplaza una evaluación independiente.

Referencias y material para reproducir la sesión

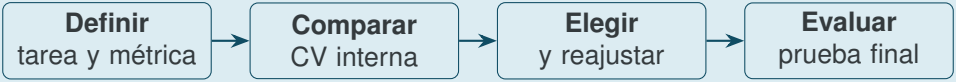
- Yeh (1998). *Concrete Compressive Strength*. UCI, DOI 10.24432/C5PK67.
- Hopkins et al. (1999). *Spambase*. UCI, DOI 10.24432/C53G6X. Ambos conjuntos: CC BY 4.0.
- James et al. (2021). *An Introduction to Statistical Learning*, caps. 2, 5 y 6. statlearning.com.
- Scikit-learn: métricas, calibración, selección del umbral y validación cruzada.

Dos archivos completos: uno en R y otro en Python. Cada uno reproduce regresión y clasificación con los datos incluidos.

¿Cómo evaluamos y seleccionamos modelos?

Evaluar: ¿qué error esperamos?
Predecir casos fuera del ajuste, medir con una métrica acorde al uso y comparar con una referencia.

Seleccionar: ¿qué receta usar?
Comparar candidatos en la misma validación, aplicar el criterio fijado y reajustar la receta elegida.



Hormigón: elegir por RMSE.
Spam: elegir probabilidades por log loss y umbral por costo.

La validación orienta la elección. La prueba reservada estima el desempeño de la elección final.

Recomendaciones para elegir y evaluar bien

1. Definir el criterio
Fijar métrica principal y referencia.
Distinguir probabilidades de decisiones en clasificación.

2. Validar sin fuga
Respetar grupos o tiempo.
Aprender las transformaciones solo con las filas de ajuste.

3. Cerrar la receta
Fijar modelo, transformaciones, hiperparámetros y umbral.
Reajustar con entrenamiento.

4. Valorar la mejora
Considerar magnitud y estabilidad.
Ante resultados similares, considerar simplicidad y costo.

Seleccionar con validación; evaluar la elección en prueba; comunicar el resultado con su referencia y sus límites.