

Aprendizaje Automático

Evaluación estadística de modelos predictivos y bootstrap

Selección, incertidumbre y comparación

Pedro Luiz Ramos

Diplomado en Ciencia de Datos

Una diferencia observada no basta

Ejemplo hipotético: dos modelos evaluados en los mismos casos.

Modelo	Log loss
Logística simple	0.30
Logística amplia	0.28

La reducción observada de log loss es $0.30 - 0.28 = 0.02$.

- Otra muestra de evaluación podría producir una diferencia distinta.
- Una mejora pequeña puede ser relevante o no, según el objetivo.

Evaluar también significa cuantificar la incertidumbre.

Entrenamiento, validación y prueba

Conjunto	Uso
Entrenamiento	Ajustar coeficientes, escalas y otras partes del modelo.
Validación	Elegir variables, hiperparámetros y umbral de decisión.
Prueba	Evaluar la receta que ya quedó definida.

La validación puede ser un conjunto fijo o realizarse mediante validación cruzada dentro del entrenamiento.

Si cambiamos la receta mirando prueba, deja de ser una evaluación final independiente.

Wisconsin: una partición conocida

Conservamos los datos y la partición de las clases anteriores:

$$569 = \underbrace{398}_{\text{entrenamiento}} + \underbrace{171}_{\text{prueba}} .$$

En una validación cruzada de cinco pliegues, uno de 80 casos valida y los otros 318 ajustan el modelo.

- Después de seleccionar, se reajusta con los 398 casos.
- Los 171 de prueba no participan en esos ajustes.

Esta prueba ya fue mostrada: aquí la reutilizamos como demostración docente.

Validación cruzada: cinco ajustes

	Pliegue 1	Pliegue 2	Pliegue 3	Pliegue 4	Pliegue 5
1	**Validar**	Ajustar	Ajustar	Ajustar	Ajustar
2	Ajustar	**Validar**	Ajustar	Ajustar	Ajustar
3	Ajustar	Ajustar	**Validar**	Ajustar	Ajustar
4	Ajustar	Ajustar	Ajustar	**Validar**	Ajustar
5	Ajustar	Ajustar	Ajustar	Ajustar	**Validar**

Cada fila recibe una predicción fuera de pliegue: **OOF**. La prueba reservada queda fuera de los cinco ajustes.

Seleccionar con OOF no convierte el resultado del ganador en una evaluación independiente.

La receta completa se ajusta dentro del pliegue

Incorrecto	Correcto
Estandarizar toda la base antes de separar.	Estimar media y escala solo con las filas de ajuste.
Elegir variables con las etiquetas de prueba.	Seleccionar dentro del entrenamiento y validación.
Escoger el mejor umbral en prueba.	Fijar el umbral antes de la evaluación final.

El bootstrap no corrige una fuga de datos que ocurrió antes.

La métrica depende de la pregunta

Pregunta	Métrica
¿Qué tan buenas son las probabilidades?	Log loss o Brier: menor es mejor.
¿Qué ocurre con una decisión y un umbral?	Exactitud, sensibilidad, precisión o costo.
¿Cuánto se equivoca en una respuesta continua?	MAE o RMSE: menor es mejor.

No cambiamos la métrica principal por la columna que favorece al modelo.

MAE y RMSE: una cuenta sencilla

Predicciones hipotéticas para una respuesta continua:

Caso	Observado y	Predicho $\widehat{y}$	Error $e = y - \widehat{y}$
1	10	9	1
2	20	22	-2
3	30	27	3
4	40	44	-4
5	50	45	5

$$MAE = \frac{1+2+3+4+5}{5} = 3, \quad RMSE = \sqrt{\frac{1+4+9+16+25}{5}} = \sqrt{11} \approx 3.317.$$

Ambas quedan en las unidades de la respuesta; RMSE da más peso a errores grandes.

Log loss: usar la probabilidad de la clase real

Ejemplo independiente: probabilidades de clase 1 y clases observadas.

$$LL = -\frac{1}{n}\sum_i \left[y_i \log(p_i) + (1-y_i)\log(1-p_i)\right].$$

Clase real	Probabilidad de la clase real	Pérdida
0	$1 - 0.10 = 0.90$	$-\log(0.90) = 0.1054$
0	$1 - 0.40 = 0.60$	$-\log(0.60) = 0.5108$
1	0.35	$-\log(0.35) = 1.0498$
1	0.80	$-\log(0.80) = 0.2231$

$$LL = (0.1054 + 0.5108 + 1.0498 + 0.2231)/4 \approx 0.4723.$$

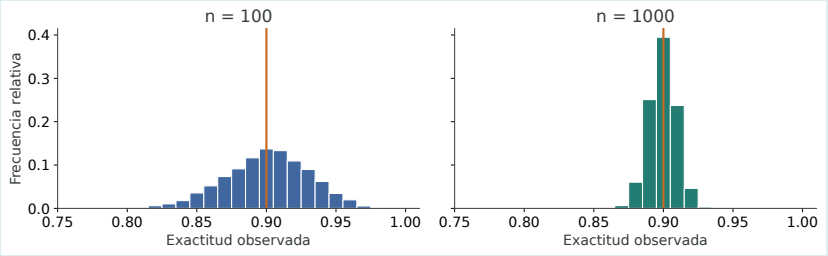
Seleccionar y evaluar son tareas distintas

1. Definir la unidad de separación y la métrica relevante.
2. Seleccionar la receta con entrenamiento y validación.
3. Reajustar la receta elegida con todo el entrenamiento disponible.
4. Evaluar en prueba sin volver a elegir.
5. Cuantificar la incertidumbre de esa evaluación.

Hoy profundizamos en el quinto paso y en la comparación de recetas ya definidas.

La exactitud cambia entre muestras

Simulación: probabilidad de acierto fija en 0.90; casos independientes.



Con más casos de evaluación, las exactitudes observadas se concentran más cerca de 0.90.

El modelo no cambió; cambiaron los casos con que lo evaluamos.

El mismo 90 % puede tener distinta precisión

Aproximación para aciertos independientes de un clasificador fijo:

$$SE(\widehat{a}) \approx \sqrt{\frac{\widehat{a}(1-\widehat{a})}{n}}.$$

Resultado	Exactitud	SE	Intervalo normal aprox.
90 de 100	0.90	$\sqrt{0.09/100} = 0.030$	$[0.841,\ 0.959]$
900 de 1000	0.90	$\sqrt{0.09/1000} = 0.0095$	$[0.881,\ 0.919]$

El intervalo se calculó como $\widehat{a} \pm 1.96\, SE$.

Estos intervalos son aproximados; la dependencia entre casos exige otro análisis.

Desviación estándar y error estándar

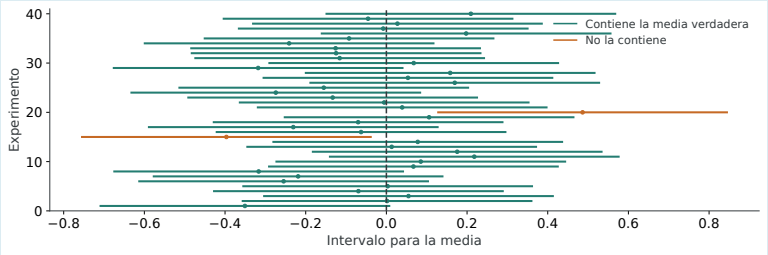
Cantidad	Qué varía
Desviación estándar de los datos	Diferencias entre observaciones.
Error estándar de una estimación	La media, log loss u otra estadística al cambiar la muestra.

Podemos tener compras muy distintas entre sí y estimar su media con bastante precisión si tenemos muchas observaciones independientes.

El error estándar no describe cuán diferentes son los casos individuales.

Qué significa un intervalo de confianza

40 muestras normales: $n = 30$, media 0 y desviación conocida 1.



Aquí 38 de 40 intervalos contienen la media verdadera.

En repetición, el procedimiento tiene cobertura 95 %; no todos los intervalos deben contener el parámetro.

Los modelos se comparan en los mismos casos

Un caso difícil puede hacer que ambos modelos fallen; uno fácil puede favorecer a ambos.

Caso	Clase real	Modelo A	Modelo B
1	1	0.80	0.90
2	0	0.20	0.15
3	1	0.40	0.45
4	0	0.60	0.55

Las dos columnas están **emparejadas por observación**.

Para comparar, conservamos ese emparejamiento al remuestrear.

La variabilidad entre pliegues no es un IC

Supongamos cinco RMSE: $3,\ 4,\ 2,\ 5,\ 6$.

$$\overline{RMSE} = 4, \qquad s_{\text{pliegues}} = \sqrt{10/4} \approx 1.581.$$

- El desvío describe diferencias entre esas cinco evaluaciones.
- Los modelos de los pliegues comparten gran parte del entrenamiento.
- No tratamos los cinco resultados como cinco muestras independientes.

Media $\pm$ desvío no es un intervalo de confianza del 95 %.

Qué incertidumbre queremos estudiar

Pregunta	Qué debe cambiar
¿Cuánto varía la evaluación de este modelo fijo?	Los casos de evaluación, manteniendo el modelo.
¿Cuánto varía el modelo si lo vuelvo a entrenar?	Los datos de entrenamiento y el proceso de ajuste.

La práctica principal estudiará la primera pregunta. En validación cruzada se reajusta en cada pliegue; en este bootstrap se mantienen las predicciones fijas.

Un intervalo puede ser correcto para una pregunta y no responder la otra.

AIC: equilibrar ajuste y complejidad

Agregar variables puede mejorar el ajuste dentro del entrenamiento, aunque no mejore las predicciones futuras.

$$AIC = -2\ell(\widehat{\theta}) + 2p.$$

- $\ell(\widehat{\theta})$: log-verosimilitud maximizada.
- p: número de parámetros estimados, incluido el intercepto.
- -2ℓ: recompensa el ajuste; $2p$ penaliza la complejidad.

Entre modelos comparables, un AIC menor es preferible.

Verosimilitud y número de parámetros

Para una logística con observaciones independientes:

$$\ell = \sum_i \left[y_i \log(p_i) + (1 - y_i) \log(1 - p_i) \right].$$

En los cuatro casos del ejemplo, $\ell \approx -1.8892$ y $LL = -\ell/4 \approx 0.4723$. Una logística con intercepto y dos predictores numéricos lineales estima tres coeficientes:

$$\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2, \qquad p = 3.$$

Contamos parámetros, no solo nombres de variables; factores e interacciones pueden agregar varios.

AIC: ejemplo resuelto

Tres modelos hipotéticos, ajustados por máxima verosimilitud a los mismos $n = 100$ casos:

Modelo	ℓ	p	Cuenta
A	-80	3	$-2(-80) + 2(3) = 166$
B	-76	5	$-2(-76) + 2(5) = 162$
C	-75.5	8	$-2(-75.5) + 2(8) = 167$

C tiene la mayor log-verosimilitud, pero B tiene el menor AIC.

La mejora de ajuste de C no compensa su mayor número de parámetros según AIC.

BIC: la penalización depende de n

El criterio de información bayesiano usa la misma log-verosimilitud:

$$BIC = -2\ell(\widehat{\theta}) + p\log(n).$$

- n: cantidad de observaciones usadas en el ajuste.
- p: parámetros estimados, incluido el intercepto.
- AIC suma $2p$; BIC suma $p\log(n)$, con logaritmo natural.

Con $n = 100$, cada parámetro cuesta $\log(100) \approx 4.605$ en BIC, frente a 2 en AIC.

Entre modelos comparables, un BIC menor es preferible. Aquí penaliza más la complejidad.

BIC: el mismo ejemplo resuelto

Con los mismos modelos A, B y C y $n = 100$:

Modelo	ℓ	p	Cuenta de BIC
A	-80	3	$160 + 3\log(100) \approx 173.82$
B	-76	5	$152 + 5\log(100) \approx 175.03$
C	-75.5	8	$151 + 8\log(100) \approx 187.84$

De A a B, -2ℓ mejora en 8, pero los dos parámetros adicionales cuestan $2\log(100) \approx 9.21$.

BIC favorece A: la mejora del ajuste no compensa su penalización adicional.

AIC y BIC pueden elegir distinto

Modelo	AIC	BIC
A	166	**173.82**
B	**162**	175.03
C	167	187.84

- AIC busca equilibrar ajuste y complejidad con un enfoque predictivo.
- BIC tiene una motivación de evidencia entre modelos, bajo supuestos; aquí favorece más la parsimonia.
- No comparamos un valor AIC con un valor BIC: miramos el mínimo dentro de cada columna.

No hay un ganador universal entre criterios. Si el objetivo es predecir, contrastamos con validación fuera del ajuste.

AIC y BIC son comparaciones relativas

En la columna AIC del ejemplo, el mínimo es 162:

$$\Delta AIC_A = 166 - 162 = 4, \quad \Delta AIC_B = 0, \quad \Delta AIC_C = 5.$$

- No existe un AIC o BIC absoluto que garantice un buen modelo.
- Todos los candidatos podrían predecir mal.
- Estos criterios no son exactitud ni un intervalo de confianza.
- Una diferencia de AIC no cuantifica por sí sola una mejora práctica.

Usamos un criterio definido para seleccionar candidatos; evaluamos predicciones fuera del ajuste.

Cuándo comparar AIC y BIC

- La misma respuesta y las mismas observaciones para todos los modelos.
- Verosimilitudes comparables y ajuste por máxima verosimilitud.
- La misma convención para calcular la log-verosimilitud.

En esta clase: logísticas **sin penalización** con distintos predictores. No aplicamos estos criterios habituales indiscriminadamente a SVM, Isolation Forest o logísticas penalizadas contando coeficientes como si nada cambiara.

El criterio de comparación tiene condiciones de uso.

Wisconsin: tres modelos comparables

Respuesta: $Y = 1$ maligno, $Y = 0$ benigno.

Modelo	Predictores	p
Simple	Radio y textura	3
Intermedio	Radio, textura y suavidad	4
Amplio	Radio, textura, suavidad y concavidad	5

Los tres modelos usan los mismos **398 casos de entrenamiento**. El intercepto está incluido; `id`, `conjunto` y `fold` no son predictores.

Las etiquetas y la partición se conservan de las clases anteriores. No es una aplicación diagnóstica.

Wisconsin: AIC y BIC en entrenamiento

Modelo	p	ℓ	AIC	BIC
Simple	3	-94.58	195.16	207.12
Intermedio	4	-57.82	123.63	139.58
Amplio	5	-50.15	110.29	130.22

$$AIC_{amplio} = -2(-50.1454) + 2(5) \approx 110.29,$$
$$BIC_{amplio} = -2(-50.1454) + 5\log(398) \approx 130.22.$$

Ambos criterios favorecen al amplio entre estos candidatos. Los 171 casos de prueba no intervienen.

AIC y BIC en R y Python

Los tres modelos ya están ajustados en entrenamiento.

R: `glm`

```r
AIC(modelo_simple,
    modelo_intermedio,
    modelo_amplio)

BIC(modelo_simple,
    modelo_intermedio,
    modelo_amplio)
```

Python: GLM binomial

```python
print(modelo_simple.aic)
print(modelo_intermedio.aic)
print(modelo_amplio.aic)

print(modelo_simple.bic_llf)
print(modelo_intermedio.bic_llf)
print(modelo_amplio.bic_llf)
```

Ambos programas usan máxima verosimilitud, sin penalización, y cuentan el intercepto.

En Python, `bic_llf` usa la definición basada en log-verosimilitud, igual que `BIC()` en R.

Bootstrap: remuestrear con reposición

Partimos de la **muestra observada**, no de toda la población.



Una remuestra produce una estadística. Las B estadísticas forman una única distribución bootstrap.

Bootstrap de una media: los datos

Cinco valores para ilustrar el procedimiento:

ID	1	2	3	4	5
Valor	2	4	5	7	8

$$\bar{x} = \frac{2+4+5+7+8}{5} = \frac{26}{5} = 5.2.$$

Queremos estudiar cuánto podría variar una estimación de la media al cambiar la muestra.

La muestra pequeña sirve para entender la cuenta; no garantiza intervalos bien calibrados.

Tres remuestras y sus cuentas

Siempre sorteamos cinco IDs, con reposición.

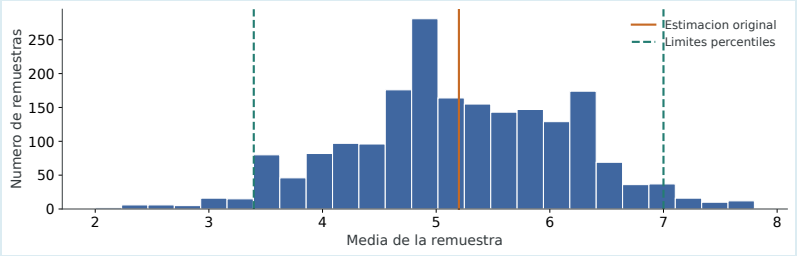
Remuestra	IDs sorteados	Valores	Media
1	$2, 2, 1, 5, 3$	$4, 4, 2, 8, 5$	$23/5 = 4.6$
2	$5, 5, 4, 3, 5$	$8, 8, 7, 5, 8$	$36/5 = 7.2$
3	$1, 1, 2, 3, 4$	$2, 2, 4, 5, 7$	$20/5 = 4.0$

La observación 2 aparece dos veces en la primera remuestra; la 4 no aparece.

El tamaño permanece en cinco, pero cambian los casos y sus multiplicidades.

La distribución bootstrap de la media

Resultados de R con $B = 2000$ remuestras de los cinco valores:



La línea continua indica la media original, 5.2. Las discontinuas delimitan el intervalo percentil.

El histograma muestra medias de remuestras, no los cinco datos originales.

Error estándar bootstrap: una cuenta

Solo para ilustrar, cinco estimaciones bootstrap: $4.6, 7.2, 4.0, 5.2, 6.0$.

$$\overline{\theta^*} = 5.4, \qquad SE_{boot} = \sqrt{\frac{\sum_{b=1}^{B}(\theta_b^* - \overline{\theta^*})^2}{B-1}}.$$

$$\sum(\theta_b^* - 5.4)^2 = 0.64 + 3.24 + 1.96 + 0.04 + 0.36 = 6.24.$$

$$SE_{boot} = \sqrt{6.24/4} \approx 1.249.$$

Con las **2000 remuestras del programa**, el resultado es 0.966.

Calculamos el desvío de las estimaciones bootstrap, no el desvío de los datos.

Intervalo percentil: dos cuantiles

Tomamos los percentiles 2.5 y 97.5 de las estimaciones bootstrap:

$$IC_{95\,\%,\,percentil} = [Q_{0.025}(\theta^*),\ Q_{0.975}(\theta^*)]\,.$$

Para la media del ejemplo, con 2000 remuestras en R:

$$\widehat{\mu} = 5.2, \qquad IC_{percentil} \approx [3.4,\ 7.0].$$

- Es un procedimiento sencillo de entender, no un intervalo exacto.
- La cobertura depende del tamaño de muestra y de la estadística.
- Existen otras construcciones, como BCa; no las desarrollamos aquí.

Remuestrear una media en R y Python

R

```r
valores <- c(2, 4, 5, 7, 8)
medias_boot <- numeric(B)
for (b in 1:B) {
  muestra <- sample(valores,
                    size = 5,
                    replace = TRUE)
  medias_boot[b] <- mean(muestra)
}
sd(medias_boot)
quantile(medias_boot,
         c(0.025, 0.975))
```

Python

```python
valores = np.array([2,4,5,7,8])
medias_boot = np.empty(B)
for b in range(B):
    muestra = rng.choice(
        valores, size=5,
        replace=True)
    medias_boot[b] = np.mean(muestra)

np.std(medias_boot, ddof=1)
np.quantile(medias_boot,
            [0.025, 0.975])
```

Más remuestras no significa más datos

Con las primeras remuestras de la misma ejecución en R:

B	SE_{boot}	IC percentil
100	1.029	[3.3, 7.4]
500	1.019	[3.4, 7.1]
2000	0.966	[3.4, 7.0]

- Aumentar B reduce el error Monte Carlo del cálculo.
- No elimina la incertidumbre debida a tener solo cinco casos originales.
- Una semilla permite repetir la ejecución, no garantiza validez estadística.

La unidad de remuestreo importa

Estructura de los datos	Unidad o esquema apropiado
Un caso independiente por fila	Remuestrear filas completas.
Varias mediciones por paciente	Remuestrear pacientes con sus mediciones.
Serie temporal	Usar un esquema que preserve dependencia, como bloques.

Sortear filas como si fueran independientes puede subestimar la incertidumbre.

Evaluar modelos ya ajustados

Comparamos la logística simple y la amplia, con probabilidades de malignidad para los mismos 171 casos.

1. Ajustar los modelos en los 398 registros de entrenamiento.
2. Obtener y conservar las probabilidades de prueba.
3. Remuestrear los casos de prueba con esas probabilidades fijas.
4. Recalcular AUC y log loss en las remuestras, no los coeficientes.

El bootstrap se hace en prueba, no en entrenamiento. No repetimos `glm`, `fit` ni `predict` dentro del ciclo.

Wisconsin: resultados puntuales de prueba

Modelo	AUC	Log loss	Exactitud	Sensibilidad
Simple	0.9394	0.2997	0.8596	0.7812
Amplio	0.9746	0.1833	0.9415	0.9062

- 171 casos: 107 benignos y 64 malignos.
- Exactitud y sensibilidad usan el umbral fijo 0.5.
- AUC usa el orden de las predicciones; log loss, sus probabilidades. No requieren elegir un umbral.

La prueba ya se revisó antes: estos resultados no son una validación independiente nueva.

Remuestrear la fila completa

Miniatura hipotética para mostrar el emparejamiento:

ID	Clase real	Prob. simple	Prob. amplia
11	0	0.10	0.15
22	1	0.65	0.80
33	0	0.40	0.30
44	1	0.55	0.70

Remuestra de IDs: $22, 22, 11, 44$.

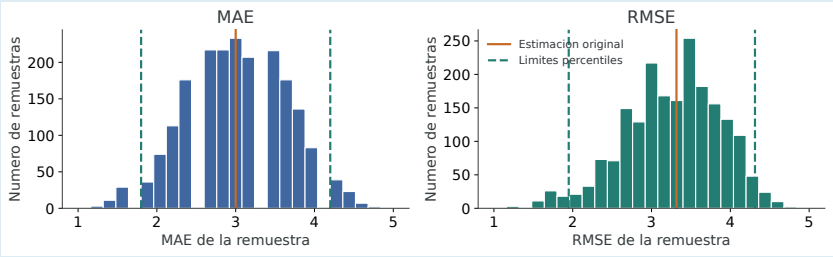
- Las dos copias de 22 conservan $y = 1$, $p_s = 0.65$ y $p_a = 0.80$.
- No sorteamos las etiquetas y las probabilidades por separado.

El caso, su respuesta y ambas predicciones viajan juntos.

Bootstrap de MAE y RMSE

Remuestreamos los cinco pares hipotéticos $(y_i, \widehat{y}_i)$ de la cuenta inicial:

$$MAE = 3, \qquad IC_{percentil} = [1.800,\ 4.200],$$
$$RMSE \approx 3.317, \quad IC_{percentil} = [1.949,\ 4.313].$$

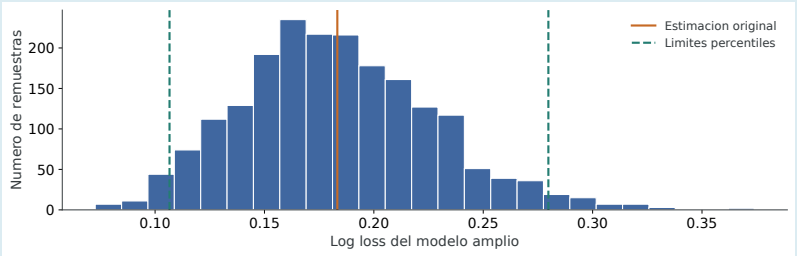


Recalculamos la raíz en cada remuestra. Son IC ilustrativos: solo hay cinco casos.

Log loss: incertidumbre de las probabilidades

Para el modelo amplio, con bootstrap por filas:

$$LL = 0.1833, \qquad IC_{percentil} \approx [0.1066,\ 0.2798].$$



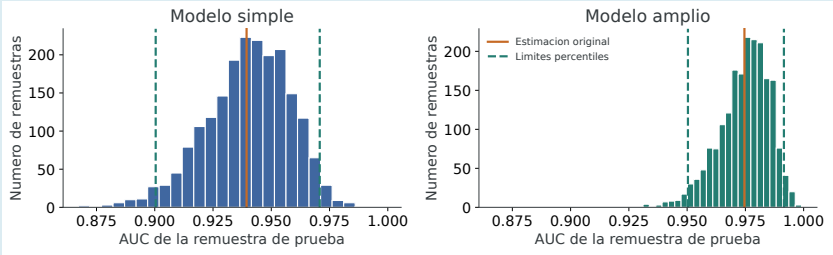
Errores con alta confianza pueden elevar mucho la pérdida de una remuestra.

No aplicamos log loss a puntajes de SVM o anomalía que no sean probabilidades.

AUC: distribución e intervalos bootstrap

Sorteamos con reposición 107 benignos y 64 malignos de **prueba**.

$$AUC_{simple} = 0.9394, \quad IC_{percentil} = [0.9004,\ 0.9708],$$
$$AUC_{amplio} = 0.9746, \quad IC_{percentil} = [0.9503,\ 0.9915].$$



Cada barra resume AUCs recalculadas. Los modelos y las predicciones permanecen fijos.

R: bootstrap de log loss con modelos fijos

```r
logloss_boot <- matrix(NA_real_, nrow = B, ncol = 2)
for (b in 1:B) {
  indices <- sample(1:n, size = n, replace = TRUE)
  logloss_boot[b, 1] <- calcular_logloss(y[indices], p_simple[indices])
  logloss_boot[b, 2] <- calcular_logloss(y[indices], p_amplio[indices])
}
apply(logloss_boot, 2, quantile, probs = c(0.025, 0.975))
```

Aquí $n = 171$ y $B = 2000$. La cantidad de benignos y malignos puede variar entre remuestras.

El mismo vector de `indices` se aplica a las etiquetas y a los dos modelos.

Python: el mismo procedimiento

```
logloss_boot = np.empty((B, 2))
for b in range(B):
    indices = rng.choice(n, size=n, replace=True)
    logloss_boot[b, 0] = log_loss(y[indices], p_simple[indices])
    logloss_boot[b, 1] = log_loss(y[indices], p_amplio[indices])
np.quantile(logloss_boot, [0.025, 0.975], axis=0)
```

R y Python ajustan los mismos modelos; sus generadores aleatorios producen remuestras distintas.

Las diferencias pequeñas entre límites pueden ser variación Monte Carlo.

AUC en R y Python: remuestrear por clase

Matrices y clases ya definidas; $B = 2000$.

R

```r
for (b in 1:B) {
  i0 <- sample(negativos,
    length(negativos), replace=TRUE)
  i1 <- sample(positivos,
    length(positivos), replace=TRUE)
  i <- c(i0, i1)
  auc_boot[b, 1] <- calcular_auc(
    y[i], p_simple[i])
  auc_boot[b, 2] <- calcular_auc(
    y[i], p_amplio[i])
}
```

Python

```python
for b in range(B):
    i0 = rng.choice(negativos,
        size=len(negativos),
        replace=True)
    i1 = rng.choice(positivos,
        size=len(positivos),
        replace=True)
    i = np.concatenate([i0, i1])
    auc_boot[b, 0] = roc_auc_score(
        y[i], p_simple[i])
    auc_boot[b, 1] = roc_auc_score(
        y[i], p_amplio[i])
```

Remuestreamos prueba por clase; no volvemos a entrenar.

La estadística es ahora una diferencia

En cada remuestra de filas b, menor log loss es mejor:

$$\Delta_b^* = LL_{simple,b}^* - LL_{amplio,b}^*.$$

- Positivo: favorece al modelo amplio.
- Negativo: favorece al modelo simple.
- Cero: el log loss es igual en esa remuestra.

Calculamos los percentiles de las **diferencias**, no restamos extremos de dos intervalos separados.

El emparejamiento conserva la dificultad compartida de los casos.

Diferencias: tres cuentas de la ejecución

Primeras tres remuestras de log loss generadas en R:

Remuestra	LL simple	LL amplio	Simple menos amplio
1	0.3014	0.1839	0.1175
2	0.3019	0.1698	0.1322
3	0.2663	0.1831	0.0832

En la muestra original:

$$\widehat{\Delta}_{LL} = 0.2997 - 0.1833 \approx 0.1163.$$

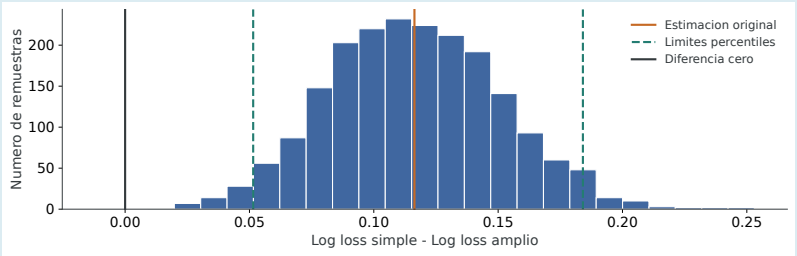
Repetimos la cuenta en las 2000 remuestras antes de obtener el intervalo.

Las cuentas se realizan antes del redondeo mostrado en las tablas.

Intervalo de la diferencia de log loss

Definimos $\Delta_{LL} = LL_{simple} - LL_{amplio}$; positivo favorece al amplio:

$$\widehat{\Delta}_{LL} \approx 0.1163, \qquad IC_{percentil} \approx [0.0515,\ 0.1841].$$



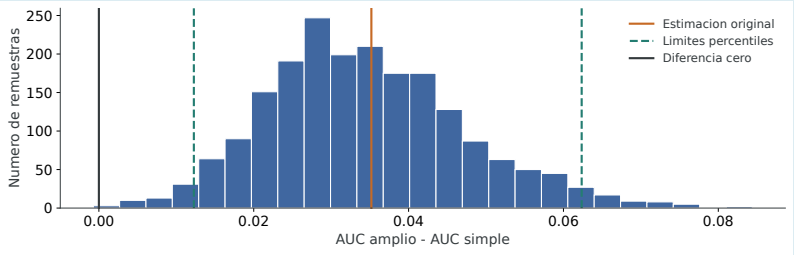
El intervalo queda por encima de cero: favorece al amplio en esta evaluación.

El resultado se refiere a estos modelos fijos y a esta muestra; no es una garantía futura.

Comparar AUC: ahora mayor es mejor

En cada remuestra estratificada: $\Delta^*_{AUC} = AUC^*_{amplio} - AUC^*_{simple}$.

$$\widehat{\Delta}_{AUC} = 0.0352, \qquad IC_{percentil} \approx [0.0123,\ 0.0624].$$



El intervalo queda sobre cero y favorece al amplio en esta evaluación.

Para log loss usamos simple menos amplio; para AUC, amplio menos simple. Positivo favorece al amplio en ambos.

Diferencia estadística y utilidad práctica

Ejemplos hipotéticos. Supongamos que se fijó antes una reducción relevante de log loss de 0.010.

$\widehat{\Delta}$	IC 95 %	Lectura
0.010	$[-0.004, 0.024]$	No hay evidencia clara de superioridad; no prueba equivalencia.
0.002	$[0.001, 0.003]$	Diferencia positiva, pero menor que la mejora relevante fijada.
0.030	$[0.020, 0.050]$	Diferencia positiva y por encima de esa mejora relevante.

La relevancia depende del problema y de sus costos; 0.010 no es una regla universal.

Alcance del intervalo que calculamos

Incluye	No incluye por sí solo
Variación al remuestrear casos de evaluación de modelos fijos.	Variación por volver a entrenar y seleccionar toda la receta.
La dependencia entre predicciones de los dos modelos en un mismo caso.	Cambios futuros de población, mediciones o prevalencia.

Para estudiar el entrenamiento, tendríamos que repetir el ajuste y sus transformaciones, con una evaluación fuera de ese ajuste.

Repetir un cálculo 2000 veces no corrige sesgos de diseño, selección o fuga de datos.

Informe de comparación

Dos logísticas sin penalización; 398 casos de ajuste y 171 de prueba.

Resultado	Estimación	IC percentil 95 %
Log loss simple	0.2997	[0.2124, 0.4005]
Log loss amplio	0.1833	[0.1066, 0.2798]
Mejora de log loss	0.1163	[0.0515, 0.1841]
AUC simple	0.9394	[0.9004, 0.9708]
AUC amplia	0.9746	[0.9503, 0.9915]
Mejora de AUC	0.0352	[0.0123, 0.0624]

$B = 2000$: log loss por filas; AUC por clase. Modelos fijos, diferencias pareadas e IC en prueba, no en entrenamiento.

La prueba reutilizada es una demostración docente, no una validación externa nueva.