DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

Aprendizaje Automático

# Aplicaciones de IA y panorama del Deep Learning

Sesión 44 · 15 de octubre de 2026

Eloy Alvarado Narváez

# Lo que ya sabemos usar

| Experiencia del curso | Idea que conservamos |
|---|---|
| Clasificar correos | Describir una observación mediante variables y obtener una predicción. |
| Agrupar vinos | Las variables y sus escalas cambian qué objetos parecen cercanos. |
| Comparar modelos | Separar ajuste y prueba, examinar errores y contrastar una referencia. |

Ahora ampliaremos el recorrido a imágenes y al contenido de textos completos. Cambiar el tipo de dato exige decidir cómo describirlo y qué resultado necesitamos.

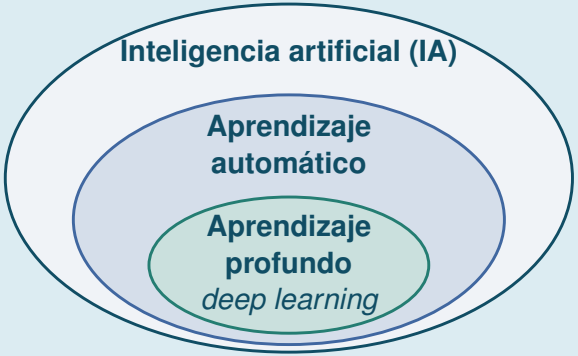
**Los modelos nuevos se explicarán desde cero. Conservamos las preguntas de evaluación que ya conocemos.**

# Preguntas para estudiar una aplicación

- **Tarea:** ¿queremos asignar una categoría, anticipar una cantidad, encontrar información o producir contenido?
- **Datos:** ¿qué recibe el sistema y qué información necesita para aprender?
- **Resultado:** ¿cómo reconoceremos un acierto, un error o una respuesta sin respaldo?
- **Uso:** ¿qué cambia cuando llegan otros datos y quién toma la decisión final?

Primero seguiremos un caso de reconocimiento de imágenes. Después aplicaremos estas preguntas a búsqueda, recomendación, generación y soporte.

# Inteligencia artificial y aprendizaje con datos




**IA: el campo más amplio.** Sistemas para reconocer, predecir o generar contenido, incluso mediante reglas escritas a mano.

**Aprendizaje automático.** Aprende patrones a partir de datos. Incluye logística y Naive Bayes.

**Aprendizaje profundo.** Aprende varias transformaciones sucesivas de los datos.

**Todo aprendizaje profundo es aprendizaje automático y es IA; las relaciones inversas no siempre se cumplen.**

Relación entre los campos: IBM, What is machine learning?

# Cuatro tareas, cuatro resultados diferentes

| Tarea | Ejemplo de salida | Qué comprobamos |
|---|---|---|
| Clasificar | Este envase presenta daño. | Categoría correcta y defectos omitidos. |
| Pronosticar | Se venderán 120 unidades mañana. | Error frente a la venta posterior. |
| Recuperar | Estos documentos responden a la consulta. | Relevancia y actualidad de las fuentes. |
| Generar | Un borrador de respuesta o una imagen. | Respeto de las fuentes, instrucciones y utilidad. |

Una aplicación puede combinar varias tareas. La evaluación debe cubrir cada salida y el resultado del proceso completo.

# Clasificar un correo y redactar una respuesta

**Consulta:** “Me cobraron dos veces y necesito el comprobante.”

| Encargo | Salida posible | Comprobación |
|---|---|---|
| Clasificar | Consulta sobre cobros. | Comparar con la categoría correcta. |
| Redactar | Una explicación del procedimiento. | Verificar cada afirmación y el paso siguiente. |

Un texto puede estar bien escrito y agregar una aprobación inexistente. La fluidez indica si se lee con naturalidad. La fidelidad exige que conserve los hechos respaldados por las fuentes.

Ejemplo hipotético.

# Qué es una red neuronal

Una **red neuronal** es un modelo que transforma datos numéricos mediante operaciones cuyos valores ajustables se aprenden a partir de ejemplos.

- Recibe números que describen la entrada, como los valores de una imagen.
- Combina esa información en varias etapas para producir una salida.
- Durante el aprendizaje modifica sus valores ajustables para mejorar un objetivo definido.

En reconocimiento de dígitos, puede entregar una probabilidad para cada número. El aprendizaje profundo usa redes que aprenden varias transformaciones sucesivas de la entrada.

**Hoy estudiaremos sus entradas, resultados y usos. Su construcción se desarrolla el 20 de octubre.**

# Aprender y utilizar un modelo

| Momento | Qué sucede | Ejemplo |
|---|---|---|
| Entrenamiento | Se ajusta el modelo usando datos y un objetivo. | Imágenes acompañadas de su dígito correcto. |
| Uso o predicción | Se aplica el modelo ya ajustado a otra entrada. | Una imagen nueva recibe probabilidades. |

Si cada vez que aparece una imagen nueva cambiamos el modelo, también cambiamos el procedimiento evaluado. En el ejemplo de esta clase mantendremos el modelo fijo al probarlo.

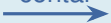
**Podemos estudiar predicciones guardadas sin volver a entrenar.**

# Qué significa representar los datos

Una **representación** describe un objeto mediante números para poder analizarlo. Puede diseñarse con variables elegidas por una persona o aprenderse con datos.

**Correo hipotético**

"crédito gratis crédito"



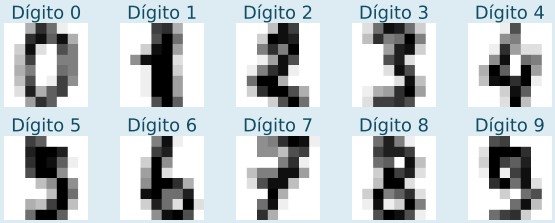

| crédito | gratis | urgente |
|---|---|---|
| 2 | 1 | 0 |

Contamos las palabras, siempre en el mismo orden de columnas.

En una imagen usamos celdas llamadas **píxeles**. Su **intensidad** es un número que describe el tono de cada celda. Un documento también puede describirse mediante una lista de números.

**Contar palabras conserva frecuencias, pero pierde el orden de la frase.**

# Reconocimiento de dígitos escritos a mano



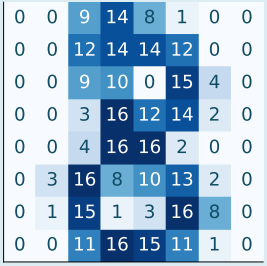

La colección contiene **1.797 imágenes de** $8 \times 8$ **píxeles**: ocho filas de ocho celdas. La etiqueta es el dígito correcto de cada imagen, entre 0 y 9.

La tarea consiste en reconocer el dígito de una imagen que el modelo no usó para ajustarse. Compararemos una regresión logística con una red ya entrenada y analizaremos sus resultados.

UCI, Optical Recognition of Handwritten Digits; colección distribuida por scikit-learn.

# Una imagen contiene intensidades

Esta imagen real tiene $8 \times 8 = 64$ píxeles. Cada intensidad va de 0 a 16.



| | | | | | | | |
|---|---|---|---|---|---|---|---|
| 0 | 0 | 9 | 14 | 8 | 1 | 0 | 0 |
| 0 | 0 | 12 | 14 | 14 | 12 | 0 | 0 |
| 0 | 0 | 9 | 10 | 0 | 15 | 4 | 0 |
| 0 | 0 | 3 | 16 | 12 | 14 | 2 | 0 |
| 0 | 0 | 4 | 16 | 16 | 2 | 0 | 0 |
| 0 | 3 | 16 | 8 | 10 | 13 | 2 | 0 |
| 0 | 1 | 15 | 1 | 3 | 16 | 8 | 0 |
| 0 | 0 | 11 | 16 | 15 | 11 | 1 | 0 |

**Leer por filas, en un orden fijo**

$[0, 0, 9, 14, 8, 1, 0, 0, \ldots]$

Primera fila, luego las otras siete: 64 números.

dividir por 16

$9 \mapsto 0.5625 \qquad 14 \mapsto 0.875 \qquad 8 \mapsto 0.5$

**Entrada: 64 números entre 0 y 1.**

**La etiqueta correcta es 8. Se guarda separada de los 64 números de entrada.**

# La salida: una probabilidad para cada dígito

Para una imagen, el clasificador entrega diez probabilidades, una por clase. Suman uno. La predicción habitual es la clase que recibe el valor más alto.

| Ejemplo hipotético | Probabilidad |
|---|---|
| Dígito 3 | 0.60 |
| Dígito 8 | 0.25 |
| Las otras ocho clases, en conjunto | 0.15 |

El modelo predice 3. Si la etiqueta real fuera 8, habría cometido un error aunque asignó alguna probabilidad al 8.

**La clase elegida y la probabilidad de la clase real aportan información distinta.**

# Datos para aprender, elegir y comprobar

| Parte de la colección | Cantidad | Uso |
|---|---|---|
| Entrenamiento | 1.077 | Ajustar los modelos candidatos. |
| Validación | 360 | Elegir entre las dos redes candidatas. |
| Prueba | 360 | Evaluar al final el procedimiento elegido. |

Después de elegir, se reajusta la red con las 1.437 imágenes de desarrollo. La logística usa ese mismo conjunto. Las 360 imágenes de prueba permanecen fuera de estas decisiones.

La separación se realizó por imagen. La copia de datos no identifica escritores; por eso no demuestra desempeño independiente en personas nuevas.

# Dos modelos para la misma tarea

| Regresión logística | Red neuronal |
|---|---|
| Usa los 64 píxeles para calcular probabilidades entre diez clases. | Aprende transformaciones de esos mismos píxeles para producir probabilidades. |
| Sirve como referencia conocida, con configuración fijada. | Se eligió entre dos configuraciones mediante el resultado de validación. |

Ambos modelos reciben las mismas imágenes y se evalúan sobre los mismos casos. Para seguir la comparación basta interpretar sus salidas y el criterio de evaluación.

**El experimento compara estas dos recetas; no establece qué familia gana en todos los problemas.**

# Qué mide la pérdida de probabilidades

Una **pérdida** asigna un costo numérico a una predicción. En **log loss**, tomamos la probabilidad del dígito real, calculamos su logaritmo natural con signo negativo y promediamos esos costos. Menor pérdida es mejor.

| Probabilidad del dígito real | Contribución a la pérdida |
|---|---|
| 0.90 | $-\log(0.90) \approx 0.105$ |
| 0.60 | $-\log(0.60) \approx 0.511$ |
| 0.01 | $-\log(0.01) \approx 4.605$ |

Si la etiqueta real es 8 y el modelo le asignó 0.01, usamos 0.01 aunque haya predicho 3 con probabilidad 0.90. Una respuesta incorrecta y muy confiada puede costar mucho.

# Resultados sobre 360 imágenes nuevas

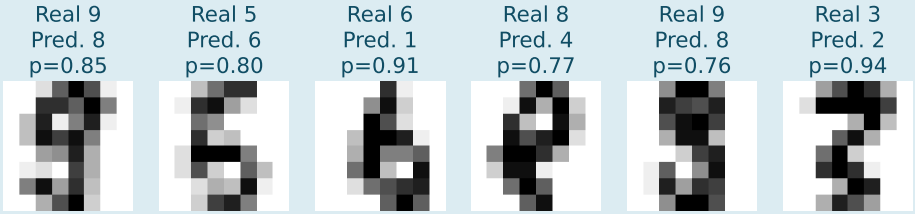
La **exactitud** es la proporción de imágenes clasificadas correctamente. El **log loss** es la pérdida media de las probabilidades asignadas a las clases reales. Un valor menor es mejor.

| Modelo | Aciertos | Exactitud | Log loss |
|---|---|---|---|
| Logística | 353 de 360 | 98.06 % | 0.1353 |
| Red neuronal | 354 de 360 | 98.33 % | 0.0657 |

La diferencia de exactitud equivale a **un acierto adicional**: $100/360 \approx 0.28$ puntos porcentuales. La red también tiene menor pérdida en estas imágenes.

**Casi el mismo número de aciertos puede coexistir con probabilidades de distinta calidad.**

# Errores con probabilidades altas




Estas son las seis imágenes que la red clasificó mal entre las 360 de prueba. Cada rótulo muestra el dígito real, el predicho y la probabilidad de la clase predicha.

En la última imagen, el dígito real es **3**, se predijo **2** con probabilidad **0.94**. Un **umbral** es un valor de corte: aceptar sin revisión sobre 0.90 dejaría pasar este error.

**La confianza numérica necesita evaluación antes de usarse para decidir qué casos revisar.**

# Qué permite concluir esta prueba

| Evidencia disponible | Límite de la conclusión |
|---|---|
| 360 imágenes reservadas de esta colección.<br>Comparación en las mismas imágenes.<br>No hay identificador de escritor. | El resultado se refiere a sus condiciones de adquisición.<br>Describe las dos recetas ajustadas, no todas las alternativas.<br>No demuestra desempeño en escritores independientes nuevos. |

Otra cámara, otros trazos o un cambio de posición pueden alterar las entradas. Para conocer el resultado en esas condiciones necesitamos observarlas y evaluarlas.

**Una evaluación útil declara tanto su resultado como la población y las condiciones a las que se refiere.**

# Lectura de una predicción, paso a paso

| Imagen identificada como 4 | Logística | Red |
|---|---|---|
| Dígito real | 3 | 3 |
| Clase predicha | 3 | 3 |
| Probabilidad asignada al 3 | 0.983575 | 0.999775 |
| Pérdida de esa imagen | 0.0166 | 0.000225 |

- Identificamos la etiqueta real y buscamos su probabilidad.
- Calculamos la pérdida y verificamos si la clase predicha coincide.
- Repetimos el cálculo para las 360 imágenes y resumimos.

Los códigos de evaluación leen estas probabilidades guardadas. Comprender la tabla no requiere ejecutar ni entrenar una red.

# Para qué usamos bootstrap

La red tuvo menor pérdida en estas 360 imágenes. **¿Cuánto podría variar esa ventaja si evaluáramos otras imágenes de las mismas condiciones?**

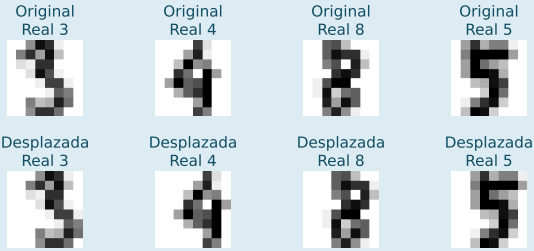
El bootstrap estima la **incertidumbre debida a los casos de prueba**. Reutiliza sus pérdidas, manteniendo fijos los dos modelos entrenados.

| **Comparación de pérdidas medias** | **Resultado** |
|---|---|
| Logística menos red | $0.1353 - 0.0657 = 0.0696$ |
| Intervalo de confianza bootstrap del 95 % | [0.0478, 0.0901] |

**Cero significaría igual pérdida media.** Todo el intervalo es positivo: hay evidencia de menor pérdida de la red, bajo independencia por imagen.

No mide la utilidad práctica de la mejora ni cubre un cambio de cámara.

# La misma imagen en otra posición




La fila inferior desplaza cada imagen una columna a la derecha. La primera columna se rellena con cero y la última columna original se descarta. La etiqueta se conserva.

Aplicamos los mismos modelos, sin reajustarlos. Así comprobamos si toleran esta transformación. Es una prueba de estrés artificial; no representa todos los cambios de una cámara real.

# El resultado cambia con las condiciones

| Condición | Modelo | Exactitud | Log loss |
|---|---|---|---|
| Original | Logística | 98.06 % | 0.1353 |
| Original | Red | 98.33 % | 0.0657 |
| Desplazada | Logística | 39.72 % | 2.3826 |
| Desplazada | Red | 45.00 % | 3.1314 |

En las mismas 360 imágenes, mover una columna a la derecha reduce los aciertos de ambos modelos. Sin reajustar, la red acierta más que la logística, pero su log loss es peor: penaliza probabilidades pequeñas asignadas al dígito real.

**Un buen resultado original no garantiza resistencia a cambios de entrada.**

# Aplicación: inspección visual

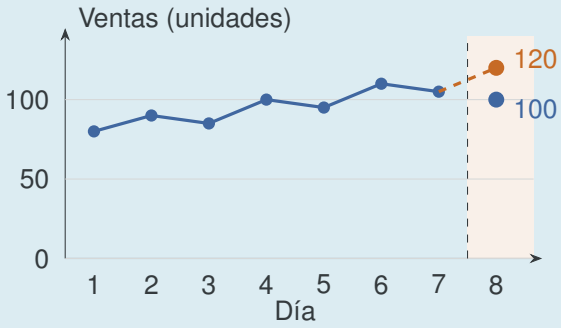
**Situación hipotética.** Una línea de producción fotografía envases para detectar daño visible.

| Decisión de diseño | Qué significa |
|---|---|
| Entrada y salida | Fotografías del envase; categoría o alerta de daño. |
| Datos necesarios | Ejemplos representativos, etiquetas revisadas y condiciones de captura. |
| Evaluación útil | Defectos omitidos, piezas sanas señaladas (falsas alarmas) y capacidad de revisión. |

Cambiar cámara, iluminación o posición puede cambiar el desempeño. La prueba debe incluir las condiciones de uso y distinguir reconocer daño de decidir retirar una pieza.

# Aplicación: pronóstico de demanda

**Ejemplo hipotético.** Al terminar el día 7 queremos anticipar la venta del día 8. La entrada conserva las fechas y el orden de las ventas anteriores.




**Entrada:** ventas de los días 1–7 y otros datos disponibles al predecir.

**Salida:** venta prevista para el día 8: 120 unidades.

**Referencia:** repetir la venta del día 1 (semana anterior): 80 unidades.

**Prueba:** observar después la venta real: 100 unidades.

Error absoluto del pronóstico: $|120 - 100| = 20$. Evaluamos en fechas posteriores; faltantes y excedentes pueden tener costos distintos.

# Balance del primer bloque

- **Definimos una tarea.** La salida puede ser una categoría o una cantidad futura.
- **Describimos la entrada.** Una imagen requiere números; la representación afecta qué diferencias se pueden utilizar.
- **Comprobamos el resultado.** La clase elegida, las probabilidades y los errores cuentan aspectos distintos.
- **Delimitamos el uso.** Otra cámara, otro escritor o una fecha futura requieren evidencia pertinente.

Después de la pausa ampliaremos el panorama a documentos, búsqueda, recomendación y contenido generado.

# Aplicaciones que trabajan con texto

Un texto puede utilizarse para tareas diferentes. Antes de elegir un sistema, definimos qué salida necesitamos.

| Entrada | Tarea | Salida |
|---|---|---|
| Consulta de un cliente | Clasificar | Categoría de consulta. |
| Consulta y archivo de documentos | Recuperar | Fuentes relevantes ordenadas. |
| Documento extenso | Resumir | Texto breve que conserve lo importante. |
| Instrucción y antecedentes | Redactar | Un borrador verificable. |

Según la tarea, comprobamos categoría, pertinencia del documento o fidelidad a los hechos de la fuente. Una redacción fluida no sustituye esas comprobaciones.

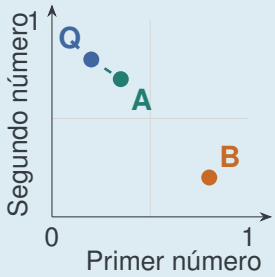
# Embeddings: números para comparar objetos

Un **vector** es una lista ordenada de números. Un **embedding** representa un objeto mediante un vector para poder compararlo con otros.

**Ejemplo ilustrativo: números inventados.**

| Texto | Vector |
|---|---|
| Q: “cobro duplicado” | [0.20, 0.80] |
| A: “reembolso” | [0.35, 0.70] |
| B: “envíos” | [0.80, 0.20] |

Aquí A está más cerca de Q que B.




**¿De dónde salen?** El modelo aprende con ejemplos una regla que convierte cada texto en un vector. Para buscar, puede aprender a acercar textos relacionados. Las coordenadas dependen del modelo; no son probabilidades ni etiquetas de temas.

Ejemplo de embeddings aprendidos para textos: Reimers y Gurevych (2019).

# Búsqueda por palabras y búsqueda por significado

**Consulta hipotética:** “¿Cómo recupero un cobro duplicado?”

| Forma de buscar | Qué compara | Posible dificultad |
|---|---|---|
| Por palabras | Coincidencias de términos. | La fuente puede hablar de reembolso. |
| Por significado (semántica) | Representaciones numéricas de consulta y documentos. | La cercanía puede recuperar un texto relacionado pero que no responde. |

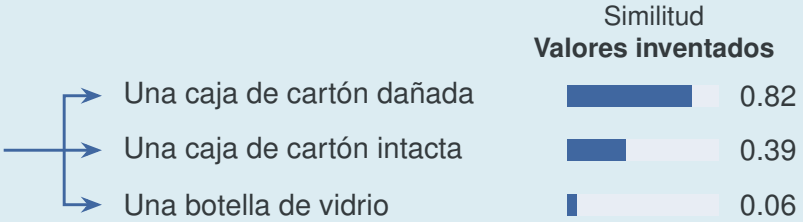
La búsqueda devuelve fuentes para leer. Debemos comprobar que respondan a la consulta, correspondan al servicio y estén vigentes. Los dos métodos pueden compararse o combinarse.

# Relacionar imágenes y descripciones

**CLIP** aprende con pares de imagen y texto a producir vectores comparables. Convierte la imagen y cada descripción en vectores y compara su similitud.



Imagen de ejemplo




Las frases candidatas pueden cambiar el orden. La similitud permite comparar opciones; no mide la probabilidad de daño.

Radford y colaboradores (2021), CLIP.

# Aplicación: recomendación de contenidos

**Ejemplo hipotético.** Un portal quiere ordenar cursos que podrían interesar a una persona.

**Personas × cursos**

| | R | Python | Gráficos |
|---|---|---|---|
| **Ana** | 1 | 1 | 0 |
| Bruno | 1 | 0 | 1 |
| Carla | 0 | 1 | 1 |

**1:** hay un clic registrado.

**0:** no hay un clic registrado; no significa rechazo.

La fila de Ana aporta señales para ordenar cursos. También importan los temas, el nivel previo y la disponibilidad.

Un clic puede indicar interés, curiosidad o una selección accidental. Evaluamos pertinencia, satisfacción o aprendizaje según el objetivo del servicio.

# Generación de texto a partir de una instrucción

La **instrucción** indica qué resultado queremos. El **contexto** es el texto disponible para producirlo: antecedentes aportados y texto ya escrito.

Un **modelo de lenguaje** aprende regularidades en el orden de las palabras y sus partes. Al generar, añade esas unidades sucesivamente utilizando el contexto.

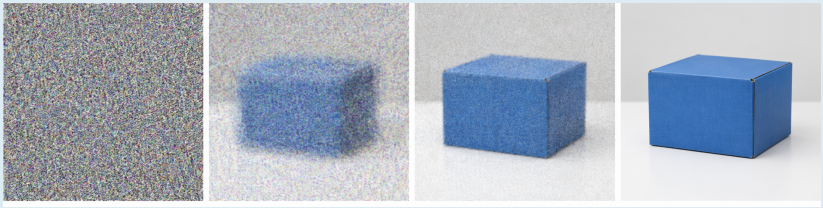
| Solicitud hipotética | Qué comprobar |
|---|---|
| Resumir un procedimiento en cinco líneas. | Conservar requisitos y excepciones. |
| Redactar una respuesta usando ese procedimiento. | Respaldar las afirmaciones y reconocer datos faltantes. |

**Producir una continuación plausible no garantiza que sea verdadera.**

# Generación de imágenes a partir de una descripción

**Descripción de entrada:** “una caja azul sobre una mesa blanca”.

En **difusión**, un modelo ya entrenado parte de **ruido visual** (puntos sin una figura reconocible) y lo transforma gradualmente en una imagen, guiado por el texto.




Secuencia ilustrativa: resume muchos pasos, no una ejecución registrada.

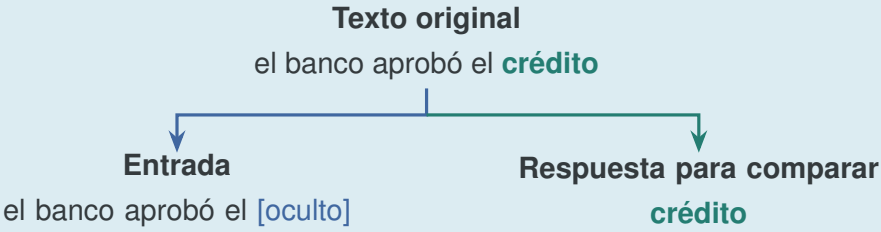
**Evaluar:** objetos, cantidades y relaciones. El realismo no acredita un hecho.

Rombach y colaboradores (2022), difusión latente.

# De dónde viene la señal para aprender

**Supervisado:** respuesta externa; por ejemplo, el dígito correcto de una imagen.

**Autosupervisado:** obtenemos la respuesta de los propios datos. Ejemplo ilustrativo: ocultar una palabra y conservar el original.




La palabra original sirve para comparar; puede haber otras continuaciones. Los datos requieren revisión y la aplicación debe evaluarse.

# Reutilizar un aprendizaje previo

Un modelo **preentrenado** ya aprendió con otros datos. Podemos reutilizar su representación o capacidad y adaptarla a una tarea local.

| Ventaja posible | Qué debemos comprobar |
|---|---|
| Aprovechar otros datos. | Que el aprendizaje sea pertinente. |
| Menos ajuste desde cero. | Que haya datos locales para adaptar y evaluar. |
| Reutilizar una representación. | Que su desempeño sirva para cada tarea. |

**El aprendizaje previo es un punto de partida. La utilidad local se demuestra con datos de la aplicación.**

Bommasani y colaboradores (2021).

# Adaptar el uso y adaptar el modelo

| Alternativa | Qué cambia | Ejemplo |
|---|---|---|
| Instrucciones y contexto | La información de entrada. | Aportar un procedimiento para redactar una respuesta. |
| Reutilizar representaciones | Se conservan los vectores y se ajusta un clasificador para la tarea. | Una logística que usa esos vectores para clasificar envases. |
| Ajuste fino | Se modifica el modelo usando datos de la tarea. | Adaptarlo con ejemplos locales etiquetados. |

Cambiar una instrucción puede cambiar la respuesta sin volver a entrenar. Cualquiera de estas alternativas necesita una evaluación de la receta completa.

# Aplicación científica: estructuras biomoleculares

Un **complejo biomolecular** reúne moléculas que interactúan, como proteínas y ADN. **AlphaFold 3** predice cómo podrían disponerse sus componentes en el espacio.

| Pregunta | Lectura de la aplicación |
|---|---|
| ¿Qué recibe? | Información sobre los componentes del complejo. |
| ¿Qué produce? | Una propuesta de su estructura espacial conjunta. |
| ¿Cómo se comprueba? | Comparando la disposición predicha con estructuras determinadas experimentalmente. |

Una estructura predicha puede orientar investigación. Por sí sola no demuestra que un compuesto sea un tratamiento eficaz: esa es otra pregunta, que necesita otra evidencia.

Abramson y colaboradores (2024), Nature.

# Panorama actual: avances y capacidades desiguales

El AI Index 2026 reúne información sobre desempeño, adopción y aplicaciones de la IA. El progreso depende de la tarea.

Un **benchmark** es una evaluación con tareas, datos y reglas definidos. Su resultado no estima automáticamente el desempeño en otra población o proceso.

- **Al leer un resultado:** ¿qué tarea se evaluó y en qué condiciones?
- **Para la aplicación local:** ¿nuestros datos, errores y restricciones son comparables?

**El panorama orienta qué alternativas estudiar; la decisión de uso necesita evidencia pertinente.**

Stanford HAI, AI Index 2026. Consulta: 15/10/2026.

# Una aplicación incluye más que el modelo

| Componente | Función | Fallo posible |
|---|---|---|
| Datos y contexto | Aportar información pertinente. | Un documento equivocado. |
| Modelo y herramientas | Predecir, redactar, consultar o calcular. | Confundir unidades o consultar otro registro. |
| Verificación | Comprobar condiciones antes de actuar. | Aceptar una afirmación sin respaldo. |
| Decisión y seguimiento | Aplicar una regla y observar su resultado. | Ejecutar una acción incorrecta. |

**Ejemplo:** 12 cajas de 24 unidades contienen $12 \times 24 = 288$ unidades. Interpretarlas como solo 12 unidades puede producir una reposición incorrecta aunque el texto esté bien redactado.

# Aplicación: atención de una consulta de cobro

**Consulta hipotética:** “Me cobraron dos veces y necesito el comprobante.”

| Paso | Salida que podemos comprobar |
|---|---|
| Clasificar | Categoría de cobros y prioridad según reglas del servicio. |
| Consultar y recuperar | Registros pertinentes y procedimiento aplicable. |
| Redactar | Borrador que distingue hechos verificados de información faltante. |

La afirmación del usuario informa qué reclama. Para confirmar el doble cobro se necesitan registros del caso. Un procedimiento general no demuestra que una devolución esté aprobada.

# Verificación de una respuesta generada

**Fuente del ejemplo:** “La revisión del cobro puede tardar hasta cinco días hábiles.”

**Borrador:** “Su devolución está aprobada y llegará mañana.”

| Afirmación del borrador | Respaldo disponible |
|---|---|
| La devolución está aprobada. | La fuente no informa el resultado del caso. |
| El abono llegará mañana. | La fuente habla de revisión, no de una fecha de abono. |

**Respuesta corregida:** “El procedimiento indica hasta cinco días hábiles de revisión. Con esta información no puedo confirmar una aprobación ni una fecha de abono.”

# Costo de errores y carga de revisión

**Ejemplo hipotético:** 1.000 piezas, de las cuales 20 tienen defectos.

| Error | Cantidad | Costo por caso |
|---|---|---|
| Defecto no detectado | 4 | 50 unidades |
| Pieza sana enviada a revisión | 30 | 1 unidad |

El costo de estos errores es $4 \times 50 + 30 \times 1 = 230$ unidades. Omitir un defecto cuesta más que producir una falsa alarma.

Se detectaron 16 defectos. Si se revisan todas las alertas, habrá 16 + 30 = 46 revisiones. Una capacidad de 20 revisiones no alcanza.

**La regla de decisión se elige con validación, costos y capacidad. El costo mostrado no incluye todos los gastos de operación.**

# Una prueba que represente el uso

| Uso previsto | Diseño necesario |
|---|---|
| Nuevas personas | Mantener todas las observaciones de una persona en el mismo conjunto. |
| Otra cámara o línea | Observar datos de esas condiciones y reservar una prueba. |
| Meses futuros | Evaluar en fechas posteriores al desarrollo. |
| Otra versión del sistema | Documentar el cambio y volver a evaluar. |

Una transformación artificial puede descubrir una debilidad. Para estimar el desempeño en producción necesitamos datos que representen el uso previsto y una separación que evite compartir información entre desarrollo y prueba.

# Restricciones de una aplicación

| Restricción | Qué se necesita medir o definir |
|---|---|
| Tiempo | Latencia: tiempo de respuesta, incluidos datos, consultas, cálculo y revisión. |
| Costo | Adaptación inicial y uso repetido según el volumen. |
| Datos | Acceso, destino, calidad y retención de la información. |
| Mantenimiento | Versiones, cambios de entrada y desempeño posterior. |

Ejemplo hipotético: si llega una pieza por segundo y el procesamiento secuencial demora cinco segundos por pieza, se acumula trabajo. Una buena exactitud no resuelve por sí sola ese límite.

# Alternativas para una primera comparación

| Problema | Referencia y candidato posible |
|---|---|
| Tabla pequeña con variables útiles | Regresión o árboles; considerar mayor complejidad si aporta una mejora. |
| Imágenes con pocas etiquetas | Una referencia simple y una representación preentrenada adaptada. |
| Pronóstico temporal | Una regla basada en historia reciente y otro modelo que respete el tiempo. |
| Búsqueda de documentos | Coincidencias de palabras y representaciones semánticas. |

Son candidatos para evaluar. La elección depende de resultados locales, errores relevantes y recursos. Una alternativa simple puede resolver mejor el problema bajo esas condiciones.

# Qué parte del proceso conviene automatizar

| Modo de uso | Condición que debe comprobarse |
|---|---|
| Proponer un borrador | Una persona dispone de información y tiempo para verificarlo. |
| Priorizar casos | El orden ayuda y se observan los casos que quedan atrás. |
| Ejecutar una decisión | La regla tiene evidencia, límites definidos y seguimiento. |

La revisión humana también puede fallar o quedar sobrecargada. Debemos medir qué errores quedan después de revisar, cuánto tarda y cuánto trabajo genera.

Cuando faltan datos pertinentes o una forma de verificar el resultado, corresponde reunir evidencia antes de ampliar la automatización.

# Caso integrador: inspección de envases

**Caso hipotético.** Una empresa dispone de 6.000 fotografías de 1.200 envases. Cada envase tiene cinco vistas y una etiqueta de daño visible. La decisión final es enviar el envase a revisión.

El próximo mes se usará una cámara nueva en otra línea. Los datos actuales proceden de las condiciones anteriores.

- ¿Qué fotografías deben permanecer juntas al separar los datos?
- ¿Qué información falta para evaluar el uso del próximo mes?
- ¿Con qué referencia compararíamos y qué errores o costos mediríamos?

**Seis mil fotografías no equivalen a seis mil envases independientes.**

# Propuesta de evaluación del caso

Para los 1.200 envases con cinco fotografías cada uno, la decisión y la evaluación se realizan por envase. El uso previsto incorpora una cámara y una línea nuevas.

- **Separación:** todas las vistas de un envase quedan en un único conjunto.
- **Destino:** reunir datos de la nueva cámara y línea. Reservar envases que no participen en adaptación ni selección.
- **Comparación:** contrastar una referencia con un candidato. Elegir en validación cómo combinar las cinco vistas y cuándo revisar.
- **Resultado:** contar defectos omitidos, falsas alarmas y revisiones por envase.
- **Incertidumbre:** remuestrear envases completos para conservar juntas sus vistas.

Cambiar el procedimiento después de mirar prueba exige otra evaluación independiente. La conclusión se limita a las condiciones observadas.

# Qué sabemos ahora y qué estudiaremos después

**Hoy:** podemos definir una aplicación, describir su entrada y salida, interpretar probabilidades o contenido generado y proponer cómo comprobar su utilidad.

Una **red neuronal** apareció como un modelo que aprende transformaciones de datos. Pudimos estudiar sus resultados sin suponer conocimientos sobre su construcción.

**20 de octubre:** estudiaremos cómo se construye una red, cómo calcula su salida y cómo aprende con ejemplos. Esos mecanismos quedan para esa clase.

Después profundizaremos en representación de datos y modelos de lenguaje.

**La tarea, los datos y la evaluación dan sentido a la elección del modelo.**

# Referencias para ampliar los conceptos

| Tema | Fuente |
|---|---|
| Aprendizaje profundo | LeCun, Bengio y Hinton (2015). Deep learning. |
| Reutilización y adaptación | Bommasani y colaboradores (2021). Foundation models. |
| Imagen y texto | Radford y colaboradores (2021). CLIP. |
| Representaciones visuales | Oquab y colaboradores (2023). DINOv2. |

Los artículos permiten profundizar según el tema de interés. Sus resultados describen experimentos y condiciones particulares; una aplicación nueva requiere evaluación propia.

# Referencias de aplicaciones y datos


- **Imágenes generadas:** Rombach y colaboradores (2022). Difusión latente.
- **Estructuras biomoleculares:** Abramson y colaboradores (2024). AlphaFold 3.
- **Panorama:** Stanford HAI. AI Index 2026. Consulta: 15/10/2026.
- **Dígitos:** UCI. Optical Recognition of Handwritten Digits, CC BY 4.0; distribución de scikit-learn.