DATA SCIENCE UC
FACULTAD DE MATEMÁTICAS

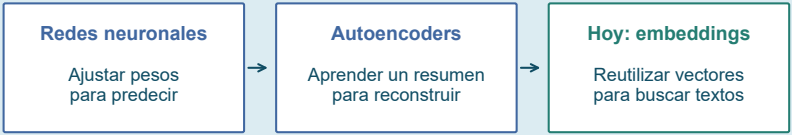
Aprendizaje Automático

Embeddings y representaciones vectoriales

Sesión 47 · 27 de octubre de 2026

Eloy Alvarado Narváez

De aprender una red a reutilizar su representación



En redes neuronales aprendimos a ajustar pesos a partir de un error. En autoencoders, ese error era reconstruir una imagen: el codificador aprendía un resumen numérico.

Hoy pasamos de imágenes a textos. Usaremos un codificador ya entrenado para representar preguntas y documentos, compararlos y evaluar una búsqueda.

La pregunta de hoy: ¿cómo ayuda una representación aprendida a encontrar información pertinente?

El caso: un buscador para consultas de estudiantes

Aula Abierta es una institución ficticia que ofrece cursos online. Su equipo de soporte recibe preguntas sobre acceso, clases, pagos y entregas. Las fichas son sus documentos breves de ayuda.

Queremos construir un buscador que encuentre la ficha de ayuda pertinente dentro de una colección de 12 fichas breves.

Pregunta de un estudiante	Ficha que debería encontrar
«Olvidé mi clave, ¿cómo vuelvo a entrar?»	D01 · Acceso: explica cómo recuperar la contraseña.

La tarea es recuperar una fuente de ayuda. Las fichas y reglas son inventadas para el caso.

Qué es una ficha y qué significa D05

Una **ficha** es un documento breve de ayuda escrito por el equipo de Aula Abierta. Cada una tiene un identificador estable, un tema y un texto.

Identificador y tema	Texto de la ficha
D01 · Acceso	Para recuperar la contraseña de Aula Abierta, use Recuperar acceso en la pantalla de ingreso. Recibirá un enlace en su correo registrado.
D05 · Pagos	El arancel puede pagarse en tres cuotas mensuales sin interés. El comprobante de pago se descarga desde la sección Finanzas.

La colección completa tiene 12 fichas, D01 a D12. Las consultas son preguntas distintas de esos documentos.

D05 identifica el documento de pagos. El 05 no es un puntaje, una posición del ranking ni una coordenada.

El procedimiento que vamos a construir

Etapa	Pregunta que resolveremos
1. Representar	¿Cómo convertir una consulta y un documento en vectores comparables?
2. Comparar	¿Qué significa que esos vectores sean parecidos?
3. Ordenar	¿Qué documentos mostraremos primero?
4. Evaluar	¿Los documentos encontrados realmente responden?

Primera parte: representación y comparación. Segunda parte: búsqueda y evaluación.

Qué es un embedding de texto

Un **embedding** es un vector que representa un objeto en un espacio numérico. Aquí, una red ya entrenada produce el vector de cada texto.

$$z = f_\theta(x) = (z_1, z_2, \ldots, z_d)$$

Símbolo	Qué significa
x	Texto de entrada.
f_θ	Codificador con parámetros aprendidos θ.
z y d	Vector de salida y cantidad de coordenadas.

El entrenamiento busca conservar relaciones útiles entre los objetos.

Contar palabras conserva coincidencias literales

Texto	clave	contraseña	video
«clave»	1	0	0
«contraseña»	0	1	0
«video clave»	1	0	1

Cada columna cuenta una palabra. «Clave» y «contraseña» activan columnas distintas, aunque puedan expresar la misma necesidad.

El conteo es interpretable y conserva términos exactos. Por sí solo, no aprende la relación entre sinónimos.

El embedding puede aprender relaciones que un conteo literal no incorpora.

La señal de relación: qué queremos que aprenda la red

Una **señal de relación** es información conocida sobre una pareja de textos. Indica qué relación debe reflejar el modelo; no es el coseno que él calcula.

Pareja de entrenamiento	Información conocida
«Olvidé mi clave» / «No recuerdo mi contraseña»	Son paráfrasis: expresan una misma necesidad.
«Olvidé mi clave» / ficha D01 de acceso	La ficha responde: pareja relevante (etiqueta 1).
«Olvidé mi clave» / ficha D05 de pagos	La ficha no responde: pareja no relevante (etiqueta 0).

Estas marcas pueden venir de personas que revisan respuestas o de pares de traducciones ya conocidos. La pérdida usa esa referencia para ajustar los pesos.

La señal fija la referencia; la pérdida la compara con la salida del modelo.

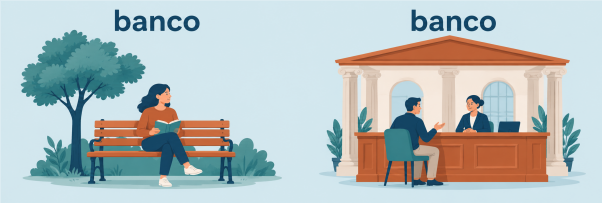
En este caso, el aprendizaje ocurrió antes

Etapa	Datos y operación	¿Cambian los pesos?
Aprendizaje previo	Los autores entrenaron el codificador con textos externos a Aula Abierta.	Sí, durante ese aprendizaje.
Preparar el buscador	Pasamos las 12 fichas por el codificador y guardamos sus vectores.	No.
Consultar	Pasamos una pregunta por el mismo codificador y comparamos vectores.	No.

Inferencia es aplicar los pesos aprendidos. En esta cátedra no hay un conjunto local que entrene MiniLM; hay datos locales para buscar y evaluar.

Añadir una ficha al buscador calcula un vector nuevo; no actualiza por sí solo la red.

La representación depende del contexto



«Me senté en el banco de la plaza» y «Pedí un crédito en el banco» contienen la misma palabra, pero expresan sentidos distintos.

Un modelo contextual procesa las palabras junto con su entorno. Después resume la oración en un vector para compararla con otras.

Representaremos el texto completo de cada consulta y de cada ficha.

Destilación: aprender de los vectores de otra red

En la **destilación**, una red ya entrenada (**maestro**) entrega la referencia que otra red (**estudiante**) aprende a imitar. Aquí la referencia es un vector.



Ejemplo ilustrativo de 2 coordenadas: error medio cuadrático $= [(0.4 - 0.2)^2 + (0.6 - 0.8)^2]/2 = 0.04$.

Se actualizan los pesos del estudiante para acercar su salida a la referencia. El maestro permanece fijo.

MiniLM: de un modelo compacto a un vector de oración

MiniLM nombra una familia de modelos de lenguaje compactos de Microsoft. **LM** corresponde a *Language Model*; «Mini» alude a su tamaño reducido.

Qué se construyó	Cómo se aprendió
La familia MiniLM	Una red pequeña imitó relaciones internas de un maestro mayor: destilación para comprimir.
La versión de oraciones que usamos	Sentence Transformers adaptó representaciones de oraciones con frases y traducciones para compararlas entre idiomas.

Nuestro modelo: `paraphrase-multilingual-MiniLM-L12-v2`. Entrega 384 coordenadas por texto; en este ejercicio produce vectores, no respuestas redactadas.

Elegimos reutilizar sus pesos. También podríamos adaptarlos con datos propios o entrenar otro modelo.

MPNet y LaBSE: otras formas de aprender la representación

MPNet: *Masked and Permuted Pre-training*. Su modelo original aprendió a recuperar partes ocultas del texto, variando el orden de predicción y conservando información de posición.

La versión MPNet multilingüe de Sentence Transformers transfiere representaciones de un maestro basado en MPNet a una red multilingüe, usando frases y traducciones.

LaBSE: *Language-agnostic BERT Sentence Embedding*, representación de oraciones compartida entre idiomas. Parte de una red BERT, que usa contexto a ambos lados de cada posición.

LaBSE combina completar texto oculto con aprender a ubicar la traducción correcta por encima de frases que no son su traducción.

Cambian los datos, la red y el objetivo de aprendizaje. Ninguno tiene garantizado ser el mejor para nuestras consultas.

¿Todos convierten el texto en números de la misma manera?

Comparten el esquema **texto** $\rightarrow$ **tokens** $\rightarrow$ **vectores con contexto** $\rightarrow$ **vector de oración**. Un token es una palabra o fragmento, identificado en el vocabulario de cada modelo.

La red transforma los tokens en vectores aprendidos. Estas versiones de Sentence Transformers resumen el texto así:

Versión de oraciones	Cómo resume las posiciones	Salida
MiniLM multilingüe	Media de las posiciones válidas.	384 valores
MPNet multilingüe	Media de las posiciones válidas.	768 valores
LaBSE	Posición especial de resumen y capa aprendida.	768 valores

Los espacios no son intercambiables. Consulta y fichas deben usar el mismo codificador y procesamiento.

De dónde salen los números del ejemplo

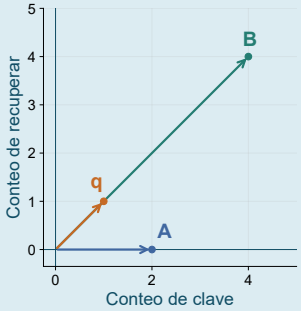
Para entender la comparación, usamos textos simplificados y **contamos palabras**: primera coordenada = veces «clave»; segunda = veces «recuperar».

Texto simplificado	clave	recuperar
Consulta q: «recuperar clave»	1	1
Texto A: «clave clave»	2	0
Texto B: «recuperar clave» repetido 4 veces	4	4

$$q = (1, 1), \qquad a = (2, 0), \qquad b = (4, 4)$$

Los números salen de contar. Este ejemplo explica la geometría; no son embeddings de la red.

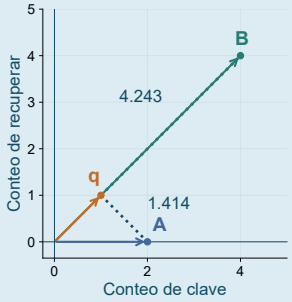
Leer un vector en el plano



Cada vector parte del origen y termina en el punto definido por sus dos coordenadas.
Dirección: q y B siguen la misma diagonal porque ambas coordenadas crecen en la misma proporción.
Longitud: B se extiende más lejos del origen que q.

La dirección describe el perfil entre coordenadas; la longitud describe su escala.

La distancia compara los puntos finales



La distancia euclidiana mide cuánto separa a dos puntos:

$$\|q - a\| = \sqrt{(1-2)^2 + (1-0)^2}$$

$$\|q - a\| = \sqrt{2} \approx 1.414.$$

$$\|q - b\| = \sqrt{(1-4)^2 + (1-4)^2}$$

$$\|q - b\| = \sqrt{18} \approx 4.243.$$

A está más cerca como punto, pero B conserva el perfil que queremos comparar.

Producto interno: multiplicar y sumar

Multiplicamos las coordenadas correspondientes de la consulta y del documento. Luego sumamos los resultados:

$$q^{\mathsf{T}} a = \sum_{j=1}^{d} q_j a_j$$

j recorre las d coordenadas. $q^{\mathsf{T}} a$ se lee «producto interno de q con a». En nuestro ejemplo, $q = (1, 1)$.

Documento	Cuenta completa	Producto
A: $(2, 0)$	$1 \cdot 2 + 1 \cdot 0$	2
B: $(4, 4)$	$1 \cdot 4 + 1 \cdot 4$	8

B obtiene un producto mayor, pero falta separar perfil y escala.

El producto interno aumenta con la escala



Si $b = (4, 4)$, entonces $2b = (8, 8)$ conserva el mismo perfil.

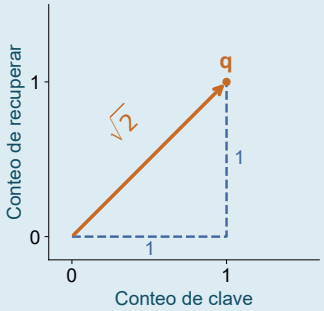
$$q^{\mathsf{T}} b = 8$$

$$q^{\mathsf{T}} (2b) = 16$$

El puntaje se duplica aunque la dirección del documento no haya cambiado.

Para comparar perfiles sin premiar la escala, necesitamos medir la longitud.

Norma: la longitud de un vector



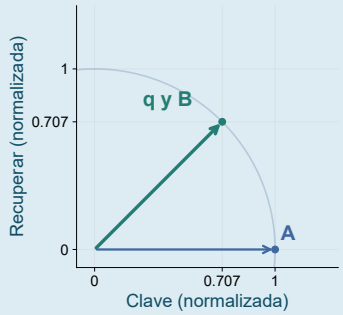
La norma euclidiana mide desde el origen hasta el punto. Es la raíz de la suma de cuadrados:

$$\|z\| = \sqrt{z_1^2 + \cdots + z_d^2}$$

$\|q\| = \sqrt{1^2 + 1^2} = \sqrt{2}.$
$\|a\| = \sqrt{2^2 + 0^2} = 2.$
$\|b\| = \sqrt{4^2 + 4^2} = \sqrt{32}.$

La norma resume la escala del vector en un solo número.

Normalización: longitud uno, misma dirección



Para $z \neq 0$, definimos $\widehat{z} = z/\|z\|$. Dividimos **todas** sus coordenadas por la misma longitud.

$$\widehat{q} = \frac{(1,1)}{\sqrt{2}} \approx (0.7071, 0.7071)$$

$$\widehat{a} = \frac{(2,0)}{2} = (1,0)$$

$$\widehat{b} = \frac{(4,4)}{\sqrt{32}} \approx (0.7071, 0.7071)$$

q y B coinciden porque compartían dirección.

Normalizar retira la escala original y conserva el perfil entre coordenadas.

Coseno: el producto después de normalizar

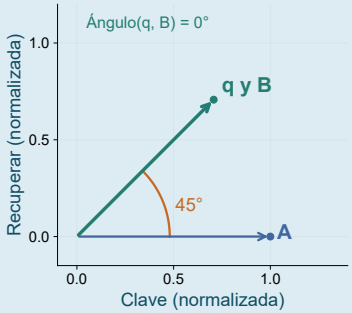
El coseno compara direcciones. Dividir por las dos normas retira del producto interno la escala de ambos vectores:

$$\cos(q, z) = \frac{q^{\mathsf{T}} z}{\|q\| \, \|z\|} = \widehat{q}^{\mathsf{T}} \widehat{z}$$

Documento	Sustitución	Coseno
A	$\frac{2}{\sqrt{2} \cdot 2}$	0.7071
B	$\frac{8}{\sqrt{2} \cdot \sqrt{32}} = \frac{8}{8}$	1

B ocupa el primer lugar: tiene la misma dirección que la consulta.

Cómo interpretar el valor del coseno



La cuenta coincide con el coseno del ángulo entre los vectores:

Ángulo	Valor
0°	1
45°	0.7071
90°	0
180°	−1

q y B forman 0 grados. q y A forman 45 grados.

Coseno 0.8 es un puntaje geométrico; no significa 80 % de probabilidad de acierto.

Las medidas responden preguntas distintas

Medida	A	B	Qué compara
Distancia	1.414	4.243	Separación entre puntos.
Producto interno	2	8	Coordenadas, con efecto de la escala.
Coseno	0.7071	1	Dirección, retirando la escala.

La menor distancia favorece A. El mayor coseno favorece B, que conserva el perfil de la consulta en este ejemplo.

La medida se elige según el modelo y la tarea; el coseno no es una solución universal.

El coseno en 384 dimensiones

En MiniLM, las 384 coordenadas resultan de la red aprendida, no del conteo de dos palabras. La comparación usa las mismas operaciones:

$$\cos(q, z) = \frac{q_1 z_1 + \cdots + q_{384} z_{384}}{\sqrt{q_1^2 + \cdots + q_{384}^2}\,\sqrt{z_1^2 + \cdots + z_{384}^2}}$$

- Consultas y documentos deben usar el mismo espacio de representación.
- Calculamos un coseno por documento y ordenamos de mayor a menor.
- Obtenemos candidatos cuyo contenido todavía debemos revisar.

Con vectores normalizados, basta sumar los 384 productos de coordenadas.

Qué construimos en la primera parte

Concepto	Papel en la búsqueda
Embedding	Representa el texto mediante números aprendidos.
Producto interno	Multiplica coordenadas correspondientes y suma.
Norma y normalización	Miden y retiran la escala del vector.
Coseno	Compara direcciones para ordenar candidatos.

B conserva el perfil de q y obtiene el mayor coseno. En datos reales verificaremos si esa cercanía corresponde a una respuesta pertinente.

Después de la pausa: aplicar la búsqueda y medir sus aciertos y errores.

La búsqueda en las fichas de Aula Abierta

Estas son las **12 fichas**; cada identificador es permanente.

Fichas D01–D06	Fichas D07–D12
D01 · Acceso: recuperar contraseña.	D07 · Equipos: tres o cuatro personas.
D02 · Grabaciones: videos por 30 días.	D08 · Software: R y Python gratuitos.
D03 · Certificado: 80 % de asistencia; nota mínima 4.0.	D09 · Tutorías: miércoles, 19:00–20:00.
D04 · Prórrogas: revisión individual.	D10 · Privacidad: datos públicos o sintéticos.
D05 · Pagos: tres cuotas sin interés.	D11 · A17: 12 de noviembre, 18:00.
D06 · Becas: parcial de 25 %; no completa.	D12 · A71: 19 de noviembre, 18:00.

Cada consulta se compara con los mismos 12 documentos.

Qué papel cumple cada conjunto en nuestro ejemplo

Datos	Para qué se usan
Textos del aprendizaje previo	Los autores los usaron para aprender los pesos de MiniLM. Son externos al caso.
12 fichas de Aula Abierta	Base que consultaremos. Ajustan vocabulario y pesos de TF-IDF; no entrenan MiniLM.
16 consultas de validación	Comparar recetas y elegir decisiones de búsqueda; no actualizar la red.
16 consultas de prueba	Evaluar la receta final sin volver a elegirla con estos resultados.

Cada grupo de consultas contiene 12 preguntas con respuesta y 4 sin respuesta. Ambos consultan las mismas 12 fichas.

Evaluamos preguntas nuevas sobre las mismas fichas de ayuda.

Si quisiéramos adaptar el codificador

Necesitaríamos un **conjunto de entrenamiento propio**: consultas y fichas cuya relevancia conocemos. Por ejemplo:

Consulta nueva para entrenar	Ficha asociada	Señal
«No logro iniciar sesión»	D01 · Recuperar acceso	Relevante
«No logro iniciar sesión»	D09 · Horario de tutorías	No relevante

La pérdida favorecería la ficha relevante frente a la otra y el optimizador actualizaría los pesos. Harían falta muchos más ejemplos variados.

Es una alternativa hipotética: hoy no la ejecutamos. Entrenamiento, validación y prueba deben permanecer separados.

TF-IDF: frecuencia del término y peso en el corpus

Comparemos los embeddings con una referencia basada en conteos ponderados.

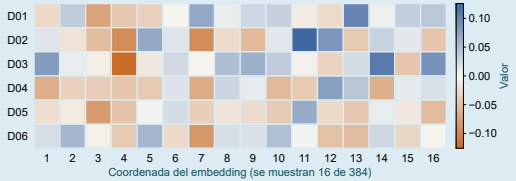
Sigla en inglés	Significado y uso
TF · Term Frequency	Frecuencia del término: aquí, cuántas veces aparece una palabra en un texto.
IDF · Inverse Document Frequency	Frecuencia inversa de documentos: da más peso a palabras presentes en menos fichas.

$$\mathrm{TF}-\mathrm{IDF}_{ij} = \mathrm{TF}_{ij}\,\mathrm{IDF}_j, \qquad \mathrm{IDF}_j = \log\left(\frac{1+N}{1+\mathrm{DF}_j}\right) + 1$$

N: cantidad de fichas. DF_j (Document Frequency): fichas que contienen la palabra j. i identifica un texto; $\log$ es el logaritmo natural.

Contamos, ponderamos con IDF y normalizamos para comparar por coseno.

Del texto a los vectores que ya calculamos



Pasamos cada ficha completa por MiniLM y dividimos su vector por su norma. Cada fila contiene 384 coordenadas; aquí vemos solo 16.

Repetimos el mismo procesamiento para las consultas. El color muestra un valor numérico, no una etiqueta, una palabra ni una probabilidad.

Los archivos incluyen esos vectores normalizados. Ahora calcularemos una comparación concreta.

Una consulta, una ficha y un puntaje

V01: «Olvidé mi clave…». **D01**: la ficha de recuperación de acceso. Sus vectores ya están normalizados: multiplicamos coordenadas correspondientes y sumamos.

Coordenada	Consulta V01	Ficha D01	Producto
1	0.04347	-0.02631	-0.00114
2	0.02170	0.03797	0.00082
3	0.02971	-0.07323	-0.00218
Otras 381	…	…	0.45262 (suma)

$$\cos(V01, D01) = \sum_{j=1}^{384} q_j d_j \approx 0.45013$$

Se suman las 384 coordenadas. La tabla muestra valores redondeados.

De un puntaje a la matriz de comparaciones

Consulta / ficha	D01	D02	D03	...	D12
V01	**0.450**	-0.150	0.078	...	-0.128
V02	0.131	0.147	-0.022	...	0.098
V03	0.052	0.056	0.366	...	0.048
...	...	...	...	...	...

Cada fila compara una consulta con las 12 fichas. Cada columna compara una ficha con las 16 consultas de validación.

Q: 16 consultas × 384 coordenadas. D: 12 fichas × 384 coordenadas.

$S = QD^{\mathsf{T}}$ reúne los 16×12 puntajes. Trasponer D pone las fichas en columnas para multiplicarlas por cada consulta y sumar.

Ordenar los puntajes de una fila produce el ranking de esa consulta.

La consulta de acceso: ranking obtenido

Consulta V01: «Olvidé mi clave, ¿cómo vuelvo a entrar?». El documento pertinente es D01, que explica cómo recuperar la contraseña.



TF-IDF sitúa D01 en el lugar 6, con puntaje 0. MiniLM lo sitúa **primero**, con coseno 0.450. Las barras verdes identifican el documento pertinente.

En esta consulta, la representación aprendida recupera la paráfrasis.

Cómo evaluaremos el buscador

Una consulta: V02. «No pude asistir, ¿puedo ver el video después?». D02 responde: las grabaciones se publican al día siguiente y duran 30 días.

Posición en MiniLM	Documento encontrado	¿Responde V02?
1	D06 · Becas: financiamiento parcial.	No
2	D02 · Grabaciones: disponibilidad del video.	Sí
3	D01 · Acceso: recuperar la contraseña.	No

El **rango** r es la posición de la ficha relevante. Para V02, $r = 2$: al mostrar tres documentos, recuperamos la respuesta a esta consulta.

Las tres filas son documentos de una sola consulta. Esa consulta aporta un único acierto.

Hit@k: aciertos entre los primeros k

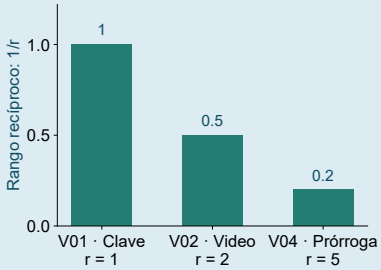
Ahora cada fila es una consulta distinta. Hit significa «acierto» y @k, «entre los primeros *k* resultados». *Hit Rate at k* es la proporción de consultas con acierto.

Consulta	Ficha que responde	Rango en MiniLM	Aporte a Hit@3
V01 · Recuperar clave	D01 · Acceso	1	1: está entre 1 y 3
V02 · Ver el video	D02 · Grabaciones	2	1: está entre 1 y 3
V04 · Pedir prórroga	D04 · Plazos	5	0: queda después de 3

$$\text{Hit@3} = \frac{1+1+0}{3} = \frac{2}{3} \approx 0.667$$

Los aportes 1, 1, 0 corresponden a tres preguntas. V02 aporta solo el 1 de la segunda fila.

MRR: dar más valor a las primeras posiciones

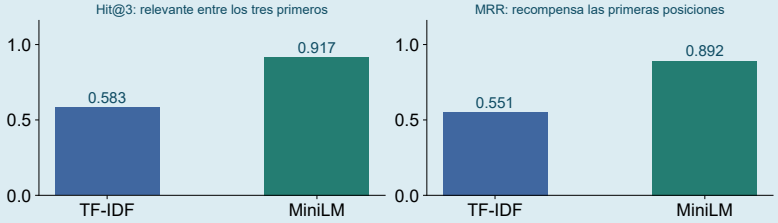


MRR: *Mean Reciprocal Rank*, promedio del rango recíproco. Cada consulta aporta $1/r$, donde r es la posición de su ficha relevante.
Conservamos V01, V02 y V04: sus rangos son $1,\ 2,\ 5$. Sus aportes son $1,\ 1/2,\ 1/5$.

$$\mathrm{MRR} = \frac{1 + 0.5 + 0.2}{3} \approx 0.567$$

V01 y V02 acertaban en Hit@3; MRR distingue el primer lugar del segundo.

Resultados en las doce consultas respondibles



Con tres candidatos, TF-IDF recupera el relevante en **7 de 12** consultas. MiniLM lo recupera en **11 de 12**.

MiniLM también tiene mayor MRR: los relevantes aparecen antes en promedio. Es una comparación de estas dos recetas en este caso pequeño y construido.

El promedio favorable debe acompañarse de una revisión de los errores.

Dos errores que el promedio no explica

Consulta	Ficha que responde	Rango en MiniLM
«No pude asistir, ¿puedo ver el video después?»	D02: grabaciones disponibles durante 30 días.	2
«¿Me conceden más días automáticamente si pido prórroga?»	D04: cada solicitud se revisa; no hay aprobación automática.	5

Mostrar tres candidatos permite encontrar D02 en la primera consulta. En la segunda, D04 queda fuera de esos tres candidatos.

La cercanía calculada puede perder una relación importante para responder.

Los identificadores cambian la respuesta

Consulta	Documento pertinente	Fecha
¿Cuándo vence A17?	D11	12 de noviembre, 18:00
¿Cuándo vence A71?	D12	19 de noviembre, 18:00

Las fichas comparten casi todas sus palabras. Sin embargo, confundir A17 con A71 produce una fecha incorrecta.

En estas dos consultas, TF-IDF y MiniLM ubican la ficha pertinente primero. La coincidencia exacta sigue siendo una señal útil.

La utilidad de una representación incluye conservar diferencias decisivas para la tarea.

Información relacionada pero insuficiente

Consulta: «¿Cuál es el precio total en pesos?»

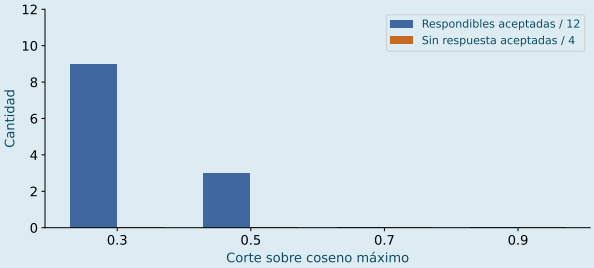
La ficha **D05** dice: «El arancel puede pagarse en tres cuotas mensuales sin interés».

Ambas recetas sitúan D05 primero. Su contenido trata de pagos, pero no informa el valor de las cuotas ni el precio total.

Lo que sabemos	Lo que falta
Hay tres cuotas.	Cuánto vale cada cuota o el total.

Un ranking siempre tiene un primer lugar, incluso si ningún documento responde.

El corte de aceptación y su costo



Aceptamos una consulta si su **coseno máximo** alcanza el corte. Con corte 0.3 aceptamos 9 de 12 consultas respondibles. Con 0.5 aceptamos solo 3.
Las 4 consultas sin respuesta quedan rechazadas en ambos cortes. Son muy pocas para generalizar.

Aceptar significa superar el corte; no demuestra que el primer documento sea correcto.

Aceptar, recuperar y responder

Etapa	Qué se comprueba
Aceptar la consulta	El puntaje alcanza el corte definido.
Recuperar información	La ficha pertinente aparece entre los candidatos.
Responder correctamente	La respuesta utiliza fielmente información suficiente de la ficha.

D05 puede quedar primero para una pregunta de precio y aun así ser insuficiente. Encontrar un vecino y contestar bien son resultados diferentes.

Cada etapa necesita un criterio de evaluación propio.

Demostración: mostrar uno o tres candidatos

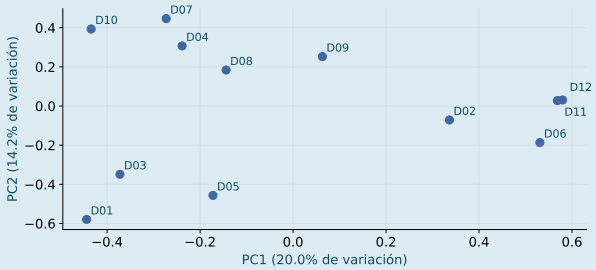
Conservamos los vectores, los cosenos y el orden. Cambiamos únicamente cuántos documentos mostramos por consulta.

Receta	Hit@1	Hit@3	MRR
TF-IDF	5/12	7/12	0.551
MiniLM	10/12	11/12	0.892

Mostrar tres candidatos recupera casos que estaban en los lugares 2 o 3. MRR permanece igual porque el ranking completo no cambia.

La interfaz puede mostrar más resultados sin que el modelo haya aprendido algo nuevo.

Ver los embeddings mediante una proyección



PCA resume las 384 coordenadas de las fichas en dos ejes para dibujarlas.

Los dos ejes explican aproximadamente 34.3 % de la variación (suma antes de redondear). El dibujo omite otras diferencias.

La búsqueda sigue usando las 384 coordenadas originales, no los dos ejes de esta figura.

El mapa ayuda a explorar; la calidad de la búsqueda se juzga con consultas y relevancia.

El embedding como entrada de otros modelos



Uso	Qué hacemos con los vectores
Clasificación	Aprender a predecir etiquetas a partir de sus coordenadas.
Agrupamiento	Formar grupos y estudiar su coherencia y estabilidad.
Búsqueda	Ordenar objetos respecto de una consulta.

Cambiar la tarea cambia qué resultado debemos evaluar.

Qué debemos revisar al cambiar la aplicación

Cambio	Consecuencia
Otro codificador	Recalcular documentos y consultas en el mismo espacio.
Otra división de las fichas	Revisar qué fragmentos contienen información suficiente.
Otro dominio o tipo de consulta	Evaluar con ejemplos representativos de ese uso.
Otro puntaje o corte	Volver a medir recuperación y aceptación.

Validamos una receta completa: representación, comparación, candidatos y criterio de éxito.

La respuesta a nuestra pregunta inicial

Para «Olvidé mi clave», el codificador representa consulta y fichas en un espacio común. El coseno permite ordenar los candidatos y **D01 aparece primero**.

Al leer D01 confirmamos el procedimiento: usar Recuperar acceso y revisar el enlace enviado al correo registrado.

- El embedding aporta una representación aprendida.
- La comparación matemática organiza los candidatos.
- La relevancia y la información disponible determinan si podemos responder.

Una representación útil debe conducir a fuentes pertinentes; la evaluación comprueba si lo consigue.