Evaluación Diplomado
Data Science

PROYECTO DE CURSO 2026

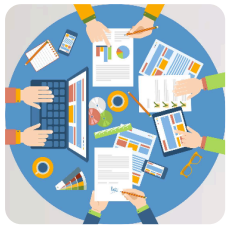
Informe Nº 1 — Pasos 1 - 4 de la Metodología

¿EN QUÉ CONSISTE?

En grupos de **2 a 5 personas**, deberán realizar un proyecto de aplicación, iniciando con la **definición del problema** para alguna organización, empresa o actividad de interés, definir los distintos orígenes y datos que usarán, aplicar **técnicas de ciencia de datos** aprendidas en el diplomado y finalizar con **conclusiones y presentación** del trabajo al curso.



EL PROYECTO DEBE CONSIDERAR

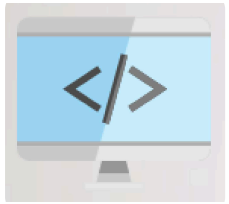


Aplicación de metodología de 6 pasos revisada en clases.

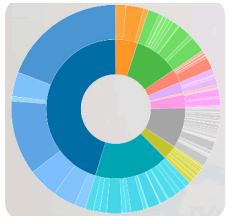


Detallar el mapeo, preparación y exploración de los datos con sus respectivas conclusiones.

EL PROYECTO DEBE CONSIDERAR (CONT.)



Diseño de modelo estadístico para el proceso analítico a efectuar con sus justificaciones respectivas.

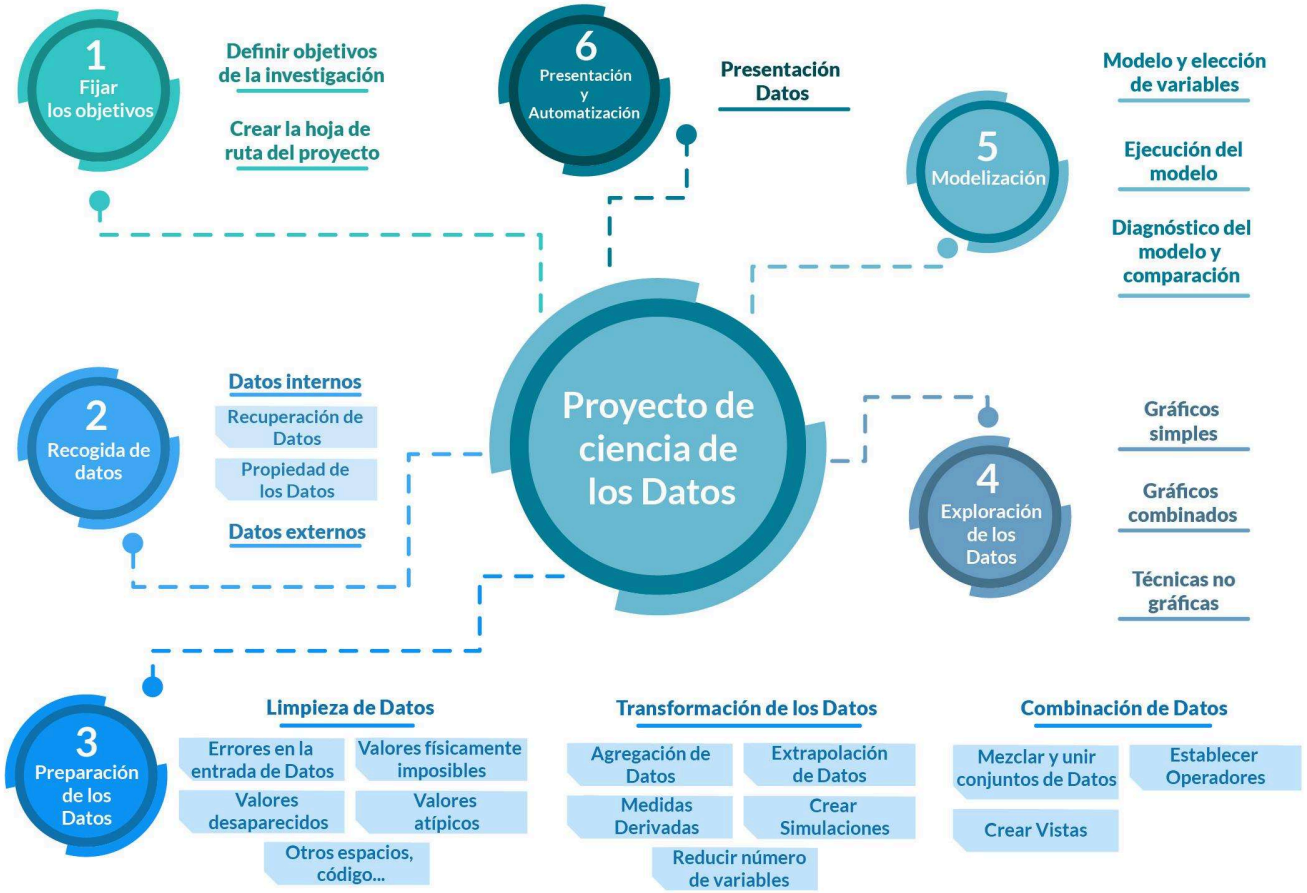


Conclusiones y presentación de los resultados obtenidos, incluyendo *dashboards* y cuadros de mando integral.

OBJETIVOS DEL PROYECTO

1. Abordar una problemática u optimización de un proceso.
2. Identificar los distintos orígenes de datos necesarios y aplicar los pasos para prepararlos.
3. Analizar los datos, mostrar técnicas aplicadas y conclusiones.
4. Definir un modelo analítico teórico utilizando técnicas de *data science* revisadas en clases.
5. *Desarrollar* un modelo analítico teórico utilizando técnicas de *data science* revisadas en clases.
6. Realizar una presentación con conclusiones y resultados, destacando cómo las técnicas ayudaron al problema planteado.

METODOLOGÍA - PROCESO DE CIENCIA DE DATOS (6 PASOS)



Proceso referencial

EVALUACIÓN - RÚBRICA (1/2) — INFORME Nº 1, PASOS 1-4 METODOLOGÍA

Criterio	Qué se espera	Por lograr	Logrado	Superado	Pts. máx
1. Definición del problema	*Claridad con que se presenta la situación a resolver: contexto, impacto y justificación del enfoque de ciencia de datos.*	Describe superficialmente el problema sin contexto ni justificación analítica. *(5 pts)*	Describe el problema y contexto, pero la justificación del enfoque de ciencia de datos es parcial. *(10 pts)*	Define claramente el problema, contexto, impacto y justifica el uso de ciencia de datos. *(15 pts)*	**15**
2. Objetivos del proyecto	*Objetivo general y objetivos específicos medibles, coherentes con la problemática y orientados a generar valor.*	Objetivo general ambiguo o ausente. Sin objetivos específicos relacionados al problema. *(5 pts)*	Define el objetivo general, pero los específicos son incompletos o poco precisos. *(10 pts)*	Define objetivo general y al menos 3 objetivos específicos medibles, coherentes y viables. *(15 pts)*	**15**
3. Preguntas de negocio	*Preguntas claras, accionables y respondibles mediante técnicas de datos, alineadas con la problemática.*	Preguntas ambiguas o no respondibles mediante análisis de datos. *(5 pts)*	La mayoría son respondibles con datos, aunque algunas presentan ambigüedad o falta de foco. *(10 pts)*	Preguntas claras, alineadas al problema y orientadas a generar valor o apoyar decisiones. *(15 pts)*	**15**

Escala: Por lograr = 1/3 del puntaje máximo · Logrado = 2/3 del puntaje máximo · Superado = puntaje máximo

EVALUACIÓN - RÚBRICA (2/2) — INFORME Nº 1, PASOS 1-4 METODOLOGÍA

Criterio	Qué se espera	Por lograr	Logrado	Superado	Pts. máx
4. Datos y alcance (*)	*Descripción de fuentes de datos, variables relevantes, período de análisis, restricciones y límites del estudio. Los requisitos mínimos del dataset dependen de la naturaleza de los datos (*)*	No define fuentes, variables, período ni restricciones. Alcance inexistente o inviable. *(7 pts)*	Define parcialmente fuentes y variables. Omite restricciones u otros límites del estudio. No justifica la cantidad de variables ni el tamaño del dataset. *(14 pts)*	Define fuentes, variables justificadas, período, restricciones y dataset que cumple los requisitos mínimos según la naturaleza de los datos (*). *(20 pts)*	**20**
5. Metodología y planificación	*Aplicación de la metodología de 6 pasos al proyecto, coherencia entre etapas, herramientas y planificación con hitos.*	No especifica metodología o las etapas son incoherentes. Sin planificación ni hitos. *(5 pts)*	Describe la metodología con coherencia, pero sin indicar origen de datos o planificación general. *(10 pts)*	Describe los 6 pasos aplicados al proyecto con herramientas, origen de datos e hitos con fechas. *(15 pts)*	**15**
6. Limpieza, transformación (**) y exploración (EDA) (***)	*Estadísticas descriptivas, visualizaciones pertinentes, identificación y tratamiento de problemas de calidad de datos (***). Cuando aplica, transformación de variables justificada (**).*	Sin EDA o solo df.head(). No identifica problemas de calidad de datos ni relaciones entre variables. Cuando aplica, no realiza transformación de variables. *(7 pts)*	Estadísticas básicas y algunas visualizaciones. Identifica nulos pero no profundiza. Cuando aplica, transforma variables sin justificar el criterio. *(14 pts)*	Estadísticas completas, histogramas, boxplots, heatmap, nulos y outliers tratados con conclusiones (***). Cuando aplica, transforma variables justificando el criterio (**). *(20 pts)*	**20**

Consideraciones: *Formato PDF | Límite 15 hojas | La rúbrica no es un índice, son los criterios a evaluar | Se descontará por ortografía y uso de IA sin personalizar.*
Penalización (se descuentan 10 pts por cada infracción): *(1) El informe no sigue una estructura formal (portada, índice, introducción, desarrollo y conclusiones). (2) Se incluyen pantallazos de la consola de R o Python en lugar de código o salidas formateadas. (3) Los gráficos no están exportados correctamente y se presentan como capturas de pantalla. (4) Hay gráficos o tablas sin comentario o interpretación asociada.*

(*) REQUISITOS MÍNIMOS DEL DATASET

Datos transversales

Variables	Entre 8 y 15. Más no es mejor: cada variable que agregan tiene que justificarse.
Observaciones	Mínimo 500–1.000 filas tras la limpieza. Con menos, los modelos no generalizan.
Split	Train/test puede ser aleatorio, pero estratificado si hay clases desbalanceadas.

Series de tiempo

Variables	Entre 5 y 10. Ser conservador: solo incluir lo que esté disponible al momento de predecir.
Historial	Al menos 3 veces el ciclo más largo. Serie mensual con estacionalidad anual → mínimo 3 años.
Puntos temporales	200–300 tras preprocesamiento. El split siempre respeta el orden cronológico, nunca aleatorio.

¿Cómo saber si una variable vale la pena incluirla? Tiene que cumplir al menos dos de estos tres criterios: tiene sentido en el dominio del problema, mejora las métricas de validación, o su importancia es verificable (SHAP, p-value, coeficiente). Si no pasa ese filtro, fuera.

(**) TRANSFORMACIÓN DE VARIABLES — ¿CUÁNDO APLICA?

Ejemplos donde SÍ aplica

- Variables con escala muy diferente → **normalización / estandarización**
- Variables categóricas que serán modeladas → **codificación (one-hot, label)**
- Fechas que se descomponen en mes, día, año → **extracción de atributos**
- Combinar columnas para crear un indicador → **derivación de nuevas variables**
- Distribuciones muy asimétricas → **transformación logarítmica o raíz cuadrada**

Ejemplos donde NO aplica

- Variables ya en la escala correcta para el análisis
- Proyectos puramente descriptivos sin modelado
- Datos categóricos usados solo para agrupar o filtrar
- Variables cuyo valor original debe preservarse para la interpretación

Nota: No es obligatorio transformar variables. Lo importante es que el equipo *evalúe si es necesario*, justifique su decisión y documente qué transformaciones realizó y por qué. Si no aplica, basta con indicarlo brevemente en el informe.

(***) ANÁLISIS EXPLORATORIO — ¿QUÉ SE ESPERA?

Estadísticas Descriptivas

TENDENCIA	Media, mediana y moda de cada variable numérica
DISPERSIÓN	Desviación estándar, varianza, rango e IQR
POSICIÓN	Percentiles (25%, 75%) y valores mínimo/máximo
FORMA	Asimetría (skewness) y curtosis cuando sea relevante
CATEG.	Frecuencias y proporciones de variables categóricas

Visualizaciones

DISTRIBUCIÓN	Histogramas o densidad por variable numérica
CATEGORÍAS	Gráfico de barras para variables categóricas
OUTLIERS	Boxplot (diagrama de caja) por variable o grupo
RELACIÓN	Scatter plot o matriz de correlaciones entre variables
TENDENCIA	Gráfico de líneas si hay variable temporal

Mínimo esperado: al menos **3 visualizaciones** y estadísticas descriptivas completas para las variables principales. Cada gráfico debe tener título, etiquetas de ejes e interpretación breve (1–2 oraciones explicando qué revela el gráfico sobre el fenómeno estudiado).

FECHAS IMPORTANTES

FECHA DE ENTREGA

20 de agosto

Informe Nº 1 — Pasos 1-4 de la Metodología

SESIONES DE COACHING

Por definir

Las fechas serán informadas oportunamente

Para las sesiones de coaching: Es fundamental que los alumnos lleguen con la **pauta estudiada** y con **dudas concretas** preparadas.

No se revisarán trabajos durante estas sesiones.