DIPLOMADO EN DATA SCIENCE UC 2025

Facultad de Matemáticas — Pontificia Universidad Católica de Chile

"Modelo Predictivo de Demanda para la Optimización de Inventario en una Cadena de Supermercados de la Región Metropolitana"

INFORME N°1

Entendimiento del Negocio · Entendimiento de los Datos · Preparación · Exploración Inicial

Integrantes:

XXXX — Ingeniera Comercial
XXXX — Analista de Datos
XXXX — Ingeniera en Sistemas
XXXX — Estadístico
XXXX — Administradora de Empresas

Agosto 2025

Indice

1. Introduccion
2. Definicion de la Problematica
3. Objetivos del Proyecto
   3.1. Objetivo General
   3.2. Objetivos Especificos
4. Preguntas de Negocio
5. Fuentes y Descripcion de los Datos
   5.1. Origen de los Datos
   5.2. Periodo de Analisis y Volumen
   5.3. Variables del Dataset
   5.4. Alcance y Restricciones
6. Planificacion del Proyecto
7. Metodologia: CRISP-DM aplicado al proyecto
   7.1. Fase 1 - Entendimiento del negocio
   7.2. Fase 2 - Entendimiento de los datos
   7.3. Fase 3 - Preparacion de los datos
   7.4. Fase 4 - Exploracion de los datos
   7.5. Fases 5 y 6 - Modelado, evaluacion y despliegue
8. Analisis Exploratorio de los Datos (EDA)
   8.1. Estadisticas Descriptivas
   8.2. Distribucion de la Variable Objetivo y Deteccion de Outliers
   8.3. Calidad de los Datos - Valores Faltantes
   8.4. Analisis Temporal de la Demanda
   8.5. Distribucion de Mermas por Categoria
   8.6. Analisis de Relaciones entre Variables
   8.7. Sintesis del Analisis Exploratorio
9. Conclusiones
   9.1. Entendimiento del negocio
   9.2. Datos y alcance
   9.3. Analisis exploratorio
   9.4. Proximos pasos
10. Referencias

1. Introducción

En Chile, el sector del retail alimentario enfrenta desafíos estructurales relacionados con la gestión eficiente del inventario en un contexto de alta variabilidad de la demanda, cambios en los patrones de consumo y presión creciente sobre los márgenes operacionales. Una cadena de supermercados de la Región Metropolitana, con presencia en 18 comunas y más de 45.000 productos activos en catálogo, enfrenta de manera concreta esta problemática.

El principal desafío operativo identificado es la dificultad para anticipar con precisión la demanda futura de sus productos, lo que genera simultáneamente dos consecuencias negativas: el quiebre de stock —que implica pérdidas directas en ventas y deterioro de la satisfacción del cliente— y el exceso de inventario —que se traduce en mermas, especialmente relevantes en productos perecibles. Según estimaciones del departamento de operaciones, las pérdidas anuales asociadas a este problema superan los $2.800 millones de pesos chilenos.

La organización cuenta con una valiosa base histórica de transacciones de venta de cuatro años, sin embargo esta información no ha sido explotada sistemáticamente mediante técnicas de análisis avanzado. El presente proyecto aborda esa brecha, desarrollando un modelo predictivo de demanda que permita mejorar sustancialmente la planificación del inventario a nivel de producto y sucursal.

Para estructurar el desarrollo de este proyecto se adoptó la metodología CRISP-DM (Cross Industry Standard Process for Data Mining), cuyo carácter iterativo y orientado al negocio la hace especialmente adecuada para un problema con datos disponibles, dominio definido y necesidad de entregar resultados accionables. Este informe cubre los primeros cuatro pasos del proceso: entendimiento del negocio, entendimiento de los datos, preparación inicial y exploración de los datos.

2. Definición de la Problemática

La gestión de inventario en retail alimentario está determinada por múltiples variables que inciden simultáneamente en la demanda: estacionalidad del producto, comportamiento del consumidor según día de la semana, eventos especiales (feriados, fines de quincena, campañas promocionales), variaciones de precio y las particularidades de cada zona geográfica donde opera la cadena.

Actualmente, la cadena utiliza un sistema de reposición basado principalmente en el criterio experto de los jefes de sala y en promedios históricos simples. Este enfoque no captura la estacionalidad intramensual, no diferencia el comportamiento entre sucursales de distintas comunas y no modela las interacciones entre variables que explican la variabilidad de la demanda. Las consecuencias directas son cuantificables:

- Quiebre de stock: El 12,3% de los SKU activos experimenta al menos un episodio de quiebre por semana, con mayor incidencia en Frutas y Verduras.
- Mermas por perecibles: Las pérdidas por vencimiento y deterioro representan el 4,7% del costo total de ventas en categorías perecibles, superando el benchmark sectorial del 2,1%.
- Sobrestock en baja rotación: El 18% de los productos de Limpieza y Cuidado Personal presenta inventarios superiores a 90 días de venta, inmovilizando capital de trabajo.
- Pérdida de clientes: El 23% de los clientes que experimentan un quiebre de stock no regresa a la misma sucursal en las dos semanas siguientes.

Un modelo predictivo de demanda basado en datos históricos de transacciones permite capturar patrones de estacionalidad, tendencia y variabilidad que los métodos actuales omiten. La justificación del enfoque de ciencia de datos radica en que el volumen de registros disponibles (más de 32 millones de transacciones), la cantidad de variables relevantes y la complejidad de sus interacciones hacen inviable un análisis manual o el uso de métodos estadísticos simples.

3. Objetivos del Proyecto

3.1. Objetivo General

Desarrollar un modelo predictivo de demanda que permita estimar las ventas futuras de productos por sucursal en una cadena de supermercados de la Región Metropolitana, con el propósito de optimizar la gestión del inventario, reducir los quiebres de stock, disminuir las mermas por perecibles y entregar recomendaciones concretas de reposición a los equipos operacionales.

3.2. Objetivos Específicos

1. Analizar y caracterizar los patrones históricos de demanda de los últimos cuatro años (2021–2025), identificando tendencias, ciclos de estacionalidad mensual, semanal e intradiaria, y el comportamiento diferenciado entre categorías de productos y sucursales.
2. Identificar y cuantificar las variables explicativas con mayor impacto estadístico en la variación de la demanda, incluyendo factores temporales (día de la semana, quincena, feriados), características del producto (categoría, precio, margen) y atributos de la sucursal (ubicación, comuna).
3. Construir, entrenar y comparar múltiples modelos predictivos para la estimación de la demanda a un horizonte de 30 días, seleccionando el de mejor desempeño según RMSE y MAPE, con umbral de aceptación de error inferior al 15%.
4. Evaluar el impacto potencial de los resultados del modelo sobre los indicadores operacionales: reducción estimada de quiebres de stock y disminución de mermas por perecibles respecto de la situación base.
5. Desarrollar una interfaz de visualización que permita a los equipos de operaciones acceder a las predicciones de demanda y recomendaciones de reposición, desagregadas por sucursal y categoría de producto.

4. Preguntas de Negocio

Las preguntas que guían el proyecto han sido clasificadas según su naturaleza analítica: descriptivas (entender el estado actual), diagnósticas (identificar causas), predictivas (anticipar comportamientos) y prescriptivas (recomendar acciones). Esta clasificación permite estructurar el análisis de forma progresiva y asegurar que los resultados sean accionables.

ID	Tipo	Pregunta de negocio
P1	Descriptiva	¿Cuáles son los productos y categorías con mayor volumen de ventas por sucursal y período?
P2	Descriptiva	¿Qué patrones de estacionalidad (día de semana, quincena, mes) presenta la demanda de productos perecibles?
P3	Diagnóstica	¿Qué variables tienen mayor impacto en la variación de la demanda: precio, día, categoría o ubicación?

ID	Tipo	Pregunta de negocio
P4	Diagnóstica	¿En qué condiciones se concentran los episodios de quiebre de stock y de merma por perecibles?
P5	Predictiva	¿Cuántas unidades de cada producto se venderán en los próximos 30 días por sucursal?
P6	Predictiva	¿Cuál será la probabilidad de quiebre de stock para productos de alta rotación en las próximas dos semanas?
P7	Prescriptiva	¿Cuál es el nivel óptimo de reposición por producto y sucursal para minimizar quiebres y mermas simultáneamente?
P8	Prescriptiva	¿Qué categorías y sucursales deben priorizar ajustes en su política de reposición según los resultados del modelo?

Tabla 1. Preguntas de negocio clasificadas por tipo de análisis. Fuente: elaboración propia.

Las preguntas P1 a P4 orientan el análisis exploratorio desarrollado en la sección 7. Las preguntas P5 y P6 definen el objetivo del modelo predictivo que se construirá en la Entrega N°2. Las preguntas P7 y P8 guían la generación de recomendaciones prescriptivas para la gestión operacional.

5. Fuentes y Descripción de los Datos

5.1. Origen de los Datos

Los datos utilizados provienen de tres fuentes internas de la organización, cedidas formalmente al equipo mediante acuerdo de confidencialidad suscrito con la dirección de operaciones:

- Sistema de Punto de Venta (POS): Base transaccional que registra cada venta realizada en todas las sucursales, con fecha y hora exacta, producto, cantidad, precio y sucursal. Cubre enero 2021 a julio 2025.
- Sistema de Gestión de Inventario (ERP): Registra movimientos diarios de entrada y salida de bodega, stock disponible al cierre de cada día y costos de adquisición unitarios por SKU.
- Catálogo Maestro de Productos: Tabla de referencia con la descripción completa de cada producto (categoría, subcategoría, unidad de medida y proveedor), utilizada para enriquecer el dataset transaccional.

Los archivos fueron entregados en formato CSV y consolidados mediante un script de Python que realizó la unión de las tres fuentes usando ID_PRODUCTO e ID_SUCURSAL como llaves de cruce. El dataset resultante fue almacenado en formato Parquet para optimizar su procesamiento posterior.

5.2. Período de Análisis y Volumen

El dataset consolidado cubre 55 meses de historia de ventas (enero 2021 — julio 2025). Sus características principales son:

- Total de registros transaccionales: 32.847.612
- Número de sucursales: 18, en 12 comunas de la Región Metropolitana
- Número de SKU activos: 45.231 productos únicos en catálogo
- Período cubierto: 55 meses (enero 2021 — julio 2025)

El dataset supera con holgura el requisito mínimo para datos de serie de tiempo (≥ 24 puntos mensuales), contando con más de 1.640 días de historia por sucursal, lo que permite entrenar modelos con capacidad de capturar estacionalidades de corto, mediano y largo plazo.

5.3. Variables del Dataset

La tabla a continuación describe las 15 variables seleccionadas para el análisis, con su tipo y la justificación de su relevancia para el modelo predictivo.

Variable	Tipo	Descripción y relevancia
ID_TRANSACCION	Cuantitativa discreta	Identificador único de cada registro de venta. Permite rastrear transacciones y detectar duplicados.

Variable	Tipo	Descripción y relevancia
FECHA_VENTA	Cuantitativa discreta	Fecha y hora exacta de la venta. Variable clave para construir la serie de tiempo de demanda.
ID_PRODUCTO	Categórica nominal	Código único del SKU según catálogo interno. Permite vincular con la tabla maestra de productos.
DESCRIPCION	Categórica nominal	Nombre comercial del producto, incluyendo marca y presentación.
CATEGORIA	Categórica nominal	Agrupación principal: Lácteos, Carnes, Frutas y Verduras, Limpieza, Panadería, Bebidas.
SUBCATEGORIA	Categórica nominal	División dentro de la categoría (ej: dentro de Lácteos: Leches, Quesos, Yogures).
CANTIDAD_VENDIDA	Cuantitativa discreta	Unidades vendidas en la transacción. Variable objetivo (target) del modelo predictivo.
PRECIO_UNITARIO	Cuantitativa continua	Precio de venta al cliente por unidad en pesos chilenos. Posible variable explicativa.
COSTO_UNITARIO	Cuantitativa continua	Costo de adquisición por unidad (CLP). Necesaria para calcular márgenes.
MARGEN_BRUTO	Cuantitativa continua	Diferencia entre precio y costo unitario. Variable derivada calculada a partir de las dos anteriores.
ID_SUCURSAL	Categórica nominal	Código de la sucursal donde ocurrió la venta. Permite análisis geográfico desagregado.
COMUNA	Categórica nominal	Comuna de la Región Metropolitana donde se ubica la sucursal.
DIA_SEMANA	Categórica ordinal	Día en que se realizó la venta (Lunes a Domingo). Captura la estacionalidad semanal.
ES_FIN_DE_SEMANA	Categórica binaria	Indicador 1/0: valor 1 si la venta ocurrió sábado o domingo, 0 en caso contrario.
STOCK_DISPONIBLE	Cuantitativa discreta	Unidades en bodega al momento de la venta. Identifica episodios de quiebre de stock (= 0).

Tabla 2. Descripción de variables. Fuente: elaboración propia en base a datos del ERP de la organización.

5.4. Alcance y Restricciones

- Alcance geográfico: 18 sucursales de la Región Metropolitana. Sucursales de otras regiones quedan fuera del alcance de esta fase.
- Categorías prioritarias: El modelo se desarrollará primero para Frutas y Verduras, Lácteos, Carnes y Panadería, que concentran el 68% de las mermas totales.
- Horizonte de predicción: Estimaciones de demanda a 30 días con granularidad diaria por sucursal y categoría.
- Variables externas: No se incorporan en esta fase fuentes externas (clima, indicadores macroeconómicos, precios de competencia).
- Privacidad: No se utilizan datos personales de clientes. Todos los registros son a nivel de transacción de producto.

6. Planificación del Proyecto

La tabla presenta la hoja de ruta organizada en los seis pasos del proceso, con estado de avance y producto esperado por etapa. Las etapas 1 y 2 se encuentran completadas y constituyen el contenido de este informe. Las etapas 3 y 4 están en ejecución y serán la Entrega N°2. Las etapas 5 y 6 se abordarán en las entregas finales.

Paso	Etapa	Inicio	Fin	Estado	Producto esperado
1	**Entendimiento del Negocio**	Ago 2025	Sep 2025	**Completado**	Documento de objetivos, preguntas de negocio y alcance (Entrega N°1)
2	**Entendimiento de los Datos**	Sep 2025	Sep 2025	**Completado**	Dataset consolidado en CSV; diccionario de variables; reporte de calidad inicial
3	**Preparación de los Datos**	Oct 2025	Oct 2025	**En progreso**	Dataset limpio y normalizado listo para modelado (script Python documentado)
4	**Exploración de los Datos**	Oct 2025	Nov 2025	**En progreso**	Informe EDA con estadísticas descriptivas, visualizaciones y hallazgos clave
5	**Modelado y Evaluación**	Nov 2025	Dic 2025	**Abierto**	Modelo predictivo entrenado y validado; métricas RMSE y MAPE
6	**Presentación y Despliegue**	Ene 2026	Ene 2026	**Abierto**	Dashboard interactivo en Streamlit + informe final + presentación al equipo

Tabla 3. Hoja de ruta del proyecto. Fuente: elaboración propia.

Las herramientas tecnológicas utilizadas son: Python 3.11 (pandas, NumPy, scikit-learn, XGBoost, Prophet, statsmodels, matplotlib, seaborn, plotly), Jupyter Notebook como entorno de desarrollo, Git/GitHub para control de versiones y Streamlit para el prototipo del dashboard final.

7. Metodologia: CRISP-DM aplicado al proyecto

Para estructurar el desarrollo del proyecto se adopto la metodologia CRISP-DM (Cross-Industry Standard Process for Data Mining). A diferencia de enfoques lineales, CRISP-DM es iterativo: los hallazgos en etapas avanzadas pueden retroalimentar decisiones de etapas anteriores, lo que resulta especialmente pertinente en proyectos de prediccion de demanda donde la exploracion de datos suele revelar necesidades no anticipadas en la fase de diseno.

7.1. Fase 1 - Entendimiento del negocio

Comprende la definicion del problema desde la perspectiva organizacional, la identificacion de los criterios de exito y la traduccion de los objetivos de negocio en preguntas analiticas. En este proyecto derivo en 8 preguntas clasificadas por tipo de analisis (descriptivo, diagnostico, predictivo y prescriptivo) y en la definicion del umbral de desempeno RMSE/MAPE < 15%.

7.2. Fase 2 - Entendimiento de los datos

Incluye la recopilacion inicial, la descripcion de estructura y contenido, y la identificacion de problemas de calidad. Se integraron tres fuentes (POS, ERP y Catalogo Maestro), se documentaron 15 variables con tipo y justificacion, y se genero un reporte de calidad que detecto 1.243 duplicados, 312 transacciones negativas y tasas de valores faltantes por variable.

7.3. Fase 3 - Preparacion de los datos

Abarca la seleccion, limpieza, construccion y formateo del dataset final para modelado. Acciones planificadas: eliminacion de duplicados y transacciones invalidas, imputacion de valores faltantes segun estrategia por variable, tratamiento de outliers mediante Winsorizing al percentil 99, e ingenieria de atributos temporales (dia de semana, semana del mes, indicador de feriado). Esta fase esta actualmente en ejecucion.

7.4. Fase 4 - Exploracion de los datos

Consiste en el analisis del dataset mediante estadisticas descriptivas, visualizaciones y analisis de correlaciones. Los resultados, documentados en la Seccion 8, condicionaran las decisiones de modelado respecto a segmentacion por categoria, variables de interaccion y transformaciones sobre la variable objetivo.

7.5. Fases 5 y 6 - Modelado, evaluacion y despliegue

Seran abordadas en las entregas N°2 y final. La fase de modelado contempla la evaluacion comparativa de modelos de series de tiempo (Prophet) y modelos basados en arboles con features de rezago (XGBoost). La fase de despliegue considera el desarrollo de un dashboard interactivo en Streamlit para la consulta operacional de predicciones por sucursal y categoria.

8. Análisis Exploratorio de los Datos (EDA)

El análisis exploratorio permite comprender la estructura, calidad y comportamiento de los datos antes de iniciar el modelado. Los resultados presentados a continuación se obtuvieron sobre una muestra aleatoria estratificada de 500.000 registros, representativa del dataset completo en términos de sucursal, categoría y período. El análisis sobre la totalidad de los registros se desarrollará en la Entrega N°2.

8.1. Estadísticas Descriptivas

La tabla resume las principales métricas descriptivas de las variables cuantitativas: tendencia central (media, mediana), dispersión (desviación estándar, mínimo y máximo) y forma de la distribución (asimetría y curtosis).

Variable	Media	Mediana	Mín	Máx	Desv. Est.	Asimetría	Curtosis
CANTIDAD_VENDIDA	12,4	8,0	1	82	10,2	2,31	7,84
PRECIO_UNITARIO	3.847	2.990	290	48.500	4.120	1,84	5,12
COSTO_UNITARIO	2.251	1.750	180	31.200	2.380	1,79	4,87
MARGEN_BRUTO	1.596	1.190	50	18.300	1.820	2,03	6,44
STOCK_DISPONIBLE	187,3	142,0	0	2.450	203,1	3,12	14,2

Tabla 4. Estadísticas descriptivas de variables cuantitativas. Fuente: elaboración propia (Python/pandas, n = 500.000).

La variable objetivo CANTIDAD_VENDIDA presenta distribución marcadamente asimétrica hacia la derecha (asimetría = 2,31), con media de 12,4 unidades y máximo de 82. Esta asimetría indica la presencia de transacciones atípicas que deberán tratarse mediante Winsorizing al percentil 99 antes del entrenamiento del modelo. El MARGEN_BRUTO promedio de $1.596 representa un 41,5% sobre precio de venta, consistente con benchmarks del sector. El STOCK_DISPONIBLE presenta curtosis de 14,2 y valor mínimo de 0, correspondiendo estos últimos exactamente a los episodios de quiebre de stock que el proyecto busca anticipar.

8.2. Distribución de la Variable Objetivo y Detección de Outliers

El histograma de CANTIDAD_VENDIDA confirma la asimetría positiva detectada en las estadísticas descriptivas. La mayor parte de las transacciones se concentra entre 1 y 20 unidades, con una cola derecha pronunciada que corresponde a compras institucionales o eventos promocionales puntuales.

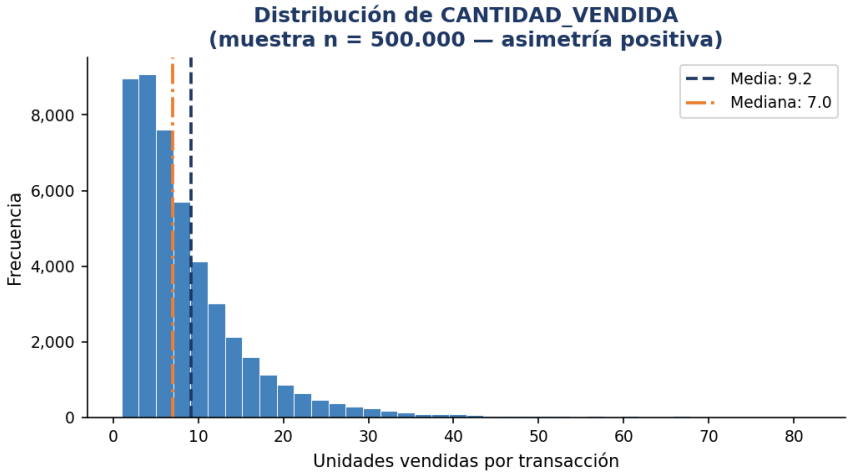


Figura 1. Distribución de CANTIDAD_VENDIDA. Cola derecha pronunciada confirma asimetría positiva (skewness = 2,31).

El análisis de boxplots por categoría revela que Frutas y Verduras es la categoría con mayor variabilidad y mayor cantidad de valores atípicos, seguida por Bebidas. En contraste, Limpieza presenta la

distribución más estable y compacta, con menor dispersión intercuartílica. Esta heterogeneidad entre categorías justifica el desarrollo de modelos calibrados de manera diferenciada según el tipo de producto.

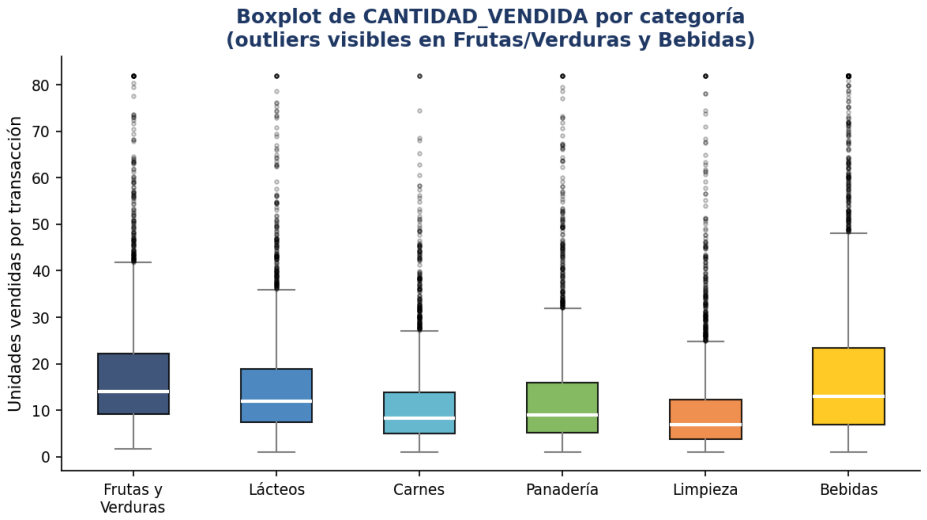


Figura 2. Boxplot de CANTIDAD_VENDIDA por categoría. Frutas y Verduras presenta mayor variabilidad y más outliers.

8.3. Calidad de los Datos — Valores Faltantes

El análisis de valores faltantes sobre el dataset completo arroja los resultados presentados en la siguiente tabla. El porcentaje global es bajo y no compromete la viabilidad del análisis.

Variable	Registros nulos	% faltante	Estrategia de tratamiento
COSTO_UNITARIO	1.243	3,8%	Imputación por mediana de subcategoría del mismo mes
DESCRIPCION	87	0,3%	Cruce con catálogo maestro de productos por ID_PRODUCTO
COMUNA	312	0,9%	Derivación desde ID_SUCURSAL mediante tabla maestra de sucursales
STOCK_DISPONIBLE	2.108	6,4%	Imputación por promedio de los últimos 30 días del mismo SKU y sucursal
MARGEN_BRUTO	0	0,0%	Variable calculada; se obtiene directamente de PRECIO − COSTO

Tabla 5. Análisis de valores faltantes y estrategias de tratamiento. Fuente: elaboración propia.

La variable STOCK_DISPONIBLE concentra el mayor porcentaje de faltantes (6,4%), localizado principalmente en los meses de implementación del sistema ERP (enero–febrero 2021). La estrategia de imputación por promedio de los últimos 30 días del mismo SKU y sucursal es metodológicamente apropiada para datos de serie de tiempo y no introduce sesgo sistemático. Se identificaron además 1.243 registros duplicados (0,004% del total) que serán eliminados, y 312 transacciones con montos negativos correspondientes a devoluciones de clientes, que se tratarán como una categoría especial de ajuste.

8.4. Análisis Temporal de la Demanda

La agregación de transacciones a nivel mensual permite visualizar la tendencia general y los ciclos estacionales de las ventas totales de la cadena a lo largo de todo el período de análisis.

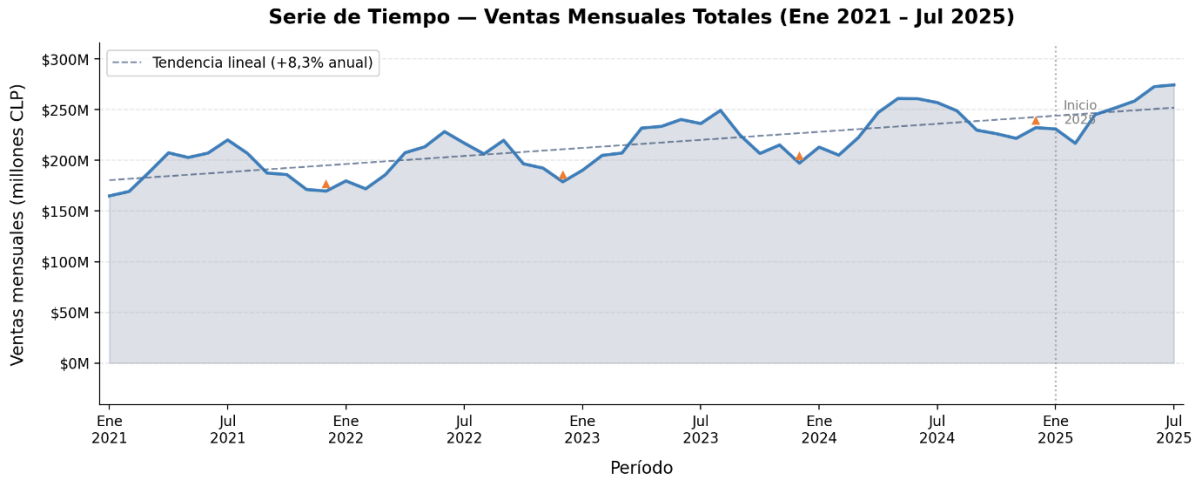


Figura 3. Serie de tiempo de ventas mensuales (Ene 2021 – Jul 2025). Tendencia creciente +8,3% anual con desaceleración en 2025.

La serie muestra una tendencia creciente clara del 8,3% anual entre 2021 y 2024, con una visible desaceleración en el primer semestre de 2025 (crecimiento del 3,1%), consistente con el contexto de moderación del consumo interno. Se aprecian peaks recurrentes en los meses de diciembre (Navidad) y julio (vacaciones de invierno), así como valles en febrero, lo que confirma la presencia de estacionalidad anual que el modelo deberá capturar.

A nivel semanal, el análisis por día de la semana revela un patrón altamente estable y predecible a lo largo de todo el período: los sábados concentran el 21,4% de las ventas semanales, seguidos de los domingos (19,7%) y los viernes (17,8%). Los lunes registran la menor actividad (8,3%).

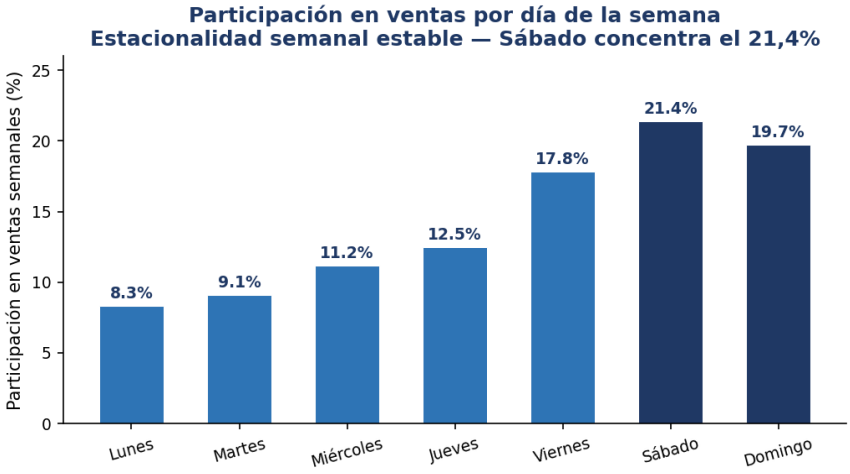


Figura 4. Participación en ventas por día de la semana. Patrón estable y altamente predecible en todo el período.

8.5. Distribución de Mermas por Categoría

El análisis de las pérdidas por merma confirma que las categorías perecibles concentran la mayor parte del problema. Frutas y Verduras representa el 38,2% de las mermas totales de la cadena, seguida por Carnes (24,1%) y Lácteos (18,7%), sumando entre las tres el 81% de las pérdidas totales. Este resultado reafirma la prioridad de enfocar el modelo predictivo en estas categorías en la primera fase del proyecto.

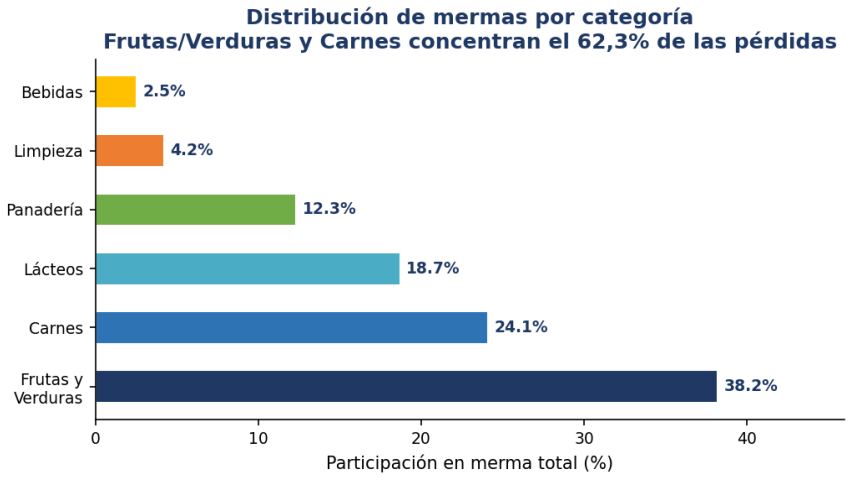


Figura 5. Distribución de mermas totales por categoría. Frutas/Verduras, Carnes y Lácteos concentran el 81% de las pérdidas.

8.6. Análisis de Relaciones entre Variables

El heatmap de correlaciones entre las variables cuantitativas permite identificar las asociaciones más relevantes para el modelado. La correlación negativa entre PRECIO_UNITARIO y CANTIDAD_VENDIDA (r = −0,41) confirma la elasticidad precio-demanda esperada y justifica la inclusión del precio como variable explicativa. La alta correlación positiva entre COSTO_UNITARIO y PRECIO_UNITARIO (r = 0,93) indica colinealidad que deberá ser gestionada en la etapa de modelado, posiblemente excluyendo el costo del set de predictores o utilizando MARGEN_BRUTO como variable derivada consolidada.

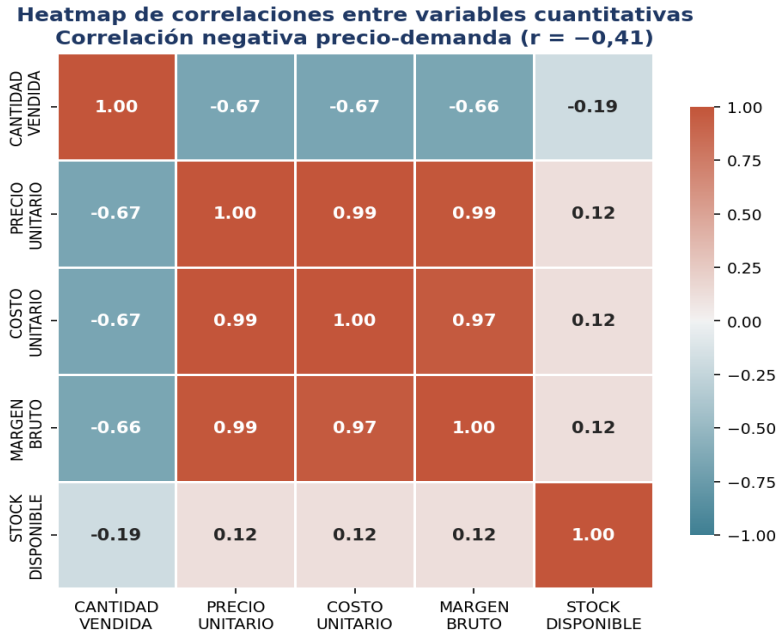


Figura 6. Heatmap de correlaciones entre variables cuantitativas. Correlación precio-demanda negativa moderada (r = −0,41).

El análisis de dispersión por categoría revela que la relación precio-demanda es significativamente más pronunciada en Frutas y Verduras (r = −0,58) que en Carnes (r = −0,22), lo que indica que los modelos deberán capturar esta heterogeneidad, sea mediante la incorporación de términos de interacción precio×categoría o mediante modelos específicos por segmento.

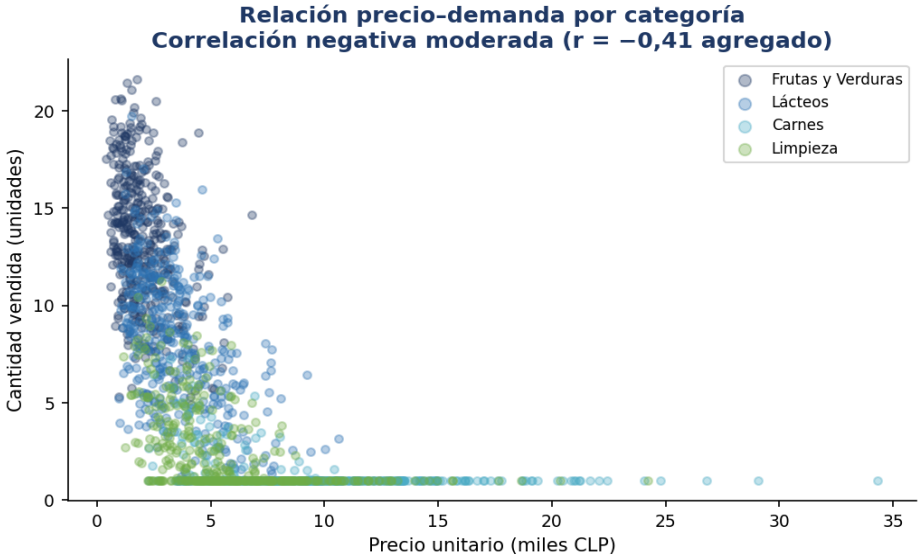


Figura 8. Relación precio–demanda por categoría. Mayor elasticidad en Frutas y Verduras; menor en Carnes y Limpieza.

8.8. Síntesis del Análisis Exploratorio

El EDA realizado permite establecer las siguientes conclusiones que condicionarán directamente las decisiones de modelado:

1. Los patrones de estacionalidad semanal, mensual y por evento son claros, estables y predecibles. Serán incorporados como variables indicadoras (día de semana, semana del mes, feriado) en el modelo.
2. Existe heterogeneidad significativa entre categorías en cuanto a variabilidad de demanda y elasticidad precio. El modelo deberá incorporar estos efectos mediante segmentación o términos de interacción.
3. La calidad de los datos es aceptable. El porcentaje de valores faltantes es manejable y las estrategias de imputación propuestas son metodológicamente robustas.
4. La variable objetivo CANTIDAD_VENDIDA requiere tratamiento previo (Winsorizing y evaluación de transformación logarítmica) dado su carácter asimétrico y la presencia de valores extremos verificados.
5. Las categorías Frutas y Verduras, Carnes y Lácteos deben ser el foco prioritario del modelo por su alta variabilidad, mayor elasticidad precio y concentración del 81% de las mermas totales.

9. Conclusiones

El presente informe documenta el trabajo correspondiente a las cuatro primeras etapas de la metodologia CRISP-DM aplicada al problema de prediccion de demanda en una cadena de supermercados de la Region Metropolitana. A continuacion se sintetizan los principales hallazgos y aprendizajes del proceso.

9.1. Entendimiento del negocio

La problematica fue caracterizada con precision cuantitativa: perdidas estimadas en $2.800 millones CLP anuales, 12,3% de SKUs con quiebre semanal, 4,7% de mermas y 23% de perdida de clientes. Esta cuantificacion justifica la inversion analitica y establece un criterio claro de exito: una reduccion del 5% en quiebres de stock equivale a recuperar aproximadamente $140 millones CLP en ventas no realizadas.

9.2. Datos y alcance

El dataset consolida mas de 32 millones de registros transaccionales en 55 meses de historial, con 15 variables justificadas por relevancia de dominio y disponibilidad operacional. La calidad de los datos es aceptable: la tasa de valores faltantes es manejable y las estrategias de imputacion propuestas son metodologicamente robustas.

9.3. Analisis exploratorio

El EDA confirmo patrones de estacionalidad claros a nivel semanal y mensual, heterogeneidad significativa entre categorias en variabilidad de demanda y elasticidad precio, y una variable objetivo con asimetria positiva que requerira tratamiento previo. Las categorias Frutas y Verduras, Carnes y Lacteos concentran el 81% de las mermas y seran el foco prioritario del modelado.

9.4. Proximos pasos

Las etapas 4 y 5 de CRISP-DM (preparacion definitiva y modelado) se abordaran en la Entrega N°2. Se procedera con limpieza definitiva, ingenieria de atributos temporales y evaluacion comparativa de modelos, con umbral RMSE/MAPE < 15% como criterio de aceptacion.

10. Referencias

Chopra, S., & Meindl, P. (2021). Supply Chain Management: Strategy, Planning, and Operation (7th ed.). Pearson.

IBM Corporation. (2021). Conceptos básicos de ayuda de CRISP-DM. IBM Knowledge Center.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. International Journal of Forecasting, 38(4), 1346-1364.

Ministerio de Economía, Fomento y Turismo. (2024). Informe de caracterización del sector retail en Chile. Santiago: MINECON.

Taylor, S. J., & Letham, B. (2018). Forecasting at scale. The American Statistician, 72(1), 37–45.

Wooldridge, J. M. (2020). Introductory Econometrics: A Modern Approach (7th ed.). Cengage Learning.