Cómo llegamos a cada decisión de la Entrega 2

Guía explicativa, punto por punto, de la propuesta metodológica para pronosticar el rendimiento por cuartel en kiwi Hayward

Para qué sirve esta guía

La pauta de la Evaluación 2 pide justificar cada decisión metodológica antes de implementar. Esta guía toma cada requisito de la pauta, muestra qué elegimos, explica la teoría que hay detrás en lenguaje simple y señala en qué diapositiva aparece.

Cada criterio sigue el mismo orden: **qué pide la pauta** → **qué elegimos** → **por qué (la teoría en simple)** → **dónde se ve** → **si el profesor pregunta**.

De dónde salen los números

Todas las cifras salen del notebook **analisis/Entrega2_Propuesta_metodologica.ipynb**, que reconstruye el panel desde los archivos originales de **Datos kiwi** y comprueba que reproduce las cifras publicadas en la Entrega 1 (112 observaciones, media 34,45 t/ha, correlación de canopia 0,67, etc.).

Grupo 36 · Diplomado en Data Science 2026 · Pontificia Universidad Católica de Chile · Noviembre 2026

1. La propuesta en una página

La pauta pide un **hilo conductor**: problema → datos → metodología → evaluación → implementación. Si cada paso se apoya en el anterior, la propuesta es coherente, que es justamente lo que más pesa en la evaluación.

Paso	En una frase
Problema	El huerto planifica con el promedio histórico de cada cuartel, y ese método se equivoca en promedio un 17 % en el total del huerto.
Datos	Rendimiento de 14 cuarteles (2019–2026) y señal satelital de canopia diaria para 11 de ellos: 77 observaciones cuartel-temporada con canopia.
Metodología	Regresión sobre un panel cuartel-temporada: pronosticar las t/ha de cada cuartel al 31 de enero con la canopia acumulada hasta esa fecha y un efecto propio de cada cuartel (modelo mixto).
Evaluación	Validación temporal (entrenar con el pasado, probar el año siguiente), prueba ciega en 2026 y comparación contra el promedio histórico, que es la práctica actual.
Implementación	Pronóstico preliminar en diciembre, oficial el 31 de enero y revisión en mayo; lo usan el administrador y el jefe técnico para bins, cuadrillas, ventas y cuarteles bajo el punto de equilibrio.

La respuesta a las cuatro preguntas guía de la pauta

¿Qué problema resolvemos? Anticipar cuántas toneladas dará cada cuartel antes de comprometer costos.
¿Cómo lo resolvemos? Con un modelo mixto que usa la canopia satelital hasta el 31 de enero.
¿Cómo sabremos si funciona? Si le gana al promedio histórico con cuatro criterios fijados antes de implementar.
¿Cómo se usa? En un tablero con tres momentos al año: diciembre, enero y mayo.

Mapa de la pauta. La tabla siguiente une cada requisito con su puntaje y su diapositiva. Las secciones 2 a 9 los explican uno por uno.

Criterio de la rúbrica	Pts.	Qué hicimos	Diap.
1. Problema, preguntas y objetivo	10	Objetivo medible con fecha (31 de enero) y tres preguntas accionables (P6, P7, P8)	2
2. Datos, variables y hallazgos	10	Variable objetivo t/ha; tres hallazgos del EDA que fijan el método	3
3. Enfoque analítico	15	Regresión sobre panel; qué entra y qué sale	4
4. Modelos y justificación	20	Cuatro alternativas comparadas con siete criterios del caso	5–6
5. Métricas y criterio de éxito	15	MAE, error del huerto, RMSE, MAPE; cuatro criterios cuantitativos	7–8
6. Validación y baseline	10	Ventana expansiva, prueba ciega, baseline justo, cuatro riesgos	9–11

Criterio de la rúbrica	Pts.	Qué hicimos	Diap.
7. Implementación	10	Flujo datos → decisión, usuarios, frecuencia, monitoreo	12–13
8. Comunicación	10	13 diapositivas, video de unos 4,5 minutos, gráficos nativos	todas

2. Problema, preguntas y objetivo analítico (10 pts)

Qué pide la pauta

«Problema acotado, preguntas que se busca responder y objetivo analítico explícito, coherentes con la Entrega 1.» Para el puntaje máximo: «preguntas accionables y objetivo analítico claro que orienta las decisiones metodológicas».

Qué elegimos

Objetivo analítico: estimar **al 31 de enero** el rendimiento (t/ha) de cada cuartel y del huerto, con **menos error que el promedio histórico**, para planificar la cosecha y anticipar si cada cuartel cubrirá su punto de equilibrio.

De las nueve preguntas de la Entrega 1 tomamos las tres que la solución puede responder directamente:

- **P6** · ¿Cuántas t/ha rendirá cada cuartel esta temporada?
- **P7** · ¿La temporada será baja, normal o alta según el histórico?
- **P8** · ¿Qué cuarteles quedarían bajo el equilibrio de 19,1 t/ha?

Por qué: la teoría en simple

Un objetivo analítico sirve si se puede **medir** y si **orienta decisiones**. El nuestro tiene tres piezas que lo hacen evaluable:

- **Qué se estima:** t/ha por cuartel (una cantidad, no una opinión).
- **Cuándo:** el 31 de enero, porque es cuando se cierran contratos y presupuesto de cosecha; antes no hay suficiente señal, después ya no sirve para decidir.
- **Contra qué se compara:** el promedio histórico, que es lo que el huerto hace hoy. «Menos error que eso» es un criterio verificable.

La fecha del objetivo no es un detalle: condiciona toda la metodología. Si el pronóstico se hace el 31 de enero, el modelo solo puede usar datos disponibles hasta esa fecha. Esa regla evita la **fuga de información** (sección 3) y define la variable principal (canopia acumulada hasta el 31 de enero).

Coherencia con la Entrega 1

El problema y las preguntas son los mismos de la Entrega 1 (P6, P7 y P8 vienen de su Tabla 1). Lo nuevo es que ahora el objetivo tiene fecha y referencia de comparación, que es lo que la rúbrica pide para el puntaje máximo.

Dónde se ve

Diapositiva 2: el 17,4 % de error del promedio histórico, el salto de +59 % entre 2023 y 2024, la brecha de ×2 entre cuarteles, el objetivo y las tres preguntas.

Si preguntan: «¿Por qué no responden las nueve preguntas de la Entrega 1?»

Porque la Entrega 2 diseña la solución predictiva. P1 a P5 eran descriptivas y diagnósticas: ya se respondieron en el análisis exploratorio. P6, P7 y P8 son las que el modelo responde; P9 queda para la entrega final, cuando el modelo esté ajustado.

3. Datos, variables y hallazgos del EDA (10 pts)

Qué pide la pauta

«Datos y variables relevantes para el enfoque, variable objetivo (si aplica) y hallazgos del EDA que condicionan la metodología.» Para el puntaje máximo: «hallazgos del EDA (desbalance, outliers, estacionalidad, etc.) usados para fundamentar decisiones».

Qué elegimos

Rol	Variable	Por qué
Objetivo (y)	Rendimiento en t/ha por cuartel y temporada	Es lo que se planifica: bins, cuadrillas y ventas se calculan en toneladas.
Predictor principal	Canopia satelital media del 1 de mayo al 31 de enero	Es la variable más asociada al rendimiento y ya está disponible en enero.
Efecto propio	Identidad del cuartel	Cada cuartel mantiene su nivel de un año a otro.
Control	Superficie del cuartel	Pasa de t/ha a kilos y bins totales; se usa en los modelos de árboles.
Sensibilidad	Clima (horas de frío, grados-día, lluvia)	Solo cuatro temporadas completas: no alcanza para estimar su efecto.

Los tres hallazgos que fijan el método

Hallazgo 1. La canopia antes de la cosecha conserva la señal. En la Entrega 1 la canopia de toda la temporada se correlacionaba 0,67 con el rendimiento. Pero ese promedio incluye marzo y abril, que son meses de cosecha: el 31 de enero todavía no existen. Al cortar la señal al 31 de enero la correlación es 0,66, prácticamente la misma. **Decisión:** el predictor es la canopia acumulada hasta el 31 de enero.

Teoría: fuga de información (data leakage)

Hay fuga cuando el modelo usa información que no estaría disponible en el momento real de la predicción. El modelo «hace trampa» sin querer: en la validación se ve mejor de lo que funcionará en la práctica. Ejemplo del caso: usar la canopia de abril para «predecir» en enero. La regla para evitarla es simple: **solo entran datos anteriores a la fecha de corte**, y todo lo que se calcula con el rendimiento (promedios por cuartel, escalado) se calcula solo con años de entrenamiento.

Hallazgo 2. El panel es pequeño: 77 observaciones. Son 11 cuarteles con canopia × 7 temporadas. **Decisión:** pocos predictores y modelos que controlan la complejidad (regularización o efectos aleatorios).

Teoría: sobreajuste y el equilibrio sesgo-varianza

Un modelo con muchos parámetros y pocos datos aprende el «ruido» de los datos de entrenamiento: los memoriza en vez de aprender el patrón. Se ve excelente en los datos con que se entrenó y falla en datos nuevos. Eso es **sobreajuste**.

Un modelo demasiado simple, en cambio, no capta el patrón (**sesgo**). Con pocos datos conviene un modelo simple y estable: se acepta un poco de sesgo a cambio de mucha menos variabilidad (**varianza**). Por eso, con 77 casos, un predictor principal.

Hallazgo 3. Cada cuartel tiene su propio nivel. Hay cuarteles que rinden sistemáticamente más que otros (las medias van de 23,1 a 44,8 t/ha). **Decisión:** el modelo debe incluir un efecto propio por cuartel; si no, atribuiría a la canopia diferencias que son del cuartel.

Hallazgo adicional: el clima todavía no se puede estimar. Solo cuatro temporadas tienen invierno completo y las variables climáticas están muy correlacionadas entre sí ($|r| > 0{,}8$). Con cuatro años hay solo cuatro valores distintos por variable: cualquier efecto estimado sería casualidad. **Decisión:** el clima queda como análisis de sensibilidad, no en el modelo principal.

Dónde se ve

Diapositiva 3: el gráfico de dispersión de canopia contra rendimiento ($r = 0{,}66$; $n = 77$) y los tres hallazgos con su consecuencia.

Si preguntan: «¿Por qué no usan el clima, si en la Entrega 1 lo calcularon?»

Porque con cuatro temporadas completas cada variable climática tiene solo cuatro valores distintos, y además están correlacionadas entre sí. Un modelo con esas variables estaría estimando cuatro puntos: no es confiable. Lo dejamos como sensibilidad y se incorpora cuando haya más temporadas.

4. Definición del enfoque analítico (15 pts)

Qué pide la pauta

«Tipo de problema (clasificación, regresión, pronóstico, segmentación, NLP, anomalías u otro) y resultado que generará la solución.» Para el puntaje máximo: «define tipo de problema, resultado que genera y variables que utiliza, en coherencia explícita con las preguntas y los datos».

Qué elegimos

Regresión supervisada sobre un panel cuartel-temporada. Cada fila es un cuartel en una temporada; la variable a predecir es continua (t/ha).

Entradas	Modelo	Salidas
Canopia media del 1 de mayo al 31 de enero; identidad del cuartel; superficie; clima solo como sensibilidad	Variable objetivo: t/ha (asimetría 0,41, sin transformar). Un pronóstico por cuartel y temporada. Se reentrena cada año con la cosecha real.	t/ha por cuartel con intervalo de predicción; kilos y bins del huerto; rango bajo, normal o alto; cuarteles en riesgo bajo el equilibrio

Por qué: la teoría en simple

Regresión o clasificación. En clasificación se predice una categoría (por ejemplo «temporada alta»); en regresión, un número. Elegimos regresión porque las decisiones del huerto necesitan toneladas: con «temporada alta» no se puede calcular cuántos bins pedir. Además, si se predice el número se puede derivar la categoría después (comparándolo con los terciles históricos), pero al revés no: clasificar desde el inicio **pierde información**.

Panel de datos. Los datos combinan dos dimensiones: varios cuarteles (corte transversal) observados varios años (serie de tiempo). Eso importa por dos razones: las observaciones de un mismo cuartel se parecen entre sí, y las de un mismo año comparten el clima. Ambas cosas condicionan el modelo (efecto de cuartel) y la validación (no mezclar años).

Sin transformar la variable objetivo. Una transformación logarítmica se justifica cuando la distribución es muy asimétrica. La asimetría del rendimiento es 0,41, moderada, así que se modela directamente en t/ha, que además es la unidad que entiende el agrónomo.

Dónde se ve

Diapositiva 4: entradas → modelo → salidas, y el recuadro «¿Por qué regresión y no clasificación?».

Si preguntan: «¿No es esto un problema de pronóstico de series de tiempo?»
Tiene una parte temporal, pero con 7 temporadas por cuartel no alcanza para un modelo de series de tiempo clásico (como ARIMA), que necesita series largas. Por eso lo tratamos como regresión sobre un panel, respetando el tiempo en la validación: siempre se entrena con el pasado y se predice el año siguiente.

5. Modelos propuestos y justificación (20 pts)

Qué pide la pauta
«Técnicas o modelos a evaluar, con supuestos, requisitos, fortalezas y limitaciones, y por qué son adecuados para este caso.» Para el puntaje máximo: «compara al menos dos alternativas y fundamenta la elección según variable objetivo, hallazgos del EDA, interpretabilidad, costo de error y factibilidad».

Es el criterio con más puntaje. Comparamos **cuatro alternativas** que representan dos familias: dos modelos lineales (simples e interpretables) y dos de árboles (flexibles). Si los de árboles hubieran ganado con claridad, eso habría indicado relaciones no lineales que justificarían perder interpretabilidad.

Alternativa 1: Ridge con efecto fijo de cuartel

Es una regresión lineal que agrega una **penalización** por coeficientes grandes. Busca los coeficientes que minimizan:

$$\Sigma\,(y_i - \hat{y}_i)^2 + \lambda \cdot \Sigma\,\beta_k{}^2$$

La primera parte es el error de siempre; la segunda castiga coeficientes grandes. El parámetro λ regula cuánto: con λ = 0 es una regresión común; con λ grande los coeficientes se encogen hacia cero. Ese encogimiento reduce la varianza, que es lo que necesitamos con pocos datos. El valor de λ se elige automáticamente con validación interna. El cuartel entra como una variable 0/1 por cuartel (efecto fijo).

- **Fortalezas:** controla el sobreajuste; coeficientes legibles.
- **Limitaciones:** necesita un parámetro por cuartel; no entrega intervalos de predicción directamente.

Alternativa 2: Modelo mixto con intercepto aleatorio por cuartel (la elegida)

Es una regresión lineal donde cada cuartel tiene su propio nivel, pero esos niveles se tratan como una muestra de un mismo huerto:

$$\text{rendimiento}_{ij} = \beta_0 + \beta_1 \cdot \text{canopia}_{ij} + u_j + \varepsilon_{ij}$$

Donde *i* es la temporada y *j* el cuartel. $\beta_0 + \beta_1 \cdot$canopia es la parte común a todo el huerto; u_j es cuánto se aparta el cuartel *j* del promedio (su «nivel propio»); ε_{ij} es lo que queda sin explicar. Se supone que u_j y ε_{ij} siguen distribuciones normales con varianzas $\sigma_u{}^2$ y σ^2.

La idea clave es el «préstamo de información» (partial pooling). Con solo 7 años por cuartel, el promedio propio de un cuartel es poco confiable: un año extraordinario lo mueve mucho. El modelo mixto estima el nivel de cada cuartel como una mezcla entre **sus propios datos** y **el promedio del huerto**. El peso que da a los datos propios es:

$$\text{peso} = \sigma_u^2 \,/\, (\sigma_u^2 + \sigma^2 / n_j)$$

En nuestros datos $\sigma_u^2 \approx 15{,}2$ y $\sigma^2 \approx 45{,}6$, con $n_j = 7$ años: el peso es ≈ 70 %. Es decir, el modelo confía un 70 % en la historia propia del cuartel y un 30 % en el promedio del huerto. Los cuarteles con niveles extremos se «encogen» hacia el promedio, lo que los protege de un año atípico.

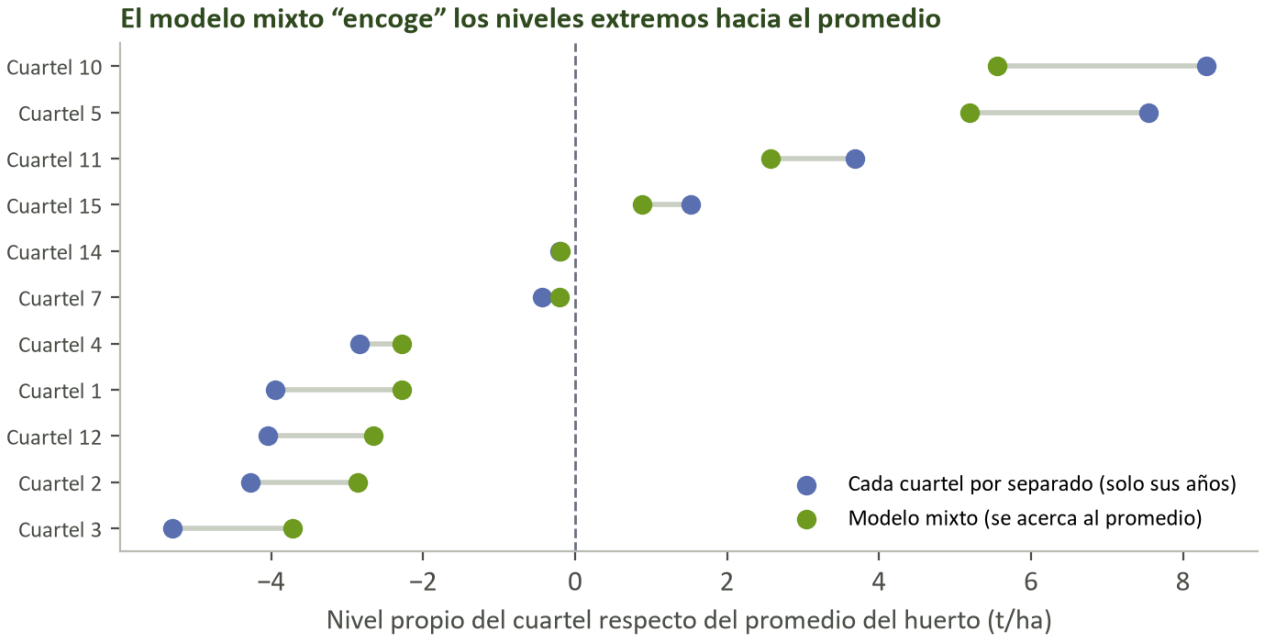


Figura 1. Nivel propio de cada cuartel estimado solo con sus años (azul) y con el modelo mixto (verde). El modelo mixto acerca los valores extremos al promedio del huerto: confía en cada cuartel, pero sin dejarse llevar por pocos años.

Interpretación para el agrónomo: en el ajuste con los 77 casos, $\beta_1 \approx 220$ t/ha por unidad de canopia. Como la canopia varía en centésimas, se lee así: **cada 0,01 más de canopia media hasta enero se asocia a unas 2,2 t/ha más**.

- **Fortalezas:** comparte información entre cuarteles; interpretable; entrega intervalos de predicción a partir de sus varianzas; sirve para un cuartel nuevo (usa el promedio del huerto).
- **Limitaciones:** supone relación lineal y errores normales; no capta interacciones no lineales.

Alternativa 3: Random Forest

Promedia cientos de árboles de decisión, cada uno entrenado con una muestra distinta de los datos y con variables elegidas al azar. Promediar muchos árboles distintos reduce la varianza de un árbol solo.

- **Fortalezas:** capta no linealidades e interacciones sin especificarlas.

- **Limitaciones:** un árbol predice el promedio de las observaciones de una hoja, así que **nunca predice fuera del rango observado**: si llega un año récord como 2024, el bosque no puede pronosticar algo más alto que lo ya visto. Además es una «caja negra» y necesita más datos para estabilizarse.

Alternativa 4: Gradient Boosting

Construye árboles pequeños uno tras otro: cada árbol nuevo intenta corregir los errores (residuos) que dejaron los anteriores.

- **Fortalezas:** suele ser de los modelos más precisos en datos tabulares grandes.
- **Limitaciones:** tiene muchos hiperparámetros (número de árboles, profundidad, tasa de aprendizaje) y con 77 casos sobreajusta con facilidad; tampoco extrapola y es poco interpretable.

Cómo se eligió: siete criterios que salen del caso

Criterio (por qué importa aquí)	Modelo mixto	Ridge + cuartel	Random Forest	Gradient Boosting
Panel pequeño (EDA: 77 casos)	Sí: pocos parámetros	Sí: regularización	Parcial: inestable	No: sobreajusta
Efecto cuartel (EDA: nivel persistente)	Sí: intercepto aleatorio	Sí: efecto fijo	Parcial: vía promedio	Parcial: vía promedio
Años récord (EDA: 2024)	Sí: extrapola	Sí: extrapola	No extrapola	No extrapola
Costo del error (decidir cerca de 19,1 t/ha)	Sí: intervalo directo	Parcial: con bootstrap	Parcial: cuantiles	Parcial: pérdida cuantílica
Interpretabilidad (la usa el agrónomo)	Sí	Sí	No: caja negra	No: caja negra
Factibilidad (reentrenar 1 vez al año)	Sí: segundos	Sí: segundos	Sí: segundos	Parcial: calibración costosa
Error del huerto en validación	9,6 %	10,5 %	15,4 %	11,8 %

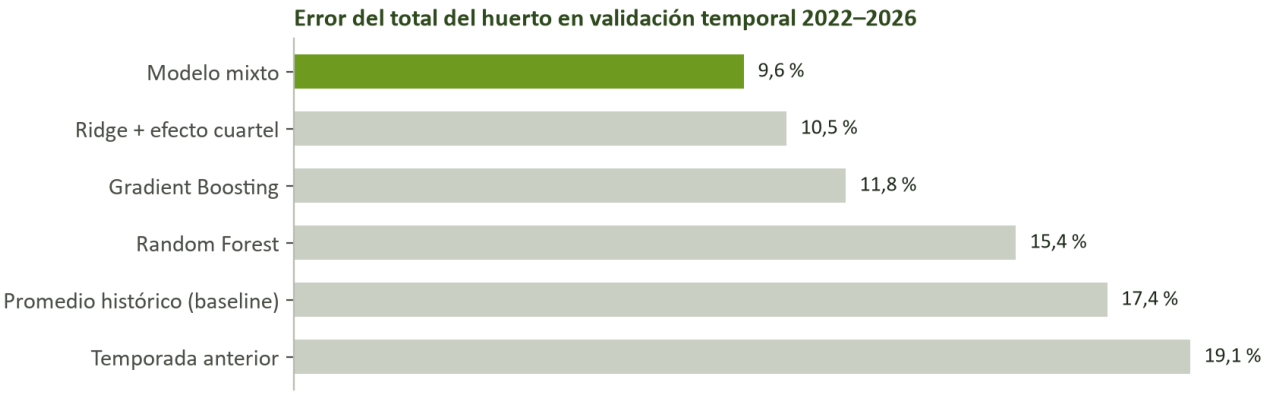


Figura 2. Error del total del huerto en la validación temporal 2022–2026 (canopia al 31 de enero). El modelo mixto tiene el menor error; Ridge queda muy cerca, lo que confirma que la relación es básicamente lineal.

La elección en una frase

Elegimos el **modelo mixto** porque es el único que cumple todos los criterios del caso y además tiene el menor error. **Ridge** queda como respaldo (casi el mismo resultado) y los **árboles** se mantienen como contraste para detectar no linealidad si en el futuro hay más datos.

Dónde se ve

Diapositiva 5 (matriz de criterios) y diapositiva 6 (resultados de la validación).

Si preguntan: «Si Ridge da casi lo mismo, ¿por qué no usar Ridge, que es más conocido?»

Por el costo del error. Cerca del punto de equilibrio no basta un valor puntual: hay que saber cuánto puede variar. El modelo mixto entrega intervalos de predicción a partir de sus varianzas; Ridge necesitaría un procedimiento adicional (bootstrap). Además, el modelo mixto puede pronosticar un cuartel nuevo usando el promedio del huerto.

6. Criterios de evaluación y métricas (15 pts)

Qué pide la pauta

«Métricas técnicas pertinentes al tipo de problema y criterio de éxito que defina cuándo la solución es suficientemente buena.» Para el puntaje máximo: «métricas pertinentes y justificadas (p. ej., según costo de error o desbalance) y criterio de éxito cuantificable, definido antes de implementar».

Las cuatro métricas y qué mide cada una

En todas, y_i es el rendimiento real, $\hat{y}_i$ el pronosticado y n el número de pronósticos.

$$\mathrm{MAE} = (1/n) \cdot \Sigma \mid y_i - \hat{y}_i \mid$$

MAE (error absoluto medio), en t/ha. Es la métrica principal. Es el error típico en la misma unidad que usa el agrónomo: «el modelo se equivoca en promedio 6,2 t/ha por cuartel». Cada tonelada de error pesa lo mismo, venga de un error grande o de uno chico; por eso un año extremo no domina la métrica, como sí ocurre con el RMSE.

$$\mathrm{RMSE} = \sqrt{[\ (1/n) \cdot \Sigma\ (\ y_i - \hat{y}_i\ )^2\ ]}$$

RMSE (raíz del error cuadrático medio), en t/ha. Al elevar al cuadrado, castiga más los errores grandes. Se reporta porque los errores grandes son los que descuadran una cosecha en un año atípico. Si el RMSE es mucho mayor que el MAE, hay errores grandes ocasionales.

$$\mathrm{MAPE} = (100/n) \cdot \Sigma \mid y_i - \hat{y}_i \mid / y_i$$

MAPE (error porcentual medio). Permite comparar cuarteles de distinto nivel, pero se interpreta con cuidado: en un cuartel que rinde poco, un error pequeño en toneladas se ve enorme en porcentaje.

$$\text{Error del huerto} = |\ \Sigma \text{ kg pronosticados} - \Sigma \text{ kg reales}\ | \ / \ \Sigma \text{ kg reales}$$

Error del total del huerto (%). Suma los kilos de todos los cuarteles antes de comparar, y se promedia entre los años de prueba. Es lo que importa para contratar bins, cuadrillas y ventas, que se deciden para el huerto completo. Aquí los errores de distintos cuarteles se compensan: uno sobreestimado y otro subestimado se cancelan en parte.

Teoría: elegir la métrica según el costo de equivocarse

El error no cuesta lo mismo en ambos sentidos. **Subestimar** deja fruta sin cosechar por falta de bins y cuadrillas. **Sobreestimar** compromete costos y contratos sin fruta que los respalde.
Y cerca del punto de equilibrio un error cambia la decisión económica. Ejemplo: con un MAE de 6 t/ha, un cuartel pronosticado en 24 t/ha podría rendir entre 18 y 30, a ambos lados de 19,1. Por eso la solución entrega **intervalos** y no solo un número.

El criterio de éxito: cuatro condiciones fijadas antes de implementar

Condición	Por qué	Resultado preliminar
Error del huerto ≤ 10 %	Es el error que afecta la operación (bins, cuadrillas, ventas)	9,6 % · cumple
MAE al menos 10 % menor que el promedio histórico	Mejora concreta frente a la práctica actual, cuartel por cuartel	15,4 % (de 7,4 a 6,2 t/ha) · cumple
Gana al baseline en 4 de 5 temporadas	Que la mejora sea estable y no dependa de un solo año	4 de 5 (falla en 2025) · cumple
IC 95 % de la mejora en MAE sobre cero	Que la mejora no sea casualidad del muestreo (sección 7)	−0,1 a 2,3 t/ha · pendiente

Teoría: por qué el criterio se fija antes

Si el criterio se elige después de ver los resultados, siempre se puede encontrar una métrica en que el modelo «gane». Fijarlo antes es como fijar la nota de aprobación antes de la prueba: protege contra el autoengaño. Por eso la pauta dice «definido antes de implementar».

Ajuste respecto de la Entrega 1

La Entrega 1 proponía un MAPE menor a 10 % por cuartel. Con la variabilidad observada no es alcanzable: el mejor modelo preliminar llega a 19 %. Lo reemplazamos por criterios que reflejan la decisión real (el total del huerto), la mejora frente a la práctica actual y que esa mejora no sea ruido. Corregir una meta con evidencia es parte del método, no una debilidad.

Dónde se ve

Diapositiva 7 (métricas y costo del error) y diapositiva 8 (los cuatro criterios).

Si preguntan: «¿Por qué la métrica principal es el MAE y no el RMSE?»

Porque se lee directo en t/ha y es la que entiende el usuario. El RMSE se reporta igual para vigilar los errores grandes, que son los más costosos en años atípicos.

7. Estrategia de validación y baseline (10 pts)

Qué pide la pauta

«Esquema de validación adecuado a los datos, riesgos identificados y baseline con el cual comparar la solución.» Para el puntaje máximo: «validación coherente con la naturaleza de los datos; identifica overfitting, data leakage, desbalance y representatividad; baseline justificado». La pauta advierte explícitamente contra el «split aleatorio en series de tiempo».

Validación temporal con ventana expansiva

Para cada año de prueba se entrena con todos los años anteriores y se pronostica ese año. Así se hacen 5 pruebas (2022 a 2026), con 11 cuarteles cada una: 55 pronósticos fuera de muestra.

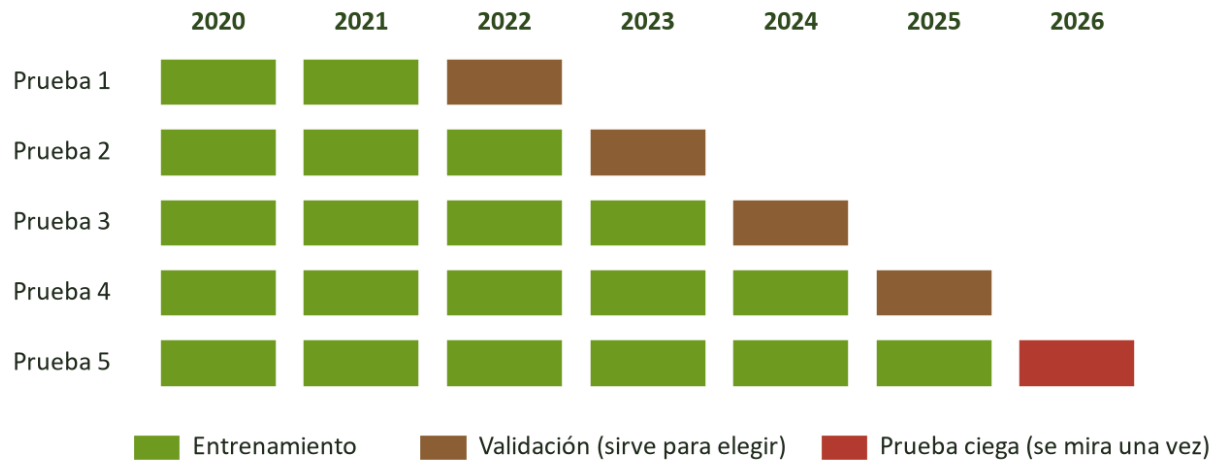


Figura 3. Ventana expansiva con selección anidada. Las pruebas 1 a 4 sirven para elegir el modelo y la variable de canopia; la prueba 5 (2026) se evalúa una sola vez, a ciegas.

Teoría: por qué no un split aleatorio

En un split aleatorio, cuarteles del mismo año quedan en entrenamiento y en prueba. Como comparten el clima de ese año, el modelo «ya conoce» el año que debería estar pronosticando: el error sale optimista. La ventana expansiva reproduce el uso real (en enero de 2027 solo existirán los datos hasta 2026) y nunca usa el futuro para predecir el pasado. A esto se le llama también **backtesting**.

Selección anidada y prueba ciega

Probamos 5 variantes de canopia × 4 modelos = 20 combinaciones. Elegir la mejor de 20 y reportar su error con los mismos años es optimista: aunque todas fueran iguales, la mejor de 20 parecería buena por azar.

Teoría: sesgo de selección (la «maldición del ganador»)

Si se prueban muchas alternativas y se reporta solo la ganadora, su error está subestimado, porque parte de su ventaja es suerte. La solución es separar **elegir** de **evaluar**: se elige con unos datos y se evalúa una sola vez con otros que no participaron en la elección.

Por eso repetimos la elección usando **solo 2022–2025**. Salió el mismo modelo mixto con la misma variable (canopia al 31 de enero). Luego lo evaluamos una vez en 2026: el error del huerto bajó de **21,6 %** (promedio histórico) a **7,0 %**, y el MAE de 10,4 a 7,5 t/ha.

El baseline: la práctica actual

El baseline es el **promedio histórico de cada cuartel**, que es como el huerto planifica hoy. La pauta lo resume bien: la pregunta no es solo «¿funciona?», sino «¿mejora algo respecto de lo que ya existe?». También se reporta la temporada anterior como segunda referencia.

Comprobamos que la comparación fuera **justa**: la práctica real usa toda la historia, incluso 2019 y los cuarteles sin canopia. Con toda la historia el baseline da 16,8 %, casi lo mismo que 17,4 %. El modelo no gana por tener un rival debilitado.

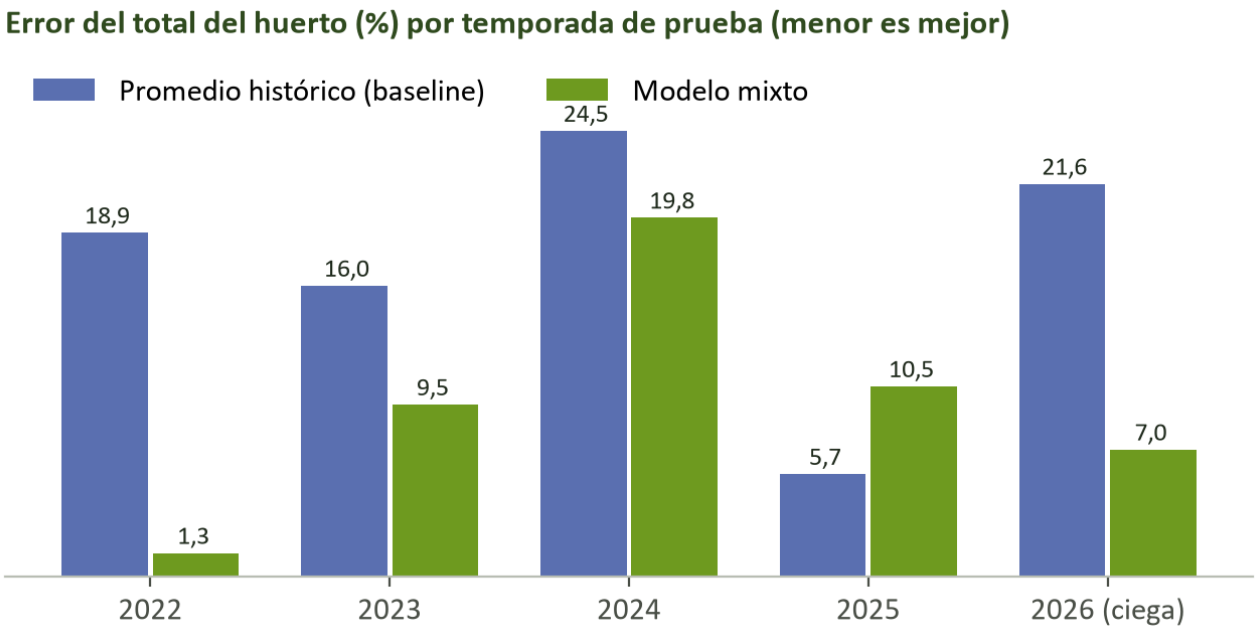


Figura 4. Error del total del huerto por temporada. El modelo gana en 4 de 5 años, justo cuando el promedio se equivocaba entre 16 y 25 %; solo pierde en 2025, cuando el promedio ya acertaba (5,7 %).

¿La mejora es real o casualidad? El bootstrap

Con 55 pronósticos, parte de la diferencia puede ser suerte. El **bootstrap** lo mide: se simulan miles de «muestras alternativas» remuestreando los datos con reposición, y en cada una se recalcula la mejora. Si en casi todas el modelo gana, la mejora es sólida.

Teoría: bootstrap por grupos (cluster bootstrap)

Los años de un mismo cuartel se parecen entre sí, así que no son 55 datos independientes. Por eso no se remuestrean pronósticos sueltos, sino **cuarteles completos** (con todos sus años). Remuestrear pronósticos sueltos haría que la incertidumbre pareciera menor de lo que es.

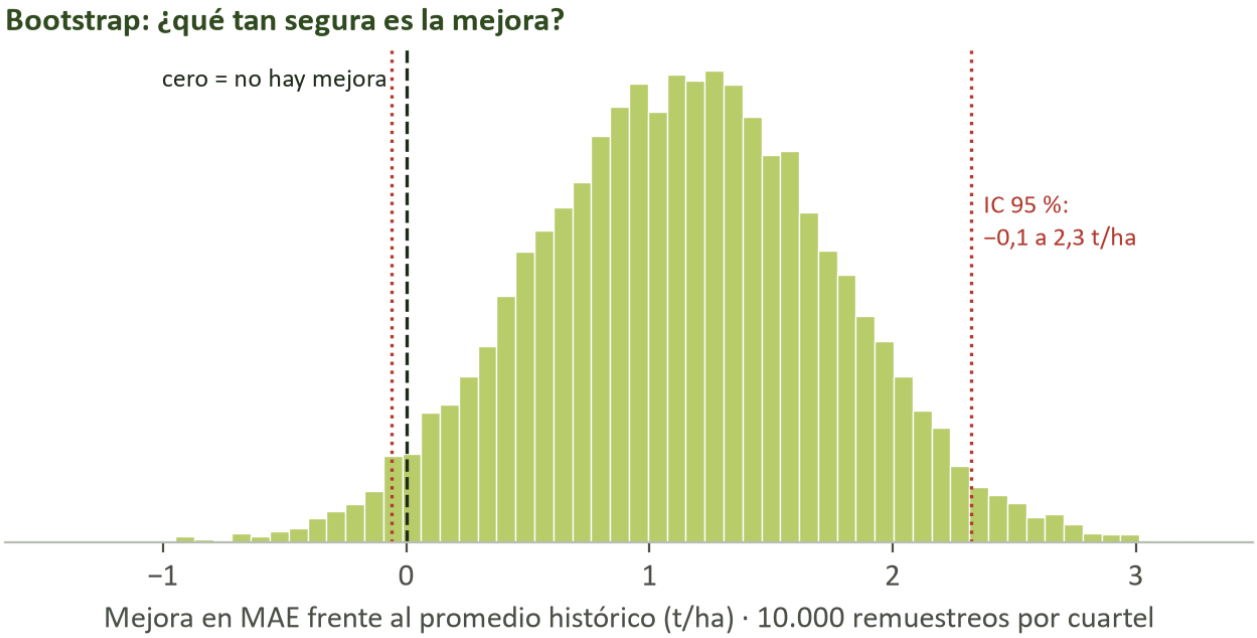


Figura 5. Distribución de la mejora en MAE en 10.000 remuestreos por cuartel. En el 97 % de ellos el modelo gana, pero el intervalo de 95 % (−0,1 a 2,3 t/ha) todavía toca el cero.

Lectura honesta: la mejora es probable, pero con 55 pronósticos todavía no es concluyente. Por eso el cuarto criterio de éxito queda «pendiente» y debe confirmarlo el modelo final.

Los cuatro riesgos que pide la pauta

Riesgo	Qué es, en simple	Cómo lo controlamos
Sobreajuste	El modelo memoriza el ruido y falla en datos nuevos	Un predictor principal, regularización y efecto aleatorio; la elección no mira 2026
Fuga de información	Usar datos que no existirían al momento de pronosticar	Solo datos previos al corte; promedios y escalado calculados con años de entrenamiento
Desbalance	En regresión: pocos casos extremos (como el récord de 2024) que el modelo ve poco	Se reporta el error por año y el RMSE, que castiga los errores grandes

Riesgo	Qué es, en simple	Cómo lo controlamos
Representatividad	Que los datos no reflejen todos los casos donde se usará	Es un solo huerto y 11 de 14 cuarteles tienen canopia; los 3 restantes usan el baseline hasta tener señal

Dónde se ve

Diapositiva 9 (esquema y riesgos), diapositiva 10 (resultado por año y prueba ciega) y diapositiva 11 (baseline y fecha de corte).

Si preguntan: «¿Por qué el corte es el 31 de enero y no otra fecha?»

Lo probamos: con el corte al 31 de diciembre el modelo ya baja el error del huerto a 10,3 %; al 31 de enero llega a 9,6 %; al 28 de febrero no mejora (9,7 %). Enero da el mejor error con dos a tres meses de anticipación a la cosecha, justo cuando se cierran contratos.

8. Plan de implementación y uso de resultados (10 pts)

Qué pide la pauta

«Flujo datos → preparación → modelo → resultado → usuario → decisión, explicando cómo se usaría el resultado en la práctica.» Para el puntaje máximo: «describe qué recibe y produce la solución, usuarios, frecuencia, decisión que apoya y pendientes para la entrega final».

Qué elegimos

Paso	En nuestro caso
Datos (qué recibe)	Canopia satelital diaria, cosecha por cuartel y clima INIA
Preparación	Suavizado de 7 días, promedio de canopia al corte, panel por cuartel
Modelo	Modelo mixto, reentrenado cada año después de la cosecha
Resultado (qué produce)	t/ha por cuartel ± intervalo, kilos y bins del huerto, rango de la temporada
Usuario	Administrador y jefe técnico, en un tablero (Streamlit)
Decisión	Bins, cuadrillas, ventas y cuarteles bajo el punto de equilibrio

Frecuencia de uso: tres momentos al año.

- **Diciembre:** pronóstico preliminar para reservar bins y cuadrillas.
- **31 de enero:** pronóstico oficial para contratos de venta y presupuesto de cosecha.
- **Mayo:** se compara con la cosecha real, se mide el error y se reentrena el modelo.

Teoría: el modelo también se vigila (monitoreo)

Un modelo predictivo puede degradarse: si cambian el manejo, las plantas o el clima, la relación aprendida deja de valer. Por eso se define una regla de monitoreo: **si el error del huerto de una temporada supera 15 %, se revisan las variables y se recalibra el modelo** antes del siguiente pronóstico. Esto viene del componente de monitoreo de CRISP-ML(Q) que adoptamos en la Entrega 1.

El vínculo con lo económico: el punto de equilibrio

El punto de equilibrio es el rendimiento con el que los ingresos igualan los costos de la temporada:

$$\text{Equilibrio (t/ha)} = \text{costo total por hectárea} / \text{precio por kilo} / 1.000$$

Con la carta Gantt de labores ($173,2 millones) más maquinaria, insumos e indirectos de la ficha ODEPA ($113,9 millones), el costo total es $287,1 millones para 33,3 ha. A $450 por kilo, el equilibrio es **19,16 t/ha** (la Entrega 1 lo informó como 19,1). Con el pronóstico de cada cuartel y su intervalo se puede marcar qué cuarteles quedarían bajo ese umbral.

Pendientes para la entrega final

1. Confirmar el mapeo de polígonos satelitales e incorporar los cuarteles sin canopia.
2. Ajustar el modelo final: canopia invernal y de crecimiento, análisis de residuos.
3. Construir intervalos de predicción y medir su cobertura con bootstrap.
4. Confirmar que la mejora no es ruido (criterio 4) y probar el pronóstico del 31 de enero de 2027.
5. Integrar el pronóstico con el punto de equilibrio y escenarios de precio.
6. Prototipo del tablero en Streamlit para el equipo del huerto.

Dónde se ve

Diapositiva 12 (flujo, usuarios, frecuencia y monitoreo) y diapositiva 13 (próximos pasos).

9. Comunicación y presentación (10 pts)

Qué pide la pauta

«Video breve y ejecutivo, con hilo conductor, que explica decisiones (no código) y usa sólo hallazgos y gráficos relevantes.» Para el puntaje máximo: «relato claro y ejecutivo que responde las cuatro preguntas guía y conecta técnica con problema».

Cómo cumplimos el formato y evitamos las penalizaciones

Requisito o penalización (−10 pts c/u)	Cómo lo cumplimos
Video de máximo 5 minutos	Guion de 623 palabras, unos 4,5 minutos a ritmo natural (meta: terminar antes de 4:45)
Máximo 15 diapositivas	13 diapositivas
Estructura formal: portada, desarrollo y cierre con próximos pasos	Portada (1), desarrollo (2–12) y próximos pasos (13)
Sin pantallazos de consola ni bloques de código	Ninguna diapositiva muestra código: se explican decisiones
Gráficos exportados correctamente, no capturas	Todos son gráficos nativos de PowerPoint, construidos desde los datos
Ningún gráfico o tabla sin interpretación	Cada gráfico tiene un texto de lectura al lado o debajo

Las cuatro preguntas guía, diapositiva por diapositiva

Pregunta guía	Diapositivas
¿Qué problema están resolviendo?	2 (problema y objetivo)
¿Cómo piensan resolverlo?	3–6 (hallazgos, enfoque, alternativas y elección)
¿Cómo sabrán si funciona?	7–11 (métricas, criterio de éxito, validación, prueba ciega y baseline)
¿Cómo se usaría el resultado?	12–13 (implementación y próximos pasos)

Una advertencia de la pauta

La pauta descuenta por «IA sin personalizar». El guion es una base: conviene que cada integrante lo diga con sus propias palabras y que el grupo pueda defender cada decisión de esta guía sin leer.

10. Preguntas probables del profesor

«¿Por qué un modelo tan simple, con un solo predictor?»

Por el tamaño del panel: 77 observaciones. Cada predictor adicional aumenta el riesgo de sobreajuste. Un predictor fuerte (r = 0,66), elegido por razón agronómica y por evidencia, es más confiable que muchos predictores débiles. La entrega final evaluará agregar variables de canopia invernal y de crecimiento con la misma validación.

«¿El modelo sirve para un cuartel nuevo o sin historia?»

Sí. Es una ventaja del modelo mixto: para un cuartel sin historia, su nivel propio se toma igual al promedio del huerto ($u_j = 0$) y el pronóstico usa solo la canopia. Los 3 cuarteles sin canopia usan el baseline hasta tener señal satelital.

«¿Qué pasa si el error supera el criterio en una temporada?»

Por eso existe la regla de monitoreo: si el error del huerto supera 15 %, se revisan las variables y se recalibra el modelo antes del siguiente pronóstico. El modelo se reentrena cada mayo con la cosecha real.

«¿Cómo saben que no hay fuga de información?»

Porque toda variable se calcula solo con datos anteriores a la fecha de corte (31 de enero), y todo lo que usa el rendimiento (promedios por cuartel, escalado de variables) se calcula solo con los años de entrenamiento de cada prueba. La prueba ciega de 2026 confirma que el resultado se sostiene fuera de la selección.

«Si el intervalo del bootstrap toca el cero, ¿el modelo sirve?»

Gana en 4 de 5 años, en la prueba ciega y con 97 % de probabilidad de mejora en el bootstrap. Lo que todavía no podemos afirmar con 95 % de confianza es el tamaño exacto de la mejora en MAE, porque 55 pronósticos son pocos. Por eso lo declaramos como criterio pendiente y lo verificaremos con el modelo final y con la temporada 2027.

«¿Por qué el error del huerto es tan bajo y el MAPE por cuartel tan alto?»

Porque en el total del huerto los errores de distintos cuarteles se compensan: uno sobreestimado y otro subestimado se cancelan en parte. Para contratar bins y cuadrillas importa el total; para decidir por cuartel importa el MAE y el intervalo.

«¿Por qué no probaron redes neuronales u otros modelos más complejos?»

Porque con 77 observaciones un modelo más flexible sobreajusta aún más que los árboles, que ya rindieron peor. La comparación entre lineales y árboles ya responde la pregunta de fondo: no hay no linealidad suficiente que justifique la complejidad.

11. Glosario rápido

Término	Significado en simple
Baseline	Referencia contra la que se compara el modelo; aquí, el promedio histórico del cuartel.
Bootstrap	Remuestrear los datos miles de veces para ver cuánto podría cambiar un resultado.
Canopia (señal satelital)	Índice de 0 a 1 de cobertura vegetal del cuartel, medido por satélite y suavizado a 7 días.
Efecto aleatorio	Nivel propio de cada cuartel, estimado como desviación del promedio del huerto y encogido hacia él.
Error del huerto	Diferencia porcentual entre los kilos totales pronosticados y reales del huerto.
Extrapolar	Predecir valores fuera del rango observado; los árboles no pueden hacerlo.
Fuga de información	Usar datos que no estarían disponibles al momento real del pronóstico.
IC 95 %	Rango donde, con 95 % de confianza, está el valor verdadero de una cantidad.
MAE / RMSE / MAPE	Error promedio en t/ha / error que castiga los errores grandes / error promedio en %.
Panel de datos	Datos con varias unidades (cuarteles) observadas en varios periodos (temporadas).
Partial pooling	Mezclar los datos propios de un grupo con el promedio de todos, según cuánta información tenga cada grupo.
Prueba ciega	Evaluación con datos que no se usaron para elegir el modelo; se mira una sola vez.
Regularización	Penalizar la complejidad del modelo para que no sobreajuste (por ejemplo, Ridge).
Sesgo de selección	Optimismo que aparece al elegir la mejor de muchas alternativas con los mismos datos que se reporta.
Sobreajuste	Cuando el modelo memoriza el ruido de los datos de entrenamiento y falla con datos nuevos.
Ventana expansiva	Validación que entrena con todos los años anteriores y prueba el año siguiente, avanzando un año cada vez.