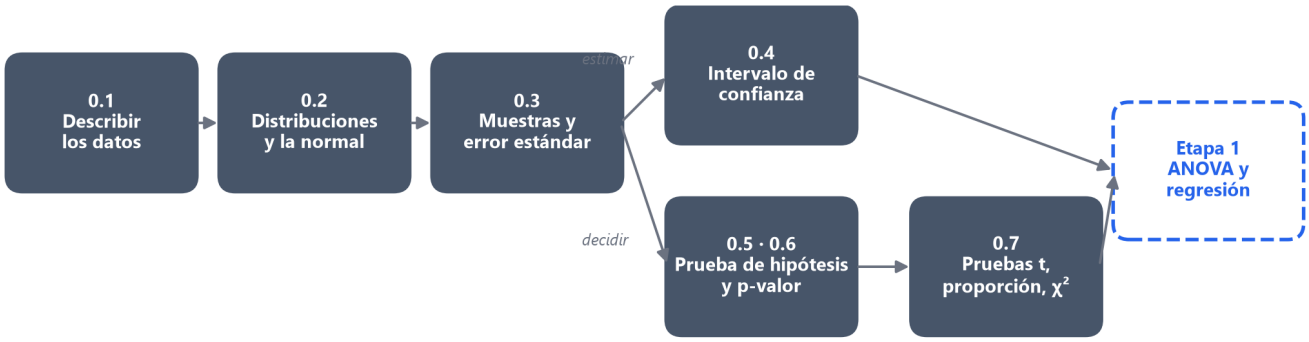
Etapa 0 · Nivelación estadística

7 sesiones · 6 al 18 de octubre · la base de las Clases 17 a 24

Por qué esta etapa existe

ANOVA, regresión, GLM, A/B testing y estadística bayesiana usan el mismo lenguaje: **muestras, error estándar, intervalos y p-valores**. Sin ese lenguaje, las clases se pueden *seguir* pero no *entender*. Son 2 semanas que ahorran muchas más después.

El camino



La pregunta de toda la etapa: con una MUESTRA, ¿qué puedo afirmar de la POBLACIÓN, y con cuánta seguridad?

Calendario

Sesión	Día	Tema	Pregunta que responde
0.1	mar 6 oct	Describir los datos	¿Cómo son mis datos?
0.2	mié 7 oct	Distribuciones y la normal	¿Qué valores son comunes y cuáles raros?
0.3	vie 9 oct	Muestras y error estándar	¿Cuánto cambiaría mi promedio con otra muestra?
Repaso	dom 11 oct	Sesiones 0.1 a 0.3	Mini evaluación de 6 preguntas
0.4	lun 12 oct	Intervalos de confianza	¿Entre qué valores está la media real?
0.5	mar 13 oct	Prueba de hipótesis y p-valor	¿La diferencia es real o es ruido?
0.6	mié 14 oct	Errores, potencia y tamaño de efecto	¿Cuánto me puedo equivocar?
0.7	vie 16 oct	Pruebas t, proporción y χ^2	¿Qué prueba uso en cada caso?
Repaso	dom 18 oct	Toda la etapa	Evaluación final + criterio de dominio

Un solo dataset para toda la etapa

ENS.csv (carpeta de las Clases 17–19): 350 personas con **COLESTEROL** (mg/dL), **EDAD** (Joven, Adulto, Adulto Mayor; 4 vacíos), **FUMA** y **DEPORTE** (Sí/No). Así te concentras en los conceptos y no en entender datos nuevos cada día.

Cambio respecto al roadmap

Correlación sale de esta etapa: la Clase 18 la enseña completa. Eso libera una sesión y la etapa queda en 7.

Para las sesiones 0.6 en adelante necesitas instalar statsmodels: `pip install statsmodels`

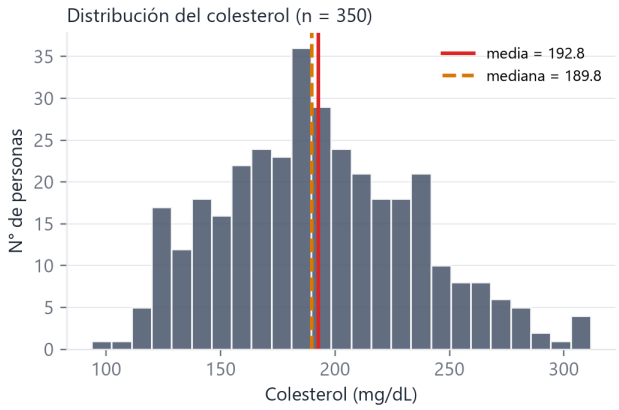
Sesión 0.1 · Describir los datos

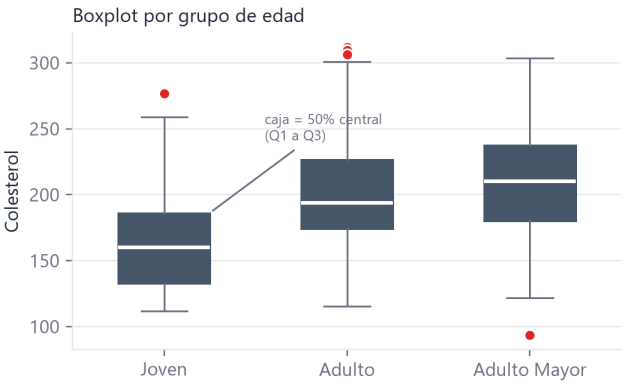
Martes 6 de octubre · ~95 min · dataset: ENS.csv

Antes de cualquier modelo hay que conocer los datos: qué tipo es cada variable, dónde está su centro y cuánto se dispersa.

Conceptos clave

1. **Tipos de variables.** Numérica (continua o discreta) o categórica (nominal u ordinal). El tipo decide qué análisis puedes hacer. EDAD en ENS es categórica ordinal.
2. **Centro.** Media y mediana. La media se mueve con los valores extremos; la mediana no. Si difieren mucho, hay asimetría u outliers.
3. **Dispersión.** Varianza, desviación estándar (en las mismas unidades que los datos) y rango intercuartílico (IQR = Q3 − Q1).
4. **Boxplot.** Resume 5 números: mínimo, Q1, mediana, Q3 y máximo. Un outlier está a más de 1.5·IQR fuera de la caja.
5. **Datos faltantes.** EDAD tiene 4 vacíos (346 de 350). Cuéntalos siempre antes de analizar.





Media y mediana casi iguales → distribución casi simétrica. Los jóvenes tienen la caja claramente más abajo. ¿Es una diferencia real o azar? Eso lo responde la sesión 0.7.

Fórmulas

$\bar{x} = \Sigma x / n$

$s^2 = \Sigma(x - \bar{x})^2 / (n - 1)$

$s = \sqrt{s^2}$

$IQR = Q3 - Q1$

outlier: $x < Q1 - 1.5 \cdot IQR$

o $x > Q3 + 1.5 \cdot IQR$

En Python

```
d.describe(include='all')
d.isna().sum()
d.groupby('EDAD').COLESTEROL
  .agg(['mean','median','std'])
d.FUMA.value_counts(normalize=True)
```

Con los datos reales

- Media 192.8 · mediana 189.8 · s = 43.3
- Joven 163 · Adulto 201 · Adulto Mayor 208
- 34% fuma · 19% hace deporte

Cuidado
pandas calcula la desviación estándar con n − 1 (43.28); numpy usa n por defecto (43.22). Con muestras chicas la diferencia importa: usa ddof=1 en numpy.

Ejercicio de cierre (solución al final)
Con salarios.xlsx, calcula media, mediana y desviación estándar del salario por industria. ¿Qué industria tiene salarios más dispersos?

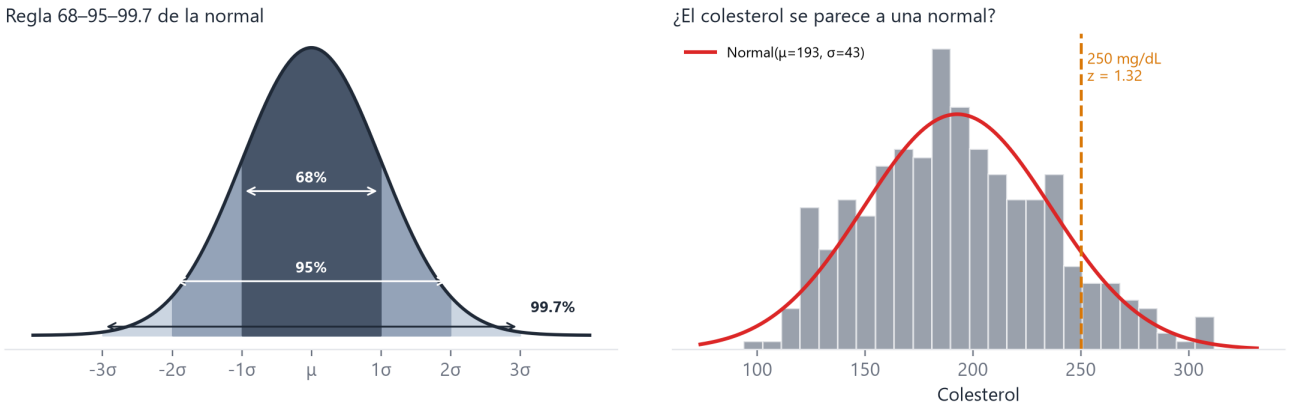
Sesión 0.2 · Distribuciones y la normal

Miércoles 7 de octubre · ~95 min · dataset: ENS.csv

Una distribución dice qué valores son comunes y cuáles son raros. La normal es la más importante porque aparece una y otra vez, sobre todo al promediar.

Conceptos clave

1. **Distribución de probabilidad.** El área bajo la curva es la probabilidad. El área total es 1.
2. **Normal.** Simétrica y definida solo por μ (centro) y σ (ancho). Regla 68–95–99.7.
3. **Puntaje z.** Cuántas desviaciones estándar está un valor de la media. Permite comparar variables con distintas unidades.
4. **Verificar normalidad.** Histograma + QQ-plot. Shapiro-Wilk en ENS da p = 0.007 aunque el histograma se ve casi normal: con n grande, el test detecta desvíos mínimos. Mira el gráfico, no solo el p-valor.
5. **Otras que verás.** t de Student (como la normal, con colas más gruesas; para muestras chicas), chi-cuadrado y binomial (conteo de éxitos).



Izquierda: la regla 68–95–99.7. Derecha: el colesterol real con la normal que mejor se le ajusta. Se parecen bastante, pero no son idénticas.

Fórmulas

$z = (x - \mu) / \sigma$

$P(X > x) = 1 - \Phi(z)$

Φ = área acumulada de la normal

$z = \pm 1.96$ deja el 95% al centro

En Python

```
(c - c.mean()) / c.std()
stats.norm.cdf(1.32) # 0.907
stats.norm.ppf(0.975) # 1.96
stats.probplot(c, plot=plt)
stats.shapiro(c)
```

Con los datos reales

- 250 mg/dL → z = 1.32
- La normal predice 9.3% sobre 250
- En los datos reales es 9.7% → buen modelo

Cuidado
La normal es un MODELO, no una ley de la naturaleza. Antes de usarla, verifica que se parezca a tus datos.

Ejercicio de cierre (solución al final)
Si el colesterol fuera Normal(193, 43), ¿qué porcentaje de personas tendría menos de 150 mg/dL? Compáralo con el porcentaje real de ENS.

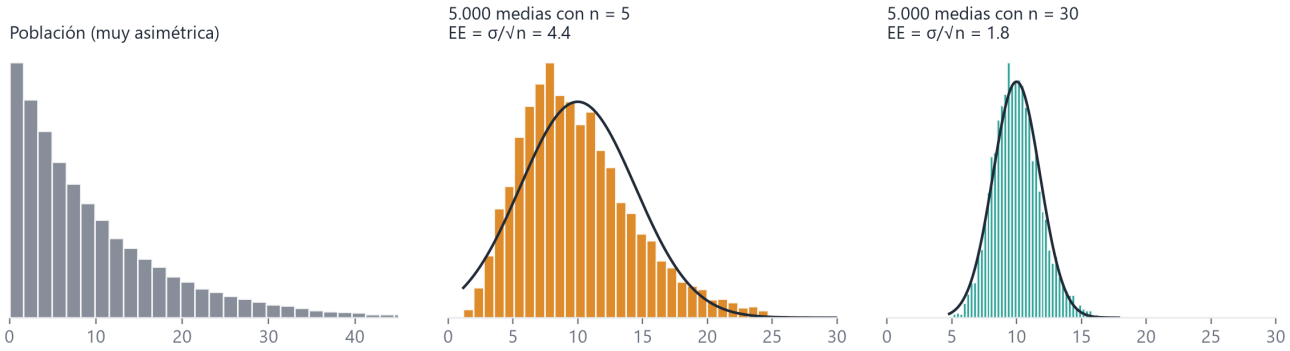
Sesión 0.3 · Muestras y error estándar

Viernes 9 de octubre · ~95 min · dataset: ENS.csv

Nunca vemos la población completa, solo una muestra. El error estándar mide cuánto cambiaría nuestro promedio si tomáramos otra muestra.

Conceptos clave

1. **Población vs muestra.** Parámetros (μ, σ) describen la población y son desconocidos. Estadísticos ($\bar{x}$, s) se calculan en la muestra y los estiman.
2. **Distribución muestral.** Si repitieras el muestreo muchas veces, las medias formarían su propia distribución.
3. **Teorema Central del Límite.** Con n suficientemente grande (regla práctica: 30 o más), la media se distribuye aproximadamente normal, AUNQUE la población no lo sea.
4. **Error estándar.** EE = s / √n: la desviación estándar de la media. Para reducirlo a la mitad hay que cuadruplicar n.
5. **s vs EE.** s describe cuánto varían las PERSONAS. EE describe cuán preciso es el PROMEDIO.



Simulación con una población muy asimétrica. Con n = 5 las medias todavía son asimétricas; con n = 30 ya son prácticamente normales y mucho más concentradas.

Fórmulas

$$EE = \sigma / \sqrt{n} \approx s / \sqrt{n}$$

$$\bar{x} \approx \text{Normal}(\mu, \sigma^2/n) \text{ si n es grande}$$

En Python

```
stats.sem(c) # 2.31
rng = np.random.default_rng(0)
rng.choice(pob, (5000, n))
   .mean(axis=1)
```

Con los datos reales

- s = 43.3 → las personas varían ±43 mg/dL
- EE = 43.3 / √350 = 2.31
- El PROMEDIO se conoce con precisión de ±2

Cuidado
El TCL habla de la distribución de la MEDIA, no de los datos: no convierte tus datos en normales.

Ejercicio de cierre (solución al final)
¿Cuánto sería el error estándar del colesterol con n = 35? ¿Y con n = 3.500? ¿Cuántas veces más datos necesitas para tener 10 veces más precisión?

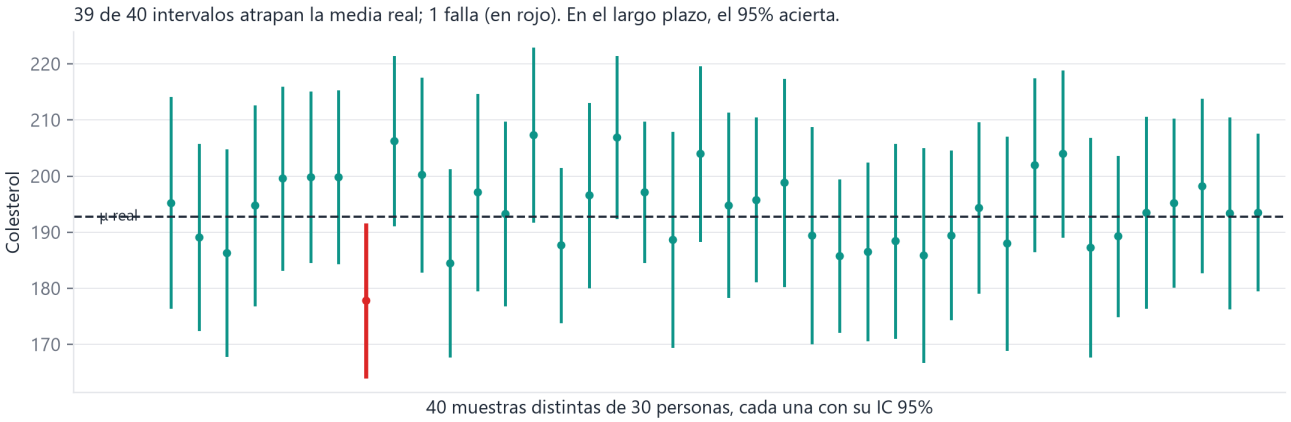
Sesión 0.4 · Intervalos de confianza

Lunes 12 de octubre · ~95 min · dataset: ENS.csv

Un intervalo de confianza entrega un rango de valores plausibles para el parámetro, en vez de un solo número que casi seguro no es exacto.

Conceptos clave

1. **Puntual vs intervalo.** $\bar{x}$ = 192.8 es una estimación puntual. El intervalo agrega cuánta incertidumbre tiene.
2. **IC 95% de la media.** $\bar{x} \pm t \cdot EE$. Con n grande, t ≈ 1.96 (de la sesión 0.2).
3. **Interpretación correcta.** Si repitiéramos el muestreo muchas veces, el 95% de los intervalos construidos así contendrían μ. Eso es lo que muestra la figura.
4. **Ancho.** Más n → más angosto. Más confianza (99%) → más ancho.
5. **Puente con las pruebas.** Si el IC 95% no contiene un valor, una prueba bilateral con α = 0.05 rechazaría ese valor.



Simulación: 40 muestras de 30 personas desde una población con la media y desviación del colesterol real. Cada línea es un IC 95%.

Fórmulas

$$IC = \bar{x} \pm t(n-1;\ 0.975) \cdot s/\sqrt{n}$$

t ≈ 1.96 si n es grande

En Python

```
stats.t.interval(0.95, n - 1,
    loc=c.mean(),
    scale=stats.sem(c))
```

Con los datos reales

- IC 95% del colesterol: [188.2; 197.3]
- No contiene 200 → la sesión 0.7 lo confirma con una prueba t (p = 0.002)

Cuidado
NO digas «hay 95% de probabilidad de que μ esté en este intervalo». μ es fija: lo que varía de muestra en muestra es el intervalo. Es sutil, pero lo preguntan.

Ejercicio de cierre (solución al final)
Calcula el IC 95% del colesterol para quienes hacen deporte y para quienes no. ¿Se solapan los intervalos? ¿Qué sugiere eso?

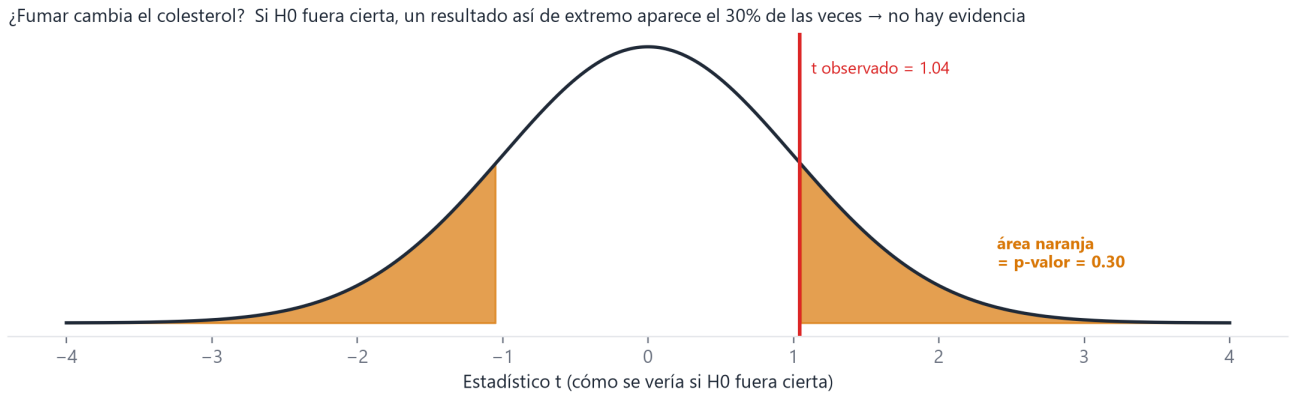
Sesión 0.5 · Prueba de hipótesis y p-valor

Martes 13 de octubre · ~95 min · dataset: ENS.csv

Una prueba de hipótesis funciona como un juicio: H0 es inocente hasta que los datos aporten evidencia suficiente en su contra.

Conceptos clave

1. **H0 y H1.** H0: no hay efecto o diferencia. H1: sí lo hay. Siempre se plantean ANTES de mirar el resultado.
2. **Estadístico de prueba.** Mide cuán lejos están los datos de lo que predice H0, en unidades de error estándar: t = diferencia / EE.
3. **p-valor.** Probabilidad de obtener un resultado igual o más extremo que el observado, SI H0 fuera cierta. Es el área naranja de la figura.
4. **Decisión.** Si p < α (0.05), se rechaza H0. Si no, «no se rechaza» — NUNCA «se acepta H0»: ausencia de evidencia no es evidencia de ausencia.
5. **Bilateral o unilateral.** Bilateral: «¿es distinto?» (lo habitual). Unilateral: «¿es mayor?», solo si la dirección se justifica antes de ver los datos.



Fumadores vs no fumadores en ENS. Los fumadores tienen 5.3 mg/dL más en promedio, pero esa diferencia cabe perfectamente dentro de lo que produce el azar.

Fórmulas

$t = (\bar{x}_1 - \bar{x}_2) / EE_{diferencia}$

$p < \alpha \rightarrow$ rechazar H0

$p \geq \alpha \rightarrow$ no rechazar H0

En Python

```
a = c[d.FUMA == 'Si']
b = c[d.FUMA == 'No']
stats.ttest_ind(a, b,
                equal_var=False)
```

Con los datos reales

- Fuma: 196.3 · No fuma: 190.9
- t = 1.04 · p = 0.30
- → no hay evidencia de que fumar cambie el colesterol en estos datos

Cuidado
El p-valor NO es la probabilidad de que H0 sea cierta. Recuerda la alerta de la Clase 17: la profesora lo confunde con α.

Ejercicio de cierre (solución al final)
Plantea H0 y H1 para la pregunta «¿hacer deporte se asocia a un colesterol distinto?». ¿Es una prueba bilateral o unilateral?

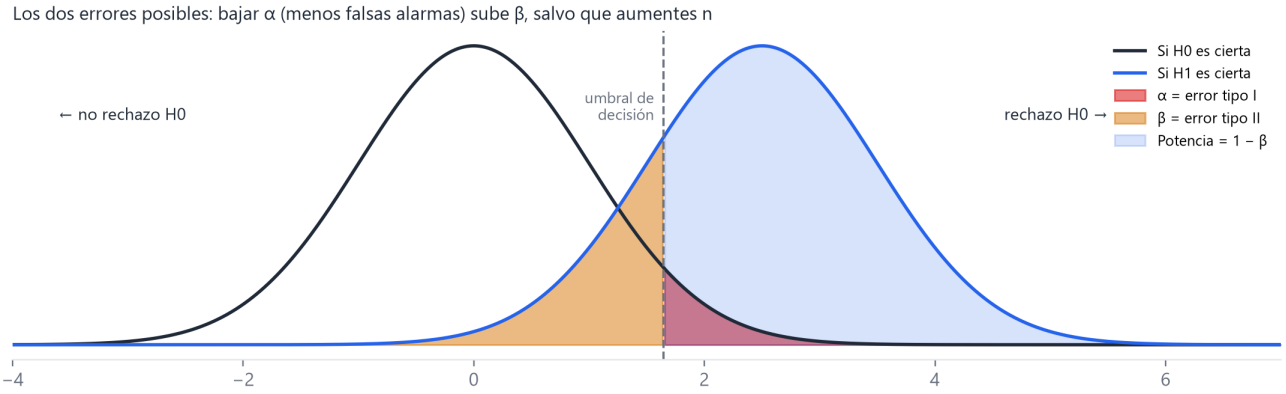
Sesión 0.6 · Errores, potencia y tamaño de efecto

Miércoles 14 de octubre · ~95 min · dataset: ENS.csv

Toda decisión con datos puede equivocarse de dos formas. Diseñar bien un estudio es controlar las dos.

Conceptos clave

1. **Error tipo I (α).** Rechazar H0 cuando es cierta: una falsa alarma. Lo fijas tú, normalmente en 0.05.
2. **Error tipo II (β).** No rechazar H0 cuando es falsa: un efecto real que no detectas.
3. **Potencia = 1 − β.** Probabilidad de detectar un efecto que existe. Sube con más n, con efectos más grandes y con α mayor. Lo habitual es buscar 80%.
4. **Significativo ≠ importante.** Con n enorme, diferencias mínimas salen significativas. Reporta siempre el tamaño del efecto, por ejemplo la d de Cohen.
5. **Comparaciones múltiples.** Con 20 pruebas a α = 0.05, se espera ~1 falso positivo solo por azar. Por eso ANOVA usa Tukey.



Si H0 es cierta (curva negra), el área roja son las falsas alarmas. Si H1 es cierta (curva azul), el área naranja son los efectos que se escapan. Mover el umbral cambia un error por el otro.

Fórmulas

H0 cierta + rechazo → Error I (α)

H0 falsa + no rechazo → Error II (β)

Potencia = 1 − β

$d = (\bar{x}_1 - \bar{x}_2) / s_{combinada}$

0.2 pequeño · 0.5 medio · 0.8 grande

En Python

```
from statsmodels.stats.power \
    import TTestIndPower
TTestIndPower().solve_power(
    effect_size=0.43,
    alpha=0.05, power=0.8)
```

Con los datos reales

- Deporte: d = 0.43 (efecto entre pequeño y medio)
- Para detectarlo con 80% de potencia se necesitan ~85 personas por grupo
- ENS tiene 68 que hacen deporte: la detectó igual (p = 0.0015)

Cuidado
p = 0.049 y p = 0.051 son prácticamente la misma evidencia. 0.05 es una convención, no una frontera mágica.

Ejercicio de cierre (solución al final)
Haces 10 pruebas independientes con α = 0.05 y todas las H0 son ciertas. ¿Cuál es la probabilidad de obtener al menos un falso positivo?

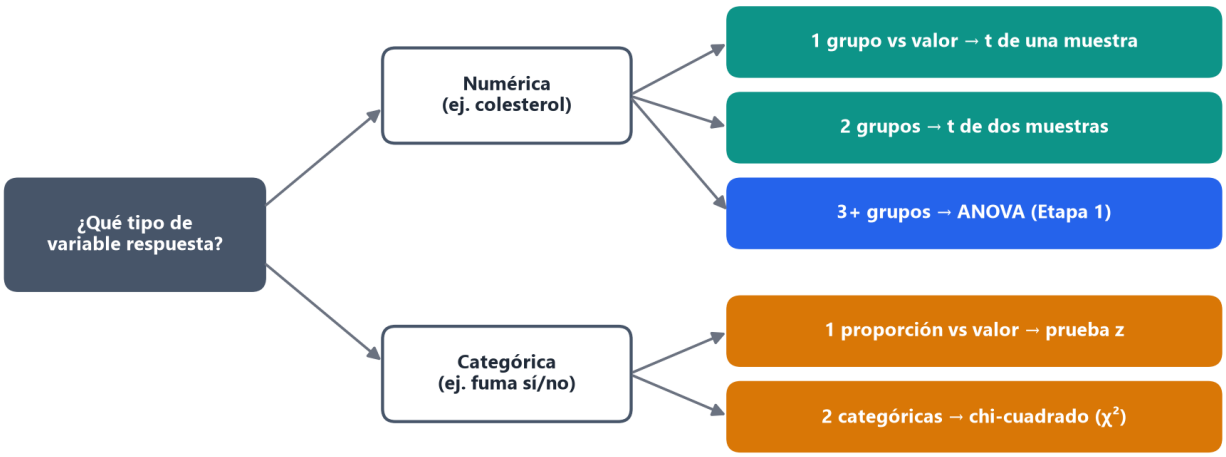
Sesión 0.7 · Pruebas t, de proporción y χ^2

Viernes 16 de octubre · ~95 min · dataset: ENS.csv

Elegir la prueba depende de dos preguntas: qué tipo de variable mides y cuántos grupos comparas.

Conceptos clave

1. **t de una muestra.** ¿La media es distinta de un valor? Colesterol vs 200: t = −3.13, p = 0.002 → sí, es menor.
2. **t de dos muestras (Welch).** ¿Dos grupos difieren? Deporte vs no: −18.5 mg/dL, p = 0.0015 → sí. Usa Welch (equal_var=False): no asume varianzas iguales.
3. **Prueba de proporción.** ¿El % de fumadores (34.3%) es distinto de 30%? p = 0.09 → no hay evidencia.
4. **Chi-cuadrado (χ^2).** ¿Dos categóricas están asociadas? FUMA × DEPORTE: χ^2 = 4.18, p = 0.041 → sí. En esta muestra los fumadores hacen MÁS deporte (26% vs 16%). Sorprendente: así se ve una asociación que no implica causa.
5. **Supuestos.** Observaciones independientes. t: normalidad aproximada o n grande (TCL). χ^2: frecuencias esperadas de 5 o más en cada celda.



Mapa de decisión. Para 3 o más grupos no se encadenan pruebas t (se inflaría el error tipo I): se usa ANOVA, el primer tema de la Clase 17.

Fórmulas

$$t = (\bar{x} - \mu_0) / (s/\sqrt{n})$$

$$\chi^2 = \Sigma\ (\text{observado} - \text{esperado})^2 / \text{esperado}$$

En Python

```
stats.ttest_1samp(c, 200)
stats.ttest_ind(a, b, equal_var=False)
stats.binomtest(120, 350, p=0.30)
tabla = pd.crosstab(d.FUMA, d.DEPORTE)
stats.chi2_contingency(tabla)
```

Con los datos reales

- Antes de elegir: ¿la respuesta es numérica o categórica?
- Después: ¿cuántos grupos comparo?
- Al final: ¿se cumplen los supuestos?

Cuidado
Reporta siempre tres cosas: el estadístico, el p-valor y la diferencia en unidades reales (ej. «18.5 mg/dL menos»). Solo el p-valor no dice cuán grande es el efecto.

Ejercicio de cierre (solución al final)
¿El colesterol difiere entre «Adulto» y «Adulto Mayor»? Elige la prueba, ejecútala y escribe la conclusión en una frase.

Cierre de la Etapa 0

Errores clásicos, evaluación, soluciones y recursos

Errores clásicos de interpretación

Lo que se dice mal	Lo correcto
«p = 0.03: hay 3% de probabilidad de que H0 sea cierta»	Si H0 fuera cierta, un resultado así o más extremo aparecería el 3% de las veces
«p = 0.30: entonces H0 es verdadera»	No hay evidencia suficiente para rechazarla. Eso no la prueba
«Hay 95% de probabilidad de que μ esté en [188; 197]»	El 95% de los intervalos construidos así contienen μ
«Es significativo, entonces es importante»	Mira el tamaño del efecto en unidades reales
«El TCL hace que mis datos sean normales»	El TCL habla de la distribución de la media, no de los datos
«Están asociados, entonces uno causa el otro»	Asociación no es causalidad (Clase 22: causalidad aplicada)

Soluciones de los ejercicios de cierre

Sesión	Solución
0.1	Retail: media 2.90, mediana 2.80, s = 0.86 · Banca: 3.36 / 3.35 / 0.63 · Minería: 4.48 / 4.50 / 0.52. Retail es la más dispersa.
0.2	z = (150 − 193) / 43 = −0.99 → la normal predice 16.2%. En los datos reales es 18.3%: la normal subestima un poco la cola baja.
0.3	n = 35 → EE = 7.32 · n = 3.500 → EE = 0.73. Para 10 veces más precisión se necesitan 10^2 = 100 veces más datos.
0.4	Deporte: [167.8; 188.0] · Sin deporte: [191.3; 201.4]. No se solapan: sugiere una diferencia real (la sesión 0.7 lo confirma).
0.5	H0: μ_deporte = μ_sin deporte. H1: μ_deporte ≠ μ_sin deporte. Es bilateral: la pregunta dice «distinto», no «menor».
0.6	$1 - 0.95^{10}$ = 0.40. Hay 40% de probabilidad de al menos una falsa alarma.
0.7	Numérica y 2 grupos → t de Welch. Adulto 200.8 vs Adulto Mayor 207.5: t = −1.29, p = 0.20 → no hay evidencia de diferencia.

Criterio de dominio: paso a la Clase 17 si...

- ☐ Explico sin apuntes qué es un p-valor y qué es un IC 95%
- ☐ Distingo desviación estándar de error estándar
- ☐ Ante una pregunta nueva, elijo la prueba correcta
- ☐ La ejecuto en Python y la concluyo en una frase con unidades
- ☐ Respondo 5 de 6 en la evaluación del domingo 18

Recursos externos (solo si algo no queda claro)

- **StatQuest (Josh Starmer), YouTube**: videos de 10–15 min sobre p-valores, IC y TCL. Es el mejor recurso para pasar de fórmula a intuición. En inglés, con subtítulos.
- **OpenIntro Statistics (libro gratuito)**, capítulos 5–7: los mismos temas con ejercicios. Las soluciones de los ejercicios impares están al final del libro.
- **Seeing Theory (Brown University)**: visualizaciones interactivas del TCL y de los IC. Sirve para jugar con la figura de la sesión 0.4.

Evaluaciones de los domingos

Responde por escrito y sin apuntes. Las respuestas están abajo: míralas solo al terminar.

Domingo 11 oct · sesiones 0.1 a 0.3

1. La variable «nivel educacional» (básica, media, superior), ¿es numérica, nominal u ordinal?
2. Una variable tiene media 80 y mediana 60. ¿Hacia qué lado está sesgada?
3. Un valor tiene $z = -2$. ¿Es un valor común o raro? ¿Por qué?
4. ¿Qué mide la desviación estándar y qué mide el error estándar?
5. Si n pasa de 100 a 400, ¿qué le pasa al error estándar?
6. ¿El Teorema Central del Límite dice que, con n grande, los datos son normales?

Domingo 18 oct · toda la etapa

1. El IC 95% de una diferencia de medias es $[-2; 8]$. ¿Hay diferencia significativa con $\alpha = 0.05$?
2. Una prueba da $p = 0.20$. Escribe la conclusión correcta en una frase.
3. Quieres comparar el ingreso medio de 4 regiones. ¿Qué prueba usas?
4. ¿El género y la preferencia de producto (A, B o C) están asociados? ¿Qué prueba usas?
5. Un estudio con 1 millón de personas halla una diferencia de 0.1 mg/dL con $p < 0.001$. ¿Es relevante?
6. ¿Qué es la potencia de una prueba y cómo la aumentas?

Respuestas

#	Domingo 11	Domingo 18
P1	Categórica ordinal: tiene orden, pero no distancias numéricas.	No: el intervalo contiene el 0.
P2	A la derecha: la media es arrastrada por valores altos.	No hay evidencia suficiente para rechazar H0 (no significa que H0 sea cierta).
P3	Raro: solo ~2.5% de los valores está por debajo de -2σ.	ANOVA (Clase 17). Varias pruebas t inflarían el error tipo I.
P4	s: cuánto varían las personas. EE: cuán preciso es el promedio.	Chi-cuadrado de independencia: dos variables categóricas.
P5	Se reduce a la mitad ($\sqrt{400} / \sqrt{100} = 2$).	Es significativa, pero sin importancia práctica: el efecto es mínimo.
P6	No. Habla de la distribución de la MEDIA, no de los datos.	La probabilidad de detectar un efecto real. Se aumenta con más n (o con un efecto mayor o un α mayor).

Nota: 5 de 6 correctas el domingo 18 es parte del criterio de dominio. Si fallas una pregunta, vuelve a la sesión que la cubre antes de empezar la Clase 17.