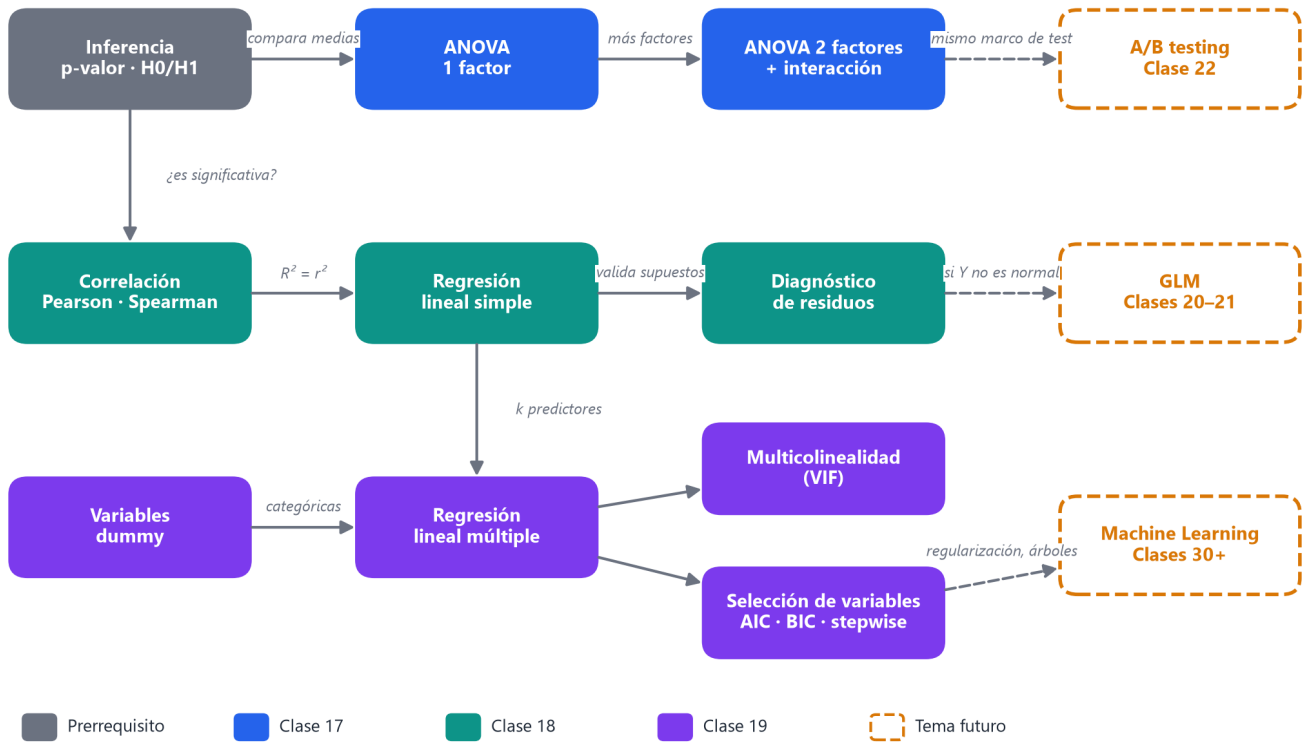
Carpeta 1 · Análisis de regresión

Clases 17, 18 y 19 · Profesora Ana María Alvarado · Etapa 1 del roadmap (semanas 3–5)

La gran idea de la carpeta

ANOVA y regresión son **el mismo modelo**: **Y = parte explicada + error**. ANOVA explica Y con variables **categóricas** (grupos), la regresión con variables **numéricas**, y la regresión múltiple mezcla ambas usando **variables dummy**. Si entiendes esto, las tres clases son una sola historia.

Mapa conceptual



Lo que necesitas ANTES

- Media, varianza y desviación estándar
- Distribución normal
- Prueba de hipótesis: H0 / H1, p-valor y α
- Intervalo de confianza
- Cuartiles y boxplot
- → Todo esto es la **Etapa 0** del roadmap

Hacia dónde lleva

- **GLM (C20–21):** la regresión logística es la regresión cuando Y es categórica
- **A/B testing (C22):** mismo marco de prueba de hipótesis que ANOVA
- **Machine Learning (C30+):** árboles y random forest cuando la regresión no alcanza
- **Regularización:** LASSO / Ridge como alternativa a stepwise

Dataset	Clase	Pregunta que responde
salarios.xlsx (40 filas)	17 · 18 · 19	¿Cambia el salario según industria, sexo y experiencia?
biomass.txt (45 filas, 17 col.)	18 · 19	¿Qué propiedades del suelo predicen la biomasa?
bio_new.csv	19	Predicción con datos nuevos (quedó pendiente en clase)
ENS.csv	17	Datos de apoyo del notebook

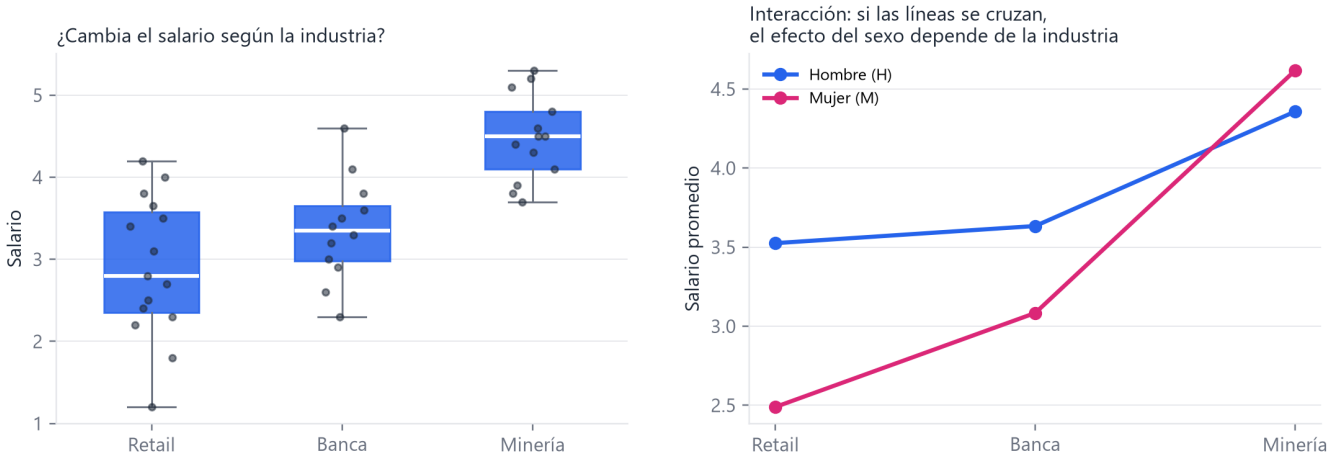
Clase 17 · ANOVA: comparar medias de grupos

Fuente: transcripción de la clase + notebook R

¿Las medias de varios grupos son realmente distintas, o la diferencia es puro ruido? ANOVA compara la variación ENTRE grupos con la variación DENTRO de los grupos.

Conceptos clave

1. **Modelo básico.** Todo dato = un promedio + un error aleatorio (Y = μ + ε). Es el punto de partida de todos los modelos.
2. **ANOVA de 1 factor.** H0: todas las medias son iguales. H1: al menos dos son distintas. Si F es grande, los grupos difieren más de lo que explica el azar.
3. **Factor en R.** Una categórica codificada con números (región 1–16) debe declararse *factor*; si no, el modelo la trata como cantidad y el resultado no tiene sentido.
4. **Comparaciones múltiples.** ANOVA dice SI hay diferencias, no CUÁLES. Tukey (grupos de tamaño similar) o Scheffé (tamaños desiguales) comparan par a par.
5. **Interacción.** El efecto de un factor puede depender del otro. En los datos de la clase, las mujeres ganan menos en retail y banca, pero más en minería.



Datos reales de salarios.xlsx. Izquierda: la variación entre industrias es visible. Derecha: las líneas se cruzan en minería → hay interacción industria × sexo.

Fórmulas

$Y_{ij} = \mu + \alpha_j + \varepsilon_{ij}$

$Y = \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + \varepsilon$

$SC_{total} = SC_{entre} + SC_{dentro}$

$F = CM_{entre} / CM_{dentro}$

Cómo leer la salida

- **Pr(>F) < 0.05** → hay diferencias entre grupos
- Coeficientes: la 1ª categoría es la base; las demás son diferencias respecto a ella
- IC de dos grupos que no se solapan → diferencia significativa
- Estrellas: *** p≈0 · ** p<0.01 · * p<0.05

En Python

```
smf.ols('Salario ~ C(Industria)', d).fit()
sm.stats.anova_lm(modelo)
pairwise_tukeyhsd(d.Salario, d.Industria)
```

Cuidado
No elimines outliers «por receta»: entiende primero por qué son atípicos.
Supuestos: errores independientes, normales y con varianza constante.

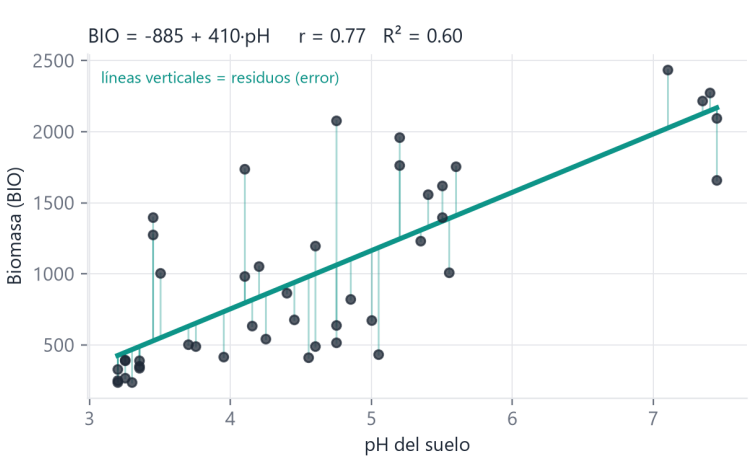
Clase 18 · Correlación y regresión lineal simple

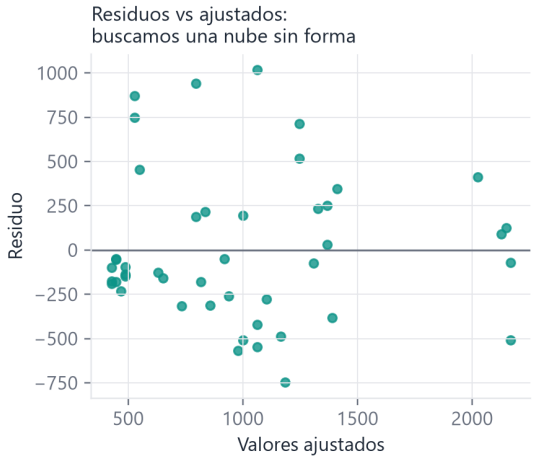
Fuente: transcripción de la clase + notebook R

La correlación mide si dos variables se mueven juntas en línea recta. La regresión convierte esa relación en una ecuación para predecir.

Conceptos clave

1. **Correlación de Pearson.** Va de −1 a 1 y mide relación LINEAL. r ≈ 0 no significa «sin relación»: puede haber una relación curva (ejemplo del datasaurus).
2. **Correlación ≠ causalidad.** Que dos variables se muevan juntas no prueba que una cause la otra.
3. **Regresión simple.** Y = β0 + β1·X + ε, estimada por mínimos cuadrados. β1 = cuánto cambia Y por cada unidad de X.
4. **R^2.** % de la variabilidad de Y que explica el modelo. En regresión simple, $R^2 = r^2$.
5. **Diagnóstico de residuos.** Normalidad (QQ-plot, Shapiro-Wilk), independencia (Durbin-Watson), homocedasticidad (Breusch-Pagan). Aquí queremos NO rechazar H0.





Datos reales de biomass.txt: r = 0.77 → $R^2 = 0.77^2 = 0.60$. El pH explica el 60% de la variación de la biomasa. El intercepto negativo (−885) no tiene sentido físico: pH = 0 está fuera del rango de los datos.

Fórmulas

$Y = \beta0 + \beta1 \cdot X + \varepsilon$

$R^2 = SC_regresión / SC_total$

$R^2 = r^2$ (solo regresión simple)

Cómo leer la salida

- **Estimate**: los β. **Pr(>|t|)**: prueba H0: β = 0
- Si β1 no es significativo, X no aporta
- **R^2** cerca de 1 = buen ajuste (pero un $R^2 = 1$ es sospechoso)
- No extrapolar fuera del rango de X observado

En Python

```
stats.pearsonr(x, y)
m = smf.ols('BIO ~ Ph', d).fit()
m.summary()
het_breuschpagan(m.resid, m.model.exog)
```

Cuidado

Un outlier en X puede «tirar» la recta (efecto palanca). Antes de borrarlo, márcalo con una dummy y prueba si influye.

No descartes una variable por baja correlación: prueba Spearman o un modelo múltiple.

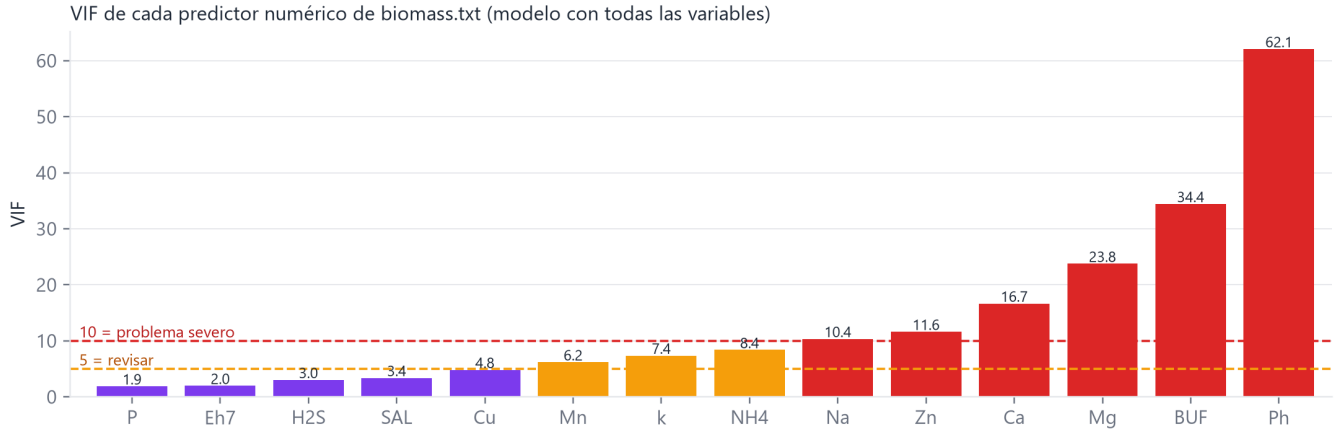
Clase 19 · Regresión lineal múltiple

Fuente: transcripción de la clase + notebook R

Con varios predictores, cada coeficiente dice el efecto de una variable MANTENIENDO LAS DEMÁS CONSTANTES. Y hay que vigilar que los predictores no se pisen entre sí.

Conceptos clave

1. **Lineal = en los parámetros.** $Y = \beta0 + \beta1 \cdot X^2$ sigue siendo lineal (X^2 es otra variable). Lo que no puede haber es β al cuadrado.
2. **Dos pruebas.** t: ¿esta variable aporta? (H0: βj = 0). F global: ¿el modelo aporta algo? (H0: todos los β = 0).
3. **Variables dummy.** Una categórica con m niveles usa m − 1 dummies. Usar las m junto al intercepto hace la matriz no invertible (dummy trap).
4. **R^2 ajustado, AIC y BIC.** El R^2 SIEMPRE sube al agregar variables, aunque no sirvan. Para comparar modelos de distinto tamaño usa R^2 ajustado, AIC o BIC.
5. **Multicolinealidad y stepwise.** Predictores muy correlacionados inflan el VIF y vuelven inestables los β. Forward, backward y both pueden terminar en modelos distintos.



VIF calculado sobre biomass.txt. El pH, el mejor predictor individual de la Clase 18, tiene VIF = 62: está muy correlacionado con BUF, Mg y Ca. Por eso su coeficiente se vuelve inestable en el modelo completo.

Fórmulas

$Y = \beta0 + \beta1 \cdot X1 + \ldots + \beta k \cdot Xk + \varepsilon$

$VIF_j = 1 / (1 - R^2_j)$

N° de subconjuntos de k variables = 2^k

Cómo leer la salida

- Cada β: efecto de Xj con las demás fijas
- VIF < 5 OK · 5–10 revisar · > 10 problema
- Menor AIC/BIC = mejor equilibrio ajuste/simplicidad
- R^2 alto + residuos malos = el modelo **NO** sirve todavía

En Python

```
smf.ols('BIO ~ Ph + SAL + k', d).fit()
variance_inflation_factor(X, j)
m.aic, m.bic, m.rsquared_adj
pd.get_dummies(d, drop_first=True)
```

Cuidado

Conclusión de la profesora: el modelo elegido ($R^2 \approx 0.85$) cumple normalidad y homocedasticidad, pero falla en independencia (Durbin-Watson), así que todavía no sirve. El siguiente paso sería transformar (Box-Cox) o cambiar de modelo.

Con 16 candidatas hay 2^16 = 65.536 modelos posibles (no 16!).

Traductor R → Python

Para leer los notebooks de clase y practicar en Python

En la clase (R)	En Python	Para qué
skim(d) / summary(d)	d.describe(include='all')	Explorar los datos
factor(x)	C(x) en la fórmula · pd.Categorical	Tratar x como grupo
aov(y ~ x)	smf.ols('y ~ C(x)', d).fit() + anova_lm()	ANOVA
TukeyHSD()	pairwise_tukeyhsd()	Comparaciones múltiples
cor() / cor.test()	d.corr() · stats.pearsonr()	Correlación
lm(y ~ x)	smf.ols('y ~ x', d).fit()	Regresión
summary(m)	m.summary()	Tabla de resultados
shapiro.test()	stats.shapiro(m.resid)	Normalidad de residuos
dwtest()	durbin_watson(m.resid)	Independencia
bptest()	het_breuschpagan(m.resid, m.model.exog)	Homocedasticidad
vif()	variance_inflation_factor()	Multicolinealidad
AIC(m) / BIC(m)	m.aic / m.bic	Comparar modelos
step()	No existe directo: se programa comparando AIC	Selección stepwise
predict(m, nuevos)	m.predict(nuevos)	Predecir

Imports: `import statsmodels.formula.api as smf` · `import statsmodels.api as sm` · `from scipy import stats`

Checklist: ¿mi regresión es confiable?

	Supuesto	Cómo lo verifico
☐	Linealidad	Gráfico Y vs X y residuos vs ajustados sin forma de curva
☐	Normalidad de residuos	QQ-plot sobre la diagonal · Shapiro-Wilk p > 0.05
☐	Independencia	Durbin-Watson cerca de 2
☐	Homocedasticidad	Nube de residuos sin forma de embudo · Breusch-Pagan p > 0.05
☐	Multicolinealidad	Todos los VIF < 5 (o justificar los que están entre 5 y 10)
☐	Puntos influyentes	Revisar outliers / palanca antes de decidir qué hacer
☐	Rango	Predecir solo dentro del rango de X observado

Ojo con el p-valor en los diagnósticos. En las pruebas de supuestos, H0 es «el supuesto se cumple». Por eso aquí queremos un p-valor GRANDE (> 0.05). Es al revés que al probar si un coeficiente es significativo.

Alertas del material, repaso y criterio de dominio

Lo que hay que corregir, lo que debes saber responder y cuándo pasar a la Clase 20

Alertas del material

Definición imprecisa del p-valor (Clase 17)

En la transcripción se dice que «el valor p es la probabilidad de rechazar H0 cuando H0 es correcta». Eso es **α** (el nivel de significancia, o probabilidad de error tipo I), que se fija ANTES del análisis.

Definición correcta: el p-valor es la probabilidad de obtener un resultado **igual o más extremo** que el observado, **suponiendo que H0 es verdadera**. Se compara con α: si p < α, se rechaza H0.

En la misma frase se dice «siempre quiero rechazar H0». Eso no aplica a los diagnósticos de supuestos, donde queremos NO rechazar.

Otras observaciones

- La transcripción de la Clase 18 tiene un tramo ilegible por error del reconocimiento de voz. No es un error de la profesora.
- En la Clase 19 se duda entre 16! y 2^16 posibles modelos. Lo correcto es 2^16 = 65.536: cada variable está o no está.
- **bio_new.csv tiene un error de datos:** las columnas Mn, Zn y Cu tienen el punto decimal corrido (ej. Cu 502.381 vs 5.02381 en biomass). Un modelo que usa esas variables predice biomasas de ~100.000. Lo trabajas en la Parte D del notebook.
- Esta guía se basa en las transcripciones y los notebooks. Las diapositivas PDF no se revisaron página a página.

Preguntas de repaso (intenta responder antes de leer)

#	Pregunta	Respuesta corta
1	Un modelo con 10 variables tiene R^2 = 0.95 y otro con 3 tiene R^2 = 0.70. ¿El primero es mejor?	No necesariamente. El R^2 siempre sube al agregar variables. Compara con R^2 ajustado, AIC o BIC.
2	El p-valor de β1 es 0.6. ¿Qué concluyes?	No se rechaza H0: β1 = 0. No hay evidencia de que esa variable aporte al modelo.
3	Breusch-Pagan da p = 0.98. ¿Es buena o mala noticia?	Buena. H0 es «hay homocedasticidad» y no se rechaza, así que el supuesto se cumple.
4	Dos predictores tienen correlación 0.95 entre sí. ¿Los incluyes juntos?	Mejor no. Hay multicolinealidad: el VIF sube y los β se vuelven inestables. Quédate con uno o combínalos.
5	Tu modelo tiene buen R^2 pero los residuos fallan independencia. ¿Lo entregas?	No. Revisa puntos influyentes, prueba transformaciones (Box-Cox) o cambia de tipo de modelo.
6	En el gráfico de interacción, ¿qué significa que las líneas se crucen?	Que el efecto de un factor depende del nivel del otro. No basta un modelo aditivo.

Criterio de dominio para pasar a la Clase 20

- ☐ Explico sin apuntes qué compara ANOVA y qué dice un p-valor
- ☐ Ajusto en Python una regresión múltiple con una variable categórica
- ☐ Interpreto coeficientes, p-valores, R^2 ajustado y AIC
- ☐ Verifico los 4 supuestos y decido si el modelo sirve
- ☐ Predigo con bio_new.csv y detecto el error de sus datos