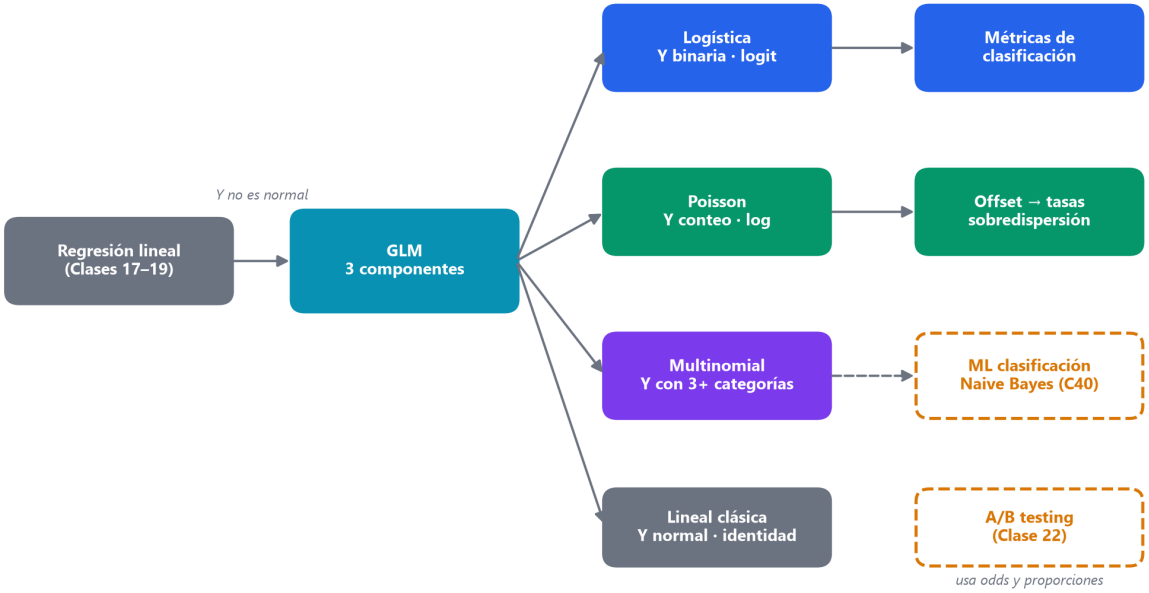
Carpeta 2 · Modelos lineales generalizados (GLM)

Clases 20 y 21 · Profesora Maritza Márquez · Etapa 2 del roadmap (semanas 6–7)

La gran idea de la carpeta

Un GLM es una regresión que **se adapta al tipo de Y**. Se arma con tres piezas: una **distribución** para Y, la misma **combinación lineal** de siempre ($\beta_0 + \beta_1 x + \ldots$) y una **función de enlace** que conecta ambas. La logística, la Poisson y la multinomial salen del mismo molde: solo cambian las piezas.

Mapa conceptual



Lo que necesitas ANTES

- Regresión lineal y lectura de coeficientes (Clases 17–19)
- p-valor, prueba de hipótesis e intervalos (Etapa 0)
- Logaritmo y exponencial: $\log(e^x) = x$
- Tipos de variables (sesión 0.1)

Hacia dónde lleva

- **A/B testing (C22):** comparar proporciones y odds
- **Clasificación en ML (C30+):** la logística es la base de muchos clasificadores
- **Naive Bayes (C40):** otra forma de estimar probabilidades de clase
- **Datos desbalanceados:** la trampa de la exactitud vuelve a aparecer

Dataset (en Guias/datos/)	Modelo	Pregunta
wcgs.csv · 3154 hombres	Logística	¿Fumar aumenta el riesgo de enfermedad coronaria (chd)?
cancer_pulmon.csv · 24 filas	Poisson + offset	¿Cómo cambia la tasa de cáncer según edad y ciudad?
nes96.csv · 944 votantes	Multinomial	¿Edad y educación predicen la afiliación política?

En clase, wcgs y nes96 se cargan desde el paquete de R *faraway*, y los datos de cáncer se escriben dentro del notebook. Para que puedas trabajar en Python, los dejé como CSV.

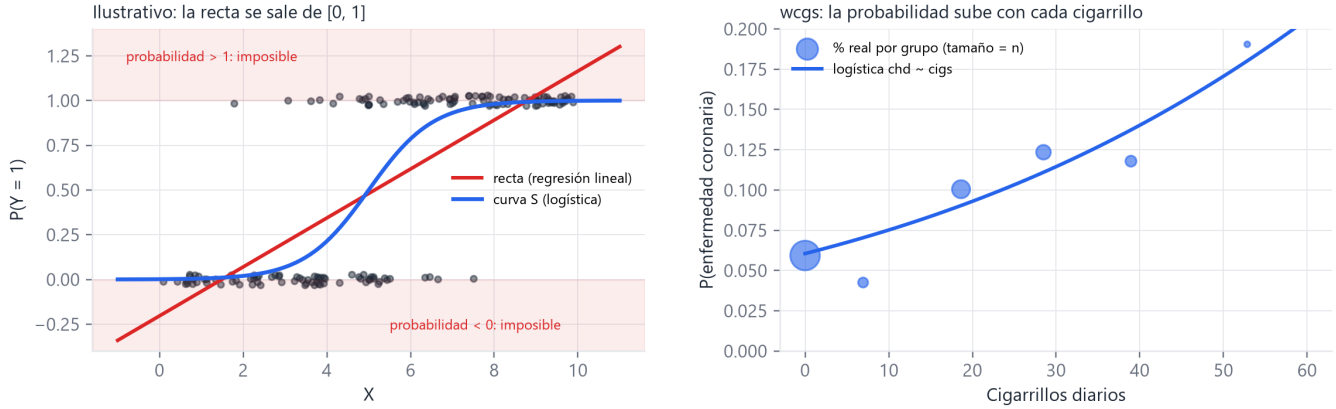
Clase 20 · La idea de los GLM

Fuente: transcripción de la clase + notebook R

Cuando Y es un sí/no, un conteo o una categoría, la recta de siempre falla. El GLM conserva la combinación lineal, pero la conecta con Y a través de una función de enlace.

Conceptos clave

1. **Por qué falla la regresión lineal.** Con Y binaria, la recta predice «probabilidades» menores que 0 o mayores que 1. Con conteos, la varianza crece con la media.
2. **Componente 1 · Distribución.** La elige el TIPO de Y: Binomial (sí/no), Poisson (conteos), Multinomial (3+ categorías), Normal (continua).
3. **Componente 2 · Predictor lineal.** $\eta = \beta_0 + \beta_1 x_1 + \ldots$: la misma combinación lineal de la regresión.
4. **Componente 3 · Enlace g(μ) = η.** Transforma la media de Y para que viva en $(-\infty, +\infty)$: logit para probabilidades, log para conteos, identidad para la normal.
5. **Odds y logit.** odds = p / (1 − p). logit = log(odds). La logística modela el logit como una recta.



Izquierda: datos ilustrativos; la recta se sale del rango posible y la curva S no. Derecha: datos reales de wcgs. Los círculos son el % real por grupo de cigarrillos y la curva es el modelo logístico.

Fórmulas

$\eta = \beta_0 + \beta_1 x$

$\text{logit}(p) = \log(p / (1 - p)) = \eta$

$p = 1 / (1 + e^{-\eta})$

Poisson: $\log(\mu) = \eta \rightarrow \mu = e^{\eta}$

Cómo leer la salida

- **Estimate**: en escala del enlace (log-odds o log), NO en la escala de Y
- **z value / Pr(>|z|)**: prueba H0: β = 0
- **Null vs Residual deviance**: cuánto mejora el ajuste al agregar las X
- **AIC**: comparar modelos (menor es mejor)

En Python

```
import statsmodels.api as sm
import statsmodels.formula.api as smf
smf.glm('y ~ x', d,
    family=sm.families.Binomial()).fit()
```

Cuidado

La distribución se elige según el tipo de Y. El enlace se elige después, entre los disponibles para esa distribución (logit, probit, cloglog para binomial). «El software aguanta lo que le pongas»: justifícalo.
El intercepto rara vez tiene interpretación práctica.

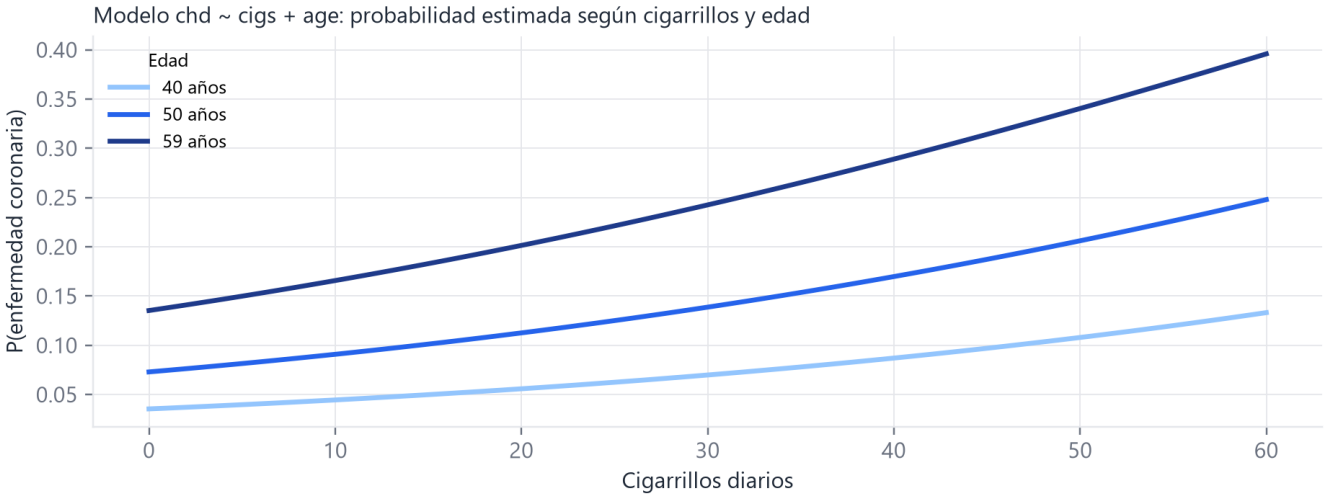
Clase 21 · Regresión logística (wcgs)

Fuente: transcripción de la clase + notebook R

Cada coeficiente dice cuánto cambian las log-odds. Al exponenciarlo, e^{β} dice por cuánto se MULTIPLICAN las odds: ese es el odds ratio (OR).

Conceptos clave

1. **El modelo.** log(p / (1 − p)) = −2.742 + 0.0232·cigs. Y = chd (enfermedad coronaria, sí/no); el 8.1% de los 3154 hombres la tiene.
2. **Odds ratio.** OR = $e^{0.0232}$ = 1.0235: cada cigarrillo diario adicional multiplica las odds por 1.0235 (+2.35%). Por 10 cigarrillos: $e^{10\cdot\beta}$ = 1.26 (+26%).
3. **Signo de β.** β > 0 → OR > 1 (factor de riesgo). β = 0 → OR = 1 (sin efecto). β < 0 → OR < 1 (factor protector).
4. **Probabilidad predicha.** Para 0 cigarrillos: p = 1/(1 + $e^{2.742}$) = 0.061. Para 20: 0.093. Para 40: 0.140.
5. **Comparar modelos.** Agregar edad baja la deviance de 1750.0 a 1705.9. Prueba de razón de verosimilitud: χ^2 = 44.1, p = $3\cdot10^{-11}$ → la edad aporta.



Modelo chd ~ cigs + age ajustado con wcgs. A igual número de cigarrillos, la probabilidad es mucho mayor a los 59 años que a los 40: OR por 10 años de edad = $e^{10\cdot0.076}$ = 2.15.

Fórmulas

OR = e^{β} · OR por k unidades = $e^{k\cdot\beta}$

% de cambio en odds = (OR − 1) · 100

LR = $\text{deviance}_{\text{simple}} - \text{deviance}_{\text{completo}} \sim \chi^2$

gl = n° de parámetros agregados

Cómo leer la salida

- Intercepto −2.742 · cigs 0.0232 (EE 0.004, p ≈ $9\cdot10^{-9}$)
- IC 95% del OR de cigs: [1.015; 1.032]: no incluye 1
- AIC: logit 1753.97 · probit 1753.49 (casi iguales)
- La curva de la figura sube con cigarrillos Y con edad

Cuidado
Odds NO es probabilidad. «Las odds aumentan 26%» no significa que la probabilidad aumente 26 puntos.
Alerta del material: un OR de 1.2614 es +26%, no +35% (ver página de alertas).

En Python

```
m = smf.logit('chd01 ~ cigs', w).fit()
np.exp(m.params) # odds ratios
np.exp(m.conf_int()) # IC de los OR
m.predict(pd.DataFrame({'cigs': [0, 20]}))
```

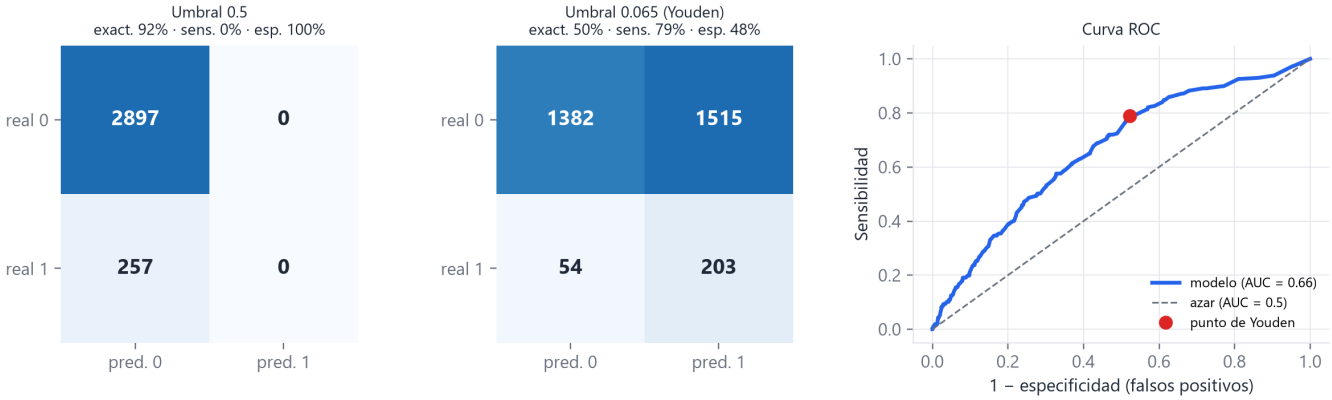
Clase 21 · Evaluar un clasificador

Fuente: transcripción de la clase + notebook R

Un modelo logístico entrega probabilidades. Para clasificar hay que elegir un umbral, y una exactitud alta puede esconder un modelo que no detecta a nadie.

Conceptos clave

1. **Matriz de confusión.** Cruza lo real con lo predicho: VP, FP, FN, VN. Todo lo demás se calcula desde ahí.
2. **La trampa de la exactitud.** En clase, con umbral 0.5: exactitud 93% pero sensibilidad 0%. El modelo dice «no» a todos y acierta porque solo el 8% está enfermo.
3. **Sensibilidad y especificidad.** Sensibilidad: de los enfermos, ¿a cuántos detecto? Especificidad: de los sanos, ¿a cuántos descarto? Precisión: de los que marco, ¿cuántos son enfermos?
4. **El umbral 0.5 no es una ley.** Es «una costumbre». Bajarlo detecta más enfermos a costa de más falsas alarmas. El índice de Youden busca el mejor equilibrio.
5. **ROC y AUC.** La curva ROC muestra todos los umbrales a la vez. AUC = 0.5 es azar; 1 es perfecto. En clase dio ≈ 0.60: un modelo débil.



Modelo chd ~ cigs + age evaluado sobre todos los datos de wcgs (en clase se usó un 30% de prueba y solo cigs, por eso los números difieren un poco). Con umbral 0.5 nadie se clasifica como enfermo; con el de Youden se detecta al 79%.

Fórmulas

Exactitud = (VP + VN) / total

Sensibilidad = VP / (VP + FN)

Especificidad = VN / (VN + FP)

Precisión = VP / (VP + FP)

Youden = sensibilidad + especificidad − 1

En Python

```
from sklearn.metrics import (
    confusion_matrix, roc_auc_score, roc_curve)
pred = (prob >= 0.5).astype(int)
confusion_matrix(y_test, pred)
```

Cómo leer la salida

- Umbral 0.5: nadie es predicho como enfermo
- Umbral de Youden (clase: 0.069): sens. 61%, esp. 55%
- Siempre reporta sensibilidad y especificidad, no solo exactitud
- Con clases desbalanceadas, mira el AUC

Cuidado

Evalúa SIEMPRE en datos que el modelo no vio (train/test). Evaluar sobre los mismos datos de entrenamiento sobreestima el rendimiento.
Elegir el umbral es una decisión de negocio: ¿qué cuesta más, un falso negativo o un falso positivo?

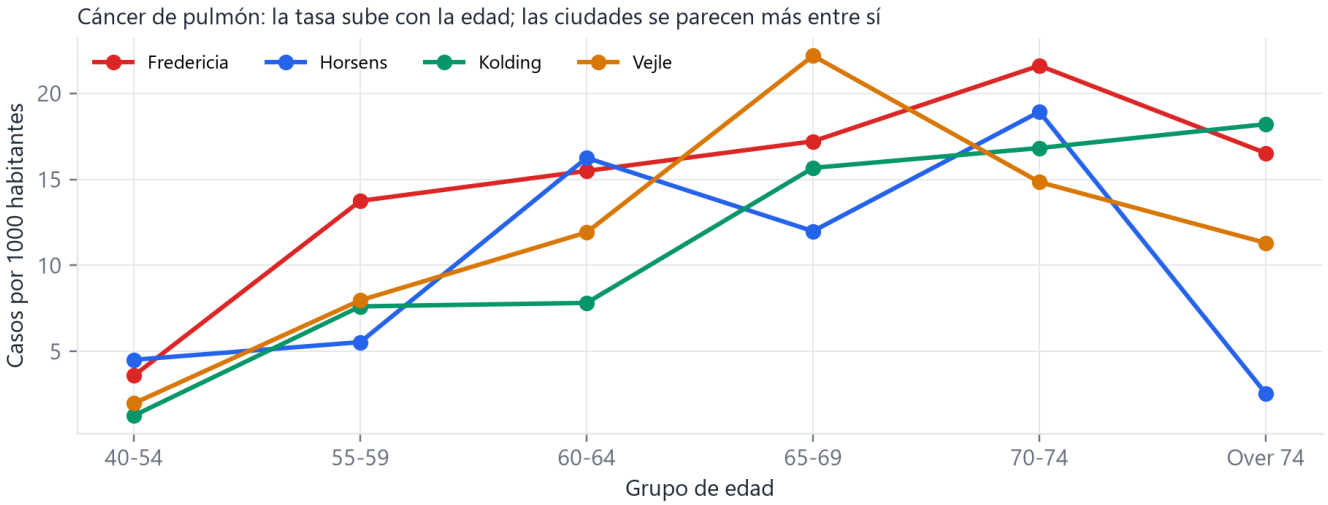
Clase 21 · Regresión de Poisson (conteos y tasas)

Fuente: transcripción de la clase + notebook R

Para conteos se modela el logaritmo de la media. Con un offset se modela una TASA (casos por persona), y e^{β} se lee como razón de tasas (RR).

Conceptos clave

1. **Conteos.** Y = 0, 1, 2, … sin tope. En la Poisson, media = varianza = λ. Enlace log: log(μ) = η.
2. **Offset.** Ciudades con más población tienen más casos aunque el riesgo sea igual. log(población) entra al modelo con coeficiente fijo 1 y convierte el conteo en tasa.
3. **Razón de tasas.** e^{β}: Kolding RR = 0.69 → su tasa es 31% menor que la de Fredericia (referencia). Edad 70–74: RR = 6.4 → tasa 6.4 veces la de 40–54.
4. **Sobredispersión.** φ = X^2 de Pearson / gl = 22.56 / 15 = 1.50. Si φ ≈ 1, la Poisson va bien; si φ > 1, los errores estándar están subestimados.
5. **Quasi-Poisson.** Mismos coeficientes, errores estándar inflados por √φ. En clase, Kolding deja de ser significativa al 5%.



Tasas reales por 1000 habitantes. El patrón de edad es claro; las diferencias entre ciudades son ruidosas y se cruzan. Por eso «ciudad» deja de ser significativa al controlar por edad.

Fórmulas

$$\log(\mu) = \log(\text{población}) + \beta_0 + \beta_1 x$$

$$\text{tasa} = \mu / \text{población} = e^{\beta 0 + \beta 1 x}$$

$$RR = e^{\beta}$$

$$\varphi = X^2_{\text{Pearson}} / (n - p)$$

Cómo leer la salida

- Deviance 129.9 (nulo) → 23.4 (con edad y ciudad), gl = 15
- Edad aporta mucho: Δdeviance = 101.6, p ≈ 0
- Ciudad no aporta una vez incluida la edad: Δdeviance = 4.86, p = 0.18
- φ = 1.50 → sobredispersión leve

Cuidado
Sin offset estarías comparando conteos, no riesgos: una ciudad grande «parecería» más peligrosa solo por tener más gente.

En Python

```
smf.glm('casos ~ C(ciudad) + C(edad)', c,
    family=sm.families.Poisson(),
    offset=np.log(c.poblacion)).fit()
m.pearson_chi2 / m.df_resid # ϕ
.fit(scale='X2') # quasi-Poisson
```

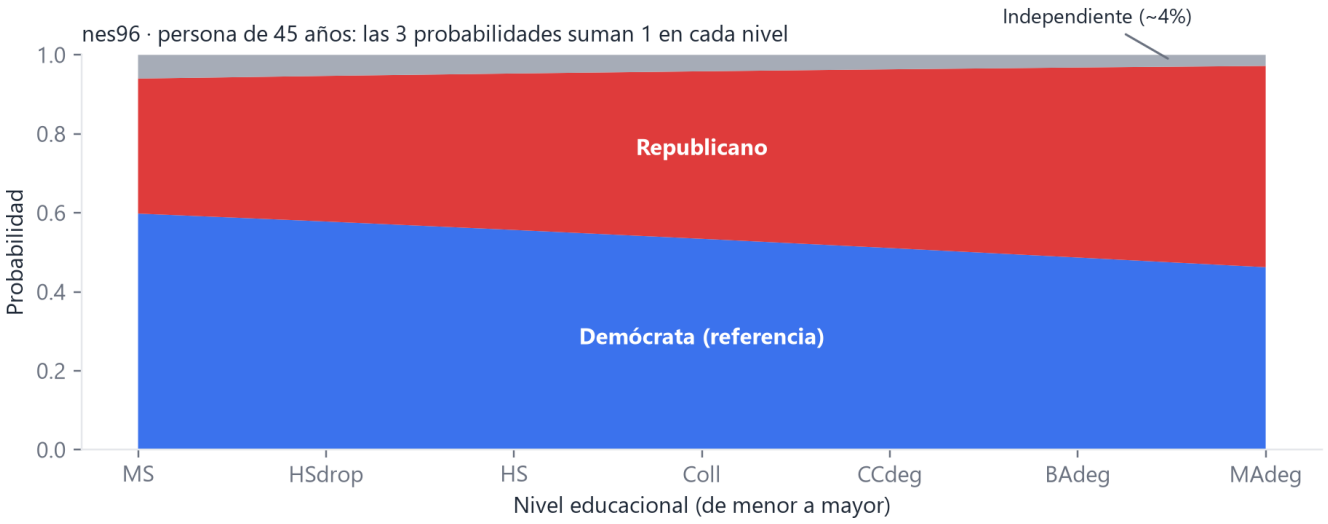
Clase 21 · Regresión multinomial (3+ categorías)

Fuente: transcripción de la clase + notebook R

Con J categorías se elige una de referencia y se ajustan J − 1 ecuaciones logit, una por cada categoría contra la referencia. Las probabilidades resultantes suman 1.

Conceptos clave

1. **Categoría de referencia.** En clase: Demócrata. Cada ecuación compara Republicano vs Demócrata e Independiente vs Demócrata.
2. **Coeficientes.** e^{β} es una razón de riesgos relativos: cuánto se multiplica P(categoría)/P(referencia) por unidad de x.
3. **Probabilidades.** $P(j) = e^{\eta j} / (1 + \Sigma\, e^{\eta k})$, con $\eta = 0$ para la referencia. Siempre suman 1.
4. **La clase minoritaria.** Independiente es el 4% de los datos: el modelo nunca la elige como clase más probable. Exactitud 57.6%.
5. **Nominal vs ordinal.** Nominal: sin orden (partido político). Ordinal: con orden (malo/regular/bueno) → logit acumulativo. R usa contrastes polinomiales en factores ordenados: la profesora los cambia a contr.treatment.



Modelo simplificado edad + educación (numérica) con los datos reales de nes96, para una persona de 45 años. Con más educación sube la probabilidad de ser Republicano.

Fórmulas

$\log(P(j) / P(\text{ref})) = \alpha_j + \beta_j x,\ j = 1 \dots J-1$

$P(j) = e^{\eta j} / (1 + \Sigma_k\, e^{\eta k})$

Logit acumulativo: $\text{logit}\, P(Y \le j) = \alpha_j - \beta x$

En Python

```
n['y'] = n.PID3.map({'Democrat': 0,
    'Republican': 1, 'Independent': 2})
m = smf.mnlogit('y ~ age + educ_num', n).fit()
np.exp(m.params) # razones de riesgo
m.predict(nuevos) # 3 probabilidades
```

Cómo leer la salida

- Modelo de clase (edad + educ + ingreso): deviance 1458.5, AIC 1582.5
- vs nulo: LR = 105.8 con 60 gl, p = 0.0002 → el modelo aporta
- 1er individuo: D 0.69 · R 0.24 · I 0.07
- Exactitud 57.6%; Independiente nunca predicho

Cuidado
Una exactitud de 57.6% suena baja, pero el modelo nulo (decir siempre «Demócrata») acierta 51.7%. Compara siempre contra esa base.

Traductor R → Python y decisión de modelo

Para leer los notebooks de clase y practicar en Python

En la clase (R)	En Python (statsmodels / sklearn)
glm(y ~ x, family = binomial)	smf.glm('y ~ x', d, family=sm.families.Binomial()).fit() · smf.logit(...)
binomial(link = 'probit')	sm.families.Binomial(link=sm.families.links.Probit())
glm(..., family = poisson) + offset(log(pob))	smf.glm(..., family=sm.families.Poisson(), offset=np.log(d.pob))
family = quasipoisson	.fit(scale='X2')
multinom(y ~ x) (nnet)	smf.mnlogit('y ~ x', d).fit() (y codificada 0, 1, 2; 0 = referencia)
exp(coef(m)) · confint(m)	np.exp(m.params) · np.exp(m.conf_int())
anova(m1, m2, test = 'Chisq')	LR = m1.deviance − m2.deviance; stats.chi2.sf(LR, gl)
predict(m, type = 'response')	m.predict(nuevos)
pROC::roc · caret::confusionMatrix	sklearn.metrics: roc_curve, roc_auc_score, confusion_matrix

¿Qué modelo uso?

Variable respuesta Y	Ejemplo	Distribución	Enlace	Se interpreta con
Continua	peso, salario	Normal	identidad	β (unidades de Y)
Binaria (sí/no)	¿compra?, ¿enferma?	Binomial	logit	OR = e^{β}
Conteo	n° de reclamos, casos	Poisson	log	RR = e^{β}
Conteo con exposición	casos por habitante	Poisson + offset	log	razón de tasas e^{β}
3+ categorías sin orden	partido, transporte	Multinomial	logit generalizado	e^{β} vs referencia
3+ categorías con orden	malo/regular/bueno	Multinomial ordinal	logit acumulativo	OR acumulado

Alertas del material, repaso y criterio de dominio

Lo que hay que corregir, lo que debes saber responder y cuándo pasar a la Clase 22

Alertas del material

Error en la interpretación del odds ratio (Clase21_R.Logistica, sección de resumen de los odds)
El texto calcula bien $OR_{10} = e^{10 \cdot 0.02322} = 1.2614$, pero en la frase siguiente dice que eso significa «odds 1.35 veces más… aproximadamente un 35% mayores».
Correcto: 1.2614 significa odds **1.26 veces**, es decir, **26% mayores**. El «35%» parece un residuo de una versión anterior del ejemplo. La tabla que viene justo después sí muestra el valor correcto.

Otras observaciones

- La descripción de wcgs llama «sbp» a la presión sistólica, pero en los datos la columna se llama **sdp**.
- La deviance se explica de forma intuitiva («falta de ajuste»). Su definición formal es $D = -2 \cdot (\log L_{modelo} - \log L_{saturado})$, y por eso las diferencias de deviance siguen una χ^2.
- El p-valor se usa sin definirlo. Repasa la sesión 0.5 y la alerta de la Clase 17.
- El ejemplo de exactitud 93% con sensibilidad 0% no es un error: es una excelente lección. Recuérdalo.

Preguntas de repaso (intenta responder antes de leer)

#	Pregunta	Respuesta corta
1	¿Por qué no usar regresión lineal para una Y de sí/no?	Predice valores fuera de [0, 1] y la varianza de una proporción no es constante.
2	¿Qué decide la distribución de un GLM, y qué decide el enlace?	La distribución, el tipo de Y. El enlace se elige entre los compatibles con esa distribución.
3	$\beta = 0.0232$ en una logística. ¿Qué significa $e^{\beta} = 1.0235$?	Cada unidad extra de x multiplica las odds por 1.0235, es decir, +2.35%.
4	Un modelo tiene exactitud 93%. ¿Es bueno?	Depende: si el 92% es de una clase, decir siempre «no» ya da 92%. Mira sensibilidad, especificidad y AUC.
5	¿Para qué sirve el offset en una Poisson?	Para modelar tasas: ajusta por la exposición (población, tiempo) y así se comparan riesgos, no conteos.
6	$\varphi = 1.5$ en una Poisson. ¿Qué haces?	Hay sobredispersión: usa quasi-Poisson (o binomial negativa) para corregir los errores estándar.

Criterio de dominio para pasar a la Clase 22

- ☐ Elijo distribución y enlace para cualquier tipo de Y
- ☐ Convierto a mano entre probabilidad, odds y logit
- ☐ Interpreto un OR y un RR en una frase, con %
- ☐ Calculo sensibilidad y especificidad desde una matriz de confusión
- ☐ Ajusto en Python una logística, una Poisson con offset y una multinomial
- ☐ Resuelvo los bloques 1 a 6 del cuaderno con al menos 80% de aciertos