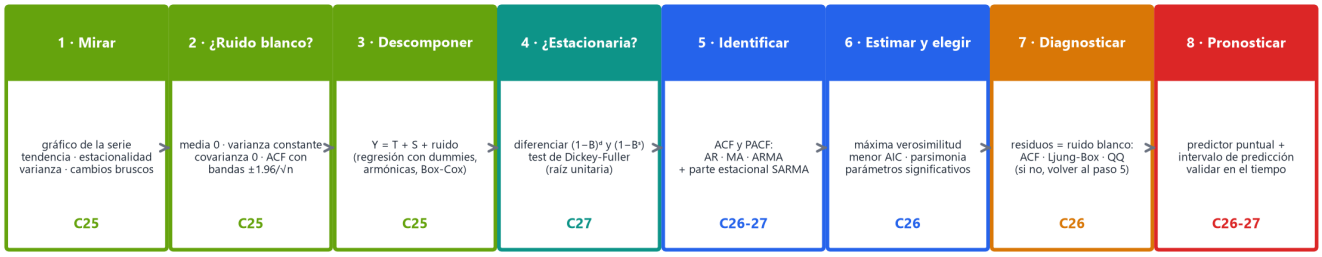
Clases 25-27 · Modelos predictivos de series de tiempo: de la descomposición a ARIMA y SARIMA

Prof. Cristian Vásquez (PUC) · puentes con regresión (C17–21), validación (C30, C38) y bootstrap (C43)

La gran idea de las tres clases

En una serie de tiempo los datos **no son independientes**: lo de hoy se parece a lo de ayer. El trabajo consiste en separar lo que se puede explicar (tendencia, estacionalidad) de lo que queda, y en **modelar esa dependencia** con modelos **AR, MA y ARMA** (Box-Jenkins) para series **estacionarias**. Se identifican con la **ACF y la PACF**, se eligen por **AIC** y parsimonia y se aceptan solo si los **residuos son ruido blanco** (Ljung-Box). Si la serie tiene tendencia estocástica se **diferencia** (ARIMA) tras un test de **Dickey-Fuller**; si tiene ciclos regulares se agrega una **parte estacional** (SARMA/SARIMA). Un pronóstico se entrega con su **intervalo de predicción** y se valida **respetando el orden del tiempo**.

Las tres clases en una imagen



Box-Jenkins es un ciclo: identificar → estimar → diagnosticar (y volver si los residuos no son ruido blanco).

Datos: IPC, IPSA, PM2.5, desocupación, pasajeros, anillos de árbol, accidentes (EE. UU.), CityBike, IAC

Qué material es de cuál clase

Clase	Fecha / tema	Material
C25	Introducción: ruido blanco, ACF, descomposición, regresión con dummies, armónicas, Box-Cox	Presentación «Clase 1» (portada dice «Clase 25») + «Código Clase 1» (R)
C26	Estacionarias: AR, MA, ARMA, ACF/PACF, estimación, AIC, Ljung-Box, pronóstico	Presentación «Clase 2» (portada repite «Clase 25») + «Código Clase 2» (R)
—	Sesión de repaso del sábado (caminatas aleatorias): sin transcripción ni archivos	no incluida en la carpeta (no existe «Clase 3»)
C27	SARMA, ARIMA, raíz unitaria (Dickey-Fuller), retornos	Presentación «Clase 4» (portada dice «Clase 27»); su cuaderno en R no se entregó
C28	Cierre del módulo: CityBike con ARIMA, SARIMA y SARIMAX (Python)	`DS26_28_Cierre_de_Módulo.ipynb` (sin transcripción)

Lo que necesitas ANTES y los datos

- **Regresión lineal y dummies** (C17–19): la descomposición de la Clase 25 es una regresión; aquí el error **no** es independiente
- **Probabilidad básica**: varianza, covarianza, correlación, normal y chi-cuadrado
- **AIC** y comparación de modelos (C20–21), **validación** (C30, C38) y **bootstrap** (C43)
- **Datos**: pasajeros EE. UU. (117 meses desde 2010), anillos de un árbol de Idaho (493 años), IPC, IPSA, PM2.5, desocupación, accidentes EE. UU. (72 meses), CityBike (546 días) e IAC (120 meses). Copias en `Guias/datos/series_tiempo/`

Puentes con otras clases (sin repetirlas)
C17–21 → C25: el ajuste con tendencia y dummies mensuales es una regresión lineal (R^2 ajustado 0.978), pero sus residuos tienen Durbin-Watson 0.93 y ACF(1) = 0.50: el error estándar de la tendencia pasa de 1 234 (OLS) a 2 110 (robusto), ×1.71. **C30 y C38 → C26–27**: en series la validación **es temporal** (corte o origen móvil), nunca al azar; en los pasajeros el SARIMA tiene MAE 0.34 frente a 1.27 del ingenuo estacional. **C43 → C26**: el intervalo de predicción del modelo para h = 10 mide 1.091 de ancho y el de un bootstrap de residuos, 1.072: dos caminos para la misma incertidumbre.

Clases 25-27 · Qué es una serie de tiempo, ruido blanco y ACF (C25)

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

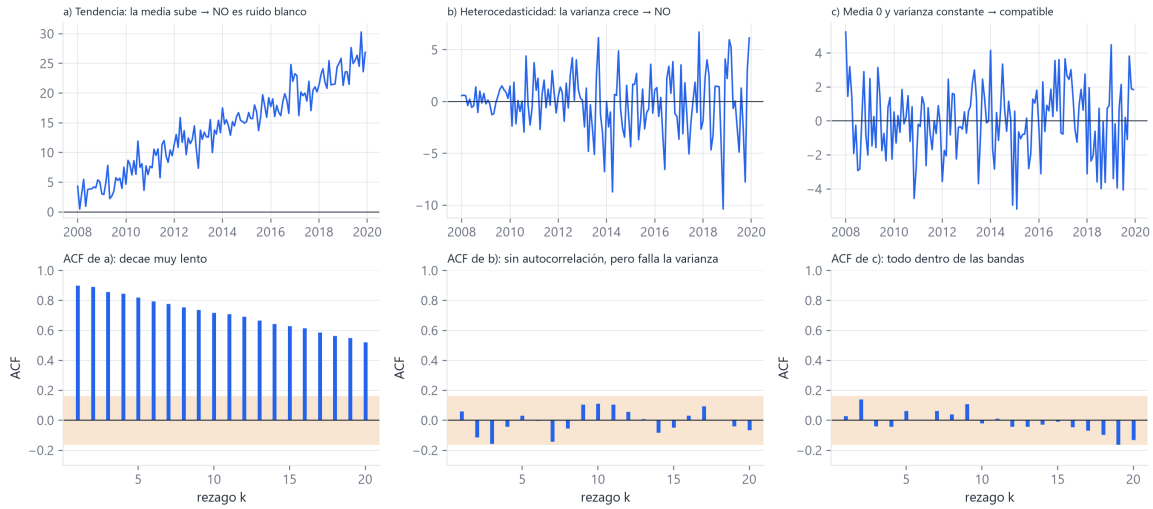
Una serie de tiempo es una secuencia de variables aleatorias $\{Y_t\}$ indexada por tiempos equidistantes. Al perder la independencia aparece la autocorrelación. El ruido blanco (media 0, varianza constante, covarianza 0) es el modelo de «lo que no se puede predecir».

Conceptos clave

1. **Objetivos.** Describir, pronosticar, retro-predecir e imputar datos faltantes. Aplica a IPC, IPSA, contaminación o desempleo; si los tiempos no son equidistantes hacen falta otras técnicas.

2. **Ruido blanco ≠ independencia.** Ruido blanco pide $E(\varepsilon_t) = 0$, $Var(\varepsilon_t) = \sigma^2$ y $Cov(\varepsilon_t, \varepsilon_s) = 0$. Independencia implica covarianza 0, no al revés: ruido blanco es más débil. Tendencia o varianza creciente lo descartan a simple vista.

3. **ACF y bandas.** $\rho(k) = Cov(Y_t, Y_{t+k})/Var(Y_t)$ está entre −1 y 1 (no depende de la escala). La estimada usa una media global; las bandas $\pm 1.96/\sqrt{n}$ marcan qué es significativo a ≈ 5 %. En k = 0 vale 1 siempre.



Tres series simuladas de n = 144: la que tiene tendencia (ACF(1) = 0.90) y la de varianza creciente no son ruido blanco; la tercera sí: 0 de 20 autocorrelaciones fuera de las bandas (±0.163).

Fórmulas y reglas

$Y_t \sim$ ruido blanco: $E = 0$, $Var = \sigma^2$, $Cov(\varepsilon_t, \varepsilon_s) = 0$

$r(k) = \Sigma_t (Y_t - \bar{Y})(Y_{t+k} - \bar{Y}) / \Sigma_t (Y_t - \bar{Y})^2$

bandas: $\pm 1.96/\sqrt{n}$

```
acf_manual(y, 20) # igual a acf() de R
from statsmodels.graphics.tsaplots import
plot_acf
```

Con los números de la clase

- Con n = 144 la banda es ±0.163; con 20 rezagos se esperan ≈ 1 fuera por azar (5 %)
- Estacionaria: media constante, varianza constante y $Cov(Y_t, Y_{t+k}) = \gamma(k)$ solo depende de k
- «Covarianza 0 no implica independencia; independencia sí implica covarianza 0»
- **Cuidado.** El código en R del IPC lee `ipc_var.txt` (tabla 12 × 22: meses × años) **por filas**, mezclando años y meses; leída por columnas la ACF(1) es 0.62 y no 0.53.

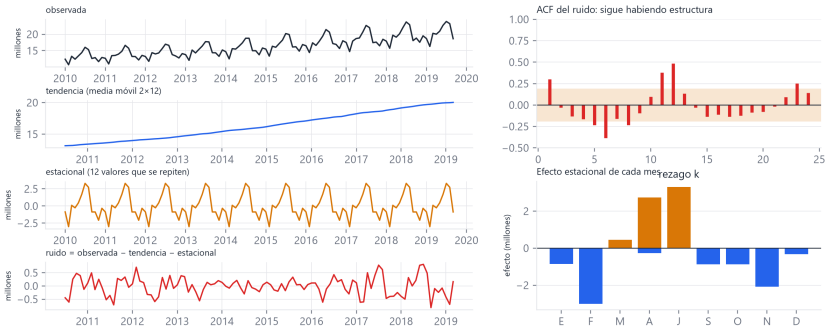
Clases 25-27 · Descomposición, regresión con dummies, armónicas y Box-Cox (C25)

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

La primera aproximación es aditiva: $Y_t = T_t + S_t + C_t + \varepsilon_t$. Tendencia y estacionalidad se estiman con funciones deterministas (polinomio, dummies); si lo que queda es ruido blanco, no hay más que hacer. Casi nunca lo es.

Conceptos clave

1. **Descomposición clásica.** decompose() usa una media móvil centrada para la tendencia (se pierden s/2 datos en cada extremo), promedia por mes para la estacionalidad y deja el ruido = observada − tendencia − estacional.
2. **Regresión lineal con dummies.** $Y_t = \beta_0 + \beta_1 t + \Sigma_j \alpha_j \cdot d_{jt} + \varepsilon_t$ con un mes como referencia (si hay 12 dummies y constante, el modelo no se identifica). Estacional («saltos» en meses puntuales) se captura con dummies; ciclos suaves con senos y cosenos.
3. **Estabilizar la varianza.** La transformación de Box-Cox (Y^α − 1)/α, o log si α = 0, se usa cuando la dispersión crece con el nivel. No quita tendencia ni estacionalidad.



Pasajeros internacionales, 2010-01 a 2019-09 (n = 117). El mes de mayor efecto es el 7 (julio, 3.30 millones) y el menor -3.02 millones. Se pierden 12 valores de tendencia (6 por lado).

Fórmulas y reglas

$Y_t = T_t + S_t + C_t + \varepsilon_t$ (aditivo); $Y_t = T_t \cdot S_t \cdot \varepsilon_t$ (multiplicativo)

$S_t = \Sigma_{j=2}^{R} \alpha_j \cdot d_{jt}$, $T_t = \beta_0 + \beta_1 t + \ldots + \beta_m t^m$

$C_t = \Sigma_j [\alpha_j \operatorname{sen}(\omega_j t) + \beta_j \cos(\omega_j t)]$

$X_t = (Y_t^{\alpha} - 1)/\alpha$ si $\alpha \neq 0$; $\log Y_t$ si $\alpha = 0$

```
descomponer_aditiva(y, 12)
sm.OLS.from_formula('y ~ t + C(mes)', df).fit()
stats.boxcox_normmax(y, method='mle')
```

Con los números de la clase

- 10 de 12 coeficientes son significativos; no lo son octubre (p = 0.58) ni septiembre (p = 0.35)
- Con el corte temporal (entrenar sin los últimos 12 meses) el MAE de ese mismo modelo es 427 773 pasajeros (2.1 %)
- Ciclo ≠ estacionalidad: la estacionalidad tiene un periodo fijo (12 meses) y se capta con dummies; el ciclo es sinusoidal y se capta con armónicas
- **Cuidado.** La regresión de la diapositiva 31 se llama «regresión lineal simple» pero tiene 12 regresores: es **múltiple**. Y un R^2 de 0.978 no demuestra que el modelo sea adecuado: los residuos siguen correlacionados.

Clases 25-27 · Modelos AR, MA y ARMA: identificación con ACF y PACF (C26)

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

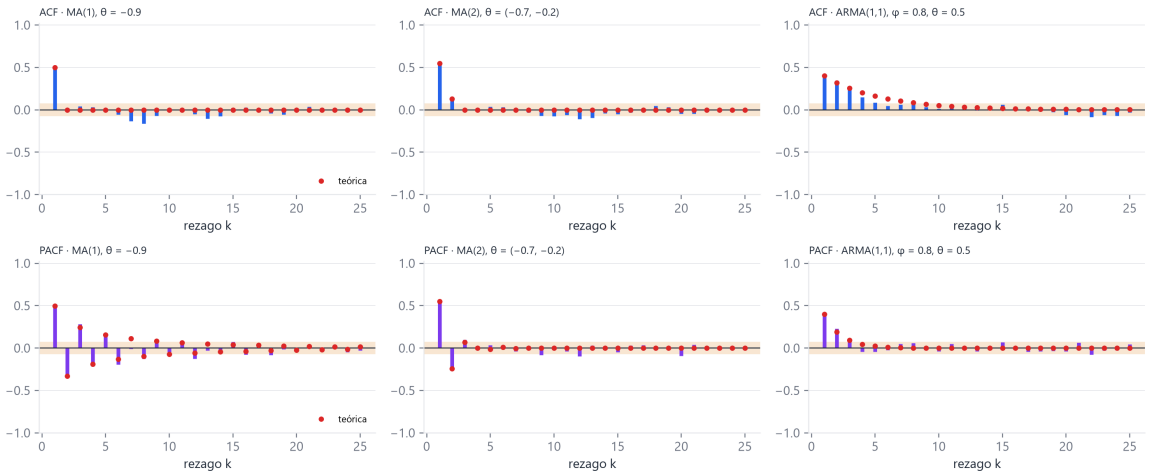
Los modelos de Box y Jenkins aproximan cualquier fenómeno estacionario de memoria corta. AR(p): Y_t depende de sus p rezagos; MA(q): Y_t es una suma ponderada de q choques; ARMA(p, q) combina ambos y necesita menos parámetros.

Conceptos clave

1. **Qué dibuja cada modelo.** AR: ACF decae ($\rho(k) = \varphi^k$ en AR(1)) y PACF se corta en p. MA: ACF se corta en q y PACF decae. ARMA: las dos decaen. La PACF mide la correlación entre Y_t y Y_{t+k} quitando el efecto de los rezagos intermedios.

2. **Estacionariedad e invertibilidad.** AR(1): $|\varphi| < 1$; AR(2): $\varphi_2 + \varphi_1 < 1$, $\varphi_2 - \varphi_1 < 1$ y $|\varphi_2| < 1$. Un MA siempre es estacionario; se exige $|\theta| < 1$ (invertibilidad) para poder escribirlo como AR y pronosticar.

3. **Signos.** Las diapositivas escriben $Y_t = \varepsilon_t - \theta\varepsilon_{t-1}$. R (arima.sim, arima) y statsmodels usan $+ \theta\varepsilon_{t-1}$: un «ma = +0.9» de R es $\theta = -0.9$ en las diapositivas. Hay que fijarse en la convención antes de comparar números.



MA(1) con $\theta = -0.9$: $\rho(1) = -\theta/(1 + \theta^2) = 0.497$, y después 0; la PACF oscila y decae. En el ARMA(1,1) ambas decaen y el orden no se lee a simple vista.

Fórmulas y reglas

AR(p): $Y_t = \mu + \varphi_1 Y_{t-1} + \ldots + \varphi_p Y_{t-p} + \varepsilon_t$

MA(q): $Y_t = \mu + \varepsilon_t - \theta_1\varepsilon_{t-1} - \ldots - \theta_q\varepsilon_{t-}_q$

AR(1): $\rho(k) = \varphi^k$; AR(2): $\rho(1) = \varphi_1/(1 - \varphi_2)$

MA(1): $\rho(1) = -\theta/(1 + \theta^2)$, $\rho(k) = 0$ si $k \geq 2$

```
from statsmodels.tsa.arima_process import
ArmaProcess
simular_arma([0.8], [], 500, rng) # AR(1)
pacf_yw(y, 25)
```

Con los números de la clase

- Con $\varphi = 0.8$: $\rho = 0.80, 0.64, 0.51, 0.41, 0.33$ (decae geométricamente)
- MA(2) con $\theta = (-0.7, -0.2)$: ACF teórica 0.55 y 0.13, luego 0
- Los MA siempre son estacionarios; los AR no: $\varphi = 1.5$ deja de serlo
- **Cuidado.** Un ARMA no se identifica «mirando»: ACF y PACF solo **sugieren** candidatos. Con series reales los patrones son difusos (ver el árbol de la página siguiente).

Clases 25-27 · Estimar, elegir por AIC y diagnosticar (C26)

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

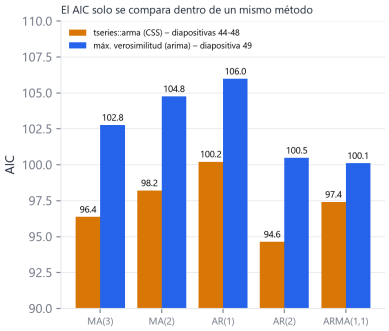
Con la serie de anillos de árbol se ajustan cinco candidatos, se comparan por AIC (menor mejor, castigando parámetros) y se comprueba que los residuos sean ruido blanco. Si no lo son, el modelo no sirve aunque su AIC sea bajo.

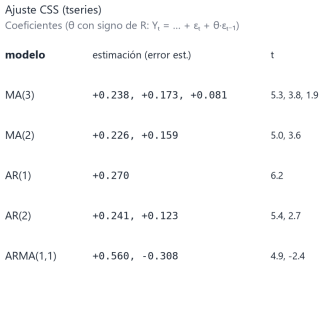
Conceptos clave

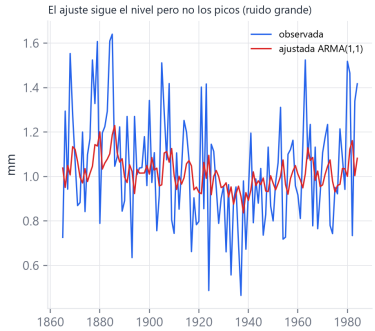
1. **Estimación.** Máxima verosimilitud con la normal multivariada (la matriz de covarianzas se construye con γ), mínimos cuadrados condicionales (tseries::arma), Yule-Walker (solo AR), Whittle o espacio de estados. Dan valores parecidos pero reportan cosas distintas.

2. **AIC y significancia.** AIC = −2 log L + 2k. Solo se comparan AIC calculados con el mismo método y los mismos datos. Además se exige que cada parámetro sea significativo; un modelo con un coeficiente borderline (MA(3): p = 0.058) pierde frente a uno parsimonioso.

3. **Diagnóstico de residuos.** Residuos estandarizados sin patrón, ACF dentro de las bandas, test de Ljung-Box (H_0: $\rho_1 = \ldots = \rho_m = 0$) con valor p > 0.05 en varios m, y normalidad aproximada (histograma, QQ-plot) para fiarse de los intervalos.







Replicamos las diapositivas: con tseries::arma el menor AIC es el AR(2) (94.64); con máxima verosimilitud es el ARMA(1,1) (100.11); por BIC también el ARMA(1,1).

Fórmulas y reglas

AIC = −2 log L + 2k; BIC = −2 log L + k log n

$Q(m) = n(n+2)\,\Sigma_r \hat{r}_r^2/(n-r) \sim \chi^2(m-p-q)$

$ARMA(1,1)$: $Y_t - \mu = \varphi(Y_{t-1} - \mu) + \varepsilon_t - \theta\varepsilon_{t-1}$

```
m = ARIMA(y, order=(1, 0, 1)).fit(); m.aic
arma_css(y, 1, 1) # réplica de tseries::arma
ljung_box(m.resid, 10, ddof=2)
```

Con los números de la clase

- MA(3) por CSS: ma = 0.238, 0.173, 0.081; AIC 96.37 y σ^2 = 0.0700 (la diapositiva: 0.23819, 0.17289, 0.08113; 96.37)
- ARMA(1,1) por CSS: φ = 0.5602, θ = -0.3082; por MLE: φ = 0.6519, ma = -0.4149
- Tabla de la diapositiva 49 (arima): 102.77, 104.77, 105.98, 100.48, 100.11 — coincide con nuestros 102.77, 104.77, 105.98, 100.48, 100.11
- **Cuidado.** Comparar 94.64 (tseries, AR(2)) con 100.11 (arima, ARMA(1,1)) no tiene sentido: son AIC de métodos distintos. La diapositiva 49 (arima) y las 44–48 (tseries) dan «ganadores» distintos.

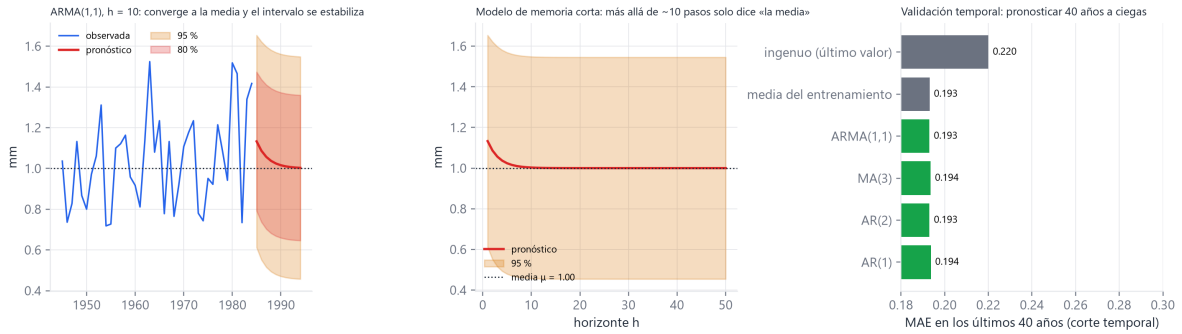
Clases 25-27 · Pronóstico, intervalos de predicción y validación temporal (C26–27)

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

El mejor predictor a h pasos es la esperanza condicional $E[Y_{n+h} \mid Y_1, \ldots, Y_n]$. En un ARMA estacionario converge a la media cuando h crece (memoria corta). Debe entregarse con un intervalo de predicción y evaluarse con datos que el modelo no vio, respetando el tiempo.

Conceptos clave

1. **Pronóstico y su intervalo.** Un AR(1) predice $\mu + \varphi^h(y_n - \mu)$ con varianza $\sigma^2(1 - \varphi^{2h})/(1 - \varphi^2)$: el intervalo se ensancha y se estabiliza en el de la serie. Aquí se llamó «intervalo de confianza» al de predicción: la diferencia importa (es sobre un valor futuro, no sobre un parámetro).
2. **Partición temporal.** Entrenar con el pasado y probar con el futuro: corte único (últimos h) u **origen móvil** (varios cortes). Separar al azar filtra información del futuro hacia el entrenamiento y entrega errores optimistas. Es el mismo principio de C30 y C38.
3. **Comparar con referencias simples.** Un modelo útil debe ganarle al **ingenuo** (último valor) y al **ingenuo estacional** (valor de hace un año), y a la media si la serie es estacionaria.



ARMA(1,1) del árbol: pronóstico a 1 año 1.133 con IC 95 % [0.612; 1.653] (la diapositiva 60: 1.1328, 0.6122 y 1.6534). A 10 años: 1.003; el ancho pasa de 1.04 a 1.09, casi 2·1.96·sd de la serie (1.09).

Fórmulas y reglas

$\hat{y}_{n+h} = E[y_{n+h} \mid y_n, y_{n-1}, \ldots]$

AR(1): $\hat{y}_{n+h} = \mu + \varphi^h(y_n - \mu)$; $\text{Var} = \sigma^2(1 - \varphi^{2h})/(1 - \varphi^2)$

IC 95 % de predicción: $\hat{y}_{n+h} \pm 1.96 \cdot \sqrt{\text{Var del error}}$

MAE = media $|y - \hat{y}|$; RMSE = $\sqrt{\text{media}\ (y - \hat{y})^2}$

```
fc = m.get_forecast(10); fc.conf_int(alpha=0.05)
train, test = particion_temporal(y, 24)
ingenuo(train, 24, 12)
```

Con los números de la clase

- Árbol, validación a ciegas de 40 años: MAE 0.1930 (ARMA(1,1)), 0.1931 (la media) y 0.220 (ingenuo): con ACF(1) = 0.27 el ARMA casi no supera a la media
- Con un solo corte de 12 meses el SARIMA acertó el intervalo del mes 12: [16.88; 20.03] y real 18.05
- Un pronóstico a muchos pasos de un ARMA es «la media»: no sirve para mirar el largo plazo
- **Cuidado.** El cuaderno de CityBike (C28) alimenta el pronóstico con la temperatura **real** del periodo de prueba (SARIMAX): es un pronóstico condicionado, no de un futuro desconocido.

Clases 25-27 · Modelos estacionales SARMA (C27)

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

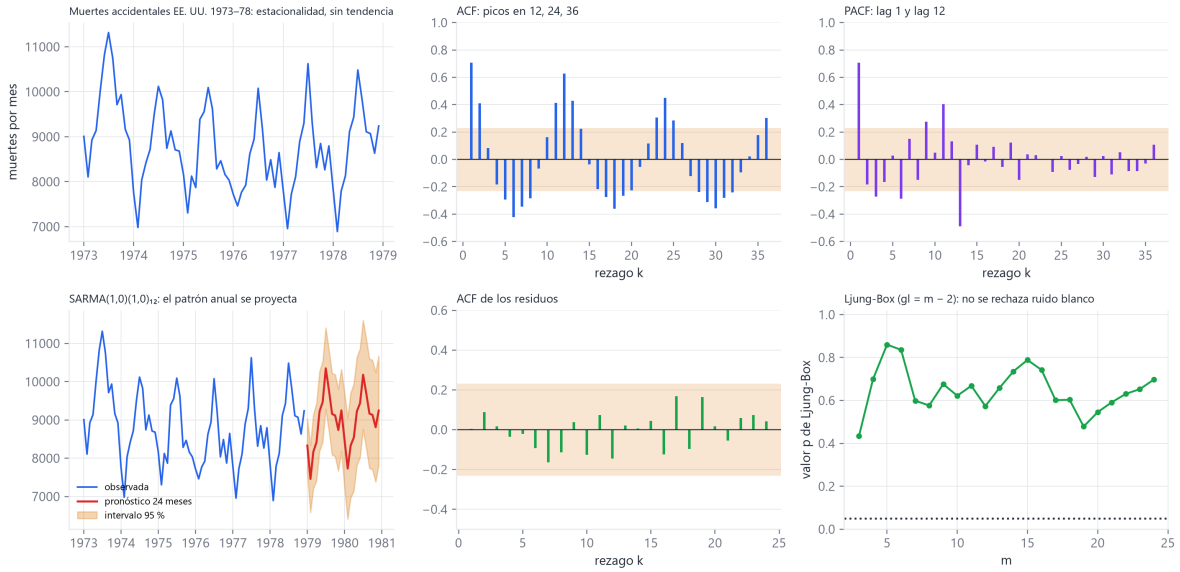
Si la serie es mensual, hoy se parece también a hace 12, 24 y 36 meses. En vez de un ARMA con 36 coeficientes se añaden polinomios en B^s: SARMA(p, q)(P, Q)$_s$. La ACF muestra picos en los múltiplos de s.

Conceptos clave

1. **Operador de rezago B.** $B \cdot Y_t = Y_{t-1}$, $B^j \cdot Y_t = Y_{t-j}$, $\Delta = 1 - B$ (diferencia) y los polinomios en B se multiplican como polinomios comunes. Con él un ARMA se escribe $\varphi(B)(Y_t - \mu) = \theta(B)\varepsilon_t$.

2. **Modelo estacional.** $\varphi(B)\cdot\Phi(B^s)(Y_t - \mu) = \theta(B)\cdot\Theta(B^s)\varepsilon_t$. Un AR estacional de orden 1 con s = 12, $Y_t = \Phi Y_{t-12} + \varepsilon_t$, tiene $\rho(12j) = \Phi^j$ y cero en el resto. P y Q rara vez superan 3 o 4; p y q, 5 o 6.

3. **Buscar el orden.** A mano es difícil: se prueba una rejilla y se elige el menor AIC (auto.arima en R). Los máximos de p y q deben ser menores que s para que no compitan con la parte estacional.



Muertes accidentales en EE. UU. (n = 72): SARMA(1,0)(1,0)$_{12}$ con $\varphi = 0.7573$, $\Phi = 0.8503$, media 9 215.5 y AIC 1075.08 (diapositiva 15: 0.7579, 0.8501, 9214.7102, 1074.89). Ljung-Box p = 0.57 (m = 12).

Fórmulas y reglas

$\varphi(B)\Phi(B^s)(Y_t - \mu) = \theta(B)\Theta(B^s)\varepsilon_t$

$\varphi(B) = 1 - \varphi_1 B - \ldots - \varphi_p B^p$; $\Phi(B^s) = 1 - \Phi_1 B^s - \ldots$

$AR(1)_s$: $\rho(k) = \Phi^{\wedge}(k/s)$ si k es múltiplo de s; 0 en otro caso

```
ARIMA(y, order=(1, 0, 0), seasonal_order=(1, 0, 0, 12))
# rejilla p, q ≤ 2; P, Q ≤ 1 y menor AIC
```

Con los números de la clase

- Rejilla de 36 modelos: menor AIC es SARMA(2, 2)x(1, 1) con 1069.47; el sencillo AR(1)xAR(1) está a ≈ 5.6 puntos (AIC similares: se prefiere el parsimonioso)
- Pronóstico a 24 meses: primer mes 8 331 (IC 7 631–9 031); el máximo es en julio, como en los datos
- Con 12 meses de prueba: MAE 285 (SARMA), 254 (ingenuo estacional) y 786 (la media)
- **Cuidado.** La función de R usa σ^2 con otra convención (132 733 frente a nuestro 127 513); log-verosimilitud y AIC coinciden. El optimizador por defecto de statsmodels se detiene antes en la media (por eso se pule con Nelder-Mead).

Clases 25-27 · Series no estacionarias: diferenciación, ARIMA y Dickey-Fuller (C27)

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

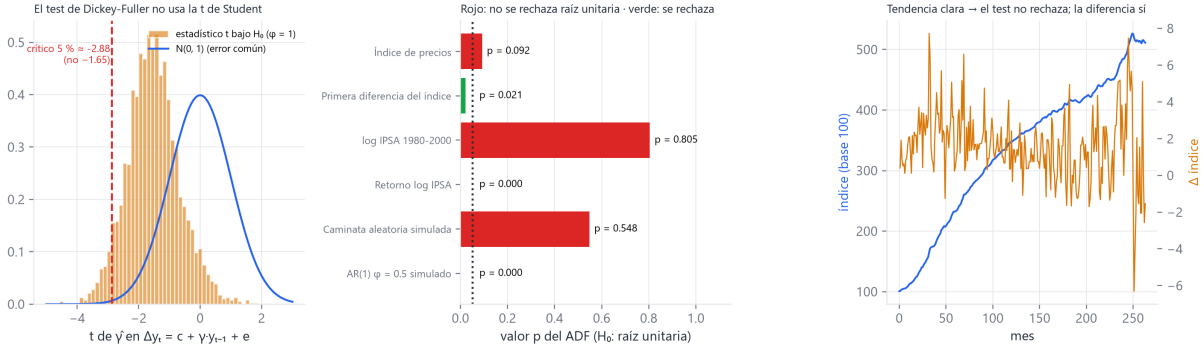
Casi ninguna serie real es estacionaria. Con tendencia estocástica (caminata aleatoria) o determinística, una diferencia $\Delta Y_t = Y_t - Y_{t-1}$ deja una serie estacionaria; un ARIMA(p, d, q) es un ARMA sobre la serie diferenciada d veces. El test de Dickey-Fuller decide si hace falta.

Conceptos clave

1. **Determinística vs estocástica.** Determinística: la serie oscila alrededor de una recta fija (mejor ajustar un polinomio y modelar los errores con ARMA). Estocástica: la tendencia cambia en el tiempo (caminata aleatoria $Y_t = Y_{t-1} + \varepsilon_t$ = ARIMA(0,1,0)).

2. **Cuánto diferenciar.** Casi siempre d = 1; d = 2 en casos extremos. Diferenciar de más aumenta la varianza: para ruido blanco $\text{Var}(\Delta^d\varepsilon) = C(2d, d)\sigma^2$ = 1, 2, 6, 20 σ^2 para d = 0, 1, 2, 3 (en clase se dijo «$3\sigma^2$» para tres veces, y no es así).

3. **Dickey-Fuller.** Regresión $\Delta y_t = c + \gamma \cdot y_{t-1} + \varepsilon$ con H_0: $\gamma = 0$ ($\varphi = 1$, raíz unitaria) frente a H_1: $\gamma < 0$. El estadístico t **no** sigue una t de Student: se compara con valores críticos propios (≈ −2.86 al 5 % con constante). Valor p grande → no se rechaza raíz unitaria → hay que diferenciar.



Simulación: el 5 % crítico del estadístico es -2.88, no −1.65. Índice de precios reconstruido: p = 0.092; log IPSA: p = 0.805; retorno del IPSA: p ≈ 0.

Fórmulas y reglas

$\Delta Y_t = (1 - B)Y_t$; $\Delta^2 Y_t = Y_t - 2Y_{t-1} + Y_{t-2}$

ARIMA(p,d,q): $\varphi(B)(1 - B)^d(Y_t - \mu) = \theta(B)\varepsilon_t$

retorno log: $\log P_t - \log P_{t-1} \approx (P_t - P_{t-1})/P_{t-1}$

DF: $\Delta y_t = c + \gamma y_{t-1} + e$; H_0: $\gamma = 0$

```
adfuller(y, regression='c', autolag='AIC')
adf_regresion(y) # γ^ y su t
ARIMA(y, order=(p, 1, q))
```

Con los números de la clase

- Slide 35 (IPC empalmado, no entregado): p = 0.9599 y 0.9438; con el índice reconstruido: p = 0.092 con rezagos elegidos por AIC
- La regresión DF sin rezagos dio t = -3.59 (p ≈ 0.006): por eso el test **aumentado** agrega rezagos de ΔY; con mucha autocorrelación el DF simple es engañoso
- Caminata simulada: p = 0.55 (no rechaza); AR(1) con φ = 0.5: p ≈ 0 (rechaza)
- **Cuidado.** Las diapositivas 28–29 escriben H_1: $\varphi < 1$ y luego H_1: $\varphi \neq 1$; el DF clásico es unilateral. Y «existe evidencia de presencia de tendencia» (diapositiva 35) debe leerse «no se rechaza la raíz unitaria». La diapositiva 39 divide por P_t en vez de P_{t-1}.

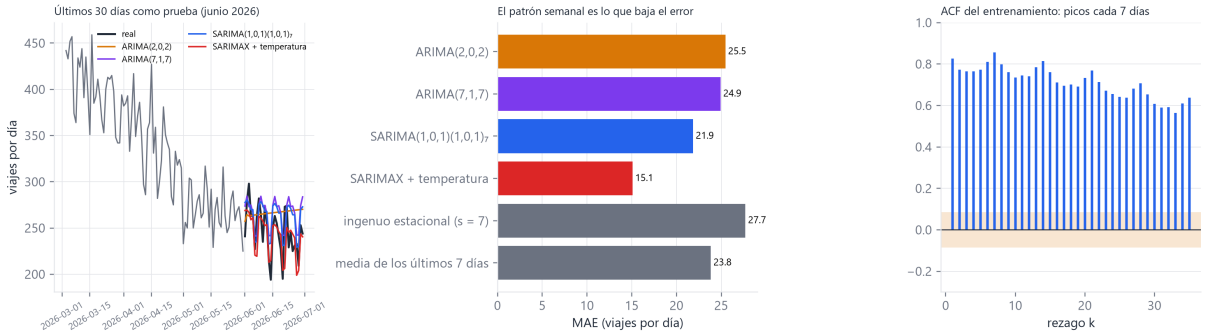
Clases 25-27 · Cierre del módulo (C28): CityBike, ARIMA, SARIMA y SARIMAX en Python

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

El cuaderno de cierre aplica lo visto a una serie diaria de viajes de CityBike. Se separan los últimos 30 días como prueba (sin barajar), se ajusta un ARIMA sencillo, se ve que ignora la semana y se pasa a SARIMA con s = 7 y SARIMAX con una variable exógena.

Conceptos clave

1. **Qué se hizo.** ARIMA(2,0,2) → ARIMA(7,1,7) (usar 7 rezagos «para explicar hoy») → SARIMA$(1,0,1)(1,0,1)_7$ → SARIMAX con la temperatura promedio. Se comparan por MAE en el periodo de prueba.
2. **Qué se aprende.** El patrón recurrente de la serie (semanal) lo capta mejor la parte estacional que 7 rezagos simples; un regresor ayuda si está relacionado con la respuesta.
3. **Qué hay que mirar con cuidado.** Los coeficientes AR del SARIMA salen 0.996 y 0.998: casi raíces unitarias, porque la serie tiene media ≈ 330 y el modelo no tiene intercepto ni diferencia. Y el SARIMAX usa la temperatura **real** de la prueba.



Reproducido con los datos del cuaderno (2025-01-01 a 2026-06-30, 546 días; entrenamiento 516): MAE 25.47, 24.93, 21.85 y 15.08 (el cuaderno: 25.47, 25.15, 21.85 y 15.08; el ARIMA(7,1,7) no converge y varía).

Fórmulas y reglas

SARIMAX: $y_t = \beta \cdot x_t$ + ARMA estacional en los errores

MAE = $(1/h)\ \Sigma\ |y_t - \hat{y}_t|$

error en prueba ≠ AIC del entrenamiento

```
SARIMAX(train, exog=X_train, order=(1,0,1),
seasonal_order=(1,0,1,7))
modelo.forecast(30, exog=X_test)
```

Con los números de la clase

- AIC: 5 110.6 (ARIMA 2,0,2), 4 944.0, 4 928.1 y 4 889.5 (SARIMAX)
- Temperatura y viajes: correlación 0.89; la temperatura baja de 26 a 10 °C mientras los viajes pasan de ≈ 398 a ≈ 247 diarios: es en parte una variable de tendencia
- Referencias simples en la prueba: ingenuo estacional 27.7 y media de 7 días 23.8
- **Cuidado.** El cuaderno carga los datos desde hojas de Google (URL): si el enlace deja de existir no se puede reproducir. Aquí hay una copia local en `citybike_serie_diaria.csv`.

Clases 25-27 · Hoja de referencia, alertas y cierre

Fuente: 3 transcripciones + presentaciones «Clase 1, 2 y 4» + cuadernos en R (Clases 1 y 2) + cuaderno de cierre (Clase 28) · Prof. Cristian Vásquez

Hoja de referencia (cheat sheet)

Pregunta	Herramienta	Cómo se decide
¿Es ruido blanco?	gráfico + ACF + Ljung-Box	sin tendencia, varianza constante y ACF dentro de $\pm 1.96/\sqrt{n}$
¿Tendencia o estacionalidad?	descomposición, regresión con dummies, Δ y Δ_s	residuos sin patrón; en la ACF, picos en múltiplos de s
¿Estacionaria?	Dickey-Fuller aumentado	$p < 0.05$ rechaza raíz unitaria; si no, diferenciar ($d = 1$)
¿Qué orden?	ACF y PACF	AR: PACF corta / MA: ACF corta / ARMA: ambas decaen; rejilla + menor AIC
¿Es bueno el ajuste?	residuos: ACF, Ljung-Box ($gl = m - p - q$), QQ	$p > 0.05$ en varios m; si no, otro modelo
¿Cuál modelo?	AIC/BIC (mismo método), parsimonia, error fuera de muestra	lo que mejor pronostica en **prueba temporal** y supera al ingenuo
¿Qué entregar?	pronóstico puntual + intervalo de predicción	indicar horizonte, supuestos y qué pasa si cambia el régimen

Lo dicho en clase y en las diapositivas (verificado)

- **Código del IPC**: lee la tabla por filas y mezcla los meses (verificado: ACF(1) 0.53 frente a 0.62 bien leída). **PM2.5**: la diapositiva dice 1990–2000, los datos son 2000–2009. **Pasajeros**: la diapositiva dice desde 2010 pero el archivo parte en 2002-10 (el profesor lo corrigió en clase).
- **Diapositiva 50**: «$Y_t = 1.0 - 0.652Y_{t-1} + \varepsilon_t + 0.415\varepsilon_{t-1}$» tiene los signos al revés: el ajuste (MLE) es $\varphi = +0.652$ y, en la notación de la diapositiva 25, $\theta = +0.415$ ($\varepsilon_t - 0.415\varepsilon_{t-1}$); además la media es 1.0, no el intercepto. **Diapositiva 47**: el MA(3) fijado tiene $ma_2 = ma_3 = -0.0863$ en la convención de R, no +0.086.
- **Ljung-Box** (diapositiva 53): al compararlo con χ^2 hay que restar los parámetros ARMA estimados ($gl = m - p - q$); en el árbol con m = 10 el valor p pasa de 0.943 a 0.848. **Kolmogorov-Smirnov** con μ y σ estimados (diapositivas 56 y 46) da valores p inflados; corresponde Lilliefors (0.37 frente a 0.064).
- **Intervalos**: se les llama «de confianza» (clase y cuaderno de cierre) pero son de **predicción**. En la transcripción «75 %» es el nivel 80 % que dibuja forecast.
- **Varianza de la diferenciación**: no es «tres veces σ^2» tras tres diferencias sino $20\sigma^2$ (verificado: 1.00, 2.00, 6.00, 19.99 para d = 0 a 3). **Diapositiva 39**: $(P_t - P_{t-1})/P_{t-1}$, no $/P_t$. **Diapositivas 6 y 11**: $\theta(B)$ con + y con −. **Diapositiva 10**: $\Phi(B^2)$ debe ser $\Phi(B^s)$.
- **Dickey-Fuller**: las diapositivas 28–29 mezclan H_1: $\varphi < 1$ y $\varphi \neq 1$; el estadístico no es una t. «Tendencia determinística + ARIMA siempre sirve» es impreciso: diferenciar una recta crea un MA(1) con $\theta = 1$ y más varianza; conviene ajustar la recta.
- **Cuaderno de cierre**: el SARIMA converge a raíces casi unitarias ($\varphi = 0.996$, $\Phi = 0.998$) y el SARIMAX usa temperatura real del futuro. **Dato**: «IPSA = 50 empresas» (clase); según mi conocimiento externo hoy son 30 (no verificable con los materiales).

Errores comunes, preguntas de repaso y criterio de dominio

- Errores: confundir ruido blanco con independencia · leer la ACF de una serie con tendencia como «dependencia» · comparar AIC de métodos distintos · usar una t de Student en Dickey-Fuller · diferenciar de más · validar al azar · olvidar el intervalo de predicción · pronosticar a largo plazo con un ARMA
- Repaso: ¿qué es $\rho(k)$ y por qué $\pm 1.96/\sqrt{n}$? · ¿cómo se ve un AR(2) en ACF y PACF? · ¿por qué $\Delta^2\varepsilon$ tiene varianza $6\sigma^2$? · ¿qué hace $1 - B^{12}$? · ¿cuándo falla Ljung-Box y qué se hace? · ¿qué entrega un intervalo de predicción que no entrega uno de confianza?
- Dominio (marca □): ☐ dibujo ACF/PACF de un AR(1), MA(1) y ARMA(1,1) ☐ calculo una autocorrelación muestral a mano ☐ diferencio y diferencio estacionalmente a mano ☐ hago un pronóstico AR(1) con su intervalo ☐ leo una salida de Dickey-Fuller ☐ elijo entre modelos con AIC y diagnóstico ☐ valido en el tiempo y gano al ingenuo ☐ resuelvo los bloques del cuaderno con ≥ 80 %
- **Siguiente**: Machine Learning (C30–32), validación (C38) y bootstrap (C43).