Apuntes · Carpeta 1 · ANOVA y regresión lineal

Para leer antes de los ejercicios · Clases 17, 18 y 19 · lectura de ~60 min

Lo más importante, en 6 ideas

1. **Un solo modelo.** Y = parte explicada + error. ANOVA explica con grupos; la regresión, con números.
2. **ANOVA.** Compara la variación ENTRE grupos con la variación DENTRO de ellos. F grande → los grupos difieren.
3. **Regresión simple.** La recta de mínimos cuadrados. β_1 = cambio en Y por unidad de X. $R^2 = r^2$.
4. **Supuestos.** Normalidad, independencia y homocedasticidad de los residuos. En esas pruebas queremos p GRANDE.
5. **Regresión múltiple.** Cada β es el efecto de su X manteniendo las demás constantes. Categóricas con m − 1 dummies.
6. **Elegir modelo.** R^2 siempre sube: compara con R^2 ajustado, AIC o BIC. Vigila el VIF y no extrapoles.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** que apunta al notebook `C17-19_Regresion.ipynb` o al cuaderno `02_Ejercicios_Cuaderno_Regresion.pdf`. La guía visual de esta carpeta es `02_Regresion_C17-19.pdf`.

1 La idea de modelo estadístico

La profesora parte con el modelo más simple posible: **Y = μ + ε**. Cada dato es un promedio más un error aleatorio. Todos los modelos de esta carpeta agregan algo a ese promedio para explicar mejor Y:

Modelo	Fórmula	Qué explica Y
Basal	$Y = \mu + \varepsilon$	nada: solo el promedio
ANOVA (Clase 17)	$Y = \mu + \alpha_{grupo} + \varepsilon$	el grupo (categórica)
Regresión simple (Clase 18)	$Y = \beta_0 + \beta_1 X + \varepsilon$	una variable numérica
Regresión múltiple (Clase 19)	$Y = \beta_0 + \beta_1 X_1 + \ldots + \beta_k X_k + \varepsilon$	varias variables, numéricas y categóricas

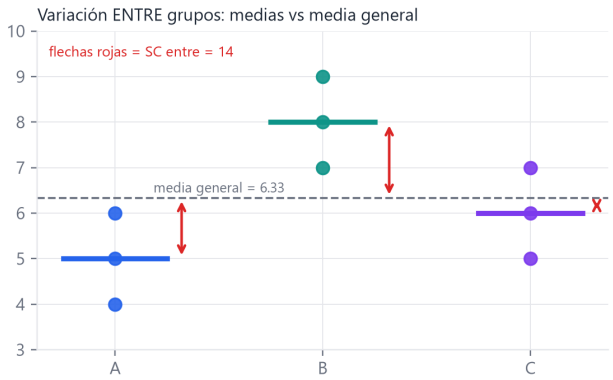
Lo que debes recordar

- En todos los casos, ε se supone normal, independiente y con varianza constante. Esos son los supuestos que se revisan al final de cada modelo.

2 ANOVA de un factor

Pregunta típica: **¿el salario promedio es igual en Banca, Minería y Retail?** H0: todas las medias son iguales. H1: al menos dos son distintas.

La idea es comparar dos variaciones. La variación **entre** grupos mide cuánto se alejan las medias de cada grupo de la media general. La variación **dentro** mide cuánto se alejan los datos de la media de su propio grupo, o sea, el ruido. Si la primera es mucho mayor que la segunda, las diferencias entre grupos no son solo ruido.





Ejemplo resuelto · tres grupos pequeños: A = 4, 5, 6 · B = 7, 8, 9 · C = 5, 6, 7

Paso	Qué haces	Resultado
1	Medias de grupo y media general	A 5 · B 8 · C 6 · general 6.33
2	SC entre = $\Sigma\, n_j \cdot (\text{media}_j - \text{media general})^2$	3·(1.78 + 2.78 + 0.11) = 14
3	SC dentro = Σ (dato − media de su grupo)^2	(1+0+1)·3 = 6
4	gl entre = k − 1 · gl dentro = N − k	2 · 6
5	CM = SC / gl	CM entre = 7 · CM dentro = 1
6	F = CM entre / CM dentro	7
7	Comparar con F crítico (2, 6; $\alpha = 0.05$) = 5.14	7 > 5.14 → se rechaza H0 ($p = 0.027$)

Pista para la Parte A del notebook y el Bloque 1 del cuaderno
Arma la tabla en el mismo orden: medias → SC entre → SC dentro → gl → CM → F. Un control rápido: SC entre + SC dentro = SC total, la suma de (dato − media general)^2 de todos los datos.

3 Después del ANOVA: comparaciones múltiples e interacción

ANOVA dice **si** hay diferencias, no **cuáles**. Para eso se usa **Tukey**: compara todos los pares de grupos controlando el error tipo I. Con los salarios: Banca vs Minería y Minería vs Retail difieren ($p < 0.001$); Banca vs Retail no ($p = 0.23$).

Con dos factores aparece la **interacción**: el efecto de uno depende del nivel del otro. En los salarios, las mujeres ganan menos en Retail y Banca, pero más en Minería. En la tabla ANOVA con interacción, Industria:Sexo tiene $p = 0.033$: la interacción es significativa. Gráficamente, las líneas de medias se cruzan.

¿Por qué no hacer varias pruebas t en vez de ANOVA?
Con 3 grupos hay 3 pares. Si cada prueba usa $\alpha = 0.05$, la probabilidad de al menos un falso positivo es $1 - 0.95^3 = 14\%$, no 5%. ANOVA + Tukey mantienen el error total en 5%.

4 Correlación

La **correlación de Pearson** (r) mide la fuerza de la relación **lineal** entre dos variables numéricas, de −1 a 1. La de **Spearman** usa rangos y detecta relaciones que siempre suben o siempre bajan, aunque no sean rectas.

- **r ≈ 0 no significa «sin relación»**: puede haber una curva. Siempre grafica antes (el ejemplo del datasaurus).
- **Correlación no es causalidad**: dos variables pueden moverse juntas por una tercera.
- La covarianza depende de las unidades; la correlación no. Por eso se compara mejor.

Pista para la Parte B del notebook
Calcula las dos correlaciones con `df.corr()` y `df.corr(method='spearman')`. Si en alguna variable difieren mucho, grafícala: probablemente la relación no es lineal o hay outliers.

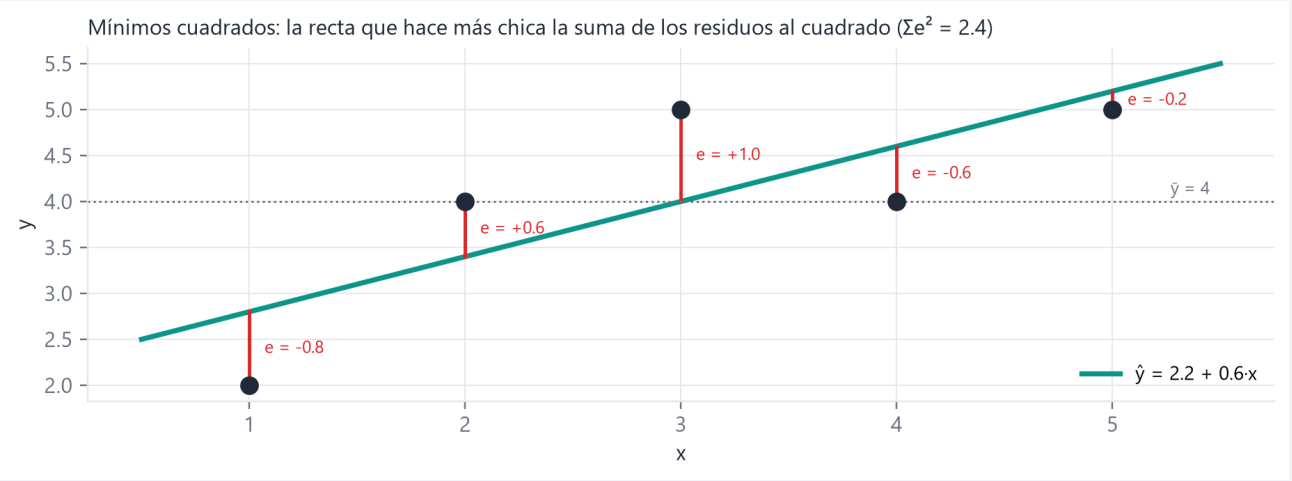
5 Regresión lineal simple

La recta de **mínimos cuadrados** es la que hace más pequeña la suma de los residuos al cuadrado. Sus coeficientes se calculan con dos fórmulas:

$\beta_1 = S_{xy} / S_{xx} = \Sigma(x - \bar{x})(y - \bar{y}) / \Sigma(x - \bar{x})^2$
$\beta_0 = \bar{y} - \beta_1 \cdot \bar{x}$
$r = S_{xy} / \sqrt{(S_{xx} \cdot S_{yy})} \cdot R^2 = r^2$ (solo en regresión simple)

Ejemplo resuelto · x = 1, 2, 3, 4, 5 · y = 2, 4, 5, 4, 5

Paso	Qué haces	Resultado
1	Medias	$\bar{x} = 3 \cdot \bar{y} = 4$
2	Desvíos $x - \bar{x}$ y $y - \bar{y}$	$(-2, -1, 0, 1, 2) \cdot (-2, 0, 1, 0, 1)$
3	S_{xy} = Σ productos de desvíos	4 + 0 + 0 + 0 + 2 = 6
4	$S_{xx} = \Sigma (x - \bar{x})^2 \cdot S_{yy} = \Sigma (y - \bar{y})^2$	10 · 6
5	$\beta_1 = 6 / 10 \cdot \beta_0 = 4 - 0.6 \cdot 3$	0.6 · 2.2
6	$r = 6 / \sqrt{(10 \cdot 6)} \cdot R^2 = r^2$	0.775 · 0.60



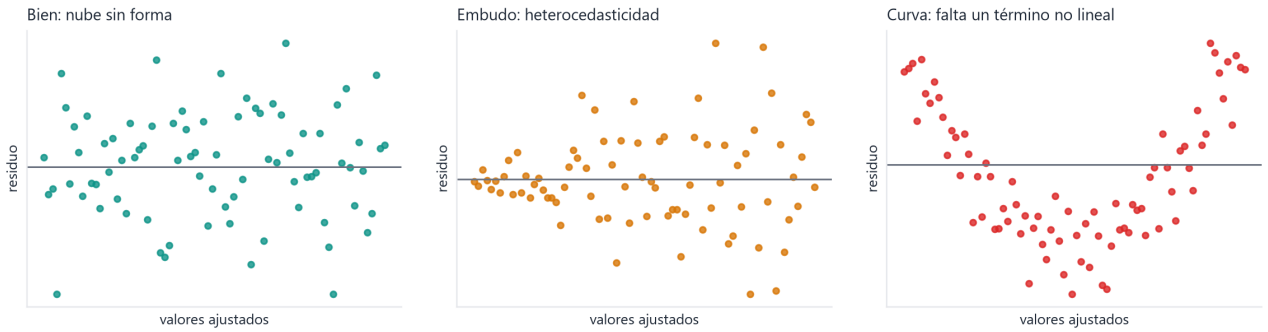
Lectura: cada unidad más de x sube y en 0.6, en promedio. El modelo explica el 60% de la variación de y.

El intercepto no siempre tiene sentido
En la clase, BIO = −885 + 410·pH. A pH = 0 la biomasa sería −885: imposible. No es un error del modelo: pH = 0 está muy fuera del rango observado (3.2 a 7.5). **Nunca interpretes ni predigas fuera del rango de X.**

Pista para la Parte B del notebook y los Bloques 3 y 4 del cuaderno
En el cuaderno, sigue los 6 pasos de la tabla. En el notebook, verifica que el R^2 del `summary()` de bio ~ ph sea igual a la correlación al cuadrado: $0.774^2 = 0.599$.

6 Diagnóstico de residuos

Un modelo puede tener buen R^2 y aun así no servir. Antes de confiar en sus p-valores hay que revisar los residuos. Primero se miran los gráficos y después las pruebas:



Supuesto	Gráfico	Prueba	H0 de la prueba	Queremos
Normalidad	QQ-plot	Shapiro-Wilk	los residuos son normales	$p > 0.05$
Independencia	residuos en orden	Durbin-Watson	no hay autocorrelación	$DW \approx 2 \cdot p > 0.05$
Homocedasticidad	residuos vs ajustados	Breusch-Pagan	varianza constante	$p > 0.05$

Aquí el p-valor se lee al revés
En estas pruebas, H0 es «el supuesto se cumple». Un p-valor GRANDE es buena noticia. Ejemplo real, bio ~ pH: Shapiro p = 0.032 (la normalidad falla), Durbin-Watson = 0.85 (hay autocorrelación) y Breusch-Pagan p = 0.98 (la homocedasticidad se cumple).

Pista para el Bloque 5 del cuaderno
Para cada prueba escribe primero su H0. Luego decide: $p > 0.05$ → no se rechaza → el supuesto se cumple.

7 Regresión lineal múltiple

Con varias X, cada coeficiente se interpreta **manteniendo constantes las demás**. Las variables categóricas entran como **dummies** (0/1): una categórica con m niveles usa m − 1 dummies, y la categoría omitida es la referencia.

Ejemplo resuelto · salarios (datos reales)
Salario = 2.004 + 0.125·Experiencia − 0.417·Mujer + 0.625·Minería − 0.322·Retail. Referencias: Hombre y Banca.

Coeficiente	Lectura correcta
0.125 (Experiencia)	Cada año extra suma 0.125 al salario, a igual sexo e industria.
−0.417 (Mujer)	Una mujer gana 0.417 menos que un hombre con la misma experiencia e industria.
0.625 (Minería)	Minería paga 0.625 más que Banca (la referencia), a igual experiencia y sexo.
−0.322 (Retail)	Retail paga 0.322 menos que Banca, pero p = 0.13: no es significativo.

Predicción para una mujer en Minería con 10 años: 2.004 + 0.125·10 − 0.417 + 0.625 = **3.462**.

La trampa de las dummies
Si incluyes las 3 dummies de industria junto al intercepto, las 3 columnas suman siempre 1, igual que la columna del intercepto. La matriz no se puede invertir y el modelo no se puede estimar. Por eso se usa `pd.get_dummies(..., drop_first=True)`.

Pista para la Parte C del notebook y el Bloque 6 del cuaderno
Para predecir, escribe la ecuación y reemplaza: las dummies valen 1 solo si la persona está en esa categoría. Si es de la categoría de referencia, todas sus dummies valen 0.

8 Comparar y elegir modelos

El R^2 **nunca baja** al agregar una variable, aunque sea basura. Por eso, para comparar modelos de distinto tamaño se usan medidas que penalizan la complejidad:

$R^2_{ajustado} = 1 - (1 - R^2)\cdot(n - 1) / (n - k - 1)$ (k = n° de predictores)
AIC y BIC: menor es mejor. BIC penaliza más fuerte que AIC.

Ejemplo resuelto · ¿agregar salinidad al modelo de biomasa? (n = 45)

Modelo	R^2	R^2 ajustado
bio ~ pH + BUF (k = 2)	0.599	1 − 0.401·44/42 = 0.580
bio ~ pH + BUF + SAL (k = 3)	0.604	1 − 0.396·44/41 = 0.575

El R^2 sube, pero el ajustado **baja**: SAL no aporta lo suficiente para justificar un parámetro más.

La **selección stepwise** automatiza la búsqueda. Forward parte de nada y agrega variables; backward parte de todas y quita. No prueban todas las combinaciones (con 16 variables serían $2^{16} = 65.536$), así que pueden terminar en modelos distintos. Con biomass, forward elige pH, type, BUF, Cu, Mn y Mg ($R^2 = 0.85$), y backward elige otro conjunto.

9 Multicolinealidad y VIF

Si dos predictores están muy correlacionados, el modelo no logra separar el efecto de cada uno: los errores estándar se inflan y los coeficientes se vuelven inestables. El **VIF** lo mide.

Ejemplo resuelto · calcular e interpretar el VIF

$VIF_j = 1 / (1 - R^2_j)$, donde R^2_j es el R^2 de explicar X_j con las demás X.

R^2_j	VIF	Lectura
0.5	1 / 0.5 = 2	aceptable
0.9	1 / 0.1 = 10	problema severo
0.984	≈ 62	el pH en el modelo completo de biomass

Regla práctica: VIF < 5 bien · 5 a 10 revisar · > 10 problema. En el modelo pH + BUF + SAL, pH y BUF tienen VIF ≈ 10: están muy correlacionados entre sí (r ≈ −0.95).

10 Predecir con datos nuevos

Un modelo solo es confiable **dentro del rango** de los datos con que se ajustó. Antes de predecir, compara los rangos de las X nuevas con los de entrenamiento.

Alerta: bio_new.csv trae un error
En ese archivo, Mn, Zn y Cu tienen el punto decimal corrido: Cu vale 502.381 donde en biomass vale 5.02381. Un modelo que usa esas variables predice biomasas de ~100.000, cuando los datos van de ~200 a ~2.500. La Parte D del notebook te pide detectarlo. Es una lección real: **revisa los datos antes de confiar en una predicción.**

11 Chuleta de código (statsmodels)

Quiero…	Código
ANOVA de un factor	m = smf.ols('y ~ C(g)', d).fit(); sm.stats.anova_lm(m)
ANOVA con interacción	smf.ols('y ~ C(a) * C(b)', d).fit()
Tukey	pairwise_tukeyhsd(d.y, d.g)
Correlaciones	d.corr() · d.corr(method='spearman') · stats.pearsonr(x, y)
Regresión	m = smf.ols('y ~ x1 + x2 + C(cat)', d).fit(); m.summary()
R^2, R^2 ajustado, AIC	m.rsquared · m.rsquared_adj · m.aic · m.bic
Normalidad	stats.shapiro(m.resid) · sm.qqplot(m.resid, line='s')
Independencia	durbin_watson(m.resid)
Homocedasticidad	het_breuschpagan(m.resid, m.model.exog)
Puntos influyentes	m.get_influence().cooks_distance[0]
VIF	variance_inflation_factor(X.values, j)
Predecir con intervalo	m.get_prediction(nuevos).summary_frame(alpha=0.05)

12 Errores comunes

Error	Por qué está mal	Qué hacer
Hacer varias pruebas t con 3+ grupos	Infla el error tipo I	ANOVA + Tukey
Comparar modelos con R^2	R^2 siempre sube	R^2 ajustado, AIC, BIC
Interpretar β sin «a igual lo demás»	En la múltiple cada β es parcial	Decir siempre qué se mantiene fijo
Incluir todas las dummies	Matriz no invertible	m − 1 dummies (drop_first)
Leer p < 0.05 en Shapiro como bueno	En supuestos, H0 = se cumple	Queremos p grande
Predecir fuera del rango de X	El modelo no sabe qué pasa ahí	Comparar rangos antes
Borrar outliers por receta	Pueden ser lo más importante	Entender su origen primero

Lo que debes recordar

- Orden sugerido: lee estos apuntes → Bloques 1–2 del cuaderno → Parte A del notebook → Bloques 3–5 → Parte B → Bloques 6–8 → Partes C y D → ejercicio de cierre.
- Si te trabas más de 10 minutos, mira la solución, entiéndela y vuelve a hacerlo sin mirar.