Ejercicios para el cuaderno · Carpeta 1 · ANOVA y regresión

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo, no solo el resultado.
- Redondea a 2 o 3 decimales. Pequeñas diferencias de redondeo con las soluciones son normales.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.
- Corrige con las soluciones y marca con color lo que tuviste mal: eso va al repaso del domingo.

Bloque 1 ANOVA a mano ★★

Tres métodos de estudio, puntaje de 3 estudiantes cada uno: M1 = 6, 7, 8 · M2 = 9, 10, 11 · M3 = 6, 8, 10.

1. Calcula la media de cada grupo y la media general.
2. Calcula la SC entre, la SC dentro y verifica que suman la SC total.
3. Completa la tabla ANOVA: gl, CM y F.
4. Con F crítico (2, 6; $\alpha = 0.05$) = 5.14, ¿rechazas H0? Escribe H0, H1 y la conclusión en palabras.

Bloque 2 Leer tablas ANOVA (datos reales de salarios) ★★

1. En Salario ~ Industria: SC Industria = 17.88 con 2 gl; SC residual = 18.04 con 37 gl. Calcula los CM y el F. ¿Cuántas personas hay en total?
2. Con el modelo con interacción, Industria:Sexo tiene F = 3.77 y p = 0.033. ¿Qué significa en palabras sobre hombres y mujeres en las distintas industrias?
3. Tukey da: Banca–Minería p = 0.0008 · Banca–Retail p = 0.23 · Minería–Retail p < 0.001. ¿Qué pares difieren? Resume en una frase.
4. ★★★ Si hicieras 3 pruebas t independientes con $\alpha = 0.05$, ¿cuál sería la probabilidad de al menos un falso positivo? ¿Qué te dice eso sobre usar ANOVA?

Bloque 3 Correlación y regresión simple a mano ★★

Horas de estudio (x) y nota (y): x = 2, 4, 6, 8 · y = 3, 5, 4, 8.

1. Calcula $\bar{x}$, $\bar{y}$, S_{xy}, S_{xx} y S_{yy}.
2. Calcula β_1, β_0 y escribe la recta.
3. Calcula r y R^2. Interpreta R^2 en una frase.
4. Calcula los 4 residuos y verifica que suman 0.
5. Predice la nota para 5 horas. ¿Sería razonable predecir para 20 horas? ¿Por qué?

Bloque 4 Interpretar bio ~ pH (datos reales) ★

Modelo de clase: BIO = −885.2 + 409.8 · pH, $R^2 = 0.599$.

1. Predice la biomasa para pH = 4 y pH = 5. ¿Cuánto cambia?
2. Interpreta la pendiente en una frase con unidades.
3. ¿Tiene sentido el intercepto? Justifica (en los datos, el pH va de 3.2 a 7.5).
4. ¿Cuánto vale r? ¿Qué signo tiene y por qué?

Bloque 5 Diagnóstico de residuos ★★

Resultados de bio ~ pH: Shapiro p = 0.032 · Durbin-Watson = 0.85 · Breusch-Pagan p = 0.98.

1. Para cada prueba, escribe su H0 y decide si el supuesto se cumple.
2. Los datos de biomass están ordenados por localidad y tipo de vegetación. ¿Cómo podría explicar eso el resultado de Durbin-Watson?
3. ★★★ Un compañero dice: «Shapiro dio p < 0.05, así que el resultado es significativo y el modelo es bueno». Explica su error.

Bloque 6 Regresión múltiple con dummies (salarios) ★★

Salario = 2.004 + 0.125·Exp − 0.417·Mujer + 0.625·Minería − 0.322·Retail. Referencias: Hombre y Banca.

1. Predice el salario de: (a) hombre en Banca con 5 años; (b) mujer en Retail con 5 años; (c) mujer en Minería con 10 años.
2. Interpreta el coeficiente −0.417 con la frase «manteniendo constante…».
3. ¿Por qué el modelo tiene solo 2 dummies de industria y no 3?
4. ★★★ Retail tiene p = 0.13. ¿Significa que Retail paga igual que Banca? Responde con cuidado.

Bloque 7 R^2 ajustado y VIF ★★

1. Con n = 45: el modelo A (k = 2) tiene R^2 = 0.599 y el modelo B (k = 3) tiene R^2 = 0.604. Calcula ambos R^2 ajustados. ¿Cuál prefieres?
2. Calcula el VIF si R^2_j = 0.75 y si R^2_j = 0.95. Clasifica cada uno.
3. En el modelo completo de biomass, el pH tiene VIF = 62. ¿Qué R^2_j implica? ¿Qué le pasa a su coeficiente?

Bloque 8 Selección de modelos y predicción ★★★

1. ¿Cuántos subconjuntos posibles de variables hay con 5 candidatas? ¿Y con 16?
2. Forward eligió pH, type, BUF, Cu, Mn, Mg (AIC 642.1) y backward eligió loc, type, Ca, Mg, Mn, Cu, NH4 (AIC 639.3). ¿Por qué pueden diferir? ¿Cuál elegirías por AIC?
3. En bio_new.csv, Cu vale 502.381 donde en biomass vale 5.02381. ¿Qué pasará si predices con un modelo que usa Cu? ¿Qué harías?

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	M1 = 7 · M2 = 10 · M3 = 8 · media general = 75 / 9 = 8.33.
2	SC entre = $3\cdot[(7-8.33)^2 + (10-8.33)^2 + (8-8.33)^2] = 3\cdot(1.78 + 2.78 + 0.11) = 14$. SC dentro = (1+0+1) + (1+0+1) + (4+0+4) = 12. SC total = $\Sigma(\text{dato} - 8.33)^2 = 26 = 14 + 12$.
3	gl entre = 2, gl dentro = 6. CM entre = 7, CM dentro = 2. F = 3.5.
4	H0: μ1 = μ2 = μ3. H1: al menos dos difieren. F = 3.5 < 5.14 → no se rechaza H0: con estos datos no hay evidencia de que los métodos difieran (p ≈ 0.10). Ojo: M3 tiene mucha variación interna, y eso «tapa» la diferencia.

Bloque 2

#	Solución
1	CM Industria = 17.88 / 2 = 8.94 · CM residual = 18.04 / 37 = 0.488 · F = 8.94 / 0.488 = 18.3. N = 2 + 37 + 1 = 40.
2	La brecha entre hombres y mujeres no es igual en todas las industrias: depende de la industria (en Minería incluso se invierte).
3	Minería difiere de Banca y de Retail; Banca y Retail no difieren entre sí. Minería paga más que las otras dos.
4	$1 - 0.95^3 = 0.143$ → 14%, casi el triple del 5% buscado. ANOVA + Tukey controla el error total.

Bloque 3

#	Solución
1	$\bar{x} = 5 \cdot \bar{y} = 5$. Desvíos x: −3, −1, 1, 3 · desvíos y: −2, 0, −1, 3. $S_{xy} = 6 + 0 - 1 + 9 = 14 \cdot S_{xx} = 20 \cdot S_{yy} = 14$.
2	$\beta_1 = 14 / 20 = 0.7 \cdot \beta_0 = 5 - 0.7\cdot 5 = 1.5 \rightarrow \hat{y} = 1.5 + 0.7x$.
3	$r = 14 / \sqrt{(20\cdot 14)} = 0.837 \cdot R^2 = 0.70$: las horas de estudio explican el 70% de la variación de la nota.
4	$\hat{y}$ = 2.9, 4.3, 5.7, 7.1 → residuos 0.1, 0.7, −1.7, 0.9. Suma = 0.
5	$\hat{y}(5) = 5.0$. Para 20 horas no: está muy fuera del rango observado (2 a 8) y la relación podría no seguir siendo lineal.

Bloque 4

#	Solución
1	pH 4 → −885.2 + 1639.2 = 754 · pH 5 → 1163.8. Cambia 409.8.
2	Por cada unidad más de pH, la biomasa aumenta en promedio 409.8 unidades.
3	No: pH = 0 está fuera del rango observado. El intercepto solo «ancla» la recta; aquí no tiene interpretación física.
4	$r = \sqrt{0.599} = 0.774$, positivo porque la pendiente es positiva.

Bloque 5

#	Solución
1	Shapiro, H0: residuos normales → p = 0.032 < 0.05 → se rechaza: la normalidad falla. Durbin-Watson, H0: no hay autocorrelación → 0.85, lejos de 2 → hay autocorrelación positiva. Breusch-Pagan, H0: varianza constante → p = 0.98 → se cumple.
2	Filas vecinas son de la misma localidad y tipo, y se parecen más entre sí: sus residuos quedan correlacionados.
3	En una prueba de supuestos, H0 = «el supuesto se cumple». p < 0.05 significa que se rechaza la normalidad: es una mala noticia.

Bloque 6

#	Solución
1	(a) 2.004 + 0.625 = 2.629 · (b) 2.004 + 0.625 − 0.417 − 0.322 = 1.890 · (c) 2.004 + 1.25 − 0.417 + 0.625 = 3.462.
2	Manteniendo constantes la experiencia y la industria, una mujer gana en promedio 0.417 menos que un hombre.
3	Con 3 categorías se usan 3 − 1 = 2 dummies. Banca es la referencia (sus dos dummies valen 0). Usar 3 dummies + intercepto hace la matriz no invertible.
4	No. Significa que no hay evidencia suficiente para afirmar que difieren. «No rechazar H0» no es lo mismo que «H0 es cierta».

Bloque 7

#	Solución
1	A: 1 − 0.401·44/42 = 0.580 · B: 1 − 0.396·44/41 = 0.575. Prefiero A: el ajustado baja al agregar la tercera variable.
2	1 / 0.25 = 4 (aceptable) · 1 / 0.05 = 20 (problema severo).
3	R^2_j = 1 − 1/62 = 0.984: el pH se explica casi por completo con las otras variables. Su coeficiente es inestable y su error estándar está muy inflado.

Bloque 8

#	Solución
1	$2^5 = 32 \cdot 2^{16} = 65.536$.
2	Cada método avanza paso a paso y se detiene cuando ningún cambio mejora el AIC: no prueba todas las combinaciones. Por AIC, backward (639.3 < 642.1), pero hay que revisar sus supuestos y su VIF antes de quedarse con él.
3	La predicción explota (valores de ~100.000), porque Cu es 100 veces mayor que cualquier valor de entrenamiento. Reportaría el error, corregiría los datos o usaría un modelo sin esas variables (por ejemplo, bio ~ pH + type).