Apuntes · Carpeta 2 · Modelos lineales generalizados

Para leer antes de los ejercicios · Clases 20 y 21 · lectura de ~60 min

Lo más importante, en 6 ideas

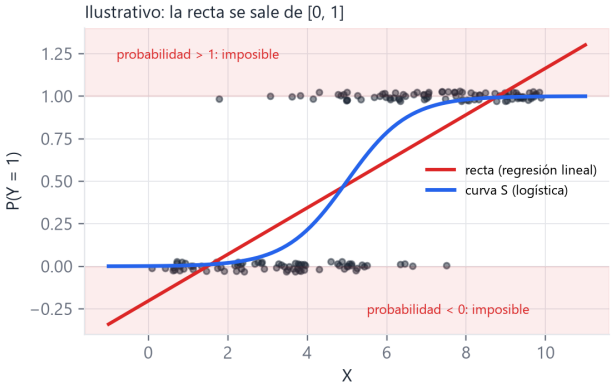
1. **El tipo de Y manda.** Sí/no → logística. Conteo → Poisson. 3+ categorías → multinomial. Continua → lineal.
2. **Mismo molde.** Todo GLM = distribución + combinación lineal + enlace.
3. **Odds ≠ probabilidad.** odds = p / (1 − p). La logística es una recta en la escala log(odds).
4. **e^{β} es lo que se interpreta.** Logística: OR (multiplica las odds). Poisson: RR (multiplica la tasa).
5. **Exactitud engaña.** Con clases desbalanceadas, reporta sensibilidad, especificidad y AUC.
6. **Offset y φ.** Offset para tasas; φ > 1 indica sobredispersión → quasi-Poisson.

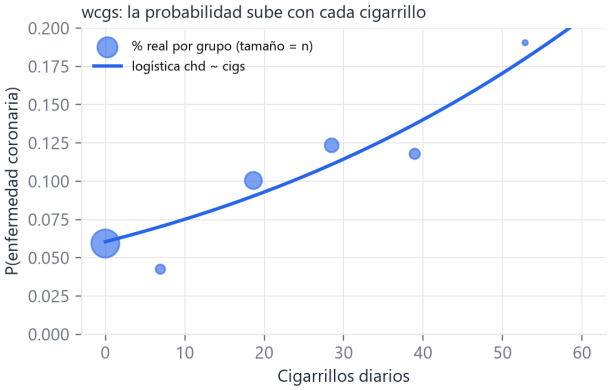
Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** que apunta al notebook `C20-21_GLM.ipynb` o al cuaderno `03_Ejercicios_Cuaderno_GLM.pdf`.

1 Por qué la regresión lineal no alcanza

En la regresión lineal, Y es continua y los errores son normales con varianza constante. Muchas preguntas reales no cumplen eso: **¿el cliente compra?** (sí/no), **¿cuántos reclamos llegan?** (conteo), **¿qué partido elige?** (categoría).

Si fuerzas una recta sobre una Y de 0 y 1, la recta no sabe que una probabilidad vive entre 0 y 1: termina prediciendo −0.2 o 1.3, que son valores imposibles. Además, la varianza de una proporción es p(1 − p), así que cambia con p y rompe el supuesto de varianza constante.





Lo que debes recordar

- El problema no son las X: es que Y no es normal.
- La solución no es abandonar la recta, sino ponerla en otra escala (la del enlace).

2 Los 3 componentes de un GLM

Piensa en un GLM como un molde con tres piezas intercambiables:

Pieza	Qué es	Quién la decide
1 · Distribución	Cómo se comporta Y: Normal, Binomial, Poisson, Multinomial	El TIPO de Y (no tú)
2 · Predictor lineal	$\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots$	Tú eliges las X
3 · Enlace g	Traduce la media de Y a la escala de η: $g(\mu) = \eta$	Tú, entre los compatibles con la distribución

La profesora corrigió a un alumno justo en este punto: **la distribución depende de Y; el enlace se elige**. Para una binomial puedes usar logit, probit o cloglog. En clase, sus AIC fueron 1753.97, 1753.49 y 1754.25: casi iguales. Se

suele preferir logit porque sus coeficientes se interpretan como odds ratios.

Ejemplo resuelto · elegir distribución y enlace

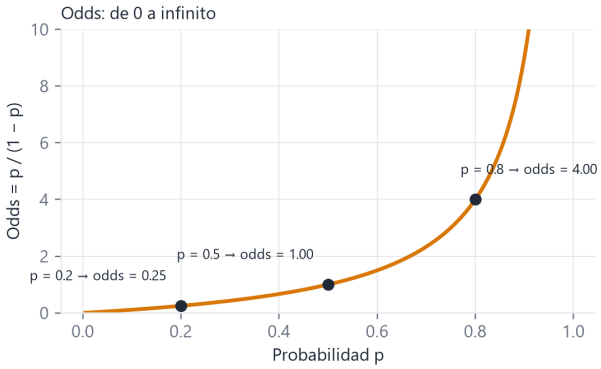
Pregunta	Tipo de Y	Distribución	Enlace
¿Un correo es spam?	binaria	Binomial	logit
N° de accidentes por mes en una autopista	conteo	Poisson	log
Accidentes por cada 1000 autos que pasan	conteo con exposición	Poisson + offset	log
Tipo de plan contratado (básico, medio, premium)	3 categorías con orden	Multinomial ordinal	logit acumulativo
Temperatura máxima del día	continua	Normal	identidad

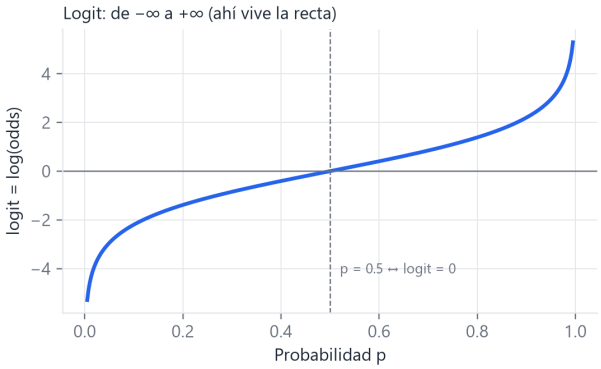
Pista para el Bloque 1 del cuaderno

Para cada situación, hazte dos preguntas en orden: **¿qué valores puede tomar Y?** y **¿hay una «exposición» distinta entre observaciones** (población, tiempo, clientes)? Si la hay, es Poisson con offset.

3 Probabilidad, odds y logit

Son tres formas de decir lo mismo. Si la probabilidad de lluvia es 0.8, las **odds** son 0.8 / 0.2 = 4: «4 a 1 a favor de que llueva». El **logit** es el logaritmo de las odds: log(4) = 1.386.





Ejemplo resuelto · ida y vuelta con p = 0.6

Paso	Qué haces	Resultado
1	odds = p / (1 − p) = 0.6 / 0.4	1.5
2	logit = ln(odds) = ln(1.5)	0.405
3	De vuelta: odds = e^{logit} = $e^{0.405}$	1.5
4	p = odds / (1 + odds) = 1.5 / 2.5	0.6

Atajo útil: **p = 1 / (1 + e^{-logit})** pasa directo del logit a la probabilidad.

Pista para el Bloque 2 del cuaderno

Usa los 4 pasos de la tabla. Ten a mano las teclas **ln** y **e^x** de la calculadora. Para revisar tu resultado: si p < 0.5, el logit debe ser negativo.

4 Leer una regresión logística

La logística ajusta **log(odds) = β_0 + β_1x**. Como la recta vive en escala log-odds, los coeficientes se leen así:

- **β_1**: cuánto suben las log-odds por unidad de x. Es difícil de imaginar.
- **$e^{\beta 1}$ = OR**: por cuánto se **multiplican** las odds por unidad de x. Esto es lo que se reporta.
- **(OR − 1) · 100**: el % de cambio en las odds.

- **Por k unidades**: $OR_k = e^{k \cdot \beta 1}$ (no k · OR).

Ejemplo resuelto · compras en una tienda online

Modelo: log(odds de comprar) = −3 + 0.04 · minutos en el sitio.

Pregunta	Cálculo	Resultado
OR por minuto	$e^{0.04}$	1.041 → +4.1% en las odds
OR por 10 minutos	$e^{10 \cdot 0.04} = e^{0.4}$	1.492 → +49%
P(comprar) con 50 min	$\eta = -3 + 0.04 \cdot 50 = -1 \rightarrow p = 1/(1 + e^{1})$	0.269
P(comprar) con 0 min	$\eta = -3 \rightarrow p = 1/(1 + e^{3})$	0.047

Observa: por 10 minutos el OR es 1.492, no 10 · 1.041. Los efectos se **multiplican**, no se suman.

Odds ratio ≠ cambio en probabilidad

Con wcgs, pasar de 0 a 20 cigarrillos multiplica las odds por 1.59 (+59%). Pero la probabilidad pasa de 0.061 a 0.093: sube 3.2 puntos porcentuales. Ambas cosas son ciertas; solo hay que decir cuál estás reportando.

Pista para la Parte A del notebook y el Bloque 3 del cuaderno

Para el OR usa `np.exp(m.params)`. Para la probabilidad a mano, calcula primero η con los coeficientes y después aplica $1 / (1 + e^{-\eta})$. Compara con `m.predict()`: deben coincidir.

5 Comparar modelos: deviance, prueba LR y AIC

La **deviance** mide cuánto le falta a un modelo para ajustar perfecto: menos deviance, mejor ajuste. Cuando un modelo contiene al otro (modelos anidados), la **diferencia de deviances** sigue una χ^2 con tantos grados de libertad como parámetros agregaste. Esa es la prueba de razón de verosimilitud (LR).

Ejemplo resuelto · ¿agregar la edad mejora el modelo de wcgs?

Paso	Qué haces	Resultado
1	Deviance de chd ~ cigs	1750.0
2	Deviance de chd ~ cigs + age	1705.9
3	LR = diferencia	44.1
4	gl = parámetros agregados (solo age)	1
5	Comparar con $\chi^2_{\text{crítico}}(1 \text{ gl}, \alpha = 0.05) = 3.84$	$44.1 > 3.84 \rightarrow p \approx 3 \cdot 10^{-11}$

Conclusión: la edad mejora significativamente el ajuste. El **AIC** sirve también para modelos **no** anidados: menor AIC, mejor equilibrio entre ajuste y simplicidad.

6 Evaluar un clasificador

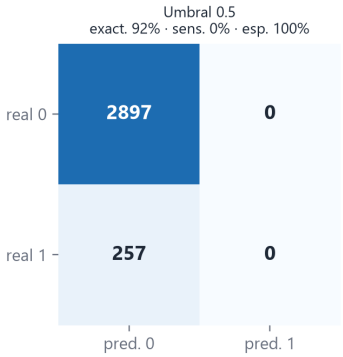
La logística entrega una probabilidad. Para decir «sí» o «no» se elige un **umbral**: si p ≥ umbral, se predice 1. Después se cruza lo predicho con lo real en una **matriz de confusión**.

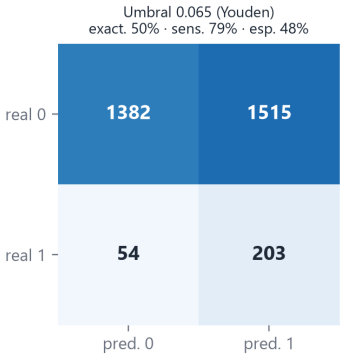
Ejemplo resuelto · una prueba de detección (200 personas)

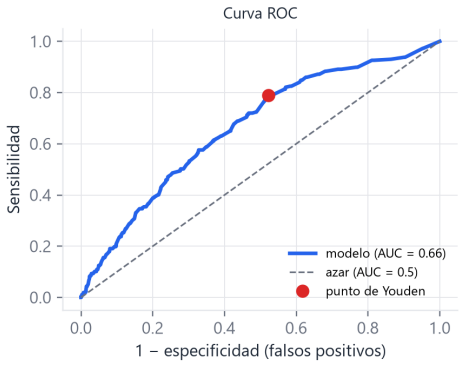
	Predicho: enfermo	Predicho: sano
Real: enfermo (50)	VP = 40	FN = 10
Real: sano (150)	FP = 30	VN = 120

Métrica	Pregunta que responde	Cálculo y resultado
Exactitud	¿Cuántos acierto en total?	(40 + 120) / 200 = 0.80
Sensibilidad	De los enfermos, ¿a cuántos detecto?	40 / 50 = 0.80
Especificidad	De los sanos, ¿a cuántos descarto?	120 / 150 = 0.80
Precisión	De los que marco enfermos, ¿cuántos lo están?	40 / 70 = 0.57

La trampa de la exactitud (ejemplo de la clase)
Con wcgs y umbral 0.5, el modelo dijo «sano» a todos: VN = 881, FN = 66, VP = FP = 0. Exactitud = 881 / 947 = 93%, pero sensibilidad = 0 / 66 = 0%. Solo el 8% está enfermo, así que decir siempre «no» ya acierta 92%. Con el umbral de Youden (0.069) se detectó a 40 de 66 (61%), a costa de 397 falsas alarmas.







Pista para la Parte B del notebook y el Bloque 4 del cuaderno
Ubica primero las 4 celdas (VP, FP, FN, VN) y escríbelas aparte. Todas las métricas son una celda dividida por una suma de celdas: la fila «real» para sensibilidad y especificidad, la columna «predicho» para precisión.

7 Poisson: conteos, tasas y offset

Para conteos se modela **log(μ) = η**. Al exponenciar, $\mu = e^{\eta}$ siempre es positivo, como debe ser un conteo. Los coeficientes se leen como **razones de tasas**: e^{β} dice por cuánto se multiplica la tasa.

El **offset** resuelve un problema práctico. Si una ciudad tiene el triple de habitantes, tendrá más casos aunque su riesgo sea igual. Agregando log(población) con coeficiente fijo 1, el modelo pasa a describir **casos por habitante**.

Ejemplo resuelto · reclamos en sucursales
Modelo: log(reclamos) = log(clientes) − 6 + 0.5 · (zona norte).

Pregunta	Cálculo	Resultado
Tasa en la zona sur (base)	e^{-6} por cliente	0.00248 → 2.48 por 1000 clientes
RR norte vs sur	$e^{0.5}$	1.65 → tasa 65% mayor en el norte
Reclamos esperados: sucursal norte, 2000 clientes	$2000 \cdot e^{-6 + 0.5}$	8.2 reclamos

Sobredispersión
La Poisson asume media = varianza. Se revisa con $\varphi = X^2_{Pearson} / gl$. Con $\varphi \approx 1$ el modelo va bien. Con $\varphi > 1$ (en clase, 1.50) los errores estándar salen demasiado chicos y los p-valores demasiado optimistas. La quasi-Poisson multiplica los errores estándar por $\sqrt{\varphi}$: en Python, `.fit(scale='X2')`.

Pista para la Parte C del notebook y el Bloque 5 del cuaderno
Para una tasa esperada, suma los coeficientes que aplican a esa fila (intercepto + ciudad + edad) y exponencia. Para los casos esperados, multiplica esa tasa por la población. Las categorías de referencia (Fredericia, 40–54) no suman nada: su coeficiente es 0.

8 Multinomial: más de dos categorías

Con J categorías se elige una de **referencia** y se ajusta una ecuación logit para cada una de las otras J − 1. Cada ecuación compara «esta categoría vs la referencia». Para obtener probabilidades se usa la fórmula de abajo, con $\eta = 0$ para la referencia.

Ejemplo resuelto · tres medios de transporte (A = referencia)
Para cierta persona: $\eta_B = 0.5$ y $\eta_C = -1$.

Paso	Qué haces	Resultado
1	Exponenciar: e^0, $e^{0.5}$, e^{-1}	1, 1.649, 0.368
2	Sumar	3.017
3	Dividir cada uno por la suma	A 0.331 · B 0.547 · C 0.122
4	Revisar: ¿suman 1?	0.331 + 0.547 + 0.122 = 1

Pista para la Parte D del notebook y el Bloque 6 del cuaderno
Calcula η para cada categoría que NO es la referencia con sus propios coeficientes. Luego aplica los 4 pasos. Si tus probabilidades no suman 1, revisa que hayas incluido el 1 (= e^0) de la referencia.

9 Chuleta de código (statsmodels)

Quiero…	Código
Importar	import statsmodels.api as sm · import statsmodels.formula.api as smf
Logística	m = smf.logit('y ~ x1 + x2', d).fit()
Logística (forma GLM)	smf.glm('y ~ x', d, family=sm.families.Binomial()).fit()
Odds ratios + IC	np.exp(m.params) · np.exp(m.conf_int())
Probabilidad predicha	m.predict(pd.DataFrame({'x1': [..], 'x2': [..]}))
Prueba LR (anidados)	LR = m1.deviance − m2.deviance; stats.chi2.sf(LR, gl)
Poisson con offset	smf.glm('y ~ x', d, family=sm.families.Poisson(), offset=np.log(d.expo)).fit()
φ (sobredispersión)	m.pearson_chi2 / m.df_resid
Quasi-Poisson	....fit(scale='X2')
Multinomial	smf.mnlogit('y ~ x', d).fit() (y = 0, 1, 2; 0 = referencia)
Matriz de confusión	confusion_matrix(y_real, (prob >= umbral).astype(int))
AUC y ROC	roc_auc_score(y_real, prob) · roc_curve(y_real, prob)

10 Errores comunes

Error	Por qué está mal	Qué hacer
Leer β de la logística como cambio en probabilidad	β está en escala log-odds	Reportar e^{β} (OR) o probabilidades predichas
OR por 10 unidades = 10 · OR	Los efectos se multiplican	$e^{10 \cdot \beta}$
Confiar en la exactitud	Con clases desbalanceadas engaña	Sensibilidad, especificidad, AUC
Poisson sin offset con exposiciones distintas	Compara conteos, no riesgos	offset = log(exposición)
Ignorar φ > 1	p-valores demasiado optimistas	Quasi-Poisson o binomial negativa
Evaluar con los datos de entrenamiento	Sobreestima el rendimiento	Separar train / test

Lo que debes recordar

- Orden sugerido: lee estos apuntes → haz los Bloques 1–3 del cuaderno → Partes A y B del notebook → Bloques 4–6 → Partes C y D → ejercicio de cierre.
- Si te trabas más de 10 minutos, mira la solución, entiéndela y vuelve a hacerlo sin mirar.