Ejercicios para el cuaderno · Carpeta 2 · GLM

Para resolver en papel, con calculadora (teclas ln y e^x) · soluciones paso a paso al final

Cómo usar esta guía

- Escribe en el cuaderno el **número del bloque y del ejercicio**, y luego tu desarrollo completo, no solo el resultado.
- Redondea a 3 o 4 decimales. Pequeñas diferencias de redondeo con las soluciones son normales.
- Nivel: ★ directo · ★★ requiere 2 o 3 pasos · ★★★ integra varios conceptos.
- Corrige con las soluciones de las últimas páginas y marca con color lo que tuviste mal. Esos ejercicios se repiten en el repaso del domingo.

Bloque 1 Elegir el modelo ★

Para cada situación indica: tipo de Y, distribución, enlace y si necesita offset.

1. Un banco quiere predecir si un cliente pagará su crédito (sí/no).
2. Un hospital cuenta las infecciones por mes en cada piso; los pisos tienen distinta cantidad de camas.
3. Una ciudad registra el medio de transporte que usa cada persona: auto, bus o bicicleta.
4. Una encuesta mide la satisfacción como mala, regular o buena.
5. Se registra el peso de recién nacidos según las semanas de gestación.
6. Se cuentan los goles por partido de un equipo.

Bloque 2 Probabilidad, odds y logit ★

1. Convierte p = 0.2, p = 0.75 y p = 0.05 a odds y a logit.
2. Si las odds son 3, ¿cuál es la probabilidad?
3. Si el logit es −1, ¿cuáles son las odds y la probabilidad?
4. Sin calcular: si p < 0.5, ¿el logit es positivo o negativo? ¿Por qué?

Bloque 3 Interpretar una logística (datos reales de wcgs) ★★

Modelo de clase: log(odds de chd) = −2.742 + 0.0232 · cigs.

1. Calcula las odds y la probabilidad de chd para alguien que no fuma.
2. Calcula la probabilidad de chd para alguien que fuma 20 cigarrillos diarios.
3. Calcula el OR por 1 cigarrillo y por 10 cigarrillos. Interpreta cada uno en una frase con %.
4. El material de clase dice que un OR de 1.2614 significa «35% mayores». ¿Qué está mal? ¿Cuál es la frase correcta?
5. Con edad: log(odds) = −6.360 + 0.0239 · cigs + 0.0764 · age. Calcula la probabilidad para un hombre de 50 años que fuma 20 cigarrillos, y el OR por 10 años más de edad.
6. ★★★ Al agregar la edad, la deviance baja de 1750.0 a 1705.9. Plantea H0, calcula el estadístico LR, indica los grados de libertad y concluye (χ^2 crítico con 1 gl y $\alpha = 0.05$: 3.84).

Bloque 4 Matriz de confusión ★★

1. Matriz de clase con umbral 0.5: VN = 881, FP = 0, FN = 66, VP = 0. Calcula exactitud, sensibilidad y especificidad. ¿Por qué la exactitud es engañosa aquí?
2. Con el umbral de Youden: VN = 484, FP = 397, FN = 26, VP = 40. Calcula las mismas tres métricas y la precisión. ¿Qué ganaste y qué perdiste?
3. Una prueba tiene VP = 90, FN = 10, FP = 45, VN = 855. Calcula las 4 métricas.
4. ★★★ Para detectar una enfermedad grave pero tratable, ¿preferirías alta sensibilidad o alta especificidad? Justifica en dos líneas y di si subirías o bajarías el umbral.

Bloque 5 Poisson con offset (cáncer de pulmón) ★★

Coeficientes de clase: intercepto −5.632 · Kolding −0.3715 · Horsens −0.3301 · edad 70–74 1.857 · edad 55–59 1.101. Referencias: Fredericia y 40–54.

1. Calcula la tasa esperada por 1000 habitantes para Fredericia, 40–54 años.
2. Calcula la tasa por 1000 para Kolding, 70–74 años, y los casos esperados si esa población es de 535 personas.
3. Calcula e interpreta el RR de Kolding y el de la edad 55–59.
4. ¿Por qué el modelo incluye log(población) como offset? Responde con un ejemplo de dos ciudades.
5. ★★★ X^2 de Pearson = 22.56 con 15 gl. Calcula φ, interprétalo y di qué modelo usarías y qué cambiaría en los resultados.

Bloque 6 Multinomial (nes96) ★★★

Referencia: Demócrata. $\eta_{Rep} = -0.863 + 0.0068 \cdot \text{edad} + 0.1095 \cdot \text{educ}$. $\eta_{Ind} = -2.385 + 0.0019 \cdot \text{edad} - 0.0845 \cdot \text{educ}$. (educ va de 0 = MS a 6 = MAdeg).

1. Calcula η_{Rep} y η_{Ind} para una persona de 45 años con educ = 5 (BAdeg).
2. Calcula las tres probabilidades y verifica que suman 1.
3. Calcula $e^{0.1095}$ e interprétalo en una frase.
4. El modelo nunca predice «Independiente» como clase más probable. Explica por qué en dos líneas.

Bloque 7 Desafío teórico ★★★

1. Partiendo de $\log(\text{odds}(x)) = \beta_0 + \beta_1 x$, demuestra que $\text{odds}(x + 1) / \text{odds}(x) = e^{\beta 1}$.
2. Un coeficiente vale −0.5 en una logística. Calcula el OR, di si es factor de riesgo o protector, y da el % de cambio.

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	Binaria → Binomial, enlace logit (regresión logística). Sin offset.
2	Conteo con exposición distinta → Poisson, enlace log, offset = log(n° de camas).
3	3 categorías sin orden → Multinomial nominal (logit generalizado).
4	3 categorías con orden → Multinomial ordinal (logit acumulativo).
5	Continua → Normal, enlace identidad (regresión lineal).
6	Conteo, misma exposición (1 partido) → Poisson, enlace log, sin offset.

Bloque 2

#	Solución
1	p = 0.2 → odds 0.25, logit −1.386 · p = 0.75 → odds 3, logit 1.099 · p = 0.05 → odds 0.0526, logit −2.944.
2	p = odds / (1 + odds) = 3 / 4 = 0.75.
3	odds = e^{-1} = 0.368 → p = 0.368 / 1.368 = 0.269.
4	Negativo: p < 0.5 → odds < 1 → ln(odds) < 0.

Bloque 3

#	Solución
1	odds = $e^{-2.742}$ = 0.0644 → p = 0.0644 / 1.0644 = 0.0605 (6%).
2	η = −2.742 + 0.0232 · 20 = −2.278 → p = 1 / (1 + $e^{2.278}$) = 0.093 (9.3%).
3	OR_1 = $e^{0.0232}$ = 1.0235: cada cigarrillo extra aumenta las odds 2.35%. OR_{10} = $e^{0.232}$ = 1.2614: 10 cigarrillos más aumentan las odds 26%.
4	1.2614 significa odds 1.26 veces, o sea +26%. «1.35 veces / 35%» no corresponde a ese OR. Frase correcta: «quien fuma 10 cigarrillos diarios más tiene odds de chd 1.26 veces las del otro, es decir, 26% mayores».
5	η = −6.360 + 0.0239 · 20 + 0.0764 · 50 = −2.06 → p = 1 / (1 + $e^{2.06}$) = 0.112 (11%). $OR_{10\ años}$ = $e^{0.764}$ = 2.15: 10 años más duplican (×2.15) las odds.
6	H0: el coeficiente de la edad es 0. LR = 1750.0 − 1705.9 = 44.1 con 1 gl. 44.1 > 3.84 → se rechaza H0 (p ≈ $3 \cdot 10^{-11}$): la edad mejora el modelo.

Bloque 4

#	Solución
1	Exactitud = 881 / 947 = 0.930 · Sensibilidad = 0 / 66 = 0 · Especificidad = 881 / 881 = 1. Engaña porque el 93% de los casos son sanos: decir «sano» a todos ya da 93% sin detectar a nadie.
2	Exactitud = (40 + 484) / 947 = 0.553 · Sensibilidad = 40 / 66 = 0.606 · Especificidad = 484 / 881 = 0.549 · Precisión = 40 / 437 = 0.092. Ganaste detectar al 61% de los enfermos; perdiste exactitud y hay muchas falsas alarmas.
3	Exactitud = 945 / 1000 = 0.945 · Sensibilidad = 90 / 100 = 0.90 · Especificidad = 855 / 900 = 0.95 · Precisión = 90 / 135 = 0.667.
4	Alta sensibilidad: un falso negativo (enfermo no detectado) es más grave que una falsa alarma que se descarta con otro examen. Bajaría el umbral.

Bloque 5

#	Solución
1	tasa = $e^{-5.632}$ = 0.00358 por persona → 3.58 por 1000.
2	$\eta = -5.632 - 0.3715 + 1.857 = -4.147$ → tasa = $e^{-4.147}$ = 0.0158 → 15.8 por 1000. Casos esperados = 535 · 0.0158 = 8.5.
3	RR Kolding = $e^{-0.3715}$ = 0.69: su tasa es 31% menor que la de Fredericia, a igual edad. RR 55–59 = $e^{1.101}$ = 3.01: tasa 3 veces la de 40–54, en la misma ciudad.
4	Ciudad A con 10.000 habitantes y 20 casos vs ciudad B con 1.000 y 5 casos: A tiene más casos, pero su tasa (2 por 1000) es menor que la de B (5 por 1000). El offset hace que el modelo compare tasas.
5	φ = 22.56 / 15 = 1.50 > 1 → sobredispersión leve. Usaría quasi-Poisson: mismos coeficientes, errores estándar × $\sqrt{1.5}$ ≈ 1.23, p-valores más grandes (en clase, Kolding deja de ser significativa).

Bloque 6

#	Solución
1	$\eta_{Rep} = -0.863 + 0.306 + 0.548 = -0.010$ · $\eta_{Ind} = -2.385 + 0.086 - 0.423 = -2.722$.
2	$e^{0} = 1$, $e^{-0.010} = 0.990$, $e^{-2.722} = 0.066$; suma = 2.056 → Dem 0.486 · Rep 0.482 · Ind 0.032. Suman 1.
3	$e^{0.1095} = 1.116$: cada nivel educacional adicional multiplica P(Rep) / P(Dem) por 1.116 (+11.6%).
4	Independiente es solo el 4% de los datos y ninguna X la separa bien: su probabilidad casi nunca supera a las de Demócrata y Republicano, así que nunca es la más alta.

Bloque 7

#	Solución
1	odds(x) = $e^{\beta 0 + \beta 1 x}$, odds(x + 1) = $e^{\beta 0 + \beta 1 x + \beta 1}$. Dividiendo: $e^{\beta 0 + \beta 1 x + \beta 1} / e^{\beta 0 + \beta 1 x} = e^{\beta 1}$. No depende de x: el OR es constante.
2	OR = $e^{-0.5}$ = 0.607 < 1 → factor protector: las odds bajan 39.3% por unidad de x.