Apuntes · Clase 22 · Experimentación, A/B testing y causalidad aplicada

Para leer antes de los ejercicios · lectura de ~35 min

Lo más importante, en 6 ideas

1. **Predecir no es intervenir.** Una pregunta causal pide qué pasaría con el cambio; la correlación no la responde.
2. **El azar hace comparables los grupos.** El efecto se estima con la diferencia de promedios; el confusor deja de importar.
3. **El p-valor y el IC se leen juntos.** p: ¿es compatible con «sin efecto»?; IC: ¿de qué tamaño puede ser el efecto?
4. **El tamaño se calcula antes.** n depende de α, potencia y MDE; mitad de MDE ≈ cuádruple de n.
5. **Antes de creer el efecto, chequeo el diseño.** SRM, peeking y comparaciones múltiples pueden invalidarlo.
6. **Sin azar, DiD con supuestos.** Efecto = cambio del tratado − cambio del control; exige tendencias paralelas.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C22_ABTesting.ipynb` o el cuaderno `C22_Ejercicios_Cuaderno_ABTesting.pdf`.

1 Pregunta predictiva o causal

Una pregunta es **predictiva** si pide anticipar un resultado con la información disponible («¿quién abandonará la app?»). Es **causal** si pide el efecto de *cambiar* algo («¿qué pasa con el abandono si ofrecemos 14 días de prueba en vez de 7?»). Para la segunda necesitamos el contrafactual: lo que habría ocurrido **sin** el cambio. Como nunca lo observamos en la misma persona, lo reemplazamos por un grupo control obtenido por **azar**.

Ejemplo resuelto · clasificar tres preguntas

Pregunta	Tipo	Por qué
¿Qué clientes tienen mayor riesgo de no pagar el mes próximo?	predictiva	anticipa con datos actuales; no cambia nada
¿Cuántas ventas más tendríamos si rebajamos el envío a 0?	causal	compara dos mundos: con y sin la rebaja
¿Los usuarios con más sesiones previas compran más?	asociación	describe una relación; no dice que sesiones causen compras

Regla práctica: si la respuesta sirve para *decidir qué hacer* (y no solo para saber qué pasará), hay que pensar en causalidad y diseñar un experimento.

Pista para la Parte A del notebook y el Bloque 1 del cuaderno

Simula en A1 los dos resultados potenciales y comprueba que la diferencia de promedios del experimento recupera el ATE.

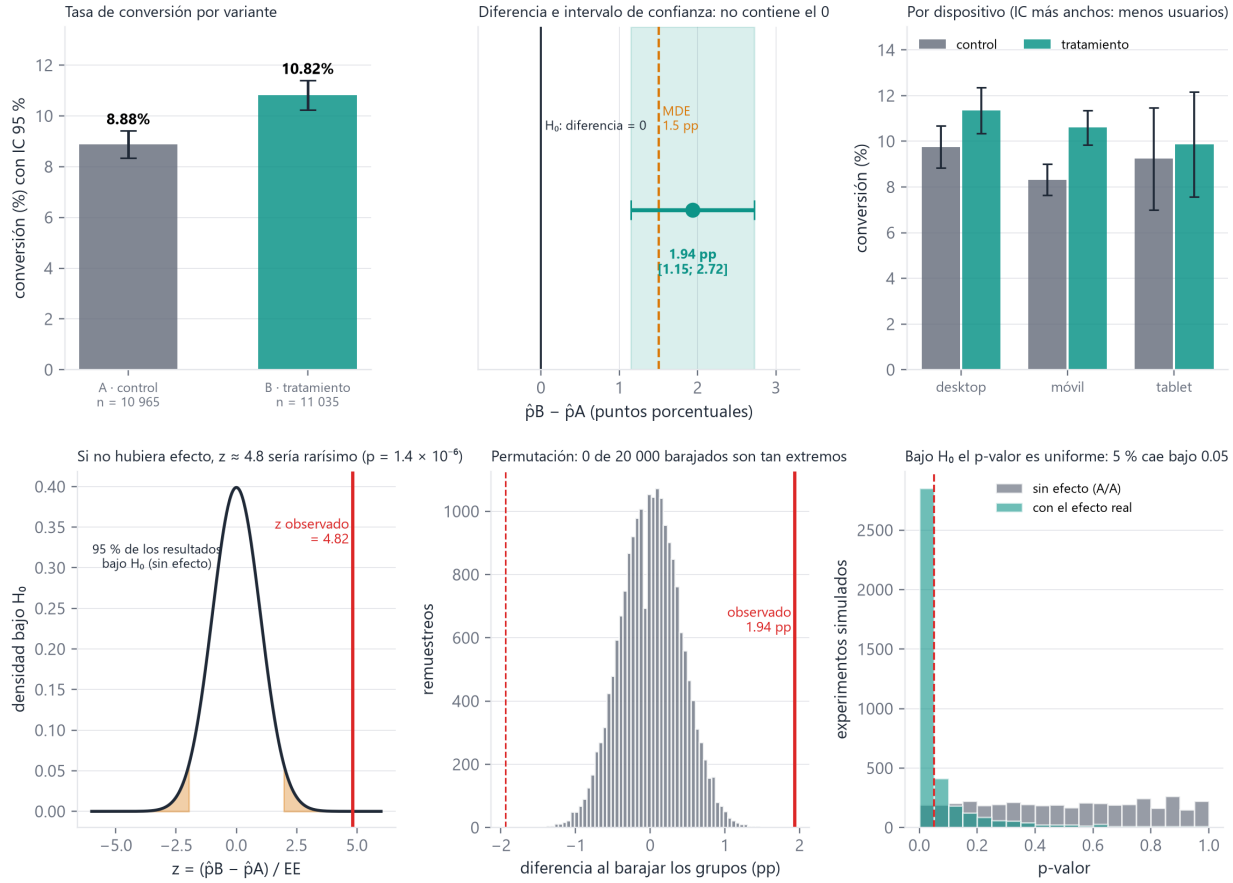
2 Diferencia de tasas, IC y p-valor, paso a paso

Idea: la tasa observada de cada grupo es una estimación con ruido. El **error estándar** (EE) cuantifica ese ruido. La diferencia dividida por su EE (el **z**) cuenta «cuántos ruidos» se aleja del 0. Si $|z| > 1.96$, el azar solo explicaría esa diferencia menos del 5 % de las veces ($p < 0.05$). El **IC** es diferencia ± 1.96·EE: el rango de efectos que los datos toleran.

Ejemplo resuelto · A: 300/5 000 · B: 365/5 000

Paso	Cálculo	Resultado
Tasas y diferencia	300/5 000 = 0.0600 · 365/5 000 = 0.0730	diferencia = 1.30 pp
Tasa conjunta	(300 + 365)/10 000	$\hat{p}$ = 0.0665
EE agrupado (para el test)	√[0.0665·0.9335·(1/5 000 + 1/5 000)]	0.00498
z y p-valor	0.0130 / 0.00498	z = 2.61 · p = 0.0091
EE de Wald (para el IC)	√[0.06·0.94/5 000 + 0.073·0.927/5 000]	0.00498
IC 95 %	1.30 ± 1.96·0.498	[0.32; 2.28] pp

Lectura: el efecto observado es +1.30 pp y el IC no contiene el 0 (p = 0.009 < 0.05). Pero el IC llega casi a 0.3 pp: el efecto podría ser pequeño. **Error común**: decir «hay 97 % de probabilidad de que B sea mejor» (eso es bayesiano y no es el p-valor).



Pista para la Parte B del notebook (B2) y los Bloques 2, 3 y 7 del cuaderno

Calcula el z a mano, compáralo con `proportions_ztest` y con el modelo lineal, y haz el test de permutación para *ver* qué es un p-valor.

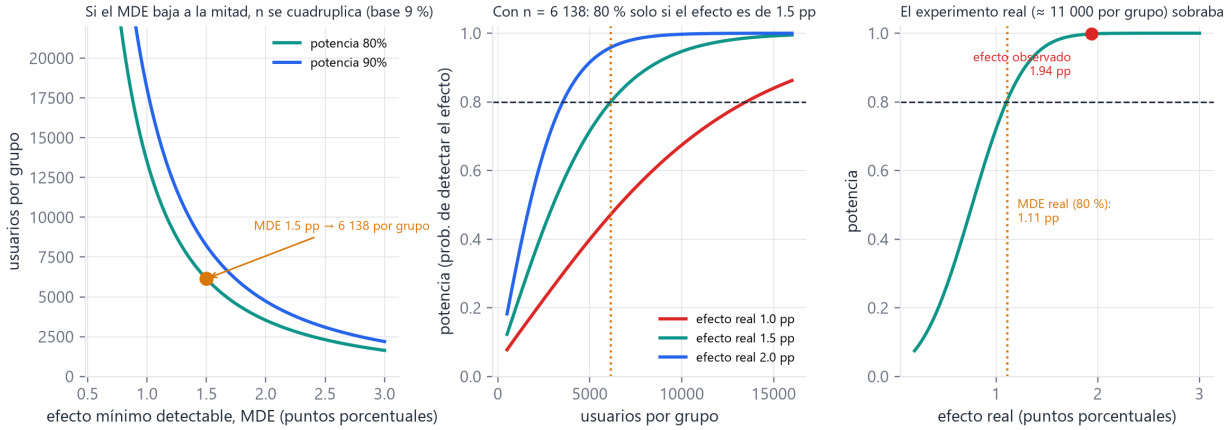
3 Potencia, MDE y tamaño de muestra

Hay dos errores posibles: decir «hay efecto» cuando no lo hay (**falso positivo**, probabilidad α) y no ver un efecto que sí existe (**falso negativo**, β). La **potencia** 1 − β es la probabilidad de detectar un efecto del tamaño del MDE. Se fijan α (0.05), la potencia (0.80 o 0.90) y el MDE, y se despeja n: crece con la variabilidad y baja con el cuadrado del MDE.

Ejemplo resuelto · línea base 12 %, queremos detectar +2 pp

Paso	Cálculo	Resultado
Constantes (α = 0.05, 80 %)	$z_{0.975} = 1.960 \cdot z_{0.80} = 0.842$	$(1.960 + 0.842)^2 = 7.85$
Varianzas	0.12·0.88 + 0.14·0.86	0.2260
Fórmula simplificada	$7.85 \cdot 0.2260 / 0.02^2$	n ≈ 4 435 por grupo
Fórmula de power.prop.test	con $\bar{p} = 0.13$	n = 4437.4 → 4 438
Mitad del MDE (+1 pp)	$p_2 = 0.13$	17 169 por grupo (≈ ×4)
Potencia 90 %	$z_{0.90} = 1.282$	5 940 por grupo

La fórmula simplificada es una aproximación; `power.prop.test` usa la varianza exacta bajo H_1 y da un valor algo mayor. Siempre se redondea **hacia arriba**, y el total es el doble.



Pista para la Parte A del notebook (A3) y el Bloque 4 del cuaderno

Reproduce 6 138 con la fórmula, descubre de dónde sale 6 131 y dibuja la curva n frente al MDE.

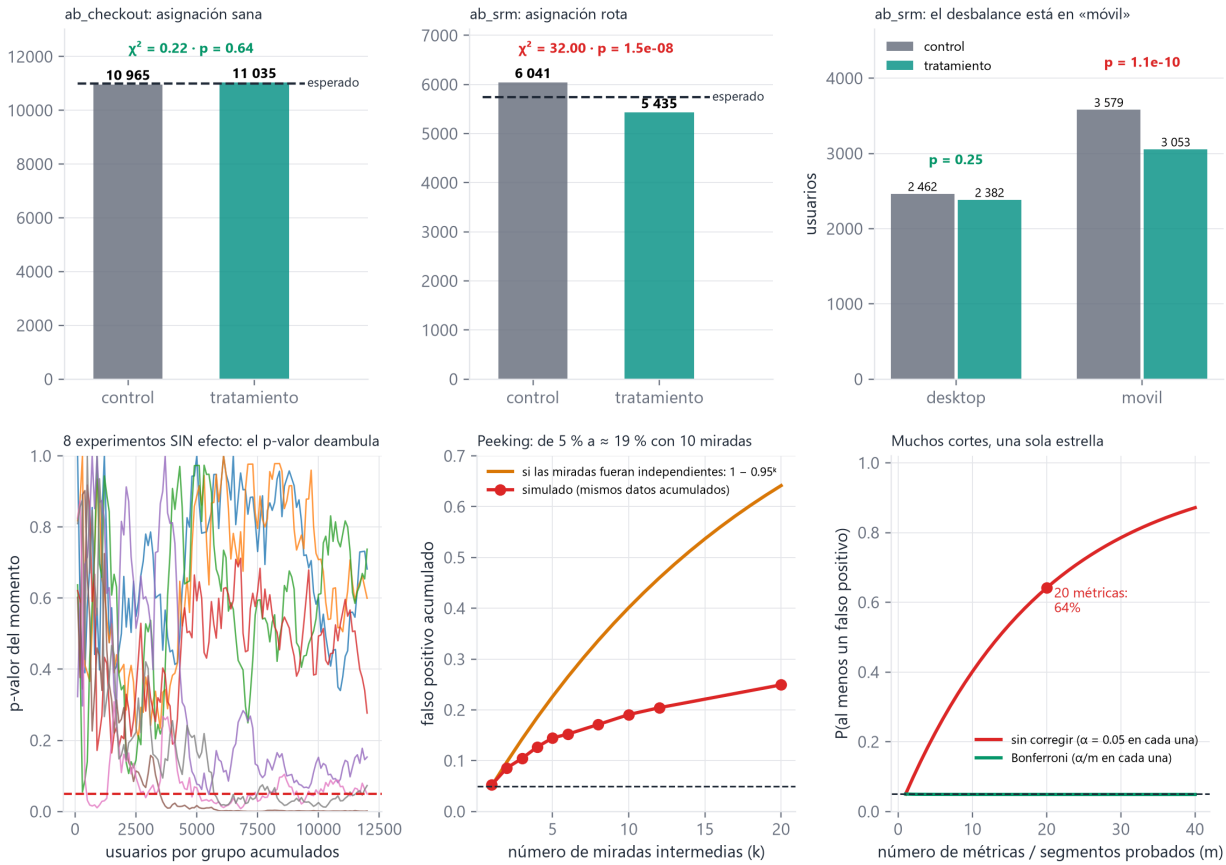
4 SRM y chequeos del diseño

Si el experimento asigna 50/50, los conteos deberían parecerse a 50/50 salvo por azar. El **chi-cuadrado** compara lo observado con lo esperado: $\chi^2 = \Sigma\ (obs - esp)^2/esp$, con (grupos − 1) grados de libertad. Con 2 grupos: $\chi^2 > 3.84 \leftrightarrow p < 0.05$; $\chi^2 > 10.83 \leftrightarrow p < 0.001$ (umbral usual para SRM).

Ejemplo resuelto · dos experimentos 50/50 con 10 000 usuarios

Caso	Cálculo	Resultado
Observado 5 300 / 4 700 (esperado 5 000)	$(300^2/5\,000) + (300^2/5\,000) = 18 + 18$	$\chi^2 = 36.0 \cdot p = 1.97 \times 10^{-9}$
Observado 5 100 / 4 900	$(100^2/5\,000) \cdot 2 = 2 + 2$	$\chi^2 = 4.0 \cdot p = 0.046$

El primero es un SRM claro (p □ 0.001): se audita y no se reporta el efecto. El segundo tiene p = 0.046: bajo 0.05 pero sobre 0.001, así que con la regla práctica no se declara SRM; conviene igual revisar. **Peeking**: mirar el p-valor 10 veces no da 5 % sino ≈ 19 % de falsos positivos (simulado), y con 20 métricas sin corregir, 64 %.



Pista para la Parte C del notebook (C1, C3, C4) y el Bloque 5 del cuaderno

Haz el SRM de ab_checkout y de ab_srm, cruza por dispositivo para localizar el problema y simula el peeking tú mismo.

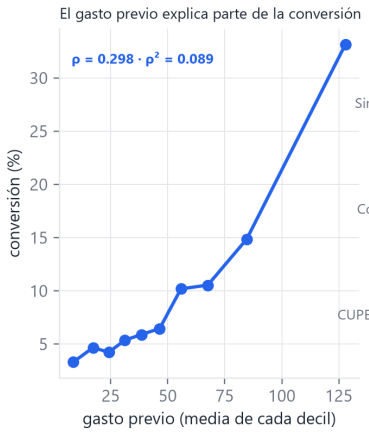
5 Regresión, CUPED y DiD

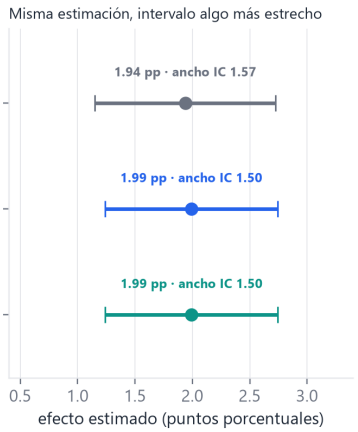
Regresión: con T = 0/1, β_1 del modelo lineal es la diferencia de tasas; agregar covariables previas reduce el error estándar pero no corrige un experimento mal hecho. **CUPED** resta $\theta(X - \bar{X})$ a Y y reduce la varianza en $\approx \rho^2$. **DiD**: efecto = cambio del tratado − cambio del control, bajo tendencias paralelas.

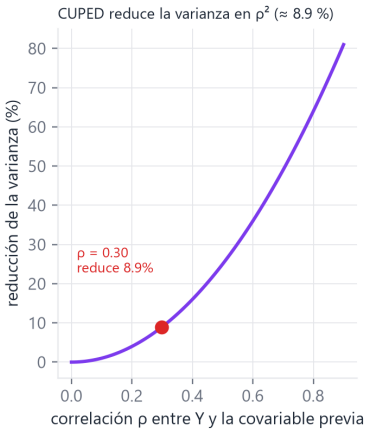
Ejemplo resuelto · tabla 2 × 2 de medias (uso diario en minutos)

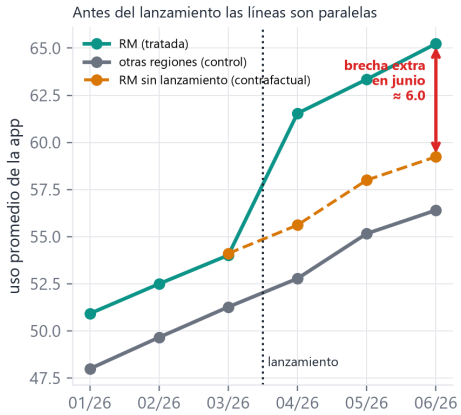
Grupo	Antes	Después	Cambio
Tratado	40	52	+12
Control	38	44	+6
DiD			12 − 6 = +6

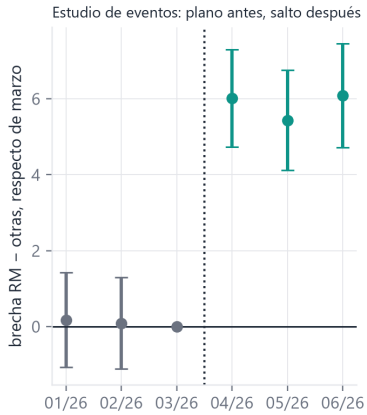
Con CUPED: si ρ = 0.5 entre Y y la covariable previa, la varianza baja $\approx 0.5^2 = 25$ % y el EE a $\sqrt{0.75} = 87$ % del original. El 6 es el efecto *si* el tratado habría subido 6 como el control (tendencias paralelas); comparar solo 52 − 40 = 12 mezclaría efecto y tendencia.











2 × 2 de medias (antes = ene–mar)
DiD = 10.90 − 5.14

	Antes	Después	Δ
RM	52.48	63.37	10.90
Otras	49.64	54.78	5.14
DiD			**5.76**

Pista para las Partes C y D del notebook y los Bloques 6 y 7 del cuaderno

Estima el DiD con la tabla, con `trat * post` y con efectos fijos, y agrupa los errores por comuna.

Lo que debes recordar

- La causalidad sale del **diseño**, no del algoritmo: «buen experimento primero, modelo elegante después».
- R ↔ Python: `prop.test` ↔ `proportions_ztest`; `power.prop.test` ↔ `NormalIndPower`; `chisq.test` ↔ `scipy.stats.chisquare`; `lm` ↔ `smf.ols`; `glm(binomial)` ↔ `smf.logit`.
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–B del notebook → Bloques 5–7 → Partes C–D → ejercicio de cierre.