Ejercicios para el cuaderno · Clase 22 · A/B testing y causalidad aplicada

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: $EE = \sqrt{[\hat{p}_A(1-\hat{p}_A)/n_A + \hat{p}_B(1-\hat{p}_B)/n_B]}$ · $IC = d \pm 1.96 \cdot EE$ · $z = d/\sqrt{[\hat{p}(1-\hat{p})(1/n_A+1/n_B)]}$ · $n = (z_{\alpha/2} + z_{\beta})^2 \cdot [p_1(1-p_1) + p_2(1-p_2)]/(p_2-p_1)^2$ · $\chi^2 = \Sigma(obs-esp)^2/esp$ · $DiD = \Delta_{tratado} - \Delta_{control}$. Constantes: $z_{0.975} = 1.96$, $z_{0.80} = 0.842$, $z_{0.90} = 1.282$; χ^2(1 gl) crítico: 3.84 (5 %) y 10.83 (0.1 %).
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 Pregunta predictiva o causal ★

Clasifica cada pregunta como predictiva, causal o de asociación y explica en una frase.

1. «¿Qué usuarios cancelarán su suscripción el próximo mes?»
2. «¿Aumentan las compras si mostramos las reseñas arriba de la página?»
3. «¿Los clientes que usan la app compran más que los que no la usan?»
4. «Si la tienda A tuvo más ventas que la B después de una promoción, ¿la promoción fue la causa?» ¿Qué faltaría para decirlo?

Bloque 2 Test de dos proporciones a mano ★★★

Un experimento 50/50: control 320 compras de 4 000 usuarios; tratamiento 372 compras de 4 000.

1. Calcula las dos tasas y la diferencia (en puntos porcentuales).
2. Calcula la tasa conjunta $\hat{p}$, el error estándar agrupado y el estadístico z.
3. Con $\alpha = 0.05$ ($|z|$ crítico = 1.96), ¿rechazas H_0: $p_B = p_A$? Calcula el p-valor aproximado con la tabla normal o una calculadora.
4. Redacta la conclusión en una frase para un gerente (sin decir «H_0»).

Bloque 3 Intervalo de confianza para la diferencia ★★

Otro experimento: A 275 conversiones de 2 500 usuarios; B 325 de 2 500.

1. Calcula las tasas, la diferencia y el error estándar de Wald.
2. Construye el IC del 95 % para la diferencia. ¿Contiene el 0?
3. El negocio solo lanzará el cambio si el efecto es al menos +1 pp. ¿Qué dice el IC?
4. Explica con tus palabras qué significa «95 % de confianza» (y una cosa que NO significa).

Bloque 4 Tamaño de muestra por grupo ★★★

Línea base de conversión 20 %; se quiere detectar 23 % (MDE = 3 pp) con $\alpha = 0.05$.

1. Calcula con la fórmula simplificada n por grupo para potencia 80 % y para potencia 90 %.
2. ¿Cuántos usuarios hacen falta en total para potencia 80 %?
3. Si el MDE fuera la mitad (1.5 pp), ¿cuánto vale n con potencia 80 %? ¿Cuántas veces mayor es?
4. El experimento solo puede reunir 1 500 usuarios por grupo. ¿Es suficiente para detectar 3 pp con 80 %? ¿Qué decisión tomarías?

Bloque 5 SRM con chi-cuadrado ★★

Diseño 50/50. Observado: 4 820 usuarios en control y 5 180 en tratamiento (total 10 000).

1. Calcula los conteos esperados y los residuos (observado − esperado).
2. Calcula χ^2 y compáralo con 3.84 y con 10.83.
3. Según la regla práctica de la clase ($p < 0.001$), ¿se reporta el efecto de conversión? ¿Qué harías primero?
4. Un mes después, el SRM da $p = 0.64$. ¿Prueba eso que la aleatorización fue perfecta? Justifica.

Bloque 6 Diferencias en diferencias ★★

Tabla de medias de ventas semanales (en millones) en una cadena: tiendas con la nueva campaña (tratadas) y sin ella (control), antes y después.

1. Tratadas: antes 31, después 45. Control: antes 33, después 39. Calcula el cambio de cada grupo y el DiD.
2. ¿Por qué no basta comparar «después» entre tratadas y control (45 frente a 39)? ¿Y «antes y después» solo de las tratadas?
3. Escribe el modelo de regresión y señala qué coeficiente es el DiD.
4. Nombra el supuesto clave y una evidencia que lo respaldaría.

Bloque 7 Interpretar un p-valor ★★

En un A/B se obtiene una diferencia de +0.4 pp con $p = 0.03$ y n enorme (500 000 por grupo).

1. ¿Verdadero o falso? «Hay un 3 % de probabilidad de que el tratamiento no tenga efecto.»
2. ¿Verdadero o falso? «Si el tratamiento no hiciera nada, ver una diferencia así o mayor ocurriría ≈ 3 % de las veces.»
3. ¿Verdadero o falso? «Como $p < 0.05$, el efecto es grande e importante.» Explica qué mirarías.
4. Con 20 métricas probadas y solo una con $p = 0.03$, ¿qué problema hay y cómo lo corregirías?

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	Predictiva: anticipa un resultado con datos actuales; no pide el efecto de cambiar algo.
2	Causal: pide el efecto de *mover* la página (comparar con y sin reseñas arriba).
3	Asociación: compara grupos que se autoseleccionaron; quienes usan la app pueden ser distintos (confusor).
4	No necesariamente: las tiendas pudieron diferir antes. Faltaría un control comparable y el cambio antes-después (DiD) o, mejor, asignación aleatoria de la promoción.

Bloque 2

#	Solución
1	A: 320/4 000 = 8.00 %. B: 372/4 000 = 9.30 %. Diferencia = +1.30 pp.
2	$\hat{p}$ = (320 + 372)/8 000 = 0.0865. EE = √[0.0865·0.9135·(2/4 000)] = 0.00629. z = 0.0130/0.00629 = 2.07.
3	$\lvert z\rvert$ = 2.07 > 1.96: se rechaza H_0. p ≈ 0.039.
4	«El nuevo diseño subió la conversión de 8.0 % a 9.3 % (+1.3 pp) y esa diferencia es poco compatible con el puro azar (p ≈ 0.04); falta ver cuánto puede valer el efecto (su intervalo) y los guardrails.»

Bloque 3

#	Solución
1	A: 275/2 500 = 11.0 %. B: 325/2 500 = 13.0 %. d = +2.00 pp. EE = √[0.11·0.89/2 500 + 0.13·0.87/2 500] = 0.00919.
2	IC = 2.00 ± 1.96·0.919 = [0.20; 3.80] pp. No contiene el 0.
3	El IC incluye valores bajo 1 pp (desde 0.20): el efecto es positivo, pero con estos datos no se puede asegurar que alcance el 1 pp exigido. Se podría extender el experimento o decidir con el costo de equivocarse.
4	Si repitiéramos el experimento muchas veces, el 95 % de los intervalos construidos así contendría el efecto verdadero. NO significa «95 % de probabilidad de que el efecto esté en este intervalo en particular».

Bloque 4

#	Solución
1	Varianzas: 0.20·0.80 + 0.23·0.77 = 0.3371. Potencia 80 %: $(1.96 + 0.842)^2$ = 7.85 → n = 7.85·0.3371/0.03^2 = 2 940 por grupo. Potencia 90 %: $(1.96 + 1.282)^2$ = 10.51 → 3 936.
2	2 · 2 940 = 5 880 usuarios en total.
3	MDE 1.5 pp: varianzas 0.20·0.80 + 0.215·0.785 = 0.3288 → n = 7.85·0.3288/0.015^2 = 11 469: ≈ 3.9 veces mayor (≈ 4).
4	No: 1 500 < 2 940; la potencia sería ≈ 52 %. Opciones: aceptar un MDE mayor, juntar más tráfico/tiempo o no experimentar (un resultado no significativo sería poco informativo).

Bloque 5

#	Solución
1	Esperados: 5 000 y 5 000. Residuos: 4 820 − 5 000 = −180 y 5 180 − 5 000 = +180.
2	χ^2 = 180^2/5 000 + 180^2/5 000 = 6.48 + 6.48 = 12.96 (1 gl). 12.96 > 3.84 y > 10.83 : sí supera ambos. p = 3.18×10^{-4}.
3	Sí hay SRM (p ≈ 0.0003 < 0.001): no se reporta el efecto de conversión. Primero se audita la infraestructura, la asignación y el registro de datos (¿en qué segmento se pierde el balance?).
4	No. Un p grande indica que no hay evidencia de desbalance en los conteos; no prueba que la aleatorización fuera perfecta (puede haber problemas que no cambian los conteos).

Bloque 6

#	Solución
1	Tratadas: 45 − 31 = +14. Control: 39 − 33 = +6. DiD = 14 − 6 = +8 millones.
2	Comparar «después» (45 frente a 39) mezcla el efecto con la diferencia que ya existía (31 frente a 33). Mirar solo antes-después de las tratadas mezcla el efecto con la tendencia (el control también subió +6).
3	$Y_{it} = \beta_0 + \beta_1 Trat_i + \beta_2 Post_t + \beta_3 (Trat_i \times Post_t) + u_{it}$; el DiD es β_3 (aquí 8).
4	Tendencias paralelas: sin la campaña, las tratadas habrían evolucionado como el control. Evidencia: varios períodos previos con brechas similares (gráfico, estudio de eventos, coeficiente pre-tendencia ≈ 0).

Bloque 7

#	Solución
1	Falso. El p-valor no es la probabilidad de que H_0 sea cierta; se calcula suponiendo H_0 cierta.
2	Verdadero: es la definición (probabilidad, bajo «sin efecto», de un resultado al menos así de extremo).
3	Falso. Con 500 000 por grupo, +0.4 pp puede ser significativo y a la vez pequeño. Se mira el IC y se compara con el MDE y el costo-beneficio.
4	Comparaciones múltiples: con 20 pruebas al 5 %, P(≥ 1 falso positivo) = $1 - 0.95^{20}$ = 64 %. Se corrige (Bonferroni: $\alpha = 0.05/20 = 0.0025$; con p = 0.03 no se rechaza) o se declara una métrica primaria antes.