Apuntes · Clase 24 · Estadística bayesiana, parte 2

Para leer antes de los ejercicios · lectura de ~30 min

Lo más importante, en 6 ideas

1. **Normal–Normal pondera por precisiones.** m_n = promedio de m_0 y $\bar{y}$ con pesos $1/s_0^2$ y n/σ^2; la precisión posterior es la suma.
2. **La predictiva suma incertidumbres.** $\mathrm{Var}(\tilde{Y}) = \sigma^2 + s_n^2$ (Normal): más ancha que usar θ fijo.
3. **Monte Carlo: integral = promedio.** El error baja como $1/\sqrt{M}$; con dependencia, como $1/\sqrt{\mathrm{ESS}}$.
4. **MCMC cuando solo hay una proporcionalidad.** Metropolis: propone, calcula r, acepta con min(1, r).
5. **Revisa la cadena antes de usarla.** Traza, burn-in, autocorrelación, ESS y R-hat de varias cadenas.
6. **Todo sale de las muestras.** Mediana, intervalo creíble, P(β > 0) y odds ratio de la regresión logística.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C24_Bayesiana2.ipynb` o el cuaderno `C24_Ejercicios_Cuaderno_Bayesiana2.pdf`.

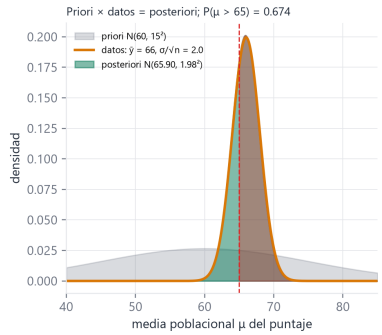
1 Modelo Normal con varianza conocida

Se observa una media muestral $\bar{y}$ de n datos con desviación σ conocida y se tiene una priori $N(m_0, s_0^2)$ para μ. Se convierte todo a **precisiones** (1/varianza): la de la priori es $1/s_0^2$ y la de los datos n/σ^2. La precisión posterior es su suma; la media posterior, el promedio de m_0 y $\bar{y}$ ponderado por precisiones.

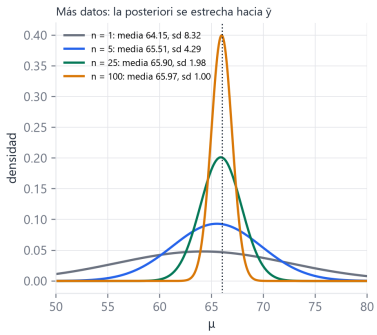
Ejemplo resuelto · tiempo de respuesta: priori $N(100, 20^2)$, σ = 15, n = 9 y $\bar{y}$ = 88

Paso	Cálculo	Resultado
Precisión de la priori	$1/20^2 = 1/400$	0.0025
Precisión de los datos	$9/15^2 = 9/225$	0.0400
Precisión posterior	0.0025 + 0.0400	0.0425 → $s_n^2 = 23.529$, $s_n = 4.851$
Peso de la priori	0.0025/0.0425	w = 0.0588
Media posterior	w·100 + (1 − w)·88	88.706
Intervalo creíble 95 %	$m_n \pm 1.96 \cdot s_n$	[79.20; 98.21]
$P(\mu < 90 \mid y)$	$\Phi((90 - m_n)/s_n)$	0.605

Lectura: los datos pesan 94.1 % y la priori 5.9 %; la media posterior queda entre 100 y 88, muy cerca de 88. **Error común**: promediar m_0 y $\bar{y}$ sin pesos, o usar σ^2 donde la fórmula pide $\sigma/\sqrt{n}$.







Pista para la Parte A del notebook y el Bloque 1 del cuaderno

Calcula m_n y s_n con la función `normal_normal`, verifícalos multiplicando priori × verosimilitud en una grilla y mira cómo cambian con n.

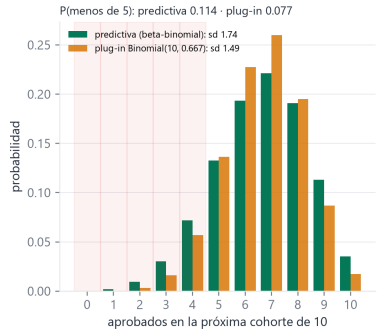
2 Distribución predictiva posterior

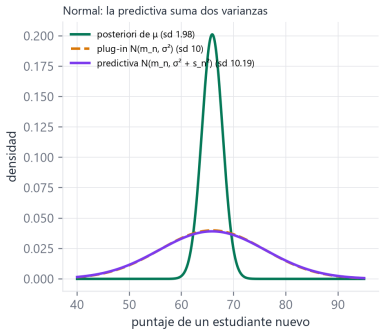
Para predecir una observación nueva se promedian las predicciones de todos los θ posibles, ponderadas por la posteriori. El resultado tiene la variabilidad del azar del dato nuevo **más** la incertidumbre sobre θ. En el caso Beta–Binomial es una distribución beta-binomial; en el Normal–Normal, $N(m_n, \sigma^2 + s_n^2)$.

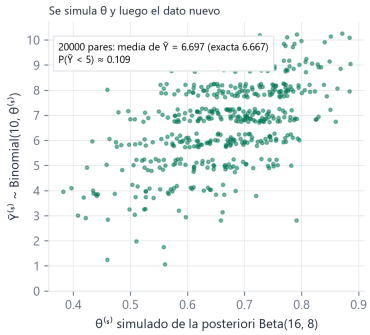
Ejemplo resuelto · posteriori Beta(9, 6) y 8 pacientes nuevos

Paso	Cálculo	Resultado
Media de θ	9/(9 + 6)	0.600
Media predictiva	8·9/(9 + 6)	4.800 pacientes
Varianza predictiva	$8 \cdot 9 \cdot 6 \cdot (23)/((15)^2 \cdot 16)$	2.760
Varianza con θ fijo	8·0.6·0.4	1.920
P(al menos 6 responden)	predictiva	0.358
P(al menos 6)	plug-in Binomial(8, 0.6)	0.315

Lectura: el centro casi no cambia, pero la varianza sube de 1.92 a 2.76 y las colas pesan más. **Error común**: predecir con la media de θ como si fuera conocida; subestima la incertidumbre.







Pista para la Parte A del notebook (A3 y A4) y el Bloque 2 del cuaderno

Simula θ y luego Ỹ, compara con la beta-binomial exacta y con el plug-in, y calcula la predictiva Normal.

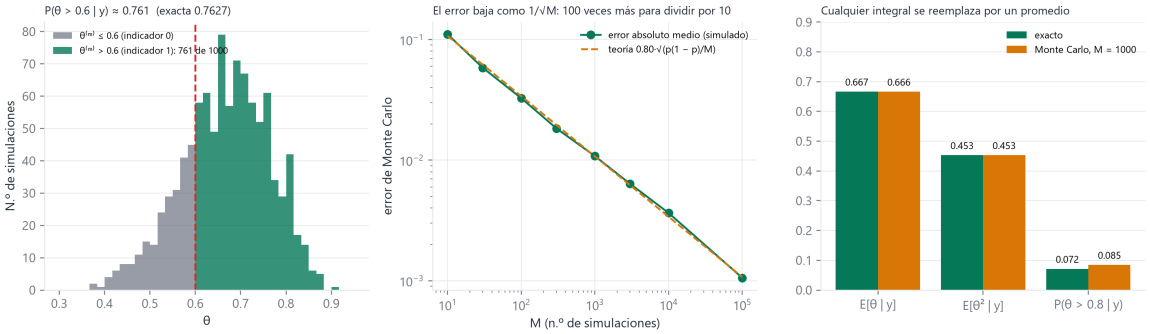
3 Simulación de Monte Carlo

Si se pueden generar M muestras independientes de la posteriori, cualquier esperanza $E[g(\theta) \mid y]$ se aproxima con el promedio de $g(\theta^{(m)})$. Una probabilidad es el caso g = indicador. El error estándar de una proporción simulada es $\sqrt{(\hat{p}(1 - \hat{p})/M)}$.

Ejemplo resuelto · de 4 000 simulaciones de la posteriori, 2 920 superan el umbral 0.5

Paso	Cálculo	Resultado
Estimación	2 920/4 000	$\hat{p} = 0.730$
Error estándar	$\sqrt{(0.73 \cdot 0.27/4\,000)}$	0.0070
Intervalo de simulación 95 %	$\hat{p} \pm 1.96 \cdot SE$	[0.716; 0.744]
M para SE ≤ 0.002	$0.73 \cdot 0.27/0.002^2$	M ≥ 49 275
Si hay autocorrelación	ESS = 800 en vez de 4 000	SE = 0.0157

Lectura: dividir el error por 2 exige 4 veces más simulaciones. Con una cadena, el tamaño que cuenta es el efectivo. **Error común**: confundir el error de simulación (cálculo) con la incertidumbre sobre θ (la posteriori).



Pista para la Parte B del notebook y el Bloque 3 del cuaderno

Reproduce 0.7627 con la cola exacta y por simulación y mide cómo baja el error con M; añade la comparación A/B por simulación.

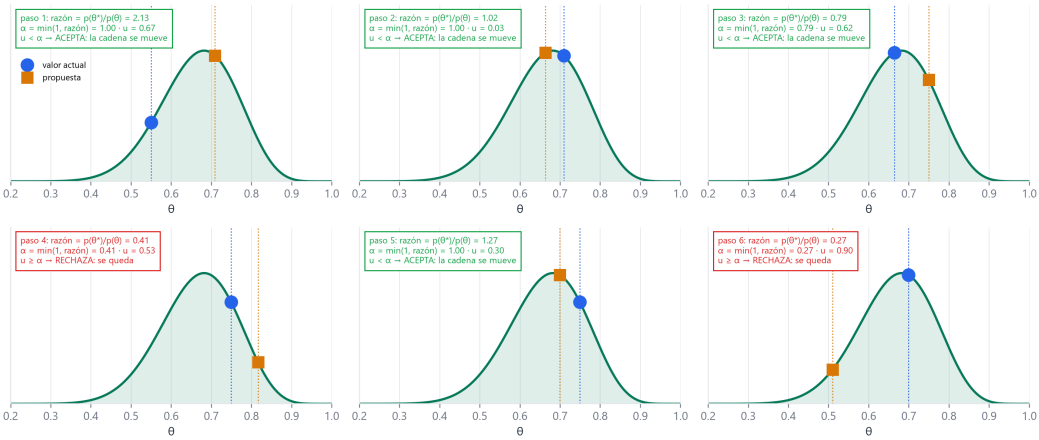
4 Metropolis a mano

Basta el núcleo de la posteriori (sin constante). Para un paso: proponer θ*, calcular r = núcleo(θ*)/núcleo(θ), α = min(1, r); si u < α se acepta, si no la cadena repite el valor actual. Una propuesta fuera del soporte tiene núcleo 0 y se rechaza.

Ejemplo resuelto · núcleo $\theta^8(1-\theta)^3$ (una Beta(9, 4)); actual 0.60

Paso	Cálculo	Resultado
Propuesta θ* = 0.72	$0.72^8 \cdot 0.28^3$ / $(0.60^8 \cdot 0.40^3)$	r = 1.475
Probabilidad de aceptar	min(1, r)	α = 1.000
Decisión con u = 0.30	u < α	acepta: θ pasa a 0.72
Siguiente propuesta θ* = 0.45	$0.45^8 \cdot 0.55^3$ / $(0.72^8 \cdot 0.28^3)$	r = 0.176
Con u = 0.40	u ≥ 0.176	rechaza: la cadena se queda en 0.72
Propuesta θ* = 1.10	fuera de (0, 1): núcleo 0	r = 0 → rechaza

Lectura: se sube siempre que la propuesta es más plausible; se baja con probabilidad r. Rechazar no es un error: la repetición del valor es parte de la cadena. **Error común**: omitir los rechazos al guardar la cadena.



Pista para la Parte C del notebook (C2 y C3) y el Bloque 4 del cuaderno

Programa tu propio paso, repítelo 5 000 veces y compara el histograma con la Beta exacta; luego prueba tres tamaños de paso.

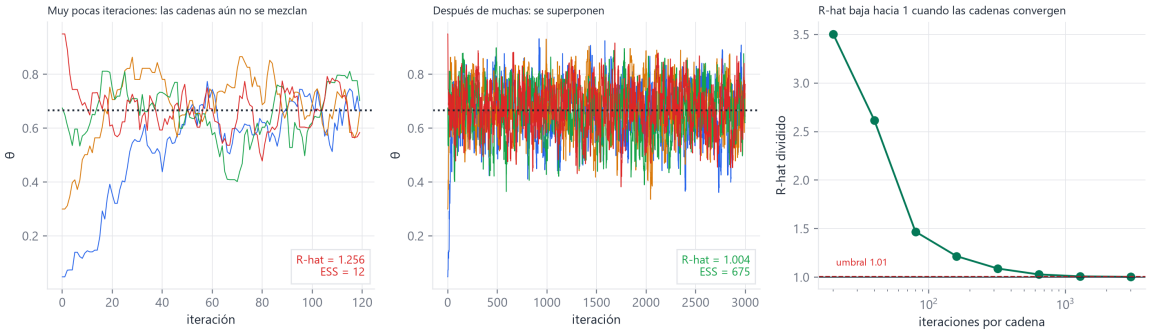
5 Leer una cadena: traza, burn-in, ESS y R-hat

Un buen ajuste cumple a la vez: trazas estables que se superponen entre cadenas, R-hat ≈ 1 (< 1.01), ESS suficiente (cientos como mínimo) y una aceptación razonable. El burn-in se descarta; el thinning no mejora la información.

Ejemplo resuelto · tres ajustes del mismo coeficiente (4 cadenas × 2 000 iteraciones)

Ajuste	R-hat · ESS · aceptación · traza	Decisión
A	1.003 · 1 450 · 33 % · oruga estable, cadenas superpuestas	Usar; ESS ≈ 18 % del total, aceptable
B	1.12 · 28 · 95 % · tramos suaves y cadenas separadas	No usar: paso pequeño y sin convergencia; aumentar el paso y correr más
C	1.002 · 90 · 4 % · tramos planos y saltos	Cuidado: R-hat bueno pero ESS bajo y casi todo rechazado; reducir el paso

Lectura: ningún criterio basta solo. R-hat compara cadenas; el ESS mide información; la aceptación orienta el tamaño de paso. **Error común**: fiarse de R-hat cuando el ESS es minúsculo.



Pista para la Parte C del notebook (C4 a C7) y los Bloques 5 y 6 del cuaderno

Calcula ESS y R-hat con la función entregada, cambia el tamaño de paso y observa cómo cambian las cuatro cifras.

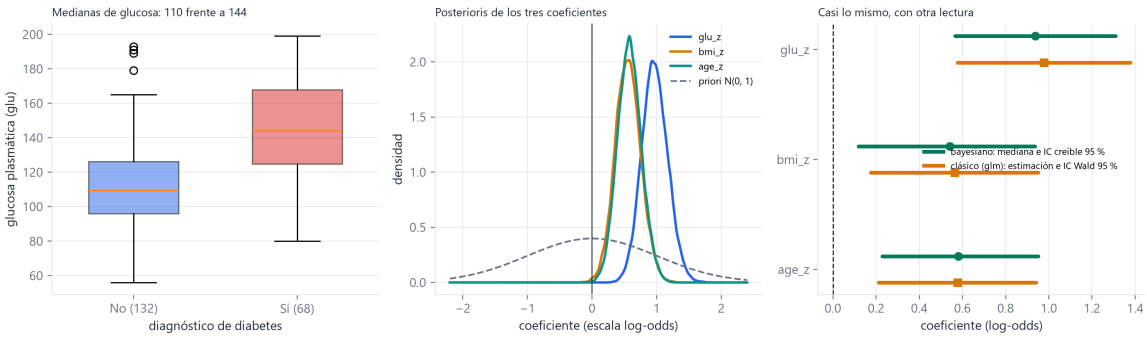
6 Resumir la posteriori con muestras: regresión logística bayesiana

Con las muestras de un coeficiente β: la **mediana** es el estimador, los cuantiles 2.5 % y 97.5 % dan el intervalo creíble, la fracción de muestras > 0 es P(β > 0 | y) y el **odds ratio** sale de exp(β). Con predictores estandarizados, el OR es por una desviación estándar.

Ejemplo resuelto · coeficiente β con mediana 0.42 e intervalo creíble 95 % [0.10; 0.75]; el 99.2 % de las muestras es positivo

Pregunta	Cálculo	Resultado
Odds ratio	exp(0.42)	1.522
IC creíble del OR	exp(0.10) y exp(0.75)	[1.105; 2.117]
P(β > 0 | y)	fracción de muestras > 0	0.992
Lectura del OR	exp(0.42) = 1.52	+1 sd en el predictor multiplica los odds por 1.52
Interpretación del IC	95 % de probabilidad	dados el modelo, la priori y los datos

Lectura: el intervalo no contiene 0 ni (para el OR) 1: hay asociación positiva. **Error común**: decir que el OR es el cambio en la *probabilidad*, o llamar «de confianza» a un intervalo creíble.



Pista para la Parte D del notebook y el Bloque 7 del cuaderno

Reproduce los resultados de la profesora (medianas −0.921, 0.966, 0.548 y 0.573) y compara con glm y con el bootstrap.

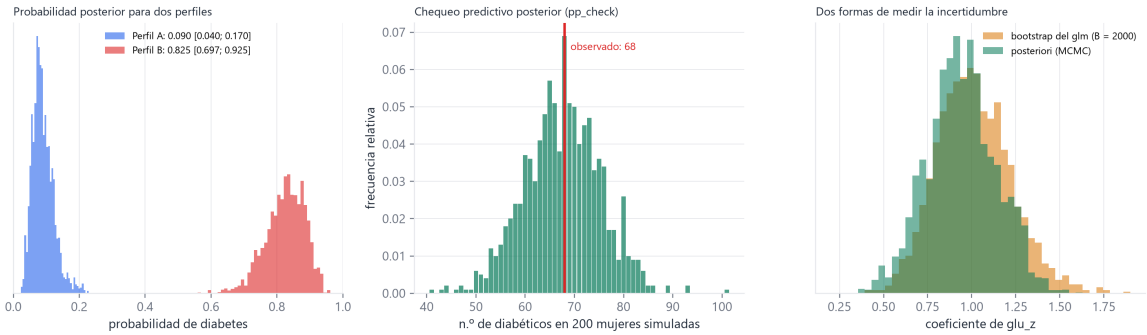
7 Puentes: los mismos datos, dos lecturas

Con 200 observaciones y prioris suaves, la posteriori y la máxima verosimilitud casi coinciden; cambia **qué significa** el intervalo y qué se puede preguntar. Los números son los de este material con los datos Pima (4 cadenas de 25 000 iteraciones, descartando las 5 000 primeras).

Ejemplo resuelto · regresión logística de diabetes con Pima.tr

Coeficiente	glm clásico: estimación [IC 95 % de Wald]	bayesiano: mediana [IC creíble 95 %]	valor p · P(β > 0 | y)
glu_z	0.977 [0.577; 1.377]	0.966 [0.587; 1.378]	0.0000 · 1.000
bmi_z	0.563 [0.176; 0.951]	0.554 [0.178; 0.951]	0.0044 · 0.999
age_z	0.577 [0.212; 0.942]	0.578 [0.227; 0.950]	0.0020 · 1.000

Lectura: el valor p responde «¿qué tan raro sería este dato si β fuera 0?»; P(β > 0 | y) responde «¿qué tan probable es que β sea positivo?». El bootstrap del glm (B = 2000) da para glu_z una desviación de 0.210 y la posteriori 0.196: dos formas de medir la incertidumbre que aquí coinciden. **Error común**: pensar que una priori «débil» deja de influir en muestras pequeñas; con n = 200 casi no se nota.



Pista para la Parte D del notebook (D8)

Compara las posterioris con el glm y con el bootstrap y repite con una priori más fuerte, $N(0, 0.25^2)$, para ver cuándo la priori sí cambia el resultado.

Lo que debes recordar

- Normal–Normal: sumar precisiones; media = promedio ponderado por precisiones.
- Predictiva: Var = (variabilidad del dato) + (incertidumbre de θ).
- Monte Carlo: integral → promedio; error ∝ 1/√M (o 1/√ESS en una cadena).
- Metropolis: r = núcleo(θ*)/núcleo(θ); α = min(1, r); u < α → acepta; si no, repite.
- Cadena: traza, burn-in, autocorrelación, ESS, varias cadenas y R-hat < 1.01.
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–B del notebook → Bloques 5–7 → Partes C–D → ejercicio de cierre.