Ejercicios para el cuaderno · Clase 30 · Preparación para Machine Learning

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: precision = TP/(TP+FP) · recall = TP/(TP+FN) · F1 = 2PR/(P+R) · z = (x − media)/desviación.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 Tipos de variables ★

1. Clasifica: (a) número de cuotas pagadas, (b) comuna, (c) saldo de la cuenta, (d) segmento «bronce/plata/oro», (e) ¿tiene tarjeta? Sí/No.
2. ¿Cuántas columnas genera el one-hot de «comuna» si hay 12 comunas distintas? ¿Y de la variable binaria (e)?

Bloque 2 Calidad e imputación ★★

1. Ingresos observados (M CLP): 2.1, 2.3, 2.4, 2.6, 12.0 y un faltante. Calcula media y mediana y elige con qué imputar.
2. Elige media, mediana o moda: (a) edad, simétrica; (b) región; (c) gasto con atípicos. Una base de 600 filas tiene 220 sin dato de ingreso: ¿imputas?
3. Identifica la dimensión que falla: (a) dos sistemas con direcciones distintas; (b) un 15 % sin teléfono; (c) edad = 190; (d) tarifa de hace 3 años.

Bloque 3 División de datos ★

1. 2.400 registros, división 70/15/15: ¿cuántos en cada conjunto? Y con 5.000 registros y 80/10/10.
2. Un modelo tiene R^2 0.97 en entrenamiento y 0.64 en validación. ¿Qué pasa y qué no debes hacer para «arreglarlo»?

Bloque 4 Estandarización y regularización ★★

1. Superficie: media 90, desviación 25. Calcula z para 140 y para 65. Habitaciones: media 3, desviación 1.5; z para 6.
2. Ridge con $\alpha = 2$: un coeficiente 0.5 por m^2 frente a 50 por centena de m^2. Calcula $\alpha \cdot \beta^2$ en cada caso. ¿Cuál se castiga más y por qué conviene estandarizar?
3. ¿Cuándo preferirías Lasso y cuándo Ridge?

Bloque 5 K-Fold ★★

Puntajes R^2 de un K-Fold de 5 pliegues: 0.71, 0.78, 0.74, 0.69, 0.78.

1. Calcula el promedio y la desviación (ddof = 0).
2. ¿Cuántas filas valida y entrena cada pliegue con 500 filas? ¿Qué te dice la desviación y qué conjunto no se usa en el K-Fold?

Bloque 6 Estratificación ★★

1. 800 casos con 4 % de fraude y prueba de 25 %. ¿Cuántos fraudes hay en total, en la prueba y en el entrenamiento si se estratifica?
2. Sin estratificar, ¿puede la prueba quedar sin fraudes? Explica por qué esto es grave para el recall.
3. ¿Estratificar aumenta la cantidad de fraudes? Justifica.

Bloque 7 Métricas ★★★

1.000 casos: TP = 24, FP = 16, FN = 6, TN = 954.

1. Calcula accuracy, precision, recall y F1.
2. Calcula el accuracy de un modelo que siempre predice «no fraude» y compáralo con el anterior.
3. El costo de un fraude no detectado es 50 veces el de una falsa alarma. ¿Qué métrica priorizas y qué harías con el umbral?

Bloque 8 Fuga de datos ★★★

1. Entrenamiento: 50, 55, 60 (media 55, desviación 4.08). Prueba: 90. Calcula z correcto y z con las 4 filas (media 63.75, desviación 15.56).
2. ¿Fuga o no? (a) imputar la mediana con todo el dataset y luego dividir; (b) ajustar el scaler solo con entrenamiento; (c) elegir alpha mirando la prueba; (d) hacer K-Fold con un Pipeline.
3. Escribe en una frase por qué un Pipeline evita la fuga en K-Fold.

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	(a) numérica discreta · (b) categórica nominal · (c) numérica continua · (d) categórica ordinal (hay orden) · (e) categórica binaria.
2	Comuna: 12 columnas (una por categoría; con `drop='first'` serían 11). La binaria: 1 columna 0/1.

Bloque 2

#	Solución
1	Media = (2.1 + 2.3 + 2.4 + 2.6 + 12.0)/5 = 21.4/5 = 4.28. Mediana = 2.4. El 12.0 arrastra la media: se imputa con la mediana 2.4.
2	(a) media · (b) moda · (c) mediana. 220 de 600 = 36.7 %, más de un tercio: no se imputa a ciegas; se revisa la recolección o se analiza con otro enfoque.
3	(a) coherencia · (b) completitud · (c) exactitud · (d) frescura.

Bloque 3

#	Solución
1	2.400: 0.70 → 1.680 · 0.15 → 360 · 360. 5.000: 4.000 · 500 · 500.
2	Brecha de 0.33: sobreajuste. No se «arregla» mirando la prueba (fuga); se simplifica el modelo, se regulariza o se consiguen más datos, decidiendo con la validación.

Bloque 4

#	Solución
1	$z(140) = (140 - 90)/25 = 2.0$ · $z(65) = -25/25 = -1.0$ · $z(6) = (6 - 3)/1.5 = 2.0$.
2	0.5 por m^2: $2 \cdot 0.5^2 = 0.5$. 50 por centena: $2 \cdot 50^2 = 5.000$. Se castiga 10.000 veces más el mismo efecto: sin escala común la penalización depende de las unidades; se estandariza.
3	Lasso: sospecho muchas variables irrelevantes y quiero un modelo más simple (puede anular coeficientes). Ridge: casi todas aportan algo y quiero estabilizar sin eliminar.

Bloque 5

#	Solución
1	Promedio = 3.70/5 = 0.74. Desviaciones: −0.03, 0.04, 0, −0.05, 0.04 → cuadrados 0.0009 + 0.0016 + 0 + 0.0025 + 0.0016 = 0.0066; /5 = 0.00132 → desviación 0.036.
2	Valida 100 y entrena 400 en cada pliegue. Una desviación de 0.036 sobre 0.74 indica estabilidad moderada. El conjunto de prueba no se usa en el K-Fold.

Bloque 6

#	Solución
1	0.04·800 = 32 fraudes · prueba 0.25·800 = 200 filas → 0.04·200 = 8 · entrenamiento 600 filas → 24.
2	Sí, el azar puede dejar muy pocos o ninguno (en un ejemplo con 200 filas y 12 fraudes, 2.2 % de las particiones). Sin positivos el recall no se puede calcular.
3	No: la cantidad total es la misma; solo se conserva la proporción en cada parte.

Bloque 7

#	Solución
1	Accuracy = (24 + 954)/1.000 = 0.978 · precision = 24/40 = 0.600 · recall = 24/30 = 0.800 · F1 = 2·0.6·0.8/1.4 = 0.96/1.4 = 0.686.
2	Siempre «no fraude»: 970/1.000 = 0.970 (hay 30 fraudes). El modelo solo mejora 0.008 en accuracy, aunque detecta 24 de 30 fraudes.
3	Recall: un fraude perdido cuesta 50 veces una falsa alarma. Se baja el umbral para subir el recall, aceptando más falsas alarmas, y el umbral se elige en validación.

Bloque 8

#	Solución
1	Correcto: (90 − 55)/4.08 = 8.57. Con fuga: (90 − 63.75)/15.56 = 1.69. La fuga esconde el atípico.
2	(a) fuga · (b) no · (c) fuga · (d) no.
3	En cada pliegue el Pipeline hace fit solo con el entrenamiento de ese pliegue y transform en el de validación; nada del pliegue de validación influye en los pasos aprendidos.