# Apuntes · Clase 31 · Introducción al Machine Learning

Para leer antes de los ejercicios · lectura de ~30 min

**Lo más importante, en 6 ideas**

1. **El tipo de problema decide el modelo.** Etiqueta categórica → clasificación; etiqueta numérica → regresión; sin etiqueta → clustering o reducción; recompensas → refuerzo.
2. **Probabilidad antes que clase.** La logística calcula un puntaje, la sigmoide lo vuelve probabilidad y el umbral decide.
3. **Siempre se mide el error en datos nuevos.** Entrenar con un conjunto, evaluar con otro; todo lo que se aprende, solo con entrenamiento.
4. **K-Means: asignar y promediar.** Cada punto al centroide más cercano; cada centroide pasa a ser la media de su grupo; se repite.
5. **Complejidad y penalización.** Mucha complejidad memoriza ruido; Ridge encoge y Lasso anula coeficientes.
6. **Accuracy no basta.** Con clases desbalanceadas se mira la matriz de confusión, el recall, la precisión y una línea base.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C31_IntroML.ipynb` o el cuaderno `C31_Ejercicios_Cuaderno_IntroML.pdf`.

## 1 Del problema a la tarea de ML

Antes de elegir un algoritmo hay que preguntarse qué se quiere predecir y con qué datos. Una **regla fija** dice qué hacer ante ciertas condiciones; un **modelo** ajusta sus parámetros con ejemplos. Si hay variable objetivo, es **supervisado** (**clasificación** si es categoría, **regresión** si es número); si no, **no supervisado** (**clustering** para formar grupos, **reducción de dimensionalidad** para resumir variables); y con un entorno que da recompensas, **refuerzo**.

**Ejemplo resuelto · cuatro situaciones de una tienda**

| Situación | Tipo de problema | Por qué |
|---|---|---|
| Saber si una compra online es fraude (hay historial marcado) | supervisado · clasificación | la etiqueta es sí / no |
| Estimar cuánto dinero gastará un cliente en diciembre | supervisado · regresión | la salida es un número |
| Descubrir tipos de clientes sin categorías previas | no supervisado · clustering | no hay etiqueta |
| Un sistema prueba precios y aprende de las ventas | refuerzo | acción → recompensa → ajuste |

Y si el problema se resuelve con una resta o una tabla de reglas que ya funciona, no hace falta ML: «no uses IA porque está de moda».



**Pista para la Parte A del notebook y el Bloque 1 del cuaderno**
Clasifica los casos, usa `recomendar_enfoque` con tu regla fija y pregúntate qué etiqueta tendrías que registrar hoy para entrenar un modelo mañana.

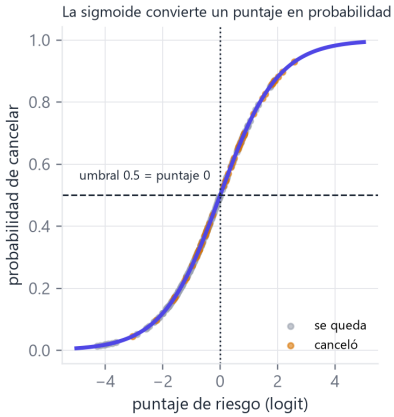
## 2 Regresión logística y la sigmoide

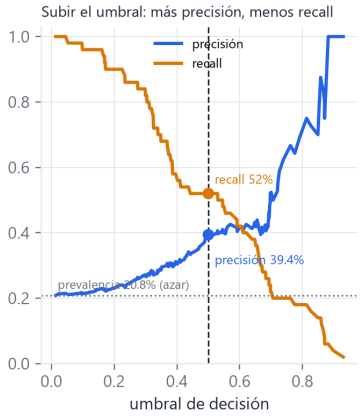
La regresión logística calcula un **puntaje** $z = b_0 + b_1x_1 + \dots$ y lo transforma en una probabilidad con $\mathbf{p = 1/(1 + e^{-z})}$. Si $z = 0$, $p = 0.5$; $z$ grande y positivo acerca $p$ a 1; $z$ muy negativo, a 0. Con un umbral de 0.5 se predice «cancela» cuando $z > 0$. Cada coeficiente multiplica las *odds* $(p/(1-p))$ por $e^b$ por cada unidad adicional de la variable.

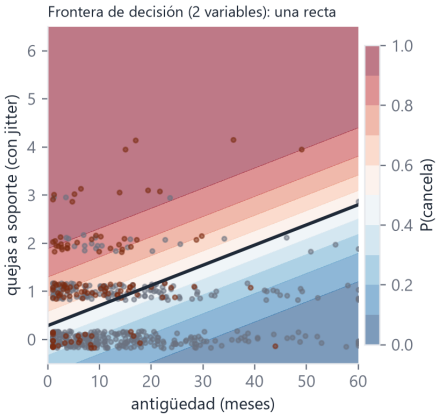
**Ejemplo resuelto · $z = -1.0 + 1.5\cdot$quejas $- 0.2\cdot$uso**

| Pregunta | Cálculo | Resultado |
|---|---|---|
| Cliente con 2 quejas y 6 usos: puntaje | $-1.0 + 1.5\cdot2 - 0.2\cdot6$ | $z = 0.8$ |
| Su probabilidad de cancelar | $1/(1 + e^{-0.8}) = 1/(1 + 0.449)$ | $p = 0.690$ |
| Cliente con 0 quejas y 8 usos | $z = -1.0 + 0 - 1.6 = -2.6 \to 1/(1 + e^{2.6})$ | $p = 0.069$ |
| Efecto de una queja más | $e^{1.5}$ | odds × 4.48 |
| Umbral 0.5: clases predichas | $z > 0$ ⇔ $p > 0.5$ | cancela / se queda |

Un cliente con $p = 0.69$ «cancela» con umbral 0.5, pero con umbral 0.7 ya no. Bajar el umbral detecta más cancelaciones (más recall) y genera más falsas alarmas.




**Pista para la Parte B del notebook (B1 y B2) y el Bloque 2 del cuaderno**
Ajusta la logística dentro de un Pipeline, imprime `predict_proba` de dos clientes y comprueba a mano que $1/(1 + e^{-z})$ coincide.

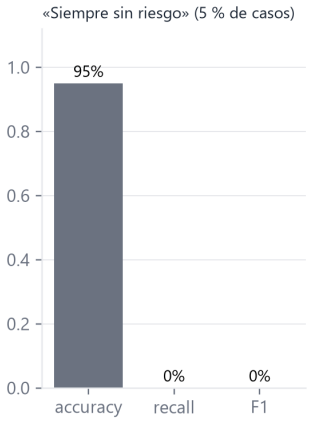
## 3 Matriz de confusión y métricas

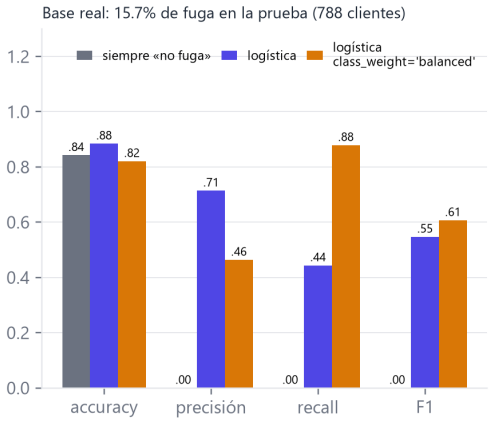
Se cuentan cuatro tipos de resultado: verdaderos positivos (VP), falsos positivos (FP), falsos negativos (FN) y verdaderos negativos (VN). **Accuracy** = (VP+VN)/total; **precisión** = VP/(VP+FP); **recall** = VP/(VP+FN); **F1** = media armónica de ambas. Con clases muy desiguales el accuracy engaña: hay que compararlo con la **línea base** «siempre la clase mayoritaria».

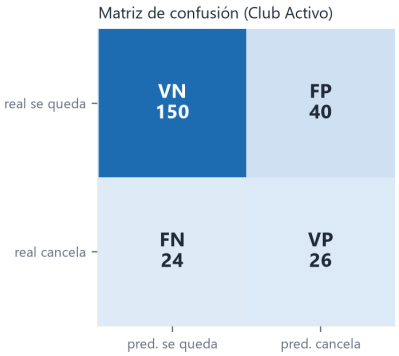
**Ejemplo resuelto · 500 transacciones, 20 fraudes**

| Pregunta | Cálculo | Resultado |
|---|---|---|
| Modelo: VP 12, FN 8, FP 30, VN 450 · accuracy | (12 + 450)/500 | 92.4 % |
| Precisión | 12/(12 + 30) | 28.6 % |
| Recall | 12/(12 + 8) | 60.0 % |
| F1 | 2·0.286·0.60/(0.286 + 0.60) | 0.387 |
| Línea base «nunca hay fraude»: accuracy · recall | 480/500 · 0/20 | 96.0 % · 0 % |

El modelo «pierde» en accuracy contra la línea base (92.4 % frente a 96 %) pero es el único que detecta fraudes. En la base real de churn, «nadie se fuga» ya da 84.3 % de accuracy.




**Pista para la Parte D del notebook (D3) y el Bloque 6 del cuaderno**

Usa `DummyClassifier` como línea base, imprime la matriz de confusión con `confusion_matrix` y calcula a mano las cuatro métricas.

## 4 K-Means a mano: una iteración

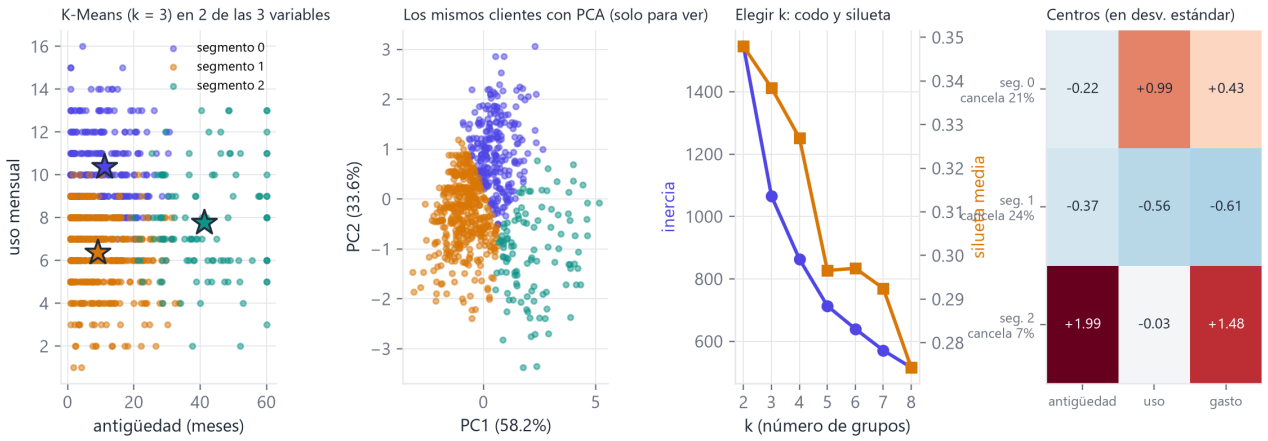
K-Means necesita k, un punto de partida (los centroides) y distancias. Cada iteración: (1) **asignar** cada punto al centroide más cercano; (2) **recalcular** cada centroide como la media de sus puntos. Se detiene cuando las asignaciones ya no cambian. Se compara con la **inercia**: suma de distancias² de cada punto a su centroide. Y se escala antes: es un método basado en distancias.

**Ejemplo resuelto · seis puntos (antigüedad, uso) y k = 2**

A(1, 2), B(2, 1), C(2, 4), D(7, 7), E(8, 9), F(9, 6); centroides iniciales c1 = A y c2 = F.

| Pregunta | Cálculo (distancia²) | Resultado |
|---|---|---|
| B a c1 y c2 | $(1^2 + 1^2) = 2 \cdot (7^2 + 5^2) = 74$ | B → c1 |
| C a c1 y c2 | $(1^2 + 2^2) = 5 \cdot (7^2 + 2^2) = 53$ | C → c1 |
| D, E a c1 y c2 | D: 61 vs 5 · E: 98 vs 10 | D, E → c2 |
| Nuevo c1 | ((1 + 2 + 2)/3, (2 + 1 + 4)/3) | (1.67, 2.33) |
| Nuevo c2 | ((7 + 8 + 9)/3, (7 + 9 + 6)/3) | (8.00, 7.33) |

Con los nuevos centroides las asignaciones no cambian: el algoritmo terminó. En un caso real se repite con varios puntos de partida (`n_init`) y se queda con la menor inercia.




**Pista para la Parte C del notebook y el Bloque 3 del cuaderno**

Reproduce una iteración con NumPy, compara la inercia antes y después y prueba K-Means con y sin `StandardScaler` (ARI 0.39 entre ambos).

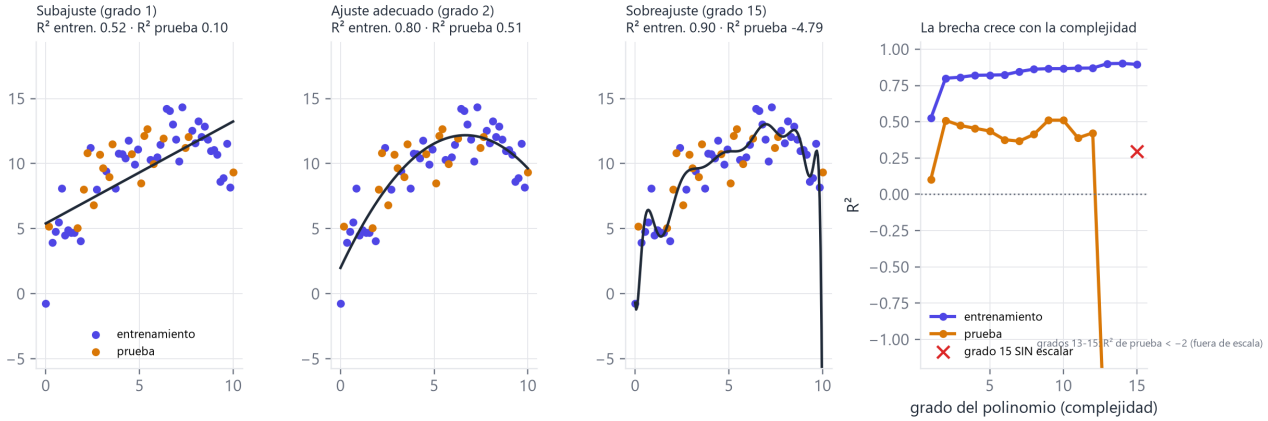
## 5 Subajuste, sobreajuste, Ridge y Lasso

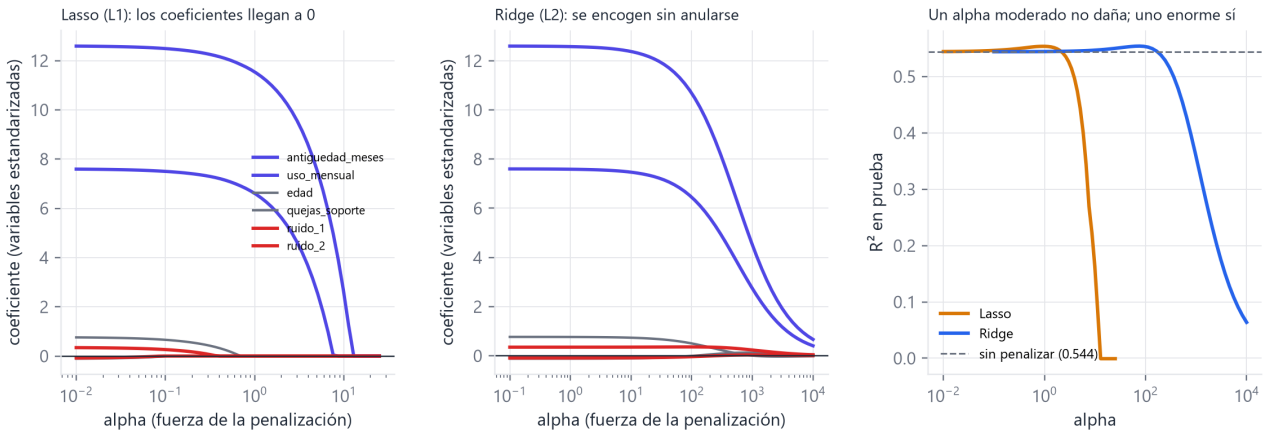
El **subajuste** aparece cuando el modelo falla incluso en entrenamiento; el **sobreajuste**, cuando acierta en entrenamiento y falla en prueba. La **regularización** añade al error una penalización: Ridge (L2) suma $\alpha \cdot \Sigma \beta^2$ y Lasso (L1), $\alpha \cdot \Sigma |\beta|$. En el caso simple de columnas ortonormales, Ridge deja $\beta/(1 + \alpha)$ y Lasso aplica un *umbral suave*: $\text{signo}(\beta) \cdot \max(|\beta| - \alpha, 0)$. Por eso Lasso anula coeficientes pequeños y Ridge no.

**Ejemplo resuelto · coeficientes de una regresión con $\alpha = 1$**

| Variable | OLS | Ridge $\beta/(1 + 1)$ | Lasso $\max(\lvert\beta\rvert - 1, 0)$ |
|---|---|---|---|
| $x_1$ | 5.0 | 2.50 | 4.0 |
| $x_2$ | −1.4 | −0.70 | −0.4 |
| $x_3$ | 0.6 | 0.30 | 0 (anulado) |
| Suma de \|coef.\| | 7.0 | 3.50 | 4.4 |

Con $\alpha = 1$, Ridge divide todo por 2 (ninguno se anula); Lasso resta 1 y deja en cero $x_3$ ($|0.6| < 1$). Un $\alpha$ demasiado grande hace que los dos converjan a predecir la media ($R^2 \approx 0$).






**Pista para la Parte D del notebook (D1 y D2) y los Bloques 4 y 5 del cuaderno**

Ajusta polinomios de grado 1 a 15 con y sin escalar, dibuja el $R^2$ de entrenamiento y prueba, y compara los coeficientes de OLS, Ridge y Lasso con ruido añadido.

## 6 Elegir el enfoque: ML o Deep Learning

El Deep Learning es un subconjunto del ML basado en redes con varias capas: aprende representaciones directamente de datos complejos (imágenes, audio, texto), pero necesita más datos, más cómputo y es menos interpretable. Para datos tabulares con miles de filas, un modelo clásico suele bastar. El orden de preguntas: ¿hay etiqueta?, ¿es categoría o número?, ¿hay entorno con recompensas?, ¿es un problema de datos complejos?, ¿qué métrica demuestra que supera a la regla actual?

**Ejemplo resuelto · tres propuestas de la dirección**

| Propuesta | Enfoque razonable | Por qué |
|---|---|---|
| Predecir ventas semanales con 3 años de historia tabular | regresión (o series de tiempo) | pocos miles de filas; ML clásico basta |
| Clasificar 2 millones de fotos de productos | Deep Learning | datos complejos y gran volumen |
| Calcular un descuento fijo según una tabla de reglas | sin ML | una regla ya resuelve el problema |

**Lo que debes recordar**

- Sesión 32 trata PCA y t-SNE en profundidad; aquí solo se usó PCA para mirar los segmentos.
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–C del notebook → Bloques 5–7 → Parte D → ejercicio de cierre.