Ejercicios para el cuaderno · Clase 31 · Introducción al Machine Learning

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: $p = 1/(1 + e^{-z})$ · accuracy = (VP+VN)/total · precisión = VP/(VP+FP) · recall = VP/(VP+FN) · F1 = 2PR/(P+R) · $R^2 = 1 - SSE/SST$ · Ridge: $\beta/(1+\lambda)$ · Lasso: signo(β)·máx(|β|−λ, 0).
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 Clasificar problemas ★

Indica el tipo de problema: clasificación, regresión, clustering, reducción de dimensionalidad, refuerzo o Deep Learning.

1 (a) Decidir si un correo es spam · (b) estimar los minutos que demorará un pedido · (c) agrupar tiendas según su perfil de ventas, sin categorías previas · (d) resumir 40 indicadores de una encuesta en 3 factores para graficarlos · (e) un robot aprende a caminar con premios por avanzar · (f) reconocer objetos en 2 millones de fotos.

2 Para los problemas supervisados, nombra la variable objetivo y una métrica adecuada.

Bloque 2 La sigmoide a mano ★★

Modelo: $z = -1.2 + 0.8 \cdot \text{quejas} - 0.1 \cdot \text{uso}$. Cliente A: 3 quejas y 5 usos. Cliente B: 0 quejas y 10 usos.

1 Calcula el puntaje y la probabilidad de cancelar de A y de B.

2 ¿Cuánto se multiplican las odds por cada queja adicional?

3 Con umbral 0.5 y luego con 0.3, ¿qué clase predice el modelo para cada cliente?

Bloque 3 Una iteración de K-Means ★★★

Puntos (antigüedad, uso): P1(1, 2), P2(2, 4), P3(3, 3), P4(6, 5), P5(7, 8), P6(8, 6). Centroides iniciales c1 = (1, 1) y c2 = (8, 8).

1 Asigna cada punto con la distancia euclidiana al cuadrado y calcula la inercia.

2 Recalcula los centroides y la nueva inercia. ¿Cambian las asignaciones?

3 Si «antigüedad» estuviera en días (valores de 365 a 3.650) y «uso» en veces, ¿qué problema aparecería? ¿Cómo se evita?

Bloque 4 Leer subajuste y sobreajuste ★★

R^2 de entrenamiento / prueba según el grado de un polinomio: grado 1: 0.52 / 0.50 · grado 2: 0.80 / 0.78 · grado 4: 0.84 / 0.74 · grado 8: 0.93 / 0.31 · grado 15: 0.99 / −0.60.

1 ¿Qué grado muestra subajuste, cuál un ajuste adecuado y cuál sobreajuste? Justifica con la brecha.

2 ¿Qué grado elegirías y por qué no el de mayor R^2 de entrenamiento?

3 Nombra dos acciones que reduzcan el sobreajuste del grado 15.

Bloque 5 Ridge frente a Lasso ★★

Coeficientes de una regresión sin penalizar con variables ortonormales: $\beta = (4.0, -2.0, 0.8, 0.3)$. Penalización $\lambda = 0.5$.

1. Calcula los coeficientes de Ridge ($\beta/(1+\lambda)$) y de Lasso ($\text{signo}(\beta)\cdot\max(|\beta| - \lambda, 0)$).
2. ¿Qué variables anula cada método? ¿Cuál usarías para «limpiar» variables sospechosas?
3. Repite con $\lambda = 1$ solo para Lasso. ¿Cuántos coeficientes quedan distintos de cero?

Bloque 6 Accuracy contra recall ★★★

2.000 transacciones, 40 fraudes. Modelo A: VP 10, FN 30, FP 20, VN 1.940. Modelo B: siempre «no fraude». Modelo C: VP 34, FN 6, FP 150, VN 1.810.

1. Calcula accuracy, precisión, recall y F1 de A, B y C.
2. Ordena los modelos por accuracy y por recall. ¿Coinciden?
3. Un fraude no detectado cuesta 100 y una falsa alarma cuesta 1. Calcula el costo total de cada modelo y elige.

Bloque 7 Métricas de regresión y elegir el enfoque ★★

Valores reales (60, 70, 80, 90) y predichos (62, 66, 83, 89).

1. Calcula los errores, el MSE, el RMSE y el R^2.
2. Una empresa propone Deep Learning para predecir la demanda de 500 productos con 3 años de historia semanal en una planilla. ¿Qué le recomiendas y qué línea base usarías?

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	(a) clasificación · (b) regresión · (c) clustering · (d) reducción de dimensionalidad · (e) refuerzo · (f) Deep Learning (clasificación de imágenes, supervisado con gran volumen).
2	(a) y = spam / no spam: precisión, recall, F1 · (b) y = minutos: RMSE, R^2 · (f) y = objeto: accuracy y matriz de confusión. Los problemas (c), (d), (e) no tienen variable objetivo en el sentido supervisado.

Bloque 2

#	Solución
1	A: $z = -1.2 + 2.4 - 0.5 = 0.7 \rightarrow p = 1/(1 + e^{-0.7}) = 0.668$. B: $z = -1.2 + 0 - 1.0 = -2.2 \rightarrow p = 1/(1 + e^{2.2}) = 0.100$.
2	$e^{0.8} = 2.23$: cada queja multiplica las odds por ≈ 2.2.
3	Umbral 0.5: A cancela, B se queda. Umbral 0.3: A cancela (0.668 ≥ 0.3), B se queda (0.100 < 0.3). Bajar el umbral aumenta los positivos solo si hay clientes entre 0.3 y 0.5.

Bloque 3

#	Solución
1	Distancia² a c1 / c2: P1 1 / 85 · P2 10 / 52 · P3 8 / 50 · P4 41 / 13 · P5 85 / 1 · P6 74 / 4. Asignación: P1, P2, P3 → c1; P4, P5, P6 → c2. Inercia = 1 + 10 + 8 + 13 + 1 + 4 = 37.
2	c1 = (2, 3); c2 = (7, 6.33). Nueva inercia: P1 2, P2 1, P3 1, P4 2.78, P5 2.78, P6 1.11 = 10.67. Las asignaciones no cambian: terminó.
3	La variable en días domina la distancia: el agrupamiento solo reflejaría antigüedad. Se evita estandarizando (o llevando todo a una misma escala) antes de ejecutar K-Means.

Bloque 4

#	Solución
1	Subajuste: grado 1 (bajo en entrenamiento y en prueba, 0.52 / 0.50). Adecuado: grado 2 (0.80 / 0.78, brecha 0.02). Sobreajuste: grados 8 y 15 (brechas 0.62 y 1.59).
2	Grado 2: el R^2 de prueba es el más alto y la brecha es pequeña. El grado 15 tiene el mejor entrenamiento pero memoriza ruido.
3	Más datos; menos complejidad (grado bajo); regularización (Ridge o Lasso con alpha elegido en validación); validación cruzada para escoger el grado.

Bloque 5

#	Solución
1	Ridge: (4.0, −2.0, 0.8, 0.3)/1.5 = (2.67, −1.33, 0.53, 0.20). Lasso: (3.5, −1.5, 0.3, 0).
2	Ridge no anula ninguno; Lasso anula el cuarto (|0.3| < 0.5). Para limpiar variables sospechosas, Lasso.
3	Con λ = 1: (3.0, −1.0, 0, 0): quedan 2 distintos de cero.

Bloque 6

#	Solución
1	A: accuracy 1.950/2.000 = 97.5 %; precisión 10/30 = 33.3 %; recall 10/40 = 25.0 %; F1 = 0.286. B: accuracy 1.960/2.000 = 98.0 %; precisión 0/0 (se define como 0); recall 0 %; F1 0. C: accuracy 1.844/2.000 = 92.2 %; precisión 34/184 = 18.5 %; recall 34/40 = 85.0 %; F1 = 0.304.
2	Por accuracy: B (98.0) > A (97.5) > C (92.2). Por recall: C (85) > A (25) > B (0). El orden se invierte.
3	A: 30·100 + 20·1 = 3.020. B: 40·100 = 4.000. C: 6·100 + 150·1 = 750. Se elige C: el modelo con peor accuracy es el más barato.

Bloque 7

#	Solución
1	Errores: 60 − 62 = −2, 70 − 66 = 4, 80 − 83 = −3, 90 − 89 = 1. SSE = 4 + 16 + 9 + 1 = 30; MSE = 7.5; RMSE = 2.74. Media real 75; SST = 225 + 25 + 25 + 225 = 500; R^2 = 1 − 30/500 = 0.94.
2	Con datos tabulares y una historia corta, no se justifica Deep Learning: conviene regresión o series de tiempo (y modelos de árboles). Línea base: «demanda de la semana anterior» o el promedio móvil; el modelo debe superarla en el error de prueba.