Apuntes · Clase 32 · Reducción de dimensionalidad y representación de variables

Para leer antes de los ejercicios · lectura de ~35 min

Lo más importante, en 6 ideas

1. **Más columnas no es más información.** Costo, multicolinealidad, ruido y varianza: se reduce por selección o por extracción.
2. **Representar antes de reducir.** Estandarizar, codificar y construir variables; lo aprendido (media, categorías, tasas) solo con entrenamiento.
3. **PCA = direcciones de máxima varianza.** Vectores propios de la covarianza; el valor propio λ es la varianza que explica cada uno.
4. **Elegir k con criterio.** Umbral de varianza, codo y validación cruzada dentro de un Pipeline.
5. **Cargas y correlaciones.** Carga × √λ = correlación; los componentes se nombran leyendo sus cargas.
6. **t-SNE explora, PCA produce.** t-SNE conserva vecindades locales, no es determinista y no transforma datos nuevos.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C32_ReduccionDimensionalidad.ipynb` o el cuaderno `C32_Ejercicios_Cuaderno_ReduccionDimensionalidad.pdf`.

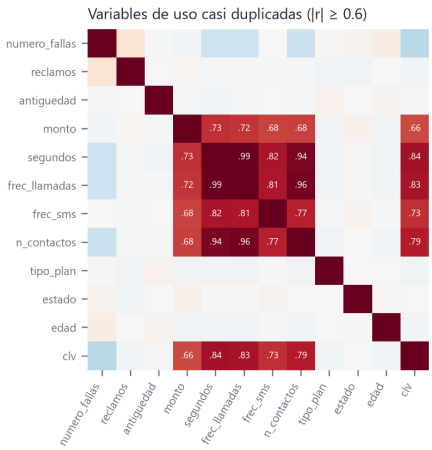
1 El problema de la dimensionalidad

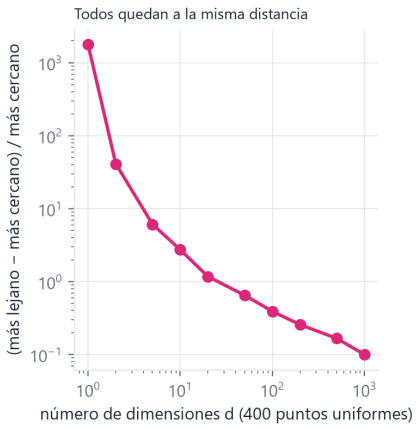
Más variables aumentan el costo, introducen **redundancia** (multicolinealidad) y **ruido**, y con pocas filas disparan la varianza del modelo. La multicolinealidad se mide con el **VIF** = $1/(1 - R^2)$, donde R^2 sale de explicar esa variable con todas las demás: VIF > 10 es una señal fuerte. Reducir puede ser **seleccionar** (quitar columnas) o **extraer** (combinarlas).

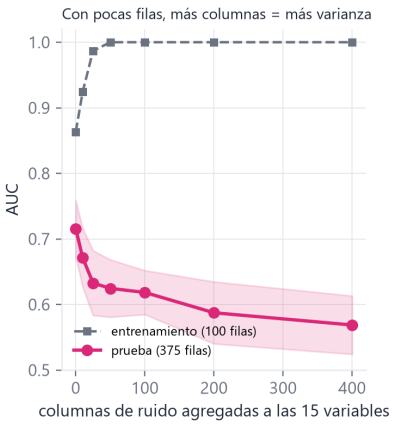
Ejemplo resuelto · un modelo de 40 columnas con 200 filas

Pregunta	Cálculo	Resultado
Filas por columna	200 / 40	5 (muy pocas)
VIF si $R^2 = 0.96$ al explicar una variable con las demás	$1/(1 - 0.96) = 1/0.04$	25
VIF si $R^2 = 0.50$	1/0.50	2 (sin problema)
Tras quitar 25 columnas redundantes: filas por columna	200 / 15	13.3

Un VIF de 25 dice que esa variable casi se puede calcular con las otras: sobra. En el notebook de la clase, segundos y frec_llamadas tienen VIF 40.8 y 48.3. Selección = eliminar una de las dos; extracción = resumirlas en un componente.







Pista para la Parte A del notebook y el Bloque 1 del cuaderno
Reproduce la matriz de correlaciones, calcula el VIF de las seis variables de uso y repite el experimento de columnas de ruido con 100 filas.

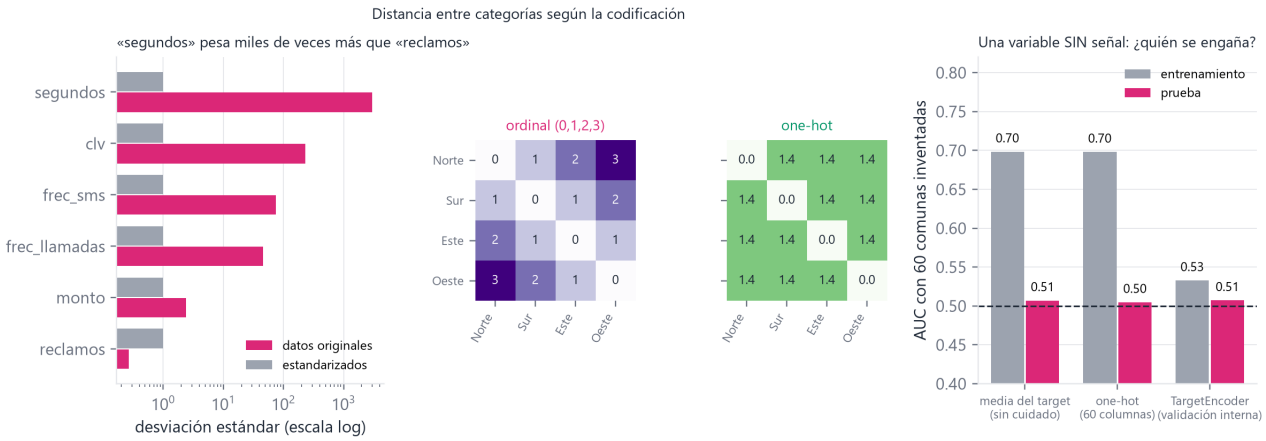
2 Escalar, codificar y construir

La **estandarización** resta la media y divide por la desviación: z = (x − media)/desviación. Después de ella, todas las variables tienen media 0 y desviación 1. La **normalización min-max** lleva a [0, 1]. Para variables **categóricas**: ordinal si hay orden, one-hot si no; target o frequency encoding con muchas categorías. Las variables construidas (cocientes) se crean antes de reducir.

Ejemplo resuelto · llamadas de un cliente

Pregunta	Cálculo	Resultado
segundos: media 4.000, desviación 3.000 · z de 10.000	(10.000 − 4.000)/3.000	z = 2
reclamos: media 0.1, desviación 0.3 · z de un 1	(1 − 0.1)/0.3	z = 3
min-max de 10.000 con mínimo 50 y máximo 17.000	(10.000 − 50)/(17.000 − 50)	0.587
Cuánto más varianza tiene segundos que reclamos (sin escalar)	3.000^2 / 0.3^2 = 9.000.000/0.09	100.000.000 veces
Región con 5 categorías, canal con 4 y estado binario: columnas one-hot con drop = 'first'	4 + 3 + 1	8 (sin drop: 5 + 4 + 2 = 11)
duracion_prom_llamada de 7.200 segundos en 90 llamadas	7.200 / 90	80 s

Sin escalar, un cliente que se desvía 2 sd en segundos pesa igual que otro 3 sd en reclamos solo si estandarizas. Con target encoding: comuna A con 40 clientes y 8 fugas, tasa global 0.15, suavizado m = 20: (8 + 20·0.15)/(40 + 20) = 11/60 = 0.183, no el 0.20 crudo.



Pista para la Parte B del notebook y los Bloques 2 y 5 del cuaderno

Estandariza con `fit` solo en entrenamiento, compara PCA con y sin estandarizar y arma un `ColumnTransformer` con ordinal, one-hot y target encoding.

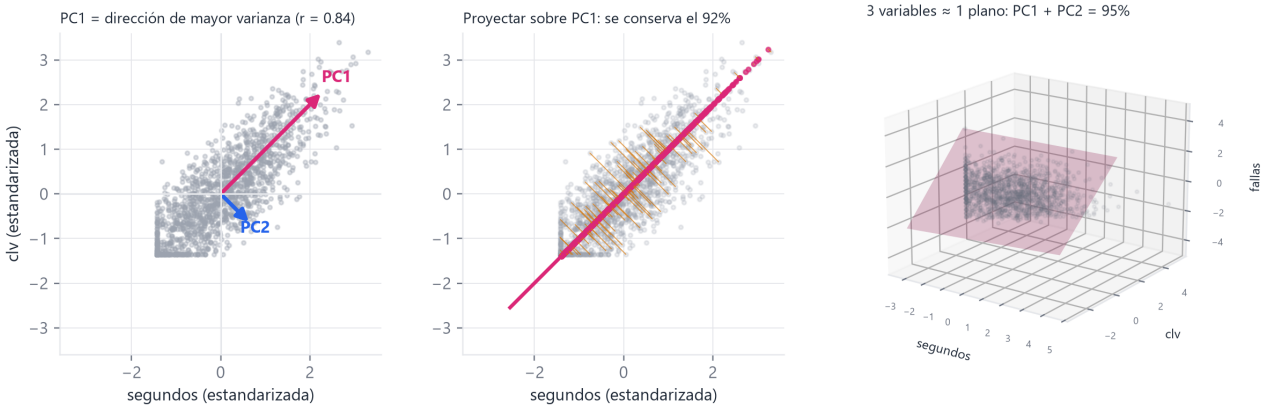
3 PCA a mano con una matriz 2×2

Con datos estandarizados, la matriz de covarianza es la matriz de correlaciones. Sus **valores propios** λ son las varianzas de los componentes y sus **vectores propios**, las direcciones. Para [[1, r], [r, 1]] los valores propios son **1 + r** y **1 − r**, con vectores (1, 1)/√2 y (1, −1)/√2. Un punto z se proyecta con el producto punto: puntaje = v · z.

Ejemplo resuelto · dos variables con r = 0.6

Pregunta	Cálculo	Resultado
Valores propios	1 + 0.6 · 1 − 0.6	$\lambda_1 = 1.6 \cdot \lambda_2 = 0.4$
Varianza explicada	1.6/2 · 0.4/2	80 % · 20 %
Vectores propios	(1, 1)/√2 · (1, −1)/√2	(0.707, 0.707) · (0.707, −0.707)
Punto z = (1.0, 0.2): puntaje en PC1	(1.0 + 0.2)/√2	0.849
Puntaje en PC2	(1.0 − 0.2)/√2	0.566
Reconstruir con solo PC1 y error	0.849·(0.707, 0.707) = (0.6, 0.6) · (0.4^2 + 0.4^2)	(0.6, 0.6) · 0.32

PC1 es la diagonal («ambas altas o ambas bajas»); PC2, lo que las diferencia. Conservar solo PC1 mantiene el 80 % de la varianza. Los dos vectores son perpendiculares: (0.707·0.707 + 0.707·(−0.707)) = 0.



Pista para la Parte C del notebook (C1) y el Bloque 3 del cuaderno

Calcula la matriz de covarianza del entrenamiento escalado, diagonalízala con `np.linalg.eigh` y compara con PCA. Ojo: los signos pueden ser opuestos.

4 Varianza explicada y cuántos componentes

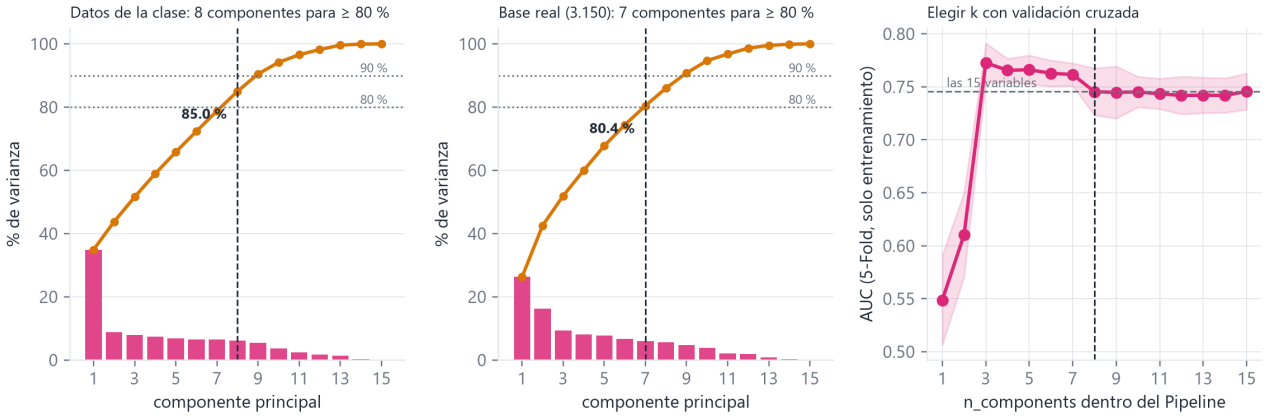
La varianza explicada del componente j es $\lambda_j/\Sigma\lambda$. Con p variables estandarizadas $\Sigma\lambda = p$. La acumulada indica cuánta información conservas con k componentes. Reglas de apoyo: el **umbral** (80 o 90 %), el **codo** del scree plot y el criterio de Kaiser ($\lambda > 1$); la decisión final se contrasta con el desempeño en validación.

Ejemplo resuelto · seis variables estandarizadas

λ = 2.4, 1.5, 1.0, 0.6, 0.3, 0.2 (suman 6.0).

Componente	Cálculo	Varianza · acumulada
PC1	2.4/6	40.0 % · 40.0 %
PC2	1.5/6	25.0 % · 65.0 %
PC3	1.0/6	16.7 % · 81.7 %
PC4	0.6/6	10.0 % · 91.7 %
Para 80 % · para 90 % · Kaiser ($\lambda > 1$)	primer k con acumulada ≥ umbral	k = 3 · k = 4 · k = 2

Los criterios no coinciden y está bien: son referencias, no verdades (la profesora insistió en bajarlas al contexto). En los datos de la clase, 8 componentes dan 85.0 % y en la base real 7 dan 80.4 %.



Pista para la Parte C del notebook (C2 y C3) y el Bloque 1 y 2 del cuaderno

Dibuja el scree plot, calcula k para 80, 85 y 90 % y elige k con `GridSearchCV` sobre un Pipeline.

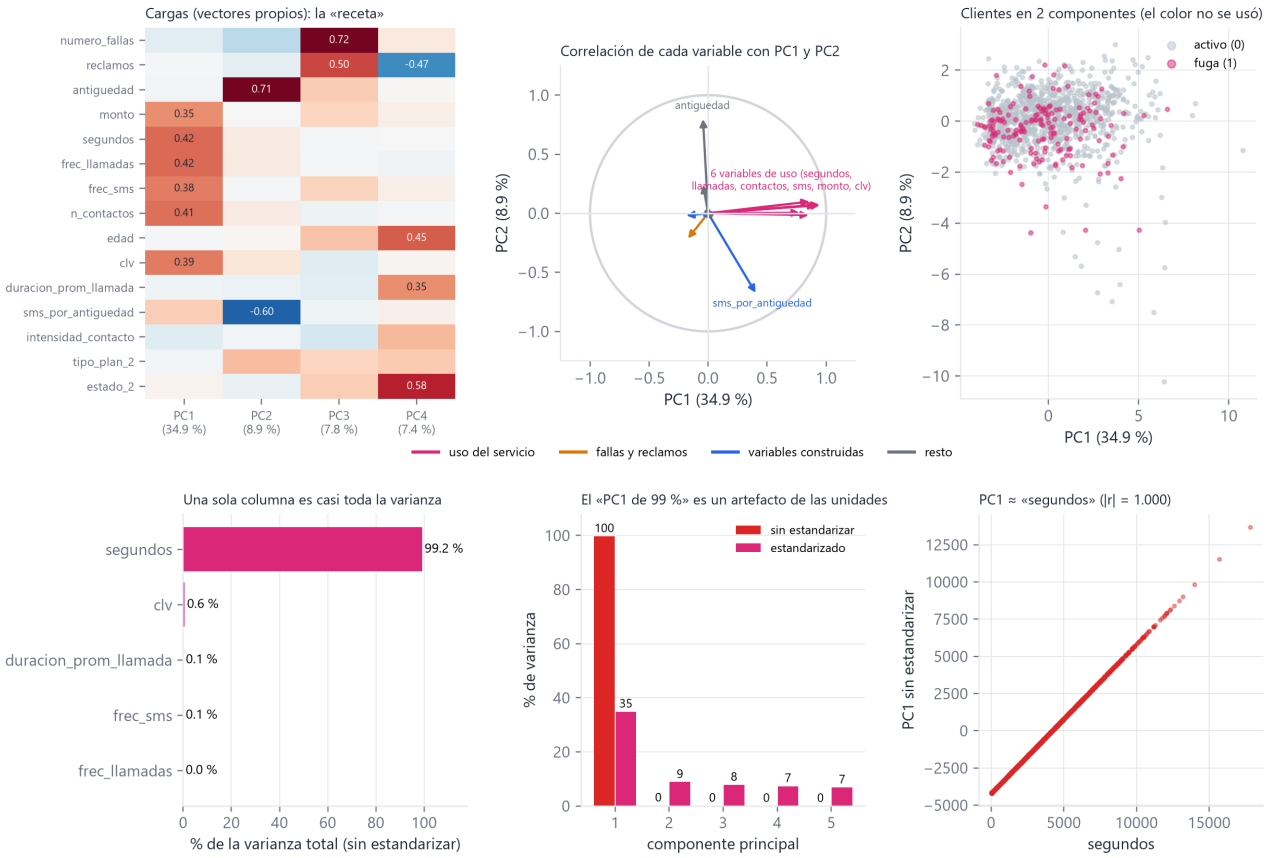
5 Cargas y correlaciones con los componentes

Cada fila de `components_` es un componente; sus cargas (norma 1) dicen cuánto pesa cada variable. El puntaje de un cliente es Σ carga·z. La correlación entre una variable y el componente es **carga · √λ**. El signo global de un componente es arbitrario; lo que importa es la relación entre signos.

Ejemplo resuelto · PC1 con cuatro variables y λ = 1.6

Pregunta	Cálculo	Resultado
Cargas de PC1: (0.5, 0.5, 0.5, −0.5): norma	√(4 · 0.25)	1 (correcto)
Cliente z = (2, 1, 0, 1): puntaje	0.5·2 + 0.5·1 + 0.5·0 − 0.5·1	1.0
Correlación de la variable 1 con PC1	0.5 · √1.6 = 0.5 · 1.265	0.63
Cómo se llama el componente	tres variables suben juntas y la cuarta baja	«A, B y C altas / D baja»

El nombre es una interpretación: ponerlo exige leer las cargas, no confiar en la diapositiva. En los datos de la clase PC1 (34.9 %) reúne segundos, llamadas, contactos, SMS, monto y CLV: «uso del servicio».



Pista para la Parte C del notebook (C4) y el Bloque 4 del cuaderno
Imprime `components_` como tabla, grafica el círculo de correlaciones y repite el PCA sin estandarizar para ver qué cambia.

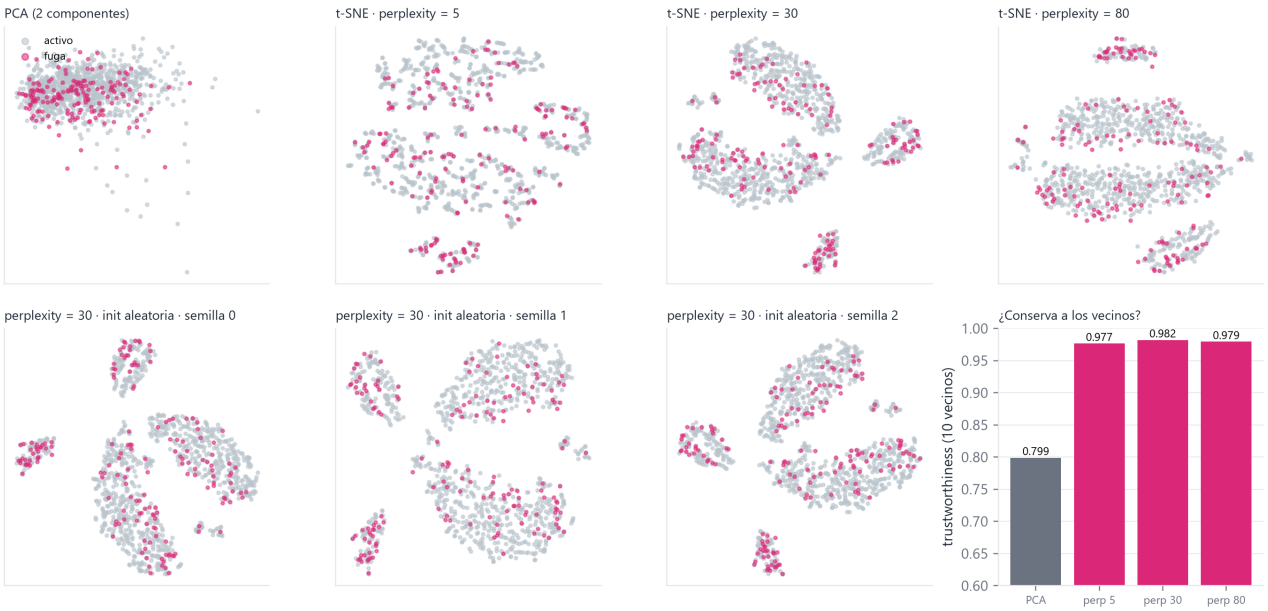
6 t-SNE, PCA y la decisión final

t-SNE calcula qué tan probable es que cada cliente sea vecino de otro y mueve puntos en 2D hasta reproducir esas vecindades. **Perplexity** controla el tamaño de la vecindad. No es determinista, no tiene `transform` y no se interpretan distancias entre islas. Para modelar se usa PCA (o selección).

Ejemplo resuelto · elegir la técnica

Situación	Técnica	Por qué
Seis variables de uso casi iguales y un modelo liviano para producción	PCA (o seleccionar una)	reduce y transforma datos nuevos
Ver si hay estructuras locales no lineales entre clientes	t-SNE	explorar y visualizar
Tengo segundos y llamadas y quiero la duración media	feature engineering	cociente, antes de reducir
Una columna no aporta y complica la explicación	selección	conserva variables originales

Un modelo que aprendió con 8 componentes necesita el mismo PCA (con el mismo escalador) al predecir: por eso todo va en un Pipeline. Con t-SNE no se puede: cada vez que llega un cliente habría que recalcular el mapa.



Pista para la Parte D del notebook y el Bloque 6 y 7 del cuaderno

Prueba perplexity 5, 30 y 80, cambia la semilla, calcula la trustworthiness y decide qué técnica usarías en cada caso.

Lo que debes recordar

- Sesión 31 (Introducción al ML) todavía no está en este material: aquí solo se usó lo que la clase 32 recuerda de ella (supervisado vs no supervisado).
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–C del notebook → Bloques 5–7 → Parte D → ejercicio de cierre.