Ejercicios para el cuaderno · Clase 32 · Reducción de dimensionalidad

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: varianza explicada = $\lambda_j/\Sigma\lambda$ · [[1, r], [r, 1]] tiene $\lambda = 1 \pm r$, vectores $(1, \pm 1)/\sqrt{2}$ · puntaje = v · z · correlación = carga · $\sqrt{\lambda}$ · VIF = $1/(1 - R^2)$.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 Varianza explicada desde los valores propios ★

Seis variables estandarizadas; los valores propios son 2.7, 1.5, 0.8, 0.5, 0.3 y 0.2.

1. Comprueba que suman p y calcula la varianza explicada y la acumulada de cada componente.
2. ¿Cuántos componentes necesitas para al menos 80 % y para 90 %? ¿Y según Kaiser ($\lambda > 1$)?

Bloque 2 Elegir el número de componentes ★★

Ocho variables estandarizadas; λ = 3.2, 1.6, 1.1, 0.8, 0.6, 0.4, 0.2, 0.1.

1. Calcula la acumulada y el k para 80 % y 90 %.
2. Con validación cruzada obtienes AUC 0.71 (k = 2), 0.78 (4), 0.79 (5) y 0.79 (8). ¿Qué k elegirías y por qué?

Bloque 3 PCA a mano con 2 variables ★★★

Matriz de correlación [[1, 0.8], [0.8, 1]].

1. Calcula los valores propios, los vectores propios y la varianza explicada de cada componente.
2. Proyecta z = (1.2, 0.8) en PC1 y PC2. Reconstruye con solo PC1 y calcula el error.
3. Sin estandarizar, la covarianza es [[400, 20], [20, 4]] (valores propios 401.0 y 3.0). ¿Qué fracción explica PC1 y qué variable domina? ¿Por qué se estandariza?

Bloque 4 Leer cargas ★★

PC1 con λ = 2.5. Cargas (A, B, C, D, E) = (0.48, 0.46, 0.45, 0.05, −0.59).

1. ¿Qué variables definen PC1 y qué significa el signo de E? Verifica que la norma sea aproximadamente 1.
2. Calcula la correlación de A y E con PC1, y el puntaje de un cliente z = (1, 2, 0.5, −1, −0.5).
3. Un colega dice «PC1 es la variable más importante para predecir la fuga». ¿Qué le respondes?

Bloque 5 Elegir la codificación ★★

1. Elige ordinal, one-hot, target/frequency o numérica: (a) tipo de plan (2 categorías), (b) nivel educativo (básico, medio, superior), (c) región (5 sin orden), (d) comuna (300 categorías), (e) monto 0 a 9.
2. La comuna B tiene 10 clientes y 4 fugas; la tasa global es 0.15. Calcula la tasa cruda y la suavizada con m = 20, y explica por qué la cruda es riesgosa.
3. ¿Por qué la media del target calculada con todas las filas es fuga de datos?

Bloque 6 Dimensiones después de codificar ★★

8 variables numéricas; categóricas: plan (2), región (5), estado civil (4), canal (6); nivel (ordinal con 3 niveles) y 2 variables construidas.

1. ¿Cuántas columnas hay con one-hot sin drop (nivel ordinal en 1 columna)? ¿Y con drop = 'first'?
2. Si PCA conserva 90 % con 9 componentes, ¿qué fracción de columnas se ahorra con el esquema drop = 'first'?

Bloque 7 Pipeline, fuga y técnica adecuada ★★★

1. ¿Fuga o no? (a) StandardScaler ajustado con todas las filas, luego dividir; (b) PCA dentro de un Pipeline evaluado con K-Fold; (c) elegir k mirando la prueba; (d) crear duracion_prom_llamada antes de dividir.
2. Elige PCA, t-SNE, selección o feature engineering: (a) modelo liviano con seis variables de uso correlacionadas, (b) ver estructura local no lineal, (c) una columna sin información, (d) distinguir llamadas largas de cortas.
3. Explica por qué t-SNE no sirve como paso de un modelo en producción (dos razones).

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	$\Sigma\lambda = 2.7 + 1.5 + 0.8 + 0.5 + 0.3 + 0.2 = 6.0 = p$. Varianza: 45.0, 25.0, 13.3, 8.3, 5.0, 3.3 %. Acumulada: 45.0, 70.0, 83.3, 91.7, 96.7, 100 %.
2	80 %: k = 3 (83.3). 90 %: k = 4 (91.7). Kaiser ($\lambda > 1$): k = 2.

Bloque 2

#	Solución
1	$\Sigma\lambda = 8$. Acumulada: 40.0, 60.0, 73.8, 83.8, 91.3, 96.3, 98.8, 100 %. 80 %: k = 4. 90 %: k = 5.
2	k = 4: ya llega a 0.78 y 5 o 8 casi no mejoran (+0.01). Se elige el más pequeño que rinde igual (parsimonia), y se compara dentro del Pipeline.

Bloque 3

#	Solución
1	$\lambda = 1 + 0.8 = 1.8$ y $1 - 0.8 = 0.2$. Vectores (0.707, 0.707) y (0.707, −0.707). Varianza explicada: 1.8/2 = 90 % y 10 %.
2	PC1 = (1.2 + 0.8)/√2 = 1.414 · PC2 = (1.2 − 0.8)/√2 = 0.283. Reconstrucción con PC1: 1.414·(0.707, 0.707) = (1.0, 1.0). Error: $(0.2^2 + 0.2^2) = 0.08$ ($= 0.283^2$).
3	PC1 explica 401.0/404 = 99.3 % y casi coincide con la variable de varianza 400 (carga ≈ 0.999). Es un efecto de la unidad: se estandariza para que cada variable pese igual.

Bloque 4

#	Solución
1	A, B y C (≈ 0.46) definen PC1; E pesa −0.59: cuando A, B y C suben, E baja. Norma^2 = 0.2304 + 0.2116 + 0.2025 + 0.0025 + 0.3481 = 0.995 ≈ 1.
2	√2.5 = 1.581: A: 0.48·1.581 = 0.76; E: −0.59·1.581 = −0.93. Puntaje = 0.48 + 0.92 + 0.225 − 0.05 + 0.295 = 1.87.
3	PCA no usa la etiqueta: PC1 es la dirección de mayor varianza, no necesariamente la que predice. Hay que contrastar con la fuga (aquí PC3, no PC1, es la que más se correlaciona).

Bloque 5

#	Solución
1	(a) one-hot con drop if_binary (una columna 0/1) · (b) ordinal · (c) one-hot · (d) target/frequency con validación interna · (e) ya es ordinal numérica: se deja como número (o se estandariza).
2	Cruda: 4/10 = 0.40. Suavizada: (4 + 20·0.15)/(10 + 20) = 7/30 = 0.233. Con 10 clientes la cruda es muy ruidosa y el modelo la memorizaría; la suavizada se acerca a la tasa global.
3	Porque usa la etiqueta de las filas de prueba para construir una variable de entrada; el modelo «ve» la respuesta. Debe calcularse con entrenamiento (idealmente con validación cruzada interna).

Bloque 6

#	Solución
1	Sin drop: 8 + (2 + 5 + 4 + 6) + 1 + 2 = 28. Con drop = 'first': 8 + (1 + 4 + 3 + 5) + 1 + 2 = 24.
2	Con 24 columnas y 9 componentes: 9/24 = 37.5 % de las columnas; se ahorra 62.5 %. (Con las 28 columnas: 9/28 = 32 %; se ahorra 68 %.)

Bloque 7

#	Solución
1	(a) fuga · (b) no · (c) fuga · (d) no (es una operación fila a fila que no aprende nada del conjunto).
2	(a) PCA (o seleccionar una) · (b) t-SNE · (c) selección · (d) feature engineering (segundos / frec_llamadas).
3	(1) No tiene transform: no proyecta clientes nuevos sin recalcular todo. (2) No es determinista y es costoso; el resultado cambia con la semilla.