Apuntes · Clase 33 · Feature engineering y selección de variables

Para leer antes de los ejercicios · lectura de ~60 min

Lo más importante, en 6 ideas

1. **Limpiar primero.** Los valores imposibles se tratan con reglas de negocio, antes de seleccionar. Imputa con la mediana; no borres filas.
2. **Construir con sentido.** Ratios, logs, binarias, cuartiles. Épsilon en todo denominador.
3. **Tres razones para sobrar.** Irrelevante (se va), redundante (queda una), útil solo en conjunto (no la mates por un p-valor).
4. **Tres familias.** Filter (rápido, univariado), wrapper (caro, ve combinaciones), embedded (Lasso: selecciona al entrenar).
5. **La trampa.** Todo lo que mira el target va dentro de cada fold. Si no, el AUC es inventado.
6. **Desconfía.** Un AUC demasiado bueno suele ser leakage, también por la ventana temporal.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C33_FeatureEngineering.ipynb` o el cuaderno `C33_Ejercicios_Cuaderno_FeatureEngineering.pdf`.

1 Qué es feature engineering y por qué importa

Un modelo solo puede aprender de lo que le entregas. El **feature engineering** es el trabajo de convertir datos crudos en variables útiles: limpiarlas, transformarlas y crear nuevas. La **selección de variables** decide cuáles de esas candidatas entran al modelo final.

El profesor insiste en que no es una receta lineal («primero esto, después esto»), sino un trabajo iterativo que depende del problema de negocio. Su ejemplo de la clase: predecir qué clientes de una telco se van a fugar, con 3.150 clientes y 12 variables.

2 Limpiar con criterio de negocio

Antes de cualquier técnica estadística, revisa mínimos y máximos con `describe()`. Un valor **imposible** (segundos negativos, 233 años) no es un outlier interesante: es un error de captura. Se marca como faltante (NaN) y luego se imputa.

Ejemplo resuelto · ¿media o mediana para imputar?

Segundos de 5 clientes: 3.000, 3.200, 2.900, 3.100 y −14.645 (imposible).

Paso	Qué haces	Resultado
1	Media con el error incluido	(12.200 − 14.645) / 5 = −489
2	Mediana con el error incluido	3.000 (casi no se mueve)
3	Marcar −14.645 como NaN y calcular la mediana	3.050
4	Imputar el NaN con esa mediana	el cliente queda con 3.050 segundos

Un solo dato malo vuelve negativa la media; la mediana es robusta. Por eso la clase imputa con la mediana.

La regla la pone el negocio

Edad entre 15 y 100 es una regla de negocio. ¿Y los 108 clientes de 0 a 14 años? Podrían ser cuentas a nombre de un menor. No hay respuesta estadística: hay que preguntar al negocio y documentar la decisión. Y no borres la fila: perderías la información de sus otras 11 variables.

Pista para la Parte A del notebook y el Bloque 1 del cuaderno
Para cada variable pregúntate: ¿qué rango es físicamente posible? Todo lo que esté fuera, a NaN. Después cuenta cuántos marcaste por variable antes de imputar.

3 Construir variables

Las variables crudas muchas veces no capturan lo importante. Un cliente con 60 llamadas en 20 meses no es igual a uno con 60 llamadas en 2 meses: lo que discrimina es el **ratio** llamadas por mes.

Familia	Ejemplo	Para qué sirve
Ratios	frec_llamadas / antigüedad	normalizar por exposición; según el profesor, las más potentes
Logaritmos	log(1 + clv)	aplastar colas largas
Binarias	tiene_reclamo, cliente_nuevo	marcar una condición de negocio
Cuartiles	clv_q1 … clv_q4	capturar relaciones no lineales
Interacciones	reclamo × antigüedad	efectos que dependen de otra variable
One-hot	estado_2, plan_2	categóricas para modelos lineales

Ejemplo resuelto · ratios con épsilon

Cliente	Cálculo	Resultado
20 meses, 60 llamadas	60 / (20 + 0.000001)	3.0 llamadas por mes
60 llamadas, 4.500 segundos	4.500 / (60 + 0.000001)	75 segundos por llamada
0 meses (cliente nuevo), 60 llamadas	60 / (0 + 0.000001)	60.000.000: enorme pero finito

Sin el épsilon, la tercera fila daría infinito y rompería el escalado y el modelo. Fíjate también que el resultado es gigante: conviene revisar y tratar esos casos, por ejemplo con un log o un tope.

Pista para la Parte B del notebook y el Bloque 2 del cuaderno
Escribe primero el ratio en palabras («llamadas por cada mes de antigüedad») y después en código. Al terminar, verifica que no queden infinitos con `np.isinf(X).sum().sum()`.

4 Irrelevante, redundante o útil en conjunto

Tipo	Qué pasa	Decisión	Ejemplo de la clase
Irrelevante	no aporta ni sola ni acompañada	descartar	ninguna clara en este dataset
Redundante	repite otra variable	conservar una	reclamos y tiene_reclamo (r = 1)
Útil en conjunto	sola no sirve, acompañada sí	NO descartar	numero_fallas, el caso XOR

Ejemplo resuelto · el XOR con 4 puntos

Punto	x1	x2	Clase (signos distintos)
A	+1	+1	0
B	+1	−1	1
C	−1	+1	1
D	−1	−1	0

Mira solo x1: con +1 hay un 0 y un 1; con −1 también. x1 sola no dice nada, y lo mismo pasa con x2. Pero x1·x2 vale +1 en las clases 0 y −1 en las clases 1: juntas separan perfecto. Un filtro univariado habría descartado las dos.

5 Métodos de filtro

Un **filtro** mide cada variable por separado contra el target, sin entrenar el modelo. Es rápido, pero no ve combinaciones.

- **Varianza:** una variable casi constante no informa. Para una binaria, Var = $\pi(1 - \pi)$; con threshold = 0.01 se exige que la categoría menor tenga más de ~1% de los casos.
- **Correlación de Pearson:** mide solo relación lineal. Con $y = x^2$ (una U perfecta), $r = 0$.
- **Información mutua:** detecta cualquier dependencia, también no lineal. Sirve para ordenar dentro de un dataset. Cambia con la semilla: fija random_state.
- **ANOVA F:** compara las medias de la variable entre fugados y no fugados. Falla con relaciones tipo U.

Ejemplo resuelto · varianza de una variable binaria

% de unos (π)	Var = π(1 − π)	¿Pasa threshold = 0.01?
0.5%	0.005 · 0.995 = 0.005	No: casi constante
1%	0.01 · 0.99 = 0.0099	No, por muy poco
10%	0.1 · 0.9 = 0.09	Sí

Pista para la Parte C del notebook y los Bloques 3 y 4 del cuaderno

Ordena las variables por información mutua y después mira la matriz de correlación entre las primeras: si dos de arriba tienen $r > 0.9$, son la misma información.

6 Wrapper y embedded

Un **wrapper** entrena el modelo con distintos subconjuntos y compara el desempeño. RFE parte con todas y va quitando la de menor coeficiente. El problema es el costo: con p variables hay $2^p - 1$ subconjuntos posibles.

Ejemplo resuelto · ¿cuánto cuesta probar todo? (1.000 modelos por segundo)

p	Subconjuntos ($2^p - 1$)	Tiempo
10	1.023	1 segundo
20	1.048.575	17 minutos
30	$\approx 1.07 \cdot 10^9$	12 días
50	$\approx 1.13 \cdot 10^{15}$	35.702 años

Un método **embedded** selecciona mientras entrena. El **Lasso** (penalización L1) empuja coeficientes a exactamente 0: las variables con coeficiente 0 quedan fuera. En sklearn, **C es el inverso de la penalización**: C = 0.01 dejó 13 variables y C = 1 dejó 45. Antes del Lasso hay que **escalar**: si no, el coeficiente depende de las unidades.

7 La trampa: selección fuera de la validación cruzada

Si eliges variables mirando el target con **todos** los datos y después validas, los casos de validación ya influyeron en la elección. Con suficientes variables, algunas parecen buenas por puro azar, y la validación no lo detecta porque esos mismos casos las hicieron parecer buenas.

Ejemplo resuelto · ¿cuántas variables «buenas» aparecen por azar?

Variables de puro ruido (p)	α	Falsos positivos esperados = α · p
1.000	0.05	50
200	0.05	10
1.000	0.01	10

En la clase, elegir 20 de 1.000 variables de ruido fuera del CV dio AUC 0.882. Dentro del pipeline, 0.514. La verdad: 0.5.

Paso	¿Mira el target?	¿Usa estadísticas del conjunto?	¿Dónde va?
Borrar imposibles, construir ratios, one-hot	No	No	Puede ir antes del split
Imputar con la mediana, escalar	No	Sí	Dentro del fold
Filtro por MI, desempate de redundantes	Sí	Sí	Dentro del fold
RFE, Lasso, SelectKBest	Sí	Sí	Dentro del fold

Pista para la Parte E del notebook y el Bloque 7 del cuaderno
Regla de bolsillo: si un paso necesita `fit`, va dentro del Pipeline. Si es una fórmula fija fila por fila (un ratio, un log), puede ir antes.

8 La ventana temporal («junio hacia atrás»)

En un modelo **predictivo**, las variables deben medirse **antes** del período en que ocurre el target. Si quieres predecir la fuga de agosto, usa información hasta junio. Si construyes una variable con datos de julio o agosto, estás usando el futuro: es leakage, aunque no uses la columna fuga.

Señal de alarma
Una variable con poder predictivo «demasiado bueno», como «llamó para dar de baja el servicio», casi siempre ocurre después de la decisión que quieres predecir. En la industria, un AUC de 0.84–0.85 en fuga ya es muy bueno.

9 Adelanto: WOE e Information Value

El profesor pidió anotar esta técnica de banca y riesgo de crédito. No se calcula en esta clase. Se discretiza la variable en tramos y, para cada tramo, se compara la proporción de «buenos» con la de «malos».

Ejemplo resuelto · una variable con 2 tramos (800 buenos y 200 malos en total)

Tramo	% buenos	% malos	WOE = ln(%buenos / %malos)	Aporte al IV
A	500/800 = 62.5%	60/200 = 30%	ln(0.625/0.30) = 0.734	(0.625 − 0.30)·0.734 = 0.239
B	300/800 = 37.5%	140/200 = 70%	ln(0.375/0.70) = −0.624	(0.375 − 0.70)·(−0.624) = 0.203

IV = 0.239 + 0.203 = **0.44** → poder predictivo fuerte. Umbrales usuales: < 0.02 nulo · 0.02–0.1 débil · 0.1–0.3 medio · 0.3–0.5 fuerte · > 0.5 sospechoso (posible leakage).

10 Chuleta de código

Quiero…	Código
Ver mínimos y máximos	d.describe().T[['min', 'max']]
Marcar imposibles	d.loc[d.x < 0, 'x'] = np.nan
Contar duplicados	d.duplicated().sum()
Ratio seguro	d.a / (d.b + 1e-6)
Cuartiles	pd.qcut(d.x, 4, labels=False)
Pares redundantes	corr.where(np.triu(np.ones(corr.shape), 1).astype(bool)).stack()
Información mutua	mutual_info_classif(X, y, random_state=0)
Lasso	LogisticRegression(penalty='l1', solver='liblinear', C=0.05)
Pipeline honesto	Pipeline([('imp', SimpleImputer(strategy='median')), ('esc', StandardScaler()), ('sel', SelectKBest(...)), ('log', ...)])
Validar	cross_val_score(pipe, X, y, cv=StratifiedKFold(5, shuffle=True), scoring='roc_auc')

11 Errores comunes

Error	Por qué está mal	Qué hacer
Borrar filas con un valor raro	Pierdes las otras variables de esa fila	NaN + imputar, o una categoría propia
Imputar con la media	Los extremos la arrastran	Mediana
Dividir sin épsilon	Un infinito rompe el pipeline	x / (y + 1e-6)
Descartar por un p-valor alto	Puede servir en conjunto	Probar en el modelo con otras
Top-k por un ranking univariado	Gasta cupos en redundantes	Revisar la correlación entre las elegidas
Seleccionar antes del CV	AUC inflado (0.88 con puro ruido)	Selección dentro del Pipeline
Variables del futuro	Leakage temporal	Ventana «junio hacia atrás»
Usar exactitud con 15.7% de fuga	Decir «nadie se va» da 84.3%	AUC, sensibilidad, precisión

Lo que debes recordar

- Orden sugerido: lee estos apuntes → Bloques 1–3 del cuaderno → Partes A y B del notebook → Bloques 4–6 → Partes C y D → Bloques 7–8 → Parte E → ejercicio de cierre.
- Si te trabas más de 10 minutos, mira la solución, entiéndela y vuelve a hacerlo sin mirar.