Ejercicios para el cuaderno · Clase 33 · Feature engineering

Para resolver en papel, con calculadora (tecla ln) · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu razonamiento completo: aquí importan tanto las decisiones como los números.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.
- Corrige con las soluciones y marca con color lo que tuviste mal: eso va al repaso del domingo.

Bloque 1 Limpiar con criterio ★★

Seis clientes: (a) edad 34, segundos 3.100 · (b) edad 233 · (c) segundos −250 · (d) antigüedad 0 meses · (e) edad 12 · (f) frec_llamadas 0.

1. Clasifica cada caso como imposible, dudoso (decisión de negocio) o válido. Justifica en una línea.
2. ¿Qué harías con cada uno: NaN + imputar, preguntar al negocio, o dejarlo?
3. Segundos de 6 clientes: 2.800, 3.000, 3.100, 3.300, 3.500 y −9.000. Calcula la media y la mediana con el error, y la mediana después de marcarlo como NaN.
4. ★★★ Un compañero borra las 111 filas con edad fuera de [15, 100]. Explica dos problemas de esa decisión.

Bloque 2 Construir variables ★

Cliente: antigüedad 25 meses, 50 llamadas, 4.000 segundos, 200 SMS, CLV 600.

1. Calcula llamadas por mes, segundos por llamada y SMS por llamada.
2. Calcula log(1 + CLV). ¿Para qué sirve el logaritmo en una variable como CLV?
3. Si la antigüedad fuera 0, ¿qué pasa con llamadas / antigüedad sin épsilon? ¿Y con $\varepsilon = 10^{-6}$?
4. La variable categórica estado tiene 2 niveles y tipo_plan tiene 2. ¿Cuántas columnas one-hot agregas con drop_first?

Bloque 3 Varianza y correlación a mano ★★

1. Una binaria vale 1 en el 2% de los clientes. Calcula su varianza. ¿La descarta VarianceThreshold(0.01)?
2. Calcula r de Pearson para x = 1, 2, 3, 4, 5 · y = 1, 3, 2, 5, 4.
3. Calcula r para x = −2, −1, 0, 1, 2 · $y = x^2$. ¿Significa que no hay relación?
4. Dos variables tienen r = 0.96 entre sí. Una tiene MI 0.10 con el target y la otra 0.08. ¿Con cuál te quedas y por qué?

Bloque 4 Irrelevante, redundante o útil en conjunto ★★

1. Clasifica: (a) log_segundos cuando ya tienes segundos · (b) el color favorito del cliente · (c) numero_fallas, que sola da AUC 0.53 pero sube el modelo de 0.907 a 0.910.
2. Para los 4 puntos (x1, x2, clase): (+1, +1, 1), (+1, −1, 0), (−1, +1, 0), (−1, −1, 1), ¿x1 sola separa las clases? Calcula x1·x2 para cada punto. ¿Qué observas?
3. ★★★ ¿Por qué un filtro univariado (ANOVA F) descartaría x1 y x2 en el ejercicio anterior? ¿Qué método no las descartaría?

Bloque 5 Filter, wrapper o embedded ★

1. Clasifica: VarianceThreshold · RFE · Lasso · información mutua · forward selection · importancia de un árbol · ANOVA F.
2. Tienes 5.000 variables candidatas y poco cómputo. Propón el orden en que aplicarías las tres familias.

Bloque 6 Costo y Lasso ★★

1. ¿Cuántos subconjuntos hay con 15 variables? ¿Cuánto tardarías a 1.000 modelos por segundo?
2. En sklearn, C = 0.01 deja 13 variables y C = 1 deja 45. ¿Qué C usarías si quieres un modelo simple de explicar? ¿Qué arriesgas?
3. ¿Por qué hay que escalar las variables antes de un Lasso? Responde con un ejemplo de segundos (miles) vs reclamos (0/1).

Bloque 7 Leakage en la selección ★★★

1. Tienes 400 variables de puro ruido y usas $\alpha = 0.05$. ¿Cuántas esperas que parezcan significativas por azar?
2. Clasifica cada paso como «antes del split» o «dentro del fold»: (a) quitar edades imposibles · (b) imputar con la mediana · (c) calcular llamadas por mes · (d) SelectKBest · (e) StandardScaler · (f) Lasso · (g) one-hot de estado.
3. Un compañero reporta AUC 0.97 en fuga. Nombra dos preguntas que le harías antes de creerle.
4. Quieres predecir la fuga de agosto. ¿Puedes usar «n° de reclamos en julio»? ¿Y «n° de reclamos en agosto»? Explica.

Bloque 8 WOE e IV ★★★

Variable con 2 tramos; total 1.000 buenos y 250 malos. Tramo A: 700 buenos y 50 malos. Tramo B: 300 buenos y 200 malos.

1. Calcula % de buenos y % de malos de cada tramo.
2. Calcula el WOE de cada tramo.
3. Calcula el IV e interprétalo con los umbrales de los apuntes.

Soluciones paso a paso

Revisa el razonamiento, no solo el número final

Bloque 1

#	Solución
1	(a) válido · (b) imposible · (c) imposible · (d) válido: cliente nuevo, pero ojo con los ratios · (e) dudoso: podría ser la cuenta de un menor · (f) válido: un cliente sin llamadas existe.
2	(b) y (c): NaN + imputar con la mediana · (e): preguntar al negocio y documentar · (a), (d) y (f): dejar; (d) necesita épsilon en los ratios.
3	Media con el error = (15.700 − 9.000) / 6 = 1.116.7 · mediana con el error = (3.000 + 3.100) / 2 = 3.050 · mediana sin el error (5 valores) = 3.100.
4	Pierde la información de las otras 11 variables de esas filas, y los 108 casos de 0–14 años podrían ser clientes reales (cuentas de menores). Además puede sesgar la muestra si esos clientes se fugan distinto.

Bloque 2

#	Solución
1	50 / 25 = 2 llamadas por mes · 4.000 / 50 = 80 segundos por llamada · 200 / 50 = 4 SMS por llamada.
2	ln(601) = 6.40. El log aplasta la cola larga: los clientes de CLV muy alto no dominan el modelo.
3	Sin épsilon: división por cero → infinito, y el pipeline se rompe. Con épsilon: $50 / 10^{-6} = 50.000.000$, finito pero enorme: conviene revisarlo o aplicarle un log.
4	2 − 1 = 1 por estado y 2 − 1 = 1 por plan: 2 columnas (estado_2, plan_2).

Bloque 3

#	Solución
1	0.02 · 0.98 = 0.0196 > 0.01 → no la descarta.
2	$\bar{x} = 3$, $\bar{y} = 3$. Desvíos x: −2, −1, 0, 1, 2 · desvíos y: −2, 0, −1, 2, 1. $S_{xy} = 4 + 0 + 0 + 2 + 2 = 8 \cdot S_{xx} = 10 \cdot S_{yy} = 10 \rightarrow r = 8 / 10 = 0.8$.
3	r = 0, pero la relación es perfecta ($y = x^2$). Pearson solo mide relaciones lineales: grafica siempre.
4	Son redundantes: me quedo con la de MI 0.10, salvo que la otra sea mucho más simple de mantener en producción.

Bloque 4

#	Solución
1	(a) redundante → conservar una · (b) irrelevante → descartar · (c) útil en conjunto → no descartarla.
2	x1 = +1 tiene una clase 1 y una 0; con −1, igual: x1 sola no separa. x1·x2 = +1, −1, −1, +1 coincide con la clase (+1 → 1, −1 → 0): juntas separan perfecto.
3	ANOVA F compara la media de cada variable entre clases, y esas medias son iguales: F ≈ 0. Un modelo con la interacción x1·x2, un Random Forest o un árbol profundo sí las aprovechan.

Bloque 5

#	Solución
1	Filter: VarianceThreshold, información mutua, ANOVA F · Wrapper: RFE, forward selection · Embedded: Lasso, importancia de un árbol.
2	Filtro (varianza + MI) para bajar a unas 200 → embedded (Lasso) para bajar a unas 30 → wrapper (RFE) solo si sobra cómputo.

Bloque 6

#	Solución
1	$2^{15} - 1 = 32.767$ subconjuntos → 33 segundos a 1.000 modelos por segundo.
2	Un C chico, por ejemplo 0.01 (13 variables). Arriesgas perder variables útiles y algo de AUC; además, entre variables redundantes el Lasso elige una casi al azar.
3	La penalización castiga el tamaño del coeficiente. Segundos en miles tendría un coeficiente diminuto aunque fuera importante, y reclamos (0/1) uno grande: el Lasso decidiría por las unidades, no por la información.

Bloque 7

#	Solución
1	$\alpha \cdot p = 0.05 \cdot 400 = 20$ variables falsamente significativas.
2	Antes del split: (a), (c), (g) · Dentro del fold: (b), (d), (e), (f).
3	¿La selección o la imputación se hizo dentro del CV? ¿Alguna variable usa información posterior al momento de predecir (ventana temporal)? También: ¿está evaluado en un test que nunca se tocó?
4	Julio sí: es anterior al período del target. Agosto no: es el mismo período que quieres predecir (leakage temporal).

Bloque 8

#	Solución
1	A: 700/1.000 = 70% buenos · 50/250 = 20% malos · B: 300/1.000 = 30% buenos · 200/250 = 80% malos.
2	$WOE_A = \ln(0.70 / 0.20) = 1.253$ · $WOE_B = \ln(0.30 / 0.80) = -0.981$.
3	$IV = (0.70 - 0.20)\cdot 1.253 + (0.30 - 0.80)\cdot(-0.981) = 0.626 + 0.490 = 1.12 > 0.5$ → sospechoso: tanto poder predictivo suele indicar leakage. Hay que revisar cómo se construyó la variable.