Ejercicios para el cuaderno · Clase 35 · Bagging y Random Forest

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: $P(\text{fuera}) = (1 - 1/n)^n$ · $\text{Var} = \rho\sigma^2 + (1 - \rho)\sigma^2/B$ · $\text{Gini} = 1 - \Sigma\, p^2$.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.
- Los bloques 8 y 9 usan los números de la guía (páginas 2 a 6).

Bloque 1 Bootstrap y fracción OOB ★

1. Calcula P(una fila queda fuera) para n = 4, 10 y 50. ¿Hacia qué valor converge?
2. n = 200: ¿cuántas filas distintas se esperan en una muestra bootstrap y cuántas quedan fuera?
3. Datos 1 a 10 y muestra bootstrap 3, 3, 4, 6, 6, 6, 8, 9, 9, 10. ¿Cuántas filas únicas tiene? Escribe el OOB y su porcentaje.

Bloque 2 OOB a mano ★★

Cuatro árboles, seis observaciones (A–F, clase real entre paréntesis: A 1, B 0, C 1, D 0, E 1, F 0). Cada árbol predice solo sus observaciones OOB: **árbol 1** {A→1, C→0, E→1, F→0} · **árbol 2** {B→0, C→0, F→1} · **árbol 3** {A→1, B→0, D→0, F→0} · **árbol 4** {B→1, C→1, D→0, E→1}.

1. ¿En cuántos árboles es OOB cada observación?
2. Calcula la predicción OOB de cada observación por mayoría de votos.
3. Calcula la exactitud OOB y el error OOB.

Bloque 3 Voto y promedio ★

1. Siete árboles votan Sí, No, Sí, Sí, No, Sí, No. ¿Predicción y probabilidad estimada por votos? Con umbral 0.70, ¿cuál es la predicción?
2. Probabilidades de cinco árboles: 0.90, 0.20, 0.60, 0.55, 0.35. Calcula la probabilidad media y la fracción de votos ($P > 0.5$). ¿Coinciden?
3. Cinco árboles de regresión predicen 210, 195, 230, 220 y 205 (miles USD). Calcula el promedio y la mediana.

Bloque 4 Varianza de un promedio ★★

$\sigma^2 = 100$ ($\sigma = 10$).

1. Con $\rho = 0.2$ calcula Var para $B = 1, 5, 25$ y $B \to \infty$.
2. Repite con $\rho = 0.6$. ¿Cuánto ganas pasando de 5 a 25 árboles en cada caso?
3. ★★★ ¿Desde qué B el término $(1 - \rho)\sigma^2/B$ es menor que $\rho\sigma^2$ con $\rho = 0.2$? ¿Y con $\rho = 0.6$? Interpreta.

Bloque 5 max_features ★

1. Calcula las candidatas por nodo con p = 16 para 'sqrt', 'log2' y max_features = 1/3 (redondea hacia abajo).
2. p = 8 y m = 3: ¿probabilidad de que la variable dominante sea candidata en un nodo? ¿Y de que falte en las raíces de 5 árboles?
3. ¿Qué algoritmo es un Random Forest con max_features = p? ¿Por qué?

Bloque 6 Importancia por impureza (Gini) ★★★

N = 100 (50 y 50). Raíz: corte por X_1 → izquierda 40 (35 de la clase 1, 5 de la 0), derecha 60 (15 de la 1, 45 de la 0). El nodo derecho se corta por X_2 → 20 (12 de la 1, 8 de la 0) y 40 (3 de la 1, 37 de la 0).

1. Calcula el Gini de la raíz, de los dos hijos del primer corte y la reducción de impureza ponderada.
2. Calcula la reducción del segundo corte y multiplícala por N_t/N.
3. Normaliza para obtener la importancia de X_1 y X_2.

Bloque 7 OOB, CV y costo ★★

1. Un bosque de 600 árboles: ¿en cuántos es OOB una fila (en promedio)? Con B = 8 árboles, ¿qué proporción de filas no tiene ninguna predicción OOB?
2. Una grilla de 3 × 3 × 2 combinaciones con CV de 5 bloques: ¿cuántos ajustes? Si cada ajuste dura 4 s en serie y paralelizas en 6 núcleos (ideal), ¿cuánto tarda?
3. El OOB de un bosque da exactitud 0.84 y el test 0.79 con 60 pacientes. ¿Es una contradicción? Justifica con el error de una proporción ($\approx \sqrt{p(1-p)/n}$).

Bloque 8 Importancia por permutación y lectura ★★

AUC base 0.90. Al desordenar cada variable en el test: X_1 → 0.74 · X_2 → 0.89 · X_3 (ruido) → 0.90 · X_4 → 0.905.

1. Calcula la importancia por permutación de cada variable.
2. ¿Qué variables eliminarías? ¿Qué significa un valor negativo pequeño?
3. Una variable continua de ruido aparece con 7 % de importancia por impureza. ¿Qué dos razones lo explican y qué harías?

Bloque 9 Elegir y leer resultados ★★★

1. Heart: logística AUC 0.913 ± 0.035 y Random Forest 0.906 ± 0.036 (CV 5×3). ¿Puedes afirmar que la logística es mejor? ¿Qué modelo elegirías si importa interpretar?
2. Entrenas con precios de 100 a 500 mil y el bosque predice 498 mil para una casa que vale 700 mil. ¿Hay un error de código? Explica y propón una alternativa.
3. Un bosque tiene exactitud de train 1.000 y de test 0.85. ¿Es sobreajuste que debes corregir? ¿Qué mirarías antes de decidir?
4. Elige modelo y justifica: (a) clasificar fraude con 2 % de positivos; (b) clasificar fotos 256×256; (c) 300 filas casi lineales.

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	n = 4: $(3/4)^4 = 0.316$ · n = 10: $0.9^{10} = 0.349$ · n = 50: $0.98^{50} = 0.364$. Converge a $e^{-1} \approx 0.368$.
2	$(1 - 1/200)^{200} = 0.367$ fuera → filas distintas = 200 · (1 − 0.367) ≈ 126.6 y fuera ≈ 73.4.
3	Únicas: 3, 4, 6, 8, 9, 10 → 6 filas (60 %). OOB = {1, 2, 5, 7} → 4 filas = 40 %.

Bloque 2

#	Solución
1	A: árboles 1 y 3 · B: 2, 3 y 4 · C: 1, 2 y 4 · D: 3 y 4 · E: 1 y 4 · F: 1, 2 y 3.
2	A: 1, 1 → 1 · B: 0, 0, 1 → 0 · C: 0, 0, 1 → 0 · D: 0, 0 → 0 · E: 1, 1 → 1 · F: 0, 1, 0 → 0.
3	Comparando con la clase real (1, 0, 1, 0, 1, 0): aciertan A, B, D, E y F; falla C. Exactitud OOB = 5/6 = 0.833; error OOB = 1/6 = 0.167.

Bloque 3

#	Solución
1	Cuatro Sí de siete → Sí. Probabilidad por votos 4/7 = 0.571. Con umbral 0.70, 0.571 < 0.70 → No.
2	Promedio = (0.90 + 0.20 + 0.60 + 0.55 + 0.35)/5 = 2.60/5 = 0.52. Votos con P > 0.5: 0.90, 0.60 y 0.55 → 3/5 = 0.60. No coinciden (0.52 vs 0.60).
3	Promedio = (210 + 195 + 230 + 220 + 205)/5 = 1.060/5 = 212. Mediana = 210.

Bloque 4

#	Solución
1	ρ = 0.2: B = 1 → 20 + 80 = 100 · B = 5 → 20 + 16 = 36 · B = 25 → 20 + 3.2 = 23.2 · B → ∞ → 20.
2	ρ = 0.6: B = 1 → 100 · B = 5 → 60 + 8 = 68 · B = 25 → 60 + 1.6 = 61.6 · B → ∞ → 60. De 5 a 25 árboles: con ρ = 0.2 baja 12.8 (36 → 23.2); con ρ = 0.6, solo 6.4 (68 → 61.6).
3	(1 − ρ)/B < ρ □ B > (1 − ρ)/ρ. ρ = 0.2: B > 4 · ρ = 0.6: B > 0.67, o sea desde el primer árbol. Con ρ alto el término de la correlación domina enseguida: más árboles ya no ayudan.

Bloque 5

#	Solución
1	'sqrt' → 4 · 'log2' → 4 · 1/3 → □5.33□ = 5.
2	P(candidata) = 3/8 = 0.375. P(falta en una raíz) = 5/8 = 0.625 → en 5 raíces: $0.625^5 = 0.095$.
3	Un bagging: con todas las variables en cada nodo no hay selección aleatoria, solo bootstrap.

Bloque 6

#	Solución
1	Raíz: $1 - (0.5^2 + 0.5^2) = 0.5$. Izquierda (35/5): $1 - (0.875^2 + 0.125^2) = 0.21875$. Derecha (15/45): $1 - (0.25^2 + 0.75^2) = 0.375$. Ponderado: 0.4·0.21875 + 0.6·0.375 = 0.3125. Reducción = 0.5 − 0.3125 = 0.1875 (peso 100/100 = 1).
2	Nodo derecho: 0.375. Hijos: (12/8) $1 - (0.36 + 0.16) = 0.48$; (3/37) $1 - (0.075^2 + 0.925^2) = 0.13875$. Ponderado: (20·0.48 + 40·0.13875)/60 = 0.2525. Reducción = 0.375 − 0.2525 = 0.1225; por N_t/N = 60/100: 0.0735.
3	Total = 0.1875 + 0.0735 = 0.261. X_1 = 0.1875/0.261 = 0.718 · X_2 = 0.0735/0.261 = 0.282.

Bloque 7

#	Solución
1	$0.368 \cdot 600 \approx 221$ árboles. Con B = 8: $0.632^8 = 0.025 \rightarrow 2.5$ % de las filas sin ninguna predicción OOB.
2	$3 \cdot 3 \cdot 2 = 18$ combinaciones × 5 = 90 ajustes · 90·4 = 360 s en serie → 360/6 = 60 s (ideal; en la práctica algo más).
3	No es contradicción: el error estándar de una proporción de 0.8 con n = 60 es $\sqrt{(0.8 \cdot 0.2/60)} = 0.052$, así que 0.84 y 0.79 difieren menos de un error estándar. Con tan pocos pacientes el test es muy ruidoso.

Bloque 8

#	Solución
1	X_1: 0.90 − 0.74 = 0.16 · X_2: 0.01 · X_3: 0.00 · X_4: 0.90 − 0.905 = −0.005.
2	Solo X_1 importa claramente; X_2 aporta poco y X_3, X_4 nada. Un valor negativo pequeño es ruido: desordenar la variable «mejoró» por azar, o sea no aporta.
3	(a) La impureza se calcula con el train y premia variables con muchos cortes posibles, aunque no tengan relación con el objetivo; (b) el bosque memoriza el train, y ahí el ruido «sirve». Calcular la permutación sobre datos no vistos (con más repeticiones) y comparar.

Bloque 9

#	Solución
1	No: la diferencia (0.007) es mucho menor que cualquiera de los desvíos (≈ 0.035). Si importa interpretar, la logística (coeficientes, odds) o un árbol, no el bosque.
2	No es un error: el bosque promedia valores de hojas de entrenamiento y no pasa de ≈ 500 mil. Alternativas: regresión lineal, modelar la tendencia aparte o transformar el objetivo (p. ej. precio por pie^2).
3	No necesariamente. Un bosque con hojas de una observación memoriza el train, y aun así generaliza: lo que importa es el error de test o de CV frente a otras configuraciones (min_samples_leaf mayor, otro max_features) y la brecha entre OOB y test.
4	(a) Random Forest con class_weight o un modelo de boosting, evaluado con recall, F1 o PR-AUC, no con exactitud. (b) Una red convolucional (el bosque no ve la estructura espacial). (c) Regresión logística: casi lineal y pocos datos.