Ejercicios para el cuaderno · Clase 36 · Boosting

Para resolver en papel, con calculadora (tecla ln y exp) · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Para AdaBoost usa $\alpha = \frac{1}{2}\ln((1-\varepsilon)/\varepsilon)$ y los factores e^{α} y $e^{-\alpha}$.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.
- Los bloques 8 y 9 usan los números de la guía (páginas 3 a 7).

Bloque 1 Bagging vs boosting ★

1. Un bosque de 1.000 árboles tarda 100 unidades con 10 procesadores. ¿Cuánto tardaría un boosting de 1.000 árboles en las mismas condiciones y por qué?
2. Completa: en bagging los árboles se entrenan _____ con _____; en boosting se entrenan _____ y cada uno usa el _____ del anterior.
3. ¿Por qué no tiene sentido que cada árbol de AdaBoost use una muestra bootstrap distinta?

Bloque 2 Una ronda de AdaBoost ★★

Diez observaciones con pesos iniciales 0.1. El primer stump clasifica mal 3 de ellas.

1. Calcula el error ponderado ε.
2. Calcula $\alpha = \frac{1}{2}\ln((1-\varepsilon)/\varepsilon)$.
3. Calcula los factores e^{α} y $e^{-\alpha}$ y los pesos sin normalizar de errores y aciertos.
4. Normaliza. ¿Cuánto pesan en total las 3 observaciones mal clasificadas?
5. ★★★ ¿Qué α recibe un stump con $\varepsilon = 0.5$? ¿Y uno con $\varepsilon = 0.8$? Interpreta.

Bloque 3 El voto final de AdaBoost ★

Cuatro stumps con $\alpha = 0.8, 0.5, 0.45$ y 0.2 votan $+1, -1, -1$ y $+1$.

1. Calcula $\Sigma\, \alpha \cdot h$ y la clase predicha.
2. ¿Gana la clase con más votos? Explica.

Bloque 4 Una etapa de Gradient Boosting ★★

Tabla de la clase: $y = [12, 7, 11, 10]$ para A, B, C, D; $F_0 = 10$. El árbol separa {A, C} de {B, D}.

1. Calcula los residuos $r_1 = y - F_0$ y el RMSE inicial.
2. Calcula las predicciones del árbol (media de r_1 por hoja).
3. Con $\eta = 1$ calcula F_1, los nuevos residuos y el RMSE. ¿Mejora cada observación?
4. Repite con $\eta = 0.5$.

Bloque 5 Dos etapas completas ★★★

$y = [10, 4, 9, 17]$ para A, B, C, D; $\eta = 0.5$; pérdida cuadrática. Árbol 1: {A, B} | {C, D}. Árbol 2: {B} | {A, C, D}.

1. Calcula F_0 y r_1. Ajusta el árbol 1 y calcula F_1 y r_2.
2. Ajusta el árbol 2 sobre r_2 y calcula F_2 y r_3.

3 Calcula el RMSE de F_0, F_1 y F_2. ¿Qué observación sigue peor explicada?

Bloque 6 Pérdida y gradiente ★★

1 $y = 20$ y $F = 26$. Calcula $-\partial L/\partial F$ para la pérdida cuadrática $\frac{1}{2}(y - F)^2$, la absoluta y Huber con $\delta = 4$.

2 Clasificación logística, $p = 1/(1 + e^{-F})$: calcula $y - p$ para $(y = 0, p = 0.8)$ y para $(y = 1, p = 0.2)$.

3 ¿Cuál de las tres pérdidas del punto 1 es menos sensible a un valor extremo de y? Justifica.

Bloque 7 Tasa de aprendizaje y número de árboles ★★

Modelo idealizado: cada árbol corrige la fracción η del residuo, que parte en $r_0 = 8$.

1 Calcula el residuo tras 1, 2 y 3 árboles con $\eta = 0.2$.

2 ¿Cuántos árboles hacen falta para bajar de 0.5 con $\eta = 0.2$ y con $\eta = 0.05$?

3 Un compañero usa $\eta = 0.01$ con 100 árboles y obtiene un modelo malo. ¿Qué pasó y qué le recomiendas?

Bloque 8 Curvas, early stopping y sobreajuste ★★

XGBoost en Ames: ronda 100 → RMSE train 20.2k, val 23.7k · ronda 400 → 12.6k, 21.4k · ronda 754 → 9.4k, 21.0k. Validación por ronda: 23, 22, 21.5, 21.2, 21.3, 21.6, 22.

1 Calcula la brecha train-validación en cada ronda. ¿Qué indica?

2 Con early_stopping_rounds = 2 y la secuencia de validación dada (rondas 1 a 7), ¿en qué ronda se detiene y cuál es la mejor?

3 ¿Por qué la validación del early stopping no puede ser el conjunto de test?

Bloque 9 Elegir y leer resultados ★★★

1 Heart: AUC (CV 5×3) AdaBoost 0.912 ± 0.039 y XGBoost 0.894 ± 0.035. ¿Puedes afirmar que AdaBoost es mejor? Justifica.

2 Ames: RMSE de test 24.4k (XGBoost), 36.2k (AdaBoost). ¿Cuánto se equivoca en promedio cada uno en dólares y cuál elegirías?

3 LightGBM en Ames: RMSE de entrenamiento 8.0k y de test 27.0k. Diagnostica y propón dos hiperparámetros para corregirlo.

4 Elige modelo y justifica: (a) 50 millones de filas, tiempo limitado; (b) 2.000 filas con 30 variables categóricas de muchas categorías; (c) base limpia, línea base rápida.

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	10 veces más: 1.000 unidades. Cada árbol necesita el error del anterior, así que no hay árboles que repartir entre procesadores.
2	En paralelo e independientes, con su muestra · en secuencia, error (o residuo) del árbol anterior.
3	Porque los pesos de los casos difíciles se aplican sobre las mismas observaciones. Con muestras distintas, el árbol 2 no vería los casos que el árbol 1 erró.

Bloque 2

#	Solución
1	$\varepsilon = 3 \cdot 0.1 / 1 = 0.3$.
2	$\alpha = ½ \ln(0.7/0.3) = ½ \ln 2.333 = ½ \cdot 0.847 = 0.424$.
3	$e^{0.424} = 1.528$ ($= \sqrt{(7/3)}$); $e^{-0.424} = 0.655$. Errores: $0.1 \cdot 1.528 = 0.1528$ cada uno. Aciertos: $0.1 \cdot 0.655 = 0.0655$ cada uno. Suma $= 3 \cdot 0.1528 + 7 \cdot 0.0655 = 0.458 + 0.458 = 0.917$.
4	Errores: $0.1528/0.917 = 0.1667$ cada uno; aciertos: $0.0655/0.917 = 0.0714$ cada uno. Las 3 observaciones mal clasificadas pesan $3 \cdot 0.1667 = 0.5$: la mitad del total.
5	$\varepsilon = 0.5$: $\alpha = ½ \ln 1 = 0$, el árbol no aporta al voto. $\varepsilon = 0.8$: $\alpha = ½ \ln(0.2/0.8) = ½ \ln 0.25 = -0.693$, es peor que el azar y su voto se invierte (equivale a predecir lo contrario).

Bloque 3

#	Solución
1	$0.8 \cdot (+1) + 0.5 \cdot (-1) + 0.45 \cdot (-1) + 0.2 \cdot (+1) = 0.8 - 0.5 - 0.45 + 0.2 = 0.05 > 0$: clase +1.
2	No: hay 2 votos +1 y 2 votos −1, y el voto ponderado desempata a favor de +1 porque el primer stump pesa más ($\alpha = 0.8$).

Bloque 4

#	Solución
1	$r_1 = [2, -3, 1, 0]$. RMSE $= \sqrt{((4 + 9 + 1 + 0)/4)} = \sqrt{3.5} = 1.87$.
2	{A, C}: $(2 + 1)/2 = 1.5$ · {B, D}: $(-3 + 0)/2 = -1.5$. Predicciones $h = [1.5, -1.5, 1.5, -1.5]$.
3	$\eta = 1$: $F_1 = [11.5, 8.5, 11.5, 8.5]$; $y - F_1 = [0.5, -1.5, -0.5, 1.5]$; RMSE $= \sqrt{((0.25 + 2.25 + 0.25 + 2.25)/4)} = \sqrt{1.25} = 1.12$. No mejora cada una: D pasa de residuo 0 a 1.5, porque comparte hoja con B.
4	$\eta = 0.5$: $F_1 = [10.75, 9.25, 10.75, 9.25]$; $y - F_1 = [1.25, -2.25, 0.25, 0.75]$; RMSE $= \sqrt{((1.5625 + 5.0625 + 0.0625 + 0.5625)/4)} = \sqrt{1.8125} = 1.35$. Baja menos, pero el siguiente árbol puede corregir D.

Bloque 5

#	Solución
1	$F_0 = (10 + 4 + 9 + 17)/4 = 10$; $r_1 = [0, -6, -1, 7]$. Hojas: {A, B} → $(0 - 6)/2 = -3$; {C, D} → $(-1 + 7)/2 = 3$. $F_1 = 10 + 0.5 \cdot h = [8.5, 8.5, 11.5, 11.5]$; $r_2 = y - F_1 = [1.5, -4.5, -2.5, 5.5]$.
2	Árbol 2: {B} → −4.5; {A, C, D} → $(1.5 - 2.5 + 5.5)/3 = 1.5$. $F_2 = F_1 + 0.5 \cdot h_2 = [9.25, 6.25, 12.25, 12.25]$; $r_3 = [0.75, -2.25, -3.25, 4.75]$.
3	$RMSE_0 = \sqrt{((0 + 36 + 1 + 49)/4)} = \sqrt{21.5} = 4.64 \cdot RMSE_1 = \sqrt{((2.25 + 20.25 + 6.25 + 30.25)/4)} = \sqrt{14.75} = 3.84 \cdot RMSE_2 = \sqrt{((0.5625 + 5.0625 + 10.5625 + 22.5625)/4)} = \sqrt{9.6875} = 3.11$. La observación D (residuo 4.75) es la que sigue peor explicada.

Bloque 6

#	Solución
1	Residuo $y - F = -6$. Cuadrática: −6. Absoluta: signo(−6) = −1. Huber ($\delta = 4$): residuo recortado a ±4 → −4.
2	($y = 0$, $p = 0.8$): $y - p = -0.8$. ($y = 1$, $p = 0.2$): $y - p = +0.8$. El modelo está muy seguro y equivocado: el gradiente es grande y empuja fuerte hacia la clase correcta.
3	La absoluta (gradiente acotado en ±1) y Huber (acotado en ±δ). La cuadrática crece con el residuo, así que un valor extremo domina el ajuste.

Bloque 7

#	Solución
1	$r_0(1 - \eta)^m = 8 \cdot 0.8, 8 \cdot 0.64, 8 \cdot 0.512 = 6.4 \cdot 5.12 \cdot 4.096$.
2	Se busca residuo < 0.5, o sea $8(1 - \eta)^m < 0.5 \rightarrow (1 - \eta)^m < 0.0625$. $\eta = 0.2$: $m > \ln 0.0625 / \ln 0.8 = (-2.77)/(-0.223) = 12.4 \rightarrow 13$ árboles. $\eta = 0.05$: $m > (-2.77)/(-0.0513) = 54.1 \rightarrow 55$ árboles.
3	Subajuste: con $\eta = 0.01$ el residuo tras 100 árboles sigue en $0.99^{100} = 37\%$ del inicial. Recomendación: subir n_estimators (≈ 300 para el 5%) o usar early stopping, o aumentar η.

Bloque 8

#	Solución
1	Brechas: ronda 100 → 3.5k; ronda 400 → 8.8k; ronda 754 → 11.6k. El entrenamiento sigue bajando y la validación se aplana: la brecha crece (más memoria, poca ganancia en validación).
2	El mínimo es 21.2 en la ronda 4. Las rondas 5 (21.3) y 6 (21.6) no mejoran: se detiene tras la 6 y la mejor ronda es la 4.
3	Porque se usa para elegir la ronda: dejaría de ser independiente y la estimación final del error sería optimista.

Bloque 9

#	Solución
1	No. La diferencia (0.018) es menor que cualquiera de los desvíos (0.039 y 0.035). Con 303 pacientes no se distinguen: hacen falta más repeticiones o más datos.
2	≈ 24 mil dólares por casa (XGBoost) y ≈ 36 mil (AdaBoost). Se elige XGBoost: 12 mil menos de error promedio, una diferencia grande.
3	Sobreajuste: gran brecha. Corregir con menos hojas (num_leaves 15), más min_child_samples (50), y además subsample con subsample_freq = 1, colsample_bytree o reg_lambda, y early stopping.
4	(a) LightGBM: histogramas y hojas, ideal para gran escala. (b) CatBoost: muchas categóricas; con 2.000 filas ojo con el sobreajuste. (c) AdaBoost o Gradient Boosting con pocos hiperparámetros.