Apuntes · Clase 37 · SVM y clasificadores clásicos

Para leer antes de los ejercicios · lectura de ~30 min

Lo más importante, en 6 ideas

1. **Probabilidad y decisión son cosas distintas.** La logística da p(x); el umbral t decide. Cambiar t no cambia p, solo la clase.
2. **La exactitud no basta.** Con la matriz de confusión se calculan sensibilidad, especificidad y precisión; siempre contra la línea base «clase mayoritaria».
3. **SVM = margen máximo.** f(x) = w·x + b; el ancho del margen es 2/||w|| y solo los vectores de soporte importan. f(x) no es una probabilidad.
4. **C y γ regulan la flexibilidad.** C pequeño tolera violaciones (suave); γ grande hace fronteras locales (riesgo de sobreajuste).
5. **Estandarizar y validar sin fugas.** Media y sd del entrenamiento, dentro de un Pipeline; C, γ y t se eligen con validación cruzada en entrenamiento.
6. **Se evalúa una sola vez.** La prueba compara el procedimiento ya elegido; mirarla para decidir la convierte en validación.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C37_SVM.ipynb` o el cuaderno `C37_Ejercicios_Cuaderno_SVM.pdf`.

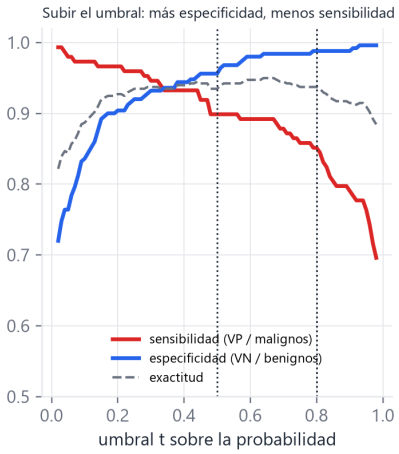
1 Regresión logística: de η a la clase

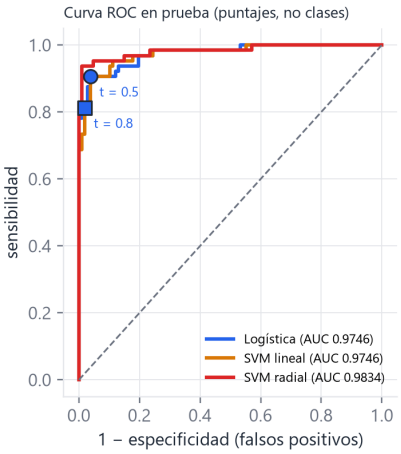
La regresión logística calcula un puntaje $\eta = \beta_0 + \beta_1 z_1 + \ldots$ y lo convierte en probabilidad con $p = 1/(1 + e^{-\eta})$. Si η = 0, p = 0.5. Cada coeficiente multiplica los *odds* p/(1 − p) por e^{β} al subir una unidad (con variables estandarizadas, una desviación estándar). Con umbral t, se predice 1 si p ≥ t; un t más alto da más especificidad y menos sensibilidad.

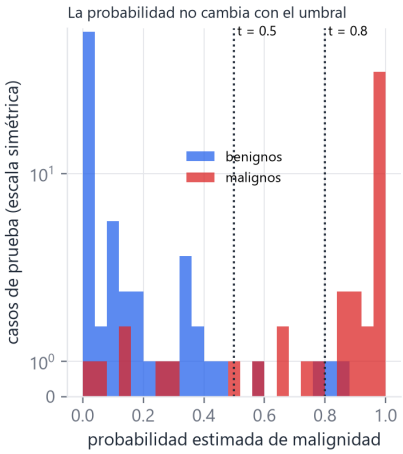
Ejemplo resuelto · $\eta = -2 + 0.9 \cdot z_1 + 0.5 \cdot z_2$

Pregunta	Cálculo	Resultado
Caso A ($z_1 = 2$, $z_2 = 1$): puntaje	$-2 + 0.9 \cdot 2 + 0.5 \cdot 1$	$\eta = 0.30$
Su probabilidad	$1/(1 + e^{-0.3}) = 1/(1 + 0.741)$	$p = 0.574$
Caso B ($z_1 = -1$, $z_2 = 0.5$)	$\eta = -2 - 0.9 + 0.25 = -2.65 \rightarrow 1/(1 + e^{2.65})$	$p = 0.066$
Efecto de +1 en z_1	$e^{0.9}$	odds × 2.46
Clase con t = 0.5 y con t = 0.7 (caso A)	$0.574 \geq 0.5 \cdot 0.574 < 0.7$	1 · 0

La probabilidad del caso A es 0.574 con cualquier umbral; solo cambia la decisión. Con t = 0.7 el modelo es más exigente: menos falsos positivos y más falsos negativos.







Pista para la Parte A del notebook y el Bloque 1 del cuaderno
Ajusta `LogisticRegression(penalty=None)`, calcula a mano $1/(1 + e^{-\eta})$ para un caso de prueba y compara con `predict_proba`. Prueba t = 0.5 y 0.8.

2 Matriz de confusión y métricas

Con la clase positiva declarada (maligno = 1) y filas = real, columnas = predicho: VN y FP arriba, FN y VP abajo. **Exactitud** = (VP + VN)/n; **sensibilidad** = VP/(VP + FN); **especificidad** = VN/(VN + FP); **precisión** = VP/(VP + FP); **F1** = 2VP/(2VP + FP + FN); **exactitud balanceada** = (sensibilidad + especificidad)/2. La AUC evalúa el orden de los puntajes para todos los umbrales.

Ejemplo resuelto · VN = 70, FP = 10, FN = 15, VP = 55 (n = 150)

Pregunta	Cálculo	Resultado
Exactitud	(55 + 70)/150	83.3 %
Sensibilidad · especificidad	55/70 · 70/80	78.6 % · 87.5 %
Precisión · F1	55/65 · 110/(110 + 10 + 15)	84.6 % · 0.815
Exactitud balanceada	(0.786 + 0.875)/2	0.830
Línea base «siempre negativo»	80/150 · sensibilidad 0/70	53.3 % · 0 %

El modelo supera a la línea base en exactitud (83.3 % frente a 53.3 %). Si dejar escapar un positivo cuesta mucho más que una falsa alarma, importa la sensibilidad (78.6 %), no la exactitud.

Pista para la Parte A del notebook (A2) y el Bloque 2 del cuaderno
Calcula la matriz con `confusion_matrix(y, pred, labels=[0, 1])`, saca las métricas a mano y con `recall_score(..., pos_label=0)` para la especificidad.

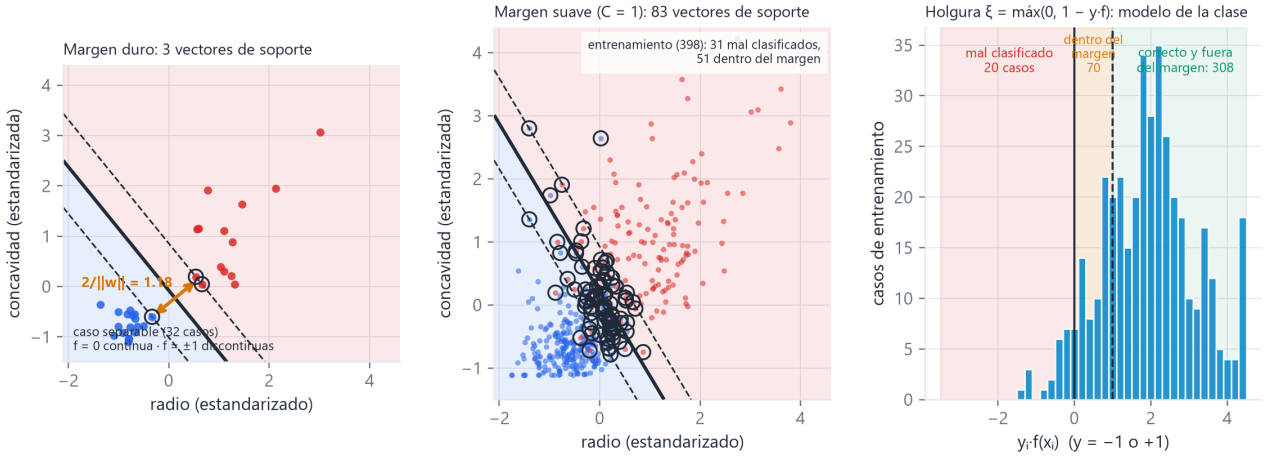
3 SVM: hiperplano, distancia y margen

El modelo es **f(x) = w·x + b**; la clase es el signo de f(x). La distancia de un punto a la frontera es **|f(x)|/||w||** y el ancho total del margen es **2/||w||** (bordes en f = ±1). Para un caso con etiqueta y = ±1 se mira **y·f(x)**: ≥ 1 está bien y fuera del margen; entre 0 y 1, dentro del margen; < 0, mal clasificado. La holgura es **ξ = máx(0, 1 − y·f(x))**, y la función objetivo $\frac{1}{2}\|w\|^2 + C\cdot\Sigma\xi$. Son vectores de soporte los casos con y·f(x) ≤ 1.

Ejemplo resuelto · w = (3, −4), b = 2

Pregunta	Cálculo	Resultado
Norma y ancho del margen	$\|\|w\|\| = \sqrt{(9 + 16)} = 5 \cdot 2/5$	$\|\|w\|\| = 5 \cdot 0.4$
x = (2, 1): puntaje y clase	3·2 − 4·1 + 2	f = 4 → +1
Distancia a la frontera	|4|/5	0.8
x = (−1, 2)	−3 − 8 + 2 = −9 · |−9|/5	−1 · 1.8
Holguras con y·f = 1.6, 0.4 y −0.5	máx(0, 1 − y·f)	ξ = 0 · 0.6 · 1.5
Costo de holgura con C = 0.1 y C = 10	Σξ = 2.1: 0.1·2.1 · 10·2.1	0.21 · 21

Los tres casos de holgura son: correcto fuera del margen, correcto dentro del margen (0.4 < 1) y mal clasificado (−0.5 < 0). Los dos últimos son vectores de soporte.



Pista para la Parte B del notebook (B1) y el Bloque 3 del cuaderno

Ajusta `SVC(kernel='linear')`, lee `coef_`, `intercept_` y `decision_function`, y comprueba a mano w·x + b y 2/||w||.

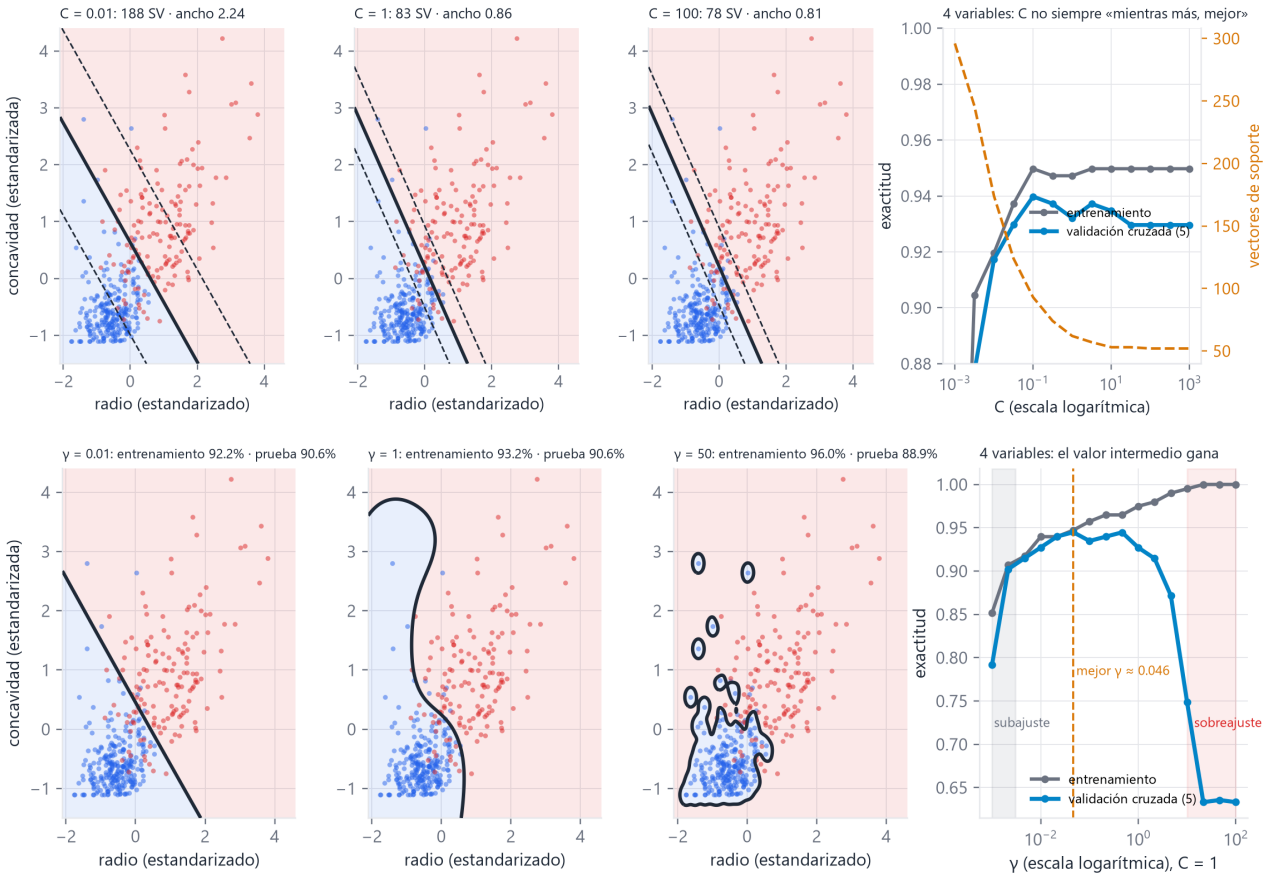
4 C, kernel y gamma

C pondera las holguras: C pequeño tolera más violaciones (margen ancho, más regularización); C grande las castiga (margen estrecho, riesgo de sobreajuste). El **kernel** define la forma de la frontera: lineal, polinomial o radial $K = \exp(-\gamma\|x - z\|^2)$. Con γ pequeño la similitud decae lento (frontera casi lineal); con γ grande es local y la frontera memoriza. Se necesita validar: «C o γ más altos» no siempre mejoran.

Ejemplo resuelto · holguras y similitud con otros valores

Pregunta	Cálculo	Resultado
Σξ = 5: contribución con C = 0.1 y C = 10	0.1·5 · 10·5	0.5 · 50
Similitud RBF a distancia 3 con γ = 0.05	$e^{-0.05 \cdot 9} = e^{-0.45}$	0.638
Misma distancia con γ = 0.5	$e^{-0.5 \cdot 9} = e^{-4.5}$	0.011
Ajustes en una rejilla de 4 C × 3 γ con 5 folds	4·3·5	60 (más 1 reajuste)

Con γ = 0.5 dos puntos a distancia 3 casi no se «ven» (0.011): la frontera se vuelve muy local. Con γ = 0.05 todavía se parecen (0.638): frontera más suave.



Pista para la Parte C del notebook y el Bloque 5 del cuaderno

Dibuja las fronteras para tres valores de C y de γ con dos variables y mira las curvas de entrenamiento frente a validación cruzada para elegir un valor intermedio.

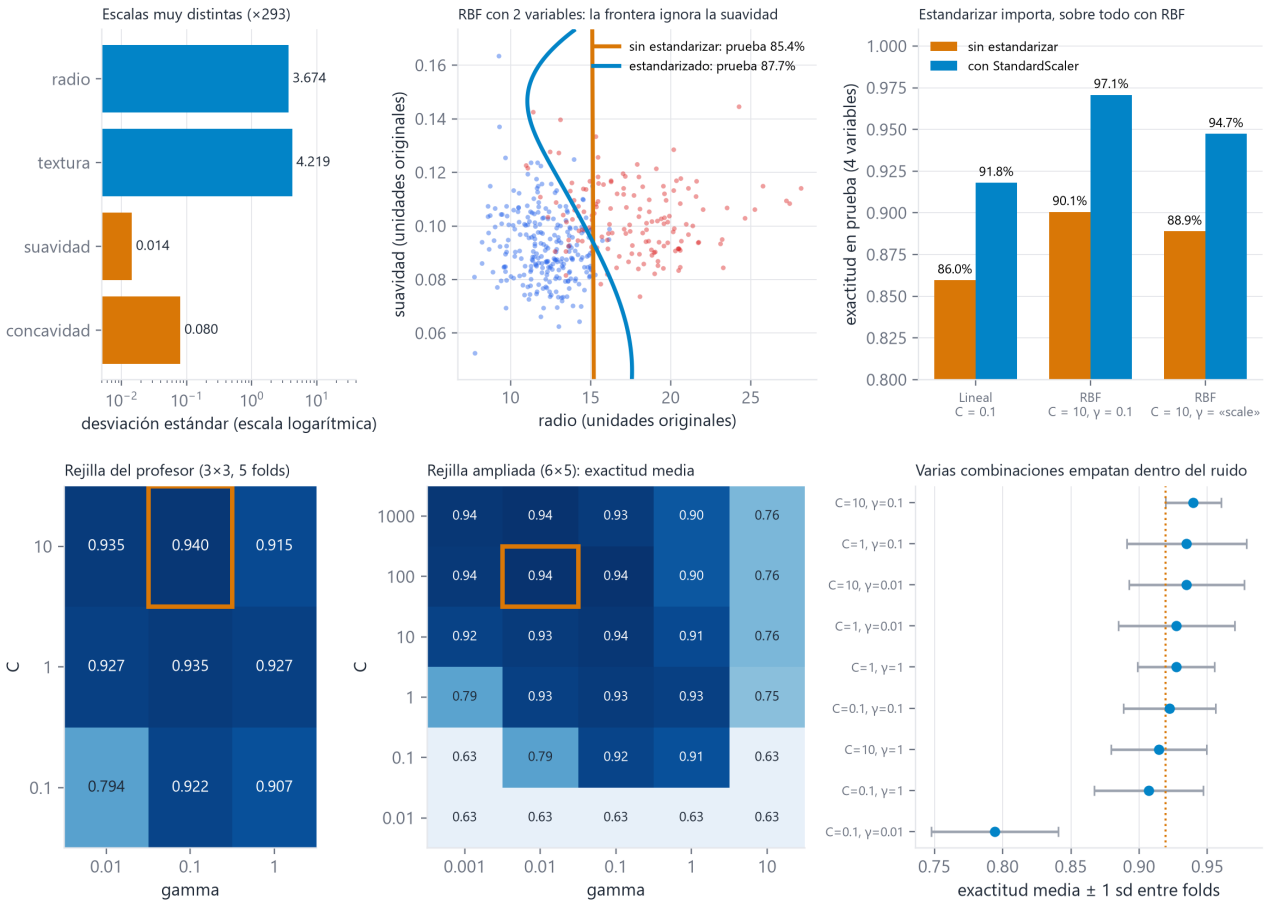
5 Estandarizar, validación cruzada y búsqueda en rejilla

Se estandariza con la **media y la sd del entrenamiento** (z = (x − media)/sd) y la misma transformación se aplica a prueba y a casos nuevos. Dentro de la validación cruzada de k folds, la escala se aprende solo con los k − 1 folds de ajuste (un `Pipeline`). `GridSearchCV` prueba todas las combinaciones de C y γ, promedia la exactitud entre folds y reajusta la mejor con todo el entrenamiento.

Ejemplo resuelto · tres combinaciones en 5 folds

Pregunta	Cálculo	Resultado
Radio 21 con media 14.0 y sd 3.5	(21 − 14.0)/3.5	z = 2.0
Exactitud por fold de (C = 1, γ = 0.1): 0.94, 0.92, 0.95, 0.93, 0.96	(0.94 + 0.92 + 0.95 + 0.93 + 0.96)/5	media 0.940
Otra combinación: 0.90, 0.95, 0.97, 0.92, 0.93	suma 4.67/5	media 0.934
¿Cuál se elige?	mayor media en validación; la prueba no participa	la primera (0.940)

Las diferencias de 0.6 puntos son menores que la variación entre folds; en un caso real se puede preferir la combinación más simple. Lo que no se hace es decidir con la prueba.



Pista para la Parte D del notebook y los Bloques 6 y 7 del cuaderno

Ajusta un `Pipeline` con `GridSearchCV` solo en entrenamiento, mira `cv_results_` y evalúa el mejor una sola vez en prueba.

Lo que debes recordar

- Probabilidad con la logística (o `probability=True`, calibrada); puntaje con `decision_function`: no son lo mismo.
- R ↔ Python: `glm(family = binomial)` ↔ `LogisticRegression(penalty=None)`; `cost` ↔ `C`; `'radial'` ↔ `'rbf'`; `scale = TRUE` ↔ `StandardScaler`.
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–C del notebook → Bloques 5–7 → Parte D → ejercicio de cierre.