Apuntes · Clase 38 · Evaluación y selección de modelos

Para leer antes de los ejercicios · lectura de ~30 min

Lo más importante, en 6 ideas

1. **La métrica es una decisión.** MAE, RMSE, R^2, log loss o costo miden cosas distintas; se fijan antes de ver resultados.
2. **Validar es predecir lo que el modelo no vio.** Pliegues por grupo, preprocesamiento dentro del Pipeline, prueba intacta hasta el final.
3. **OOF: una predicción honesta por fila.** RMSE OOF = raíz del promedio de todos los errores; no es el promedio de los RMSE.
4. **Sesgo, varianza y ruido.** Más flexibilidad: menos sesgo, más varianza; el ajuste siempre baja, lo nuevo hace una U.
5. **Probabilidad ≠ decisión.** ROC/PR miden el orden, log loss y calibración las probabilidades, el costo la decisión.
6. **Elegir también sobreajusta.** La validación anidada mide el procedimiento completo; AIC/BIC penalizan sin datos nuevos.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C38_EvaluacionModelos.ipynb` o el cuaderno `C38_Ejercicios_Cuaderno_EvaluacionModelos.pdf`.

1 Pérdida y métricas: MAE, RMSE y R^2

El error de un caso es $e = y - \hat{y}$. Una métrica resume los errores con una función: MAE promedia $|e|$ (cada unidad pesa igual), RMSE promedia e^2 y saca raíz (los errores grandes pesan más) y $R^2 = 1 - SSE/SST$ compara con predecir la media. MAE y RMSE están en las unidades de y; R^2 no.

Ejemplo resuelto · cuatro mediciones: y = (30, 25, 40, 35) y ŷ = (28, 29, 37, 38)

Paso	Cálculo	Resultado
Errores $e = y - \hat{y}$	30−28, 25−29, 40−37, 35−38	2, −4, 3, −3
MAE	(2 + 4 + 3 + 3)/4	3.00
MSE y RMSE	(4 + 16 + 9 + 9)/4 = 9.5; raíz	3.082
SSE y SST	$\Sigma e^2 = 38$; media de y = 32.5, $\Sigma(y - \bar{y})^2 = 125$	38 y 125
R^2	1 − 38/125	0.696

Lectura: el RMSE (3.08) supera al MAE (3.00) porque hay errores desiguales; si todos fueran ±3, serían iguales. **Error común**: decir que un R^2 de 0.70 es «bueno» sin mirar el campo, o creer que R^2 no puede ser negativo (sí puede, si el modelo es peor que la media).

Pista para la Parte A del notebook y el Bloque 1 del cuaderno

Calcula las tres métricas con NumPy y con `sklearn.metrics`, y reproduce el ejemplo de correlación 1 con $R^2 = -149$.

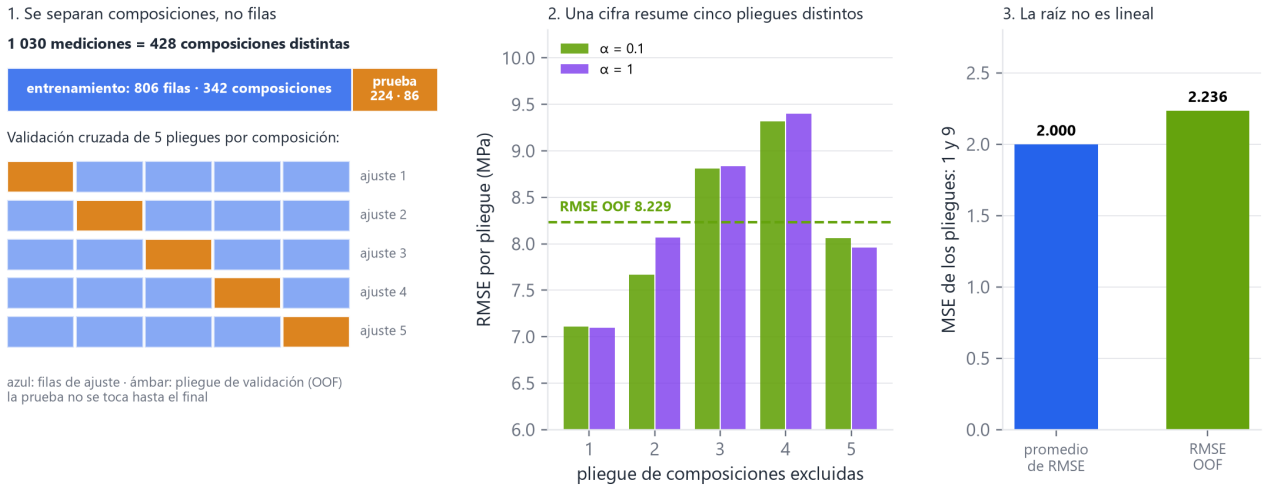
2 Pliegues, OOF y por qué no se promedian los RMSE

Con validación cruzada, cada fila se predice con un modelo ajustado sin su pliegue (predicción **OOF**). El RMSE OOF reúne todos los errores al cuadrado y saca una sola raíz; el promedio de RMSE saca raíz en cada pliegue y luego promedia. Como la raíz no es lineal, no coinciden, y si los pliegues tienen distinto tamaño la diferencia crece. Todo el preprocesamiento va dentro del `Pipeline` para que en cada pliegue se aprenda solo con las filas de ajuste.

Ejemplo resuelto · tres pliegues de 10, 10 y 20 filas con MSE 4, 9 y 16

Resumen	Cálculo	Resultado
RMSE por pliegue	√4, √9, √16	2, 3 y 4
Promedio de RMSE	(2 + 3 + 4)/3	3.000
Suma de cuadrados total	10·4 + 10·9 + 20·16	450
RMSE OOF	√(450/40)	3.354

Lectura: el pliegue grande (20 filas, el de peor error) pesa más en el RMSE OOF, que por eso supera al promedio (3.354 frente a 3.000). **Error común**: calcular un «intervalo» con la desviación de los pliegues como si fueran réplicas independientes: comparten datos de entrenamiento.



Pista para la Parte A del notebook (A2 y A3) y el Bloque 2 del cuaderno

Calcula el RMSE OOF de los siete candidatos con tus propios pliegues y compáralo con el promedio de RMSE; después repite con particiones al azar.

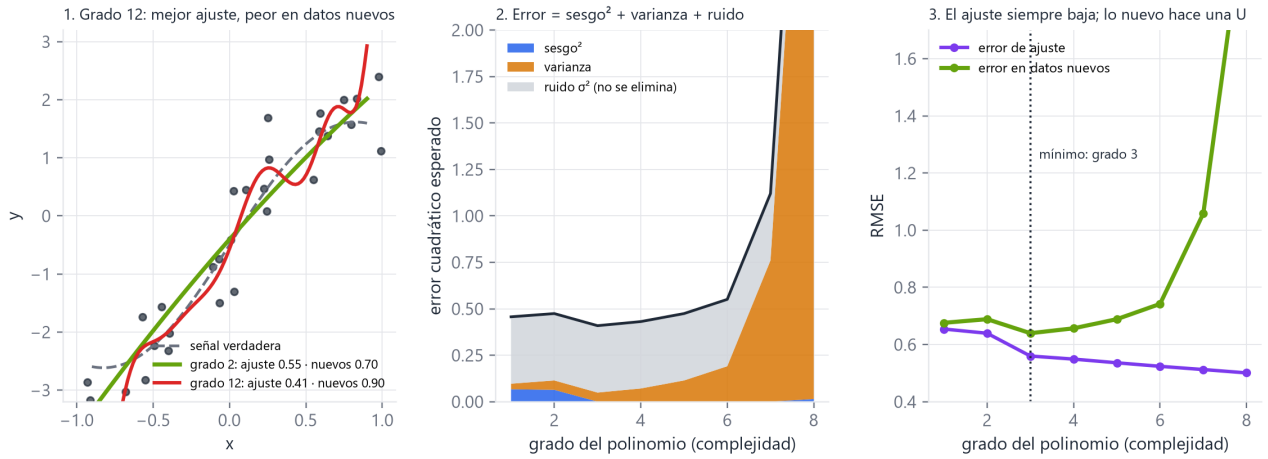
3 Sesgo, varianza y qué hacer en cada caso

El error de predicción se descompone en sesgo² + varianza + ruido. Se diagnostica comparando error de ajuste y de validación: ambos altos y juntos → **sesgo alto** (modelo muy simple: añadir flexibilidad o variables); ajuste bajo y validación alta con brecha grande → **varianza alta** (más datos, más penalización o menos flexibilidad). El ruido no se reduce.

Ejemplo resuelto · penalización ridge α con error de ajuste y de validación (RMSE)

α	Ajuste	Validación	Brecha	Diagnóstico
0.01	2.1	4.8	2.7	varianza alta (sobreajuste)
1	2.9	3.9	1.0	equilibrado: se elige
100	4.2	4.5	0.3	sesgo alto (muy penalizado)

Lectura: se elige α = 1 porque tiene el menor error de **validación** (3.9), no el menor de ajuste. **Error común**: elegir por error de ajuste: siempre favorece al modelo más flexible.



Pista para la Parte C del notebook (C1 y C2) y el Bloque 3 del cuaderno
Simula la descomposición con 400 muestras por grado y dibuja las curvas de aprendizaje del hormigón.

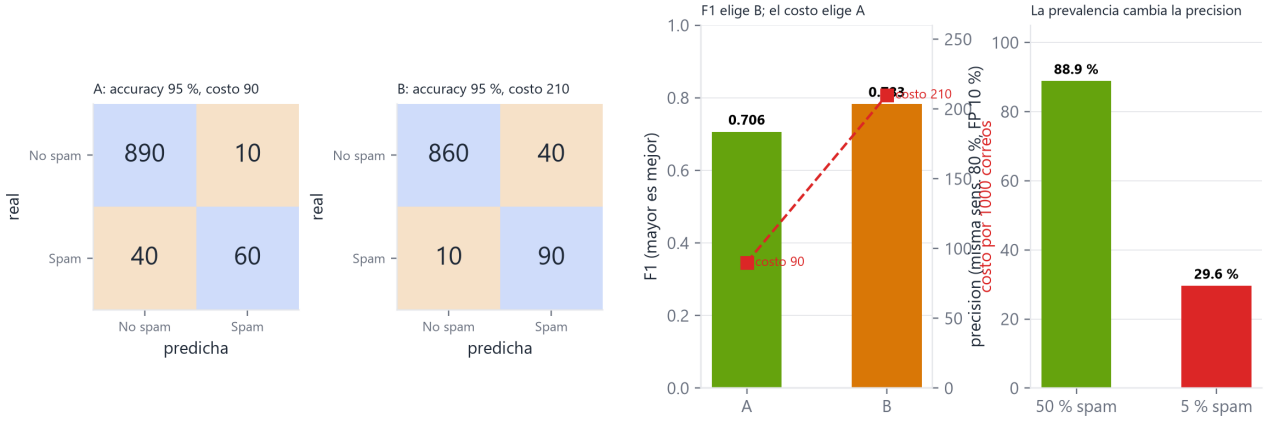
4 Clasificación: matriz de confusión, costo y log loss

La matriz de confusión cuenta VN, FP, FN y VP. Accuracy = (VN + VP)/n trata igual a todos los errores; el costo pondera: costo = (c_FP·FP + c_FN·FN)/n. Los costos se declaran **antes**. El log loss $-\ln p$(clase verdadera) y el Brier $(y - p)^2$ evalúan las probabilidades, no solo la clase.

Ejemplo resuelto · 200 correos: VN = 150, FP = 10, FN = 15, VP = 25; costos FP = 3 y FN = 1

Métrica	Cálculo	Resultado
Accuracy	(150 + 25)/200	87.5 %
Precision y recall	25/35 y 25/40	0.714 y 0.625
F1	2·25/(2·25 + 10 + 15)	0.667
Costo por 1 000	(3·10 + 15)/200·1000	225
Referencia «siempre no spam»	accuracy 160/200; costo 40/200·1000	80 % y 200

Lectura: el modelo acierta más (87.5 % frente a 80 %) pero cuesta **más** (225 frente a 200) porque sus 10 FP pesan 3 cada uno: con estos costos no mejora a la regla trivial. **Error común**: elegir por accuracy cuando los errores no cuestan lo mismo.



Pista para la Parte B del notebook (B1 a B3) y el Bloque 5 del cuaderno
Calcula log loss y Brier a mano para tres correos y comprueba con scikit-learn; luego calcula el costo de dos reglas.

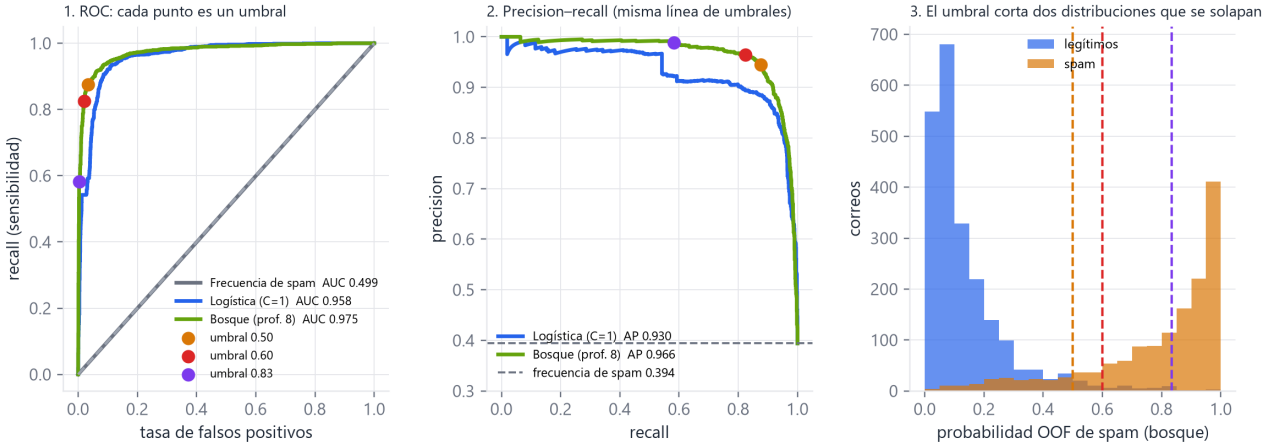
5 ROC, AUC y umbral

Para cada umbral t se marca spam si p ≥ t y se obtiene un punto (tasa de FP, recall). Al bajar t se suben ambos. La curva ROC los une; el AUC es el área y equivale a la probabilidad de que un positivo reciba mayor puntaje que un negativo. La curva precision–recall usa precision y recall y depende de la proporción de positivos. El umbral que minimiza el costo con probabilidades correctas es c_FP/(c_FP + c_FN).

Ejemplo resuelto · tres spam con puntajes 0.9, 0.6, 0.4 y tres legítimos con 0.7, 0.3, 0.2

Umbral t	VP	FP	Recall	FPR
0.9	1	0	1/3	0
0.7	1	1	1/3	1/3
0.6	2	1	2/3	1/3
0.4	3	1	1	1/3
0.3	3	2	1	2/3
0.2	3	3	1	1

AUC por trapecios: 1/3·(1/3) + 1·(1/3) + 1·(1/3) = 7/9 ≈ 0.778. Por pares: 0.9 supera a 3 legítimos, 0.6 a 2 y 0.4 a 2: 7 de 9. **Error común**: leer una AUC de 0.78 como «78 % de aciertos» (resume el orden, no fija ningún umbral).



Pista para la Parte B del notebook (B4 a B6) y el Bloque 4 del cuaderno

Construye la ROC con `roc_curve`, marca los umbrales 0.5, 0.6 y 5/6 y busca el mínimo de costo en una cuadrícula.

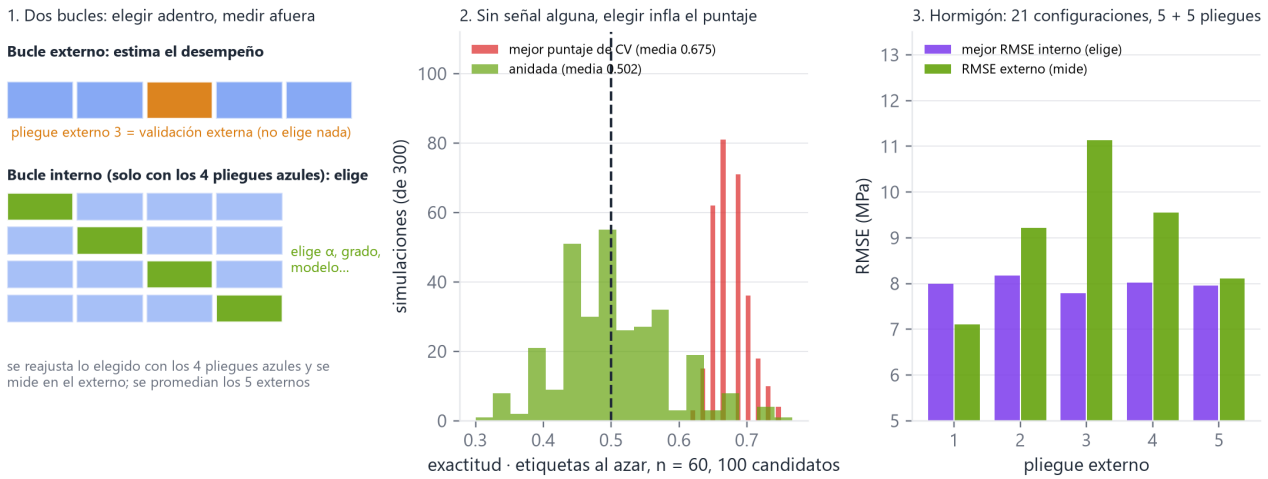
6 AIC, BIC y validación anidada

Con errores normales, AIC = n·ln(SSE/n) + 2k y BIC = n·ln(SSE/n) + k·ln n (más una constante que no cambia la comparación); k cuenta los coeficientes. Gana el menor. El BIC penaliza más cuando n > 7. La validación anidada usa un bucle interno para elegir hiperparámetros y uno externo para medir; así el desempeño informado no se infla por haber elegido el mejor de varios.

Ejemplo resuelto · n = 50: M1 con k = 2 y SSE = 60; M2 con k = 4 y SSE = 45

Modelo	k	SSE	AIC	BIC
M1	2	60	13.12	16.94
M2	4	45	2.73	10.38

Lectura: ΔAIC = 10.4 y ΔBIC = 6.6 a favor de M2: bajar la SSE de 60 a 45 compensa los 2 parámetros extra. **Anidada**: con 5 pliegues externos, 4 internos y 6 candidatos hay 5·4·6 + 5 = 125 ajustes, frente a 5·6 + 1 = 31 de una búsqueda simple. **Error común**: informar el mejor puntaje interno como si fuera el desempeño esperado.



Pista para la Parte C del notebook (C4 a C6) y los Bloques 6 y 7 del cuaderno

Calcula AIC y BIC con `statsmodels`, compara con la CV y mide el optimismo con una validación anidada.

Lo que debes recordar

- Métrica, referencia y regla de elección se fijan antes de ver resultados.
- Preprocesamiento dentro del Pipeline; pliegues por grupo cuando hay filas relacionadas.
- Una cifra de validación o de prueba es una estimación con incertidumbre.
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–B del notebook → Bloques 5–7 → Partes C–D → ejercicio de cierre.