Ejercicios para el cuaderno · Clase 38 · Evaluación y selección de modelos

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: MAE = $\Sigma|e|/n$ · RMSE = $\sqrt{(\Sigma e^2/n)}$ · $R^2 = 1 - SSE/SST$ · RMSE OOF = $\sqrt{(\Sigma \text{ todos los } e^2/n)}$ · costo = $(c_{FP}\cdot FP + c_{FN}\cdot FN)/n$ · AIC = $n \ln(SSE/n) + 2k$ · BIC = $n \ln(SSE/n) + k \ln n$.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 RMSE, MAE y R^2 a mano ★★

Cinco mediciones de resistencia: y = (12, 15, 9, 20, 14) y predicciones $\hat{y}$ = (10, 16, 12, 17, 15).

1. Calcula los errores y el MAE.
2. Calcula el RMSE. ¿Es mayor o menor que el MAE? ¿Por qué?
3. Calcula R^2 con la media de y y con la media de entrenamiento 13 como referencia.
4. Si el error del cuarto caso fuera 6 en vez de 3 ($\hat{y}_4 = 14$), ¿qué métrica sube más, MAE o RMSE? Calcúlalas.

Bloque 2 Pliegues, media y desviación ★★

Una validación cruzada de 4 pliegues con 25 filas cada uno entrega los RMSE: 2, 3, 4 y 5.

1. Calcula el promedio de RMSE y su desviación estándar muestral.
2. Calcula el RMSE OOF reuniendo los errores. ¿Coincide con el promedio? ¿Por qué?
3. Si el último pliegue tuviera 75 filas y los otros 25, ¿cuánto vale ahora el RMSE OOF?
4. ¿Por qué la desviación entre pliegues no es un intervalo de confianza?

Bloque 3 Sesgo y varianza leídos en las curvas ★★★

Error de ajuste y de validación (RMSE) de polinomios de distinto grado: grado 1: 6.0 y 6.4; grado 3: 3.1 y 3.6; grado 6: 2.0 y 4.1; grado 10: 0.8 y 5.9; grado 15: 0.1 y 11.0.

1. ¿Qué grado eliges y por qué?
2. Diagnostica el grado 1 y el grado 15 (sesgo alto o varianza alta).
3. Calcula la brecha (validación − ajuste) de cada grado. ¿Qué patrón ves?
4. Para cada diagnóstico, propón una acción: más datos, más flexibilidad, penalización, menos variables.

Bloque 4 ROC a mano y AUC por trapecios ★★★

Ocho correos con puntaje de spam y etiqueta real (1 = spam): (0.95; 1), (0.85; 1), (0.80; 0), (0.70; 1), (0.55; 0), (0.45; 1), (0.30; 0), (0.10; 0).

1. Con el umbral bajando por cada puntaje, escribe el par (tasa de FP, recall) de cada paso.
2. Calcula el AUC con trapecios.
3. Cuenta los pares (positivo, negativo) bien ordenados y comprueba que da el mismo AUC.
4. ¿Qué significa un AUC de 0.8125? ¿Dice cuántos correos se clasifican bien?

Bloque 5 Elegir el umbral por costo ★★

Con los mismos ocho correos, bloquear un legítimo (FP) cuesta 4 y dejar pasar un spam (FN) cuesta 1.

1. Calcula FP, FN y el costo para t = 0.90, 0.85, 0.75, 0.60, 0.50, 0.40 y 0.20.
2. ¿Qué umbral minimiza el costo y cuánto vale?
3. Calcula el umbral teórico c_FP/(c_FP + c_FN) y compáralo con tu resultado.
4. Compara con la regla «dejar pasar todo». ¿Mejora el modelo a esa referencia?

Bloque 6 AIC y BIC ★★

Con n = 100 se ajustan tres modelos: M1 (k = 3, SSE = 250), M2 (k = 5, SSE = 200) y M3 (k = 9, SSE = 170).

1. Calcula AIC = n ln(SSE/n) + 2k de cada modelo y elige.
2. Calcula BIC = n ln(SSE/n) + k ln n de cada modelo y elige.
3. ¿Por qué pueden discrepar? ¿Cuál es más prudente con muchos parámetros?
4. Menciona una razón por la que ninguno reemplaza a la validación cruzada.

Bloque 7 ¿Para qué la validación anidada? ★★

Se prueban 6 valores de α. La búsqueda simple usa 5 pliegues; la anidada, 5 externos y 4 internos.

1. Cuenta los ajustes de una búsqueda simple (con el reajuste final) y de la anidada.
2. Un analista informa «el mejor RMSE de CV fue 7.9»; la anidada da 9.1. ¿Cuál estima mejor el desempeño futuro del procedimiento?
3. Con etiquetas al azar, ¿qué exactitud esperarías de la anidada y por qué el mejor puntaje de CV da más?
4. ¿Con qué modelo final se predice en producción?

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	$e = y - \hat{y} = (2, -1, -3, 3, -1)$. MAE = (2 + 1 + 3 + 3 + 1)/5 = 2.00.
2	MSE = (4 + 1 + 9 + 9 + 1)/5 = 4.80; RMSE = 2.191. Es mayor que el MAE porque los errores no son iguales (el cuadrado pesa más los grandes).
3	$\bar{y} = 14$, SST = 4 + 1 + 25 + 36 + 0 = 66; SSE = 24; $R^2 = 1 - 24/66 = 0.636$. Con referencia 13: SSE_ref = (1 + 4 + 16 + 49 + 1) = 71; 1 − 24/71 = 0.662.
4	Con $\hat{y}_4 = 14$ el error del cuarto es 6: errores (2, −1, −3, 6, −1). MAE = 13/5 = 2.60 (sube 0.6); RMSE = √(51/5) = 3.194 (sube 1.003). En términos relativos, el RMSE sube más (46 % frente a 30 %).

Bloque 2

#	Solución
1	Promedio = 14/4 = 3.5. Desviación muestral = √[(2.25 + 0.25 + 0.25 + 2.25)/3] = 1.291.
2	MSE por pliegue: 4, 9, 16, 25; promedio 13.5; RMSE OOF = √13.5 = 3.674. No coincide con 3.5: la raíz no es lineal (√ de promedio ≥ promedio de √).
3	Suma de cuadrados = 25·(4 + 9 + 16) + 75·25 = 725 + 1 875 = 2 600; n = 150; RMSE OOF = √(2 600/150) = 4.163. El pliegue grande pesa más.
4	Los pliegues comparten filas de entrenamiento: sus errores no son réplicas independientes, y la desviación subestima o confunde la incertidumbre real.

Bloque 3

#	Solución
1	Grado 3: tiene el menor error de validación (3.6). Los grados 6, 10 y 15 ajustan mejor (2.0, 0.8, 0.1) pero validan peor (4.1, 5.9, 11.0).
2	Grado 1: ajuste 6.0 y validación 6.4, ambos altos y juntos → sesgo alto. Grado 15: ajuste 0.1 y validación 11.0 → varianza alta (sobreajuste).
3	Brechas: 1: 0.4, 3: 0.5, 6: 2.1, 10: 5.1, 15: 10.9. La brecha crece con el grado; el error de ajuste solo baja.
4	Sesgo alto: más flexibilidad (más grado o variables). Varianza alta: más datos, penalización (ridge/lasso) o menos variables/grado.

Bloque 4

#	Solución
1	(FPR, recall) por paso: (0, 0.25), (0, 0.50), (0.25, 0.50), (0.25, 0.75), (0.50, 0.75), (0.50, 1), (0.75, 1), (1, 1).
2	Solo hay avance horizontal en 4 pasos de ΔFPR = 0.25, con recall 0.50, 0.75, 1 y 1: área = 0.25·0.50 + 0.25·0.75 + 0.25·1 + 0.25·1 = 0.125 + 0.1875 + 0.25 + 0.25 = 0.8125 (los tramos verticales no suman área).
3	Positivos: 0.95, 0.85, 0.70, 0.45; negativos: 0.80, 0.55, 0.30, 0.10. 0.95 supera a 4; 0.85 a 4; 0.70 a 3; 0.45 a 2 → 13 de 16 = 0.8125.
4	Es la probabilidad de que un spam elegido al azar reciba mayor puntaje que un legítimo. No dice cuántos se clasifican bien: eso depende del umbral.

Bloque 5

#	Solución
1	t = 0.90: FP 0, FN 3, costo 3; t = 0.85: FP 0, FN 2, costo 2; t = 0.75: FP 1, FN 2, costo 6; t = 0.60: FP 1, FN 1, costo 5; t = 0.50: FP 2, FN 1, costo 9; t = 0.40: FP 2, FN 0, costo 8; t = 0.20: FP 3, FN 0, costo 12.
2	El mínimo es 2, con t = 0.85 (cualquier t en (0.80, 0.85]): se bloquean 0.95 y 0.85, sin FP y con 2 FN.
3	Teórico: 4/(4 + 1) = 0.80 (bloquear si p > 0.80). Coincide con la zona óptima; con probabilidades mal calibradas pueden separarse.
4	«Dejar pasar todo»: FN = 4, FP = 0 → costo 4. El umbral 0.85 (costo 2) la mejora; con t = 0.50 (costo 9) la regla trivial sería mejor.

Bloque 6

#	Solución
1	AIC: M1 = 97.63; M2 = 79.31; M3 = 71.06. Gana M3 (el menor).
2	BIC (ln 100 = 4.605): M1 = 105.44; M2 = 92.34; M3 = 94.51. Gana M2.
3	El BIC penaliza cada parámetro con 4.605 y el AIC con 2: M3 agrega 4 parámetros por una baja de SSE de 200 a 170, que el AIC acepta y el BIC no. El BIC es más prudente con muchos parámetros.
4	Se calculan con las filas de ajuste y suponen un modelo y observaciones independientes; no miran datos nuevos ni sirven para comparar modelos de distinta familia sin verosimilitud.

Bloque 7

#	Solución
1	Simple: 5 pliegues × 6 valores + 1 reajuste = 31 ajustes. Anidada: 5 externos × 4 internos × 6 valores + 5 reajustes = 125.
2	La anidada (9.1): el mejor RMSE de CV (7.9) se obtuvo eligiendo el mínimo entre varios y es optimista.
3	Con etiquetas al azar la anidada da ≈ 0.50 (no hay señal que aprender); el mejor puntaje de CV entre muchos candidatos da más (en la simulación del curso, ≈ 0.68) solo porque se elige el máximo.
4	Se vuelve a elegir con todo el entrenamiento (bucle interno sobre todo el entrenamiento) y se ajusta ese modelo con todas las filas; la anidada solo estima su desempeño.