# Apuntes · Clase 39 · Clustering

Para leer antes de los ejercicios · lectura de ~30 min

**Lo más importante, en 6 ideas**

1. **Agrupar no es clasificar.** No hay Y observada; el número del grupo es una etiqueta arbitraria.
2. **K-means minimiza el WSS.** Asigna al centro más cercano y promedia; cada vuelta baja o mantiene el costo.
3. **Estandariza siempre.** Si no, la variable de mayor escala decide los grupos.
4. **Repite con varios inicios.** Hay mínimos locales: se conserva el menor WSS (n_init, nstart).
5. **k no es único.** Codo, silueta y Gap pueden discrepar; decide con interpretación y estabilidad.
6. **Categóricas y mixtas.** K-modes usa modas y desacuerdos; K-prototypes suma medias y modas con un peso γ.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C39_Clustering.ipynb` o el cuaderno `C39_Ejercicios_Cuaderno_Clustering.pdf`.

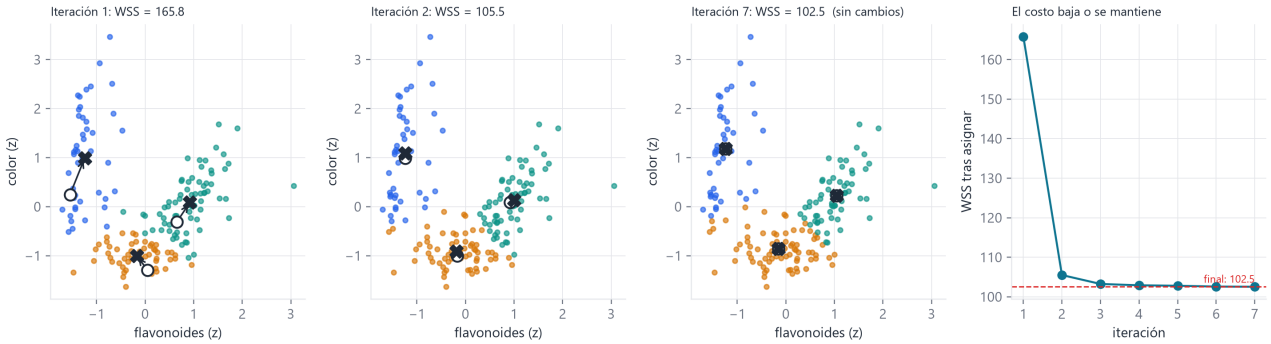
## 1 K-means a mano: asignar, promediar y WSS

Con k centros iniciales: (1) cada punto va al centro más cercano (distancia al cuadrado); (2) cada centro pasa a ser la media de su grupo; se repite hasta que no cambie ninguna asignación. El costo es WSS = Σ (x − μ_grupo)²; la variabilidad total se descompone como TSS = WSS + BSS, con BSS = Σ n_g (μ_g − media global)².

**Ejemplo resuelto · seis valores: 3, 5, 6, 14, 16 y 22, con k = 2 y centros iniciales 5 y 14**

| Paso | Cálculo | Resultado |
|---|---|---|
| Iteración 1: asignar | $(x-5)^2$ frente a $(x-14)^2$ | grupo 1: 3, 5, 6 · grupo 2: 14, 16, 22 |
| Actualizar | (3 + 5 + 6)/3 y (14 + 16 + 22)/3 | $\mu_1 = 4.667$, $\mu_2 = 17.333$ |
| Iteración 2: asignar | con los nuevos centros | mismas asignaciones: converge |
| WSS | 4.667 + 34.667 (por grupo) | 39.333 |
| TSS | media global 11: 64 + 36 + 25 + 9 + 25 + 121 | 280 |
| BSS | $3(4.667-11)^2 + 3(17.333-11)^2$ | 240.667 (= TSS − WSS) |

Lectura: aquí el 14 estaba justo en el centro 2 y el 5 en el centro 1, por eso converge enseguida; con otros inicios podría tardar más. **Error común**: restar sin elevar al cuadrado, o calcular el WSS con el centro inicial en vez del final.




**Pista para la Parte A del notebook (A2 y A3) y los Bloques 1 y 2 del cuaderno**

Programa las dos iteraciones con NumPy y compara el WSS con `KMeans(...).inertia_`.

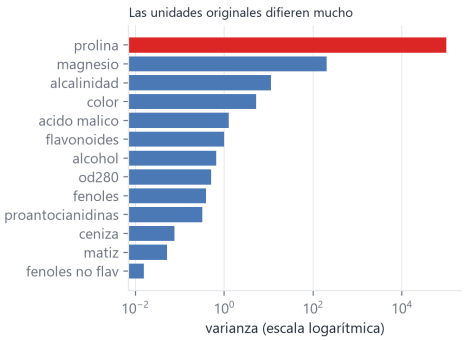
## 2 Estandarizar y por qué importa

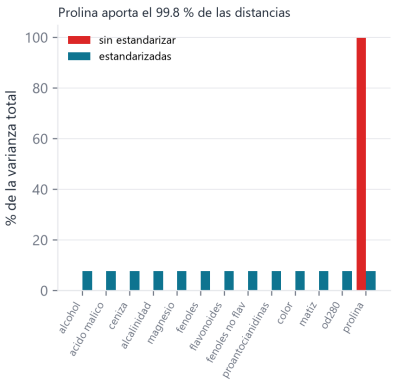
K-means compara distancias. Si una variable tiene unidades mucho mayores, casi sola decide a qué centro va cada punto. Estandarizar (z = (x − media)/s) deja todas las variables en desviaciones estándar. No elimina atípicos ni correlaciones. En Python usa `ddof=1` para igualar el `scale()` de R.

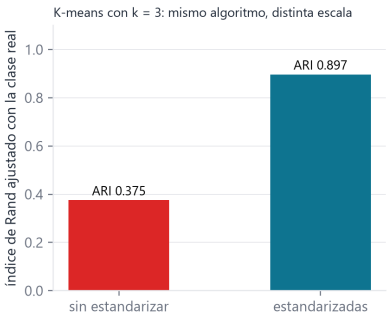
**Ejemplo resuelto · tres vinos (alcohol, magnesio): A = (12.0, 90), B = (14.0, 95), C = (12.2, 120); medias 13 y 100, desviaciones 0.8 y 15**

| Concepto | Cálculo | Resultado |
|---|---|---|
| Distancias sin estandarizar | d(A, B) = √(2² + 5²); d(A, C) = √(0.2² + 30²) | 5.39 y 30.00 |
| Vecino más cercano de A | sin estandarizar | B (el magnesio decide) |
| z de A, B, C | (x − media)/desviación | A(-1.25; -0.67) B(1.25; -0.33) C(-1.00; 1.33) |
| Distancias estandarizadas | d(A, B), d(A, C) | 2.52 y 2.02 |
| Vecino más cercano de A | estandarizando | C (ahora pesan las dos variables) |

Lectura: el cambio de escala altera quién es «vecino» de quién, y por tanto los grupos. En los vinos reales la prolina aporta casi 100 % de las distancias. **Error común**: estandarizar con la desviación de un subconjunto distinto o olvidar guardar la media y la desviación.




**Pista para la Parte A del notebook (A1 y A6) y el Bloque 6 del cuaderno**
Compara K-means con y sin estandarizar y mide la concordancia con la clase real (ARI).

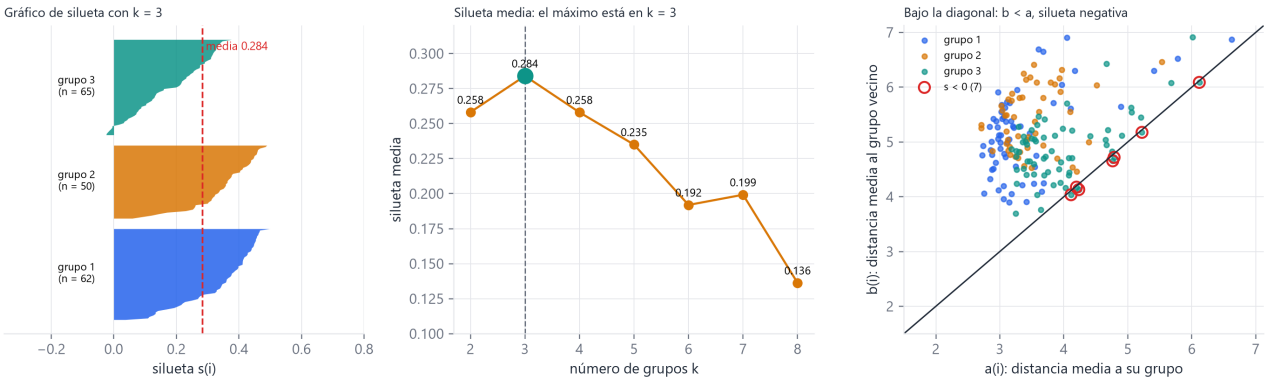
## 3 Elegir k: codo, silueta y Gap

El WSS baja siempre al subir k (con k = n vale 0), así que no basta: el **codo** busca dónde la reducción se vuelve pequeña; la **silueta media** se maximiza; el **Gap** compara con datos sin estructura y toma el primer k con Gap(k) ≥ Gap(k+1) − s(k+1). Si discrepan, se razona con interpretación y estabilidad.

**Ejemplo resuelto · silueta de dos puntos (grupos {1, 2, 3} y {9, 10}) y regla del Gap con una tabla hipotética**

| Concepto | Cálculo | Resultado |
|---|---|---|
| Punto 3: a | (\|3 − 1\| + \|3 − 2\|)/2 | 1.50 |
| Punto 3: b | (\|3 − 9\| + \|3 − 10\|)/2 | 6.50 |
| Punto 3: s | (b − a)/máx(a, b) | 0.769 (bien separado) |
| Punto 9: a, b | a = \|9 − 10\| = 1; b = (8 + 7 + 6)/3 | 1.00 y 7.00 |
| Punto 9: s | (7 − 1)/7 | 0.857 |
| Gap(k): 1, 2, 3, 4 | 0.55, 0.82, 0.83, 0.84 (s = 0.03) | k = 1: 0.55 ≥ 0.79? no |
| Regla | k = 2: 0.82 ≥ 0.83 − 0.03 = 0.80? | sí → se elige k = 2 |

Lectura: el Gap sigue subiendo (0.84 es el mayor) pero la regla de un error estándar elige el primer k suficiente. **Error común**: tomar el máximo del Gap o decidir k solo con el codo.




**Pista para la Parte B del notebook (B1 a B4) y el Bloque 4 del cuaderno**
Reproduce el codo, la silueta y el Gap del profesor y decide k con los tres.

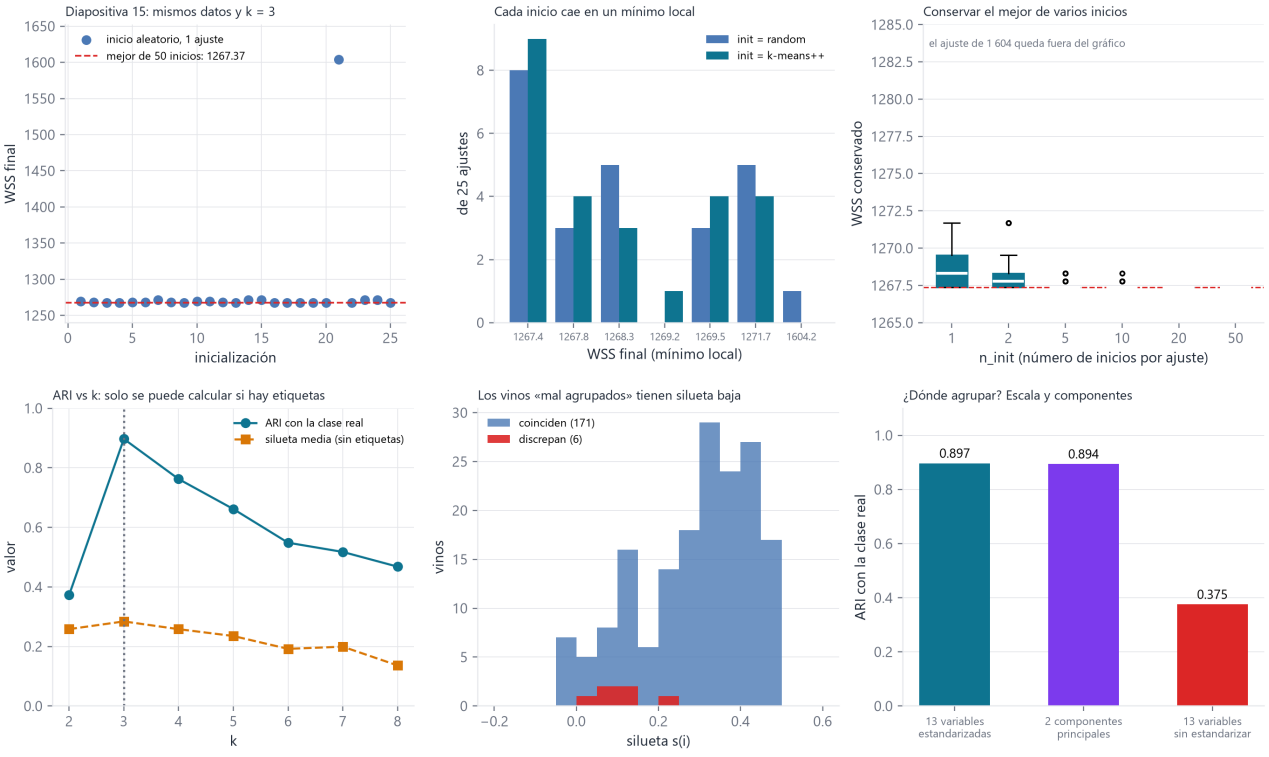
## 4 Inicialización y validación con clases

K-means puede terminar en mínimos locales según los centros iniciales: se repite (n_init, nstart) y se conserva el menor WSS. Si existe una clase real, se compara con los grupos mediante una tabla de contingencia, la pureza y el índice de Rand ajustado (ARI); los números de grupo son arbitrarios, por eso se comparan **particiones**, no etiquetas.

**Ejemplo resuelto · 50 casos con clase real (A: 20, B: 30) agrupados en 2 grupos**

| Concepto | Cálculo | Resultado |
|---|---|---|
| Tabla | filas A y B; columnas grupo 1 y 2 | A: 18 y 2 · B: 3 y 27 |
| Pureza | (18 + 27)/50 | 0.90 |
| Pares dentro de celdas | C(18,2) + C(2,2) + C(3,2) + C(27,2) | 508 |
| ARI | (pares − esperados)/(promedio − esperados) | 0.633 |
| Si se intercambian los números de grupo | las columnas se permutan | pureza y ARI no cambian |

Lectura: 5 casos «mezclados» bastan para bajar el ARI a 0.63 aunque la pureza sea 0.90. **Error común**: usar la pureza o el ARI para elegir k en un proyecto real: sin etiquetas no existen.



**Pista para la Parte A (A5) y la Parte C del notebook y el Bloque 7 del cuaderno**
Mide cuántos mínimos locales aparecen con un solo inicio y arma la tabla de contingencia con las clases reales.

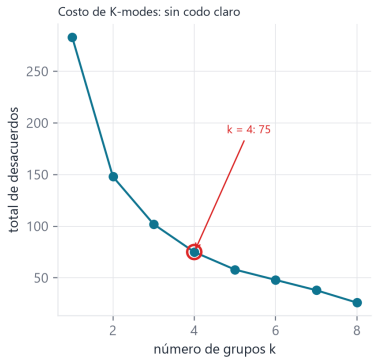
## 5 K-modes y K-prototypes

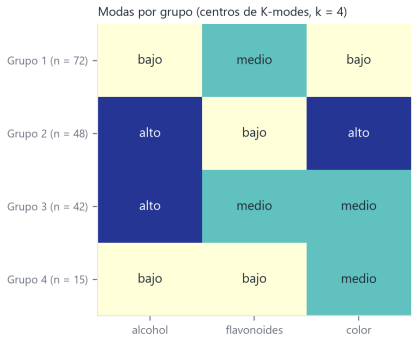
Con categorías no tiene sentido promediar: el centro es la moda de cada variable y la disimilitud cuenta variables con valores distintos. En K-prototypes, el costo de un punto frente a un prototipo es $\Sigma$ (x_num − μ)² + γ · (nº de desacuerdos). Cambiar γ puede cambiar la asignación aunque los datos sean los mismos.

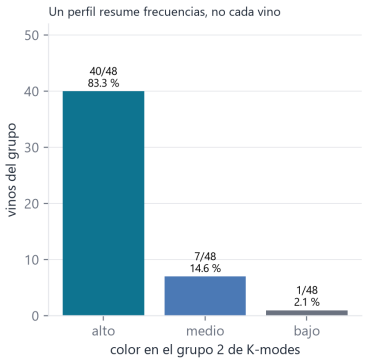
**Ejemplo resuelto · cliente (Silver, Web, Norte) y observación (2, 1) con (Web, Norte)**

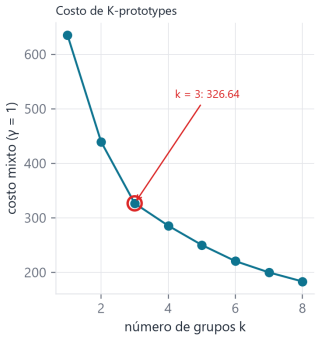
| Concepto | Cálculo | Resultado |
|---|---|---|
| Desacuerdos con A | (Gold, App, Norte) | 2 |
| Desacuerdos con B | (Silver, Web, Sur) | 1 |
| Asignación K-modes | menor desacuerdo | grupo B |
| Costo mixto con P1: (1, 1) y (Web, Sur) | $(2-1)^2 + (1-1)^2 + \gamma \cdot 1$ | 1 + γ |
| Costo mixto con P2: (3, 2) y (Web, Norte) | $(2-3)^2 + (1-2)^2 + \gamma \cdot 0$ | 2 |
| Decisión | γ = 0.5: 1.5 < 2 → P1; γ = 3: 4 > 2 → P2 | cambia con γ |

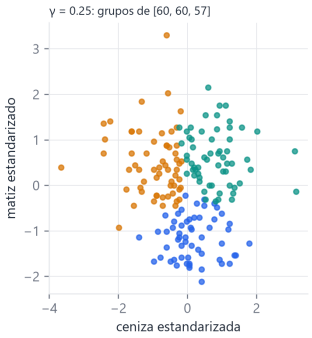
Lectura: en γ = 1 hay empate. **Error común**: comparar el costo de K-modes (desacuerdos) con el de K-means (cuadrados) para elegir el método.

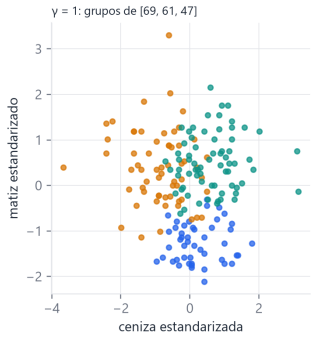


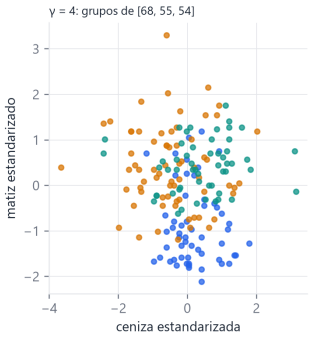




**Pista para la Parte D del notebook (D1 y D2)**
Reproduce los costos de las diapositivas 40, 48 y 52 con el paquete `kmodes` y varía γ.

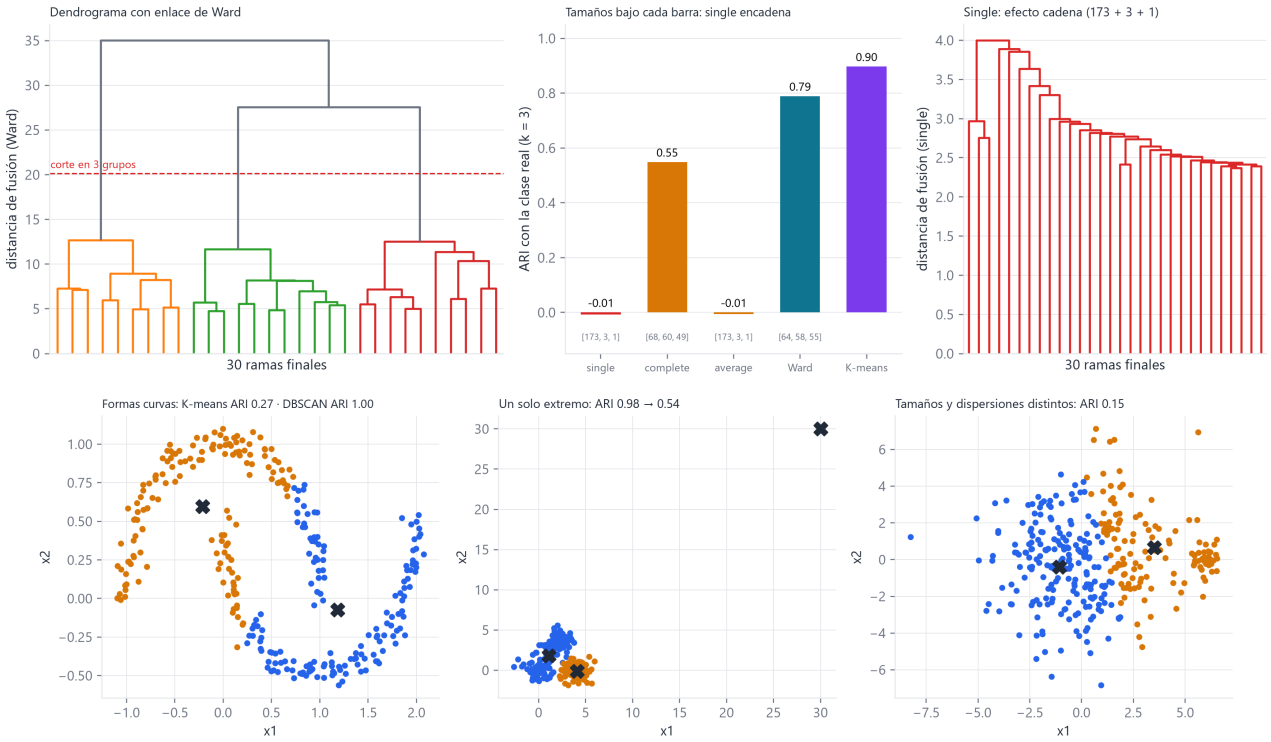
## 6 Complemento: agrupamiento jerárquico y límites de K-means

Este tema **no se vio en clase**: se incluye porque aparece en cursos y en el taller. El jerárquico aglomerativo parte con cada punto solo y une los dos grupos más cercanos; el **enlace** define la distancia entre grupos: *single* (mínima), *complete* (máxima), *average* y *Ward* (aumento de la suma de cuadrados). K-means, en cambio, supone grupos compactos y de tamaño parecido.

**Ejemplo resuelto · cuatro puntos en una recta: 1, 3, 8 y 12**

| Paso | Single | Complete |
|---|---|---|
| 1.º: unir {1, 3} | altura 2 | altura 2 |
| 2.º: unir {8, 12} | altura 4 (el 8 y el 12 están a 4) | altura 4 |
| 3.º: unir los dos pares | altura 5 (mínima entre grupos: 8 − 3) | altura 11 (máxima: 12 − 1) |

Lectura: el mismo árbol, alturas muy distintas; con muchos puntos *single* encadena (en los vinos produce grupos de 173, 3 y 1). **Error común**: leer la altura como si fuera comparable entre enlaces.







**Pista para la Parte D del notebook (D3 y D4) y el Bloque 5 del cuaderno**

Compara los enlaces por ARI y silueta y reproduce las formas curvas con DBSCAN (Clase 41).

**Lo que debes recordar**

- Agrupar no es clasificar: un grupo no es una clase y su número es solo una etiqueta.
- Estandariza, repite con varios inicios y elige k con más de un criterio.
- Los costos de K-means, K-modes y K-prototypes no son comparables; y cambia los grupos.
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–B del notebook → Bloques 5–7 → Partes C–D → ejercicio de cierre.