Ejercicios para el cuaderno · Clase 39 · Clustering

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: WSS = $\Sigma(x - \mu_g)^2$ · TSS = WSS + BSS · s(i) = (b − a)/máx(a, b) · z = (x − media)/s · $\Delta SS(Ward) = n_1 n_2/(n_1 + n_2)\cdot d^2$(centros) · pureza = Σ máx. por grupo/n.
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 Una iteración de K-means a mano ★★

Valores 2, 3, 7, 10, 12 y 21, con k = 2 y centros iniciales 3 y 12.

1. Asigna cada valor al centro más cercano (distancia al cuadrado) y escribe los grupos.
2. Calcula los nuevos centros. Repite la asignación: ¿cambia algo? ¿Convergió?
3. Calcula el WSS final.

Bloque 2 WSS, BSS y TSS ★★

Usa la partición final del Bloque 1.

1. Calcula la media global y el TSS.
2. Calcula el BSS con $n_g(\mu_g - \text{media global})^2$ y comprueba que TSS = WSS + BSS.
3. ¿Qué fracción de la variabilidad total explica la partición (BSS/TSS)?

Bloque 3 Silueta de un punto ★★

Con la partición del Bloque 1, grupos {2, 3, 7} y {10, 12, 21}.

1. Calcula a(i), b(i) y s(i) del valor 7 (distancia |x − y|).
2. Calcula s(i) del valor 10. ¿Qué indica el signo?
3. ¿Por qué K-means lo dejó en el grupo 2 si su silueta es negativa?

Bloque 4 Leer una tabla para elegir k ★★★

WSS: 500, 300, 180, 150, 128 y 112 para k = 1 a 6. Silueta media (k = 2 a 6): 0.41, 0.55, 0.46, 0.39 y 0.33. Gap (k = 1 a 5): 0.31, 0.55, 0.74, 0.75 y 0.76, con s = 0.03.

1. Calcula la reducción porcentual del WSS en cada paso. ¿Dónde está el codo?
2. ¿Qué k elige la silueta? Aplica la regla Gap(k) ≥ Gap(k + 1) − s(k + 1) y di qué k elige.
3. Si los criterios discreparan, ¿qué más revisarías antes de decidir?

Bloque 5 Enlaces: single, complete y Ward ★★★

Puntos en una recta A = 0, B = 1, C = 2.5, D = 4.1 y E = 5.8 (distancias |x − y|).

1. Con enlace single, escribe el orden de las uniones y sus alturas.
2. Con enlace complete, igual. ¿En qué se parecen y en qué se diferencian los dos árboles?
3. Ward: después de unir {A, B} y {C, D}, calcula $\Delta SS = n_1 n_2/(n_1 + n_2)\cdot d^2$ para unir {C, D} con E y para unir {A, B} con {C, D}. ¿Cuál se une primero?

Bloque 6 Por qué estandarizar ★★

Tres vinos (alcohol, prolina): A = (13.0, 700), B = (14.5, 720), C = (13.1, 1100). Medias 13 y 750; desviaciones 0.8 y 315.

1. Calcula d(A, B) y d(A, C) sin estandarizar. ¿Cuál es el vecino más cercano de A?
2. Estandariza los tres vinos y recalcula d(A, B) y d(A, C). ¿Cambia el vecino?
3. Explica con una frase por qué ocurre y qué variable dominaba.

Bloque 7 Grupo no es clase: leer una contingencia ★★★

Clase real (filas A, B, C) frente a grupos 1, 2 y 3: A = (40, 5, 5), B = (4, 38, 8), C = (3, 2, 45).

1. Calcula la pureza. ¿Qué clase domina en cada grupo?
2. Si se renumeran los grupos (1 ↔ 3), ¿cambian la pureza y el ARI? ¿Y la tabla?
3. ¿Se podría usar esta pureza para elegir k en un proyecto sin clase real? Justifica.

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	Distancias a 3 y a 12: 2 → (1, 100); 3 → (0, 81); 7 → (16, 25); 10 → (49, 4); 12 → (81, 0); 21 → (324, 81). Grupo 1: 2, 3, 7; grupo 2: 10, 12, 21.
2	$\mu_1 = (2 + 3 + 7)/3 = 4.00$; $\mu_2 = (10 + 12 + 21)/3 = 14.333$. Con estos centros el 7 queda a 3 de μ_1 y a 7.33 de μ_2; el 10, a 6 y 4.33: las asignaciones no cambian. Convergió.
3	Grupo 1: $4 + 1 + 9 = 14$. Grupo 2: $(-4.333)^2 + (-2.333)^2 + (6.667)^2 = 68.667$. WSS = 82.667.

Bloque 2

#	Solución
1	Media global = 55/6 = 9.167. TSS = $\Sigma(x - \text{media})^2 = 242.833$.
2	BSS = $3(4.00 - 9.167)^2 + 3(14.333 - 9.167)^2 = 160.167$. Comprobación: 82.667 + 160.167 = 242.833.
3	BSS/TSS = 0.660: la partición explica el 66.0 % de la variabilidad total.

Bloque 3

#	Solución
1	$a = (\|7 - 2\| + \|7 - 3\|)/2 = 4.50$; $b = (\|7 - 10\| + \|7 - 12\| + \|7 - 21\|)/3 = 7.333$; $s = (7.333 - 4.50)/7.333 = 0.386$.
2	$a = (\|10 - 12\| + \|10 - 21\|)/2 = 6.50$; $b = (8 + 7 + 3)/3 = 6.00$; $s = (6.00 - 6.50)/6.50 = -0.077$. Negativo: en promedio está más cerca del otro grupo.
3	K-means compara con el **centro**: el 10 está a 4.33 de $\mu_2 = 14.33$ y a 6 de $\mu_1 = 4$. La silueta compara **distancias medias a todos** los puntos: el 21 eleva la distancia media al grupo 2 (6.50) por encima de la media al grupo 1 (6.00). Criterios distintos, resultado distinto.

Bloque 4

#	Solución
1	Reducciones: 40.0 %, 40.0 %, 16.7 %, 14.7 %, 12.5 % (k = 1→2, …, 5→6). Las caídas fuertes (40 % y 40 %) llegan hasta k = 3; después son de 16.7 %, 14.7 % y 12.5 %: codo en k = 3.
2	La silueta es máxima en k = 3 (0.55). Gap: k = 1: $0.31 \geq 0.55 - 0.03$? no; k = 2: $0.55 \geq 0.74 - 0.03 = 0.71$? no; k = 3: $0.74 \geq 0.75 - 0.03 = 0.72$? sí → k = 3.
3	Los tres coinciden. Aun así: tamaños y estabilidad de los grupos (otras semillas y n_init), perfiles interpretables y el propósito del análisis.

Bloque 5

#	Solución
1	Single: {A, B} a 1.0; luego C a 1.5 (distancia B–C); luego D a 1.6 (C–D); luego E a 1.7 (D–E): efecto cadena.
2	Complete: {A, B} a 1.0; {C, D} a 1.6; E se une a {C, D} a 3.3 (máx. con C); al final todo a 5.8 (máx. A–E). Single une todo en una cadena; complete forma dos grupos compactos y E se une a ellos.
3	{C, D} + E: centros 3.3 y 5.8, $d^2 = 6.25$, $\Delta SS = (2 \cdot 1/3) \cdot 6.25 = 4.167$. {A, B} + {C, D}: centros 0.5 y 3.3, $d^2 = 7.84$, $\Delta SS = (2 \cdot 2/4) \cdot 7.84 = 7.84$. Se une primero {C, D} con E (ΔSS menor).

Bloque 6

#	Solución
1	$d(A, B) = \sqrt{(1.5^2 + 20^2)} = 20.06$; $d(A, C) = \sqrt{(0.1^2 + 400^2)} = 400.00$. El más cercano es B.
2	$z(A) = (0; -0.159)$; $z(B) = (1.875; -0.095)$; $z(C) = (0.125; 1.111)$. $d(A, B) = 1.876$; $d(A, C) = 1.276$. Ahora el más cercano es C: el vecino cambió.
3	La prolina (cientos de unidades) dominaba la distancia sin estandarizar; al pasar a desviaciones estándar el alcohol y la prolina pesan comparable.

Bloque 7

#	Solución
1	Máximos por grupo: 40 (A), 38 (B), 45 (C); pureza = 123/150 = 0.820. El grupo 1 está dominado por A, el 2 por B y el 3 por C.
2	No: la pureza y el ARI (0.528) se calculan sobre la partición; permutar números de grupo solo permuta las columnas de la tabla.
3	No: sin clase real no hay tabla ni pureza. Se elige k con criterios internos (codo, silueta, Gap), estabilidad y propósito; la clase real solo valida cuando existe.