Apuntes · Clase 40 · Naive Bayes y clasificación probabilística

Para leer antes de los ejercicios · lectura de ~30 min

Lo más importante, en 6 ideas

1. **Bayes invierte la pregunta.** P(spam | señales) sale de P(señales | spam) y de la previa; no son lo mismo.
2. **Naive = independencia dentro de la clase.** Se multiplica un factor por señal; si falla, el modelo se sobreconfía.
3. **Suaviza los ceros.** (conteo + α)/(n + 2α): ningún cero anula el producto.
4. **Suma logaritmos.** Evita el desborde y muestra la evidencia como log-odds.
5. **Ordenar no es calibrar.** NB y la logística pueden tener el mismo AUC y distinto log loss.
6. **Predecir ≠ decidir.** El umbral sale de los costos de FP y FN, no de 0.5 por costumbre.

Cada sección trae una explicación, un **ejemplo resuelto con números distintos** a los de los ejercicios y una **pista** para el notebook `C40_NaiveBayes.ipynb` o el cuaderno `C40_Ejercicios_Cuaderno_NaiveBayes.pdf`.

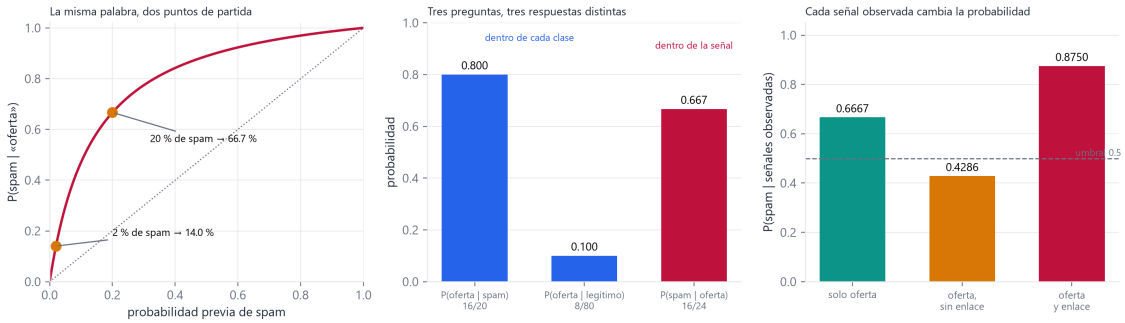
1 Bayes con una tabla de frecuencias

Con una tabla de conteos se calculan tres cosas: la **previa** (fracción de cada clase), la **condicional** (dentro de cada clase, fracción con la señal) y la **posterior**, que se obtiene multiplicando previa por condicional en cada clase y dividiendo por la suma de ambos productos.

Ejemplo resuelto · 200 correos (150 legítimos y 50 spam); «gratis» aparece en 10 legítimos y en 35 spam

Paso	Cálculo	Resultado
Previa	50/200	0.25
Condicionales	35/50 y 10/150	0.70 y 0.0667
Productos	0.25 × 0.70 y 0.75 × 0.0667	s1 = 0.1750; s0 = 0.0500
Posterior	s1/(s0 + s1)	0.7778
Con otra previa (50 %)	0.5 × 0.70/(0.5 × 0.70 + 0.5 × 0.0667)	0.9130

Lectura: de los spam, el 70 % trae «gratis», pero de los correos con «gratis» el 77.8 % es spam; y si la previa fuera 50 % subiría a 91.3 %. **Error común**: tomar 0.70 como probabilidad de spam o ignorar la previa.



Pista para la Parte A del notebook (A1 y A2) y los Bloques 1 y 2 del cuaderno

Reproduce 0.6667, 0.1404, 0.4286 y 0.4140 con NumPy y con `BernoulliNB`.

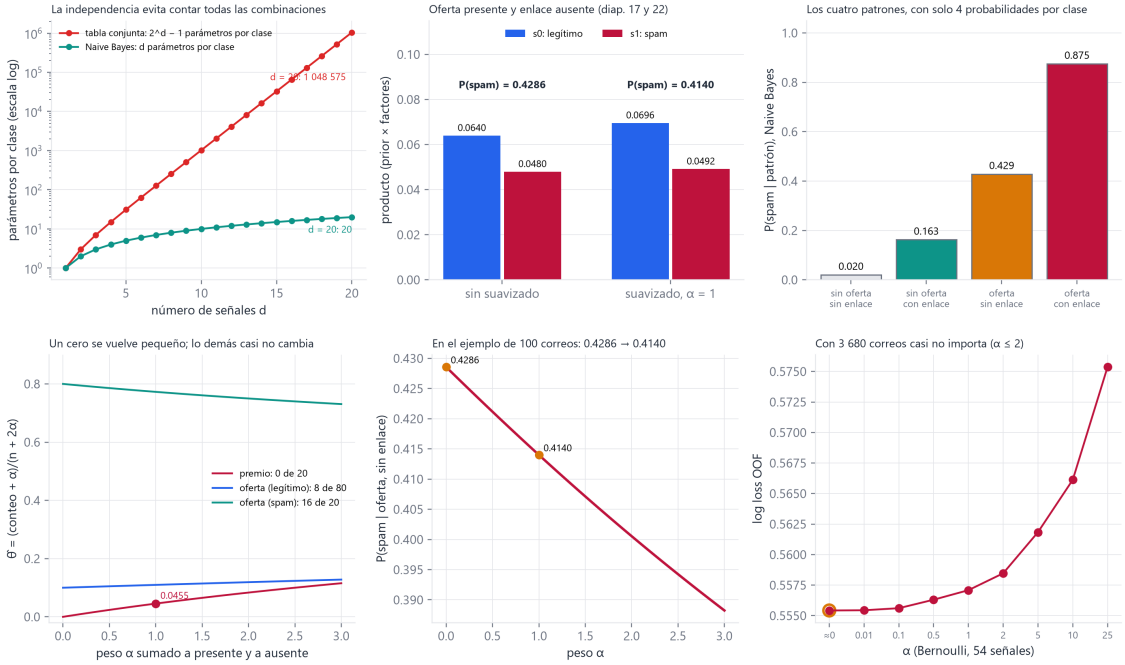
2 Dos señales, independencia y suavizado

Con dos señales se multiplica un factor por señal dentro de cada clase, usando el estado observado (presente o ausente). El **suavizado de Laplace** reemplaza cada conteo c por c + α y cada total n por n + 2α.

Ejemplo resuelto · mismos 200 correos; «gratis» presente y «reunión» ausente (reunión: 60 legítimos, 5 spam)

Concepto	Cálculo	Resultado
Factores spam	0.25 × (35/50) × (1 − 5/50)	s1 = 0.1575
Factores legítimo	0.75 × (10/150) × (1 − 60/150)	s0 = 0.0300
Posterior sin suavizar	s1/(s0 + s1)	0.8400
Con α = 1	(35 + 1)/52, (45 + 1)/52, (10 + 1)/152, (90 + 1)/152	s1 = 0.1531; s0 = 0.0325
Posterior suavizado	s1/(s0 + s1)	0.8249
Un conteo cero	«ganador»: 0 de 50 spam; α = 1	0 → 1/52 = 0.0192

Lectura: con 200 correos el suavizado cambia poco el resultado, pero evita que una palabra nunca vista en spam anule todo el producto. **Error común**: sumar solo 1 al denominador, o suavizar y creer que se corrigió la dependencia entre señales.



Pista para la Parte A del notebook (A3 y A4) y los Bloques 1 y 2 del cuaderno

Calcula los productos s0 y s1 a mano y compáralos con `predict_proba` de `BernoulliNB`.

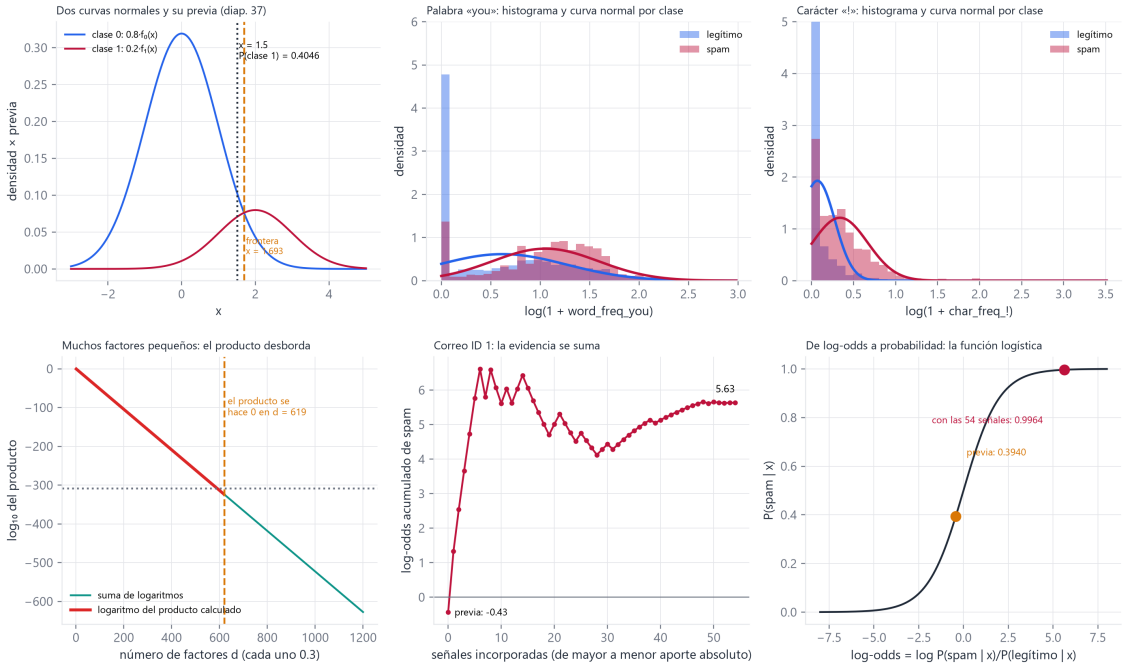
3 Naive Bayes gaussiano y las log-probabilidades

Para una medición se aprende una media y una desviación por clase; la «verosimilitud» es la altura de la curva normal en el valor observado. Con varias variables se multiplican (se suman logaritmos), por la previa, y se normaliza.

Ejemplo resuelto · una medición x = 2.5; clase 0: media 1, desviación 0.8; clase 1: media 3, desviación 1.2; previas 0.7 y 0.3

Paso	Cálculo	Resultado
Altura en clase 0	N(2.5; 1, 0.8)	0.0860
Altura en clase 1	N(2.5; 3, 1.2)	0.3048
Productos con previa	0.7 × altura$_0$ y 0.3 × altura$_1$	0.0602 y 0.0914
Posterior de la clase 1	$q_1/(q_0 + q_1)$	0.6031
Log-odds	ln q_1 − ln q_0	0.418 → 1/(1 + e^(−log-odds)) = 0.6031

Lectura: aunque x = 2.5 está más cerca de la media de la clase 1, la previa pequeña (0.3) compensa esa cercanía; aun así gana la clase 1. La decisión depende de la previa y de las dos curvas. **Error común**: leer la altura como si fuera una probabilidad, o olvidar la previa.



Pista para la Parte B del notebook (B1 y B2) y el Bloque 3 y 4 del cuaderno

Calcula las alturas con `scipy.stats.norm.pdf` y compáralas con `GaussianNB`; luego suma logaritmos.

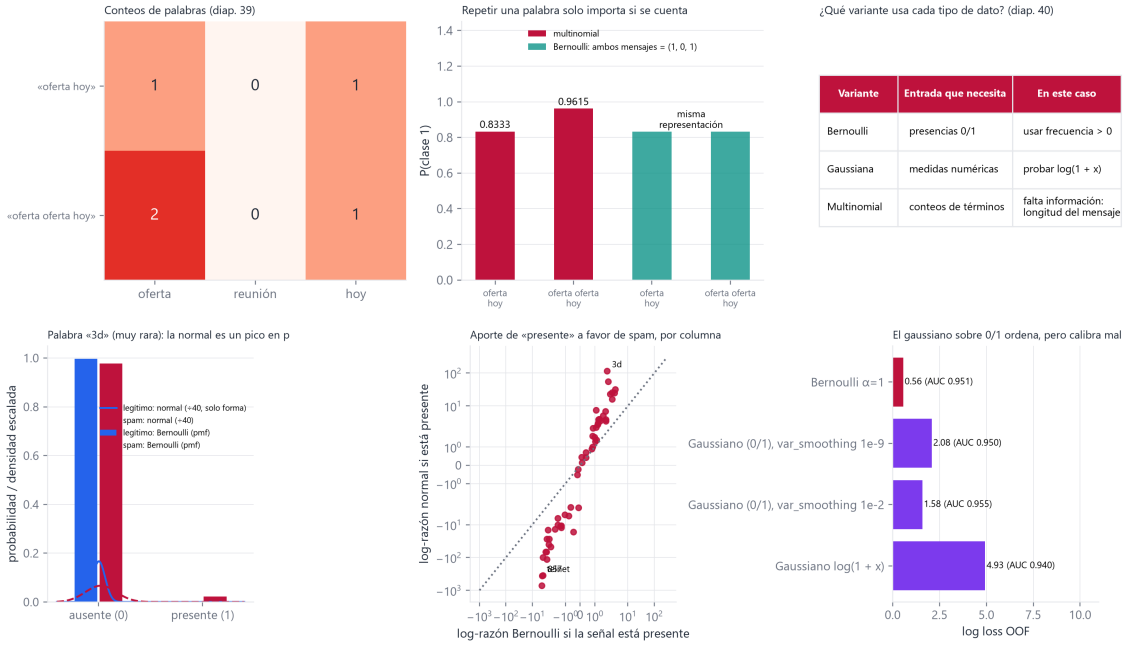
4 Variantes, y el gaussiano sobre columnas 0/1

Bernoulli usa presencias (0/1); **multinomial**, conteos de términos; **gaussiana**, mediciones continuas. Con frecuencias en porcentaje no hay conteos: se usa Bernoulli (frecuencia > 0) o gaussiana (log(1 + x)). Aplicar la gaussiana a una columna 0/1 la trata como normal con media p y varianza p(1 − p).

Ejemplo resuelto · una palabra presente en el 2 % de los legítimos y en el 15 % de los spam; el correo la trae (x = 1)

Concepto	Cálculo	Resultado
Bernoulli: log-razón	ln(0.15/0.02)	2.015
Varianzas normales	p(1 − p) por clase	0.0196 y 0.1275
Alturas en x = 1	N(1; 0.02, √0.0196) y N(1; 0.15, √0.1275)	6.52e-11 y 0.0657
Gaussiano: log-razón	$\ln(\text{altura}_1/\text{altura}_0)$	20.73

Lectura: con Bernoulli el aporte es 2.01 (la señal es 7.5 veces más frecuente en spam); con la normal sale 20.7, unas diez veces más, porque la varianza minúscula del grupo legítimo exagera la evidencia. **Error común**: creer que un gaussiano sobre dummies «no funciona»; funciona como aproximación, pero con probabilidades poco fiables.



Pista para la Parte C del notebook (C1 y C2) y el Bloque 3 del cuaderno

Aplica `GaussianNB` y `BernoulliNB` a las presencias de los 54 correos y compara log loss y AUC.

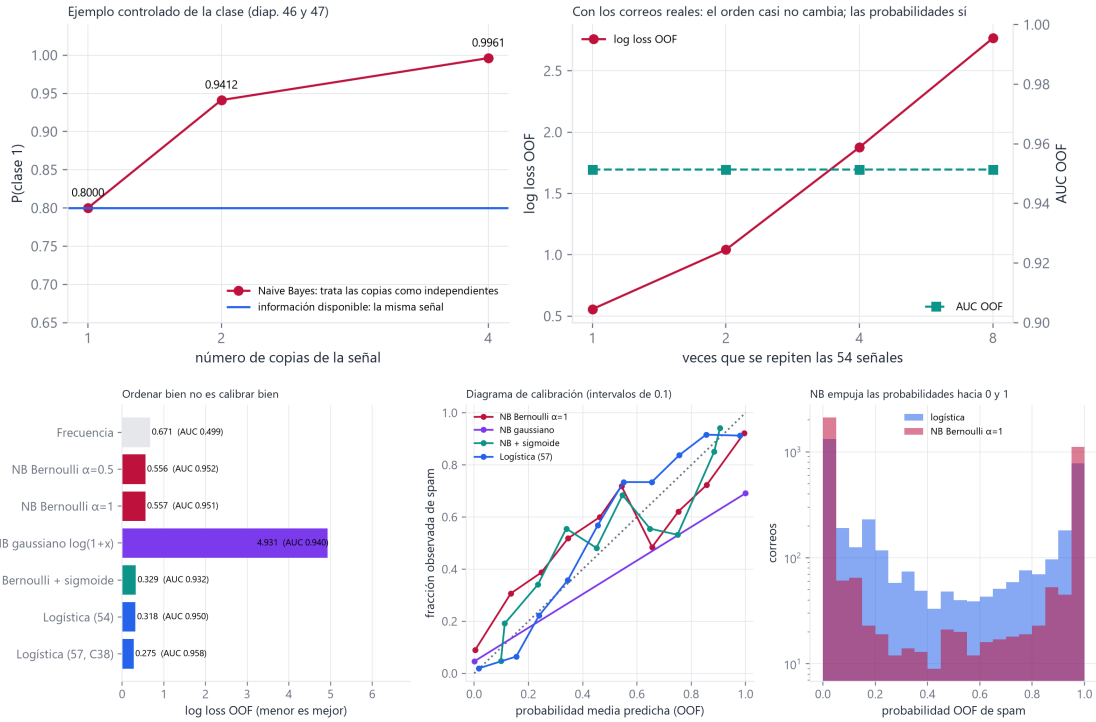
5 Dependencia entre señales: sobreconfianza

Si una señal se repite, Naive Bayes la multiplica de nuevo. La clase predicha puede no cambiar, pero la probabilidad sí: sube sin información nueva. Por eso Naive Bayes ordena bien y calibra mal.

Ejemplo resuelto · una señal en el 60 % de los spam y el 15 % de los legítimos; previas iguales

Copias	Cálculo	Posterior
1	0.5·0.60^1 / (0.5·0.60^1 + 0.5·0.15^1)	0.8000
2	0.5·0.60^2 / (0.5·0.60^2 + 0.5·0.15^2)	0.9412
3	0.5·0.60^3 / (0.5·0.60^3 + 0.5·0.15^3)	0.9846

Lectura: con una copia, 0.8000; con dos, 0.9412; con tres, 0.9846. La información real es la misma señal, pero el modelo cree tener tres evidencias independientes. **Error común**: verlo como «sobreajuste»; es sobreconfianza por dependencia.



Pista para la Parte C del notebook (C3 y C4) y el Bloque 5 y 6 del cuaderno
Repite las 54 señales 1, 2, 4 y 8 veces y mira log loss y AUC; compara con la logística.

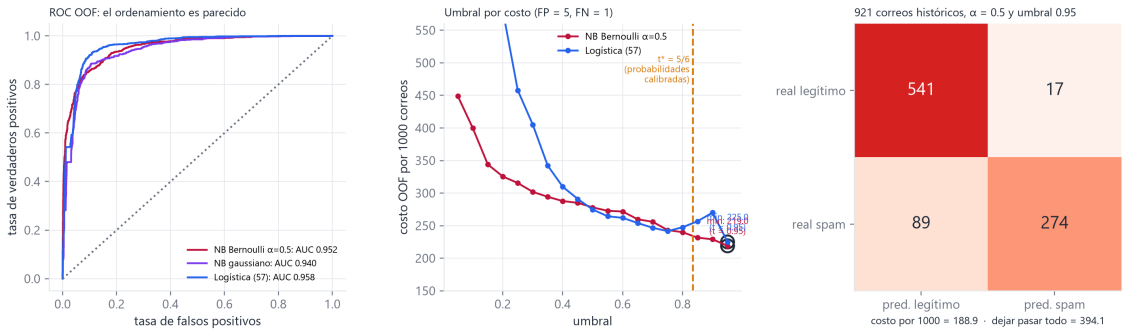
6 Decidir: umbral y costos

Si bloquear un legítimo (FP) cuesta a y dejar pasar un spam (FN) cuesta b, con una probabilidad p bien calibrada se bloquea cuando a (1 − p) < b p, es decir p > a/(a + b). En la práctica el umbral se busca en una rejilla con predicciones OOF y se prueba una vez.

Ejemplo resuelto · costos FP = 4 y FN = 1

p	bloquear: 4 (1 − p)	dejar pasar: p	decisión
0.90	0.40	0.90	bloquear
0.85	0.60	0.85	bloquear
0.60	1.60	0.60	dejar pasar

Lectura: el umbral teórico es 4/5 = 0.80. En un conjunto de 1 000 correos con FP = 30 y FN = 120 el costo es (4 × 30 + 120)/1 000 = 0.24, o 240 por cada 1 000 correos. **Error común**: usar 0.5 por costumbre aunque los errores no cuesten lo mismo, o elegir el umbral con el conjunto de prueba.



Pista para la Parte D del notebook (D1 y D2) y el Bloque 7 del cuaderno
Barre 19 umbrales con las OOF, elige el de menor costo y pruébalo una vez en los 921 correos históricos.

Lo que debes recordar

- Previa, condicional y posterior son tres cantidades distintas; la prevalencia cambia la respuesta.
- Naive Bayes supone independencia dentro de la clase: el suavizado evita ceros, pero no corrige la dependencia.
- Usa logaritmos; el log-odds suma la evidencia y la probabilidad es su función logística.
- AUC mide el orden; log loss y la calibración miden las probabilidades. Naive Bayes ordena bien y calibra peor.
- Orden sugerido: apuntes → Bloques 1–4 del cuaderno → Partes A–B del notebook → Bloques 5–7 → Partes C–D → ejercicio de cierre.