Ejercicios para el cuaderno · Clase 40 · Naive Bayes

Para resolver en papel, con calculadora · soluciones paso a paso al final

Cómo usar esta guía

- Escribe el número del bloque y del ejercicio, y tu desarrollo completo.
- Fórmulas: P(clase | x) = π_k ∏ f_jk(x_j) / Σ_ℓ π_ℓ ∏ f_jℓ(x_j) · θ̂ = (c + α)/(n + 2α) · N(x; μ, σ) = exp(−(x − μ)²/2σ²)/(σ√2π) · log loss = −media[y ln p + (1 − y) ln(1 − p)] · umbral = a/(a + b).
- Nivel: ★ directo · ★★ 2 o 3 pasos · ★★★ integra varios conceptos.

Bloque 1 Naive Bayes desde una tabla de frecuencias ★★

300 correos: 240 legítimos y 60 spam. «urgente» aparece en 12 legítimos y 30 spam; «enlace», en 48 legítimos y 27 spam. Un correo trae «urgente» y no trae «enlace».

1. Calcula la previa y las probabilidades condicionales de cada señal en cada clase (incluidas las ausencias).
2. Calcula s0 y s1 con independencia y la probabilidad de spam.
3. Con umbral 0.5, ¿se bloquea? ¿Y si «urgente» fuera la única señal?

Bloque 2 Suavizado de Laplace a mano ★★

En los mismos correos, «ganador» no aparece en ninguno de los 60 spam y aparece en 4 de los 240 legítimos. Llega un correo con «ganador» y «urgente» (y sin «enlace»).

1. Calcula P(ganador | spam) sin suavizar y con α = 1. ¿Qué pasa con el producto de spam sin suavizar?
2. Calcula P(ganador | legítimo) con α = 1 y α = 0.5.
3. Con α = 1, calcula la probabilidad de spam del correo (usa las tres señales con los conteos del Bloque 1 suavizados).

Bloque 3 Naive Bayes gaussiano ★★★

Dos mediciones: x_1 (clase 0: media 10, desviación 2; clase 1: media 14, desviación 3) y x_2 (clase 0: media 1.0, desviación 0.5; clase 1: media 2.5, desviación 1.0). Previas 0.6 y 0.4. Un caso: $x_1 = 12$ y $x_2 = 1.5$.

1. Calcula las cuatro alturas normales.
2. Calcula la posterior de la clase 1 multiplicando los factores de las dos variables.
3. Si x_2 se reemplazara por una columna 0/1 con media 0.05 y desviación 0.22 en la clase 0, ¿qué problema aparecería?

Bloque 4 Por qué logaritmos ★★

Un filtro multiplica 500 factores, cada uno cercano a 0.1 (por clase).

1. Calcula el orden de magnitud del producto. ¿Qué ocurre en doble precisión (mínimo ≈ 1e−308)?
2. En log natural, ln s1 = −812.4 y ln s0 = −815.1. Calcula el log-odds y la probabilidad de spam.
3. ¿Por qué se puede restar logaritmos sin pasar por los productos?

Bloque 5 Independencia violada: señales duplicadas ★★★

Una señal aparece en 70 de 100 spam y en 30 de 100 legítimos; previas iguales.

1. Calcula la probabilidad de spam con una copia y con dos copias de la señal.
2. Calcula con tres copias. ¿Cuánta información nueva hay respecto de una copia?
3. Explica con una frase por qué esto es sobreconfianza y no sobreajuste.

Bloque 6 Ordenar bien frente a calibrar bien ★★★

Seis correos. 1: y = 1, logística 0.90, Naive Bayes 0.999; 2: y = 1, logística 0.75, Naive Bayes 0.964; 3: y = 0, logística 0.60, Naive Bayes 0.771; 4: y = 1, logística 0.55, Naive Bayes 0.646; 5: y = 0, logística 0.30, Naive Bayes 0.073; 6: y = 0, logística 0.10, Naive Bayes 0.001.

1. Ordena los correos por probabilidad con cada modelo. ¿Coinciden los órdenes? ¿Cuántos pares (spam, legítimo) quedan bien ordenados (AUC)?
2. Calcula el log loss de cada modelo. ¿Cuál es mejor y por qué?
3. ¿Qué modelo usarías para ordenar la bandeja y cuál para estimar el costo esperado de bloquear?

Bloque 7 Umbral por costo ★★★

Costos: FP = 3 y FN = 1. En 500 correos de desarrollo, con umbral 0.5: FP = 40, FN = 50; con 0.75: FP = 20, FN = 85; con 0.90: FP = 8, FN = 140.

1. Calcula el umbral teórico y explica qué supone.
2. Calcula el costo por 1000 correos de cada umbral y elige el mejor.
3. Si el mejor umbral empírico difiere del teórico, ¿qué dice eso de las probabilidades? ¿Qué más harías antes de usarlo?

Soluciones paso a paso

Revisa el desarrollo, no solo el número final

Bloque 1

#	Solución
1	Previa spam 60/300 = 0.20 (legítimo 0.80). «urgente»: spam 30/60 = 0.50, legítimo 12/240 = 0.05; «enlace»: spam 27/60 = 0.45, legítimo 48/240 = 0.20. Ausencias: sin enlace 0.55 en spam y 0.80 en legítimos.
2	s1 = 0.20 × 0.50 × 0.55 = 0.0550; s0 = 0.80 × 0.05 × 0.80 = 0.0320. P(spam) = 0.0550/(0.0320 + 0.0550) = 0.6322.
3	0.632 > 0.5: se bloquea. Con solo «urgente»: 0.20 × 0.50 = 0.10 y 0.80 × 0.05 = 0.04 → 0.7143: también se bloquea y con más certeza, porque la ausencia de enlace (más frecuente en legítimos) baja la probabilidad de spam.

Bloque 2

#	Solución
1	Sin suavizar: 0/60 = 0 y el producto de spam vale 0 (la probabilidad de spam sería 0 aunque otras señales indiquen spam). Con α = 1: (0 + 1)/(60 + 2) = 0.0161.
2	α = 1: (4 + 1)/(240 + 2) = 0.0207; α = 0.5: (4 + 0.5)/(240 + 1) = 0.0187. El suavizado cambia poco una señal con conteos grandes.
3	Con α = 1: urgente 31/62 = 0.500 y 13/242 = 0.0537; sin enlace 1 − 28/62 = 0.5484 y 1 − 49/242 = 0.7975. s1 = 0.2 × 0.500 × 0.5484 × 0.0161 = 0.000884; s0 = 0.8 × 0.0537 × 0.7975 × 0.0207 = 0.000708. P(spam) = 0.5554.

Bloque 3

#	Solución
1	x_1 = 12: clase 0 → 0.1210; clase 1 → 0.1065. x_2 = 1.5: clase 0 → 0.4839; clase 1 → 0.2420.
2	q_0 = 0.6 × 0.1210 × 0.4839 = 0.0351; q_1 = 0.4 × 0.1065 × 0.2420 = 0.0103. P(clase 1) = 0.2268.
3	Una columna 0/1 con media 0.05 tiene desviación 0.22: un valor 1 queda a (1 − 0.05)/0.22 ≈ 4.3 desviaciones; la altura es minúscula y arrastra el producto hacia la otra clase. Además la altura no es una probabilidad (puede ser mayor que 1) y la columna no es normal: Bernoulli es la variante natural.

Bloque 4

#	Solución
1	500 × $\log_{10}(0.1)$ = −500: el producto es 1e−500, menor que el mínimo ≈ 1e−308: en doble precisión se redondea a 0 y el cociente s1/(s0 + s1) queda 0/0.
2	log-odds = ln s1 − ln s0 = -812.4 − (-815.1) = 2.7; P(spam) = 1/(1 + e^(−2.7)) = 0.9370.
3	Porque ln(s1/s0) = ln s1 − ln s0: la razón de productos es una diferencia de sumas de logaritmos; solo hace falta exponenciar el resultado final, que ya es moderado.

Bloque 5

#	Solución
1	1 copia: 0.7/(0.7 + 0.3) = 0.7000. 2 copias: 0.49/(0.49 + 0.09) = 0.8448.
2	3 copias: 0.343/(0.343 + 0.027) = 0.9270. La información nueva es nula: las copias son la misma señal.
3	El modelo cuenta tres veces la misma evidencia (independencia falsa) y se vuelve más seguro sin motivo; sobreajustar sería ajustar el ruido de la muestra de entrenamiento.

Bloque 6

#	Solución
1	Ambos modelos ordenan 1, 2, 3, 4, 5, 6 (el orden de las probabilidades coincide, porque Naive Bayes aquí es una transformación creciente de la logística). Pares spam–legítimo: 3 × 3 = 9; mal ordenado: el correo 3 (legítimo, 0.60) supera al 4 (spam, 0.55) → 8 de 9 bien: AUC = 0.8889 en los dos.
2	Logística: −media[ln 0.90, ln 0.75, ln 0.40, ln 0.55, ln 0.70, ln 0.90] = 0.3949. Naive Bayes: 0.3379. La logística es mejor: Naive Bayes es más seguro y el error (correo 3, correo 4) se castiga mucho más.
3	Para ordenar, cualquiera (mismo AUC); para estimar costos esperados o fijar un umbral por costo, el de mejores probabilidades (menor log loss y mejor calibración), o recalibrar el Naive Bayes.

Bloque 7

#	Solución
1	Se bloquea si $3(1 - p) < p$, es decir $p > 3/4 = 0.75$. Supone que las probabilidades están calibradas y que los costos son los dados.
2	Costo por 1000 = 1000 (3 FP + FN)/500: 0.50 → 340; 0.75 → 290; 0.90 → 328. El menor es el de 0.75.
3	Si coincide con el teórico (0.75), las probabilidades están razonablemente calibradas; si el óptimo se desplaza (como pasa con Naive Bayes sobreconfiado), hay que revisar la calibración. Antes de usarlo: afinar la rejilla de umbrales en OOF, probar una vez en un conjunto aparte y comprobar la prevalencia.